VAR 모형 요약 정리 — Part 1

Oct 10, 2026 · @Keehong Rhee

한눈에 보기

VAR(Vector Autoregression, 벡터자기회귀)는 여러 시계열을 한 시스템으로 묶어, 각 변수가 **모든 변수의 과거**에 반응하도록 만든 모형이다. Part 1의 결론은 세 줄로 요약된다.

1. **VAR는 '벡터판 AR'이다.** 단변량 AR이 자기 과거만 보았다면, VAR는 다른 변수의 과거까지 본다. 그 연결은 계수 행렬의 비대각 원소(교차 효과)에 담긴다.
2. **제약은 안정성과 절약성이다.** 계수 행렬의 고유값이 모두 단위원 안에 있어야 하고, 파라미터 수가 변수 수의 제곱으로 늘어나므로 시스템을 작게 유지해야 한다.
3. **공동 모형은 새로운 질문을 연다.** 적합한 VAR로 여러 변수를 동시에 예측하고, 이어서 "누가 누구를 선행하는가(Part 2, 그레인저 인과)", "충격이 어떻게 퍼지는가(Part 3, IRF·FEVD)"를 물을 수 있다.

1. 왜 여러 시계열을 함께 모형화하는가

시장의 변수들은 서로 영향을 주고받으므로, 하나씩 따로 모형화하면 그 연결 정보를 버리게 된다. 금리는 주가를 움직이고, 유가는 항공주를 움직이며, 한 자산의 충격은 다른 자산으로 번진다.

단변량 모형이 놓치는 것

지금까지 배운 AR·ARMA·GARCH는 모두 **한 시계열을 자기 과거로만** 설명했다. 5주차 GARCH도 각 자산의 변동성을 따로 모형화했다. 그러나 포트폴리오, 헤지, 페어 트레이딩은 모두 "여러 자산이 함께 어떻게 움직이는가"에 달려 있다.

함께 모형화하면 다음 세 가지를 얻는다.

- **더 나은 예측**: 한 변수의 과거가 다른 변수의 예측을 돕는다(borrowing strength).
- **선행-후행(lead-lag) 검정**: 누가 누구를 먼저 움직이는지 통계적으로 확인할 수 있다(Part 2).
- **충격 전파 지도**: 한 변수의 충격이 시스템 전체로 어떻게 퍼지는지 추적할 수 있다(Part 3).

일상적인 예로는 단기·장기 금리, 개별 주식과 섹터 지수, 현물과 선물 가격(페어 트레이딩의 출발점)이 있다.

에피소드: "경제학자들이여, 아는 척을 멈춰라" — Christopher Sims (1980)

1970년대 거시경제학은 수백 개의 방정식으로 된 대형 구조모형(structural model)을 썼다. 이 모형들은 검증되지 않은 이론적 제약(어떤 변수가 어떤 변수를 결정한다는 가정)을 수백 개 깔고 있었다. Sims는 1980년 논문 "Macroeconomics and Reality"에서 이런 제약을 "믿기 어려운(incredible)" 가정이라고 비판했다. 이론을 사실처럼 포장했다는 것이다.

그의 대안은 단순했다.

- 모든 변수를 대칭적으로 다룬다. 이론이 특정 변수를 원인으로 지정하지 않는다.
- 각 변수가 모든 변수의 최근 과거에 의존하게 한다.
- 이 최소 가정 모형이 바로 VAR다.

VAR는 이후 실증 거시·금융의 표준 도구가 되었고, Sims는 2011년 노벨 경제학상을 받았다. 교훈은 "가정한 관계가 아니라 측정할 수 있는 관계를 모형화하라"는 것이다. 다만 VAR가 보여주는 것이 '인과'인지에 대해서는 겸손해야 한다. 이 문제는 Part 2에서 다룬다.

2. VAR(p) 모형: 벡터를 위한 AR

VAR(p)는 AR(p)의 변수 자리에 **벡터**를, 계수 자리에 **행렬**을 넣은 모형이다.

출발점: AR(p) 복습

단변량 AR(p)는 오늘 값을 자기 과거 p개 값으로 설명한다.

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

VAR(p)의 정의

k개 변수를 세로로 쌓은 벡터를 Y_t라 하면, VAR(p)는 다음과 같다.

$$\mathbf{Y}_t = \mathbf{c} + A_1 \mathbf{Y}_{t-1} + A_2 \mathbf{Y}_{t-2} + \cdots + A_p \mathbf{Y}_{t-p} + \boldsymbol{\varepsilon}_t$$

기호	크기	의미
Y_t	k×1	t시점의 k개 변수를 쌓은 벡터 (예: 주식 수익률, 섹터 수익률)
c	k×1	각 방정식의 상수항

기호	크기	의미
A_i	k×k	i번째 시차의 계수 행렬. 자기 효과와 교차 효과를 모두 담는다
ε_t	k×1	오차(충격) 벡터. 평균 0, 공분산 행렬 Σ
p	정수	시차 차수(lag order). AR(p)의 p와 같은 뜻

핵심은 **모든 변수가 모든 변수의 과거에 회귀된다**는 점이다. 변수가 하나(k=1)면 행렬이 숫자가 되어 VAR(p)는 그대로 AR(p)로 돌아간다. 그래서 VAR는 AR의 자연스러운 일반화다.

2변수 VAR(1)을 풀어 쓰면

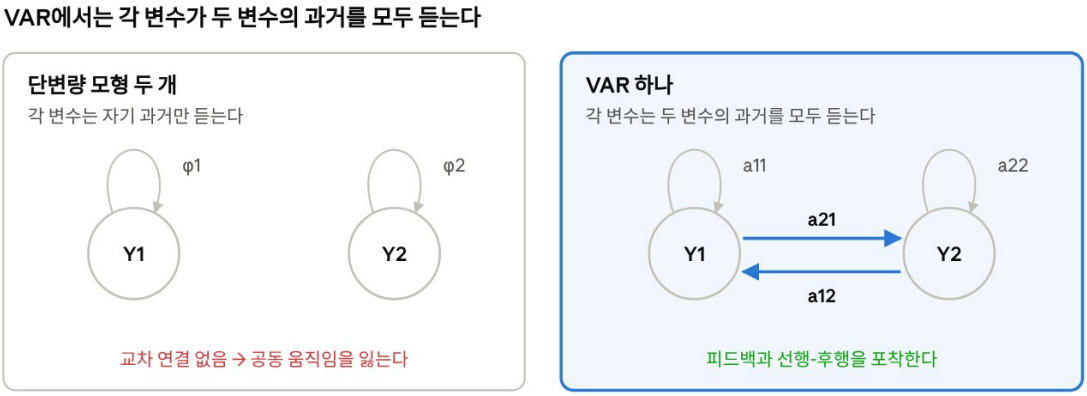
행렬 표기가 낯설면 변수 두 개, 시차 하나로 풀어 보면 된다.

$$y_{1,t} = c_1 + a_{11}\, y_{1,t-1} + a_{12}\, y_{2,t-1} + \varepsilon_{1,t}$$
$$y_{2,t} = c_2 + a_{21}\, y_{1,t-1} + a_{22}\, y_{2,t-1} + \varepsilon_{2,t}$$

같은 식을 행렬로 묶으면 다음과 같다.

$$\begin{pmatrix} y_{1,t} \\ y_{2,t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{pmatrix}$$

- 각 변수는 **자기** 직전 값(a11, a22)과 **상대** 직전 값(a12, a21)에 의존한다.
- a12 ≠ 0이면 Y2의 과거가 Y1의 예측에 도움이 된다. a21 ≠ 0이면 그 반대다.
- 이 교차항(cross-term)이 VAR를 쓰는 이유의 전부다. 교차항이 모두 0이면 서로 무관한 AR 두 개를 따로 돌린 것과 같다.



단변량 두 개 vs VAR 하나 · 자기 효과와 교차 효과

왼쪽은 자기 과거(φ)만 보는 AR 두 개, 오른쪽은 교차 화살표(a12: Y2→Y1, a21: Y1→Y2)가 더해진 VAR다. 이 두 화살표가 VAR가 단변량 모형보다 더 아는 정보다.

3. 계수 행렬 읽는 법

계수 행렬은 시스템 전체의 연결 구조를 한 장에 담은 지도다. 대각 원소는 자기 효과, 비대각 원소는 변수 사이의 상호작용이다.

$$A_1 = \begin{pmatrix} a_{11} & \overbrace{a_{12}}^{\text{cross}} \\ \underbrace{a_{21}}_{\text{cross}} & a_{22} \end{pmatrix}$$

위치	원소	뜻
대각(diagonal)	a11, a22	자기 시차 효과. 단변량 AR 계수와 같은 역할
비대각(off-diagonal)	a12, a21	교차 효과. 한 변수의 과거가 다른 변수를 움직이는 정도

읽는 요령은 세 가지다.

- **크기**: 비대각 원소가 크면 강한 선행-후행(lead-lag) 관계가 있다는 뜻이다.
- **부호**: 양(+)이면 같은 방향, 음(–)이면 반대 방향으로 영향을 준다.
- **대각 행렬**이면 상호작용이 전혀 없다. 이때 VAR는 서로 무관한 AR 모형 k개와 같다.

주의할 점이 하나 있다. 계수 행렬은 **시차를 둔(lagged)** 관계만 보여준다. 같은 시점에 함께 움직이는 관계는 오차의 공분산 Σ에 들어 있으며, 이것은 Part 3(충격의 직교화)에서 다룬다.

4. 축약형 VAR와 추정

지금까지 본 VAR는 '축약형(reduced form)'이며, 방정식마다 OLS(최소제곱법)로 추정하면 된다. 이론은 거의 넣지 않고, 추정은 놀랄 만큼 간단하다.

축약형: 데이터가 말하게 하라

축약형 VAR가 두는 가정은 "변수들이 서로의 최근 과거에 의존한다" 하나뿐이다. 이것이 Sims가 말한 최소 가정 모형이다.

- 어떤 변수도 다른 변수의 '원인'으로 지정하지 않는다.
- 방정식은 시간에 걸친 상관 구조를 기술할 뿐, 경제적 메커니즘을 주장하지 않는다.
- '진짜' 구조에 대해 의도적으로 판단을 유보한다.

대가도 있다. 데이터에 충실한 동학과 예측은 얻지만, 축약형에서 "금리 충격" 같은 인과적 충격을 바로 읽어낼 수는 없다. 그러려면 추가 가정이 필요하며, Part 3에서 다룬다.

추정: 방정식별 OLS

VAR의 모든 방정식은 **설명변수가 똑같다**(모든 변수의 시차값과 상수). 예를 들어 2변수 VAR(1)의 두 방정식은 모두 다음 설명변수를 쓴다.

$$\mathbf{x}_t = (1,\ y_{1,t-1},\ y_{2,t-1})^\top$$

설명변수가 같으면 방정식을 하나씩 OLS로 추정한 결과가 시스템 전체를 한꺼번에 추정한 결과와 일치한다(SUR 이론의 결과). 그래서 방정식별 OLS가 효율적인 추정법이 된다.

추정 결과로 두 가지를 얻는다.

1. 계수 행렬 A_1, ..., A_p와 상수 c
2. 잔차의 공분산 행렬 Σ

$$\hat{\Sigma} = \frac{1}{T}\sum_{t=1}^{T} \hat{\boldsymbol{\varepsilon}}_t \hat{\boldsymbol{\varepsilon}}_t^{\top} = \begin{pmatrix} \hat{\sigma}_1^2 & \hat{\sigma}_{12} \\ \hat{\sigma}_{12} & \hat{\sigma}_2^2 \end{pmatrix}$$

Σ의 비대각 원소 σ12는 두 변수의 충격이 **같은 시점에** 함께 오는 정도다. 이것이 0이 아니면 "Y1만 충격을 준다"는 실험이 불가능해지며, Part 3의 출발점이 된다. 실무에서는 statsmodels 같은 소프트웨어가 시스템 전체를 한 번에 적합한다.

5. 안정성 조건과 정상성 전제

VAR는 동반 행렬(companion matrix)의 고유값이 모두 단위원 안(절댓값 < 1)에 있을 때만 안정적이다. 이것은 단변량의 단위근 조건 |φ| < 1을 다변량으로 옮긴 것이다.

직관: 충격은 매기 A를 곱하며 전달된다

VAR(1)에서 오늘 들어온 충격 ε_t가 h기 뒤 Y에 남기는 영향은 A를 h번 곱한 것이다.

$$\frac{\partial \mathbf{Y}_{t+h}}{\partial \boldsymbol{\varepsilon}_t^{\top}} = A^h$$

숫자 하나를 계속 곱할 때 그 절댓값이 1보다 작으면 0으로 줄고, 1보다 크면 폭발한다. 행렬에서 그 '크기' 역할을 하는 것이 고유값 λ다. 따라서 조건은 다음과 같다.

$$A^h \to 0 \quad (h \to \infty) \iff |\lambda_i| < 1 \ \text{ for all } i, \qquad \det(A - \lambda I) = 0$$

2×2 행렬이면 고유값을 대각합(trace)과 행렬식(det)으로 바로 구할 수 있다.

$$\lambda = \frac{\operatorname{tr}(A) \pm \sqrt{\operatorname{tr}(A)^2 - 4\det(A)}}{2}$$

예를 들어 A = [[0.5, 0.3], [0.1, 0.4]]이면 tr = 0.9, det = 0.17이고 고유값은 0.63과 0.27이다. 둘 다 1보다 작으므로 안정적이다.

시차가 여러 개면: 동반 행렬

VAR(p)는 시차를 쌓아 VAR(1) 형태로 바꾼 뒤 같은 조건을 확인한다. p = 2라면 다음과 같다.

$$\underbrace{\begin{pmatrix}\mathbf{Y}_t\\ \mathbf{Y}_{t-1}\end{pmatrix}}_{\boldsymbol{\xi}_t} = \underbrace{\begin{pmatrix}A_1 & A_2\\ I & 0\end{pmatrix}}_{F\ \text{(companion)}} \begin{pmatrix}\mathbf{Y}_{t-1}\\ \mathbf{Y}_{t-2}\end{pmatrix} + \begin{pmatrix}\mathbf{c}+\boldsymbol{\varepsilon}_t\\ \mathbf{0}\end{pmatrix}$$

아래 블록 [I 0]은 "어제 값을 한 칸 밀어 둔다"는 항등식일 뿐이다. 이 F의 고유값이 모두 단위원 안에 있으면 VAR(p)는 안정적이다.

왜 중요한가

	안정적 VAR	불안정 VAR
고유값	모두 단위원 안	하나라도 단위원 위·밖
충격	시간이 지나면 사라진다	증폭된다
경로	일정한 평균 주위에서 등락 (정상)	시스템 전체가 폭발 (단위근과 같음)
예측·IRF	믿을 수 있다	쓸 수 없다

그래서 예측이나 IRF를 보기 전에 **안정성부터 확인**해야 한다.

정상성이 먼저다

ARMA와 마찬가지로 표준 VAR는 정상(stationary) 시계열을 입력으로 가정한다. 준비 과정은 다음과 같다.

1. 각 시계열에 단위근 검정(2주차, ADF 등)을 한다.
2. 추세가 있는 시계열은 차분해 수익률·증가율로 바꾼다. 가격이면 로그수익률을 쓴다.
3. 정상화된 시계열로 VAR를 적합한다.

$$r_t = \ln P_t - \ln P_{t-1} \qquad (\text{가격 수준 } P_t\text{대신 수익률 } r_t\text{를 VAR에 넣는다})$$

예외가 하나 있다. 두 I(1) 시계열이 공적분(cointegration) 관계라면 장기적으로 묶여 있으므로, 차분하면 그 장기 관계 정보를 잃는다. 이 경우는 벡터오차수정모형(VECM)이 따로 필요하며 7주차에서 다룬다.

6. 시차 p 선택과 차원의 저주

시차 p는 정보기준(AIC·BIC·HQ)이 가장 작은 값으로 고르되, 파라미터가 변수 수의 제곱으로 늘어나므로 p와 k를 모두 작게 유지해야 한다.

정보기준: 적합도와 복잡도의 저울

시차를 늘리면 잔차는 항상 줄지만, 추정할 파라미터도 늘어 과적합 위험이 커진다. 정보기준은 "잔차가 얼마나 작은가"와 "파라미터를 얼마나 썼는가"를 한 숫자로 저울질한다.

$$\mathrm{AIC}(p) = \ln|\hat{\Sigma}_p| + \frac{2}{T}\,pk^2$$

$$\mathrm{BIC}(p) = \ln|\hat{\Sigma}_p| + \frac{\ln T}{T}\,pk^2$$

$$\mathrm{HQ}(p) = \ln|\hat{\Sigma}_p| + \frac{2\ln\ln T}{T}\,pk^2$$

- 첫 항 ln|Σ̂_p|는 잔차 공분산 행렬의 행렬식(로그)으로, 적합이 좋을수록 작아진다.
- 둘째 항은 벌점이다. 시차 하나를 늘리면 계수가 k^2개 늘어난다.
- 값이 **작을수록** 좋다. 여러 p로 적합해 보고 최솟값의 p를 고른다.
- 표본이 8개 이상이면 ln T > 2이므로 BIC 벌점이 AIC보다 무겁다. 그래서 BIC는 더 짧은 시차를 고르는 경향이 있다. 둘이 다르면 BIC의 단순한 모형이 표본 밖 예측에서 더 안정적인 경우가 많다.
- 선택 후에는 잔차에 자기상관이 남지 않았는지 확인한다. 남아 있으면 시차가 부족한 것이다.

차원의 저주: 파라미터는 k^2으로 늘어난다

상수항 k개에 시차마다 k×k 행렬이 하나씩 붙으므로, 추정할 파라미터 수는 다음과 같다.

$$\#\text{params} = \underbrace{k}_{\text{constants}} + \underbrace{p\,k^2}_{\text{coefficient matrices}}$$

변수 수 k	p = 1	p = 2	p = 4
2	6	10	18
3	12	21	39
5	30	55	105

변수 수 k	p = 1	p = 2	p = 4
10	110	210	410

변수를 두 배로 늘리면 계수는 대략 네 배가 된다. 변수 10개, 시차 4개면 410개를 추정해야 하는데, 월간 데이터 10년치(T = 120)로는 방정식당 관측치 120개로 계수 41개를 맞추는 셈이다. 그래서 VAR는 **작고 낮은 차수**로 유지한다. 절약성(parsimony)은 단변량보다 훨씬 중요하다.

7. VAR로 예측하기

VAR 예측은 행렬 곱셈 한 번으로 모든 변수를 동시에 한 기 앞으로 밀고, 그 예측값을 다시 넣어 반복하는 것이다.

한 기 앞 예측

마지막으로 관측된 모든 변수의 값을 넣으면 된다. 오차의 기댓값은 0이므로 빠진다.

$$\hat{\mathbf{Y}}_{t+1|t} = \mathbf{c} + A_1\mathbf{Y}_t + A_2\mathbf{Y}_{t-1} + \cdots + A_p\mathbf{Y}_{t-p+1}$$

여러 기 앞 예측: 반복(iterate)

h > 1이면 아직 관측되지 않은 값 자리에 앞 단계의 예측값을 넣는다. VAR(1)이면 다음과 같다.

$$\hat{\mathbf{Y}}_{t+h|t} = \mathbf{c} + A\,\hat{\mathbf{Y}}_{t+h-1|t}$$

안정적 VAR라면 h가 커질수록 예측은 장기 평균으로 수렴한다. 장기 평균은 μ = c + Aμ를 풀어 얻는다.

$$\mu = (I - A)^{-1}c$$

예측 구간은 함께 넓어진다

h기 앞 예측오차의 공분산은 그동안 쌓인 충격들의 합이다.

$$\Sigma(h) = \sum_{i=0}^{h-1} A^i \Sigma \left(A^i\right)^\top$$

항이 하나씩 더해지므로 구간은 지평이 길어질수록 넓어진다. 안정적이면 A^i가 0으로 줄어 구간도 일정 폭에서 멈춘다. 이 식에 Σ의 비대각 원소가 들어가므로, 두 변수의 구간은 **함께(jointly)** 움직인다.

공동 예측이 좋은 이유

- 각 변수의 예측이 다른 변수의 최근 움직임을 활용한다.
- 추정한 교차 동학을 지키는, 서로 일관된 예측이 나온다.
- 모든 변수를 한 번에 예측한다.

8. VAR 작업 흐름 5단계

데이터에서 적합된 시스템까지는 다섯 단계이며, 1~4단계가 모형을 만들고 5단계가 Part 2·3의 분석이다.

1. **정상화**: 각 시계열을 단위근 검정하고, 필요하면 차분해 정상 시계열로 만든다.
2. **시차 선택**: AIC·BIC·HQ를 비교해 p를 고른다. p는 작게 유지한다.
3. **추정**: 방정식별 OLS로 A와 잔차 공분산 Σ를 얻는다.
4. **진단**: 고유값이 모두 단위원 안인지(안정성), 잔차에 자기상관이 없는지 확인한다.
5. **활용**: 공동 예측을 하고, 그레인저 인과·IRF·FEVD로 분석한다.

단변량 모형과 VAR 비교

측면	단변량 모형 따로	VAR (공동)
교차 동학	무시	비대각 계수로 포착
예측	변수마다 따로	모든 변수를 일관되게 함께
선행-후행·피드백	보이지 않음	명시적이고 검정 가능
파라미터 부담	적음	많음 (k^2에 비례)

VAR는 상호작용을 현실적으로 반영하는 대신 파라미터를 훨씬 많이 쓴다. 그래서 k와 p를 작게 유지한다.

9. 흔한 오해와 자기 점검

흔한 오해	실제
변수를 많이 넣을수록 VAR가 좋아진다	변수 하나를 늘릴 때마다 파라미터가 k^2으로 늘어난다. VAR는 작게 유지한다 (6절)
VAR는 무엇이 무엇의 원인인지 보여준다	축약형 VAR는 예측 관계를 보여줄 뿐 인과를 증명하지 않는다 (4절, Part 2)

흔한 오해	실제
가격 수준에 바로 VAR를 적합해도 된다	표준 VAR는 정상 시계열이 필요하다. 먼저 차분하거나, 공적분이면 VECM을 쓴다 (5절, 7주차)

넘어가기 전 세 질문

1. **2변수 VAR에서 비대각 계수가 0이 아니면 무슨 뜻인가?** 한 변수의 과거가 다른 변수를 예측하는 데 도움이 된다는 뜻이다.
2. **적합한 VAR가 안정적인지 어떻게 확인하는가?** 계수 행렬(시차가 여럿이면 동반 행렬)의 고유값이 모두 단위원 안에 있는지 본다.
3. **VAR에서 변수 수를 작게 유지해야 하는 이유는?** 파라미터 수 $k + pk^2$이 변수 수의 제곱으로 늘어나기 때문이다.

다음: Part 2

그레인저 인과(Granger causality)로, 한 변수의 과거가 다른 변수의 예측을 **정말로** 개선하는지 검정한다. 2절에서 본 비대각 계수 a12, a21이 통계적으로 0인지 묻는 것이 핵심이다.