그레인저 인과 요약 정리 — Part 2

Oct 10, 2026 · @Keehong Rhee

한눈에 보기

그레인저 인과(Granger causality)는 "X의 과거가 Y의 예측을 더 정확하게 만드는가"를 묻는 **예측 검정**이며, 진짜 원인-결과 관계를 증명하지는 않는다. Part 2의 결론은 세 줄이다.

1. **그레인저 인과는 예측 검정이다.** Y를 자기 과거로만 예측한 모형(제약)과 X의 과거를 추가한 모형(비제약)을 F-검정으로 비교한다. 방향은 X→Y, Y→X 두 번 따로 검정한다.
2. **진짜 인과가 아니다.** 숨은 공통 요인(교란변수), 시장의 기대, 발표 시차만으로도 예측 관계가 생긴다. 결과는 항상 "X가 Y를 예측하는 데 도움이 된다"로만 읽는다.
3. **정직하게 쓰면 정보 흐름의 지도가 된다.** 표본 밖에서 검증하고 관련 변수를 함께 통제하면, 어느 시계열이 다른 시계열보다 정보를 먼저 담는지(선행-후행) 보여준다.

1. 핵심 질문과 정의

X가 Y를 그레인저 인과한다는 것은, Y의 자기 과거만 쓸 때보다 X의 과거까지 쓸 때 Y의 예측오차가 **확실히 작아진다**는 뜻이다. 그 이상도 이하도 아니다.

Part 1에서 이어지는 질문

Part 1의 VAR는 각 시계열을 다른 시계열의 과거와 잇는 비대각 계수(교차 효과)를 추정했다. 이제 그 연결이 통계적으로 실재하는지 묻는다.

- 먼저 Y를 자기 과거만으로 가장 잘 예측한다.
- 여기에 X의 과거를 더한다. 예측이 좋아지는가?
- 좋아진다면 X는 Y의 미래에 대한 정보를 담고 있다. 즉 예측의 의미에서 X가 Y를 **선행**한다.

이 아이디어는 Clive Granger(1969)가 제시했고, 그는 2003년 노벨 경제학상을 받았다. 이론을 깔지 않고 두 예측의 오차만 비교하므로 표준 통계 검정으로 바로 바꿀 수 있다.

정의: 예측오차로 쓴 문장

MSE(평균제곱오차, mean squared error)는 예측이 평균적으로 얼마나 빗나가는지를 재는 척도다. Y_{<t}는 "t 이전까지의 Y 전체"를 뜻한다.

$$X \text{ Granger-causes } Y \iff \mathrm{MSE}(Y_t \mid Y_{<t},\, X_{<t}) < \mathrm{MSE}(Y_t \mid Y_{<t})$$

- 왼쪽은 두 시계열의 과거를 모두 쓴 예측오차, 오른쪽은 Y의 과거만 쓴 예측오차다.
- X를 더해 오차가 **엄격히** 줄면 X가 Y를 그레인저 인과한다.
- 여기서 '인과(cause)'는 "예측에 도움이 된다"는 뜻일 뿐이다. 이름은 역사적 관례이며, 5절에서 보듯 오해를 부른다.

VAR 계수로 다시 쓰면

VAR 안에서 그레인저 인과는 특정 비대각 계수들이 모두 0인지의 문제가 된다. 2변수 VAR(p)에서 Y1 방정식에 들어간 Y2의 시차 계수가 a12다(시차 i마다 a12^(i)).

$$\text{2변수 VAR}(p): \quad Y_2 \not\Rightarrow Y_1 \iff a_{12}^{(1)} = a_{12}^{(2)} = \cdots = a_{12}^{(p)} = 0$$

즉 "Y2가 Y1을 그레인저 인과하지 않는다"는 "Y1 방정식에서 Y2의 과거 계수가 시차 1부터 p까지 모두 0"과 같은 말이다. Part 1에서 "교차항이 VAR의 핵심"이라고 한 바로 그 계수를 검정하는 것이다.

2. 검정 방법: 제약 모형 vs 비제약 모형

검정은 두 회귀식의 잔차를 비교하는 F-검정이다. X의 시차를 넣었을 때 잔차가 우연으로 보기 어려울 만큼 줄면, X가 Y를 그레인저 인과한다고 판단한다.

두 개의 회귀식

$$\text{제약 모형 (R):} \quad Y_t = c + \sum_{i=1}^{p} a_i\, Y_{t-i} + u_t$$

$$\text{비제약 모형 (U):} \quad Y_t = c + \sum_{i=1}^{p} a_i\, Y_{t-i} + \sum_{i=1}^{p} b_i\, X_{t-i} + \varepsilon_t$$

제약 모형은 "X의 계수 b가 모두 0"이라는 제약을 건 모형이다. 비제약 모형은 그 제약을 푼 모형이다. 따라서 귀무가설은 다음과 같다.

$$H_0 : \ b_1 = b_2 = \cdots = b_p = 0 \qquad (X\text{의 과거는 Y 예측에 아무것도 더하지 않는다})$$

여러 시차를 하나씩 따로 보지 않고 **한꺼번에(jointly)** 검정한다. 개별 b가 작아 보여도 함께 보면 의미 있을 수 있기 때문이다.

F-통계량

RSS(잔차제곱합, residual sum of squares)는 모형이 설명하지 못한 오차의 크기다. 변수를 더하면 RSS는 항상 줄어들므로, "줄어든 양이 우연 이상인가"를 F-통계량으로 판단한다.

$$F = \frac{(\mathrm{RSS}_R - \mathrm{RSS}_U)/q}{\mathrm{RSS}_U/(T-k)} \ \sim \ F(q,\, T-k)$$

기호	의미
RSS_R, RSS_U	제약·비제약 모형의 잔차제곱합. 항상 RSS_U ≤ RSS_R
q	제약의 개수 = 0으로 묶은 X의 시차 수(보통 p)
T	관측치 수
k	비제약 모형의 추정 계수 수(상수 1 + Y 시차 p + X 시차 p)

분자는 "X의 시차 하나가 줄여 준 오차", 분모는 "자유도 하나당 남은 잡음"이다. 분자가 분모보다 충분히 크면 X가 잡음 이상으로 기여한 것이다. F가 F(q, T−k) 분포의 5% 임계값을 넘으면 귀무가설을 기각한다.

결과 예시: 섹터 지수(X)가 개별 주식(Y)을 예측하는지 시차 2개, 관측치 100개로 검정했더니 RSS가 52에서 45로 줄었고 F = 7.39였다. 5% 임계값 3.09를 크게 넘으므로 "섹터가 주식을 그레인저 인과한다". 계산 과정은 연습(practice) 자료에 있다.

판정

- **기각**: X의 과거가 Y 예측에 기여한다 → X는 Y를 그레인저 인과한다.
- **기각 실패**: X는 Y의 자기 과거 이상으로 더해 주는 것이 없다.

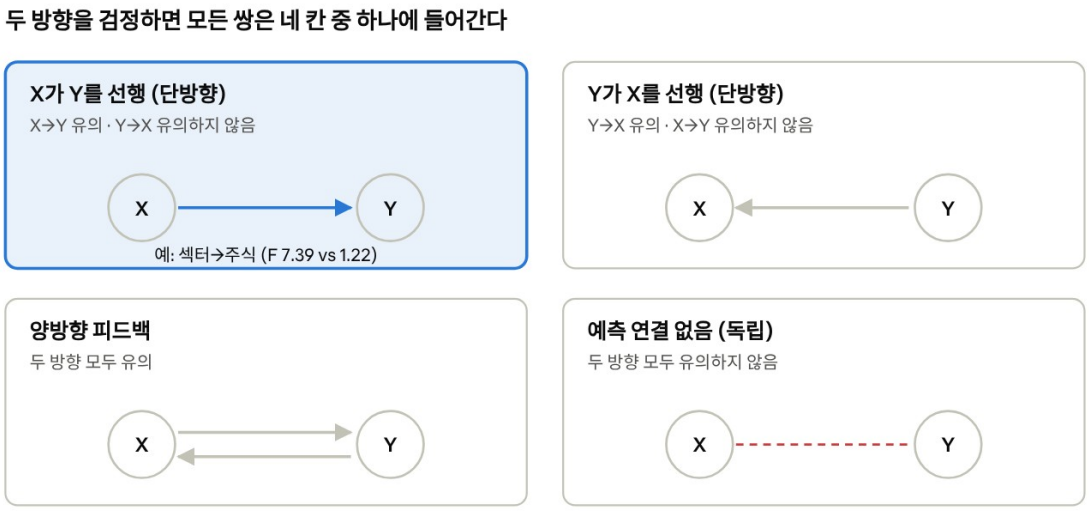
5단계 절차

1. **정상화**: X와 Y를 차분해 정상 시계열로 만든다(Part 1). 비정상 시계열에서는 F-분포가 맞지 않아 가짜 유의성이 나온다.
2. **시차 선택**: VAR의 시차 차수 p를 그대로 쓰고, 두 변수에 같은 p를 둔다.
3. **두 모형 추정**: 제약 모형과 비제약 모형을 각각 OLS로 적합한다.
4. **F-검정**: X의 시차 계수가 모두 0인지 결합 검정한다.
5. **역방향 검정**: X와 Y의 역할을 바꿔 다시 검정한다. X→Y와 Y→X는 **별개의 질문**이며 답도 다를 수 있다.

결과 예시를 이어가면, 역방향(주식이 섹터를 예측하는가)은 F = 1.22로 3.09에 못 미쳐 유의하지 않았다. 따라서 이 쌍은 "X→Y 단방향"이다.

3. 네 가지 결과

두 방향을 따로 검정하면 각 방향은 유의하거나 유의하지 않다. 그 두 답의 조합으로 모든 쌍은 네 가지 중 하나에 들어간다.



그레인저 검정의 네 가지 결과

- **단방향(X→Y 또는 Y→X)**: 예측의 의미에서 분명한 선행 순서가 있다. 앞의 섹터-주식 예가 여기 속한다.
- **양방향 피드백**: 서로의 과거가 서로를 예측한다. 금리와 주가처럼 영향을 주고받는 쌍에서 나타난다.
- **독립**: 어느 쪽도 상대의 예측에 더해 주는 것이 없다. 단, 같은 시점의 연결(5절의 동시적 인과)은 남아 있을 수 있다.

4. 가장 중요한 경고: 그레인저 인과는 진짜 인과가 아니다

"X가 Y를 그레인저 인과한다"는 "X의 과거가 Y를 예측한다"는 뜻이지 "X가 Y를 일어나게 한다"는 뜻이 아니다. 이름이 검정보다 훨씬 많은 것을 약속하기 때문에 여러 세대의 연구자가 오해해 왔다.

증명하는 것	증명하지 못하는 것
X의 과거에 Y의 미래에 대한 정보가 있다	X를 바꾸면(개입하면) Y가 바뀐다
시간 순서가 있는 방향성 있는 예측 관계	그 뒤에 어떤 인과 메커니즘이 있다
예측과 후보 변수 선별(screening)에 쓸 수 있는 신호	숨은 제3의 변수가 둘을 함께 움직이지 않는다

예측과 인과가 갈라지는 세 경로

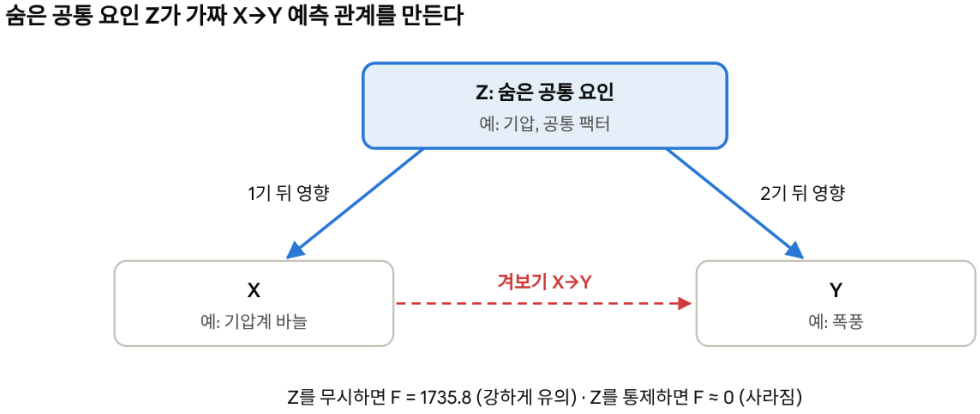
1. **교란변수(confounder)**: 숨은 공통 요인 Z가 X와 Y를 서로 다른 시차로 움직인다.
2. **기대(expectations)**: 시장은 미래를 미리 가격에 반영한다. 그래서 겉보기 선행-후행이 실제 인과 방향과 거꾸로 나올 수 있다. 예를 들어 주가는 경기를 "그레인저 인과"하지만, 주가가 경기를 만드는 것이 아니라 경기 전망을 먼저 반영할 뿐이다.
3. **타이밍 착시**: 표본 추출 간격이나 발표 지연(reporting delay) 때문에 동시에 일어난 일이 시차를 두고 관측된다.

교란변수가 가짜 연결을 만드는 원리

가장 단순한 예를 보자. Z가 X에는 1기 뒤, Y에는 2기 뒤에 영향을 준다고 하자.

$$X_t = Z_{t-1} + u_t, \qquad Y_t = Z_{t-2} + v_t \quad \Longrightarrow \quad X_{t-1} \approx Z_{t-2} \text{ 가 } Y_t\text{를 예측한다}$$

X와 Y 사이에는 아무 연결도 없다. 그런데 X_{t−1}은 사실상 Z_{t−2}를 담고 있으므로 Y_t를 잘 예측한다. 검정은 "X→Y"를 강하게 기각할 것이다. 강의의 시뮬레이션에서 Z를 무시하면 F = 1735.8이었지만, Z를 회귀식에 넣어 통제하자 F ≈ 0으로 사라졌다.



교란변수가 만드는 가짜 그레인저 인과

실선은 실제 영향, 점선은 검정이 찾아낸 검보기 연결이다. X가 Z에 더 빨리 반응하므로 X의 과거가 Y를 예측하지만, X와 Y 사이에는 아무 메커니즘도 없다.

기압계 이야기

기압계 바늘이 떨어지면 곧 폭풍이 온다. 기압계의 과거는 폭풍을 "그레인저 인과"한다. 그러나 기압계를 부숴도 폭풍은 막지 못한다. 숨은 원인인 기압(Z)이 둘을 함께 움직이고, 기압계가 먼저 반응할 뿐이다. 검정은 예측 정보를 정확히 찾아냈고, 그것 이상은 아니다.

금융에서도 같다. 한 자산이 다른 자산을 선행하는 것은 둘이 같은 팩터를 따라가는데 한쪽이 공통 뉴스를 더 빨리 반영하기 때문일 수 있다. 이를 인과로 보고 거래하면 팩터 구조가 바뀌는 순간 실패한다.

정직하게 읽는 법

- "X가 Y를 그레인저 인과한다" = "X의 과거가 Y를 예측한다". 거기서 멈춘다.
- 머릿속으로 "순전히 통계적인, 인과가 아닌 의미에서"를 덧붙인다.
- 인과 주장은 실험이나 신중한 식별 설계가 있을 때만 한다.

5. 동시적 인과와 블록 외생성

그레인저 인과는 **시차를 둔** 예측만 다룬다. 같은 시점의 연결은 오차 상관(동시적 인과)으로, 변수가 셋 이상이면 변수 묶음 단위(블록 외생성)로 확장한다.

동시적 인과(instantaneous causality)

두 시계열의 충격이 같은 기간 안에서 함께 움직이면, 그 연결은 계수 행렬 A가 아니라 VAR 오차의 공분산에 나타난다.

$$\text{동시적 인과} \iff \mathrm{Cov}(\varepsilon_{1,t},\, \varepsilon_{2,t}) \neq 0$$

- Part 1에서 본 잔차 공분산 행렬 Σ의 비대각 원소 σ12가 0이 아니라는 뜻이다.
- **방향이 없다.** Cov(ε1, ε2) = Cov(ε2, ε1)이므로 누가 먼저인지 데이터만으로는 알 수 없다.
- 바로 이 성질 때문에 Part 3에서 충격을 직교화(orthogonalization)하고, 그때 변수 순서라는 가정이 필요해진다.

쌍을 넘어서: 블록 외생성(block exogeneity)

변수가 셋 이상이면 X→Y만 따로 검정할 때 제3의 변수에 속기 쉽다(4절의 교란변수). 그래서 다른 변수를 함께 넣은 VAR 안에서 검정하거나, 변수 **묶음(블록)** 이 다른 묶음을 예측하는지 결합 검정한다. 변수 벡터를 두 블록 Y1, Y2로 나누면 귀무가설은 다음과 같다.

$$\mathbf{Y}_t = \begin{pmatrix} \mathbf{Y}_{1,t} \\ \mathbf{Y}_{2,t} \end{pmatrix}, \qquad H_0 :\ A_{12}^{(1)} = A_{12}^{(2)} = \cdots = A_{12}^{(p)} = \mathbf{0}$$

- A12^(i)는 i번째 시차 계수 행렬에서 "Y1 방정식 안의 Y2 계수"만 모은 부분 행렬이다.
- 이 블록이 모두 0이면 Y2 블록은 Y1 블록에 대해 그레인저 인과가 없다. 즉 Y1은 Y2에 대해 블록 외생적이다.
- 검정은 보통 왈드(Wald) 또는 우도비(LR) 검정으로, 제약 수만큼의 자유도를 갖는 χ^2 분포와 비교한다.

핵심 교훈은 "시스템에 무엇이 더 들어가야 하는가"를 항상 묻는 것이다. 적절한 변수를 넣으면 가짜 연결이 사라질 수 있다.

6. 금융 적용: 선행-후행 분석

인과 주장이 아니라 예측·선별 도구로 정직하게 쓰면, 그레인저 인과는 어느 시계열이 다른 시계열보다 정보를 먼저 담는지 보여준다. 이것이 선행-후행(lead-lag) 분석의 본질이다.

전형적인 선행-후행 패턴

- 선물 가격이 현물 가격을 선행하는 경우가 많다(거래 비용이 낮아 정보가 먼저 반영된다).

- 유동성이 큰 대형주가 관련 소형주를 선행할 수 있다.
- 일부 거시지표 발표가 섹터 수익률을 선행한다.

교차상관으로 먼저 눈으로 보기

교차상관함수(cross-correlation function, CCF)는 한 시계열을 k기 밀어 두고 다른 시계열과의 상관을 잰 것이다.

$$\rho_{XY}(k) = \mathrm{Corr}(X_{t+k},\, Y_t)\,, \qquad k<0 \text{ 에서 정점} \Rightarrow X\text{가 } Y\text{를 선행}$$

강의 그림에서는 k = −3 부근에서 상관이 0.9 가까이 정점을 찍었다. X의 3기 전 값이 Y의 현재와 가장 잘 맞는다는 뜻이다. CCF는 선행 관계를 눈으로 보여주고, 그레인저 검정은 그것을 통계적으로 확인한다.

효율적 시장의 관점

- X가 Y의 **수익률**을 안정적으로 예측한다면 트레이더가 그것을 이용하고, 그 거래가 패턴을 지운다(1주차, 효율적 시장 가설).
- 그래서 거래 가능하고 견고한 수익률의 그레인저 인과는 드물고, 찾더라도 깨지기 쉽다.
- 실제로 나타나는 곳은 고빈도(정보가 자산 사이로 퍼지는 몇 초~몇 분), 수익률보다 거래량·변동성·펀더멘털, 그리고 알려지면 사라지는 일시적 선행-후행이다.

쓰는 법

- 후보 예측변수를 고르는 선별 도구로 쓰고, 반드시 표본 밖(out-of-sample)에서 검증한다.
- 정보 흐름의 기술(description)로 쓰되, 수익 보장으로 보지 않는다.
- 경제적 논리와 함께 쓴다. 검정 결과 하나에만 기대지 않는다.

7. 상관·그레인저 인과·진짜 인과

그레인저 인과는 상관과 인과 사이에 있다. 상관에 시간 순서와 예측을 더했지만, 개입(intervention)의 근거는 주지 못한다.

성질	상관	그레인저 인과	진짜 인과
시간 순서 사용	아니오	예	예
예측력	약함·정적	정의상 있음	있음

성질	상관	그레인저 인과	진짜 인과
교란변수 배제	아니오	아니오	예(설계가 있을 때)
허용하는 해석	연관(association)	예측(forecasting)	개입(intervention)

유의한 결과가 말해 주는 것과 아닌 것

말해 주는 것	말해 주지 않는 것
이 표본에서 X의 과거가 Y 예측에 기여한다	X가 기계적인 의미에서 Y의 원인이다
시간 순서가 있는 방향성 있는 통계적 연결이 있다	그 연결이 표본 밖에서도, 앞으로도 유지된다
X는 Y 예측 모형의 후보 입력변수다	빠진 변수가 그 연결을 설명하지 않는다

바른 사용법

할 것	하지 말 것
예측·선별 도구로 쓴다	원인-결과로 읽는다
양방향을 검정하고 관련 변수를 함께 통제한다	교란변수와 시장의 기대를 무시한다
표본 밖에서 검증한 뒤에 신뢰한다	표본 안 결과가 계속된다고 가정한다

8. 흔한 오해와 자기 점검

흔한 오해	실제
그레인저 인과는 X가 Y의 원인임을 증명한다	예측 정보만 증명한다. 메커니즘은 아니다 (4절)
한 방향만 검정하면 충분하다	양방향을 모두 검정해야 단방향·피드백·독립을 구분한다 (3절)
표본 안에서 유의하면 돈이 된다	표본 밖 검증이 필요하고, 효율적 시장은 쉬운 기회를 지운다 (6절)

넘어가기 전 세 질문

1. **검정 결과 X가 Y를 그레인저 인과한다. X가 Y의 원인이라고 결론 낼 수 있는가?** 아니다. 예측 관계만 확인한 것이다.

2. **X→Y와 Y→X가 모두 유의하다. 이를 무엇이라 부르는가?** 양방향 피드백(bidirectional feedback)이다.
3. **유의했던 연결이 변수 Z를 넣자 사라졌다. 무슨 일이 일어났는가?** Z가 X와 Y를 함께 움직인 교란변수였다.

다음: Part 3

충격들이 같은 시점에 서로 얽혀 있다는 문제(5절의 동시적 인과)를 직교화로 풀고, 충격이 시스템 안에서 퍼지는 경로(IRF)와 예측오차 분산의 출처(FEVD)를 추적한다.