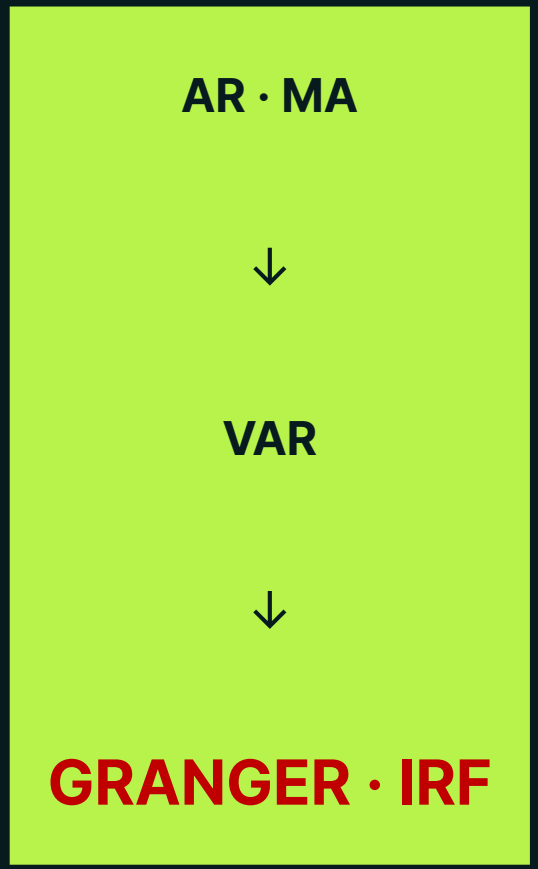
VAR 모형 입문
여러 시계열을 함께 보기

AR·MA 복습에서 VAR · 그레인저 인과 · IRF까지



Advanced Financial Time Series · Week 6

아는 모형에서 출발해 한 걸음씩 넓혀 갑니다

변수 하나(AR·MA) → 변수 여럿(VAR) → VAR로 묻는 질문 두 가지

00	복습	**AR과 MA** 과거 값과 과거 오차로 예측
01	VAR 모형	**변수 여러 개를 한꺼번에** 풀어 쓰기 · 행렬 · 첨자 · VARMA
02	그레인저 인과	**남의 과거가 도움이 되나** ADL · γ ≠ 0 · F-검정 · 사례 · 한계
03	충격반응 · 분산분해	**충격이 어떻게 퍼지나** 정의 · 손계산 예 · 직교화 · 순서

새로 배우는 것은 '변수가 여럿'이라는 것 하나뿐이다

00

AR과 MA 복습

변수 하나를 예측하는 두 가지 재료 — 과거 값과 과거 오차

AR은 자기 과거 값(시차)으로 오늘을 예측합니다

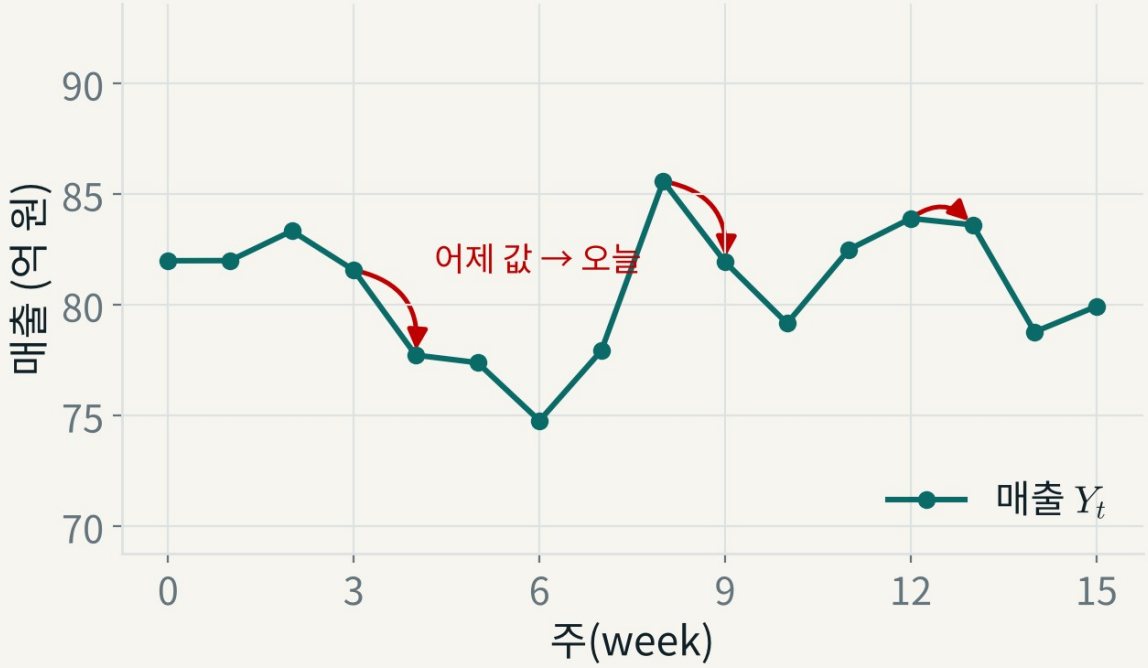
AR = AutoRegressive, 자기회귀 — 과거 값을 시차(lag)라고 부른다

AR(p) 모형

$$Y_t = \omega + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + e_t$$

읽는 법

- Y(t−1): 어제 값 = 시차 1
- φ: 가중치, e(t): 오늘의 새 오차



AR의 재료는 '내 과거 값'이다

MA는 과거 예측 오차(오차 시차)로 오늘을 예측합니다

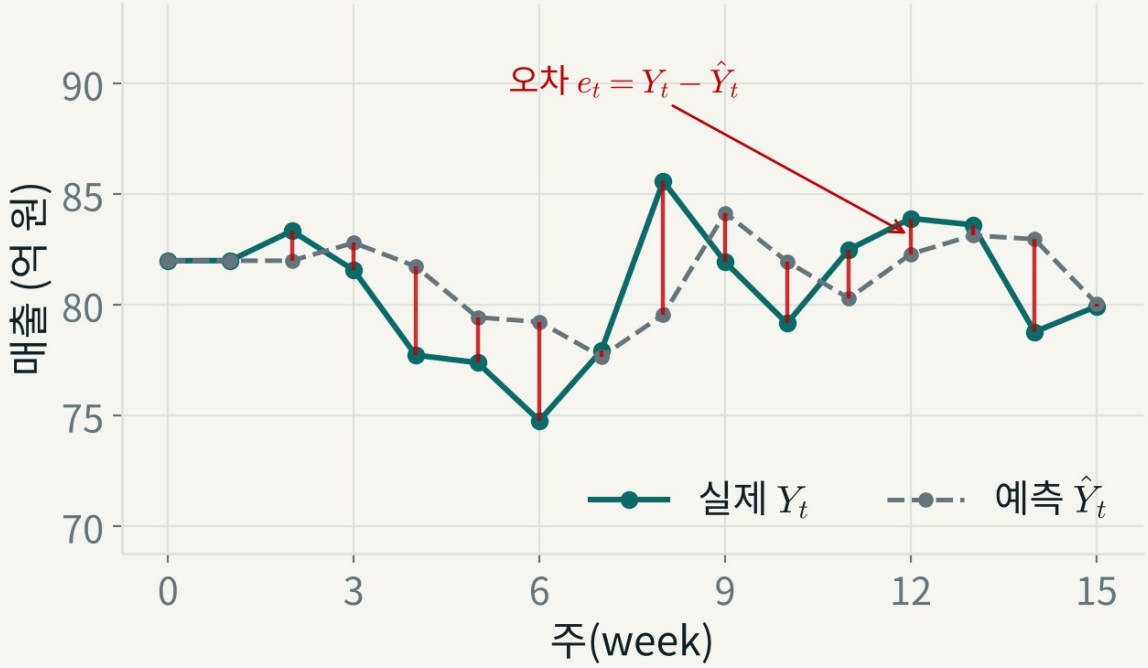
MA = Moving Average, 이동평균 모형 — 과거 오차를 오차 시차(error lag)라고 부른다

MA(q) 모형

$$Y_t = \omega + \theta_1 e_{t-1} + \theta_2 e_{t-2} + \cdots + \theta_q e_{t-q} + e_t$$

읽는 법

- 오차 = 실제 − 예측 (빨간 막대)
- 어제 빗나간 만큼 오늘 고친다



MA의 재료는 '내 과거 오차'다

ARMA는 과거 값과 과거 오차를 함께 씁니다

ARMA(p, q) = AR(p) + MA(q) — 변수 하나짜리 모형의 완성형

ARMA(p, q)

$$Y_t = \omega + \underbrace{\phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p}}_{\text{AR: past values}} + \underbrace{\theta_1 e_{t-1} + \cdots + \theta_q e_{t-q}}_{\text{MA: past errors}} + e_t$$

읽는 법

- 앞부분은 AR: 과거 값 p개
- 뒷부분은 MA: 과거 오차 q개
- e(t)는 오늘의 새 충격
- 변수가 하나일 때는 ARMA가 흔하다

이제 '변수가 하나'라는 가정을 푼다

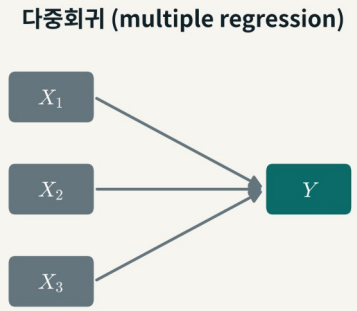
01

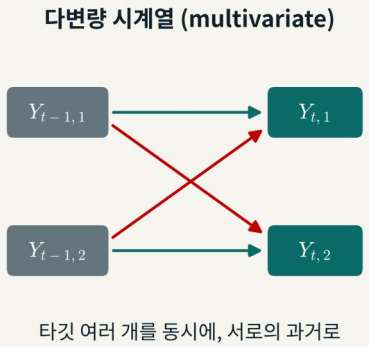
VAR 모형

Vector AutoRegressive — 여러 변수의 AR을 한꺼번에

다변량 시계열은 다중회귀가 아닙니다

multivariate ≠ multiple — 타깃(예측할 변수)이 여러 개를 동시에 예측한다





다중회귀: 타깃은 하나

$$\underbrace{Y_t}_{\text{one target}} = \beta_0 + \beta_1 X_{t,1} + \beta_2 X_{t,2} + \beta_3 X_{t,3} + e_t$$

VAR는 타깃이 여럿이고, 각 타깃이 모든 변수의 과거를 쓴다

변수 두 개짜리 VAR(1)을 풀어 쓰면 회귀식 두 개입니다

예: Y1 = 매출, Y2 = 광고비 — 각 식이 '자기 과거'와 '상대 과거'를 함께 쓴다

VAR(1), 변수 2개 — 풀어 쓴 형태

$$Y_{t,1} = \alpha_{0,1} + \alpha_{11,1}\, Y_{t-1,1} + \alpha_{12,1}\, Y_{t-1,2} + e_{t,1}$$
$$Y_{t,2} = \alpha_{0,2} + \alpha_{21,1}\, Y_{t-1,1} + \alpha_{22,1}\, Y_{t-1,2} + e_{t,2}$$

읽는 법

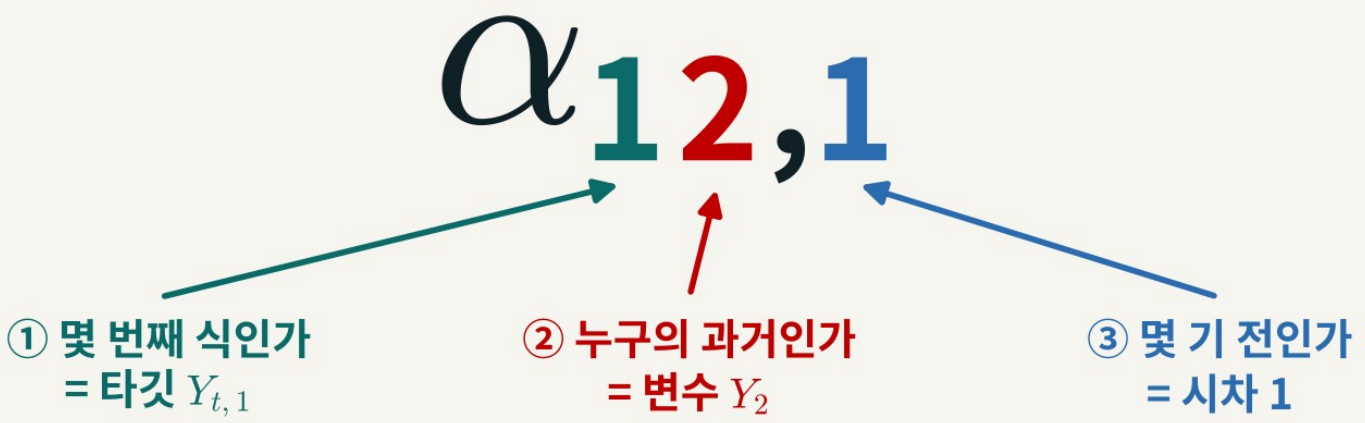
- 윗식: 오늘 매출을 어제 매출·어제 광고비로
- 아랫식: 오늘 광고비를 어제 매출·어제 광고비로
- α(0,1), α(0,2): 각 식의 절편
- e(t,1), e(t,2): 각 식의 오차

식마다 보면 그냥 회귀식이다 — 설명변수가 두 변수의 어제 값일 뿐

계수 α의 첨자는 '어느 식 · 누구의 과거 · 몇 기 전'을 뜻합니다

이 표기만 익히면 변수가 늘어도 식을 읽을 수 있다

참고: $\alpha_{0,1}$ = 1번 식의 절편



α(12,1) = 1번 식에서, 변수 2의, 1기 전 값에 붙는 계수

같은 두 식을 세로로 쌓아 행렬로 쓰면 VAR의 표준 표기가 됩니다

위의 행렬식을 곱해서 풀면 앞 장의 두 회귀식이 그대로 나온다

행렬 표기 — 덩어리마다 이름을 붙인다

$$\underbrace{\begin{bmatrix} Y_{t,1} \\ Y_{t,2} \end{bmatrix}}_{\mathbf{Y}_t} = \underbrace{\begin{bmatrix} \alpha_{0,1} \\ \alpha_{0,2} \end{bmatrix}}_{\boldsymbol{\alpha}_0} + \underbrace{\begin{bmatrix} \alpha_{11,1} & \alpha_{12,1} \\ \alpha_{21,1} & \alpha_{22,1} \end{bmatrix}}_{A_1} \underbrace{\begin{bmatrix} Y_{t-1,1} \\ Y_{t-1,2} \end{bmatrix}}_{\mathbf{Y}_{t-1}} + \underbrace{\begin{bmatrix} e_{t,1} \\ e_{t,2} \end{bmatrix}}_{\mathbf{e}_t}$$

$$\Longrightarrow \quad \mathbf{Y}_t = \boldsymbol{\alpha}_0 + A_1\,\mathbf{Y}_{t-1} + \mathbf{e}_t$$

읽는 법

- Y(t): 오늘 값을 쌓은 벡터
- α(0): 절편을 쌓은 벡터
- A1: 계수 4개를 담은 표(행렬)
- A1의 행 = 식, 열 = 누구의 과거
- e(t): 오차를 쌓은 벡터

A1은 새 개념이 아니다 — 회귀계수를 표 한 장에 모은 것이다

변수가 k개여도 모양은 같고, 행렬만 커집니다

k개 타깃 변수 — 계수 행렬 A1은 k행 k열

VAR(1), 변수 k개

$$\begin{bmatrix} Y_{t,1} \\ Y_{t,2} \\ \vdots \\ Y_{t,k} \end{bmatrix} = \begin{bmatrix} \alpha_{0,1} \\ \alpha_{0,2} \\ \vdots \\ \alpha_{0,k} \end{bmatrix} + \begin{bmatrix} \alpha_{11,1} & \cdots & \alpha_{1k,1} \\ \vdots & \ddots & \vdots \\ \alpha_{k1,1} & \cdots & \alpha_{kk,1} \end{bmatrix} \begin{bmatrix} Y_{t-1,1} \\ Y_{t-1,2} \\ \vdots \\ Y_{t-1,k} \end{bmatrix} + \begin{bmatrix} e_{t,1} \\ e_{t,2} \\ \vdots \\ e_{t,k} \end{bmatrix}$$

읽는 법

- 행 하나 = 식 하나
- 대각선: 자기 과거의 영향
- 대각선 밖: 다른 변수 과거의 영향
- 줄여 쓰면 앞 장과 똑같은 한 줄

아무리 커져도 VAR(1)은 Y(t) = α(0) + A1·Y(t−1) + e(t) 한 줄이다

시차를 p개까지 쓰면 VAR(p)가 됩니다

AR(1) → AR(p)로 넓혔던 것과 똑같이, 계수 행렬을 시차마다 하나씩 붙인다

VAR(1)

$$\mathbf{Y}_t = \boldsymbol{\alpha}_0 + A_1 \mathbf{Y}_{t-1} + \mathbf{e}_t$$

VAR(p): 시차마다 계수 행렬 Ai

$$\begin{aligned}\mathbf{Y}_t &= \boldsymbol{\alpha}_0 + \sum_{i=1}^{p} A_i \mathbf{Y}_{t-i} + \mathbf{e}_t \\ &= \boldsymbol{\alpha}_0 + A_1\mathbf{Y}_{t-1} + A_2\mathbf{Y}_{t-2} + \cdots + A_p\mathbf{Y}_{t-p} + \mathbf{e}_t\end{aligned}$$

읽는 법

- A1: 1기 전 값에 붙는 행렬
- A2: 2기 전 값에 붙는 행렬
- Ap: p기 전 값에 붙는 행렬
- Σ는 '모두 더한다'는 기호

VAR(p) = 변수 여럿 × 시차 여럿의 AR

MA 부분까지 붙이면 VARMA가 됩니다

ARMA를 다변량으로 넓힌 모형 — 과거 오차 벡터에 계수 행렬 B를 붙인다

VARMA(1, 1)

$$\mathbf{Y}_t = \boldsymbol{\alpha}_0 + \underbrace{A_1\,\mathbf{Y}_{t-1}}_{\text{VAR part}} + \mathbf{e}_t + \underbrace{B_1\,\mathbf{e}_{t-1}}_{\text{VMA part}}$$

VARMA(p, q)

$$\mathbf{Y}_t = \boldsymbol{\alpha}_0 + \sum_{i=1}^{p} A_i\,\mathbf{Y}_{t-i} + \mathbf{e}_t + \sum_{j=1}^{q} B_j\,\mathbf{e}_{t-j}$$

읽는 법

- A: 과거 값에 붙는 행렬 (VAR 부분)
- B: 과거 오차에 붙는 행렬 (VMA 부분)
- 변수 하나일 때의 ARMA와 같은 구조
- 이론상 가장 일반적인 형태

ARMA : 변수 하나 = VARMA : 변수 여럿

VARMA는 파라미터가 적지만 추정이 훨씬 어렵습니다

VAR(Vector AR)와 VARMA(Vector ARMA)의 비교

	VAR	VARMA
파라미터 수	많다 (시차를 길게 써야 예측력)	적다 (오차 항이 많이 대신함)
추정 방법	식마다 OLS · 단순 최대우도	반복 최대우도 + 편미분
계산 난이도	쉽다	어렵다 — 수렴이 안 될 수도
실무 사용	여러 변수면 대부분 VAR	드물다

변수 하나면 ARMA, 변수 여럿이면 VAR가 표준이다

변수 5개면 VAR(12)는 320개, VARMA(1,1)는 70개를 추정합니다

파라미터 = 절편 + 계수 행렬 + 오차 공분산 — VARMA 70개는 편미분 $70^2 = 4{,}900$개를 반복 계산한다

파라미터 세기

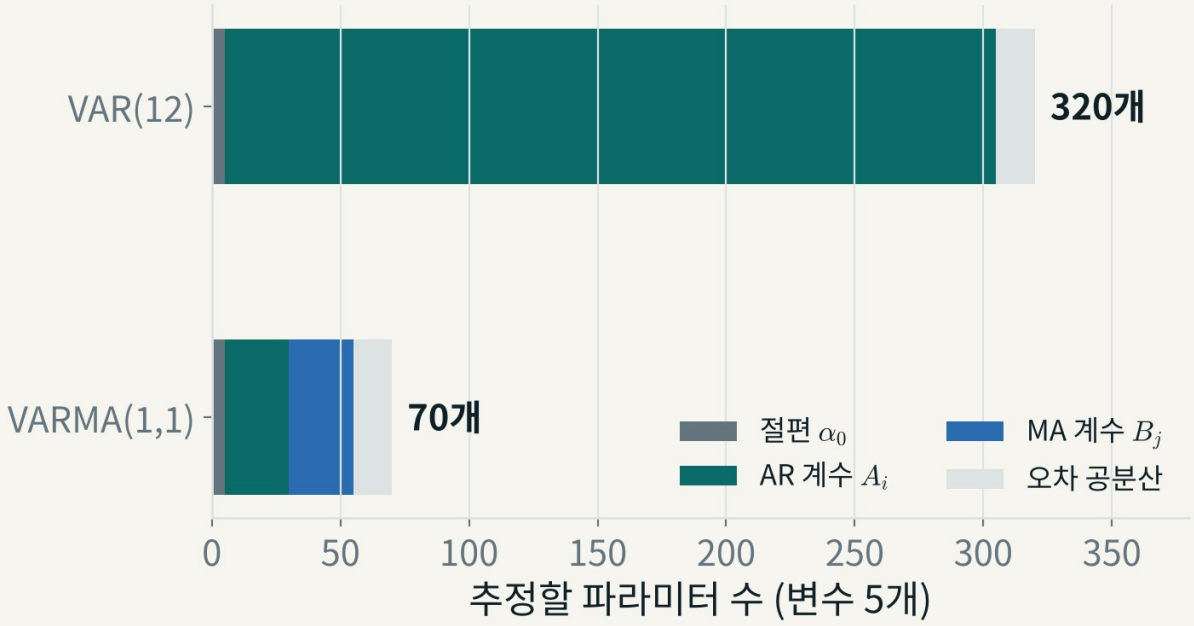
$$\text{VAR}(p): \quad \underbrace{k}_{\alpha_0} + \underbrace{p\,k^2}_{A_1,\ldots,A_p} + \underbrace{k(k+1)/2}_{\text{error cov.}}$$

$$\text{VAR}(12),\ k=5: \quad 5 + 12 \times 25 + 15 = 320$$

$$\text{VARMA}(1,1),\ k=5: \quad 5 + 25 + 25 + 15 = 70$$

읽는 법

- VARMA는 적어도 계산이 어렵다



그래서 VAR는 '변수는 적게, 시차는 정보기준으로' 고른다

시차 p는 정보기준이 가장 작은 값으로 고릅니다

잘 맞추는 것(첫 항)과 단순한 것(둘째 항)의 균형 — 시차를 늘리면 첫 항은 줄고 둘째 항은 커진다

AIC = 못 맞춘 정도 + 복잡도 벌점

$$\mathrm{AIC}(p) = \underbrace{\ln\left|\hat{\Sigma}_p\right|}_{\text{misfit} \downarrow \text{ as } p\uparrow} + \underbrace{\frac{2\,p\,k^2}{T}}_{\text{penalty} \uparrow \text{ as } p\uparrow}$$

읽는 법

- 시차를 늘리면 잘 맞추지만 복잡해진다
- 두 힘의 합이 가장 작은 p를 고른다
- BIC는 벌점이 더 커서 짧은 p를 고른다
- 소프트웨어가 p별로 계산해 준다

시차는 감이 아니라 정보기준으로 정한다

VAR는 식마다 보통 OLS로 추정하면 됩니다

모든 식의 설명변수가 똑같아서(모든 변수의 과거), 식별로 따로 회귀해도 효율적이다

1번 식 = 평범한 회귀

$$Y_{t,1} = \alpha_{0,1} + \alpha_{11,1}\, Y_{t-1,1} + \alpha_{12,1}\, Y_{t-1,2} + e_{t,1}$$

읽는 법

- 식 k개를 하나씩 OLS로
- 결과: 계수 행렬 A와 오차 공분산
- 엑셀·Python 어디서나 가능
- VARMA처럼 반복 계산이 필요 없다

VAR의 가장 큰 장점은 추정이 쉽다는 것이다

예측하기 전에, 충격이 시간이 지나며 사라지는지 확인합니다

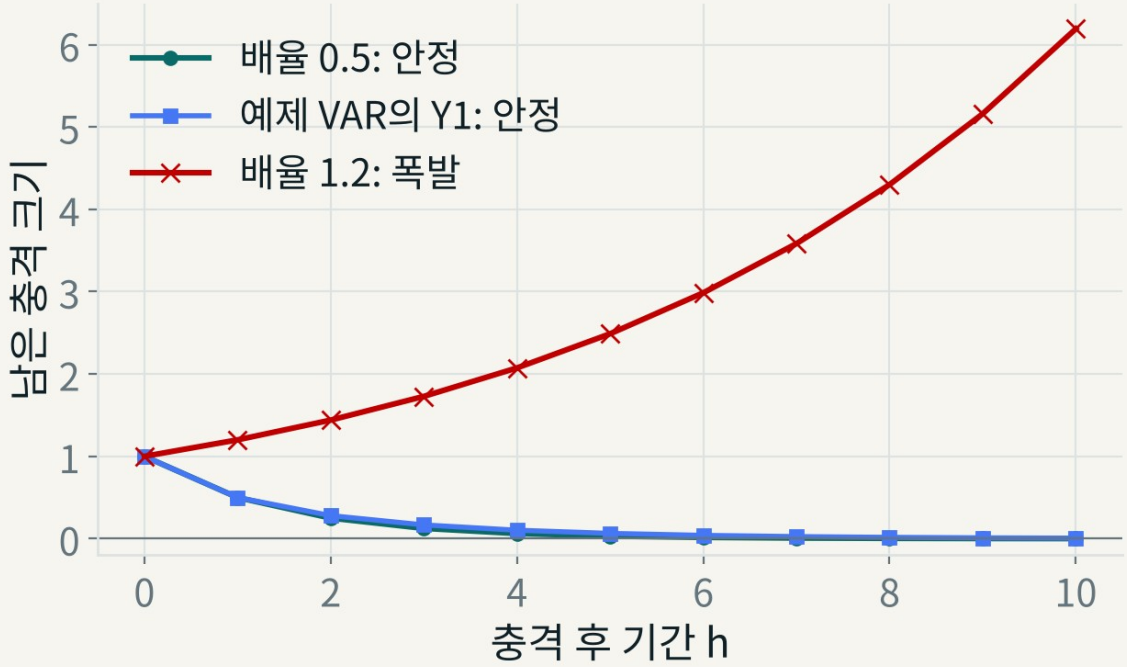
안정성(stability) — 충격에 매기 곱해지는 배율이 1보다 작아야 한다. 예측과 IRF(03부)의 전제 조건

충격이 매기 몇 배가 되나

$$0.5: \quad 1 \to 0.5 \to 0.25 \to \cdots \to 0$$
$$1.2: \quad 1 \to 1.2 \to 1.44 \to \cdots \to \infty$$

읽는 법

- 배율 < 1이면 0으로, VAR는 A1의 고유값이 배율



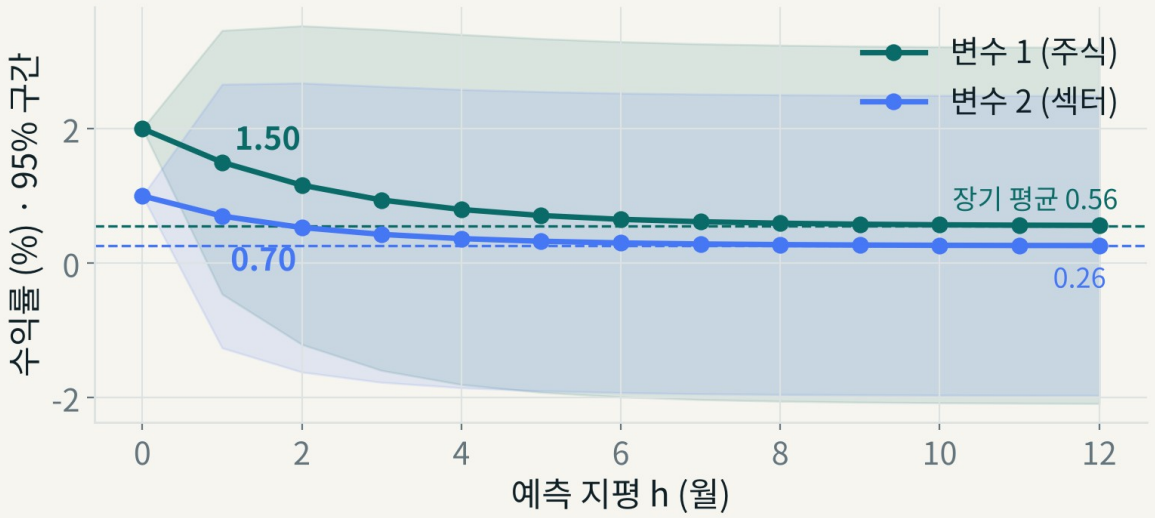
안정적이어야 예측이 평균으로 돌아오고, 충격반응이 0으로 사라진다

VAR 예측은 어제 값을 넣고 한 칸씩 앞으로 반복합니다

한 기 앞을 예측하고, 그 예측값을 다시 넣어 두 기 앞을 예측한다

반복 예측

$$\hat{\mathbf{Y}}_{t+1} = \hat{\boldsymbol{\alpha}}_0 + \hat{A}_1 \mathbf{Y}_t$$
$$\hat{\mathbf{Y}}_{t+2} = \hat{\boldsymbol{\alpha}}_0 + \hat{A}_1 \hat{\mathbf{Y}}_{t+1}$$



읽는 법

- 모든 변수를 한 번에 예측
- 멀리 갈수록 장기 평균으로 수렴

안정적인 VAR의 먼 미래 예측은 결국 평균이다

02

그레인저 인과

x의 과거가 y의 예측에 도움이 되는가

그레인저 인과는 '예측에 도움이 되는가'를 묻는 단순한 검정입니다

Granger causality — 우리가 일상에서 말하는 인과관계와는 다르다

1 · 인과는 아니다

- 일상의 인과와 다른, 인과 추측 방법

2 · 과거로 예측해 본다

- x의 과거로 y 예측이 좋아지면 인과

3 · 계산이 쉽다

- OLS 두 번이면 끝 — 널리 쓰인다

4 · 확대 해석 금지

- 결과를 원인으로 읽지 않는다

그레인저 인과 = 예측 선행 관계, 원인이 아니다

ADL 모형은 자기 과거에 다른 변수의 과거를 더해 예측합니다

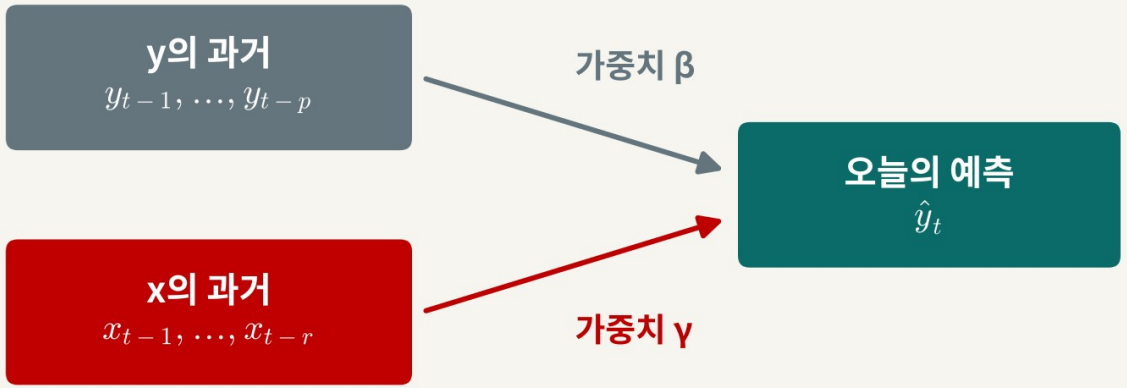
ADL(p, r) = Autoregressive Distributed Lag — 자신 이외 다른 설명변수도 포함한 시계열 모형

예측 = 두 변수 과거의 함수

$$\hat{y}_t = F\left(PY_{t-1},\ PX_{t-1}\right), \qquad \varepsilon_t = y_t - \hat{y}_t$$

읽는 법

- PY(t−1): y의 과거 전부
- 오차 ε가 과거와 무관하게 F를 고른다



AR(p)에 x의 과거 r개를 더한 것이 ADL(p, r)이다

가장 흔한 선택은 선형식이고, 추정은 그냥 OLS입니다

F를 직선(선형) 형태로 놓으면 보통의 회귀분석이 된다

선형 예측식

$$\hat{y}_t = \alpha + \underbrace{\beta_1 y_{t-1} + \cdots + \beta_p y_{t-p}}_{\text{own past}} + \underbrace{\gamma_1 x_{t-1} + \cdots + \gamma_r x_{t-r}}_{\text{past of } x}$$

ADL(p, r): 실제값 = 예측 + 오차

$$y_t = \hat{y}_t + \varepsilon_t = \alpha + \sum_{j=1}^{p} \beta_j \, y_{t-j} + \sum_{j=1}^{r} \gamma_j \, x_{t-j} + \varepsilon_t$$

읽는 법

- β: y 자신의 과거에 붙는 가중치
- γ: x의 과거에 붙는 가중치
- 오차제곱합을 최소로 → OLS
- p, r: 각각 몇 기 전까지 쓰나

ADL은 '시차가 붙은 회귀분석'일 뿐이다

두 변수 각각에 ADL을 세우고, 상대 과거의 계수 γ를 봅니다

y의 식에는 x의 과거(γ), x의 식에는 y의 과거(γ*)

ADL 두 개: y의 식과 x의 식

$$y_t = \alpha + \sum_{j=1}^{p} \beta_j \, y_{t-j} + \sum_{j=1}^{r} \gamma_j \, x_{t-j} + \varepsilon_t$$

$$x_t = \alpha^* + \sum_{j=1}^{p^*} \beta_j^* \, x_{t-j} + \sum_{j=1}^{r^*} \gamma_j^* \, y_{t-j} + \varepsilon_t^*$$

읽는 법

- γ ≠ 0 (어느 하나라도): x가 y 예측에 도움
- γ* = 0 (모두): y는 x 예측에 도움 안 됨
- 둘이 함께면 'x가 y를 그레인저 인과'
- 두 식은 각각 OLS로 추정한다

x → y 판정에는 γ ≠ 0 과 γ* = 0 이 둘 다 필요하다

ADL 두 개를 위아래로 쌓으면 2변수 VAR가 됩니다

시차 길이를 모두 p로 맞춘 경우 — ADL 하나는 VAR의 한 줄(식 하나)이다

ADL 두 개 = VAR(p)

$$\begin{bmatrix} y_t \\ x_t \end{bmatrix} = \begin{bmatrix} \alpha \\ \alpha^* \end{bmatrix} + \begin{bmatrix} \beta_1 & \gamma_1 \\ \gamma_1^* & \beta_1^* \end{bmatrix} \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} + \cdots + \begin{bmatrix} \beta_p & \gamma_p \\ \gamma_p^* & \beta_p^* \end{bmatrix} \begin{bmatrix} y_{t-p} \\ x_{t-p} \end{bmatrix} + \begin{bmatrix} \varepsilon_t \\ \varepsilon_t^* \end{bmatrix}$$

$$\text{row 1} = \text{ADL of } y, \qquad \text{row 2} = \text{ADL of } x, \qquad A_j = \begin{bmatrix} \beta_j & \gamma_j \\ \gamma_j^* & \beta_j^* \end{bmatrix} = \begin{bmatrix} \alpha_{11,j} & \alpha_{12,j} \\ \alpha_{21,j} & \alpha_{22,j} \end{bmatrix}$$

읽는 법

- β: 자기 과거 (대각선)
- γ: 상대 과거 (대각선 밖)
- 식마다 OLS로 추정
- x(t)를 넣으면 VAR 아님

그레인저 검정 = VAR의 대각선 밖 계수(γ)가 0인지 묻는 것

γ가 모두 0이라는 가설을 F-검정으로 확인합니다

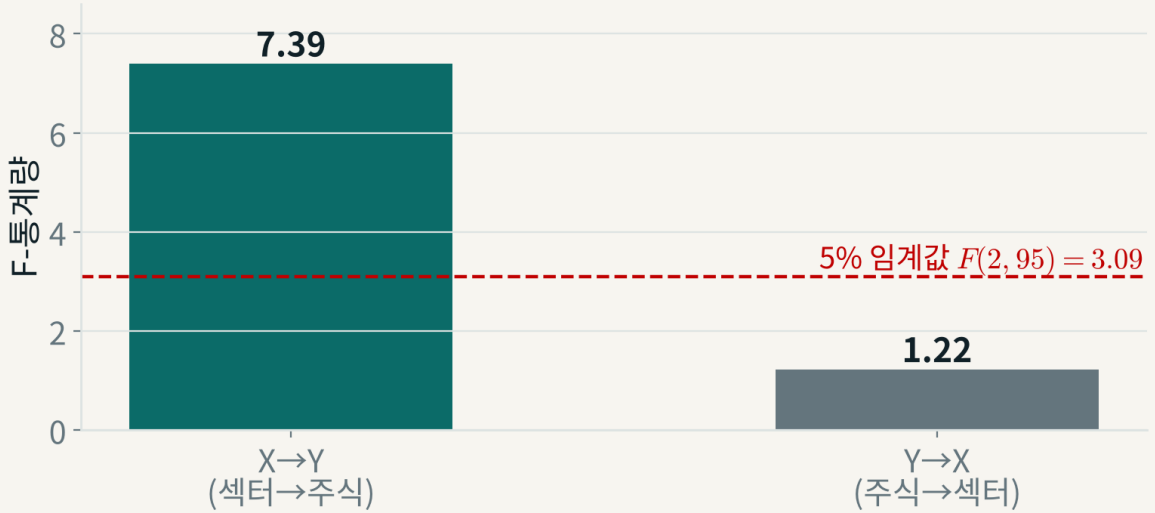
x의 과거를 넣은 식과 뺀 식의 잔차제곱합(RSS)을 비교한다

귀무가설: x는 y를 그레인저 인과하지 않는다

$$H_0 : \ \gamma_1 = \gamma_2 = \cdots = \gamma_r = 0$$

읽는 법

- F가 크면 γ = 0 기각 → 도움 된다
- 7.39 > 3.09 → 섹터가 주식을 예측
- 반대 방향 1.22 → 도움 안 됨



두 방향을 모두 검정해야 '누가 누구를 앞서나'가 보인다

F-통계량은 x를 넣어서 줄어든 잔차가 우연 이상인지 잽니다

분자: x를 넣어서 줄어든 오차, 분모: 남아 있는 오차

F-통계량

$$F = \frac{(\mathrm{RSS}_{\text{without } x} - \mathrm{RSS}_{\text{with } x})/r}{\mathrm{RSS}_{\text{with } x}/(n-p-r-1)}$$

읽는 법

- RSS: 잔차제곱합 (작을수록 잘 맞춤)
- r: 검정하는 γ의 개수
- n: 관측 수
- F > 임계값이면 γ = 0 기각

γ와 VAR 표기는 같다 — 1번 식의 변수 2 계수 α(12, j)

두 방향 검정으로 관계는 네 가지 중 하나가 됩니다

x → y와 y → x를 각각 검정한 결과의 조합

네 가지 결과

- 단방향: 한쪽이 앞선다
- 피드백: 서로를 예측한다
- 독립: 시차 관계가 없다

X → Y 단방향
X→Y 유의 · Y→X 아님



Y → X 단방향
Y→X 유의 · X→Y 아님



양방향 피드백
두 방향 모두 유의



독립
두 방향 모두 유의하지 않음



결과는 '누가 누구를 먼저 움직이나'의 지도다

응용 사례: 성장은 분배를 예측했지만, 분배는 성장을 거의 예측하지 못했습니다

신문기사 발췌 — 실질 GDP와 지니계수, 1990~2011년 연도별 자료의 그레인저 인과 검정

두 개의 ADL 결과

$$\begin{aligned} \text{Gini}_t \text{ eq.}: &\quad \gamma\ (\text{past GDP}) \neq 0 \quad \text{significant} \\ \text{GDP}_t \text{ eq.}: &\quad \gamma^*\ (\text{past Gini}) \approx 0 \quad \text{weak} \end{aligned}$$

주의해서 읽기

- 연도별 22개 — 표본이 매우 짧다
- '인과관계'라는 기사 표현은 과장



1990~2011년 연도별 자료 (신문기사 발췌)

올바른 해석: '성장의 과거가 분배 예측에 도움이 된다'까지만

그레인저 인과에는 세 가지 한계가 있습니다

검정 결과를 쓰기 전에 꼭 확인할 것

LINEARITY

선형성

- 직선 관계만 잡는다
- 비선형 관계는 놓친다

STATIONARITY

정상성

- 시계열이 정상이어야 한다
- 추세가 있으면 차분·증가율로

HIDDEN CAUSE

관측 변수 의존

- 숨은 원인 z가 x에 빨리, y에 늦게
- 그러면 x → y로 잘못 나온다

x, y의 진짜 원인이 z라면 그 그레인저 인과는 잘못된 결론이다

숨은 공통 원인 z를 넣으면 가짜 그레인저 인과가 사라집니다

기압계 바늘(x)이 폭풍(y)을 '예측'하지만 원인은 기압(z)

읽는 법

- z가 x를 먼저, y를 나중에 움직인다
- z를 빼면 x → y가 유의 (F = 1735.8)
- z를 넣으면 관계가 사라진다 (F ≈ 0)



빠뜨린 변수가 없는지가 결과의 신뢰도를 정한다

03

충격반응과 분산분해

IRF: 충격이 어떻게 퍼지나 · FEVD: 예측오차는 누구 탓인가

충격반응함수(IRF)는 충격 하나가 퍼져 나가는 경로입니다

IRF = Impulse Response Function — 연못에 돌을 던졌을 때 물결이 퍼지고 잦아드는 모습

정의: 충격이 있을 때와 없을 때의 차이

$$\mathrm{IRF}_{i \leftarrow j}(h) = Y_{t+h,\,i}\ (\text{with shock } j) - Y_{t+h,\,i}\ (\text{without shock})$$

VAR(1)에서 구하는 법 (e: 충격 벡터)

$$\text{response}(h) = A_1 \times \text{response}(h-1) = A_1^h\,\mathbf{e}$$

읽는 법

- j: 충격을 준 변수, i: 반응을 보는 변수
- h: 충격 후 몇 기가 지났나
- 충격 크기 1 → 반응도 '1당' 크기
- 매기 A1을 한 번씩 곱하면 된다

IRF = '한 변수에 충격 1을 주면 h기 뒤 각 변수는 얼마 달라지나'

IRF는 기간 h를 넣으면 반응값 하나가 나오는 '함수'입니다

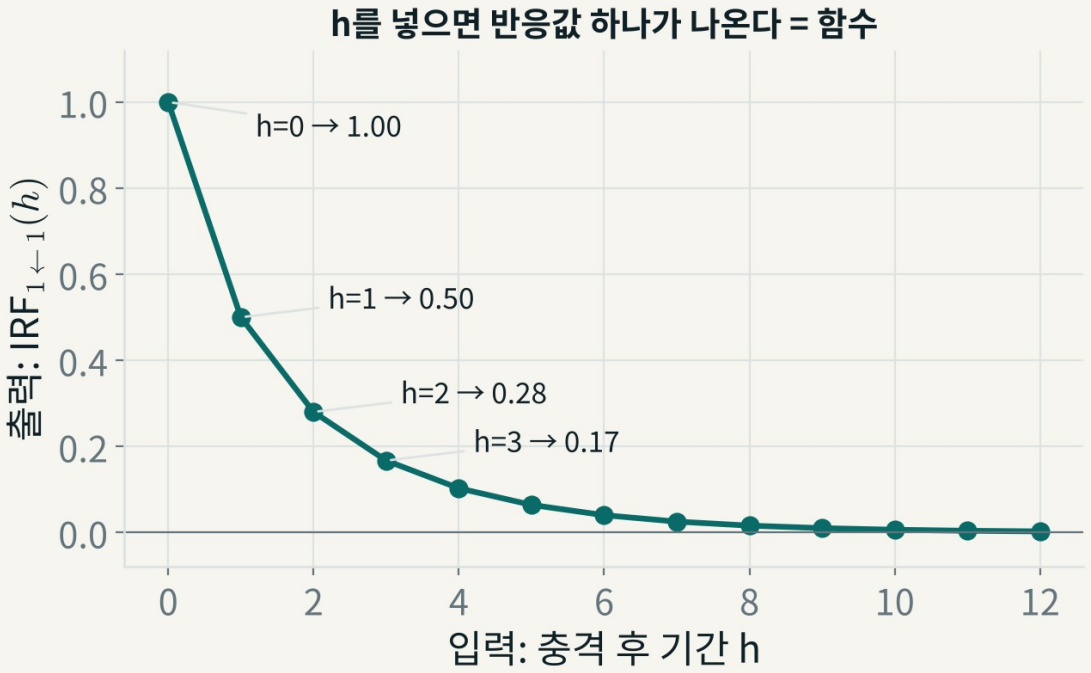
함수 = 입력 하나에 출력 하나 — 입력은 충격 후 기간 h, 출력은 그때의 반응 크기

정의: 충격 u(j)가 1 늘 때 h기 뒤 Y(i)의 변화

$$\mathrm{IRF}_{i\leftarrow j}(h) = \frac{\partial Y_{t+h,\,i}}{\partial u_{t,\,j}}, \qquad h = 0, 1, 2, \ldots$$

읽는 법

- h마다 값이 하나씩 → h의 함수
- ∂: '1 변할 때 얼마 변하나'



IRF(h)의 그래프가 곧 'IRF 그림'이다 — 그래서 '함수'라 부른다

IRF 공식: 계수 행렬을 h번 곱한 행렬의 (i, j) 칸이 반응값입니다

VAR(p)의 반응 행렬 Ψ(h)는 앞 반응들에 계수 행렬을 곱해 차례로 만든다

IRF를 구하는 공식

$$\Psi_0 = I, \qquad \Psi_h = A_1\Psi_{h-1} + A_2\Psi_{h-2} + \cdots + A_p\Psi_{h-p}$$
$$\Psi_h = A_1^h \ \ (\mathrm{VAR}(1)), \qquad \Theta_h = \Psi_h P \ \ (\mathrm{orthogonalized})$$
$$\mathrm{IRF}_{i\leftarrow j}(h) = [\Theta_h]_{ij} \ \ (\mathrm{row}\ i,\ \mathrm{column}\ j)$$

읽는 법

- Ψ: 직교화 전
- Θ: 직교화 후
- 행 i: 반응 변수
- 열 j: 충격 변수

앞 예의 손계산은 VAR(1)에서 Ψ(h) = A1의 h제곱을 구한 것이다

계수 행렬을 한 번씩 곱해 나가면 IRF가 구해집니다

예: A1 = [0.5 0.3; 0.1 0.4], Y1에 충격 1 (Y2는 0) — 행렬 곱 = 행마다 곱해서 더하기

손으로 구하는 IRF

$$h = 0: \quad \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$h = 1: \quad \begin{bmatrix} 0.5 & 0.3 \\ 0.1 & 0.4 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0.5 \times 1 + 0.3 \times 0 \\ 0.1 \times 1 + 0.4 \times 0 \end{bmatrix} = \begin{bmatrix} 0.50 \\ 0.10 \end{bmatrix}$$

$$h = 2: \quad \begin{bmatrix} 0.5 & 0.3 \\ 0.1 & 0.4 \end{bmatrix} \begin{bmatrix} 0.50 \\ 0.10 \end{bmatrix} = \begin{bmatrix} 0.5 \times 0.50 + 0.3 \times 0.10 \\ 0.1 \times 0.50 + 0.4 \times 0.10 \end{bmatrix} = \begin{bmatrix} 0.28 \\ 0.09 \end{bmatrix}$$

읽는 법

- h = 1: Y1 0.50, Y2 0.10
- h = 2: Y1 0.28, Y2 0.09
- h = 3: 0.17, 0.06 …
- Y2 반응은 교차 계수 0.1 때문

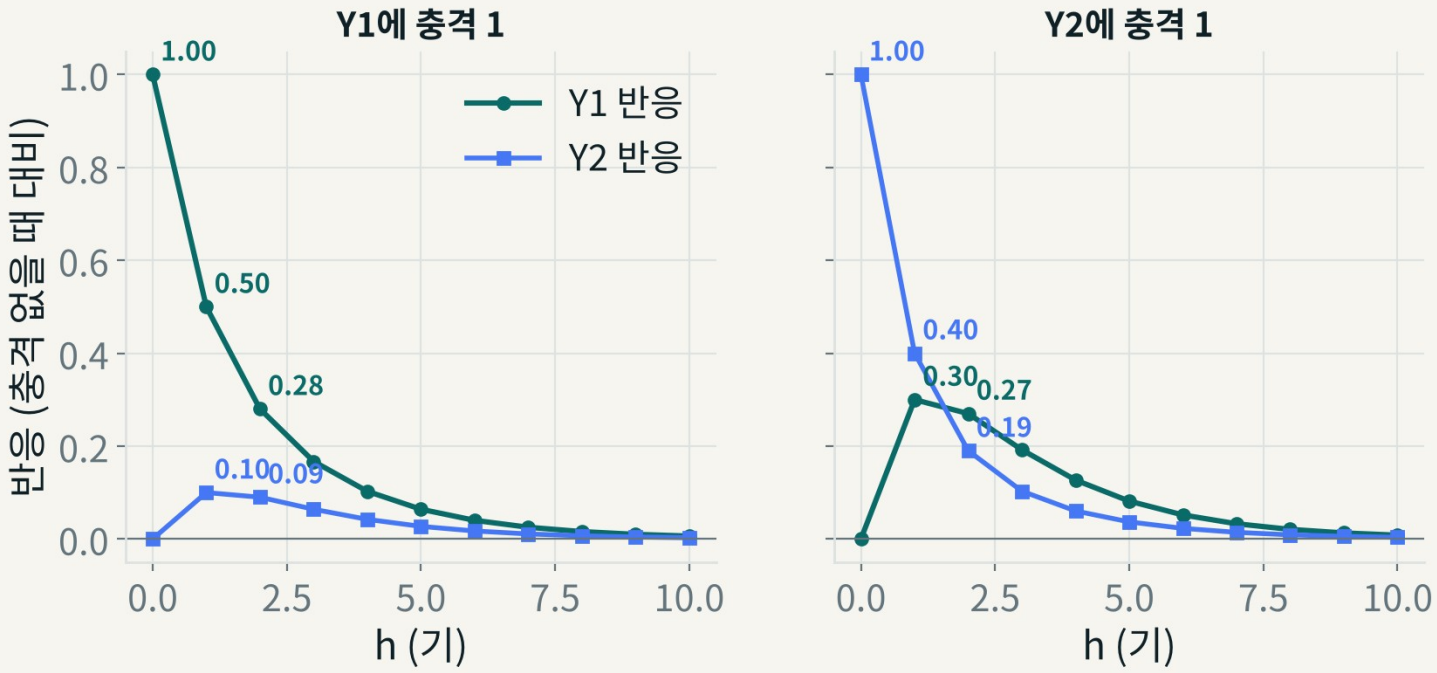
직전 반응에 A1을 곱하는 일을 반복할 뿐이다

계산한 반응을 그리면 IRF 그림이 됩니다

같은 A1 예 — 왼쪽: Y1에 충격, 오른쪽: Y2에 충격 (오차는 서로 무관하다고 가정)

읽는 법

- h = 0: 충격받은 변수만 1
- 다른 변수는 교차 계수로 번진다
- 안정적이라 모두 0으로 돌아온다



IRF 그림은 '얼마나, 언제, 얼마 동안'에 답한다

직교화를 하지 않으면 '현실에 없는 충격'의 반응을 보게 됩니다

앞의 손계산은 두 오차가 무관하다고 가정했다 — 실제 주식·섹터 오차는 상관 0.6~0.7로 같이 움직인다

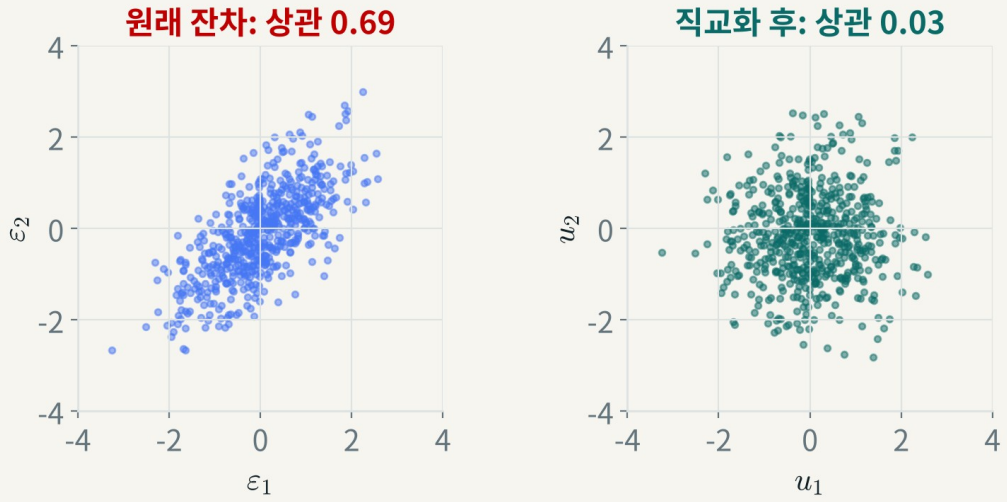
오차가 같이 움직이면

$$\mathrm{Corr}(e_1, e_2) = 0.6 \;\Rightarrow\; \text{when } e_1 = 1, \quad E[e_2] = 0.6$$

$$\text{shock } \mathbf{e} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \text{ assumes } e_2 = 0 \;\Rightarrow\; \text{an unrealistic experiment}$$

안 하면 생기는 문제

- IRF: 현실에 없는 충격을 준다
- FEVD: 겹친 몫을 나눌 수 없다



그래서 겹친 부분을 먼저 한 변수 몫으로 정리한다 = 직교화

예시: 상관 0.6인 두 오차를 '섹터 먼저' 순서로 나눕니다

직교화(촐레스키) — 서로 무관한 충격 u1(섹터 뉴스), u2(종목 고유 뉴스)로 다시 쓴다. 두 오차 모두 분산 1

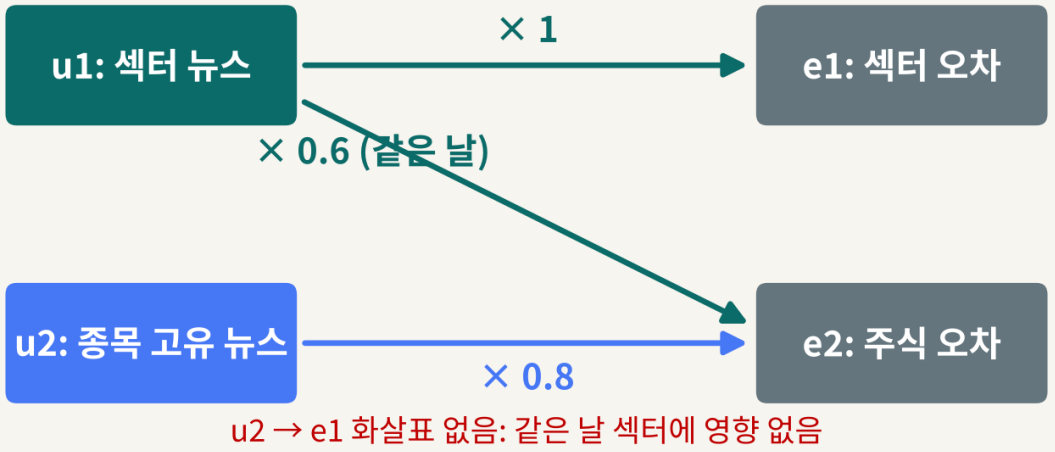
나누는 식과 확인

$$e_{t,1} = u_{t,1}$$
$$e_{t,2} = 0.6\,u_{t,1} + 0.8\,u_{t,2}$$

$$\mathrm{Var}(e_2) = 0.6^2 + 0.8^2 = 1$$
$$\mathrm{Cov}(e_1, e_2) = 0.6 \;\checkmark$$

읽는 법

- 섹터 뉴스는 같은 날 주식도 0.6 움직인다
- 종목 뉴스는 같은 날 섹터를 못 움직인다



겹친 부분(0.6)은 순서상 앞에 둔 섹터의 몫으로 돌린다

이렇게 나눈 충격으로 IRF를 다시 계산합니다

같은 A1 = [0.5 0.3; 0.1 0.4] — 이제 '섹터 뉴스 1'을 주면 같은 날 주식도 0.6 반응한다

직교화한 충격의 IRF (h = 0, 1)

$$u_1 = 1: \quad h{=}0 \begin{bmatrix} 1 \\ 0.6 \end{bmatrix} \xrightarrow{A_1} h{=}1 \begin{bmatrix} 0.5(1) + 0.3(0.6) \\ 0.1(1) + 0.4(0.6) \end{bmatrix} = \begin{bmatrix} 0.68 \\ 0.34 \end{bmatrix}$$

$$u_2 = 1: \quad h{=}0 \begin{bmatrix} 0 \\ 0.8 \end{bmatrix} \xrightarrow{A_1} h{=}1 \begin{bmatrix} 0.5(0) + 0.3(0.8) \\ 0.1(0) + 0.4(0.8) \end{bmatrix} = \begin{bmatrix} 0.24 \\ 0.32 \end{bmatrix}$$

읽는 법

- u1: 같은 날부터 둘 다 반응
- u2: 섹터는 다음 날부터
- 예: 섹터 −2, 종목 +0.5인 날
- 주식 오차 = −1.2 + 0.4 = −0.8

직교화한 충격은 '현실에서 함께 일어나는 움직임'을 그대로 담는다

직교화해야 예측오차를 충격별로 깔끔하게 나눌 수 있습니다

주식 오차의 분산 1을 두 충격 몫으로 — 겹친 부분이 없어야 몫의 합이 정확히 100%가 된다

주식 오차 분산의 분해 (h = 1)

$$\mathrm{Var}(e_2) = 1 = \underbrace{0.6^2}_{36\% \text{ from } u_1 \text{ (sector)}} + \underbrace{0.8^2}_{64\% \text{ from } u_2 \text{ (own)}}$$

읽는 법

- 섹터 충격 몫 36%
- 자기 충격 몫 64%
- 순서를 바꾸면 몫도 바뀐다

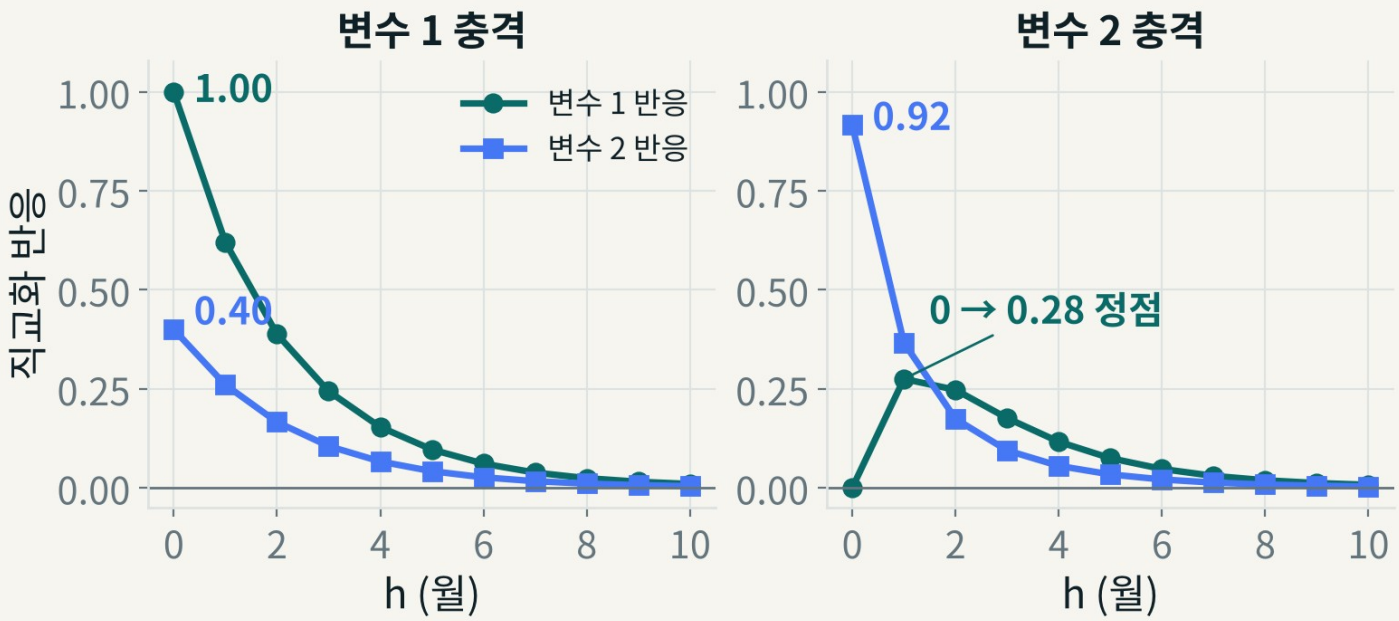
직교화 = 겹친 움직임을 정리해 IRF와 FEVD를 가능하게 하는 단계

직교화한 충격으로 그리면 실제 분석의 IRF가 됩니다

주식·섹터 수익률 예 — 같은 날 반응(h = 0)도 생긴다는 점이 앞의 예와 다르다

읽는 법

- 변수 1 충격: 변수 2도 즉시 0.40 반응
- 변수 2 충격: 변수 1은 1기 뒤 0.28로 정점
- 모두 0으로 돌아온다 → 안정



IRF를 읽는 법은 같다 — 크기, 정점 시점, 지속 기간

분산분해(FEVD)는 h기 앞 예측오차가 어느 충격에서 왔는지의 비중입니다

FEVD = Forecast Error Variance Decomposition — '예측이 빗나간 이유'를 충격별로 나눈 몫

예측오차 = 충격별 반응(IRF) × 충격의 합

$$\underbrace{Y_{t+h,1} - \hat{Y}_{t+h,1}}_{h\text{-step forecast error}} = \sum_{s=0}^{h-1} \left(\underbrace{\psi_{11,s}\, u_1}_{\text{shock 1}} + \underbrace{\psi_{12,s}\, u_2}_{\text{shock 2}} \right)$$

결과는 합이 100%인 비중

$$\underbrace{100\%}_{\text{forecast error of } Y_1} = \underbrace{90\%}_{\text{own shock}} + \underbrace{10\%}_{\text{shock of } Y_2}$$

읽는 법

- ψ: 앞에서 구한 IRF 값
- u: 서로 무관한 충격 (분산 1)
- Y1이 틀리는 원인 = 자기 충격 + 상대 충격
- IRF가 '모양'이면 FEVD는 '비중'

FEVD = 'Y1 예측오차 중 몇 %가 Y2 충격 탓인가'

FEVD도 지평 h를 넣으면 비중이 나오는 '함수'입니다

입력은 예측 지평 h, 출력은 'h기 앞 예측오차 중 충격 j의 몫' — IRF 값을 제곱해 더한 비율

공식: IRF 제곱합의 비율

$$\mathrm{FEVD}_{i\leftarrow j}(h) = \frac{\sum_{s=0}^{h-1} \theta_{ij,s}^2}{\sum_{s=0}^{h-1} \sum_{k=1}^{K} \theta_{ik,s}^2}, \qquad \theta_{ij,s} = \mathrm{IRF}_{i\leftarrow j}(s)$$

성질: 0과 1 사이, 합은 항상 1

$$0 \le \mathrm{FEVD}_{i\leftarrow j}(h) \le 1, \qquad \sum_{j=1}^{K} \mathrm{FEVD}_{i\leftarrow j}(h) = 1 \ \text{ for every } h$$

읽는 법

- θ: 직교화한 IRF 값
- 분자: 충격 j에서 온 오차
- 분모: 모든 충격에서 온 오차
- h가 바뀌면 비중도 바뀐다

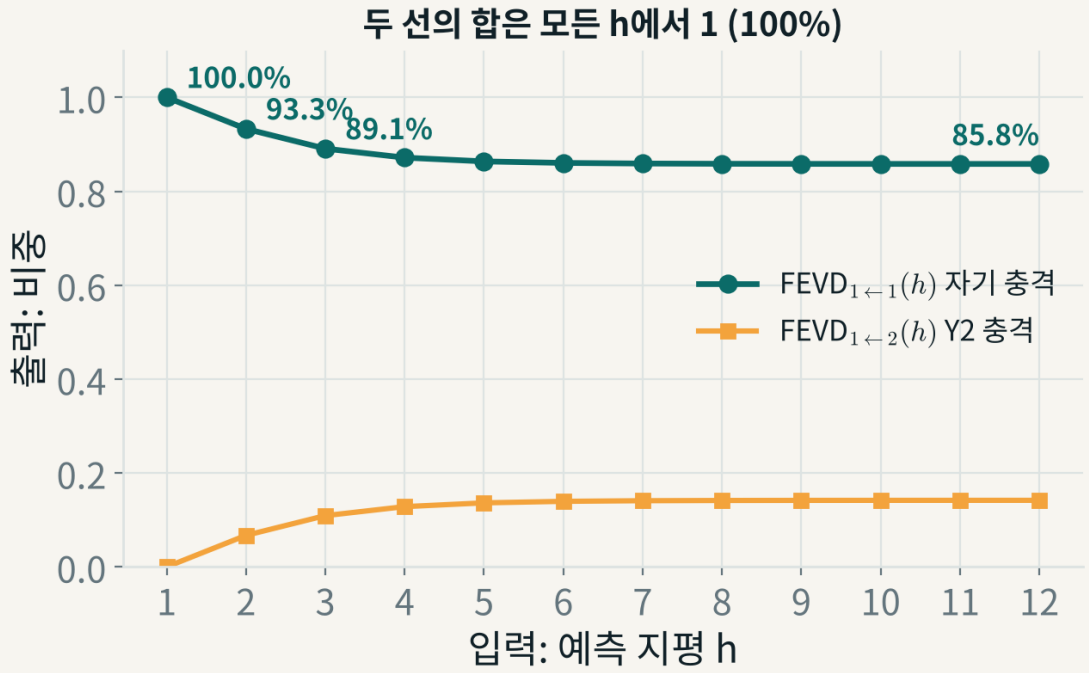
FEVD(h)는 IRF(h)로 만든 두 번째 함수다

FEVD 함수를 그리면 비중이 지평에 따라 변하는 모습이 보입니다

같은 A1 예 — Y1의 예측오차, 지평 h = 1~12

읽는 법

- h = 1 → 100%
- h = 2 → 93.3%
- h = 3 → 89.1%
- h = 10 → 85.8%
- 두 선의 합은 항상 100%



안정적인 VAR에서는 h가 커질수록 FEVD가 일정한 값에 수렴한다

FEVD는 IRF 값을 제곱해서 더한 뒤 비율로 구합니다

같은 A1 예, Y1의 예측오차 — 자기 충격 반응 ψ11과 상대 충격 반응 ψ12를 쓴다

손으로 구하는 FEVD (Y1 자기 충격 비중)

$$\psi_{11}: 1,\ 0.50,\ 0.28 \qquad \psi_{12}: 0,\ 0.30,\ 0.27 \quad (\text{IRF of } Y_1)$$

$$h=1: \quad \frac{1^2}{1^2+0^2} = 100\%$$

$$h=2: \quad \frac{1^2+0.5^2}{(1^2+0.5^2)+(0^2+0.3^2)} = \frac{1.25}{1.34} = 93.3\%$$

$$h=3: \quad \frac{1.25+0.28^2}{1.34+0.28^2+0.27^2} = \frac{1.328}{1.491} = 89.1\%$$

읽는 법

- h = 1: 100%
- h = 2: 93.3%
- h = 3: 89.1%
- 나머지는 Y2 충격 몫

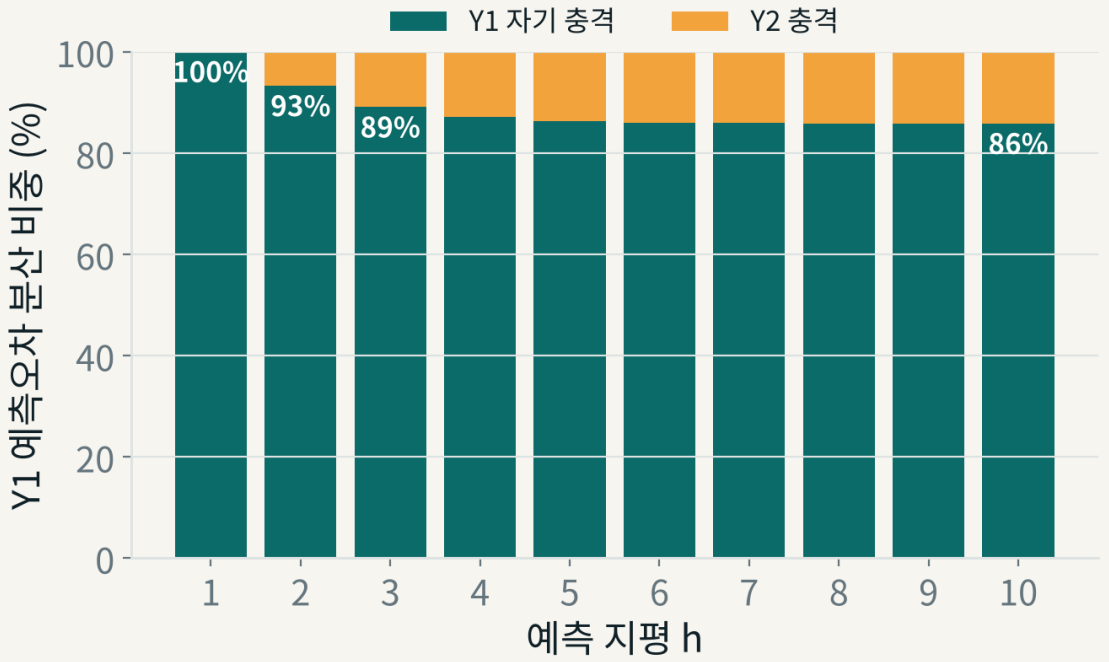
지평이 길수록 다른 변수 충격의 몫이 커진다

지평을 늘리며 비중을 쌓으면 FEVD 그림이 됩니다

같은 A1 예 — Y1 예측오차의 출처, 지평 1~10기

읽는 법

- h = 1: 자기 충격 100%
- h = 10: 자기 86%, Y2 14%
- 합은 언제나 100%



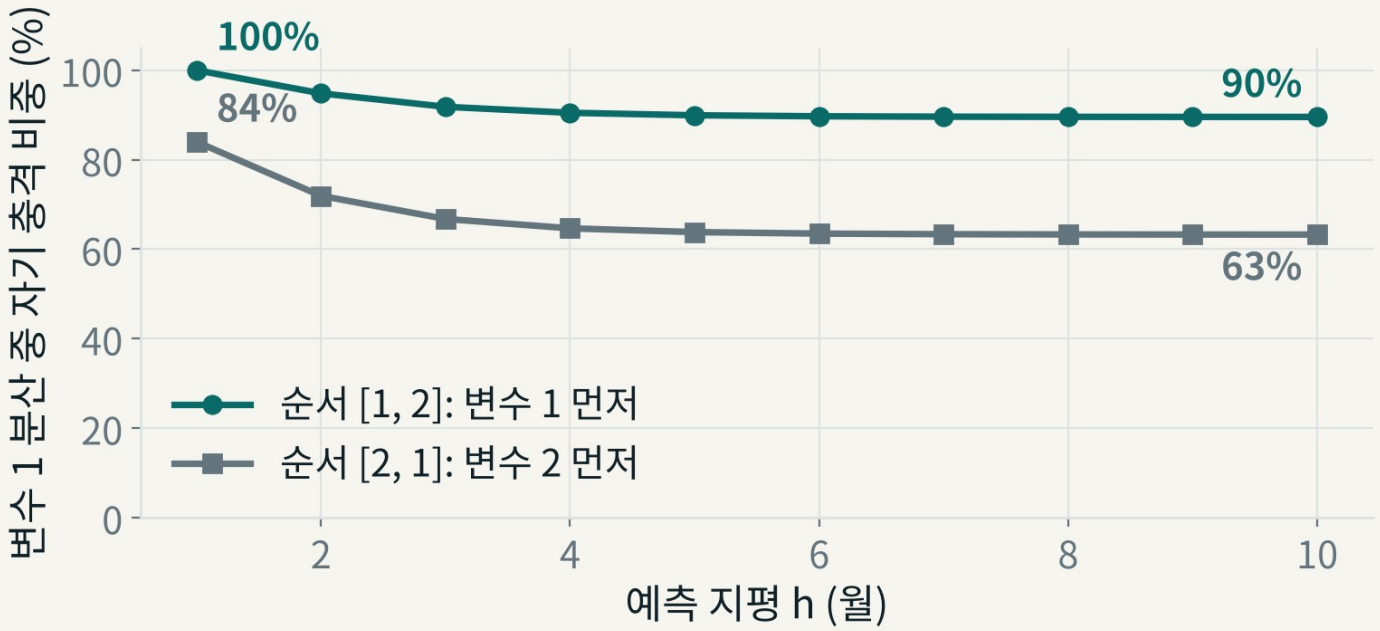
짧은 지평은 자기 충격, 긴 지평일수록 상대 충격이 섞인다

단, 직교화 순서만 바꿔도 분산분해 비중이 크게 바뀝니다

주식·섹터 예, 같은 데이터에서 촐레스키 순서만 [1, 2]와 [2, 1]로 바꾼 결과

읽는 법

- 순서 [1, 2]: 자기 비중 90%
- 순서 [2, 1]: 자기 비중 63%
- 결과와 함께 순서를 꼭 적는다



IRF · FEVD를 보고할 때는 변수 순서를 함께 밝힌다

04

종합

하나의 VAR, 세 가지 질문

VAR 하나로 예측 · 선행 관계 · 충격 경로를 봅니다

모형은 하나, 묻는 질문에 따라 도구가 다르다

도구	질문	볼 것
VAR 예측	**앞으로 어떻게 될까?**	**모든 변수의 동시 예측**
그레인저 인과	**남의 과거가 도움이 되나?**	**상대 과거 계수 = 0의 F-검정**
IRF	**충격이 어떻게 퍼지나?**	**시간에 따른 반응 경로**
FEVD	**예측오차는 누구 탓인가?**	**충격 출처별 비중 (합 100%)**

다음 주: 수준 변수들이 함께 떠도는 경우 — 공적분

AR · MA — 변수 하나

VAR — 변수 여럿을 한 줄로

그레인저 · IRF · FEVD — VAR로 묻는 질문

다음 주
공적분과 오차수정