강의 · 상태공간모형

상태공간모형과 칼만 필터·EM

소비·금리·ETF 동적 헤징·변동성·나우캐스팅으로 배우는 상태공간모형

State Space Model · Kalman Filter · Expectation-Maximization

두 개의 방정식으로 숨은 상태를 표현하고, 칼만 필터로 상태를 추정하며, EM으로 모형의 숫자를 학습한다.

상태공간모형은 두 방정식과 두 도구로 정리된다

이 강의 전체를 관통하는 세 가지 메시지

1

두 방정식이 모형을 정한다

상태방정식은 숨은 대상이 시간에 따라 움직이는 법을, 관측방정식은 그 대상이 데이터로 보이는 방식을 말한다.

2

칼만 필터는 상태를, EM은 모수를 추정한다

필터는 관측값이 들어올 때마다 상태를 갱신하고, EM은 상태 추정(E)과 Q·R 수정(M)을 번갈아 반복한다.

3

같은 틀이 금융·경제 문제 전반에 쓰인다

소비, 금리, 헤지 비율, 변동성, 경기 상태를 모두 숨은 상태로 놓고 같은 절차로 추정한다.

01

PART 1 · 기본 모형

기본 방정식 두 개

상태방정식과 관측방정식, 칼만 필터, EM

상태공간모형은 두 방정식으로 이루어진다

우선 상태와 관측값이 각각 숫자 하나인 경우로 배운다

상태방정식

$$\underbrace{x_t}_{\text{오늘 상태}} = \underbrace{A}_{\text{이어지는 방식}} \underbrace{x_{t-1}}_{\text{어제 상태}} + \underbrace{w_t}_{\text{상태 변화}}, \qquad w_t \sim N(0, Q)$$

관측방정식

$$\underbrace{y_t}_{\text{관측값}} = \underbrace{H_t}_{\text{연결 숫자}} \underbrace{x_t}_{\text{상태}} + \underbrace{v_t}_{\text{관측식 잔차}}, \qquad v_t \sim N(0, R)$$

상태방정식이 말하는 것

- 알고 싶은 대상이 시간에 따라 어떻게 변하는지 설명한다

관측방정식이 말하는 것

- 그 대상과 실제로 보는 자료의 관계를 설명한다

기호마다 맡은 역할이 정해져 있다

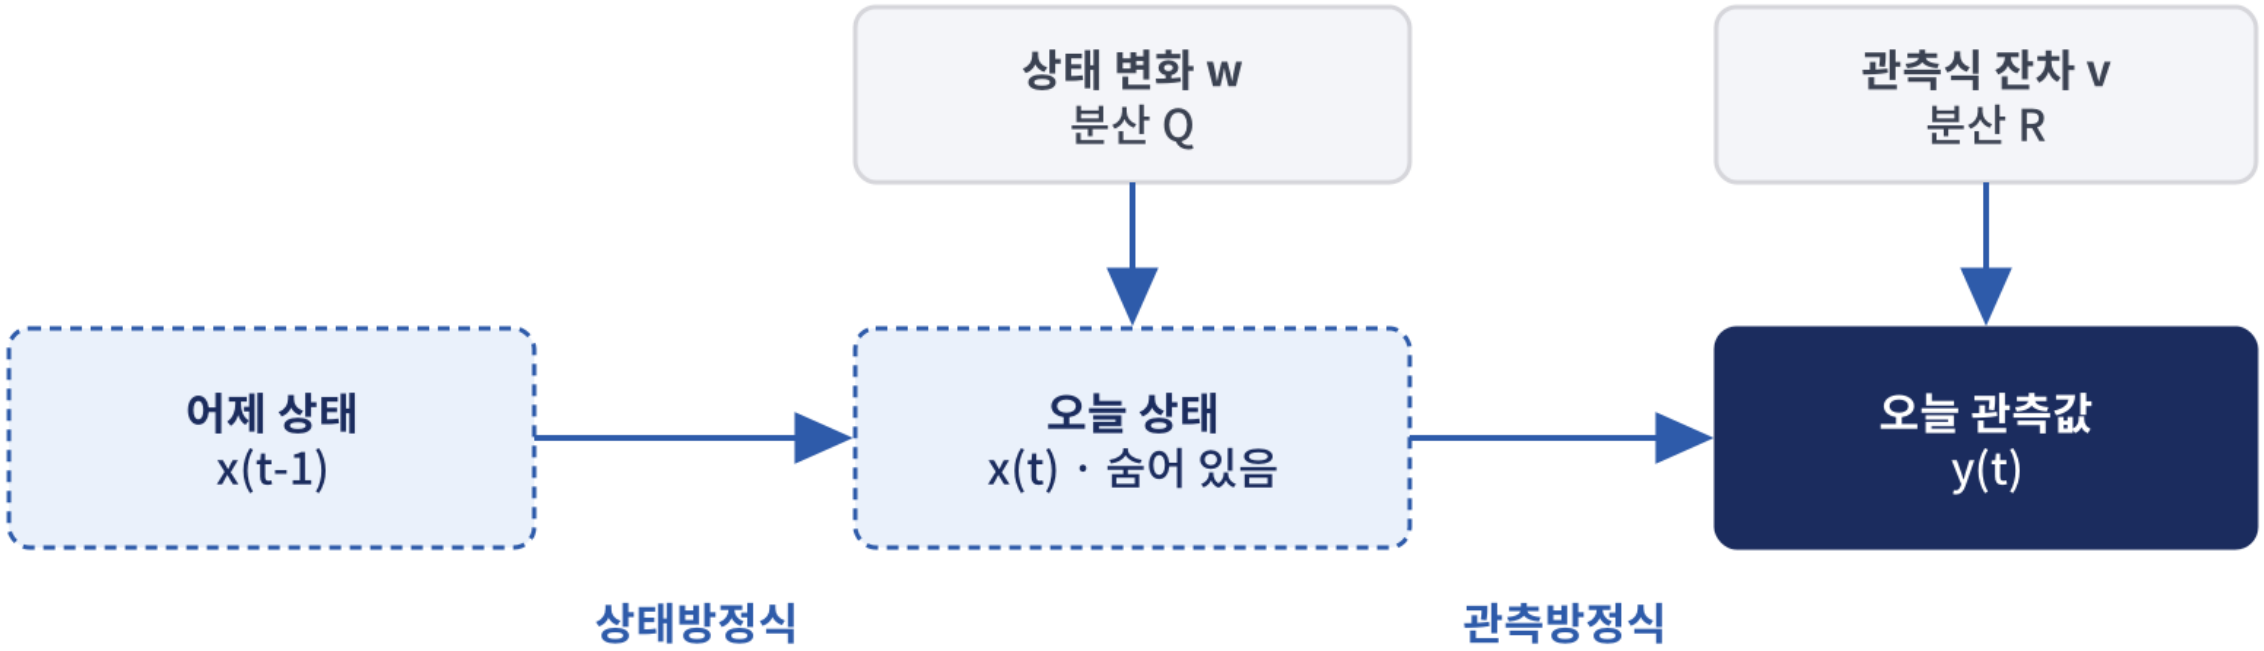
분산은 흔들림의 크기다. 두 오차는 평균 0, 시점 사이와 서로 간에 독립으로 가정한다

기호	쉬운 의미
x_t	알고 싶은 상태. 직접 정확하게 관측하기 어려운 값
y_t	실제로 확보한 자료
A	어제의 상태가 오늘에 이어지는 방식
H_t	상태를 관측값에 연결하는 숫자 (알려진 입력에 따라 변할 수 있음)
w_t	상태 자체에 새로 생기는 변화
v_t	상태만으로 설명되지 않는 관측값의 부분
Q	상태 변화의 분산
R	관측식 잔차의 분산

시작 상태의 평균과 분산도 정해야 한다

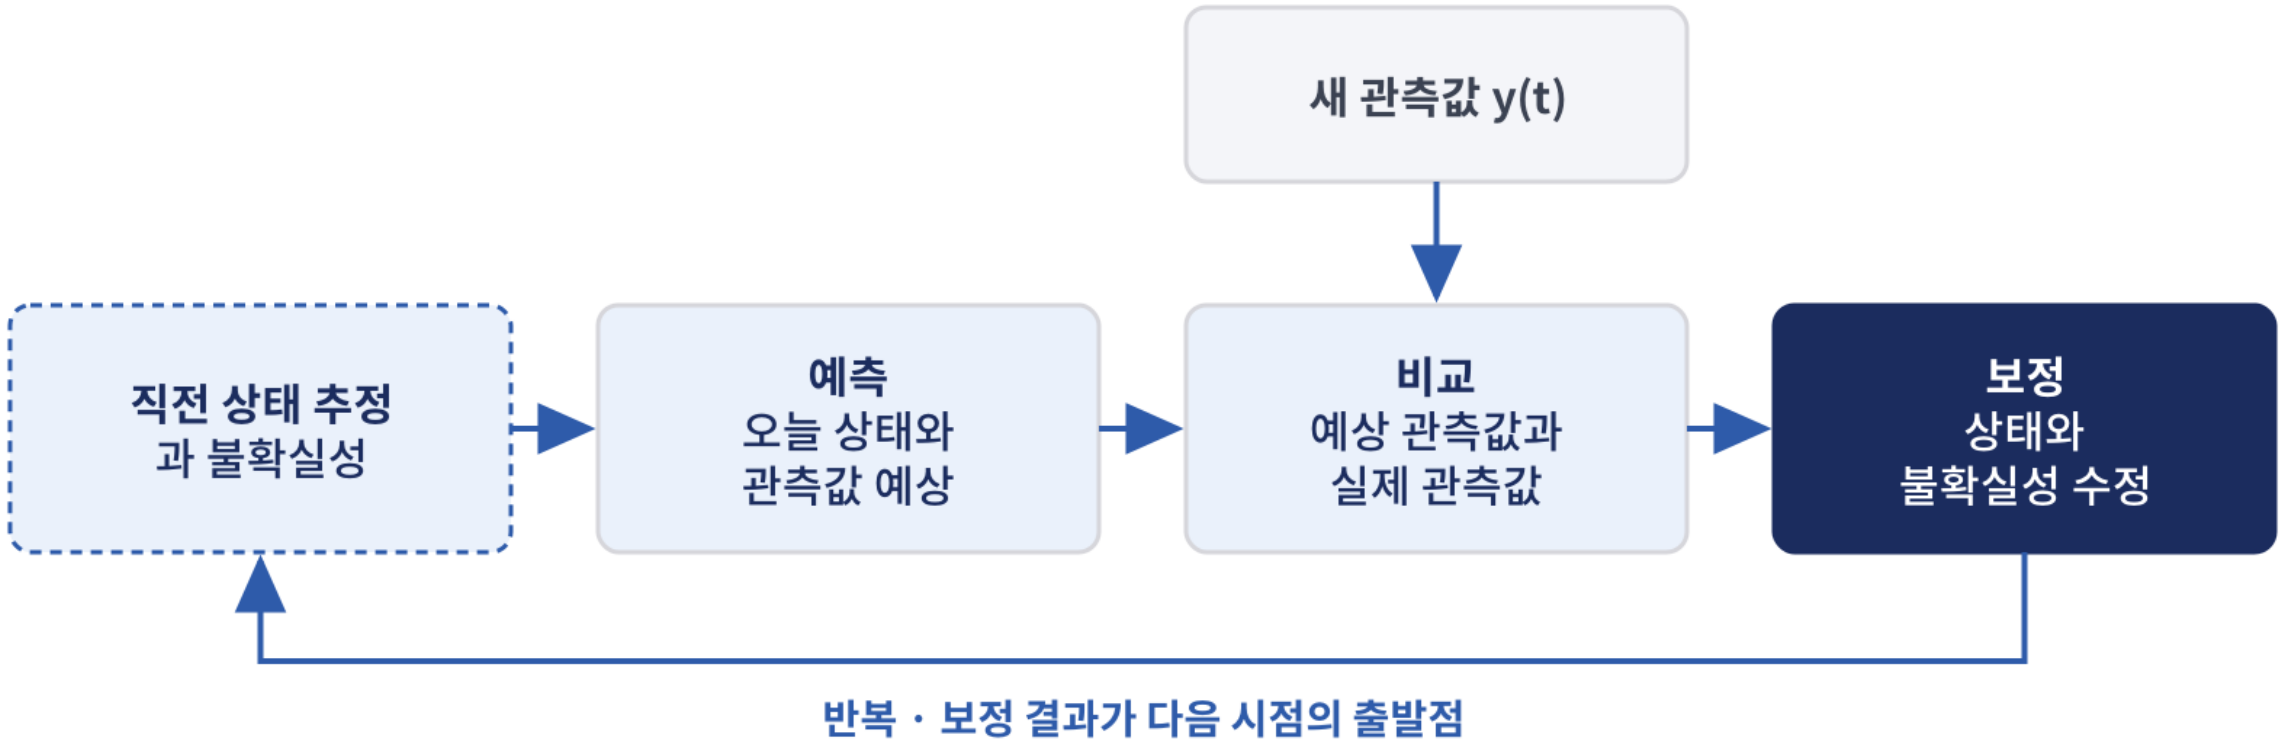
숨은 상태는 이어지며 관측값을 만든다

상태는 실제 소비액처럼 정확히 모르는 값일 수도, 헤지 비율처럼 관계를 설명하는 계수일 수도 있다



칼만 필터는 관측마다 상태를 갱신한다

모델의 숫자 A·H·Q·R과 시작 상태의 평균·분산이 주어져도 실제 상태는 추정해야 한다



칼만 필터의 계산은 예측·비교·보정의 일곱 줄로 끝난다

윗첨자 마이너스는 관측 전 예측, 모자 기호는 관측 후 추정, P는 상태 추정 오차의 분산이다

$$\hat{x}_t^- = A\hat{x}_{t-1}$$ 상태 예측

$$P_t^- = A^2 P_{t-1} + Q$$ 예측 오차 분산

$$e_t = y_t - H_t\hat{x}_t^-$$ 혁신(실제 − 예상)

$$S_t = H_t^2 P_t^- + R$$ 혁신의 분산

$$K_t = \frac{P_t^- H_t}{S_t}$$ 칼만 이득

$$\hat{x}_t = \hat{x}_t^- + K_t e_t$$ 상태 보정

$$P_t = (1 - K_t H_t) P_t^-$$ 보정 후 오차 분산

입력과 출력

- 입력: 직전 추정과 그 불확실성, 오늘 관측값
- 출력: 오늘 추정과 줄어든 불확실성
- 혁신 e는 예상과 실제의 차이, 칼만 이득 K는 그 차이를 얼마나 반영할지 정한다
- H가 1이면 K는 예측과 관측 사이의 가중치다

EM은 상태 추정과 숫자 수정을 번갈아 반복한다

이 강의는 A와 관측식 구조를 정해 두고 주로 Q와 R을 학습한다 · E는 기댓값, M은 최대화

알고 싶은 것	사용하는 방법
현재 상태	칼만 필터
과거 상태를 전체 기록으로 다시 추정	칼만 스무더
상태 변화와 관측 잔차의 분산 Q, R	EM

E단계 · 지금 숫자로 상태를 추정한다

- 지금 쓰는 Q·R로 필터를 앞으로, 스무더를 뒤로 돌린다
- 각 시점 상태의 평균과 불확실성을 얻는다

M단계 · 추정한 상태에 맞게 숫자를 고친다

- 잔차가 평균적으로 얼마나 컸는지를 새 분산으로 삼는다
- 새 Q와 새 R은 여기서 나온다

Q와 R은 E단계의 입력이고 M단계의 출력이다

E는 기댓값(Expectation), M은 최대화(Maximization) · 한 번 돌 때마다 Q·R이 새로 바뀐다

단계	입력	하는 일	출력
E단계	지금 쓰는 Q·R과 전체 관측 기록	필터로 앞으로, 스무더로 뒤로 계산한다	각 시점 상태의 평균과 불확실성, 기대 제곱 잔차
M단계	E단계가 넘긴 기대 제곱 잔차	시점별로 평균 낸다	새 Q와 새 R

한 바퀴가 끝나면

- 새 Q·R을 들고 다시 E단계로 간다. 우도 개선이 충분히 작아지면 멈춘다

기대 제곱 잔차가 E단계와 M단계를 잇는다

상태를 정확히 모르므로 잔차도 하나의 값이 아니라 평균적인 크기로 계산한다

E단계가 만드는 값

가능한 상태 전체를 고려해, 잔차 제곱이 평균적으로 얼마인지 계산한다

두 종류의 잔차

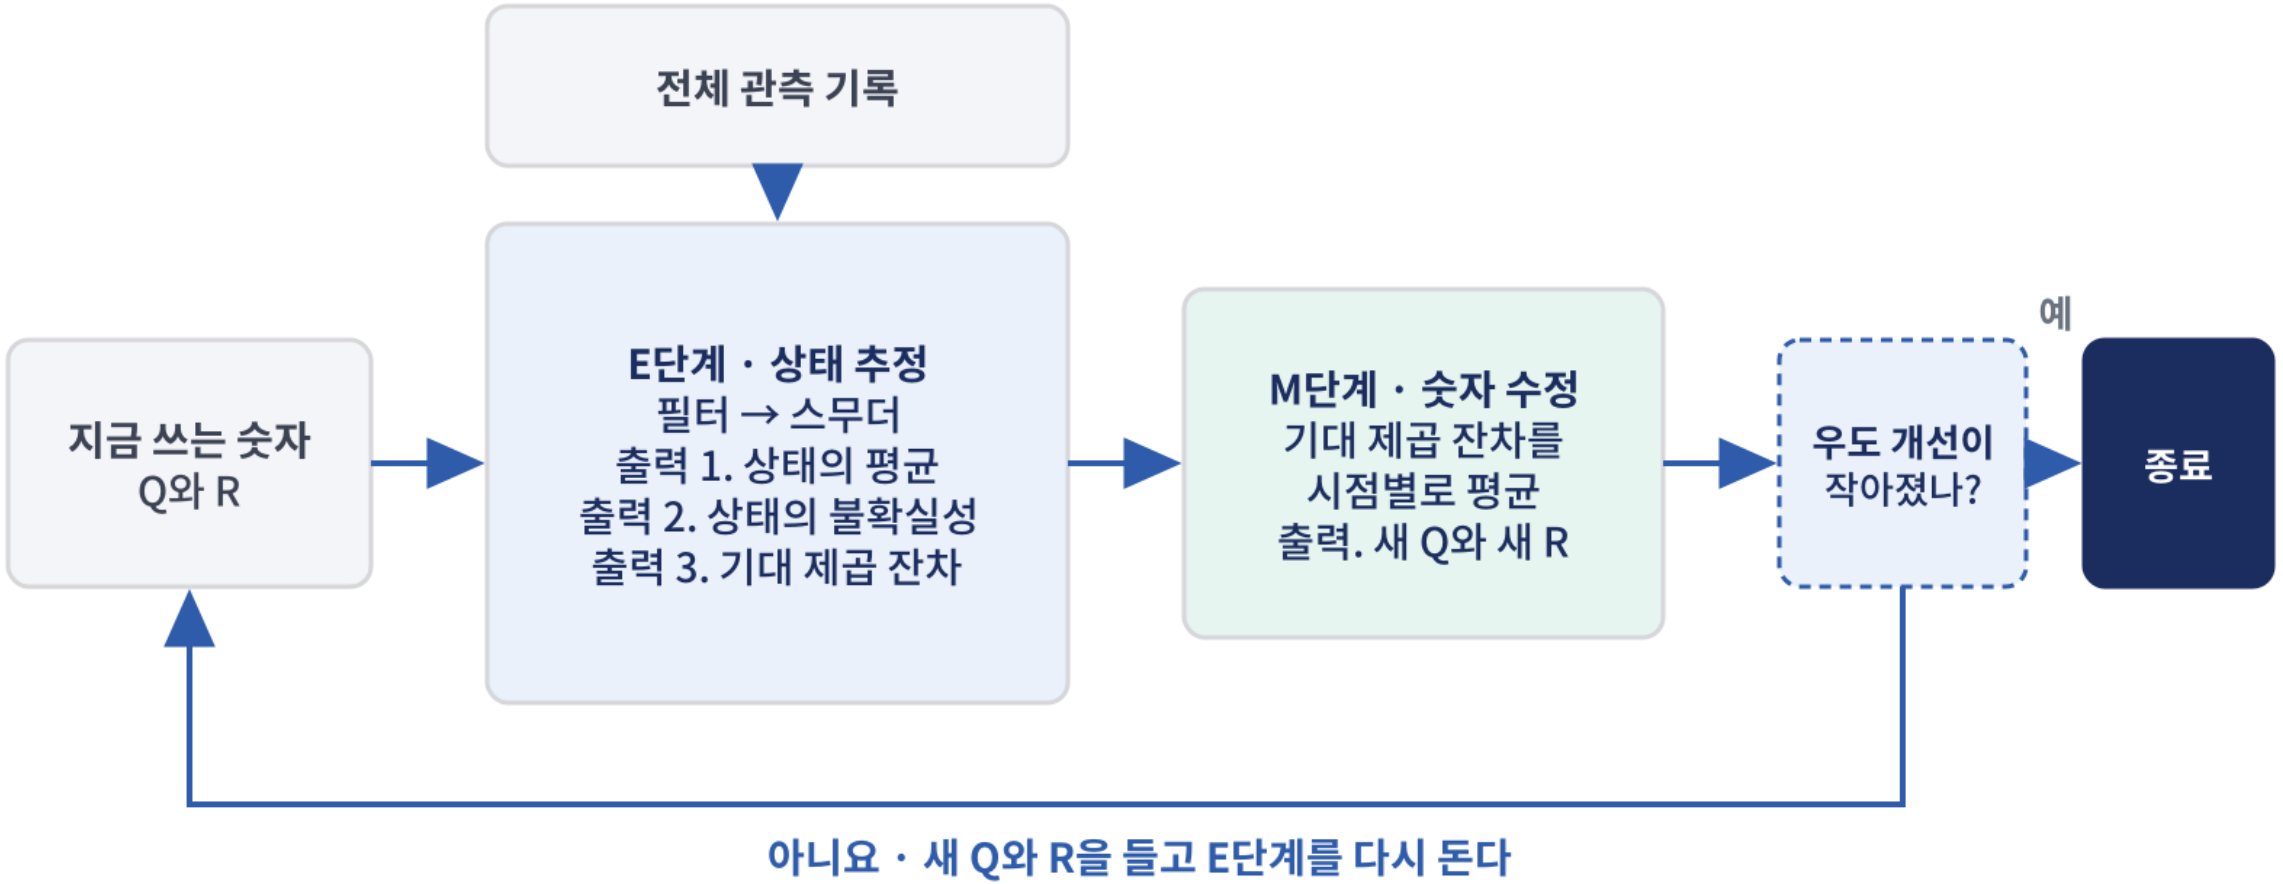
관측값과 상태의 차이는 R에 쓰고, 오늘 상태와 어제 상태의 차이는 Q에 쓴다

M단계가 하는 일

두 값을 시점별로 평균 내면 그대로 새 R과 새 Q가 된다

숫자를 고칠 때마다 상태를 다시 추정한다

EM은 초깃값에 따라 다른 해에 수렴할 수 있어 학습 결과와 우도 변화를 확인한다



필터링과 스무딩은 쓰는 관측값이 다르다

EM은 상태 추정치를 정답으로 놓지 않고 여러 값일 가능성까지 포함해 계산한다



큰 그림만 정하면 계산은 클코가 한다

Claude Code 데스크톱 앱 Code 탭에서 한다 · 수강생은 붙여넣고 확인만 한다

1. 큰 그림 정하기

무엇이 숨은 상태이고 무엇이 관측값인지, 어떤 숫자를 학습할지 두 방정식으로 정한다

2. 프롬프트로 맡기기

자료 내려받기, 필터·스무더·EM 구현, 그림 그리기, 오류 수정은 Claude Code가 한다

3. 결과 확인하기

Q·R이 수렴했는지, 추정이 직관과 맞는지, 미래 정보가 섞이지 않았는지 확인한다

02

PART 2 · 소비 예제

실제 평균 소비액 추정

A = H = 1인 가장 단순한 상태공간모형 · 단위 만 원

실제 소비가 상태, 조사 평균이 관측값이다

A = H = 1 · 단위는 만 원

상태방정식

$$\underbrace{x_t}_{\text{실제 평균 소비}} = x_{t-1} + \underbrace{w_t}_{\text{실제 소비 변화}}, \qquad w_t \sim N(0, Q)$$

관측방정식

$$\underbrace{y_t}_{\text{조사 평균}} = x_t + \underbrace{v_t}_{\text{표본조사 오차}}, \qquad v_t \sim N(0, R)$$

상태 · 전체 가구의 실제 월평균 소비액

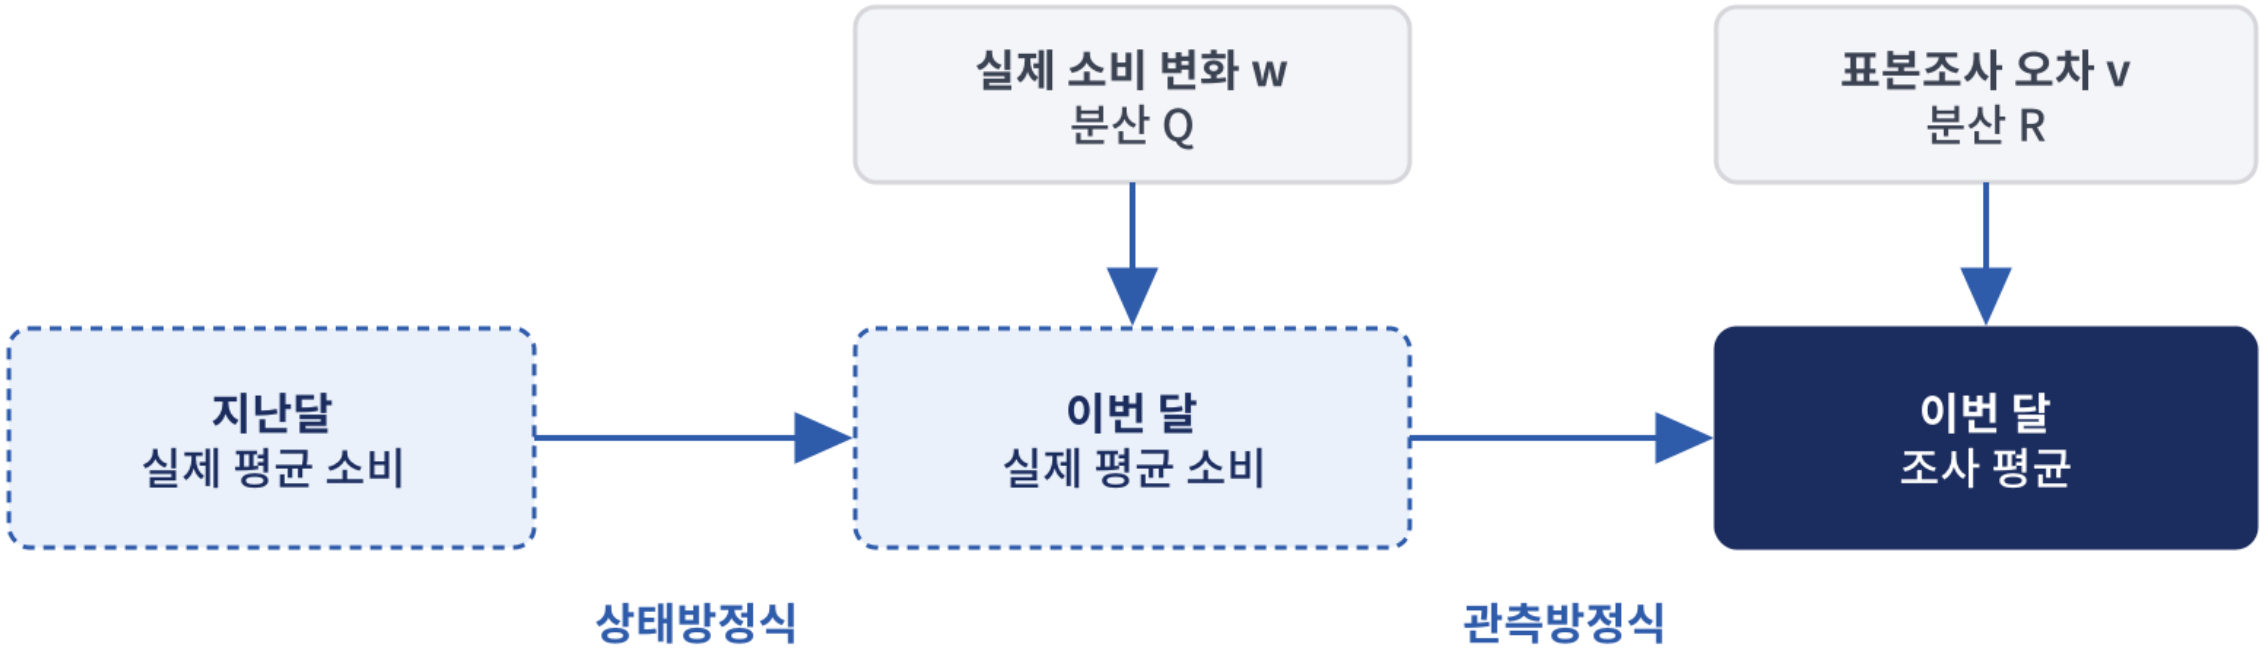
- 소득이나 지출 수요에 따라 변한다

관측값 · 일부 가구를 조사해 얻은 평균

- 조사 대상 가구에 따라 실제 평균과 달라질 수 있다

표본조사 오차 때문에 조사 평균은 실제 평균과 어긋난다

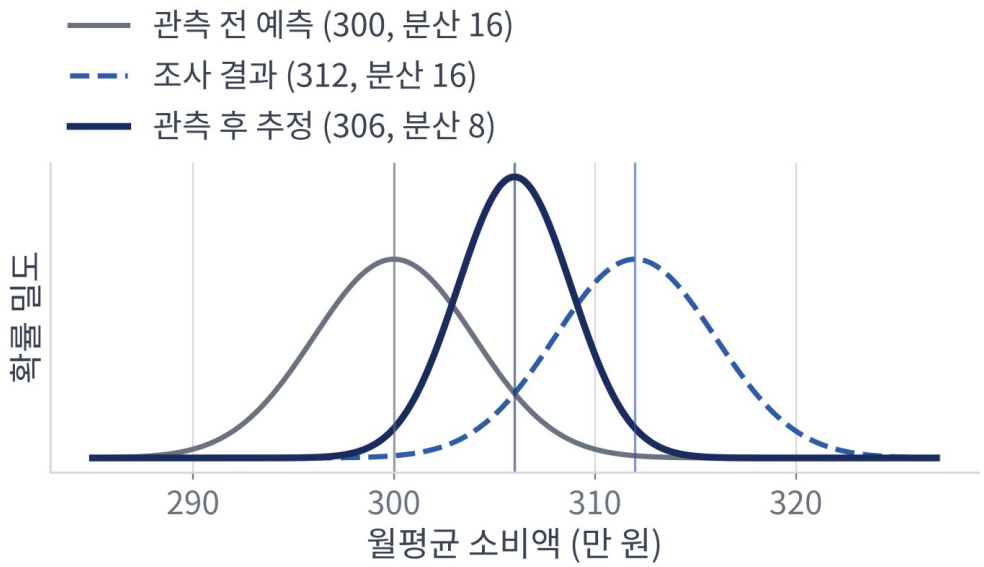
실제 소비 변화의 분산 Q, 표본조사 오차의 분산 R



조사 결과 312만 원이 추정을 306만 원으로 올린다

가상 예시 · 분산 단위는 (만 원)² · 단계별 손계산은 워크북

항목	값
지난달 보정 후 추정	300만 원
지난달 보정 후 오차 분산	8
실제 변화의 분산 Q	8
이번 달 조사 결과	312만 원
조사 오차 분산 R	16

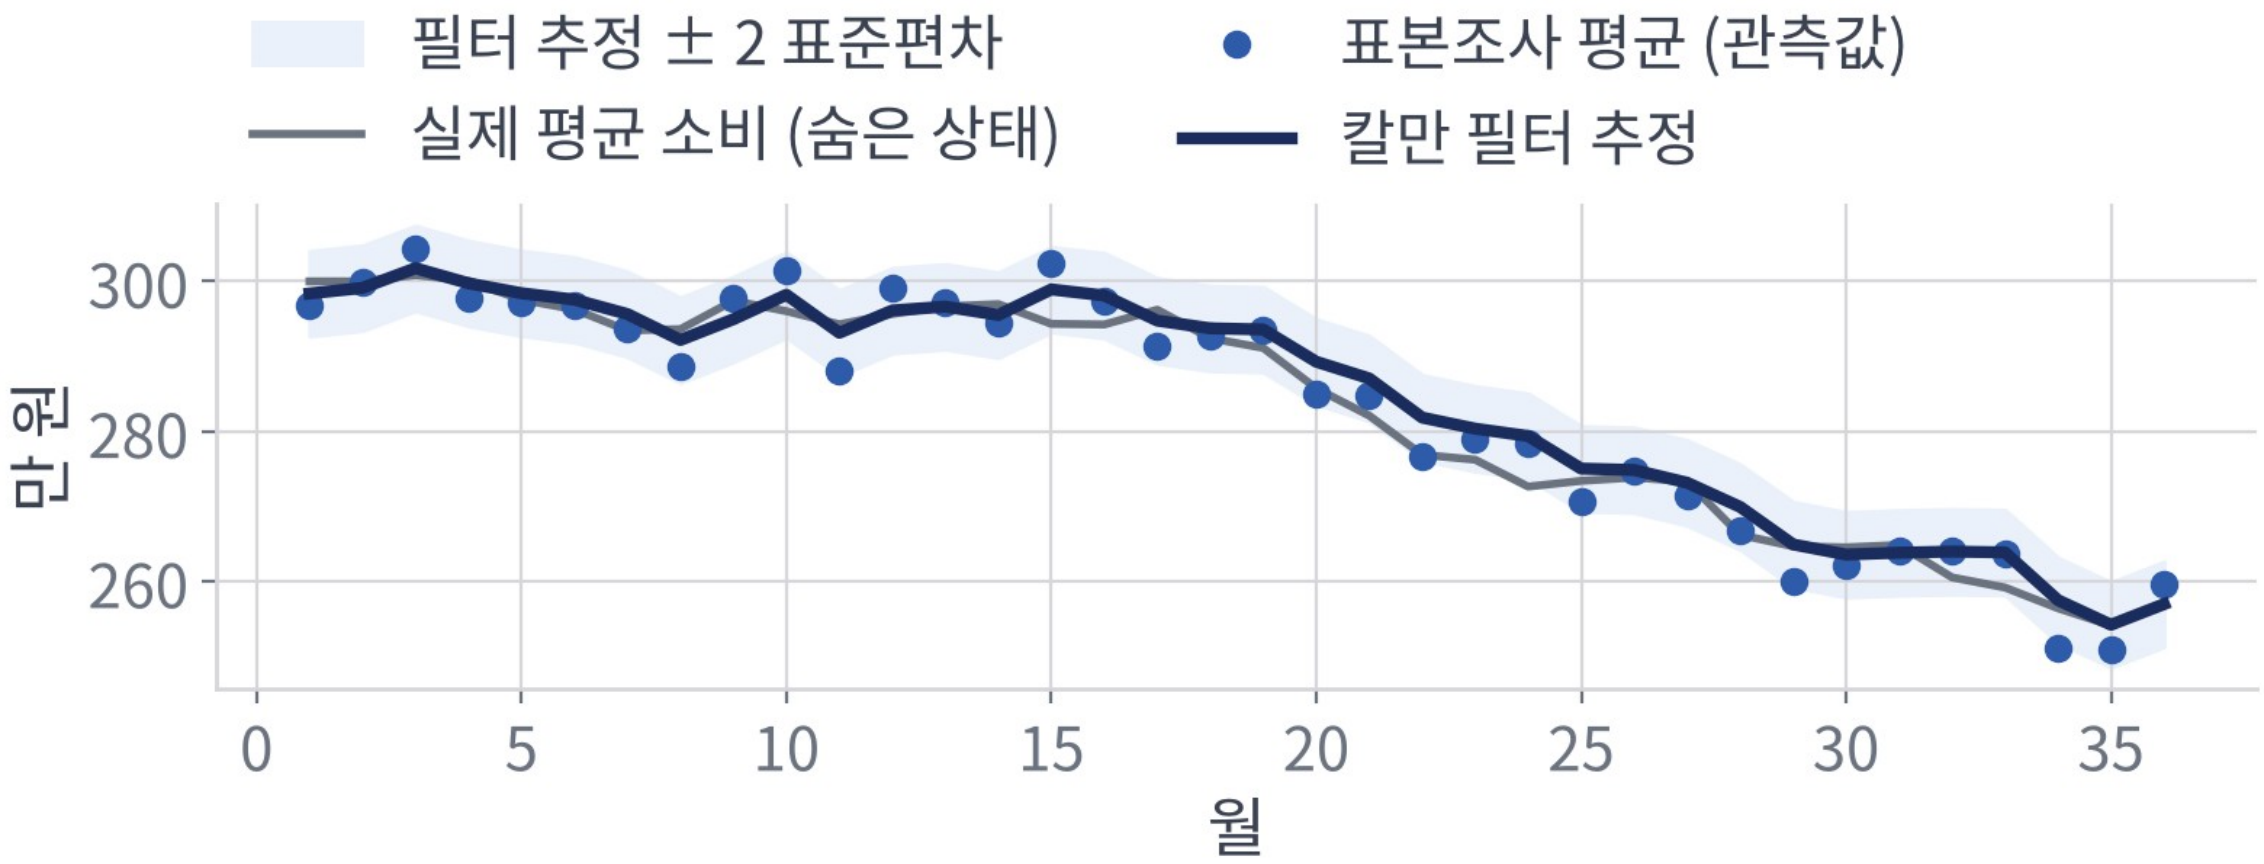


결과 · 오차 분산은 관측 전 16에서 관측 후 8로 줄어든다

$$\hat{x}_t = 300 + 0.5 \times 12 = 306 \text{ 만 원}, \qquad P_t : \ 16 \ \rightarrow \ 8$$

필터는 흔들리는 조사 속에서 실제 소비를 따라간다

Q = 8, R = 16으로 만든 36개월 모의 경로 · 매달 보정 결과에서 다시 출발 · ※ 예시 데이터



E단계는 각 달의 실제 소비를 범위로 넘겨준다

스무딩 평균을 m, 불확실성(스무딩 분산)을 V로 쓴다 · ※ 세 달 예시 숫자

달	조사 결과	스무딩 평균	불확실성	차이 제곱 + 불확실성
1	312	308	6	16 + 6 = 22
2	305	304	5	1 + 5 = 6
3	298	300	6	4 + 6 = 10

E단계 출력 · R에 쓰는 기대 제곱 잔차

$$E[(y_t - x_t)^2 \mid Y] = \underbrace{(y_t - m_t)^2}_{\text{스무딩 평균과의 차이}} + \underbrace{V_t}_{\text{남은 불확실성}}$$

실제 소비를 한 점이 아니라 범위로 보므로, 그 불확실성만큼 잔차가 커진다

V는 기댓값을 정직하게 계산하면 저절로 나온다

E단계는 실제 소비를 모르는 상태에서 잔차 제곱의 평균을 구한다

어떤 값에든 성립하는 사실

$$\text{제곱의 평균} = (\text{평균})^2 + \text{분산}$$

잔차에 적용하면

$$E[(y_t - x_t)^2 \mid Y] = \underbrace{(y_t - m_t)^2}_{\text{스무딩 평균과의 차이}} + \underbrace{V_t}_{\text{남은 불확실성}}$$

평균의 제곱 자리

- 조사 결과와 스무딩 평균의 차이 제곱

분산 자리

- 실제 소비의 불확실성 V

숫자로 확인 · 1과 3

- 제곱의 평균 5 = 평균 2의 제곱 4 + 분산 1

M단계는 기대 제곱 잔차를 평균 내 새 Q와 R로 삼는다

기댓값은 모두 E단계가 지금 쓰는 Q·R로 계산해 넘긴 것이다 · 달 사이 변화는 T−1개

M단계 출력 · 새 Q

$$\underbrace{Q_{\text{new}}}_{\text{상태 변화 분산}} = \frac{1}{T-1}\sum_{t=2}^{T} E[(x_t - x_{t-1})^2 \mid Y]$$

M단계 출력 · 새 R

$$\underbrace{R_{\text{new}}}_{\text{조사 오차 분산}} = \frac{1}{T}\sum_{t=1}^{T} E[(y_t - x_t)^2 \mid Y]$$

Q에 쓰는 값

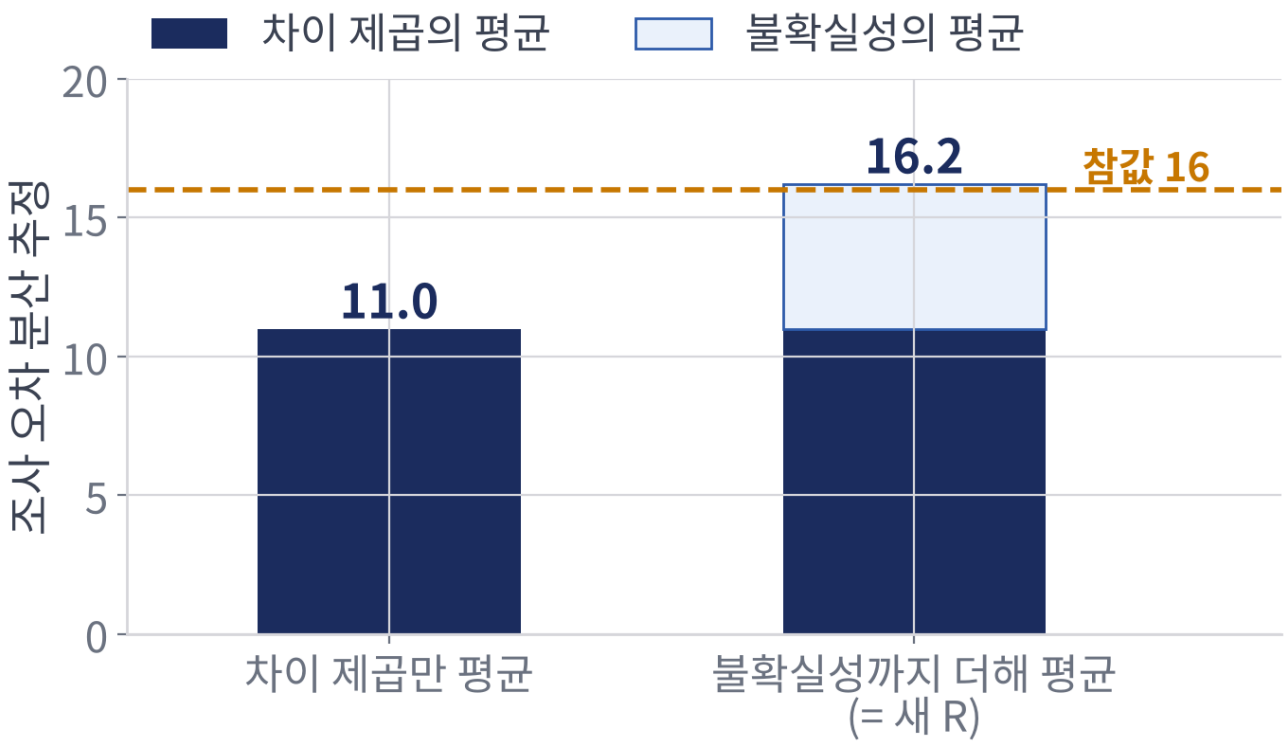
- 달 사이 변화의 기대 제곱이다
- 두 달 평균의 차이에, 두 달의 불확실성과 두 추정이 함께 움직이는 정도를 반영한다

R에 쓰는 값

- 조사와 실제의 기대 제곱이다
- 조사 결과와 평균의 차이 제곱에 그달의 불확실성을 더한다

V를 빼면 R이 평균 V만큼 과소추정된다

Q = 8, R = 16으로 만든 240개월 자료 · EM이 수렴한 뒤 기준 · ※ 예시 데이터

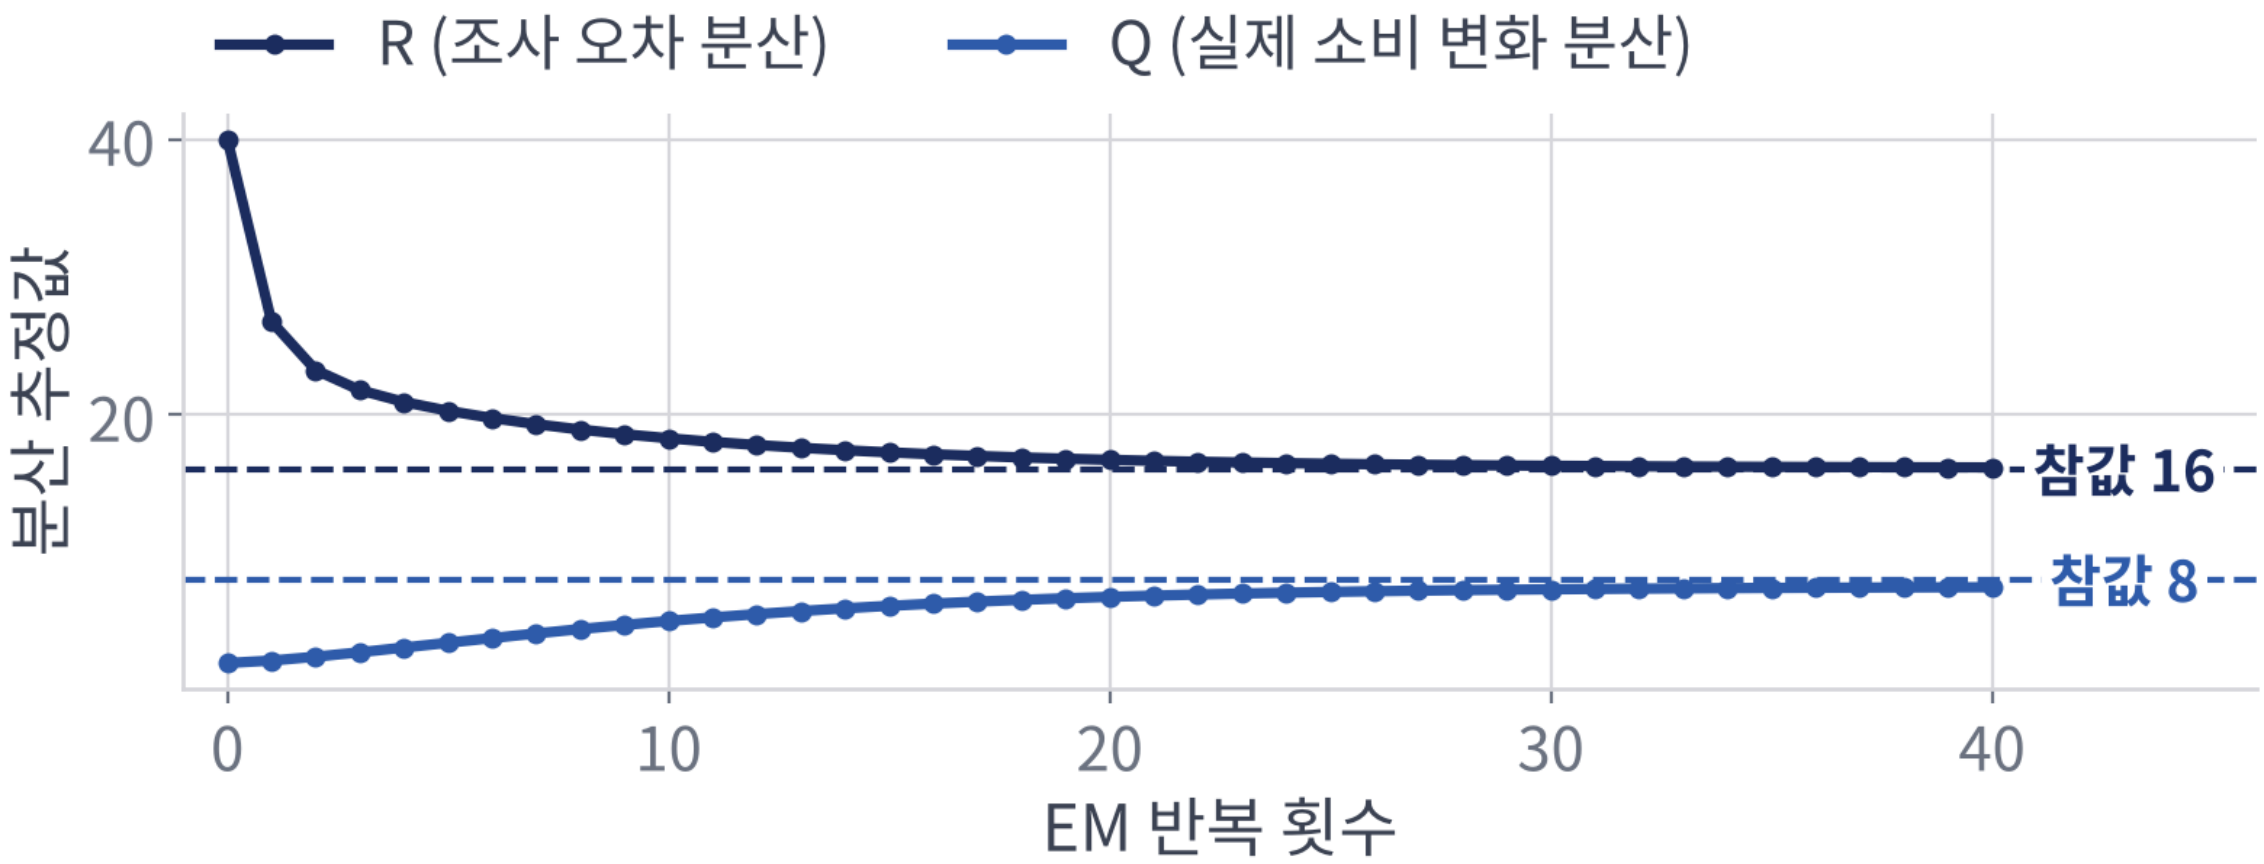


왜 그런가

- V는 보정 항이 아니라 기댓값 계산에서 저절로 생기는 항이다
- 빼면 실제 소비를 한 점으로 확정하고 계산한 셈이다
- V는 항상 양수라 R이 그만큼 작아진다
- 작아진 R은 다음 E단계에서 조사를 지나치게 믿게 만든다

E와 M을 반복할수록 Q와 R이 참값 근처에 자리 잡는다

초깃값 Q = 2, R = 40에서 출발 · 같은 240개월 예시 자료 · ※ 예시 데이터



실습 · 소비 예제를 클코로 끝까지 풀어 본다

큰 그림: 실제 평균 소비가 상태이고 조사 평균이 관측값이며, 학습할 숫자는 Q와 R이다

[입력] 프롬프트 · Claude Code 데스크톱 앱 · Code 탭

```
상태공간모형 실습을 해 줘. 작업 폴더는 ssm_lab/consumption.

1. 모형: 상태 x(t) = x(t-1) + w, 관측 y(t) = x(t) + v
   (상태 = 실제 평균 소비, 관측 = 조사 평균, 단위 만 원)
2. Q=8, R=16, 시작 300으로 120개월 자료를 시뮬레이션해 줘.
3. 칼만 필터·스무더·EM을 numpy로 직접 구현해 줘.
   EM은 Q=2, R=40에서 시작해 Q와 R을 학습하고,
   반복마다 E단계 출력과 M단계 출력(새 Q·R)을 표로 남겨 줘.
4. 그림 3장: 실제·조사·필터·스무딩 경로 /
   필터 분산 P와 스무딩 분산 V / 반복별 Q·R 경로
5. report.md로 정리하고 그림과 함께 열어 줘.
   오류가 나면 스스로 고쳐서 끝까지 실행해 줘.
```

출력과 확인

- 출력: 시뮬레이션 자료, 필터·스무더·EM 코드, 그림 3장, report.md
- Q와 R이 참값 8과 16 근처로 수렴하는가?
- V가 P보다 작고 마지막 달에 같아지는가?
- E단계 출력과 M단계 출력이 표에서 구분되는가?

03

PART 3 · 금리 예제

잠재적인 공통 금리 수준 추정

금리를 지속적인 수준과 일시적인 벗어남으로 나누는 통계 모형

시장금리를 지속 수준과 일시적 벗어남으로 나눈다

관측값은 매일 관측하는 동일 만기의 시장금리다

상태방정식

$$\underbrace{\ell_t}_{\text{금리 수준}} = \ell_{t-1} + \underbrace{w_t}_{\text{수준 변화}}, \qquad w_t \sim N(0, Q)$$

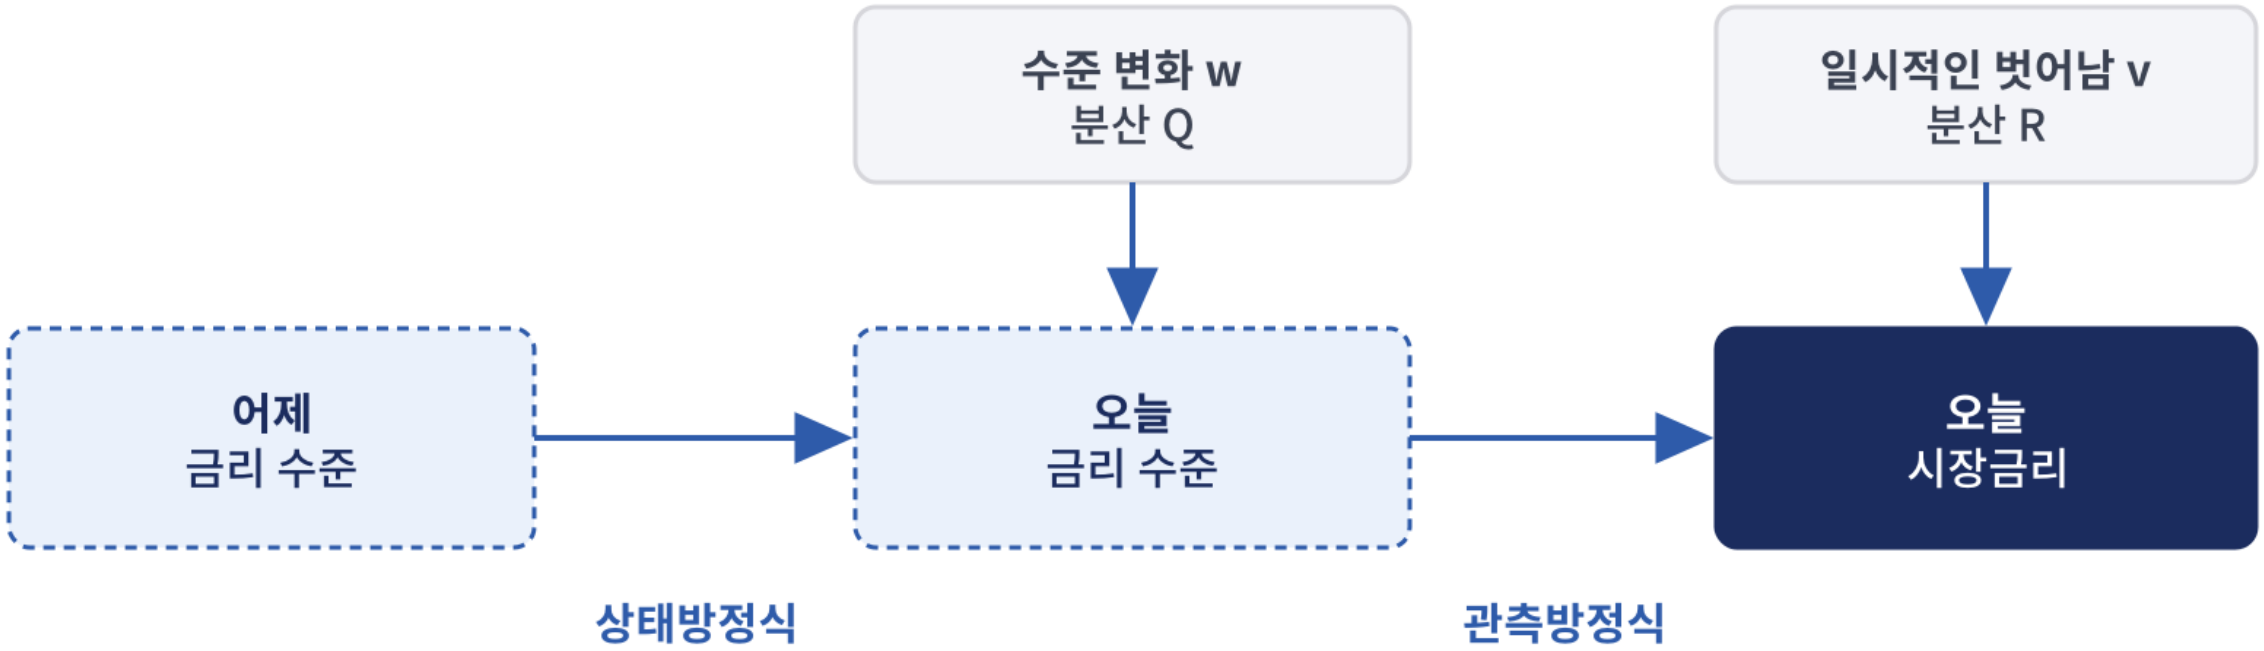
관측방정식

$$\underbrace{y_t}_{\text{시장금리}} = \ell_t + \underbrace{v_t}_{\text{일시적 벗어남}}, \qquad v_t \sim N(0, R)$$

부분	의미
ℓ_t	여러 날에 걸쳐 이어지는 금리 수준
w_t	그 수준을 바꾸는 새로운 변화
v_t	관측 금리가 그 수준에서 벗어난 부분

소비 예제와 같은 구조에서 상태가 잠재 수준으로 바뀐다

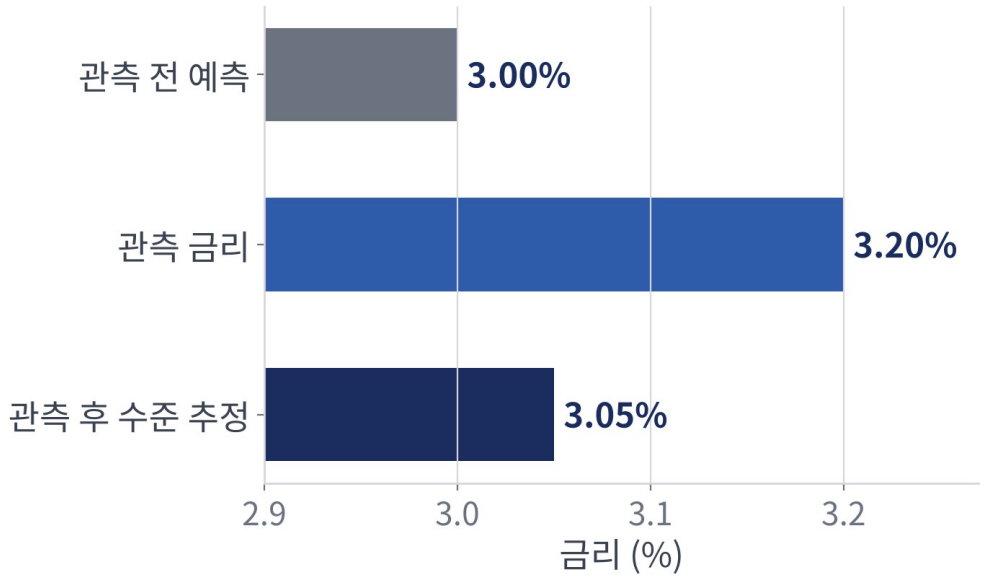
소비 예제는 실제 평균이라는 대상이 있었지만, 여기서는 모형이 지속되는 부분을 수준으로 정의한다



금리가 0.20%p 오르면 수준 추정은 0.05%p 오른다

가상 예시 · 3.00은 금리 3.00% · 분산 단위는 (%p)²

항목	가상 값
오늘 수준의 예측	3.00%
예측 오차 분산	0.0025
관측 잔차 분산 R	0.0075
실제 관측 금리	3.20%



결과

$$K_t = \frac{0.0025}{0.0025 + 0.0075} = 0.25, \qquad \hat{\ell}_t = 3.00 + 0.25(3.20 - 3.00) = 3.05\%$$

금리 EM도 E단계 출력이 M단계의 입력이 된다

소비 예제의 실제 소비 자리에 금리 수준을 넣으면 같은 계산이 된다

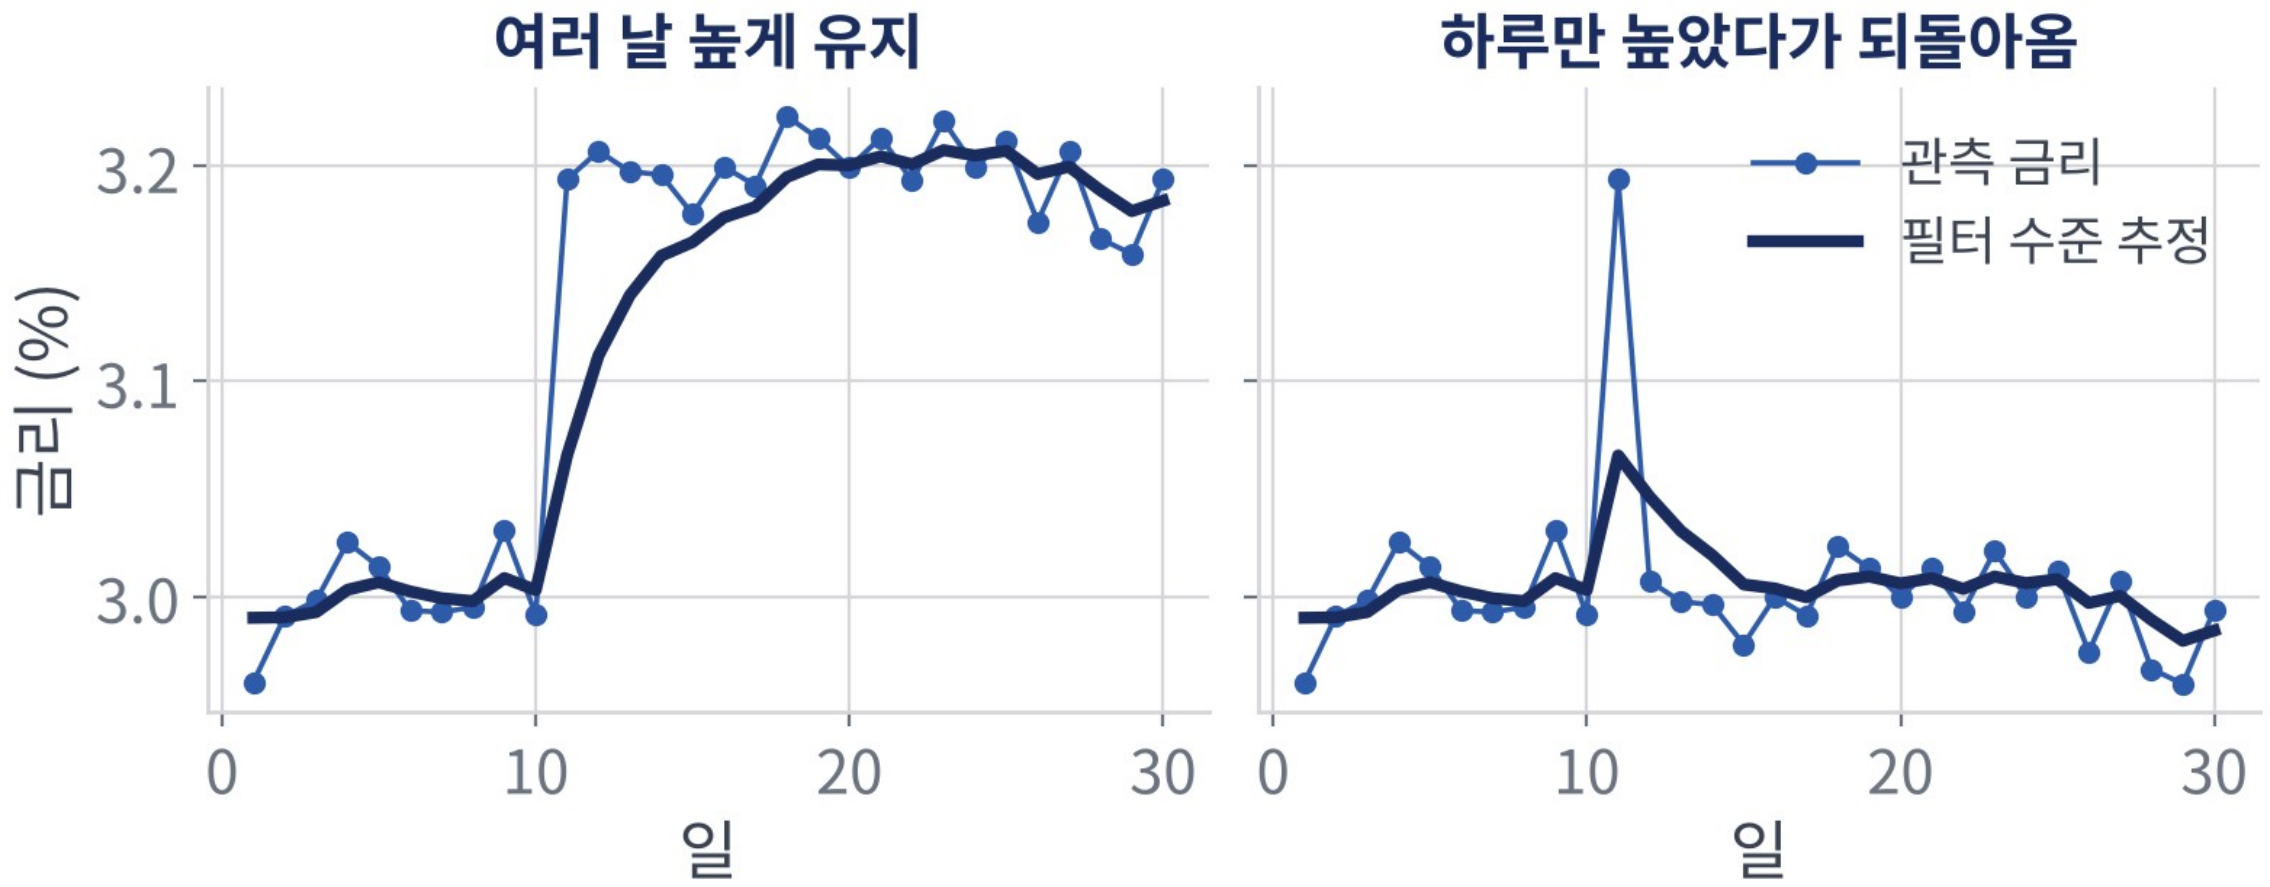
단계	입력	출력
E단계	지금 쓰는 Q·R과 금리 기록	날짜별 금리 수준의 평균과 불확실성, 두 종류의 기대 제곱 잔차
M단계	E단계의 기대 제곱 잔차	새 Q: 수준이 날마다 바뀐 크기의 평균
M단계	E단계의 기대 제곱 잔차	새 R: 관측 금리가 수준에서 벗어난 크기의 평균

직관

- 여러 날 이어지는 변화가 많으면 Q가, 하루 튀고 돌아오는 값이 많으면 R이 커진다

상승의 지속 여부가 Q와 R을 가르는 단서다

여러 날 유지되면 수준 변화, 하루 튀고 돌아오면 일시적 벗어남 · ※ 예시 데이터



실습 · 실제 금리 자료로 수준을 추정한다

큰 그림: 잠재 금리 수준이 상태이고 시장금리가 관측값이며, 학습할 숫자는 Q와 R이다

[입력] 프롬프트 · Claude Code 데스크톱 앱 · Code 탭

```
금리 예제를 실습해 줘. 작업 폴더는 ssm_lab/rate.

1. FRED에서 미국 10년 국채금리(DGS10) 일별 자료를
   2015년부터 내려받고 결측일은 빼 줘.
2. 모형: 수준 l(t) = l(t-1) + w, 관측 y(t) = l(t) + v
3. 칼만 필터·스무더·EM을 numpy로 구현해 Q와 R을 학습하고,
   statsmodels UnobservedComponents(local level)
   추정 결과와 비교해 줘.
4. 그림: 관측 금리와 필터·스무딩 수준 /
   금리가 크게 움직인 날 전후의 확대 그림
5. Q/R 비율의 의미를 한 문단으로 해석해 report.md에 쓰고
   그림과 함께 열어 줘. 오류는 스스로 고쳐 줘.
```

출력과 확인

- 출력: 금리 자료, EM 결과와 statsmodels 비교표, 그림 2장, report.md
- EM과 statsmodels의 Q·R이 비슷한가?
- 이어진 상승에는 수준이 크게, 하루 튄 날에는 조금만 움직이는가?

04

PART 4 · EWC·EWA 헤징

헤지 비율을 매일 갱신

EWC(캐나다 주식 ETF)를 보유하고 EWA(호주 주식 ETF)를 매도하는 교육용 예제

헤지 비율이 상태, EWC 수익률이 관측값이다

수익률을 쓰고 절편은 0으로 고정한다 · 같은 거래 구간의 미국 달러 기준 수익률

상태방정식

$$\underbrace{\beta_t}_{\text{헤지 비율}} = \beta_{t-1} + \underbrace{w_t}_{\text{비율 변화}}, \qquad w_t \sim N(0, Q)$$

관측방정식

$$\underbrace{r_{\mathrm{EWC},t}}_{\text{EWC 수익률}} = \beta_t \underbrace{r_{\mathrm{EWA},t}}_{\text{EWA 수익률}} + \underbrace{v_t}_{\text{EWC 개별 움직임}}, \qquad v_t \sim N(0, R)$$

목적

- EWA와 함께 움직이는 EWC 수익률 부분을 EWA 매도로 상쇄한다

상태의 성격

- 가격과 수익률은 관측되지만 그 관계를 설명하는 비율은 추정해야 한다

기본 모형의 기호가 헤징 문제로 옮겨진다

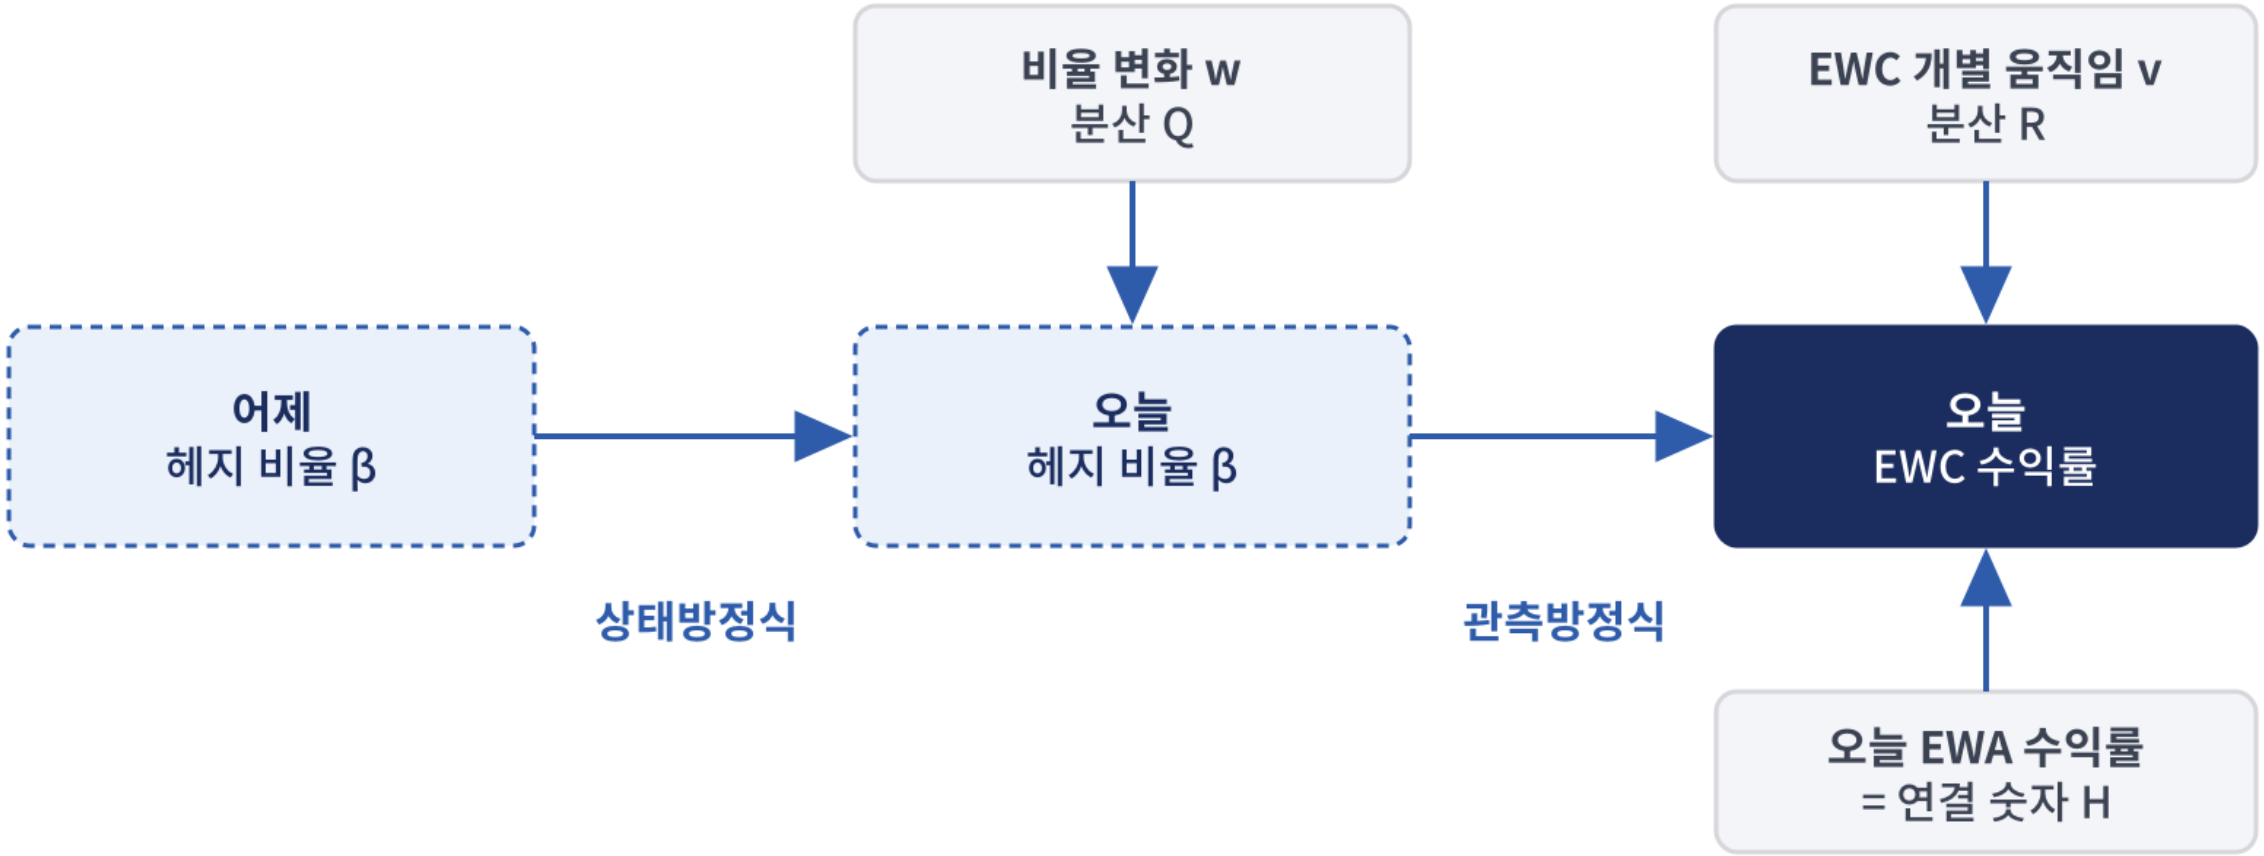
관측식의 연결 숫자 자리에 그날 관측한 EWA 수익률이 들어간다

기본 모형의 기호	이 예제에서의 의미
x_t	헤지 비율
y_t	EWC 수익률
H_t	관측한 EWA 수익률
Q	헤지 비율이 시간에 따라 변하는 정도
R	EWA로 설명되지 않는 EWC 수익률의 분산

상태는 수익률 관계를 나타내는 계수다

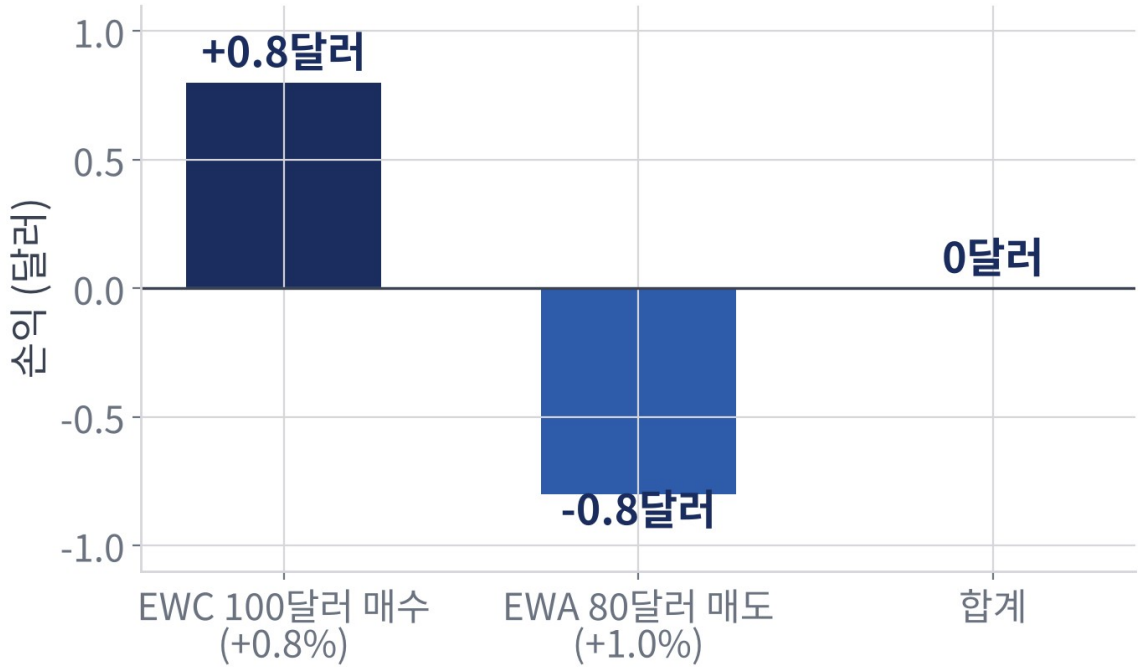
EWA 수익률이 관측식의 연결 숫자 역할을 한다

오늘 헤지 비율과 오늘 EWA 수익률이 함께 오늘 EWC 수익률을 설명한다



헤지 비율 0.8은 100달러당 80달러 매도다

수익률 회귀의 헤지 비율은 금액 비율이다 · 수익률이 관계대로 움직인 가상 상황



주식 수량으로 바꿀 때

$$\text{EWA 매도 수량} = \beta \times \text{EWC 보유 수량} \times \frac{\text{EWC 가격}}{\text{EWA 가격}}$$

실제 손익에 남는 것

- 관측식 잔차, 거래비용, 매도 관련 비용
- 이 관계만으로 평균회귀나 수익성이 보장되지 않는다

예상보다 큰 EWC 상승이 비율을 1.00으로 올린다

가상 예시 · 수익률은 소수로 계산한다 (1% = 0.01) · 예상 +0.8%, 실제 +1.2%

항목	값
헤지 비율 예측	0.80
예측 오차 분산	0.04
EWA 수익률 (연결 숫자)	0.010
실제 EWC 수익률	0.012
관측 잔차 분산 R	0.000004

칼만 이득은 가중치와 다르다

- 연결 숫자가 1이 아니면 K는 0과 1 사이일 필요가 없다
- 보정 크기는 K와 혁신의 곱으로 판단한다

결과 · 보정 후 오차 분산은 0.04에서 0.02로

$$K_t = \frac{0.04 \times 0.010}{0.010^2 \times 0.04 + 0.000004} = 50, \qquad \hat{\beta}_t = 0.80 + 50 \times 0.004 = 1.00$$

비율은 관측 후 갱신해 다음 시점에 반영한다

EWA 수익률이 음수인 날에는 차이와 비율 수정의 방향을 함께 계산한다

1. 오늘 거래 구간

어제까지의 정보로 정한 비율을 사용한다

2. 구간 종료

두 ETF 수익률을 관측한다

3. 필터 갱신

칼만 필터로 비율을 1.00으로 갱신한다

4. 다음 체결 시점

EWC 100달러당 EWA 100달러 매도로 조정한다

헤징 EM도 E단계가 비율의 범위를 넘겨준다

EWA 수익률을 관측한 입력으로 둔다 · 기댓값은 지금 쓰는 Q·R로 계산한다

단계	출력
E단계	매일 헤지 비율의 평균과 불확실성, 이웃한 날 사이의 연관, 두 종류의 기대 제곱 잔차
M단계 · 새 Q	헤지 비율이 하루 사이 바뀐 크기의 기대 제곱을 평균
M단계 · 새 R	관측식 잔차의 기대 제곱을 평균

$$\underbrace{Q_{\text{new}}}_{\text{비율 변화 분산}} = \frac{1}{T-1}\sum_{t=2}^{T} E[(\beta_t - \beta_{t-1})^2 \mid \text{전체 자료}]$$

$$\underbrace{R_{\text{new}}}_{\text{관측 잔차 분산}} = \frac{1}{T}\sum_{t=1}^{T} E[(r_{\text{EWC},t} - \beta_t r_{\text{EWA},t})^2 \mid \text{전체 자료}]$$

E단계는 R용 값에 헤지 비율의 불확실성까지 담는다

제곱의 평균 = 평균의 제곱 + 분산 · 잔차의 분산은 EWA 수익률의 제곱 × V가 된다

$$\underbrace{(r_{\mathrm{EWC},t} - m_t r_{\mathrm{EWA},t})^2}_{\text{스무딩 평균 기준 잔차}} + \underbrace{r_{\mathrm{EWA},t}^2 V_t}_{\text{헤지 비율의 불확실성}}$$

Q가 크면

- 비율이 실제로 바뀔 가능성을 더 크게 허용한다

R이 크면

- 두 ETF의 하루 차이를 개별 움직임으로 더 많이 받아들인다

EWA 수익률이 0 근처면

- 그날 자료가 비율에 주는 정보가 적다. 정확히 0이면 칼만 이득도 0이다

백테스트의 각 거래 시점에서는 그때까지의 자료만 쓴다

스무더는 과거 학습 구간의 EM에만 쓴다 · 미래 정보가 든 스무딩 비율로 거래를 평가하지 않는다



실습 · EWC·EWA 동적 헤지를 백테스트한다

큰 그림: 헤지 비율이 상태이고 EWC 수익률이 관측값이며, EWA 수익률이 연결 숫자다

[입력] 프롬프트 · Claude Code 데스크톱 앱 · Code 탭

```
EWC·EWA 동적 헤징을 실습해 줘. 작업 폴더는 ssm_lab/hedge.

1. yfinance로 EWC, EWA 수정주가를 2012년부터 받아
   일별 수익률을 만들어 줘.
2. 모형: 비율 b(t) = b(t-1) + w
         r_EWC(t) = b(t) * r_EWA(t) + v  (절편 0)
3. 2012~2018년 자료로 EM을 돌려 Q·R을 학습하고,
   2019년 이후는 필터만 돌려 매일 비율을 갱신해 줘.
4. 백테스트: 오늘 포지션은 어제까지의 비율만 쓴다
   (스무딩 비율 사용 금지). 고정 OLS 비율과
   헤지 후 수익률의 변동성을 비교해 줘.
5. 그림: 동적 비율과 고정 비율 / 두 헤지의 누적 손익.
   report.md로 정리하고 열어 줘. 오류는 스스로 고쳐 줘.
```

출력과 확인

- 출력: 학습 구간 Q·R, 매일의 헤지 비율, 백테스트 비교표, 그림 2장
- 포지션에 미래 정보가 들어가지 않았는가?
- 동적 헤지가 헤지 후 변동성을 줄였는가? 아니라면 Q가 지나치게 크거나 작지 않은가?

05

PART 5 · 확률적 변동성

시장의 흔들림 자체를 상태로 추정

Stochastic Volatility(SV) 모형 · 정규 준우도 근사

확률적 변동성 모형은 로그 분산을 숨은 상태로 둔다

평균을 제거한 일별 수익률을 쓴다 · 두 충격은 서로 독립이고 시간 사이에도 독립이다

상태방정식

$$\underbrace{h_t}_{\text{로그 분산}} = \underbrace{\mu_h}_{\text{장기 평균}} + \underbrace{\phi}_{\text{지속성}}(h_{t-1} - \mu_h) + \underbrace{\eta_t}_{\text{변동성 충격}}, \qquad \eta_t \sim N(0, Q)$$

관측방정식

$$\underbrace{r_t}_{\text{수익률}} = \underbrace{\exp(h_t/2)}_{\text{변동성}} \underbrace{\varepsilon_t}_{\text{표준화된 충격}}, \qquad \varepsilon_t \sim N(0, 1)$$

알고 싶은 대상

- 오늘 시장이 얼마나 크게 흔들릴 수 있는가

SV 모형의 관점

- 같은 주식도 조용한 시기와 크게 출렁이는 시기가 있어 변동성도 매일 달라진다

SV 모형의 기호는 수익률·변동성·두 충격으로 나뉜다

지속성이 1보다 작으면 장기 평균으로 돌아가고, 1에 가까울수록 충격이 오래 이어진다

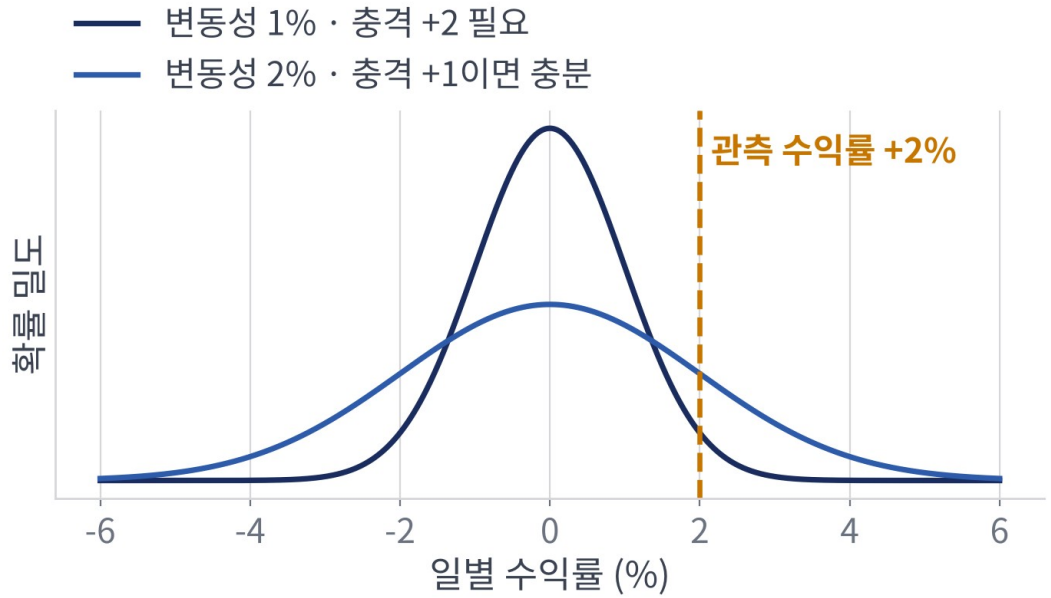
기호	의미
r_t	관측한 수익률 (1%는 0.01)
h_t	로그 분산인 숨은 상태
$\sigma_t = \exp(h_t/2)$	일별 변동성 · 수익률의 조건부 표준편차
μ_h	로그 분산이 돌아가려는 장기 평균
ϕ	높거나 낮은 로그 분산이 이어지는 정도
η_t	변동성 상태에 새로 생기는 충격
Q	로그 분산 충격의 분산
ε_t	그날 수익률의 방향과 크기를 만드는 표준화된 충격

하루 수익률 하나로는 변동성을 확정할 수 없다

같은 +2% 수익률을 만드는 두 가상 상황

$$\text{오늘 수익률} = \text{오늘 변동성} \times \text{오늘 표준화된 충격}$$

가상 상황	변동성	충격
흔들림은 작지만 큰 충격	1%	+2
흔들림이 크고 보통 충격	2%	+1

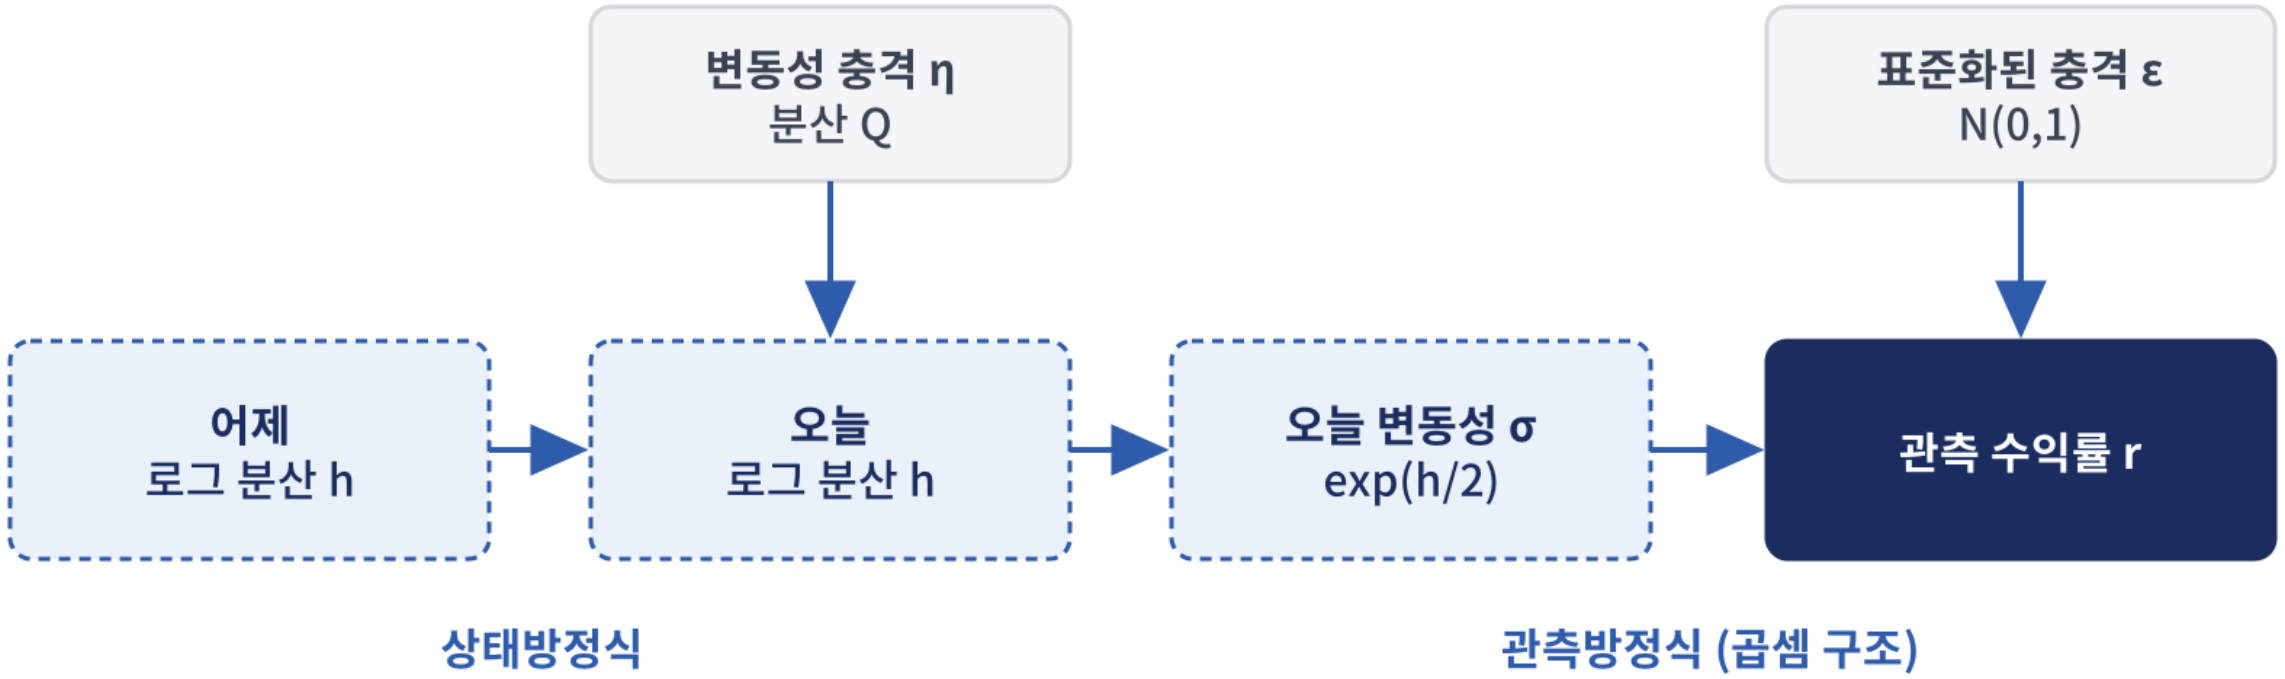


그래서

- 여러 날의 움직임과 상태방정식의 지속성을 함께 쓴다. 큰 하락도 변동성이 높다는 단서다

변동성과 표준화된 충격의 곱이 수익률이다

관측식이 곱셈 구조라 상태가 수익률의 분산을 바꾼다



제곱하고 로그를 취하면 관측식이 덧셈 꼴이 된다

원래 SV 관측식에서는 일반 칼만 필터가 정확한 사후분포를 계산하지 못한다

제곱하고 로그

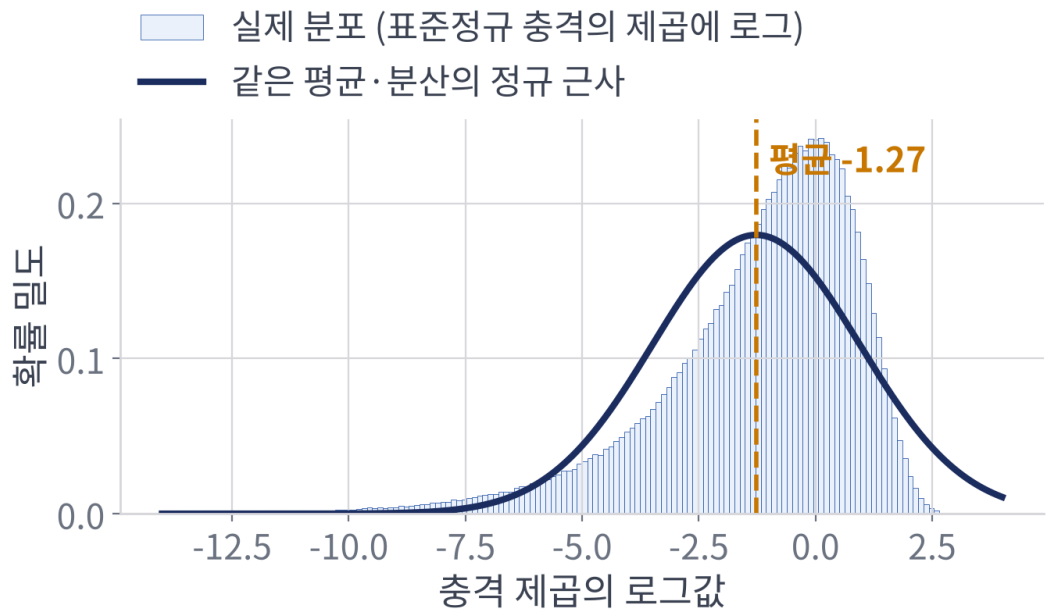
$$\log(r_t^2) = h_t + \log(\varepsilon_t^2)$$

표준정규 충격의 상수

$$c = E[\log(\varepsilon_t^2)] \approx -1.2704, \qquad \mathrm{Var}[\log(\varepsilon_t^2)] = \frac{\pi^2}{2} \approx 4.9348$$

정의

$$z_t = \log(r_t^2) - c, \qquad u_t = \log(\varepsilon_t^2) - c$$



변환 후 식은 선형이지만 오차는 정규분포가 아니다

같은 평균·분산의 정규분포로 근사하면 칼만 필터와 스무더를 연결할 수 있다 · 정규 준우도 접근

변환 후 상태방정식

$$\underbrace{h_t}_{\text{로그 분산}} = \underbrace{\mu_h}_{\text{장기 평균}} + \underbrace{\phi}_{\text{지속성}}(h_{t-1} - \mu_h) + \underbrace{\eta_t}_{\text{변동성 충격}}, \qquad \eta_t \sim N(0, Q)$$

변환 후 관측방정식

$$\underbrace{z_t}_{\text{변환한 관측값}} = h_t + \underbrace{u_t}_{\text{비정규 오차}}, \qquad E[u_t] = 0, \quad \mathrm{Var}(u_t) = \pi^2/2$$

해석 주의

- 일반 칼만 필터로 원래 SV 모형을 정확히 추정했다고 해석하면 안 된다

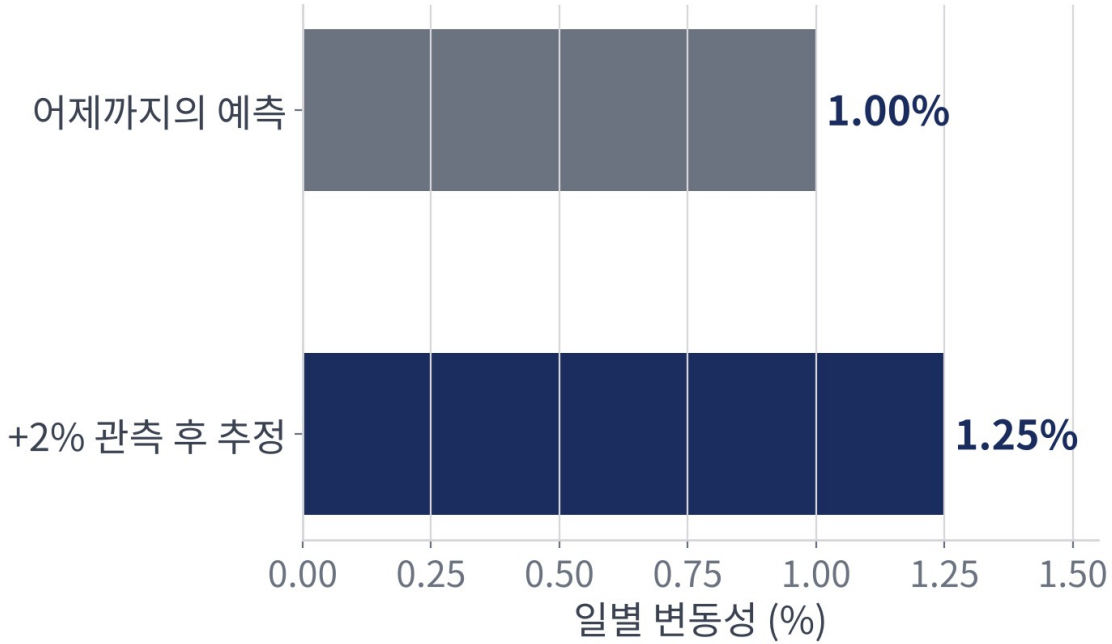
구현 주의

- 수익률이 정확히 0이면 로그를 계산할 수 없다. 보정값과 수익률 단위를 기록한다

+2% 하루 움직임이 변동성 추정을 1.25%로 높인다

가상 예시 · 예측 오차 분산 1 가정 · −2%여도 제곱값이 같아 갱신은 같다 · 손계산은 워크북

$$\hat{h}_t^- \approx -9.2103 \;\rightarrow\; \hat{h}_t \approx -8.7627, \qquad \hat{\sigma}_t = \exp(\hat{h}_t/2) \approx 1.25\%$$



정규 근사 사후분포에서

$\underbrace{\exp(\hat{h}_t/2)}$ 변동성의 중앙값

$\underbrace{\exp(\hat{h}_t/2 + P_t/8)}$ 변동성의 사후평균

비선형 변환의 함정

- 평균을 먼저 구해 변환한 값과 변환한 뒤 평균 낸 값은 다르다

정규 근사 모형에서는 Q부터 학습한다

이 EM이 최대화하는 것은 정규 근사 모형의 우도다 · 관측 오차 분산은 고정된다

단계	출력
E단계	필터와 스무더로 각 날 로그 분산의 평균·불확실성·이웃한 날 사이의 연관
M단계	상태방정식 잔차의 기대 제곱을 평균한 새 Q

$$\underbrace{Q_{\text{new}}}_{\text{로그 분산 충격 분산}} = \frac{1}{T-1}\sum_{t=2}^{T} E\left[\{h_t - \mu_h - \phi(h_{t-1}-\mu_h)\}^2 \mid z_1, \ldots, z_T\right]$$

확장 · 지속성도 갱신

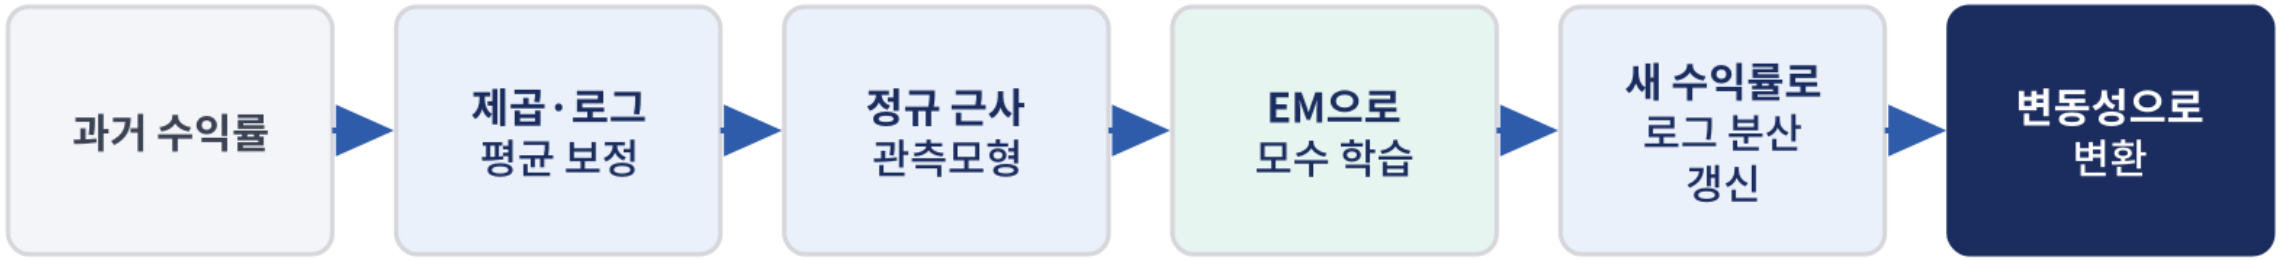
$$h_t = a + \phi h_{t-1} + \eta_t, \qquad \mu_h = a/(1-\phi)$$

더 정밀한 방법

- 혼합정규, 입자필터·시뮬레이션 EM, 베이지안 MCMC

SV 추정은 변환에서 시작해 변환으로 끝난다

헤징은 함께 움직이는 정도가, SV는 흔들림의 크기가 상태다 · 둘을 함께 바꾸면 더 복잡해진다



실습 · SPY 수익률로 변동성을 추정한다

큰 그림: 로그 분산이 상태이고 변환한 수익률이 관측값이며, 정규 근사로 칼만 필터를 쓴다

[입력] 프롬프트 · Claude Code 데스크톱 앱 · Code 탭

```
확률적 변동성 실습을 해 줘. 작업 폴더는 ssm_lab/sv.

1. yfinance로 SPY 수정주가를 2010년부터 받아
   일별 로그수익률을 만들고 평균을 빼 줘.
2. z(t) = log(r(t)^2) + 1.2704 로 변환하고,
   수익률이 0인 날의 처리 방법을 정해 기록해 줘.
3. 상태 h(t) = mu + phi*(h(t-1) - mu) + eta
   관측 z(t) = h(t) + u, Var(u) = pi^2/2 (정규 근사)
4. 칼만 필터·스무더로 h를 추정하고 EM으로 Q를 학습해 줘.
   mu와 phi도 함께 추정하는 확장판도 만들어 줘.
5. 그림: |수익률|과 추정 변동성 exp(h/2) /
   21일 실현변동성과의 비교.
   report.md로 정리하고 열어 줘. 오류는 스스로 고쳐 줘.
```

출력과 확인

- 출력: 변환 자료, 추정 변동성 시계열, Q(확장판은 mu·phi 포함), 그림 2장
- 2020년 3월에 추정 변동성이 치솟는가?
- report에 정규 근사 모형의 추정이라는 점을 밝혔는가?

06

PART 6 · 헤스톤 변동성

옵션 가격모형의 변동성도 상태로 본다

분산의 평균회귀와 두 충격의 상관 · 비선형 필터의 필요성

헤스톤 모형은 분산 자체를 상태로 둔다

분산은 변동성의 제곱이다 · 시간 간격을 Δt로 쓴다

상태방정식

$$\underbrace{v_t}_{\text{오늘 분산}} = v_{t-1} + \underbrace{\kappa(\theta - v_{t-1})\Delta t}_{\text{장기 수준으로 회귀}} + \underbrace{\sigma_v \sqrt{v_{t-1}}\,\eta_t}_{\text{분산 충격}}, \qquad \eta_t \sim N(0, \Delta t)$$

관측방정식

$$\underbrace{r_t}_{\text{수익률}} = \left(\mu - \frac{1}{2} v_t\right)\Delta t + \underbrace{\sqrt{v_t}\,\varepsilon_t}_{\text{수익률 충격}}, \qquad \varepsilon_t \sim N(0, \Delta t)$$

SV와의 차이

- SV는 로그 분산을, 헤스톤은 분산을 상태로 둔다

중요한 특징

- 수익률 충격과 분산 충격이 독립이 아닐 수 있다

헤스톤은 평균회귀와 충격 상관을 함께 담는다

가격이 크게 하락할 때 변동성이 오르는 현상을 레버리지 효과라 부른다

기호	쉬운 의미
v_t	오늘의 숨은 분산 · 변동성의 제곱
θ	장기적으로 돌아가려는 분산 수준
κ	장기 수준으로 돌아가는 속도
σ_v	분산 자체가 흔들리는 정도 (vol of vol)
ε_t	수익률 충격
η_t	분산 충격
ρ	수익률 충격과 분산 충격의 상관관계

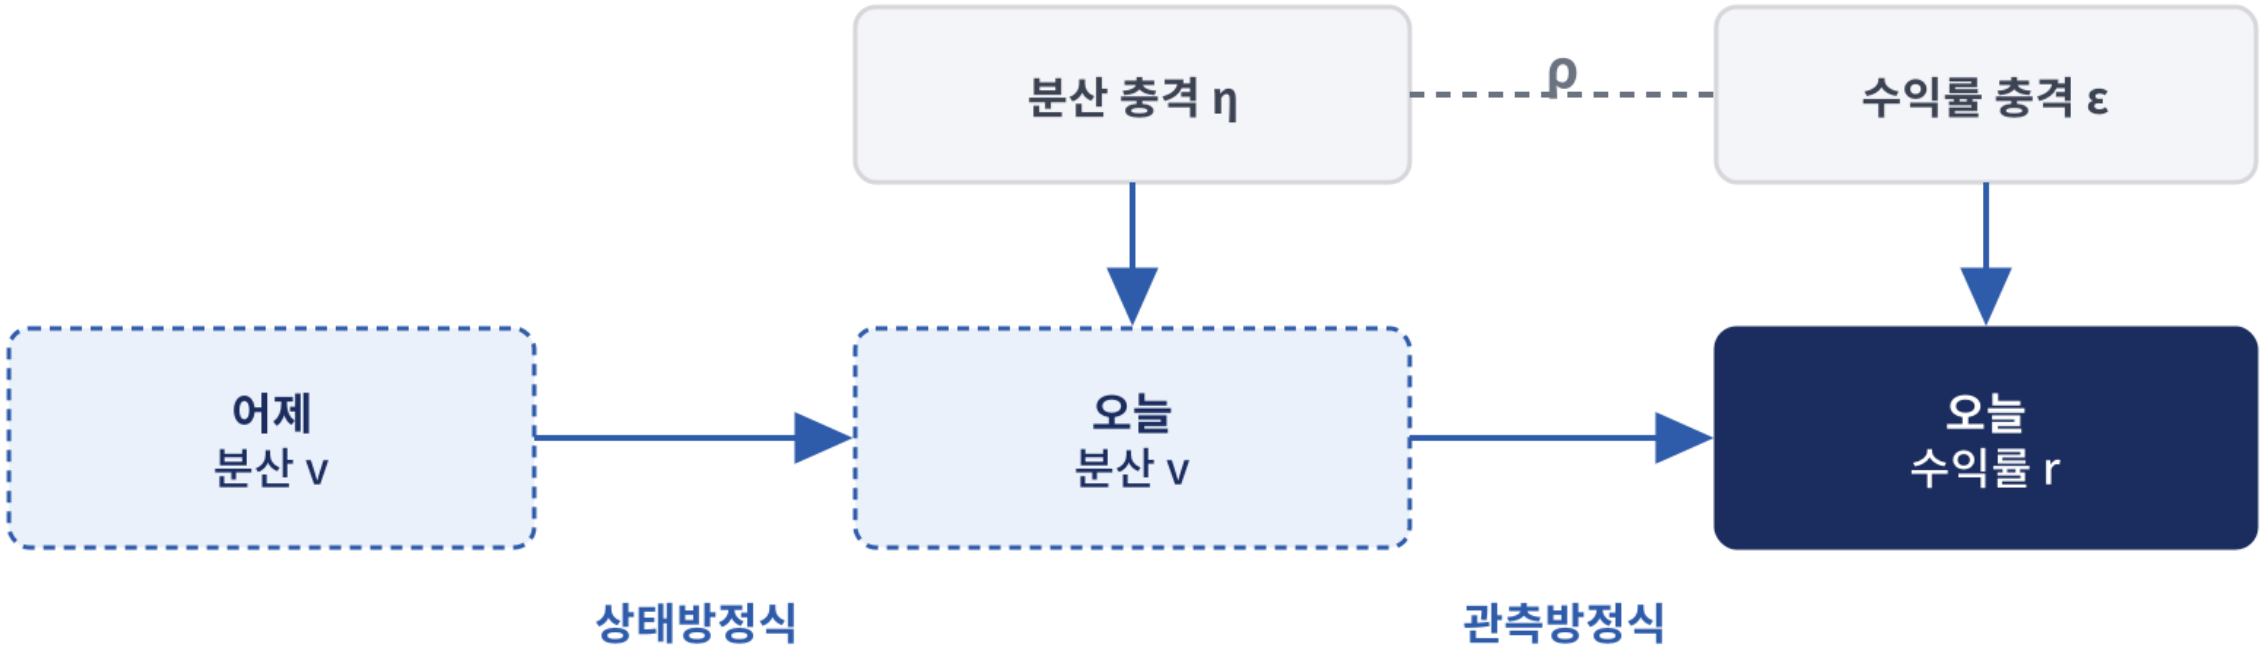
$$\mathrm{Corr}(\underbrace{\varepsilon_t}_{\text{수익률 충격}}, \underbrace{\eta_t}_{\text{분산 충격}}) = \rho$$

레버리지 효과

- 가격이 크게 하락할 때 변동성이 올라간다
- 이때 상관은 보통 음수로 해석한다

분산 충격과 수익률 충격은 상관관계로 이어진다

점선이 두 충격 사이의 상관을 나타낸다



헤스톤은 표준 칼만 필터로 바로 풀기 어렵다

앞의 소비·금리·헤징 예제는 관측방정식이 선형이고 오차가 정규분포였다

어려운 점	이유
비선형	수익률에 분산의 제곱근이 들어간다
상태 의존 분산	분산 충격의 크기도 분산의 제곱근에 비례한다
양수 제약	분산은 음수가 될 수 없다
충격 상관	두 충격이 상관관계로 연결된다

방법	쉬운 설명
EKF	비선형식을 현재 추정값 주변에서 직선으로 근사
UKF	몇 개의 대표점을 움직여 비선형 변환을 근사
입자 필터	가능한 분산 경로를 많은 입자로 표현
옵션 가격 기반	옵션 가격·내재변동성까지 함께 사용

칼만 필터는 곧은 자로 재는 문제에 강하고, 헤스톤은 굽은 곡선과 양수 제약이 있는 문제다

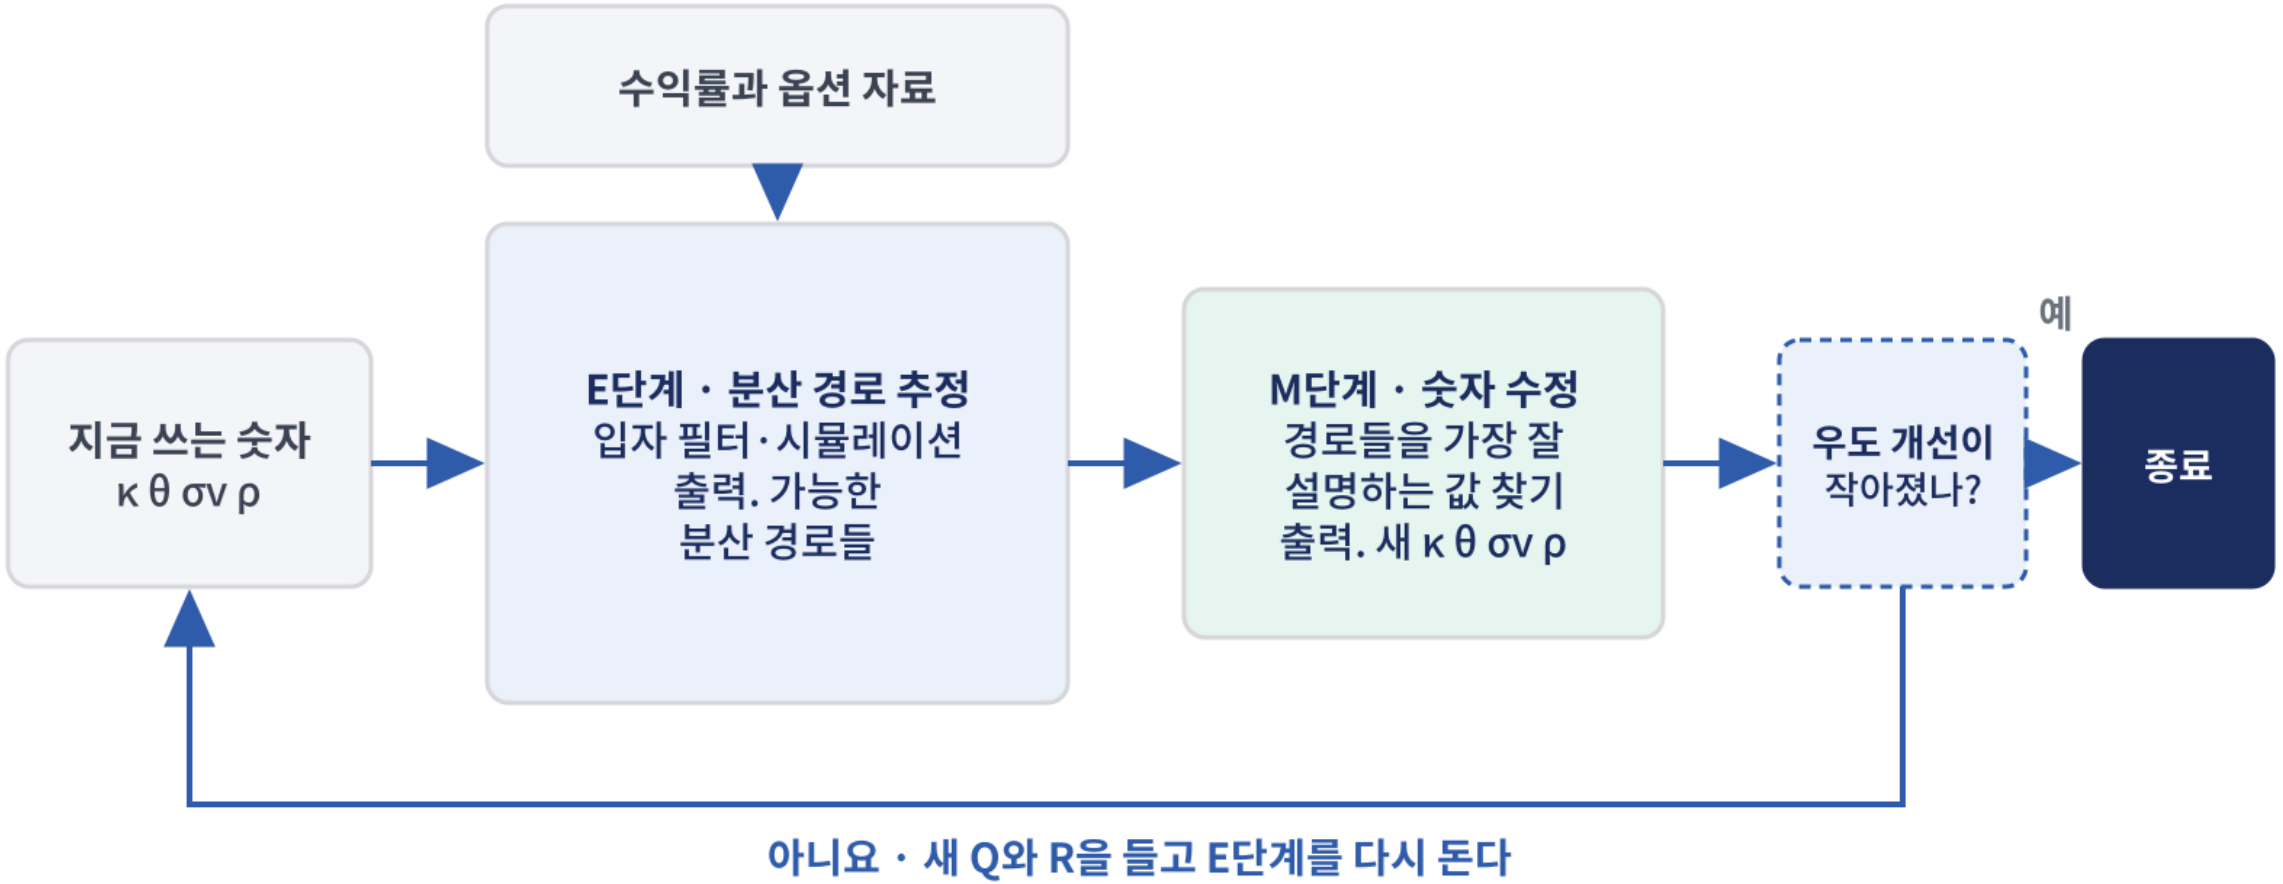
헤스톤의 핵심 구조도 상태공간모형이다

EKF는 확장 칼만 필터, UKF는 무향 칼만 필터를 말한다

기본 상태공간모형	헤스톤 예제
상태	숨은 분산
관측값	수익률, 또는 옵션 가격·내재변동성
상태방정식	분산이 장기 평균으로 회귀
관측방정식	분산이 수익률 또는 옵션 가격을 설명
칼만 필터류	오늘의 분산을 순차적으로 추정
EM류	회귀 속도·장기 수준·vol of vol·상관 등을 반복 추정

헤스톤의 E단계는 분산 경로를 시뮬레이션한다

닫힌 형태로 끝나지 않는다 · 옵션 가격을 쓰면 관측식이 헤스톤 가격공식이나 수치 가격함수가 된다



비선형성을 단계적으로 높여 가며 배운다

교육용 학습 순서

1. 기본 SV

로그 분산을 정규 근사로 추정한다

2. 헤스톤

분산이 장기 수준으로 평균회귀한다는 점을 배운다

3. 옵션 가격 추가

추정 문제가 훨씬 비선형이 된다는 점을 이해한다

실습 · 입자 필터로 헤스톤 분산을 추적한다

큰 그림: 분산이 상태이고 수익률이 관측값이며, 비선형이라 입자 필터를 쓴다 · 시뮬레이션 자료

[입력] 프롬프트 · Claude Code 데스크톱 앱 · Code 탭

```
헤스톤 변동성 실습을 해 줘. 작업 폴더는 ssm_lab/heston.

1. kappa=3, theta=0.04, sigma_v=0.5, rho=-0.7, mu=0.05로
   일별 5년 경로를 시뮬레이션해 줘.
   분산이 음수가 되지 않게 하는 처리 방법도 정해 줘.
2. 수익률만 보고 숨은 분산을 추정하는
   입자 필터(입자 2,000개)를 구현해 줘.
3. 실제 분산 경로와 입자 필터 추정, 90% 구간을 그려 줘.
4. 같은 자료에 SV 정규 근사 칼만 필터도 적용해
   두 방법의 추정 오차를 비교해 줘.
5. report.md로 정리하고 그림과 함께 열어 줘.
   오류가 나면 스스로 고쳐서 끝까지 실행해 줘.
```

출력과 확인

- 출력: 시뮬레이션 경로, 입자 필터 추정과 90% 구간, 두 방법 비교표
- 실제 분산 경로가 대부분 90% 구간 안에 들어오는가?
- 이어서 rho를 0으로 바꿔 다시 실행하게 하고 차이를 비교한다

07

PART 7 · 나우캐스팅

지금 경기 상태를 여러 지표로 추정

공식 GDP 발표 전, 이미 나온 월별·주별 지표로 현재 경기를 추정한다

나우캐스팅은 여러 지표로 경기 상태를 추정한다

아직 공식 GDP가 발표되기 전에 현재 경기 상태를 추정하는 작업이다

상태방정식

$$\underbrace{g_t}_{\text{경기 상태}} = A\, g_{t-1} + \underbrace{w_t}_{\text{경기 충격}}, \qquad w_t \sim N(0, Q)$$

관측방정식

$$\underbrace{y_t}_{\text{경제지표}} = H_t\, g_t + \underbrace{v_t}_{\text{지표별 잡음}}, \qquad v_t \sim N(0, R)$$

상태

- 지금의 숨은 경기 상태 또는 GDP 성장률 흐름

관측값

- 산업생산, 소매판매, 수출, 고용, 물가, 금융지표 같은 여러 지표

관측값이 여러 개라 관측방정식은 벡터 꼴이 된다

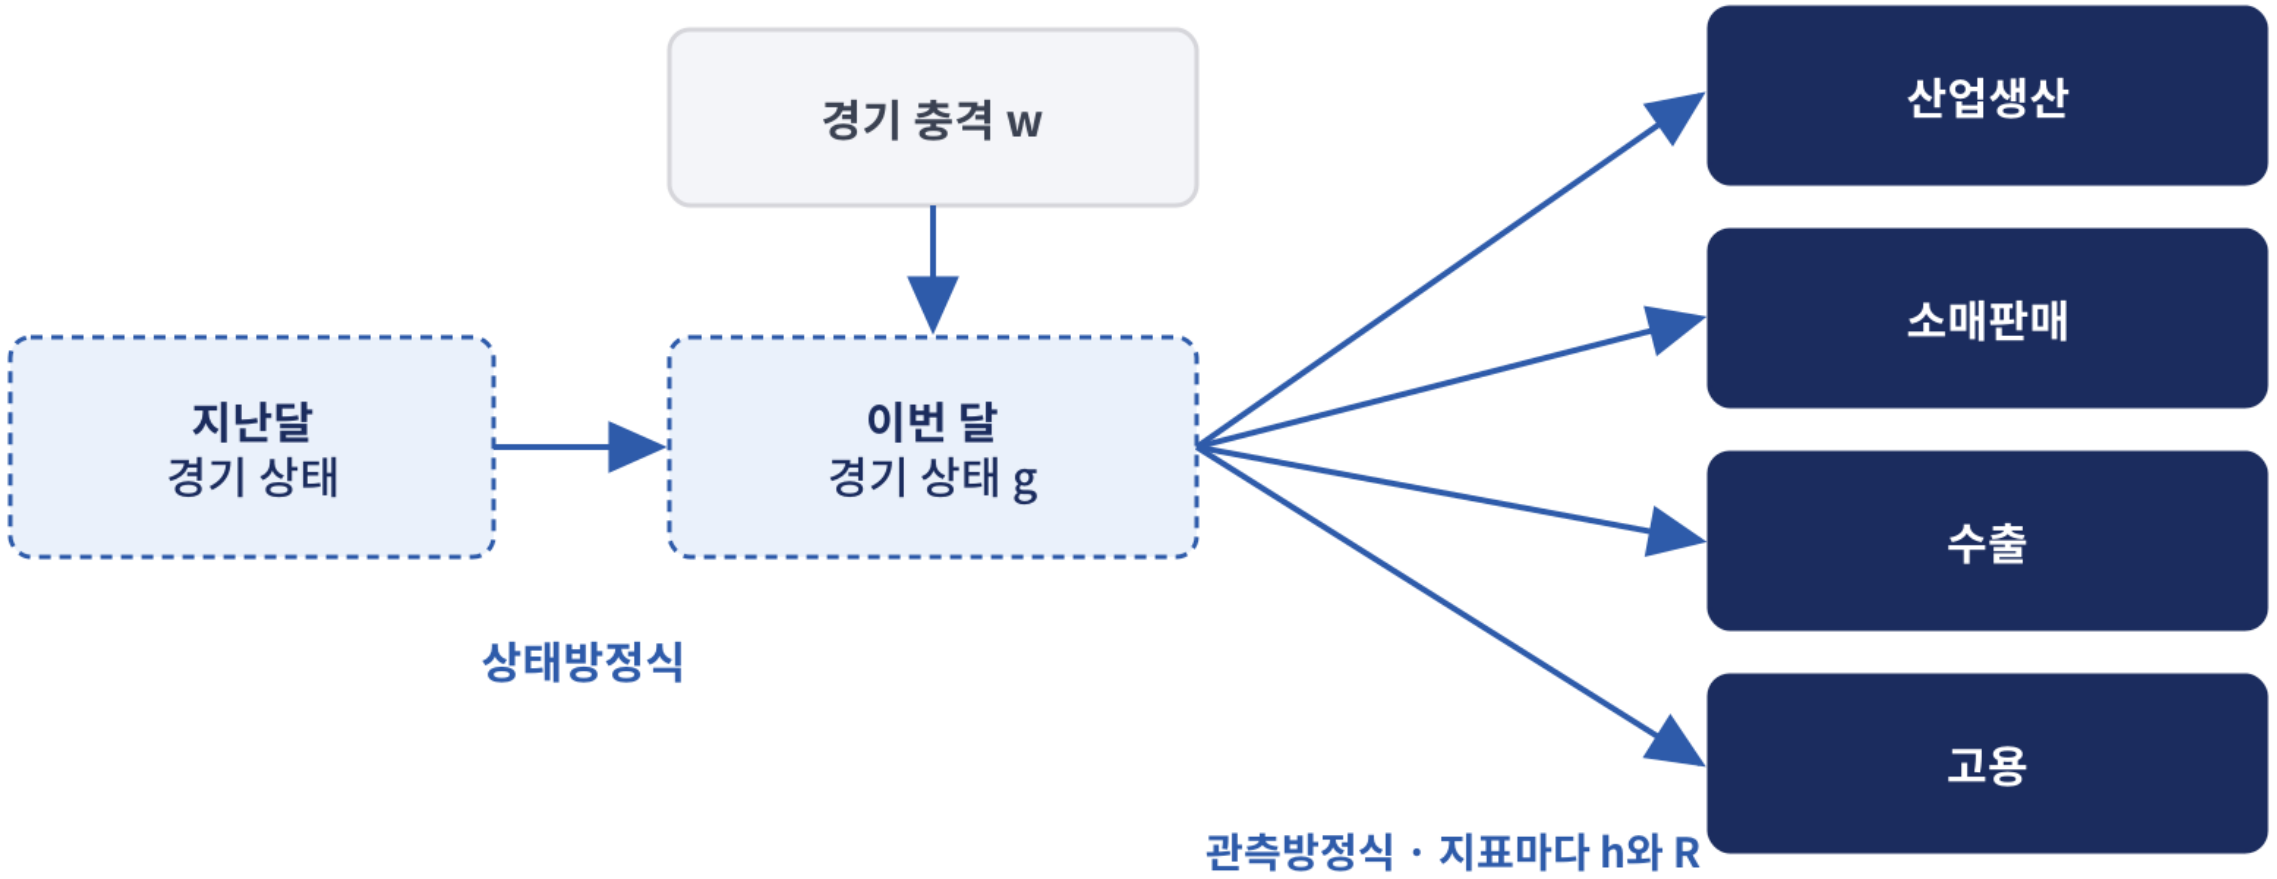
소비 예제에서는 관측값이 하나였다

$$\begin{bmatrix} \text{산업생산}_t \\ \text{소매판매}_t \\ \text{수출}_t \\ \text{고용}_t \end{bmatrix} = \begin{bmatrix} h_1 \\ h_2 \\ h_3 \\ h_4 \end{bmatrix} g_t + \begin{bmatrix} v_{1t} \\ v_{2t} \\ v_{3t} \\ v_{4t} \end{bmatrix}$$

기호	쉬운 의미
g_t	지금의 숨은 경기 상태
y_t	여러 경제지표
H_t	각 지표가 경기 상태를 반영하는 정도
w_t	경기 상태 자체의 새로운 변화
v_t	각 지표의 개별 잡음 또는 측정오차

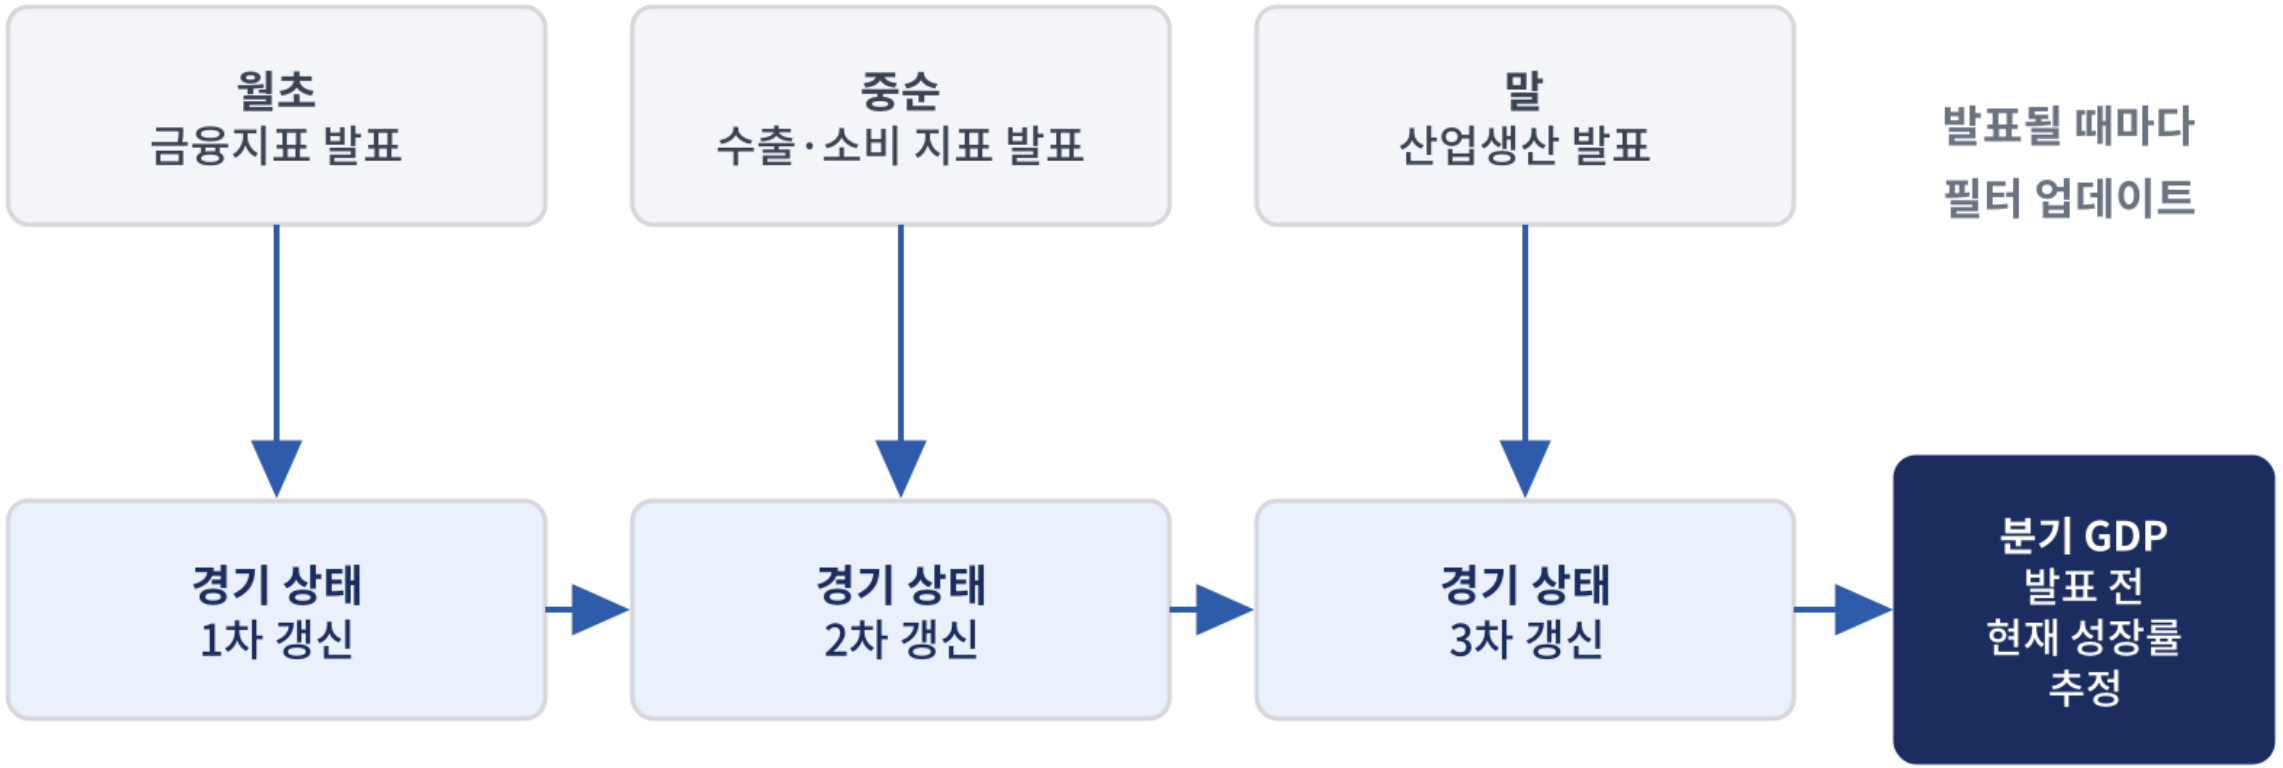
공통 경기 상태 하나가 여러 지표에 동시에 나타난다

지표마다 반영 정도와 잡음 크기가 다르다



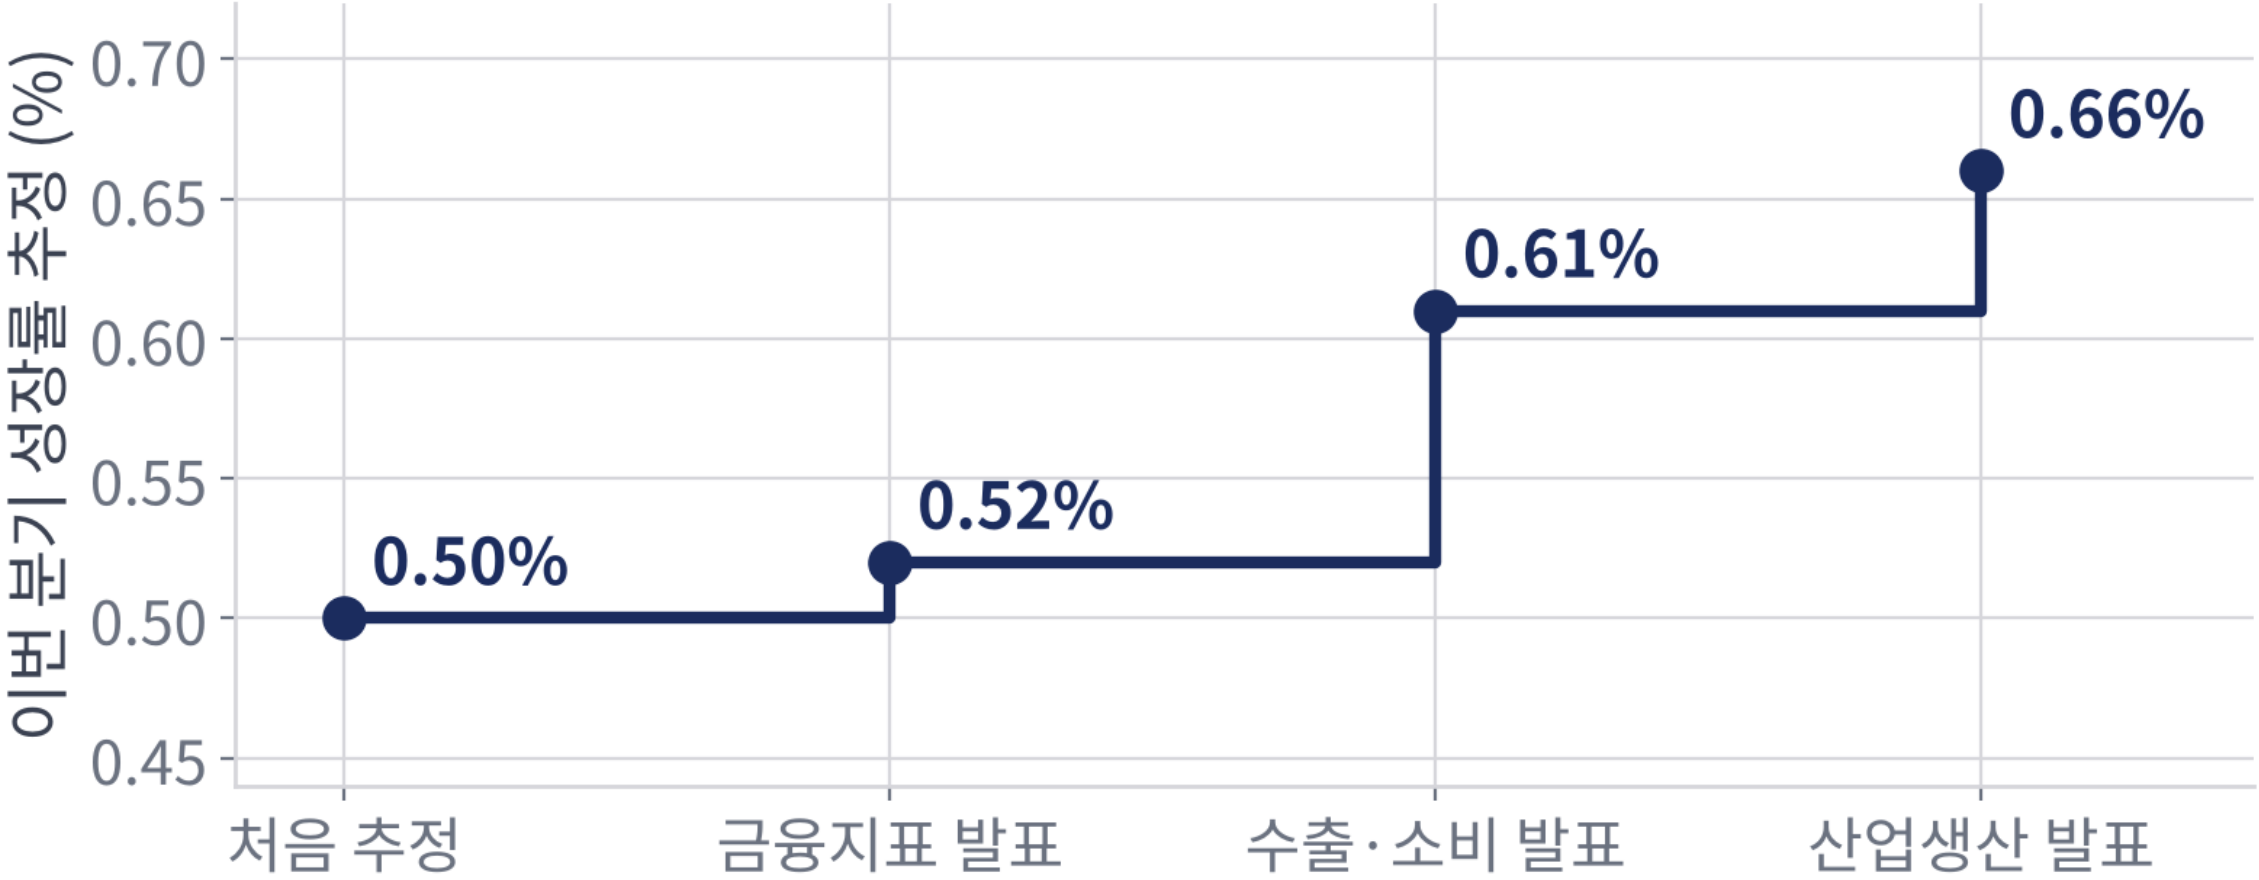
지표가 발표될 때마다 경기 추정을 다시 그린다

경제지표는 한꺼번에 발표되지 않는다 · 어떤 지표는 빨리, 어떤 지표는 늦게 나온다



강한 지표는 성장률 추정을 끌어올린다

처음 0.5%로 보던 이번 분기 성장률 흐름 · 고용·소비가 약하면 반대로 낮춘다 · ※ 예시 데이터



결측치와 혼합주기 자료도 구조적으로 처리된다

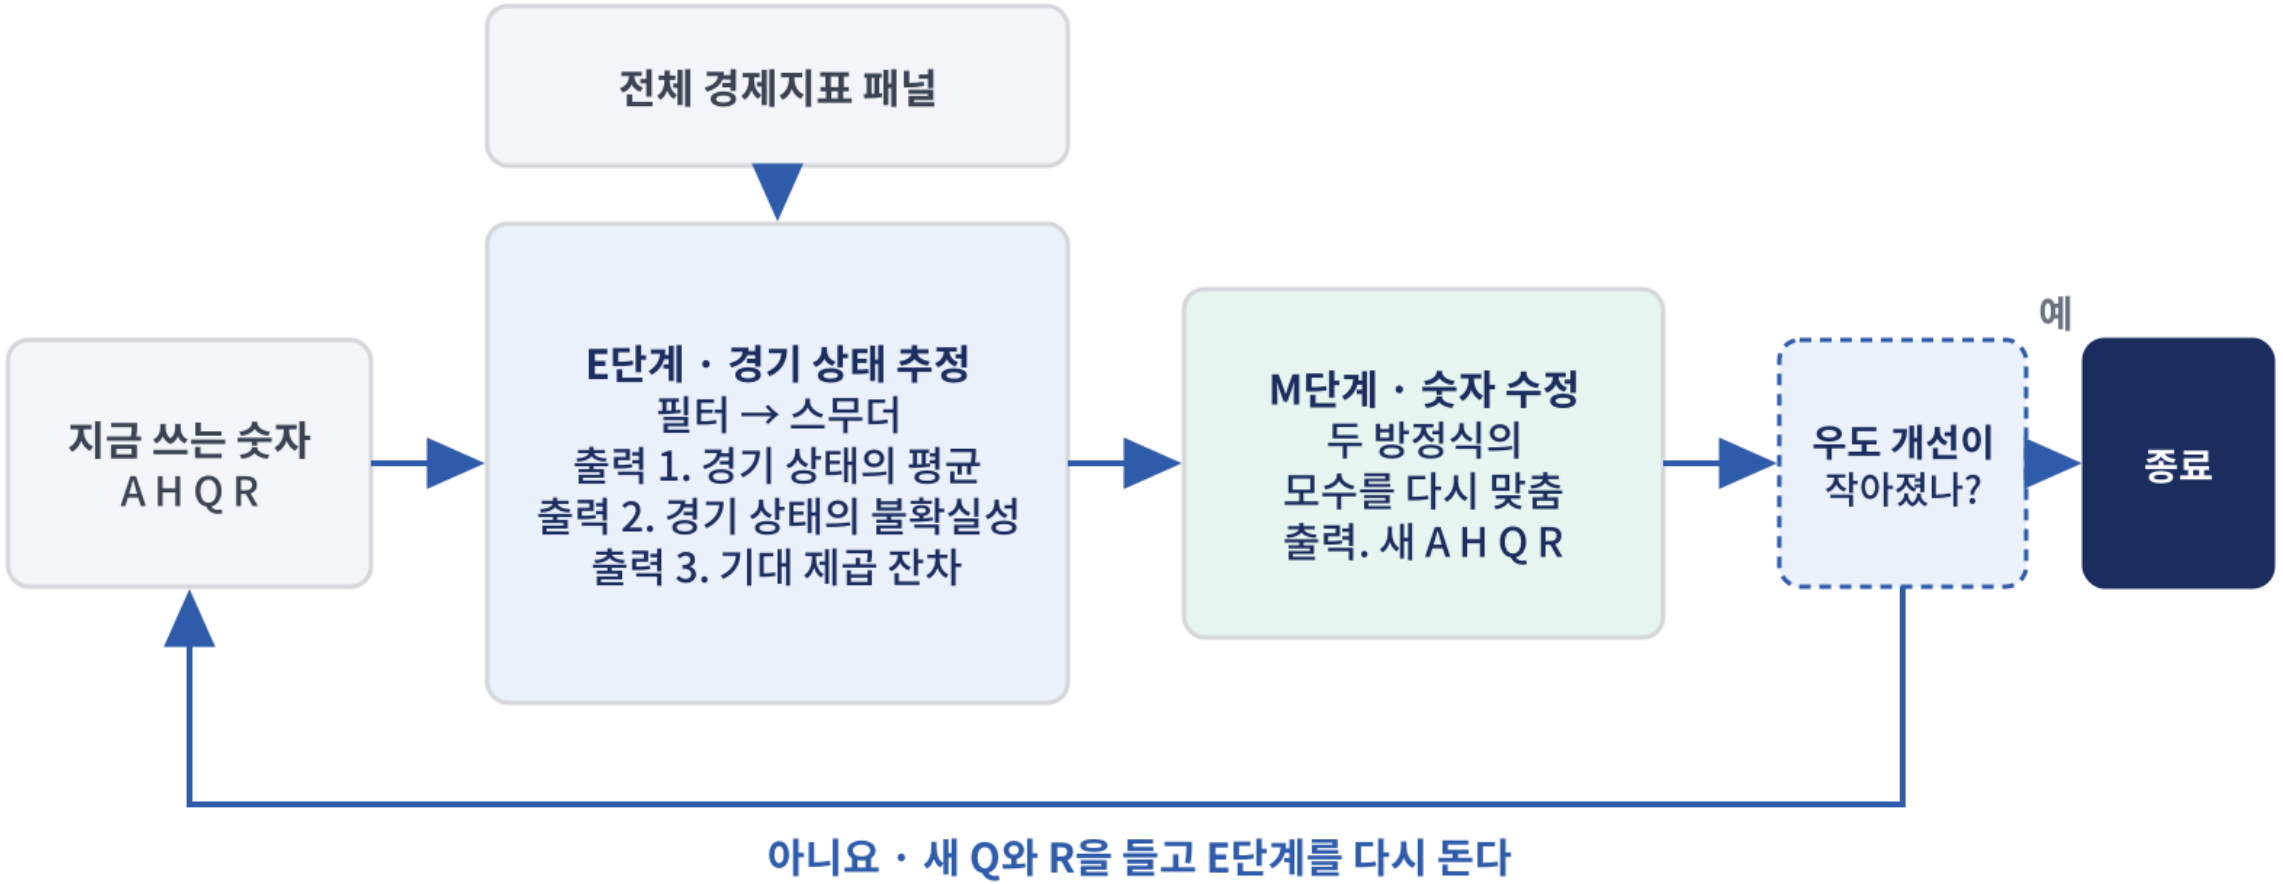
자료가 비어 있어도 처리할 수 있다는 점이 나우캐스팅의 장점이다

문제	상태공간모형에서의 처리
이번 달 고용지표가 아직 없음	그 행의 관측 업데이트를 건너뛴다
GDP는 분기별, 지표는 월별	월별 상태를 쌓아 분기 GDP와 연결한다
지표 발표일이 다름	발표되는 순간마다 필터를 업데이트한다
지표마다 잡음 크기가 다름	R의 대각원소 또는 공분산으로 반영한다

칼만 필터는 경제 뉴스가 도착할 때마다 현재 경기 그림을 조금씩 다시 그리는 장치다

나우캐스팅 EM도 E단계 출력으로 네 숫자를 고친다

지속성 A, 지표 반영 정도 H, 경기 변동성 Q, 지표 잡음 R을 학습한다



함께 움직이면 공통 상태, 혼자 튀면 개별 잡음이다

EM이 학습하는 네 가지 모수와 그 직관

모수	의미
A	경기 상태의 지속성
H	각 지표가 경기 상태를 반영하는 정도
Q	경기 상태 자체의 변동성
R	각 지표의 잡음 또는 개별 변동성

직관

- 여러 지표가 함께 움직이면 공통 경기 상태를 더 강하게 추정한다
- 특정 지표만 튀면 그 지표의 개별 잡음으로 더 많이 해석한다
- 경기 상태를 잘 따라가는 지표는 H가 크게 추정된다
- 자주 빗나가는 지표는 R이 크게 추정된다

실습 · 미국 지표로 GDP를 나우캐스팅한다

큰 그림: 공통 경기 상태가 상태이고 여러 지표가 관측값이며, 월별·분기 자료를 함께 쓴다

[입력] 프롬프트 · Claude Code 데스크톱 앱 · Code 탭

```
나우캐스팅 실습을 해 줘. 작업 폴더는 ssm_lab/nowcast.

1. FRED에서 월별 INDPRO(산업생산), RRSFS(실질 소매판매),
   PAYEMS(고용), BOPTEXP(수출)와 분기 GDPC1(실질 GDP)을
   2000년부터 내려받아 줘.
2. 지표는 전월 대비, GDP는 전기 대비 증가율로 바꿔 줘.
3. statsmodels DynamicFactorMQ로 공통 요인 1개,
   월·분기 혼합주기 모형을 EM으로 추정해 줘.
4. 가장 최근 분기의 GDP 증가율을 나우캐스트하고,
   지표가 발표될 때마다 추정이 바뀌는 과정(news)을
   표와 그림으로 보여 줘.
5. 지표별 반영 정도(H)를 표로 정리해 report.md에 쓰고
   열어 줘. 오류는 스스로 고쳐 줘.
```

출력과 확인

- 출력: 지표 패널, 추정 요인, 나우캐스트 값, 지표별 news 표와 그림
- 최근 달 지표가 비어 있어도 추정이 나오는가?
- 추정 요인이 2008년과 2020년 경기침체기에 떨어지는가?

08

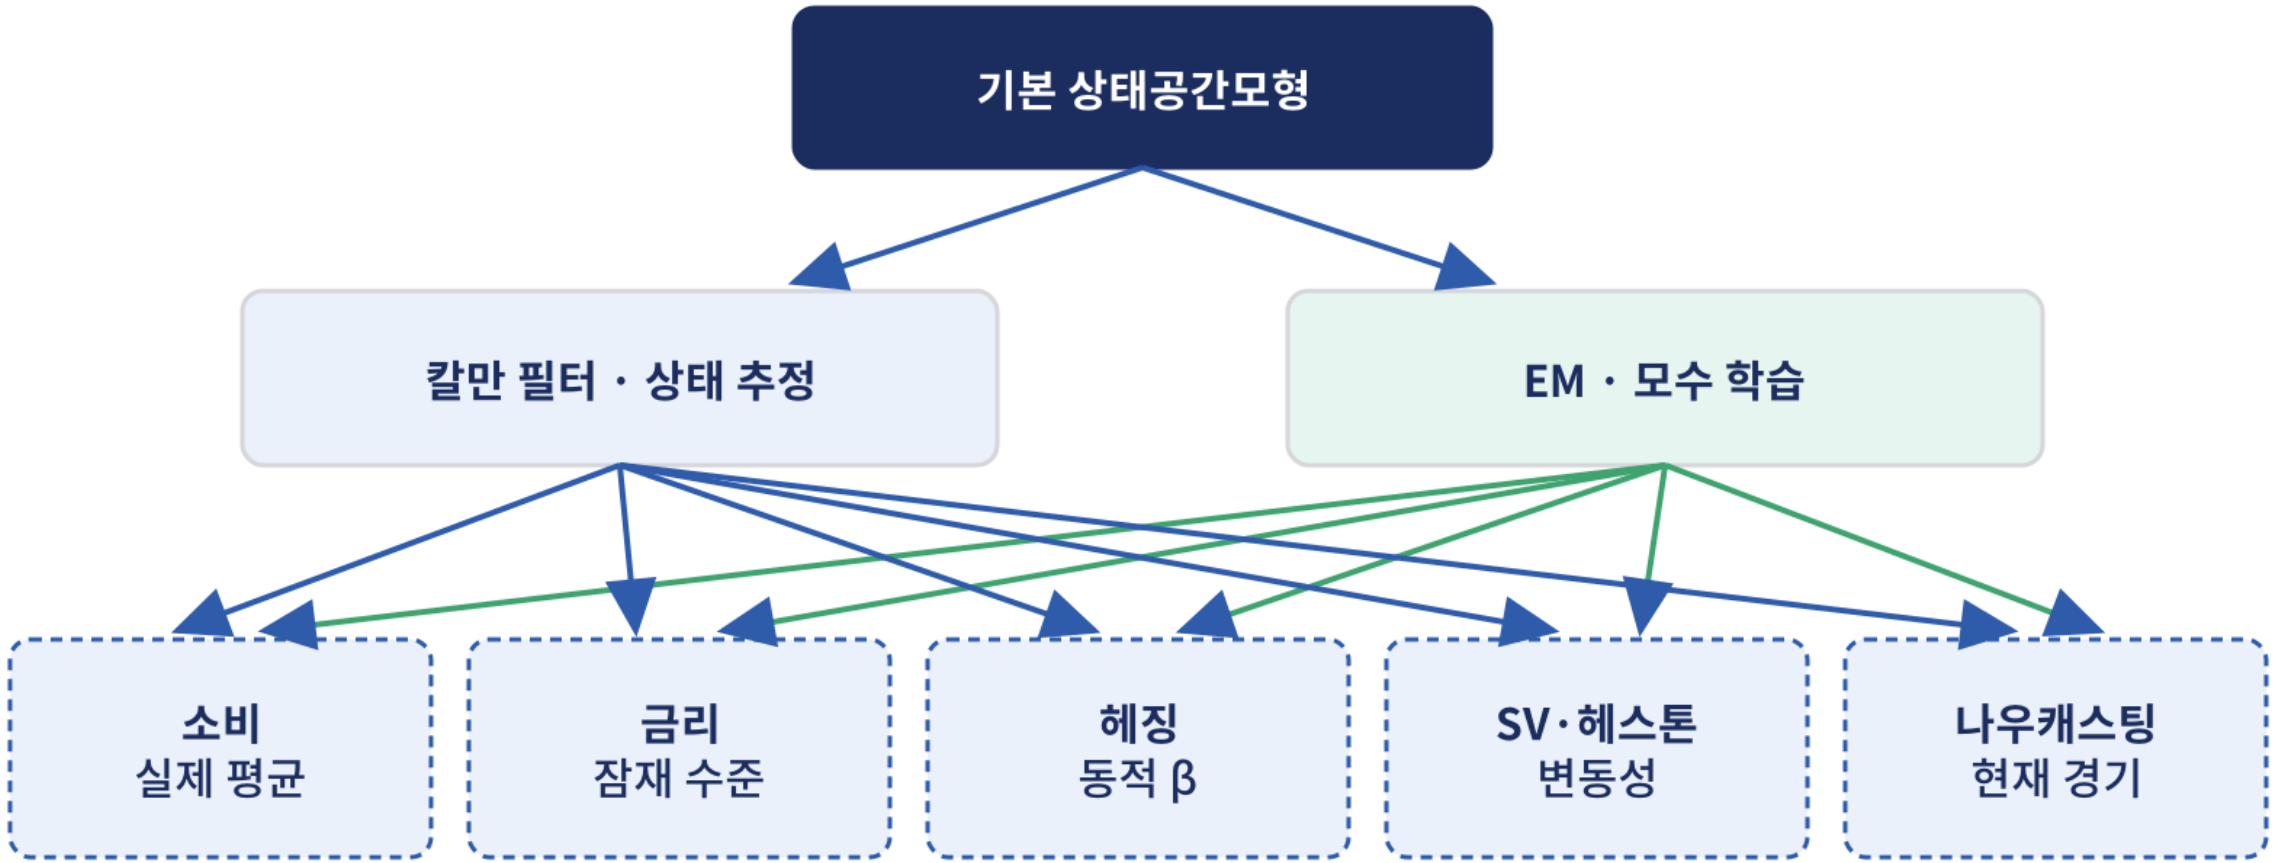
PART 8 · 종합

예제를 같은 틀로 비교하기

상태·관측값·Q·R·칼만 필터·EM의 역할

모든 예제가 필터와 EM의 같은 틀을 쓴다

하나의 기본 상태공간모형에서 다섯 가지 응용이 갈라진다



선형·정규 예제 셋은 상태만 바뀐다

세 예제 모두 EM으로 두 분산을 학습한다

항목	소비	금리	EWC·EWA 헤징
상태	실제 평균 소비액	잠재 금리 수준	헤지 비율
관측값	표본조사 평균	시장금리	EWC 수익률
관측 연결 숫자	1	1	EWA 수익률
Q가 표현하는 것	실제 소비 변화	금리 수준 변화	비율 변화
R이 표현하는 것	조사 오차	수준에서의 벗어남	EWC 개별 움직임
칼만 필터	현재 소비 추정	현재 수준 추정	현재 비율 추정
EM	두 분산 학습	두 분산 학습	두 분산 학습

변동성·나우캐스팅은 관측 구조가 달라진다

SV는 정규 근사, 헤스톤은 비선형 필터, 나우캐스팅은 다변량 관측이 핵심이다

예제	상태	관측값	칼만 필터류	EM의 주요 학습 대상
확률적 변동성	로그 분산	제곱·로그 변환한 수익률	정규 근사 후 적용	장기 평균·지속성·Q
헤스톤 변동성	분산	수익률, 옵션 가격, 내재변동성	EKF·UKF·입자 필터	회귀 속도·장기 수준·vol of vol·상관
나우캐스팅	경기 상태	여러 경제지표	발표될 때마다 갱신	A, H, Q, R

두 방정식과 두 도구가 하나의 틀을 이룬다

이 강의의 핵심 한 문장

상태방정식은 보이지 않는 대상이 시간에 따라 움직이는 법을, 관측방정식은 그 대상이 데이터로 보이는 방식을 말한다

칼만 필터

- 관측값이 들어올 때마다 상태와 불확실성을 추정한다

EM

- E단계로 상태를 추정하고 M단계로 Q·R을 고치는 일을 반복한다

A

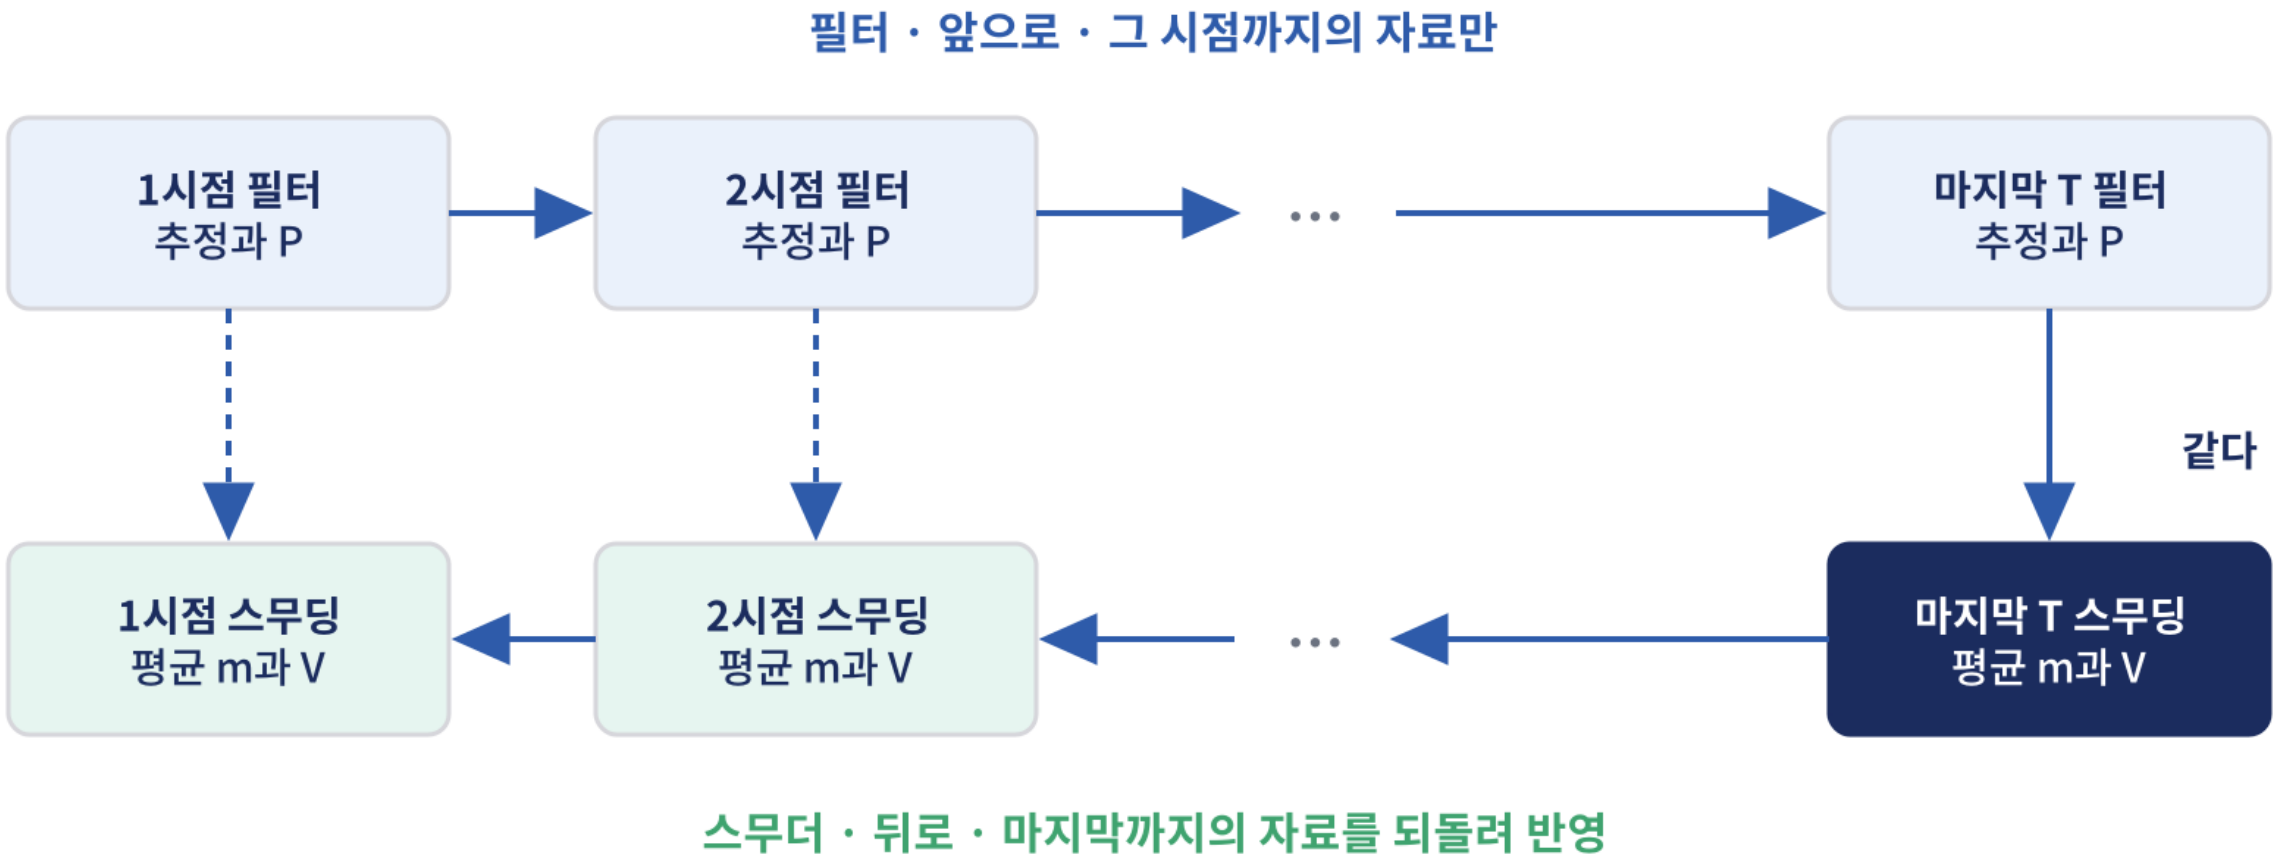
부록 · 칼만 스무더

스무딩 분산 V는 어떻게 계산되나

E단계 안에서 필터 결과를 뒤에서 앞으로 다시 계산한다

스무더는 나중 자료를 되돌려 과거 추정을 다듬는다

필터가 남긴 추정과 P를 재료로, 마지막 시점에서 출발해 거꾸로 계산한다



나중에 알게 된 사실로 지난 판단을 고치는 것과 같다

경기 판정도 몇 달 뒤 자료까지 보고 다시 내리면 더 정확해진다

필터의 판단

그 시점까지의 자료만 보고 내린 판단이다. 불확실성 P가 남는다

뒤에 알게 된 것

다음 시점의 추정이 예측과 다르면, 앞 시점의 판단도 그 방향으로 고친다

그래서 V는 P보다 작다

자료를 더 봤으니 불확실성이 줄어든다. 마지막 시점은 더 볼 자료가 없어 V와 P가 같다

스무더는 네 줄의 식을 뒤에서 앞으로 반복한다

A = 1인 이 강의의 예제 기준 · 표준 RTS(Rauch–Tung–Striebel) 스무더 · 원본 노트 밖 보충

$$m_T = \hat{x}_T, \quad V_T = P_T$$

출발점

$$J_t = \frac{P_t}{P_{t+1}^-}$$

끌어오는 비율

$$m_t = \hat{x}_t + J_t\,(m_{t+1} - \hat{x}_{t+1}^-)$$

스무딩 평균

$$V_t = P_t + J_t^2\,(V_{t+1} - P_{t+1}^-)$$

스무딩 분산

읽는 법

- 마지막 시점은 필터 결과에서 그대로 출발한다
- 필터가 저장해 둔 추정, P, 다음 시점 예측만 있으면 된다
- 괄호 안은 다음 시점에서 줄어든 불확실성으로 늘음수다
- 그 감소분이 J의 제곱만큼 앞 시점으로 전해진다

끌어오는 비율 J는 오늘과 내일의 불확실성 비교다

J가 클수록 다음 시점의 정보를 많이 끌어와 앞 시점을 크게 고친다

$$J_t = \frac{\overbrace{P_t}^{\text{오늘 필터의 불확실성}}}{\underbrace{P_{t+1}^{-}}_{\text{내일 예측의 불확실성}}}$$

J가 크면

- 오늘 필터가 아직 불확실하다
- 다음 시점 정보에 많이 기대어 크게 고친다

J가 작으면

- 오늘 필터가 이미 확실하다
- 다음 시점 정보가 와도 거의 고치지 않는다

소비 예제로 보면 지난달 분산은 8에서 6으로 줄어든다

지난달 300·8, 이번 달 예측 300·16, 이번 달 관측 후 306·8 · 이번 달을 마지막으로 둔다

1. 출발점

$$m_T = 306, \qquad V_T = P_T = 8$$

2. 끌어오는 비율

$$J = \frac{8}{16} = 0.5$$

3. 지난달 평균

$$m_{T-1} = 300 + 0.5 \times (306 - 300) = 303$$

4. 지난달 분산

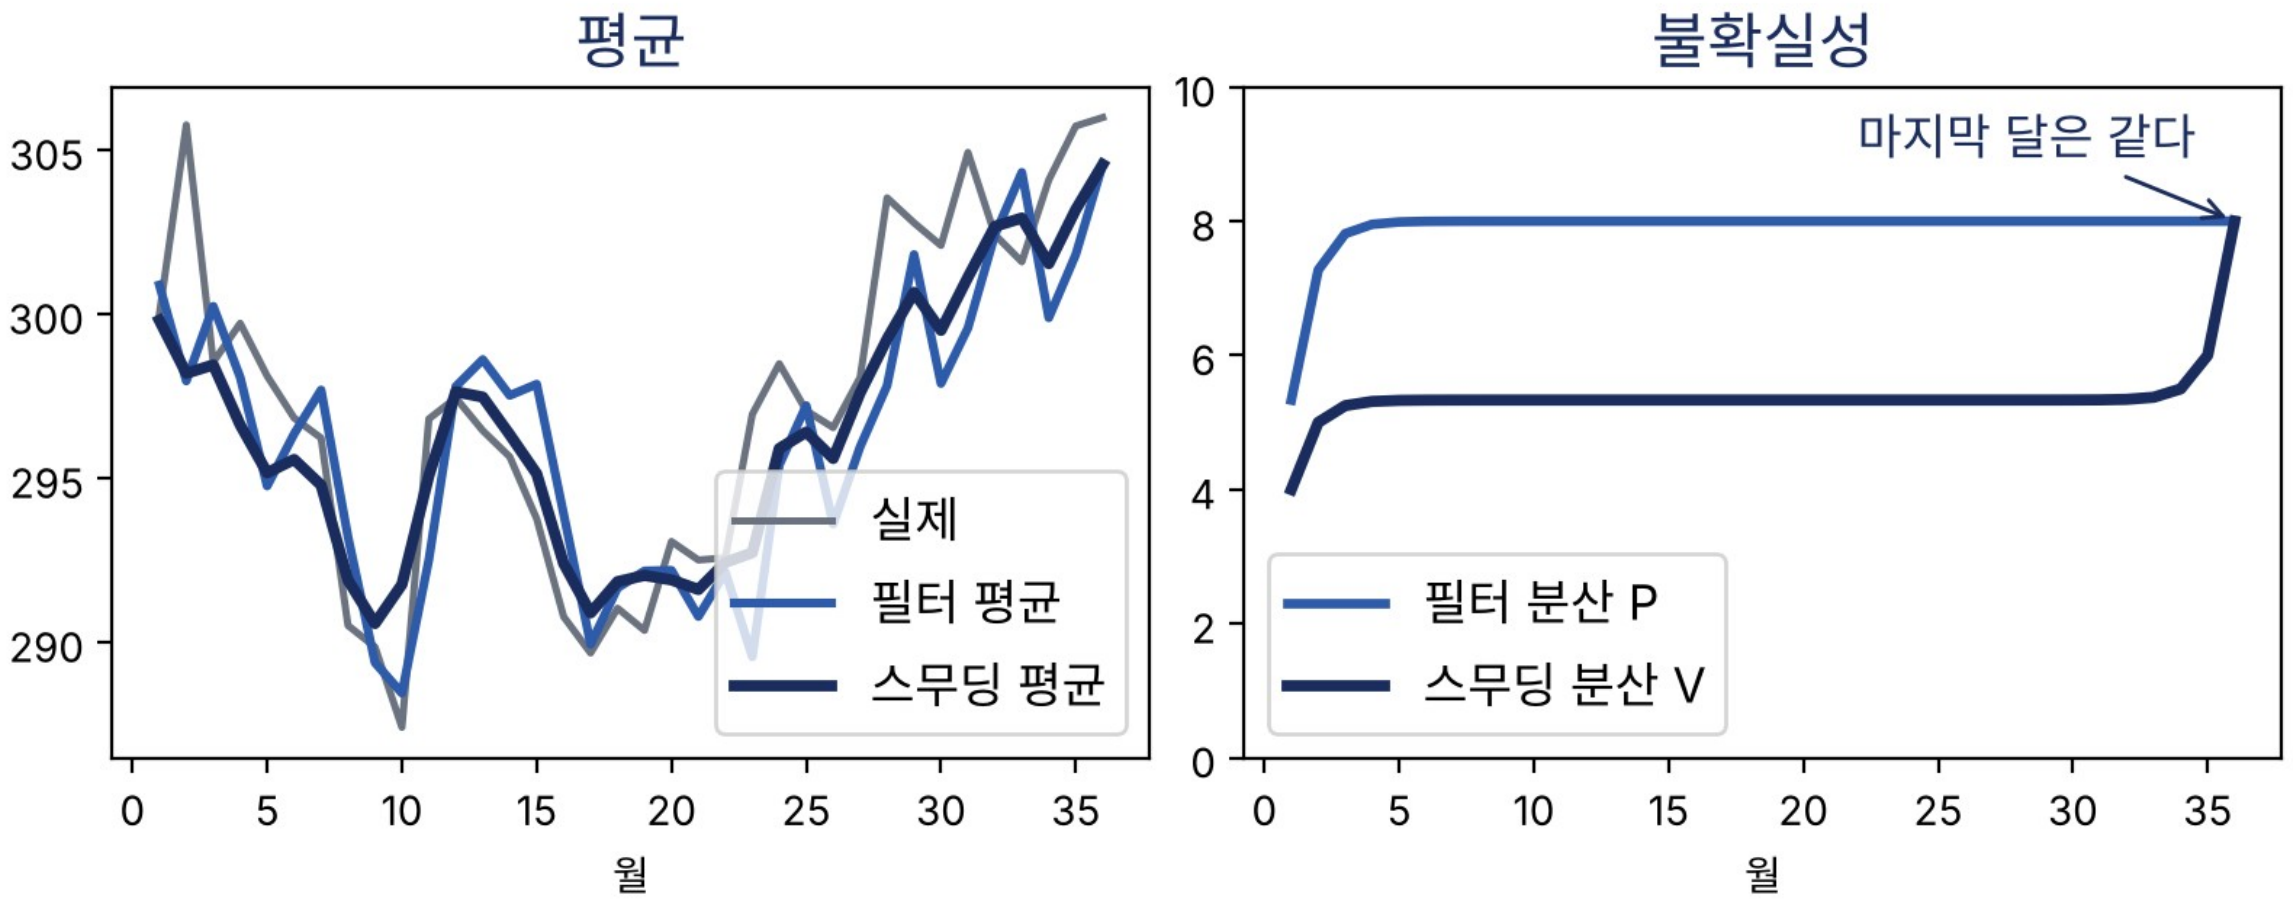
$$V_{T-1} = 8 + 0.5^2 \times (8 - 16) = 6$$

읽는 법

- 이번 달 추정이 306으로 오른 것을 보고 지난달 추정도 303으로 올린다
- 이번 달 자료를 더 봤으므로 지난달 불확실성은 8에서 6으로 줄어든다

스무딩 분산은 필터 분산보다 작고 마지막 달에 같아진다

Q = 8, R = 16 모의 36개월 · 스무딩 평균이 더 매끄럽다 · ※ 예시 데이터



헤징에도 같은 식을 쓰고, 값은 EM 반복마다 바뀐다

V는 E단계의 출력이며 M단계가 쓰는 기대 제곱 잔차의 재료다

헤징에서 달라지는 점

- 필터 단계의 연결 숫자가 그날의 EWA 수익률이다
- 뒤로 가는 식에는 연결 숫자가 들어가지 않는다
- EWA 수익률이 0에 가까운 날은 필터 분산이 거의 줄지 않아 V도 크게 남는다

EM 안에서의 위치

- V는 지금 쓰는 Q·R로 계산한 E단계 출력이다
- M단계가 Q·R을 고치면 다음 바퀴에서 V를 다시 계산한다
- 기대 제곱 잔차에 더해지는 불확실성이 바로 이 V 다

참고 자료

ETF 상품 정보와 확률적 변동성 추정 문헌

자료	내용
BlackRock · iShares MSCI Canada ETF (EWC)	EWC 공식 상품 설명
BlackRock · iShares MSCI Australia ETF (EWA)	EWA 공식 상품 설명
Chad Fulton · Stochastic volatility, quasi-maximum likelihood	SV의 정규 준우도 추정
Kim, Shephard and Chib (1998)	Stochastic Volatility, Likelihood Inference and Comparison with ARCH Models