기초 가이드

칼만 필터

보이지 않는 값을 관측값이 들어올 때마다 추정한다

직관 · 모형 하나 · 알고리즘 하나 · 다양한 응용

그림을 먼저 보고 수식은 줄인다. 표기는 끝까지 하나로 쓴다: 상태 x, 관측값 z, 모형 A와 H, 잡음 Q와 R, 불확실성 P, 이득 K.

세 가지 생각이 강의 전체를 이끈다

뒤에 나오는 추적, 헤지 비율, 나우캐스팅은 모두 이 세 가지 생각을 다시 쓴다

1

잡음이 섞인 추정치 둘이 하나보다 낫다

모형의 예측과 관측값을 각각의 신뢰도에 따라 가중해 결합한다.

2

모형 하나, 식 두 개

상태식은 은닉상태가 어떻게 움직이는지를, 관측식은 센서에 무엇이 보이는지를 나타낸다.

3

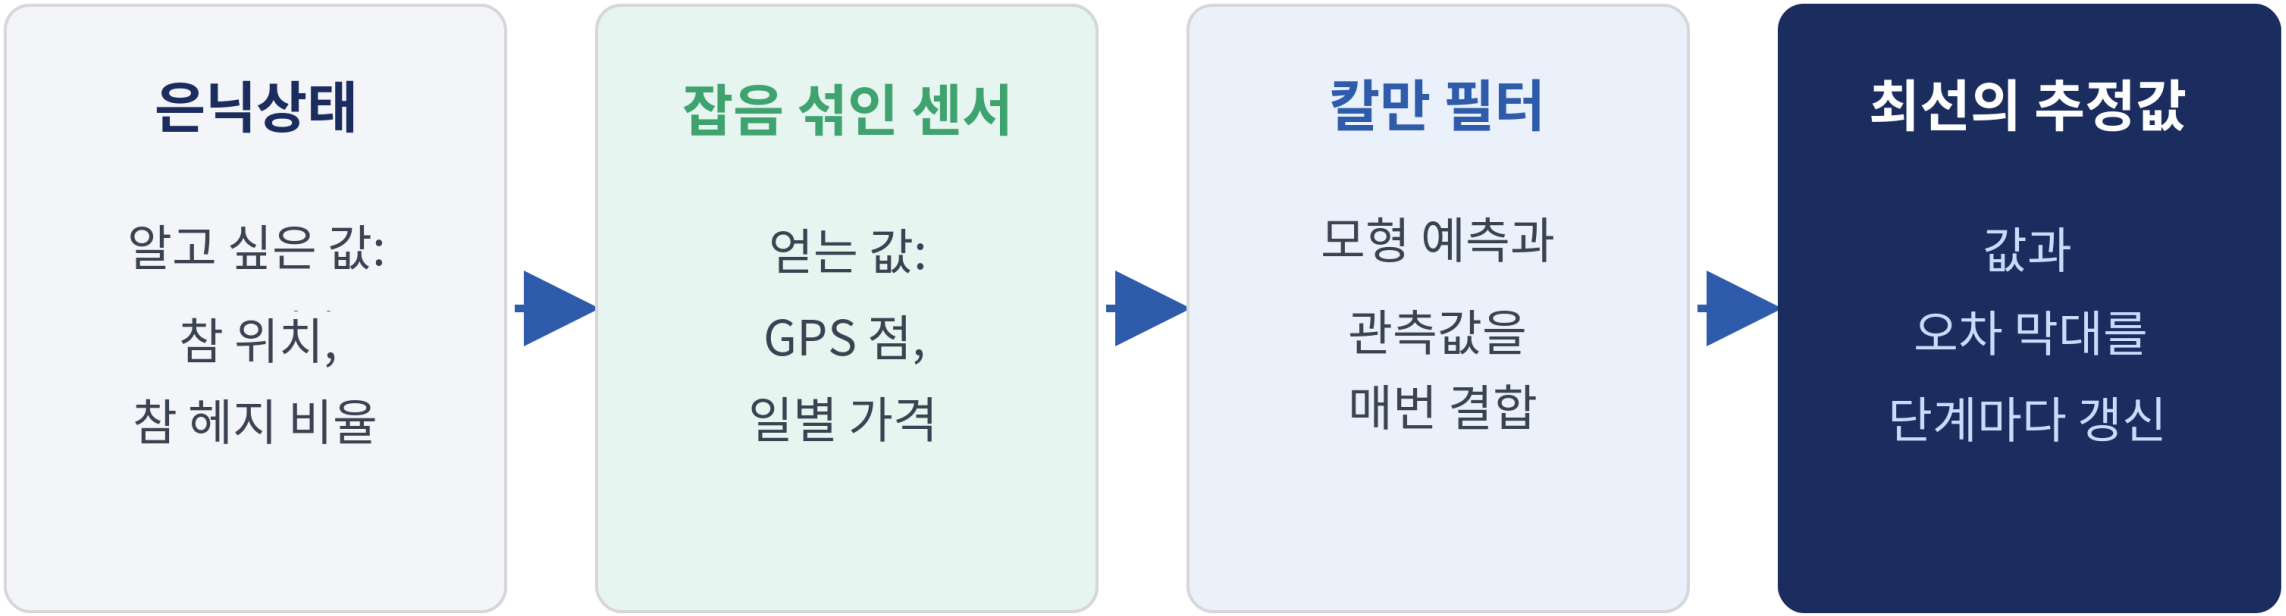
반복 하나, 단계 두 개

예측한 뒤 갱신하고, 새 자료가 들어올 때마다 반복한다. 결합 비율은 이득 K가 정한다.

틀을 한 번 익히면 응용마다 x, A, z, H, Q, R만 달리 채우면 된다.

칼만 필터는 잡음이 섞인 관측값에서 은닉상태를 추론한다

기초 지식: 칼만 필터가 푸는 문제



필터는 은닉상태를 직접 보지 못하고 추론한다.

01

유래

칼만 필터의 유래

행성 궤도에서 아폴로 유도 컴퓨터까지

유래

칼만은 최소제곱법을 단계별 갱신으로 바꾸었다

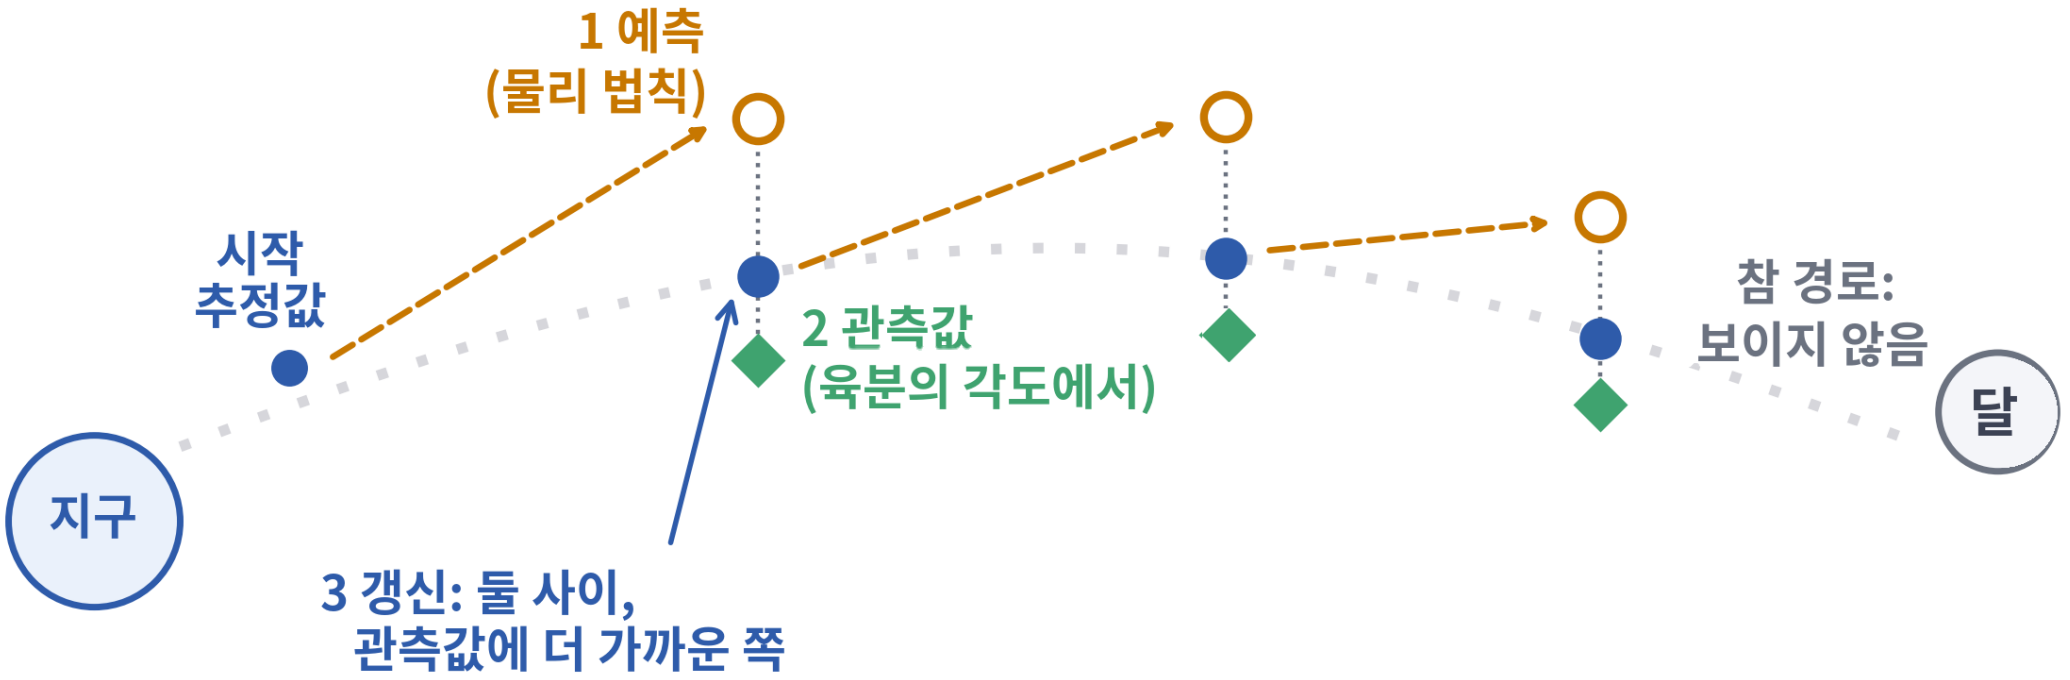
루돌프 칼만(Rudolf Kálmán)이 1960년 재귀 필터를 발표했고, 미국 항공우주국(NASA)의 슈밋(Stanley Schmidt)이 아폴로에 적용했다

가우스	위너	칼만	슈밋, NASA 에임스	모든 분야
1795–1809	1940년대	1960	1960년대	1980년대–
행성 궤도의 최소제곱법	레이더 신호의 최적 필터	재귀 필터: 예측 후 갱신	달까지 가는 아폴로 항법	GPS, 항공기, 경제, 금융

칼만의 방법: 전부 다시 적합하지 않고 직전 추정값을 보정한다

아폴로는 육분의로 관측할 때마다 예측 위치를 보정했다

빈 원 = 물리 법칙에 따른 예측 · 마름모 = 육분의 관측값 · 파란 점 = 둘 사이의 갱신 위치



새 시작점 = 직전 갱신값. 파란 점은 은닉 경로를 가깝게 따라간다.

02

직관

잡음이 섞인 두 추정치 결합

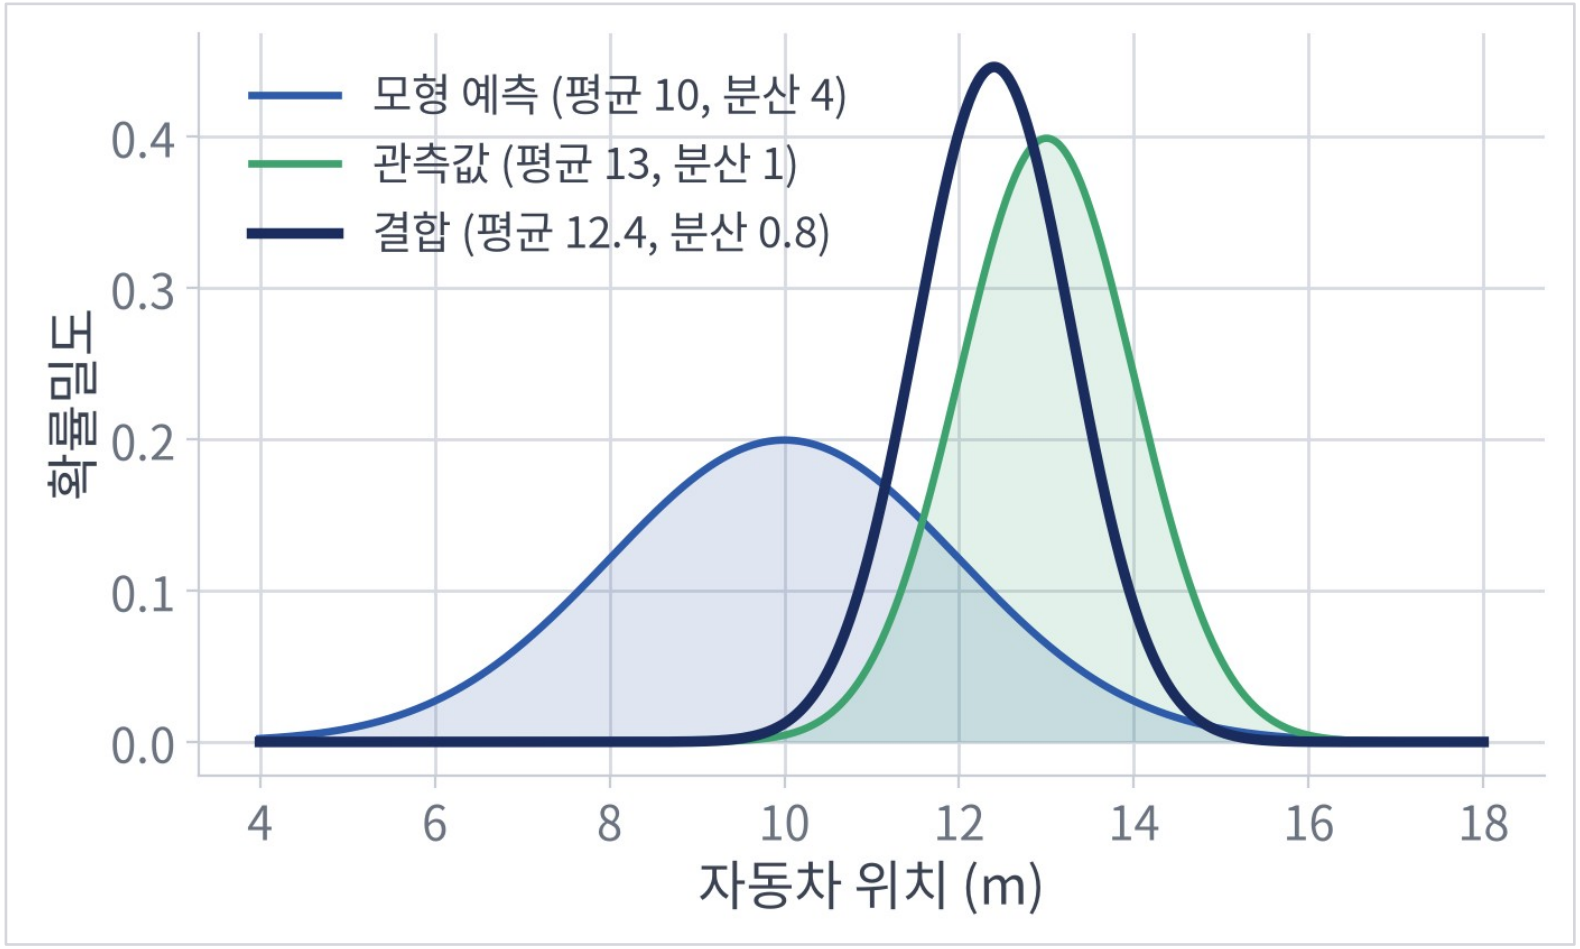
결합한 값이 각각의 값보다 더 정밀한 이유

잡음이 섞인 두 추정치를 결합하면 더 정밀한 답을 얻는다

모형은 10 m(분산 4), GPS(Global Positioning System)는 13 m(분산 1)로 추정한다

읽는 법

- 종 모양 곡선 하나가 추정치 하나다
- 폭이 좁은 곡선을 더 신뢰한다
- 결과는 GPS 쪽에 더 가깝다
- 결과의 폭은 두 곡선보다 좁다

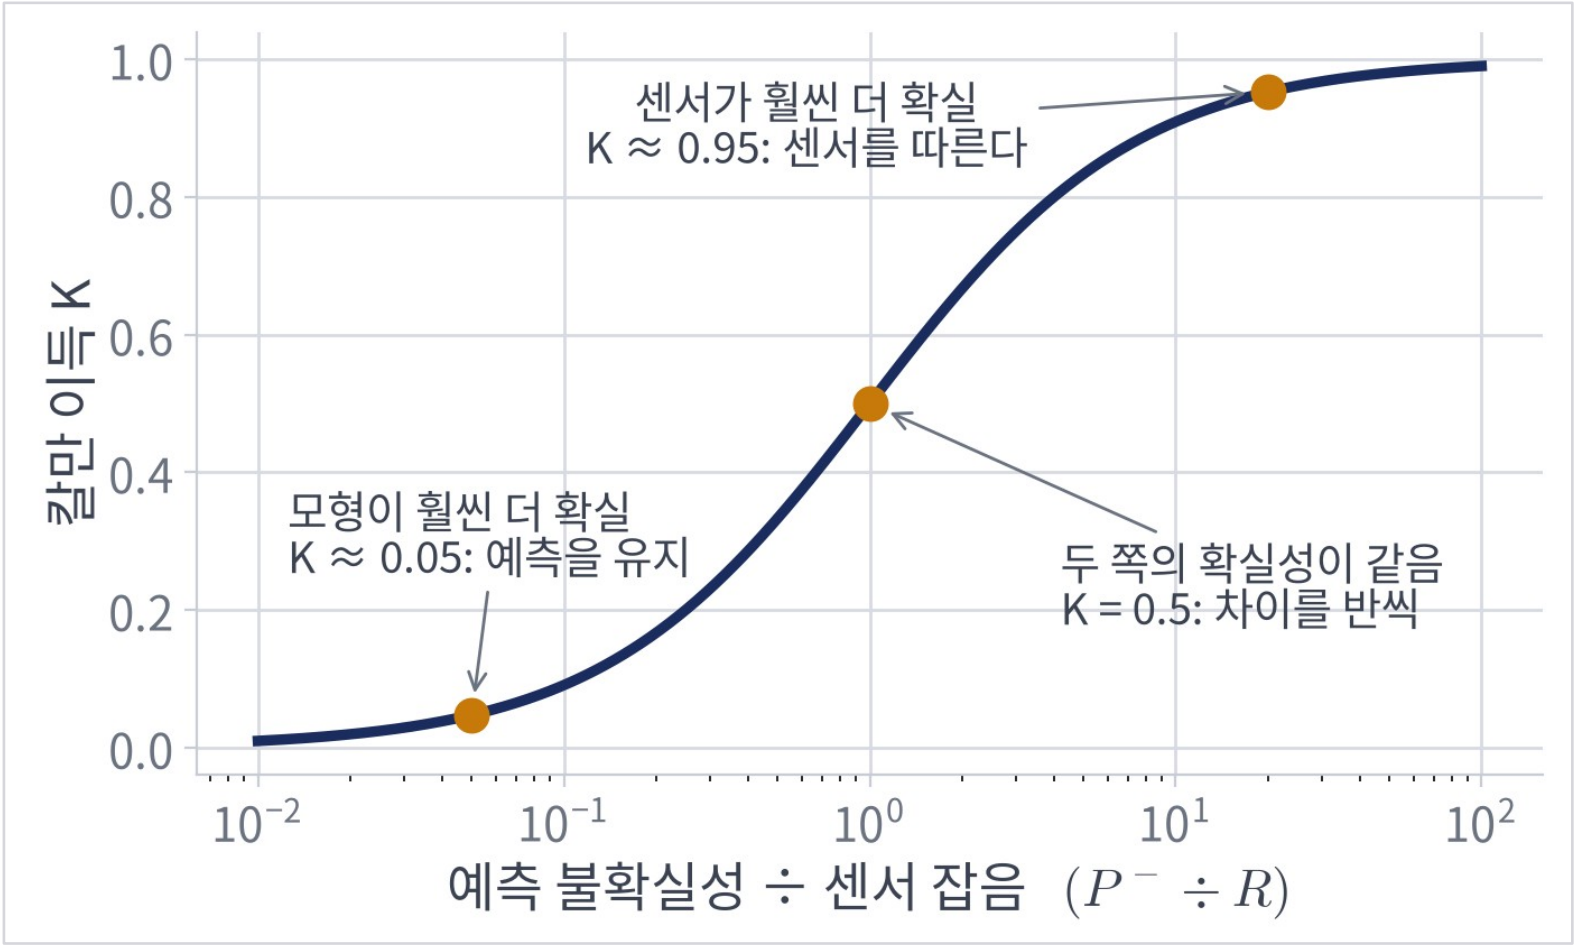


칼만 이득은 모형과 센서 사이의 신뢰 비중을 조절한다

K는 0(센서 무시)에서 1(센서 값 그대로)까지 움직인다

이득을 움직이는 요인

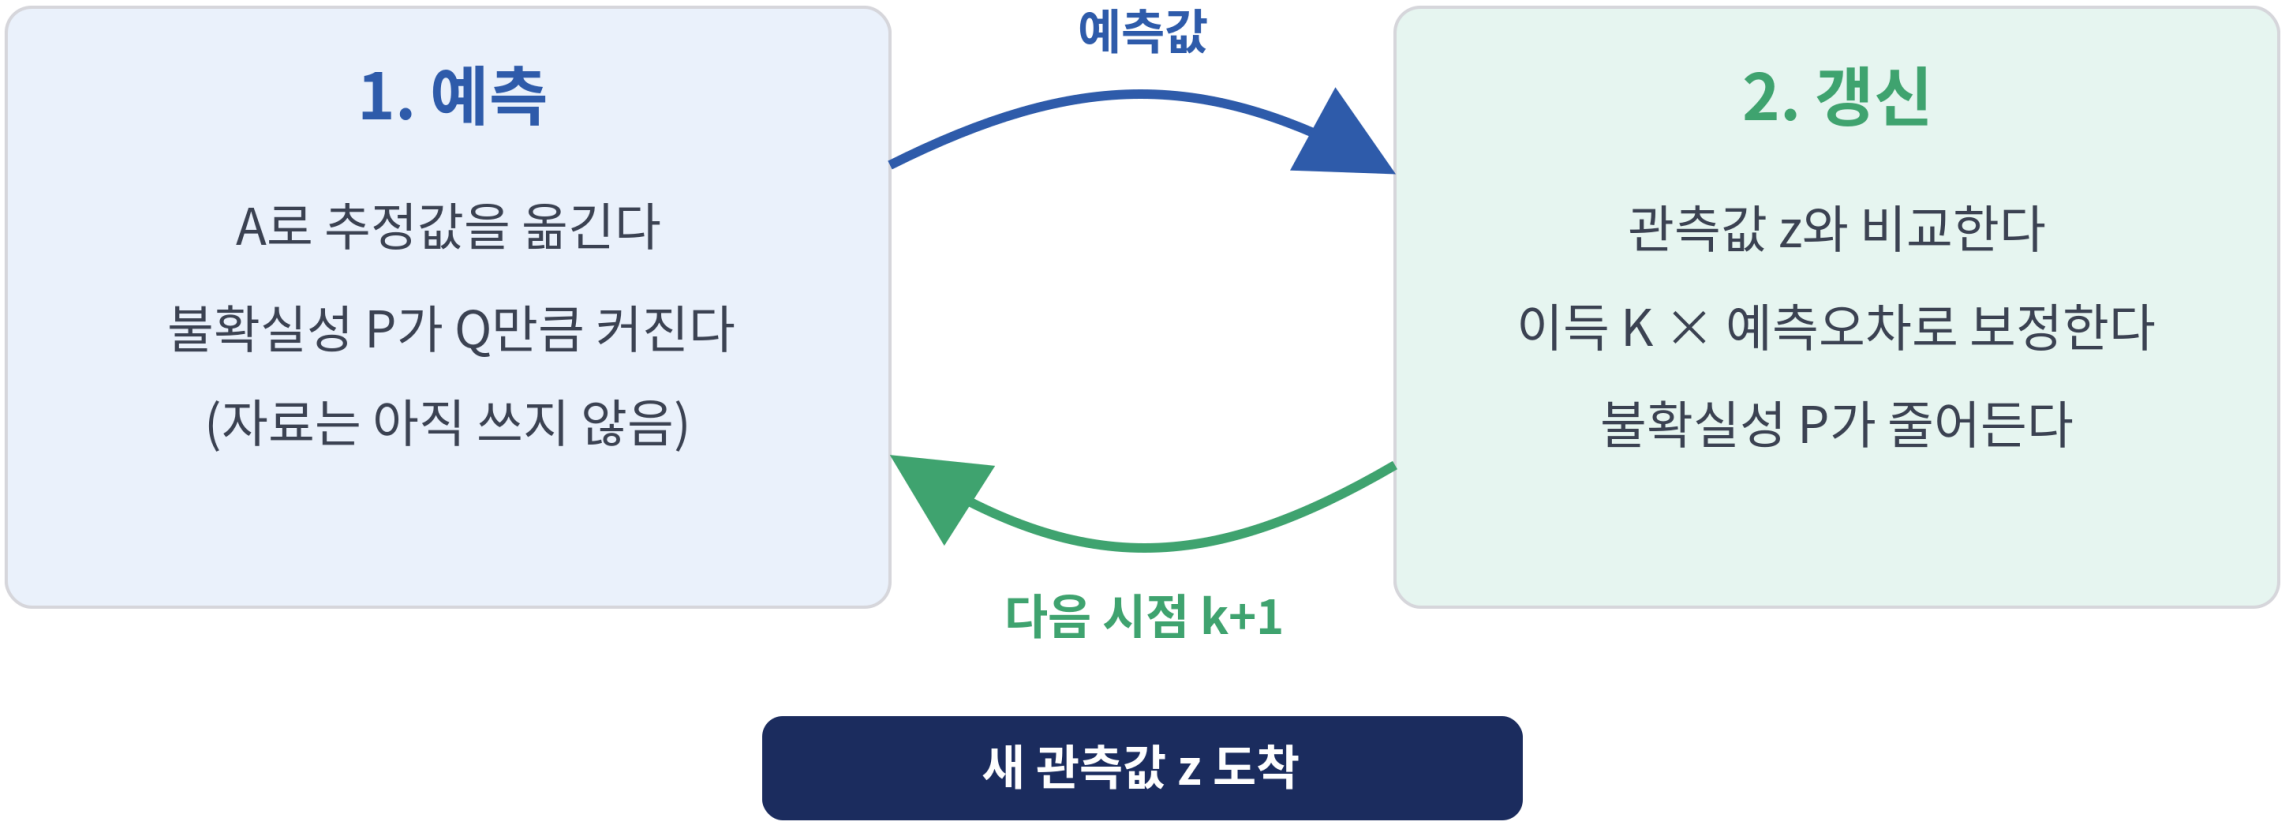
- 모형이 불확실 (P^- 큼): K 상승
- 센서 잡음이 큼 (R 큼): K 하락
- 둘의 비율만 중요하다



반복

필터는 예측과 갱신을 번갈아 수행한다

시점 k마다 모형으로 예측하고 관측값으로 보정한다

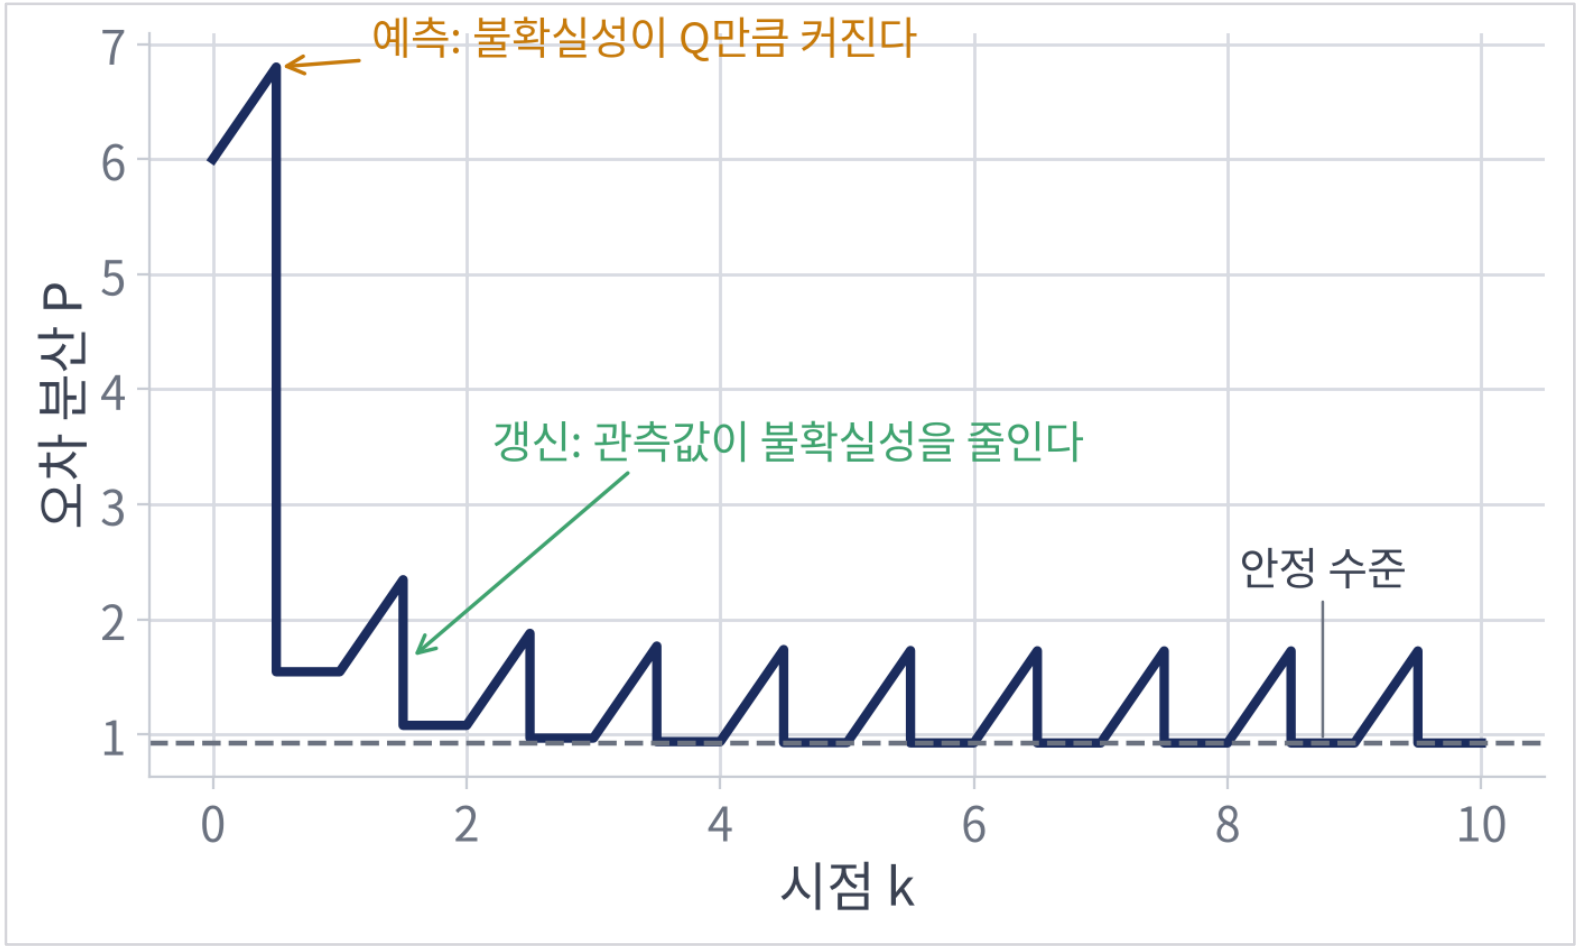


불확실성은 예측할 때 커지고 갱신할 때 줄어든다

Q와 R을 고정하고 10단계 동안 추적한 오차 분산 P

왜 중요한가

- 예측은 Q를 더한다
- 관측값은 일부를 줄인다
- P는 일정 수준에 안착한다
- 따라서 K도 안착한다



03

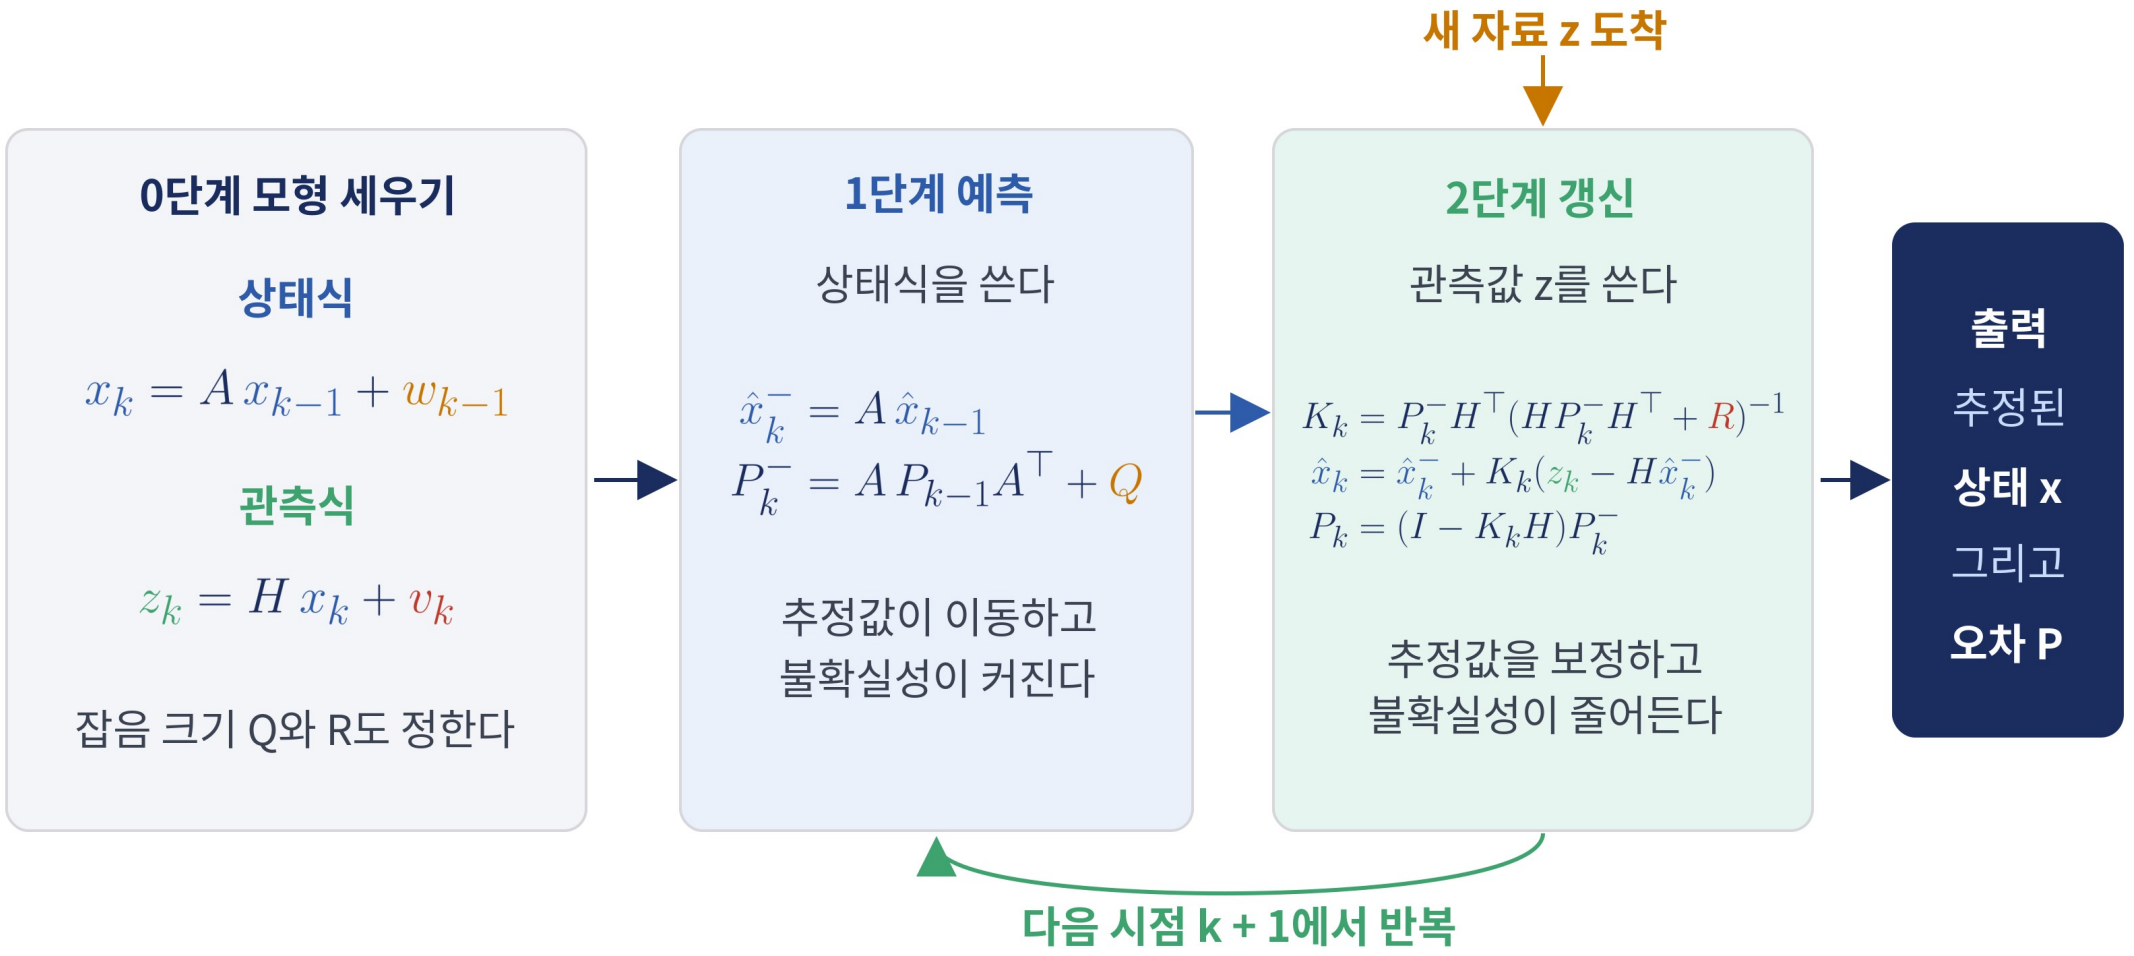
모형

기본 상태공간모형

식 두 개와 잡음 항 두 개: 모든 응용에 쓰는 같은 틀

칼만 필터는 모형 하나와 2단계 반복으로 이루어진다

0단계는 한 번만 수행하고, 1·2단계는 시점 k마다 반복한다



상태식은 은닉상태가 어떻게 움직이는지를 나타낸다

상태 전이식: 다음 상태를 모형 자체로 예측한다

$$\underbrace{x_k}_{\text{현재 상태}} = \underbrace{A\,x_{k-1}}_{\text{움직이는 방식}} + \underbrace{w_{k-1}}_{\text{무작위 충격}}$$

각 항 읽기

- A: 어제에서 오늘로 이어지는 방식
- w: 모형이 내다보지 못하는 부분

자동차 예

- x = 위치와 속도
- A: 새 위치 = 이전 위치 + 속도 × 시간
- w: 노면 충격과 작은 가속

관측식은 센서에 무엇이 보이는지를 나타낸다

관측식: 은닉상태를 관측 자료와 연결한다

$$\underbrace{z_k}_{\text{관측하는 값}} = \underbrace{H\,x_k}_{\text{센서에 보이는 값}} + \underbrace{v_k}_{\text{센서 잡음}}$$

각 항 읽기

- H는 관측되는 부분을 골라낸다
- v: 센서 잡음
- 보이는 것은 z뿐이다

자동차 예

- GPS는 위치만 알려 준다
- 그래서 H는 위치만 남기고 속도를 뺀다
- v: 수 미터 수준의 GPS 오차

두 분산 Q와 R은 각각의 오차 크기를 나타낸다

두 잡음 모두 평균이 0인 정규분포로 가정한다

$$w_k \sim \mathcal{N}(0,\, Q) \qquad v_k \sim \mathcal{N}(0,\, R)$$

Q: 과정잡음

- 참 상태가 움직일 수 있는 폭
- Q가 크면: 모형이 느슨하다

R: 관측잡음

- 센서 잡음의 크기
- R이 크면: 자료 품질이 낮다

표기

이 장부터 마지막 장까지 표기를 하나로 쓴다

아래첨자 k는 시점, 모자(^)는 추정값, 위첨자 −는 관측 전을 뜻한다

기호	이름	자동차 추적	페어 트레이딩
x	상태(은닉)	위치, 속도	헤지 비율 β
z	관측값	GPS 위치	EWC 가격
A	전이 모형	운동 법칙	1(β가 서서히 움직임)
H	관측 모형	위치만 남김	EWA 가격
Q, R	과정잡음 / 관측잡음	노면 충격 / GPS 오차	β 변동 / 스프레드 잡음
P, K	불확실성 / 이득	필터가 계산	필터가 계산

04

알고리즘

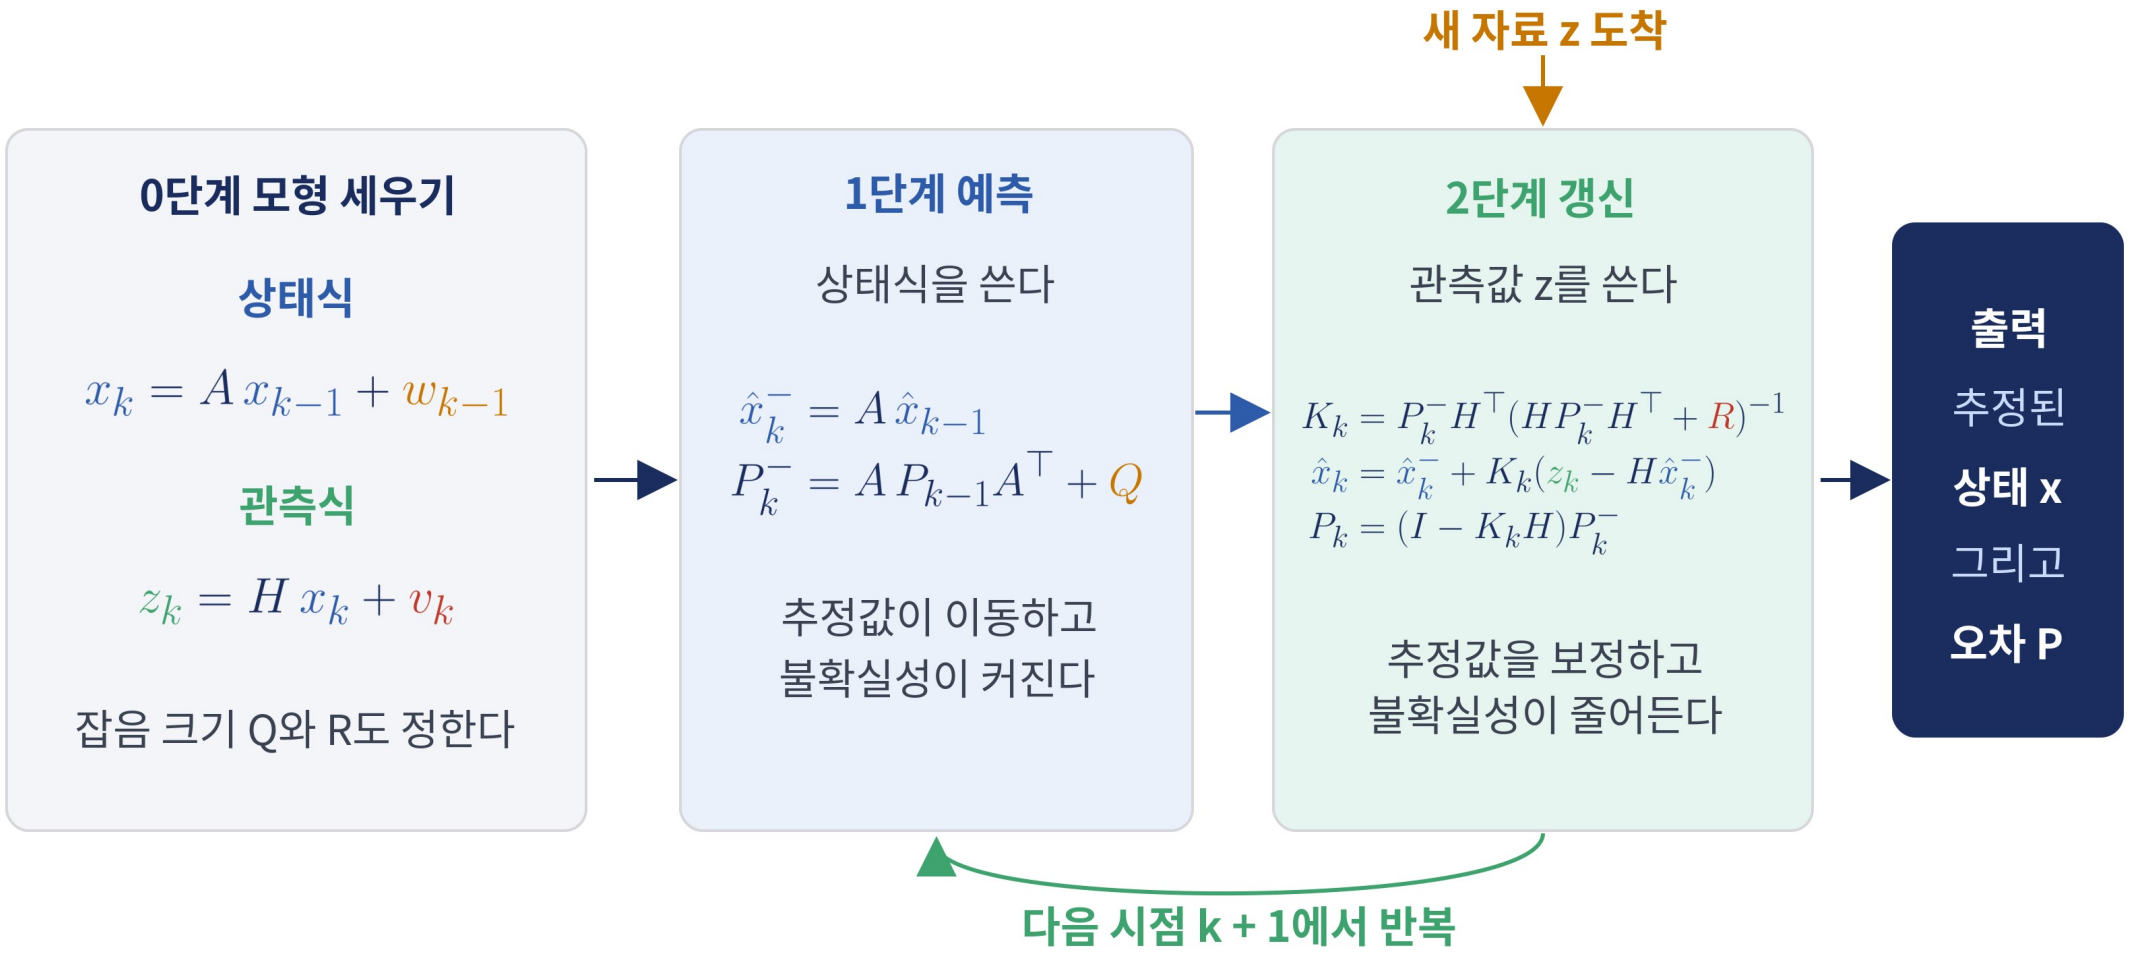
예측과 갱신

칼만 필터의 전부인 다섯 줄

전체 그림

알고리즘은 가운데 두 상자로 이루어진다

모형을 세우고 나면 필터는 예측과 갱신만 수행한다



예측 단계는 추정값과 그 불확실성을 다음 시점으로 옮긴다

상태식만 쓴다. 새 자료는 아직 쓰지 않는다

$$\hat{x}_k^- = A\,\hat{x}_{k-1}$$

$$P_k^- = A\,P_{k-1}\,A^\top + Q$$

첫째 줄

- 직전 추정값을 A로 옮긴다
- 새 자료는 아직 쓰지 않는다

둘째 줄

- 불확실성을 A로 옮긴다
- Q를 더한다: 미래는 더 불확실하다

갱신 단계는 관측값으로 예측을 보정한다

관측식을 쓴다: K를 계산하고, 보정하고, P를 줄인다

$$K_k = P_k^- H^\top \left(H P_k^- H^\top + R \right)^{-1}$$
$$\hat{x}_k = \hat{x}_k^- + K_k \left(z_k - H \hat{x}_k^- \right)$$
$$P_k = (I - K_k H) P_k^-$$

세 줄

- 이득: z를 얼마나 신뢰할지
- 추정값: K × 예측오차를 더한다
- 불확실성: 자료를 반영하면 줄어든다

예측오차

- z에서 예측 관측값을 뺀 값
- 혁신(innovation)이라고 부른다
- 예측오차가 0이면 변화가 없다

상태가 숫자 하나이면 이득은 간단한 분수다

H = 1인 스칼라 경우: 대부분의 계산 예제에 쓰는 형태

$$K_k = \frac{P_k^-}{P_k^- + R} \qquad (\text{숫자 하나}, \quad H = 1)$$

두 극한

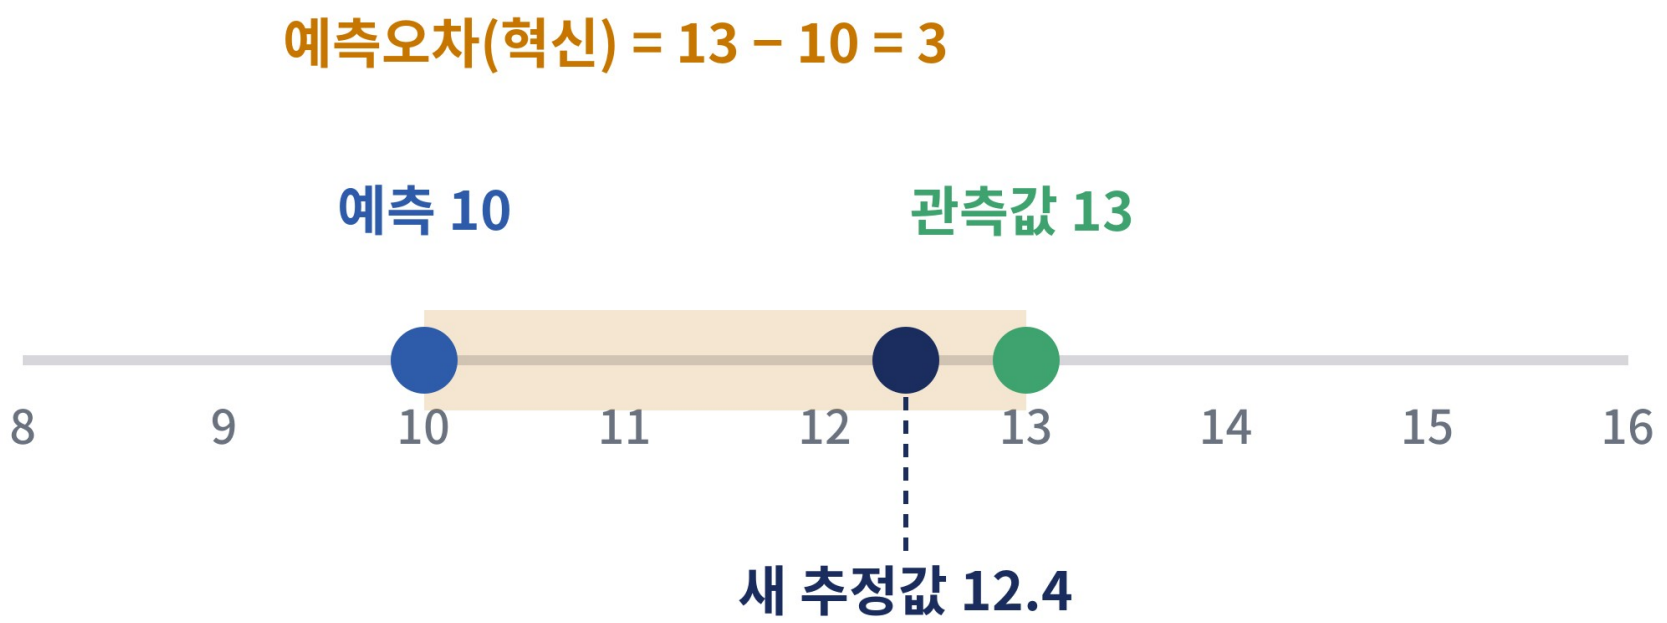
- R → 0: K → 1, 센서 값 그대로
- P^- → 0: K → 0, 모형 값 유지

말로 풀면

- 새 추정값은 가중평균이다
- 가중치는 불확실성으로 정해진다

추정값은 관측값 쪽으로 일부만 이동한다

종 모양 곡선 장과 같은 수치: K = 4 ÷ (4 + 1) = 0.8



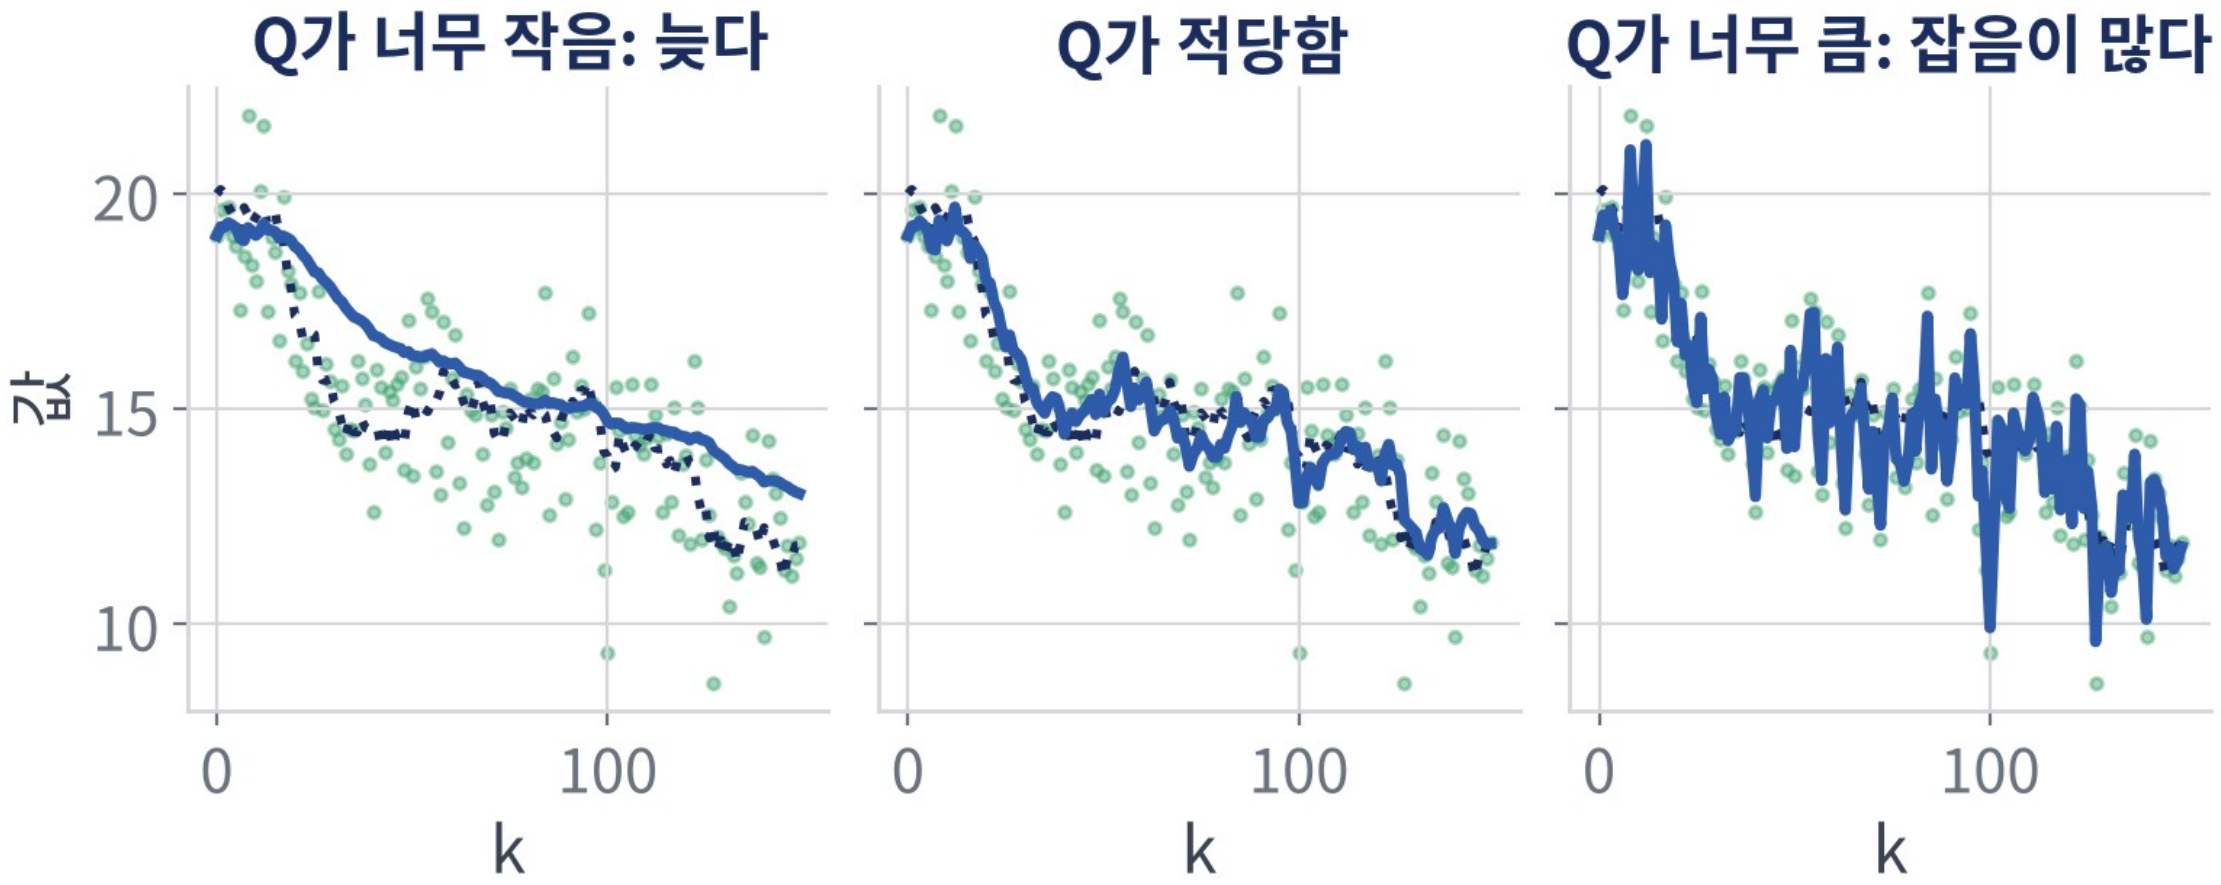
K = 0.8

예측오차의
80%만큼 이동

10 + 0.8 × 3
= 12.4

Q와 R의 비율이 매끄러움과 반응 속도를 결정한다

같은 자료에서 R을 고정하고 Q만 셋으로 바꿨다. 점은 관측값, 점선은 참값이다



파이썬 다섯 줄로 필터 전체를 구현한다

예측식과 갱신식의 스칼라판

파이썬 · 다섯 식을 한 줄씩

```
A, H, Q, R = 1.0, 1.0, 0.12, 1.96   # 모형
x_hat, P = 0.0, 10.0                # 초기 추정값

for z in measurements:
    # 1. 예측
    x_pred = A * x_hat
    P_pred = A * P * A + Q

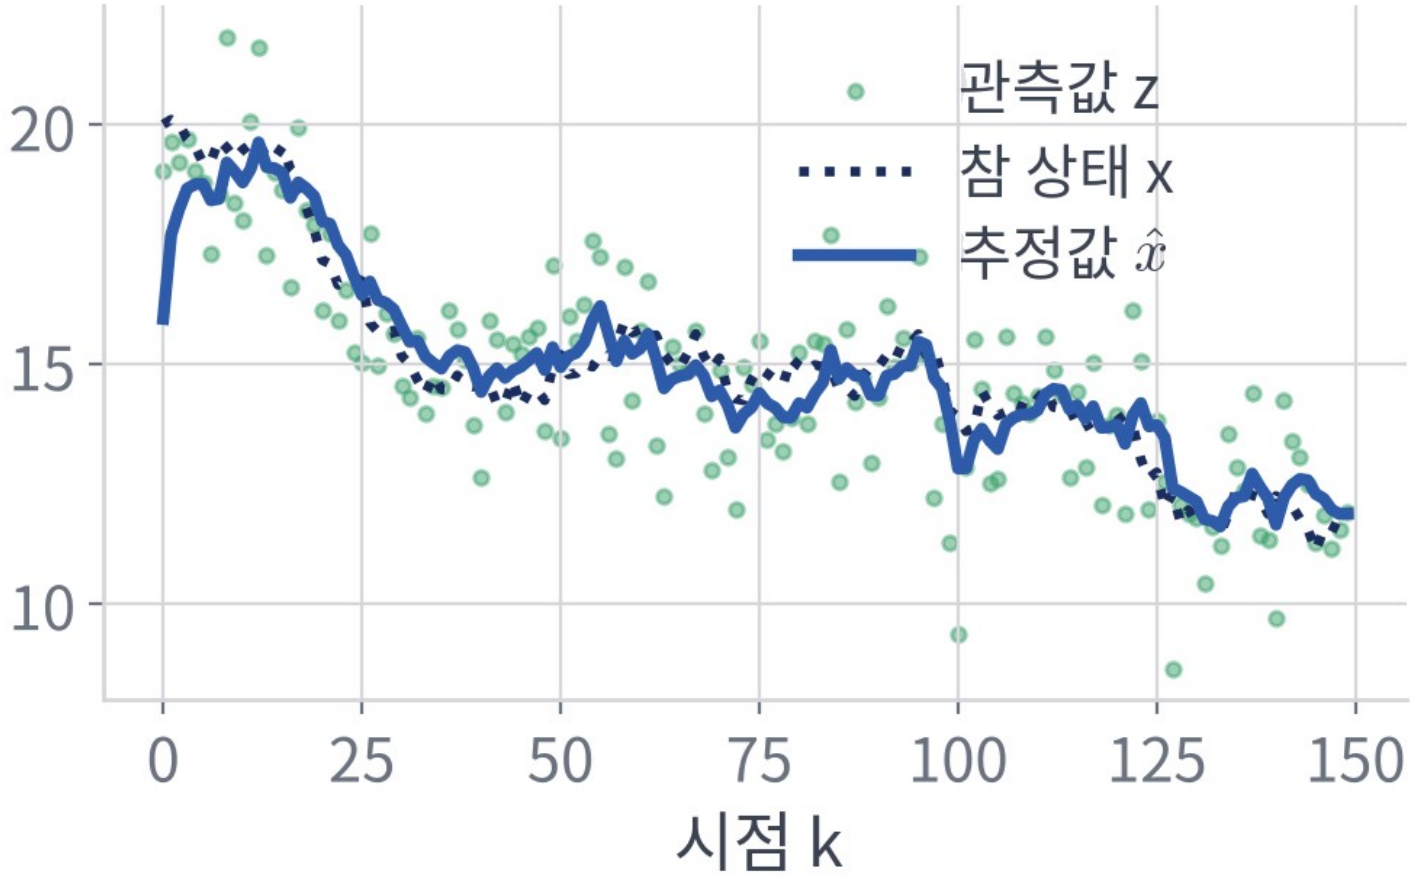
    # 2. 갱신
    K     = P_pred * H / (H * P_pred * H + R)
    x_hat = x_pred + K * (z - H * x_pred)
    P     = (1 - K * H) * P_pred
```

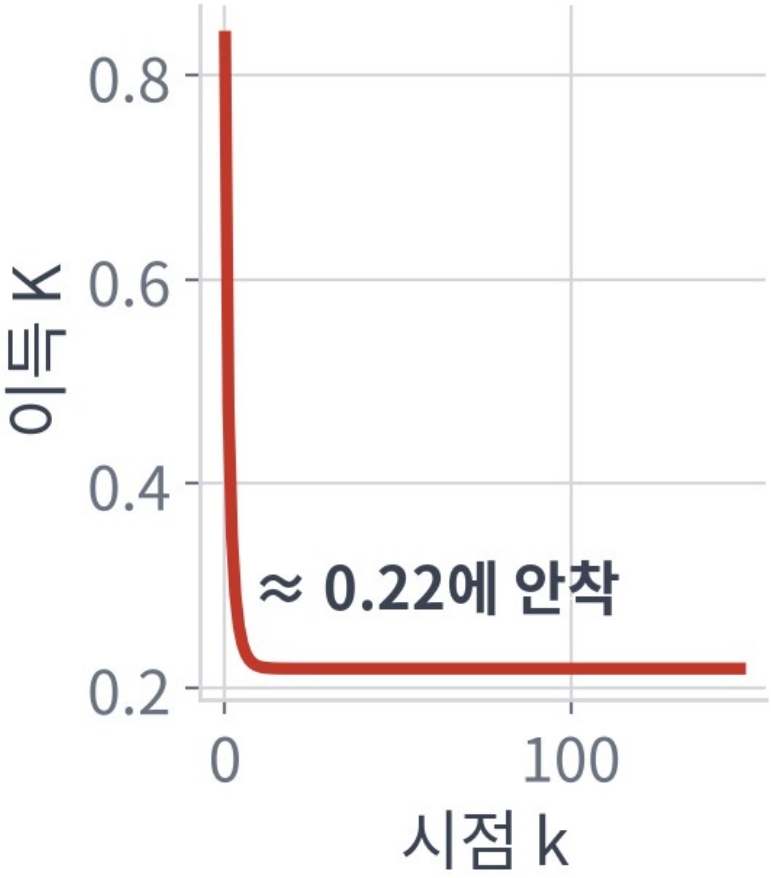
슬라이드와 대응

- 6~7행 = 예측 단계
- 10~12행 = 갱신 단계
- 행렬: @와 .T를 쓴다
- 라이브러리: filterpy, pykalman

코드는 참값을 따라가고 이득은 빠르게 안착한다

모의 자료에 코드를 돌린 결과: 오차가 원자료의 1.4에서 약 0.6으로 줄어든다





모든 응용은 다섯 질문에 답해 만든다

다음 절의 사례마다 이 점검표를 쓴다

1. 상태 x

은닉된 것은?

알고 싶지만 직접 볼 수 없는 값.

β, 추세, 위치

2. 모형 A

어떻게 움직이나?

상수, 랜덤워크, 또는 물리 법칙.

A = 1이 흔하다

3. 센서 H

무엇이 보이나?

상태가 관측값 z로 이어지는 방식.

H는 날마다 바뀔 수 있다

4. 잡음 Q, R

오차는 얼마나?

판단으로 정하거나 자료에서 추정한다.

Q/R만 중요하다

5. 시작

초기 추정값

대략적인 값과 큰 P.

곧 자료가 주도한다

05

응용

응용

다섯 식은 같고 재료만 바뀐다

일곱 가지 응용은 각 자리에 채우는 내용만 다르다

한 행을 가로로 읽으면 그 행이 칼만 필터 하나다

응용	상태 x	모형 A	관측값 z	센서 H
자동차 추적	위치, 속도	운동 법칙	GPS 위치	[1 0]
센서 융합	위치	랜덤워크	GPS와 휠 센서	두 센서
가격 추세	수준, 기울기	추세	일별 가격	[1 0]
페어 헤지 비율	β	1	EWC 가격	EWA 가격
주식 베타	α, β	1	주식 수익률	[1, 시장]
나우캐스팅	성장 갭 G	φ	발표 자료	1(또는 없음)
수익률 곡선	요인 갭 F	0.97	수익률	요인 적재량

자동차 추적: 상태는 위치와 속도이고, GPS는 위치를 본다

모형 먼저: 자동차 추적 필터의 두 식

상태식 :

$$\begin{bmatrix} \text{위치} \\ \text{속도} \end{bmatrix}_k = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \text{위치} \\ \text{속도} \end{bmatrix}_{k-1} + w_{k-1}$$

관측식 :

$$z_k^{\text{GPS}} = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} \text{위치} \\ \text{속도} \end{bmatrix}_k + v_k$$

자리 채우기

- x: 위치와 속도
- A: 등속 운동 법칙
- H: GPS는 위치만 읽는다

사용한 설정

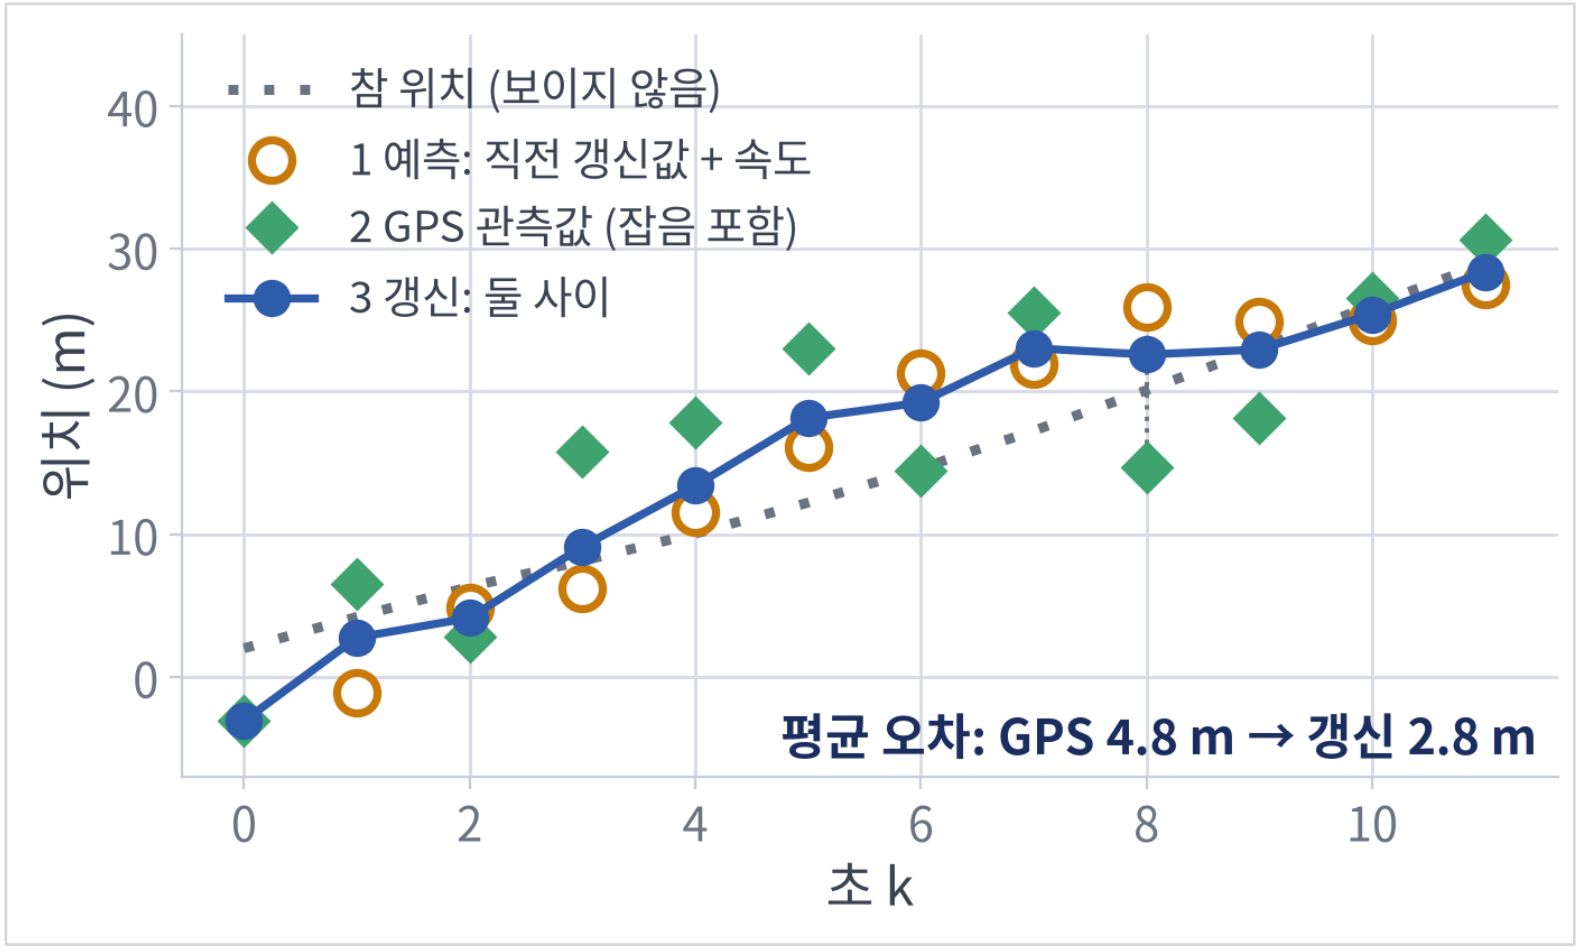
- Δt = 1초
- GPS 잡음 R = 36(표준편차 6 m)
- Q는 작게: 완만한 가속

필터는 매초 예측하고 관측한 뒤 둘 사이로 조정한다

참 위치는 보이지 않지만, 파란 갱신값은 GPS 값보다 참 위치에 가깝다

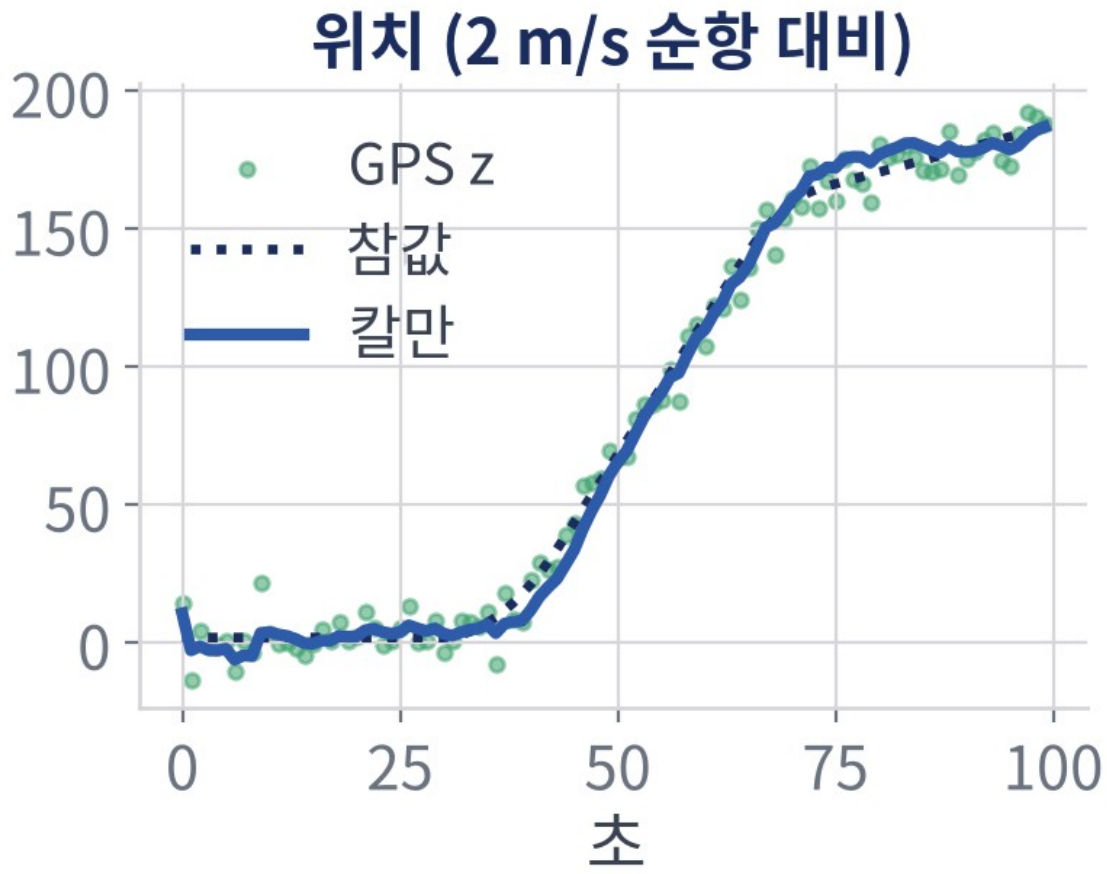
매초

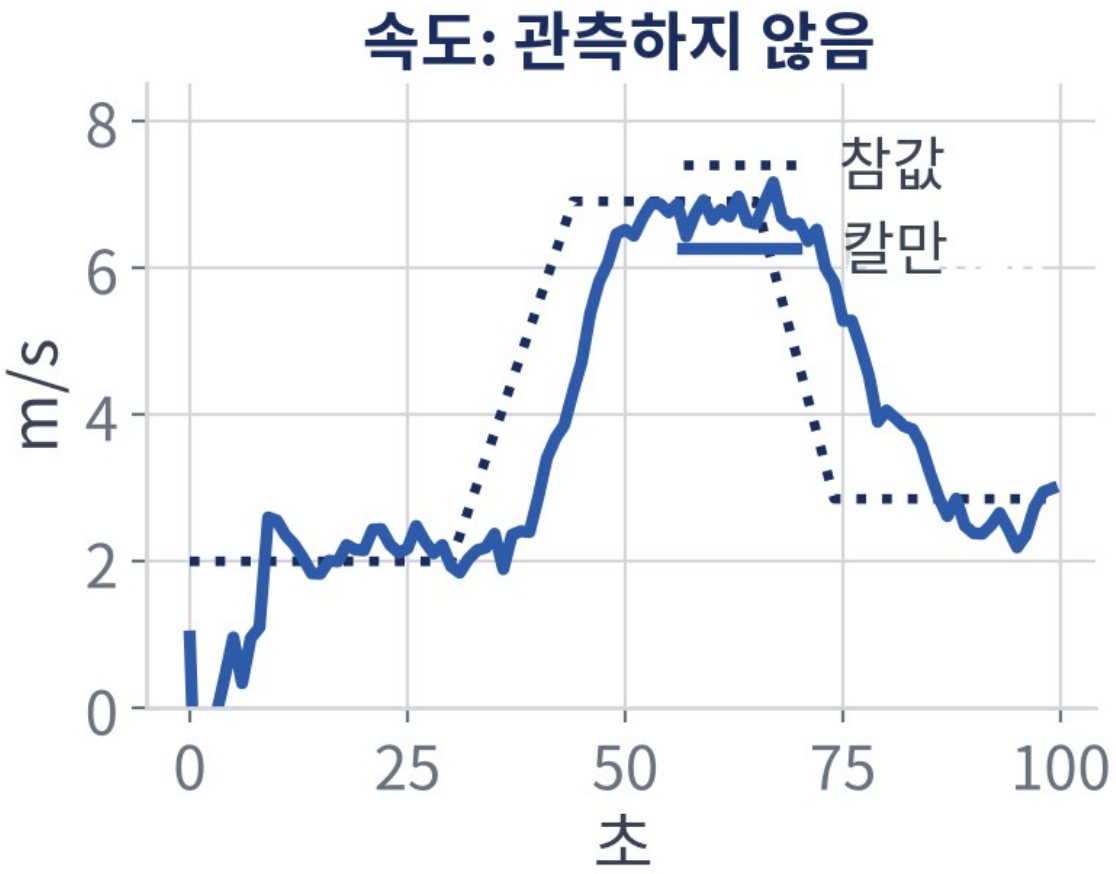
- 1 빈 원: 직전 갱신값 + 속도
- 2 마름모: GPS 관측값
- 3 파란 점: GPS 쪽으로 일부 이동
- 파란 점의 오차 ≈ GPS의 0.6배



GPS만 쓰면 값이 튀지만, 필터는 속도까지 복원한다

x = [위치, 속도]인 자동차 추적: 속도는 관측하지 않는다



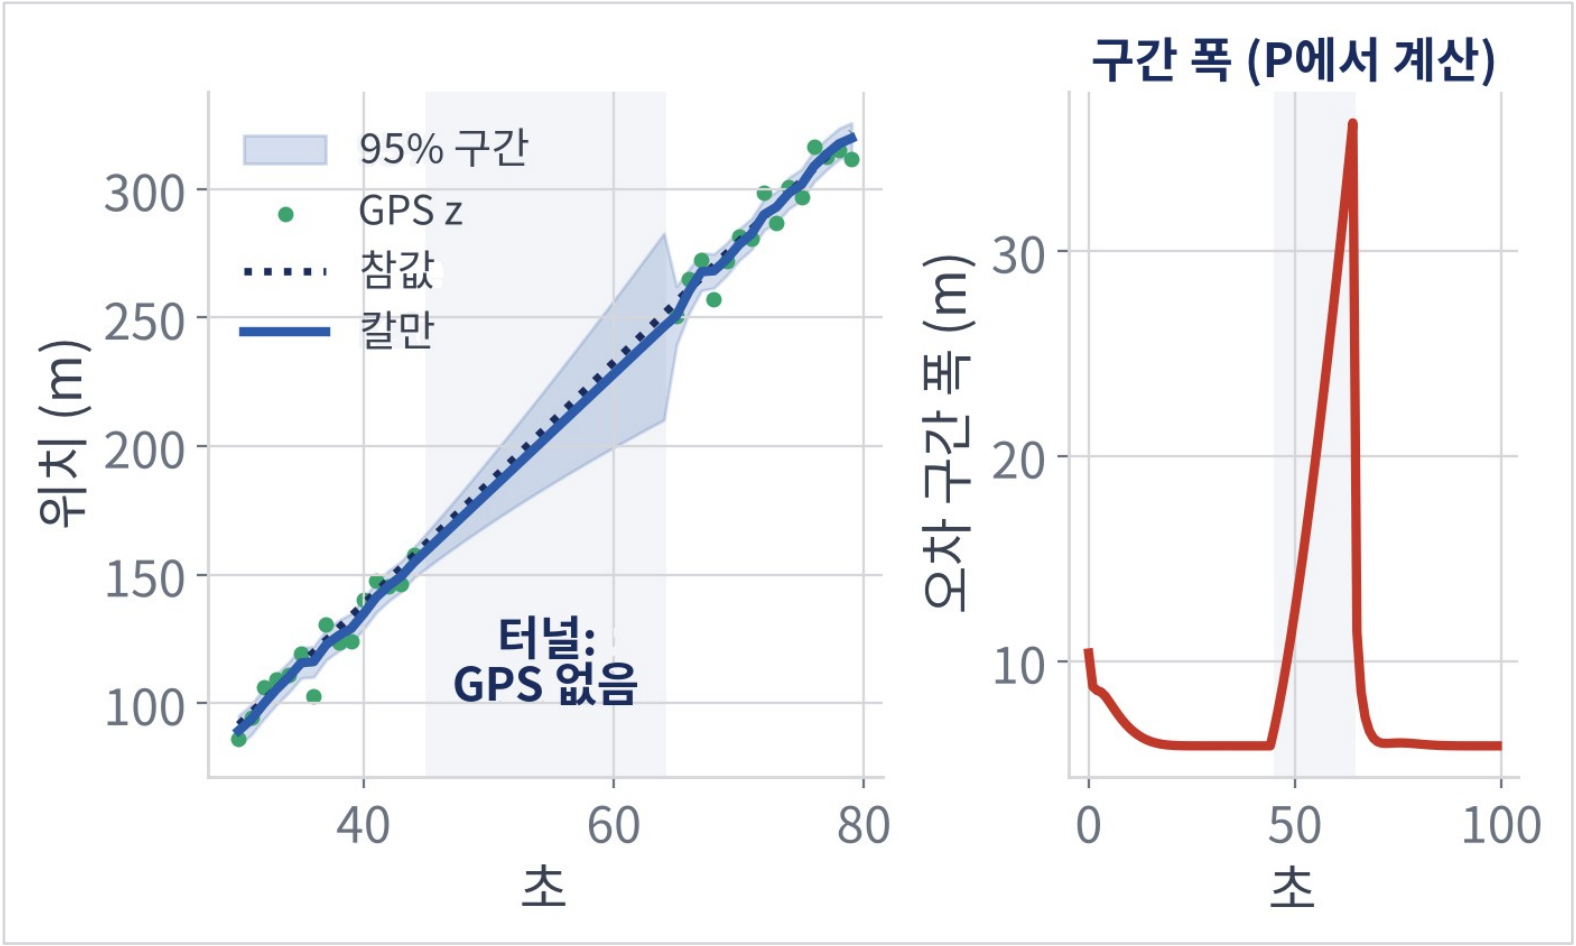


GPS가 끊기면 필터는 예측만 하고 오차 구간을 넓힌다

모의 주행: 45초에서 64초 사이에 GPS 신호가 끊긴다(회색 구간)

초 단위로 보면

- 회색: GPS 없음, 예측만 수행
- 속도가 추정값을 끌고 간다
- P 증가: 구간이 넓어진다
- GPS 복귀: 구간이 좁아진다



사례 1

터널 안에서 필터는 모형만으로 계속 주행한다

다섯 식은 같고, z가 없는 동안 갱신식만 실행하지 않는다

GPS가 없으면 갱신도 없다.
위치는 속도 × Δt만큼 움직이고, P는 매초 Q만큼 커진다.

필터가 하는 일

- 마지막으로 추정한 속도를 쓴다
- 위치를 앞으로 옮긴다
- 더 넓은 오차 구간을 보고한다

GPS가 돌아오면

- P가 커서 K는 1에 가깝다
- 처음 관측값에 큰 가중치가 붙는다
- 구간은 몇 초 안에 좁아진다

사례 2

센서 융합: 상태 하나, 관측 행 두 개

모형 먼저: GPS와 휠 센서가 같은 위치를 관측한다

상태식 : $$\text{위치}_k = \text{위치}_{k-1} + w_{k-1}$$

관측식 : $$\begin{bmatrix} z_k^{\text{GPS}} \\ z_k^{\text{휠}} \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \text{위치}_k + \begin{bmatrix} v_k^{\text{GPS}} \\ v_k^{\text{휠}} \end{bmatrix}$$

자리 채우기

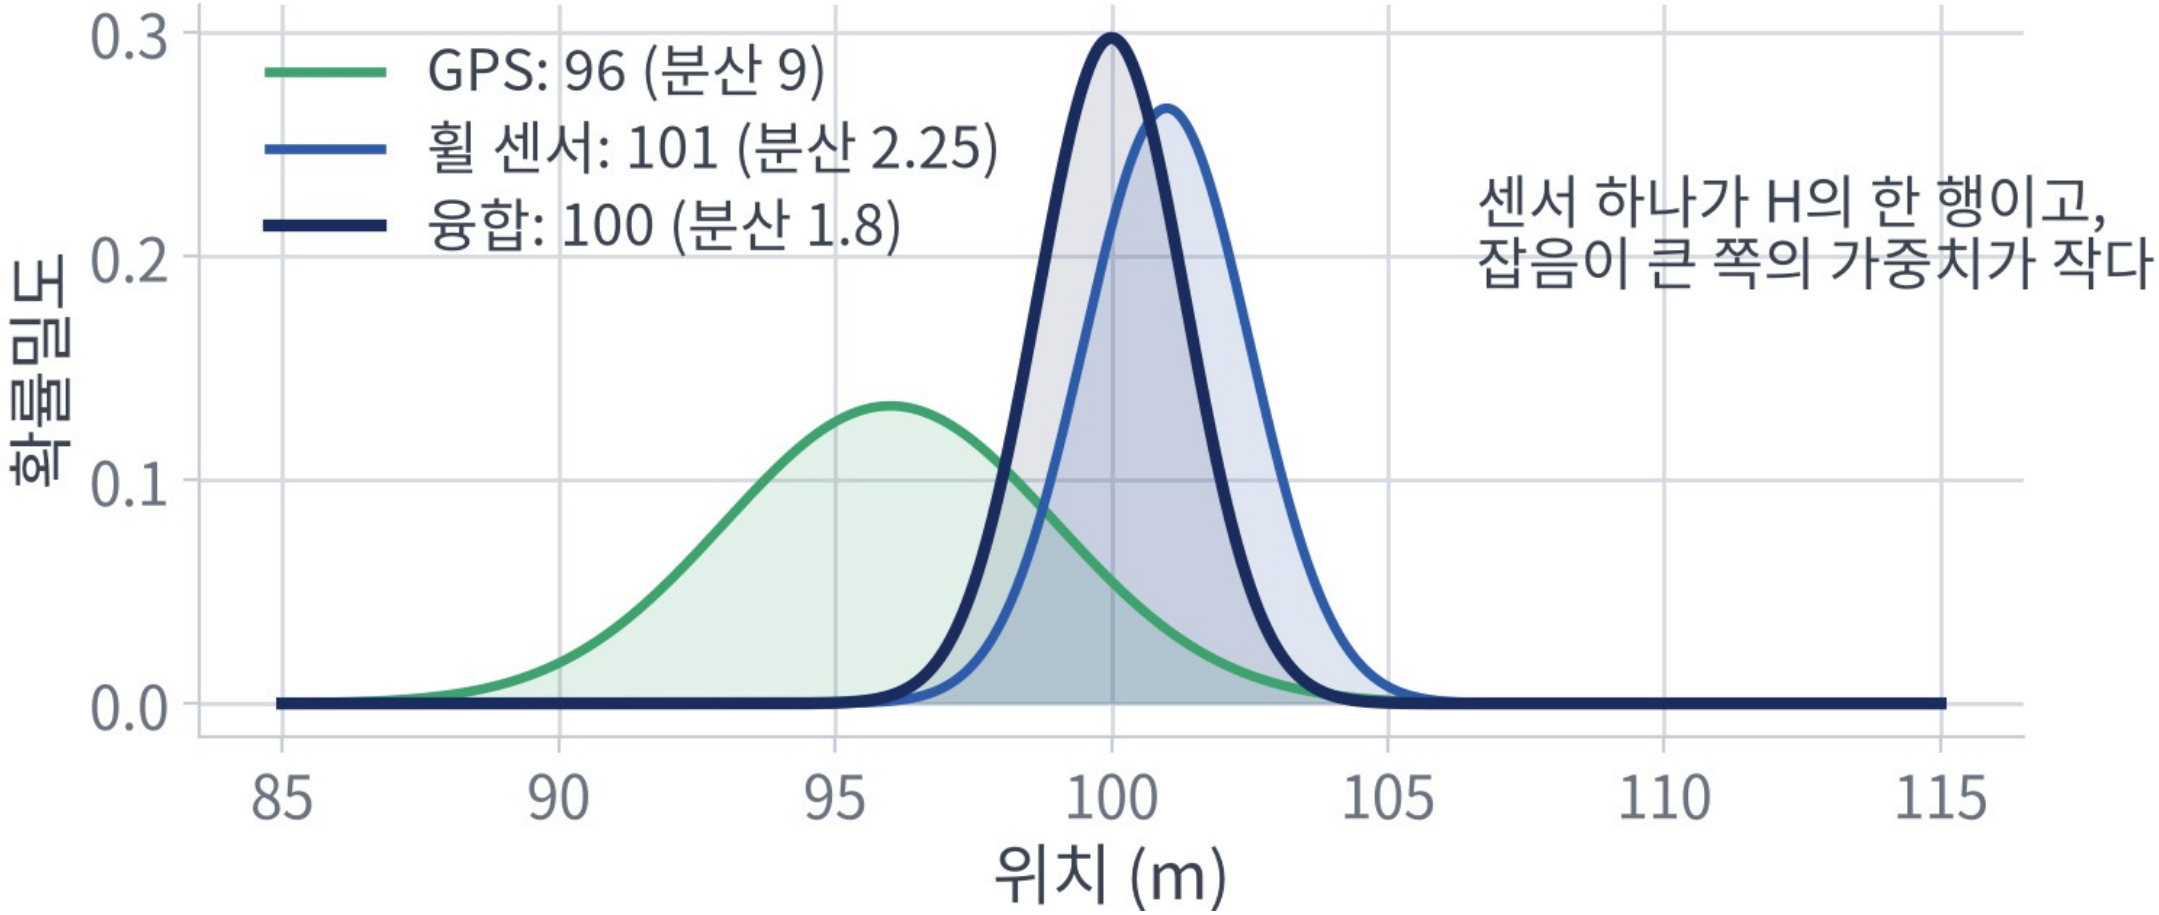
- x: 위치
- A = 1: 랜덤워크
- H: 센서마다 한 행

사용한 설정

- Q = 0.09
- R: GPS 9, 휠 센서 2.25
- 각 행을 차례로 갱신

센서 둘은 종 모양 곡선 둘을 주고, 융합 곡선은 둘보다 좁다

모형을 그림으로: 센서 하나가 관측식의 한 행이다



사례 2

관측값이 둘이면 칼만 이득은 행벡터가 된다

갱신 단계와 같은 이득 공식이다. H는 두 행이고, R은 두 센서의 분산을 담는다

$$H = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad R = \begin{bmatrix} R_1 & 0 \\ 0 & R_2 \end{bmatrix} \quad \Rightarrow \quad K_k = P_k^- H^\top \left(H P_k^- H^\top + R \right)^{-1} = \underbrace{\frac{P_k^-}{D} \begin{bmatrix} R_2 & R_1 \end{bmatrix}}_{1\times 2 \text{ 행벡터}}$$

$$D = P_k^- (R_1 + R_2) + R_1 R_2$$

$$\hat{x}_k = \hat{x}_k^- + K_1 \left(z_k^{\mathrm{GPS}} - \hat{x}_k^- \right) + K_2 \left(z_k^{\text{휠}} - \hat{x}_k^- \right)$$

$$P_k = (1 - K_1 - K_2)\, P_k^-$$

이득 읽기

- K_1에는 R_2가, K_2에는 R_1이 곱해진다
- 잡음이 큰 센서의 가중치가 더 작다

K의 크기

- 행 = 상태(1), 열 = 센서(2)
- 일반적으로 K는 상태 n개 × 센서 m개

사례 2

두 센서를 한꺼번에 갱신하든 차례로 갱신하든 답은 같다

두 센서 잡음이 독립이어서 R이 대각행렬이면 항상 성립한다

벡터 이득 한 단계 = 스칼라 이득 두 단계.
이 장의 차트는 두 단계 방식을 쓴다: 역행렬이 필요 없다.

한꺼번에

- 두 관측값을 z로 쌓는다
- 성분이 둘인 이득 K 하나
- 2 × 2 행렬 S의 역행렬이 필요하다

차례로

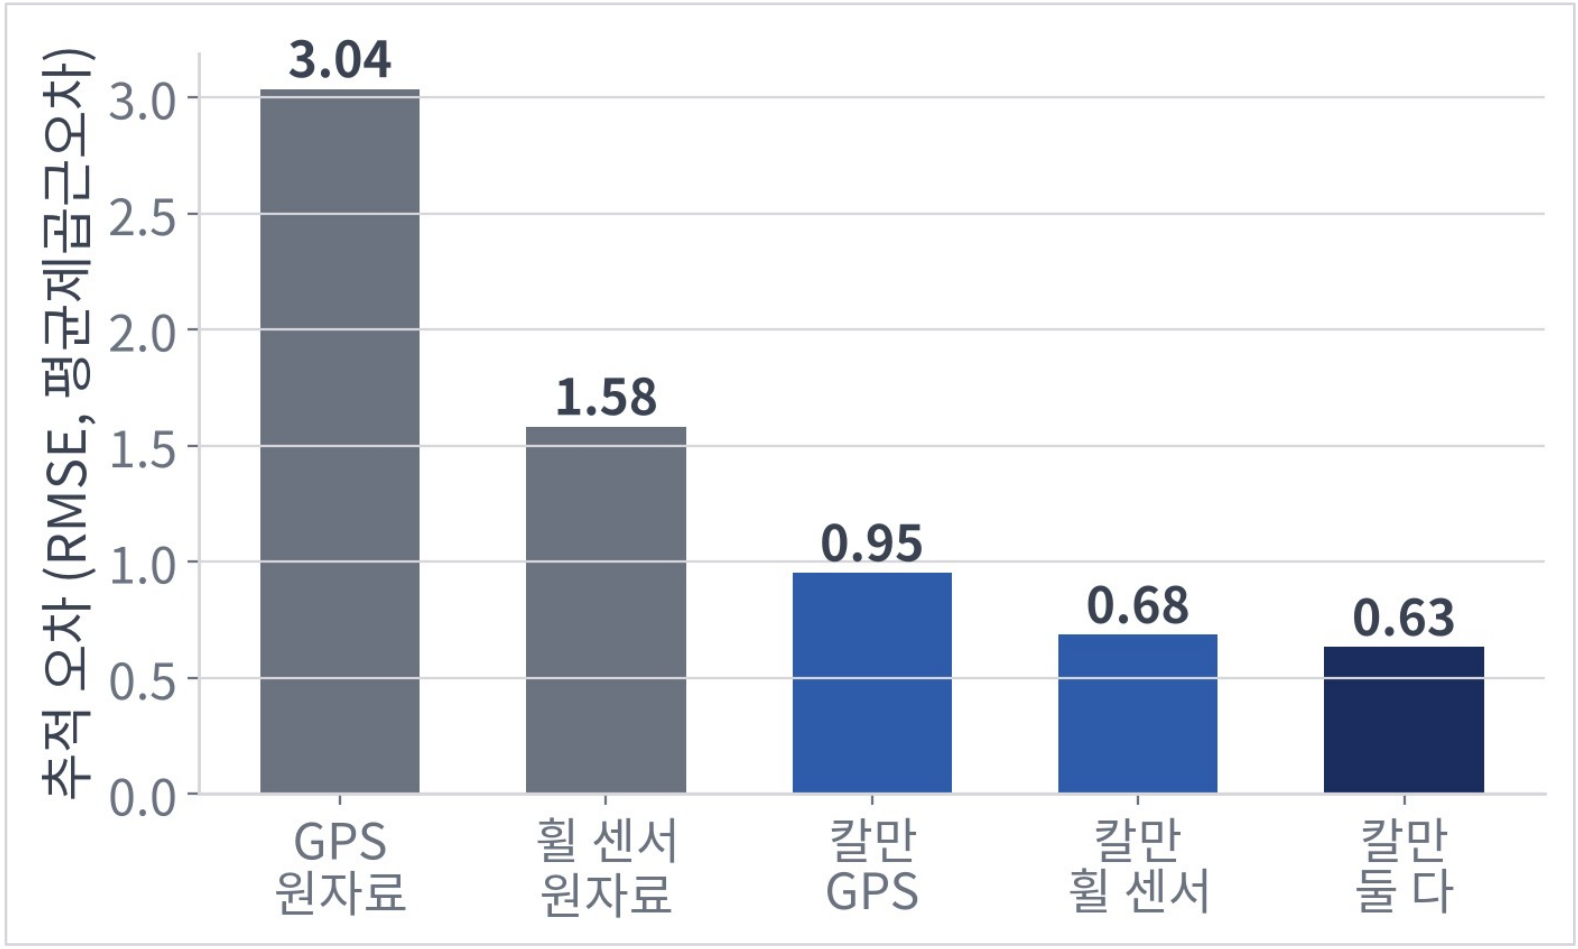
- GPS로 갱신, $R_1 = 9$
- 이어서 휠 센서로, $R_2 = 2.25$
- 단계마다 스칼라 공식을 쓴다

두 센서를 함께 쓰면 더 나은 센서 하나보다 낫다

센서 융합: 각 관측값이 자기 R로 추정값을 갱신한다

융합 방법

- GPS로 갱신(R = 9)
- 이어서 휠 센서 (R = 2.25)
- 잡음이 큰 센서는 K 가 작다
- 휴대전화는 매초 이렇게 한다



가격 추세: 상태는 수준과 기울기, 가격은 수준에 잡음을 더한 값

모형 먼저: 국소 선형 추세 모형

$$\text{상태식 :} \quad \begin{bmatrix} \text{수준} \\ \text{기울기} \end{bmatrix}_k = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \text{수준} \\ \text{기울기} \end{bmatrix}_{k-1} + w_{k-1}$$

$$\text{관측식 :} \quad \text{가격}_k = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} \text{수준} \\ \text{기울기} \end{bmatrix}_k + v_k$$

자리 채우기

- x: 수준과 기울기
- A: 수준이 기울기만큼 커진다
- H: 가격은 수준을 보여 준다

사용한 설정

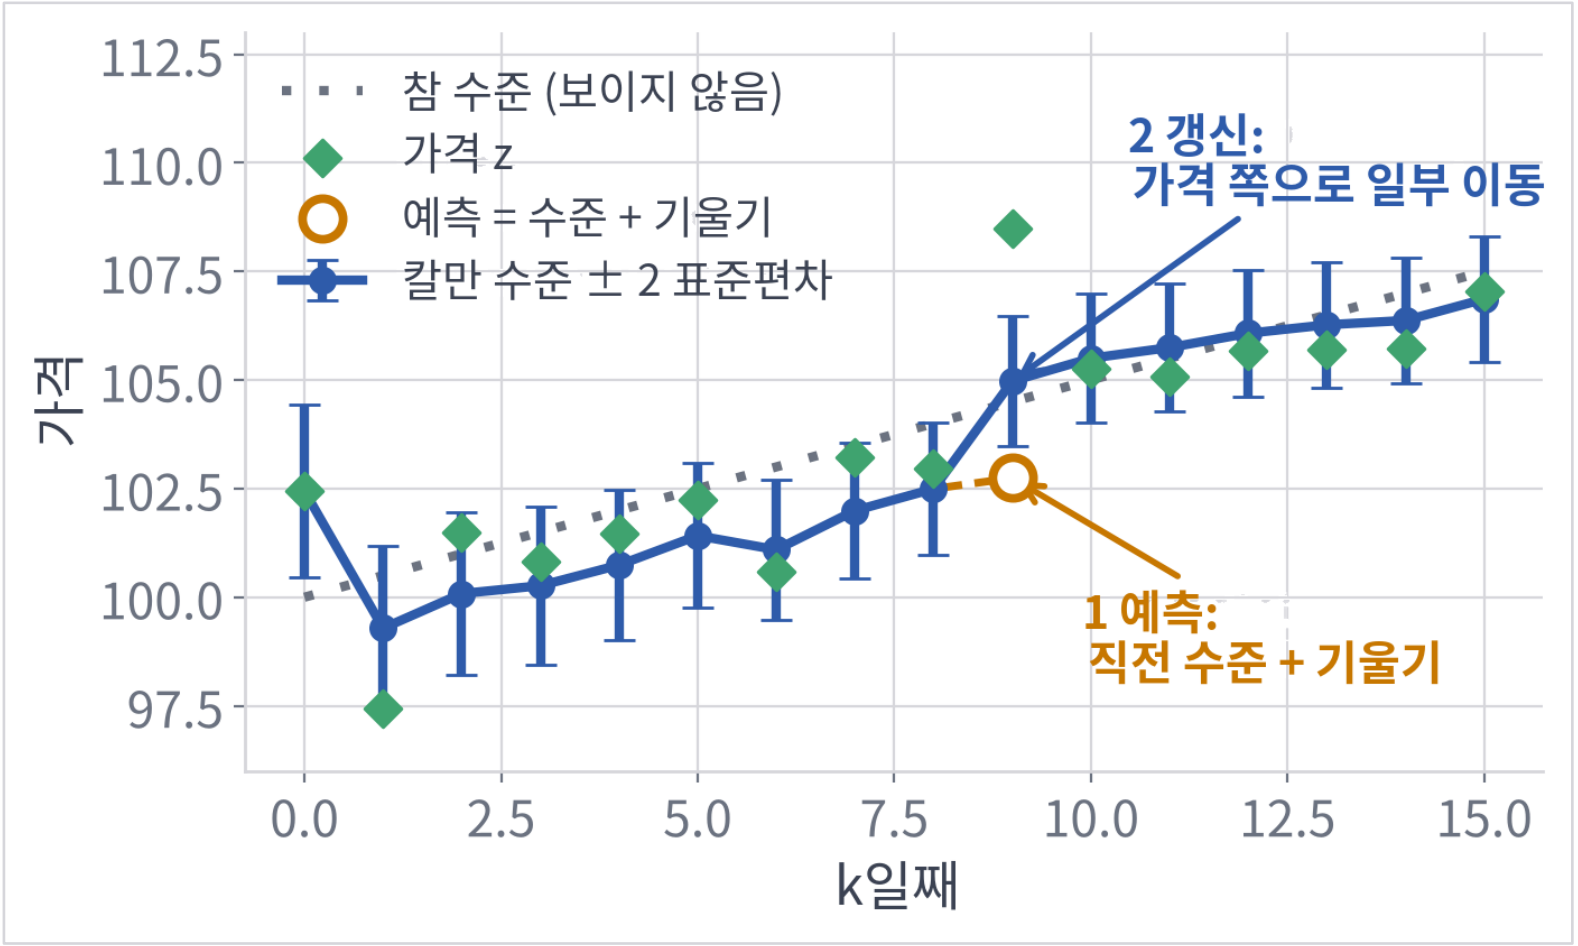
- Q: 수준 0.05, 기울기 0.002
- R = 2.56(표준편차 1.6)
- 매끄러움은 Q/R이 결정

필터는 매일 기울기로 예측한 뒤 가격 쪽으로 끌어당긴다

참 수준은 보이지 않는다. 동그라미 친 날이 두 단계를 보여 준다

읽는 법

- 점선: 참 수준
- 마름모: 가격 z
- 빈 원: 수준 + 기울기
- 파란 점: 갱신 후
- 막대: ± 2 표준편차

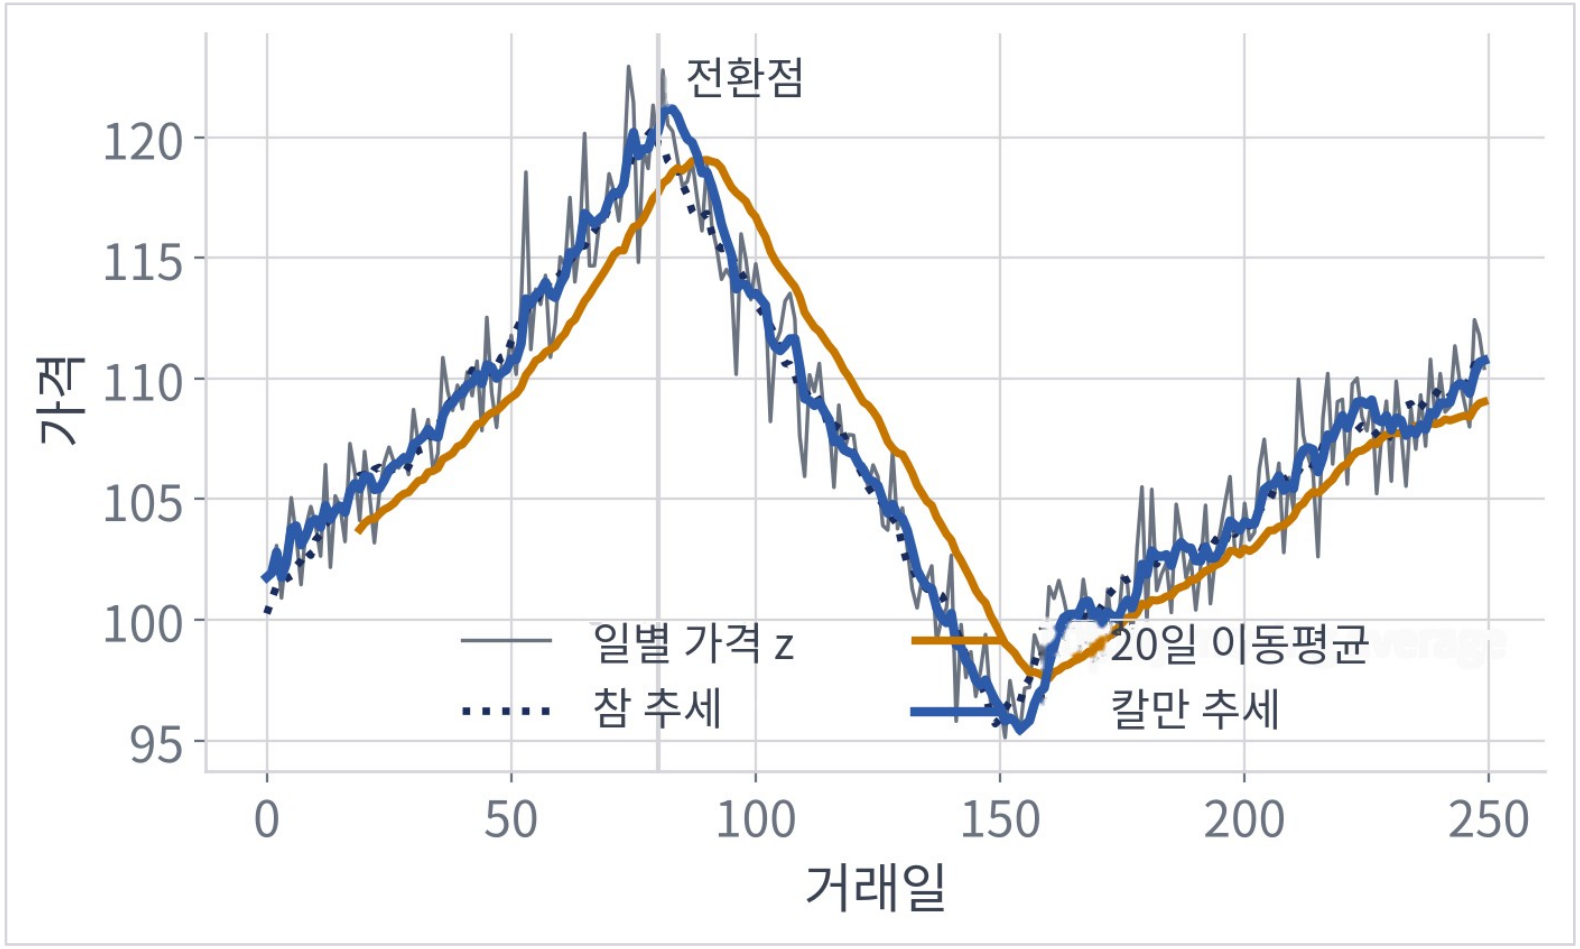


칼만 추세는 이동평균보다 빨리 방향을 튼다

x = [수준, 기울기]로 추세 추출: 기울기가 있어 모형이 앞을 내다본다

시차가 작은 이유

- 평균은 옛 자료를 기다린다
- 필터는 기울기를 지닌다
- Q/R이 매끄러움을 결정
- 윈도를 고를 필요가 없다



페어 트레이딩: 헤지 비율이 상태이고, EWA 가격이 H다

모형 먼저: β는 랜덤워크로 움직이고, EWC 가격이 관측값이다

상태식 : $\beta_k = \beta_{k-1} + w_{k-1}$

관측식 : $\mathrm{EWC}_k = \mathrm{EWA}_k \cdot \beta_k + v_k$

자리 채우기

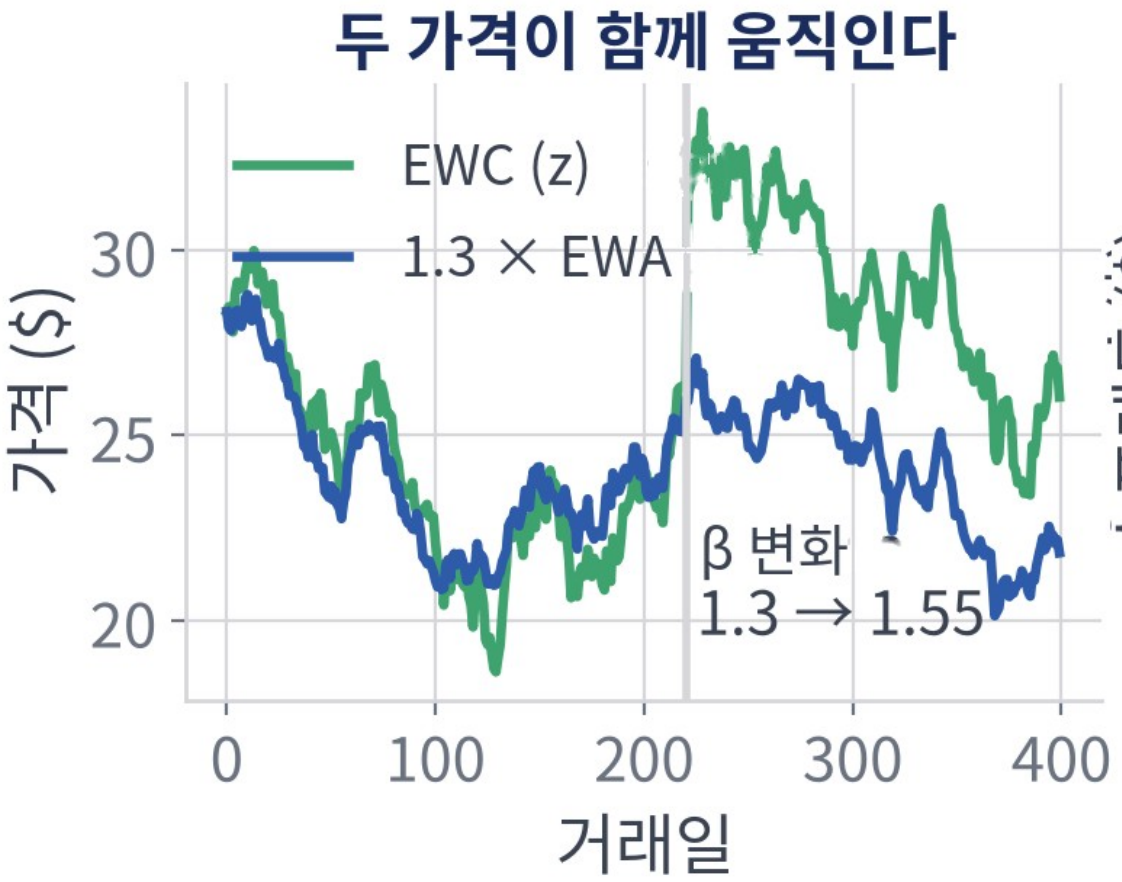
- x: 헤지 비율 β
- A = 1: β가 서서히 움직인다
- H: 오늘의 EWA 가격

사용한 설정

- Q = 하루 0.00001
- R = 1(스프레드 잡음)
- 초기 추정값 β = 0, P = 1

β가 틀리면 안정적인 스프레드가 표류한다

모형을 그림으로: EWC는 β × EWA를 따라가고, β 자체도 움직일 수 있다





사례 4

페어 거래에는 시간에 따라 바뀔 수 있는 헤지 비율이 필요하다

기초 지식: EWA(호주)와 EWC(캐나다)는 모두 원자재 수출국을 추종하는 상장지수펀드(Exchange-Traded Fund, ETF)다

EWC 1주를 매수하고 EWA β주를 매도한다.
둘 사이의 스프레드는 평균으로 계속 돌아와야 한다.

β가 중요한 이유

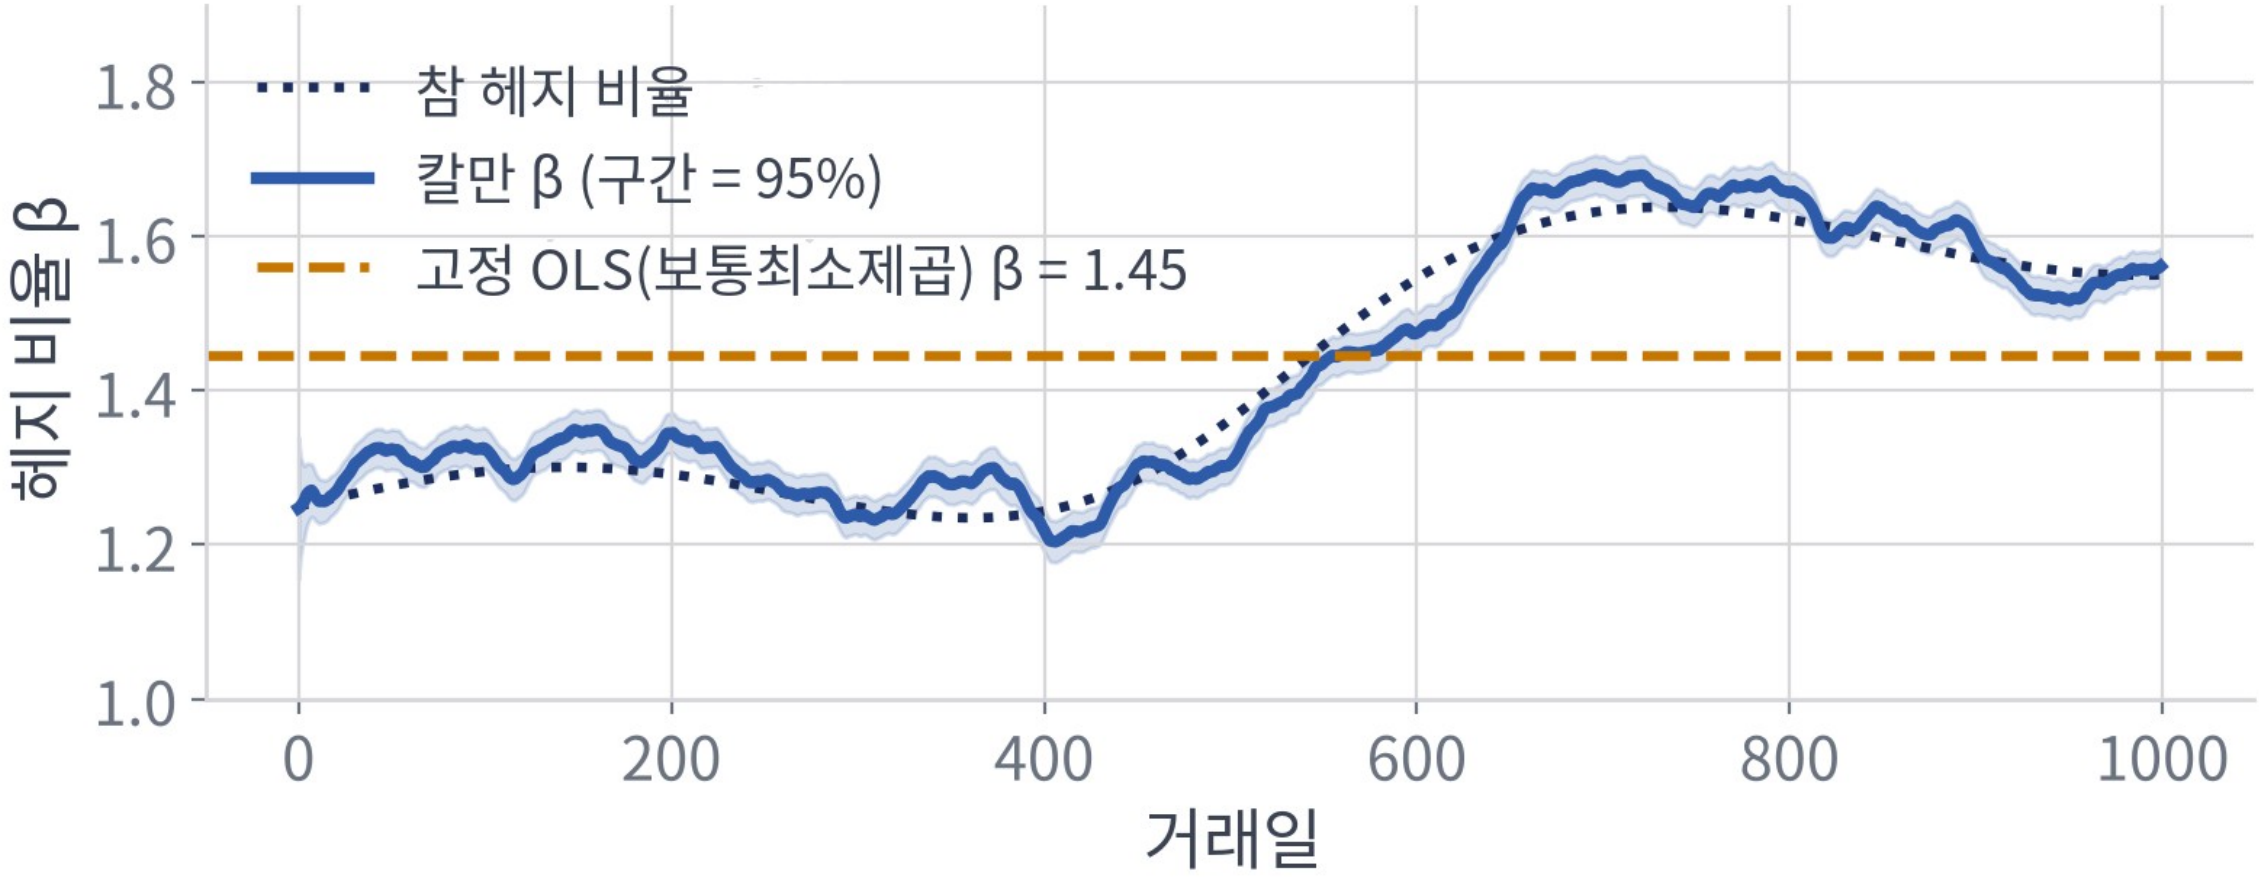
- β가 틀리면: 스프레드가 표류한다
- 표류하는 스프레드: 거짓 신호
- 경제가 변하면 β도 변한다

칼만 필터의 해법

- β를 은닉상태로 둔다
- 매일 갱신한다
- 혁신을 신호로 쓴다

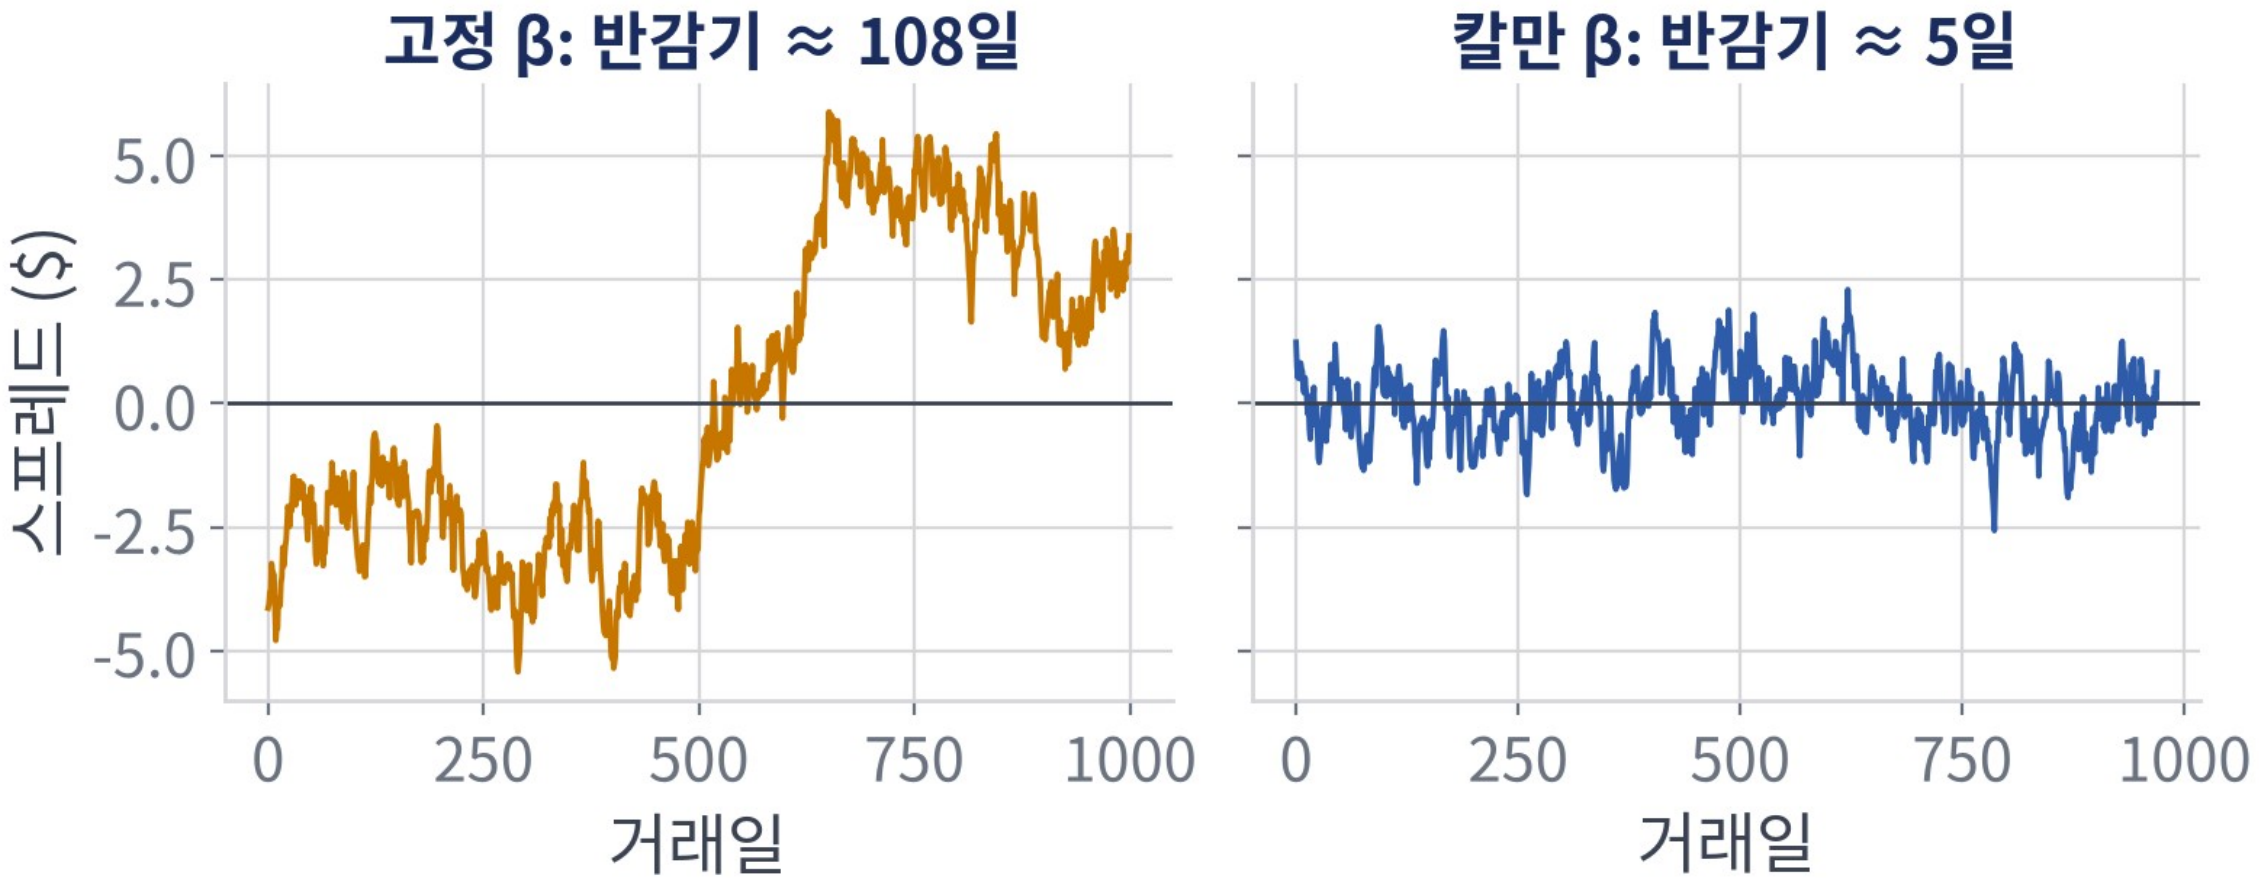
칼만 헤지 비율은 참 β를 따라가지만 고정 β는 그러지 못한다

EWA·EWC와 비슷한 가격에 일별 필터 적용 · 모의 자료 · Q = 0.00001, R = 1



칼만 β를 쓰면 스프레드가 계속 0으로 돌아온다

스프레드는 EWC − β × EWA이며, 전날 β를 써서 미래 자료가 들어가지 않는다 · 모의 자료



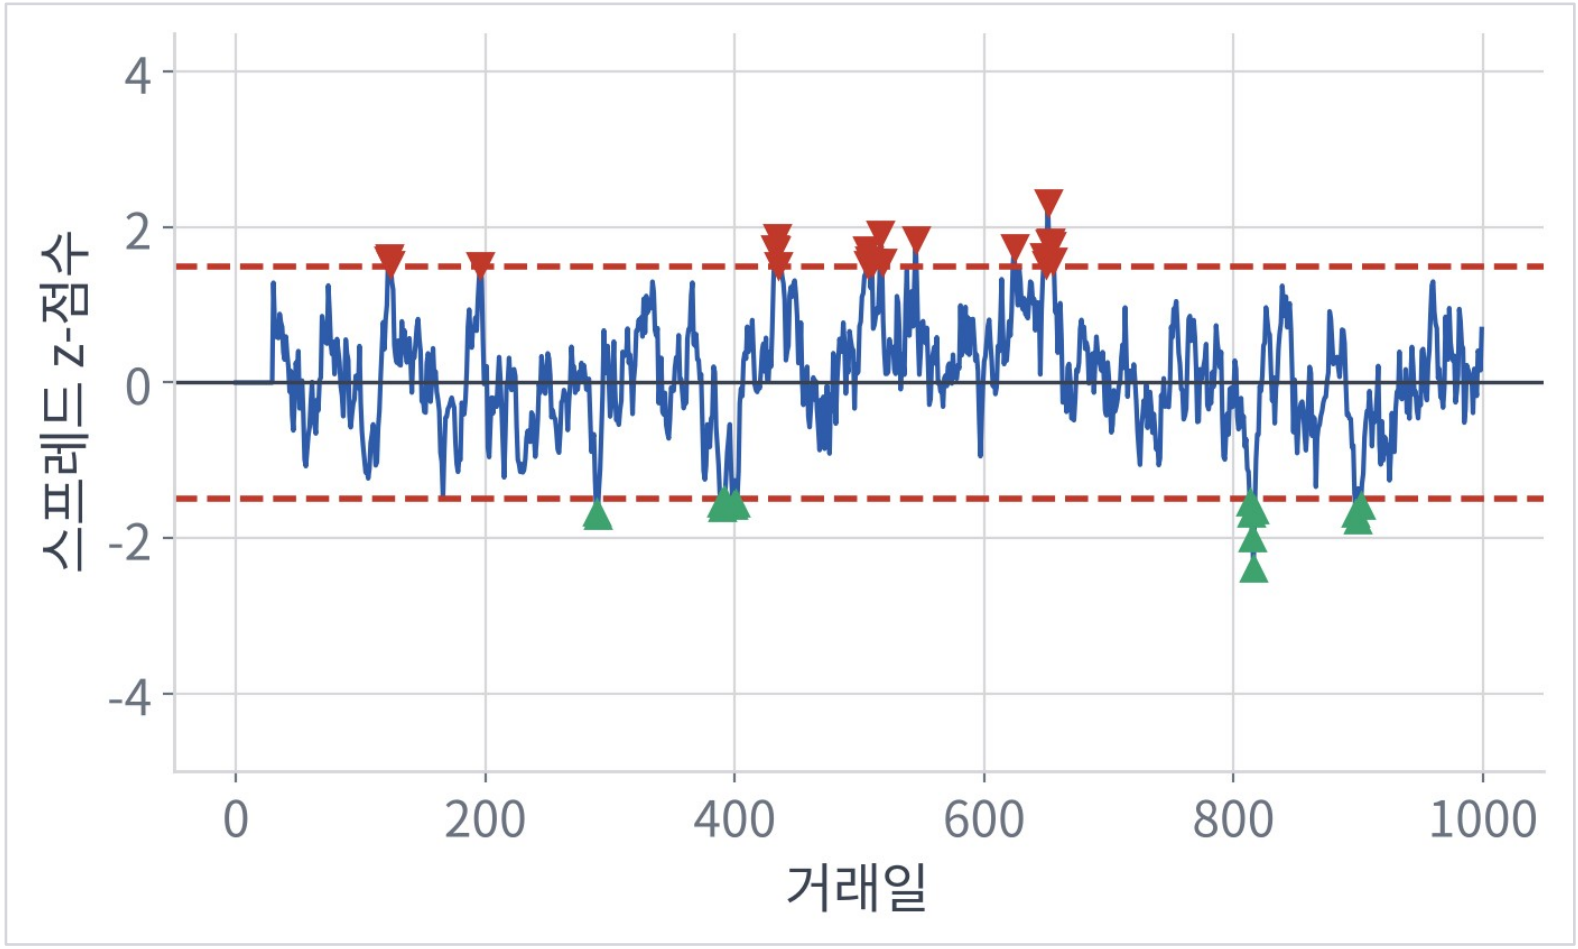
사례 4

혁신 z-점수는 그대로 거래 신호가 된다

빨간 삼각형: +1.5 위에서 스프레드 매도 · 초록 삼각형: −1.5 아래에서 매수

작동 원리

- 혁신 = 예측오차
- 그 분산을 알고 있다
- 그래서 z-점수는 단위가 없다
- 거래비용은 포함하지 않았다



주식 베타: 상태는 알파와 베타이고, H에 시장 수익률이 들어간다

모형 먼저: 시변 자본자산가격결정모형(CAPM) 회귀의 상태공간 표현

상태식 : $$\begin{bmatrix}\alpha\\ \beta\end{bmatrix}_k = \begin{bmatrix}\alpha\\ \beta\end{bmatrix}_{k-1} + w_{k-1}$$

관측식 : $$r_k^{\text{주식}} = \begin{bmatrix}1 & r_k^{\text{시장}}\end{bmatrix} \begin{bmatrix}\alpha\\ \beta\end{bmatrix}_k + v_k$$

자리 채우기

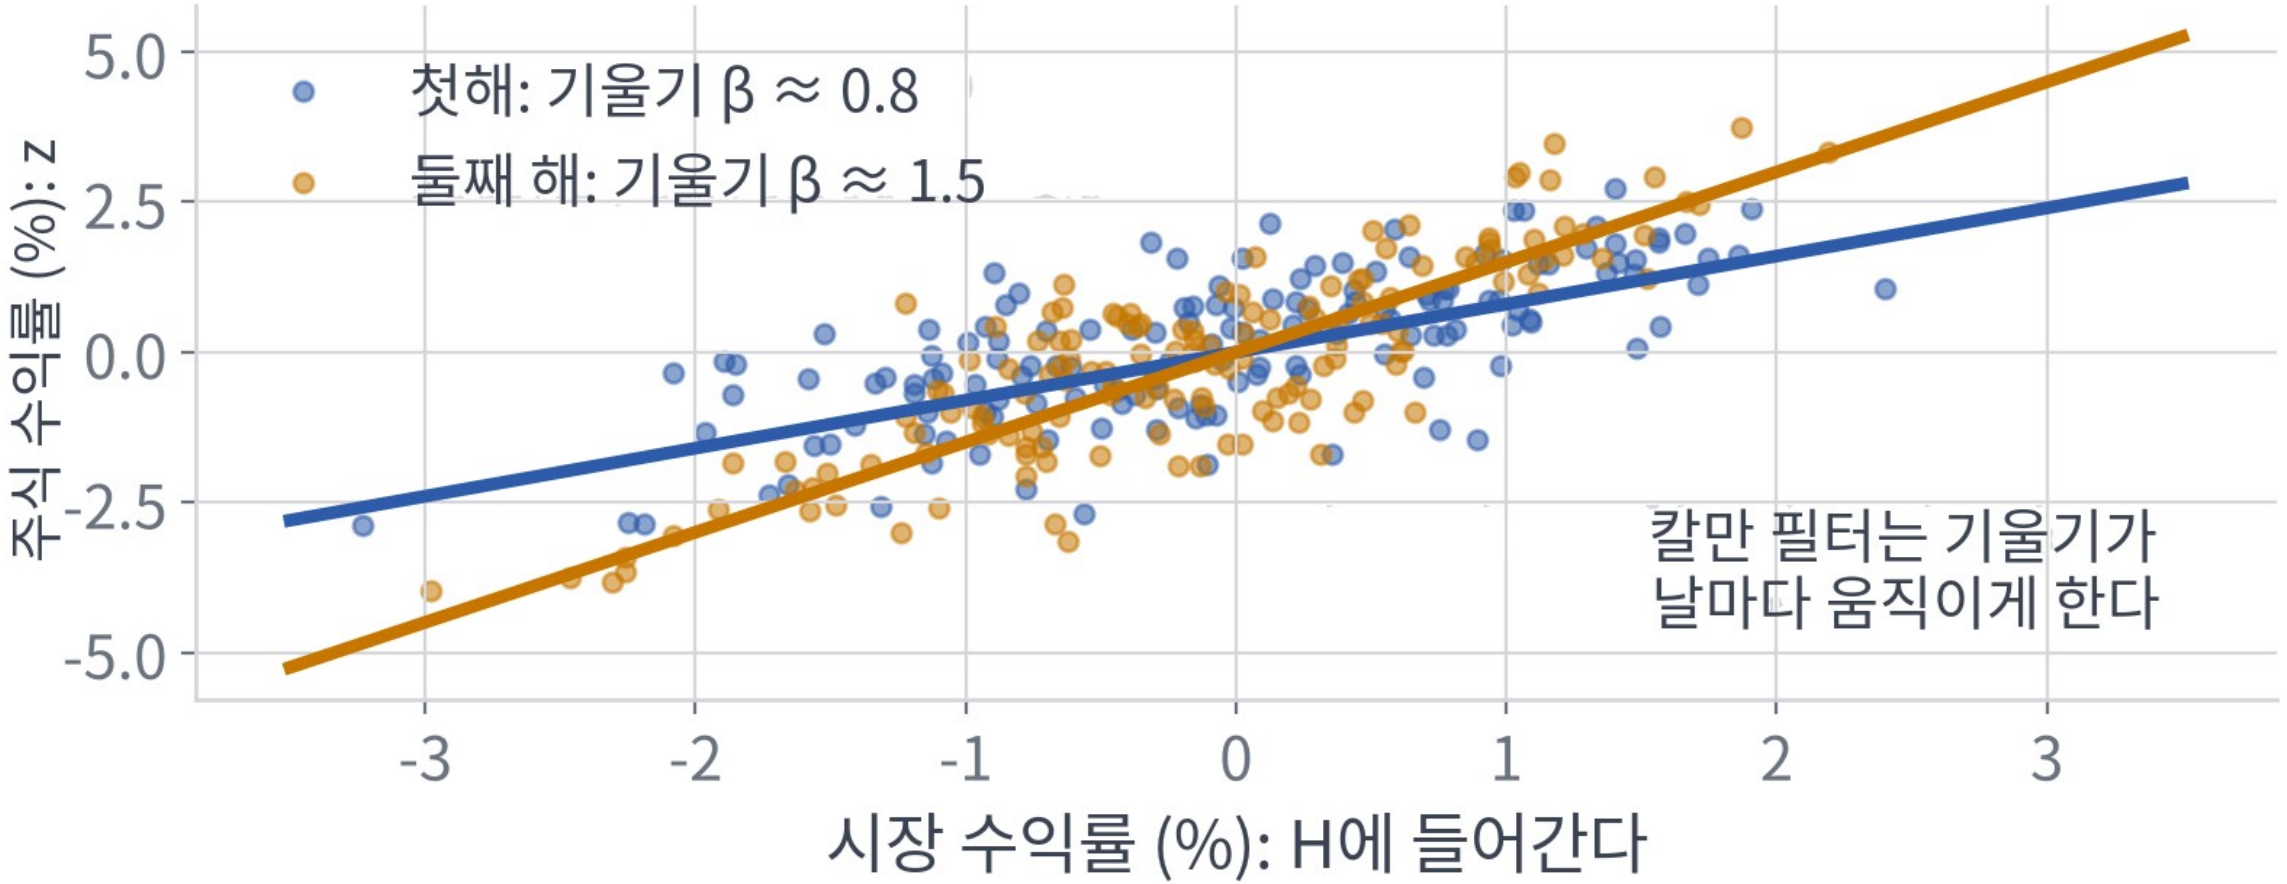
- x: α와 β
- A = 1: 둘 다 서서히 움직인다
- H: [1, 시장 수익률]

사용한 설정

- Q: β가 α보다 빠르게 움직인다
- R = 일별 잔차 분산
- H는 날마다 바뀐다

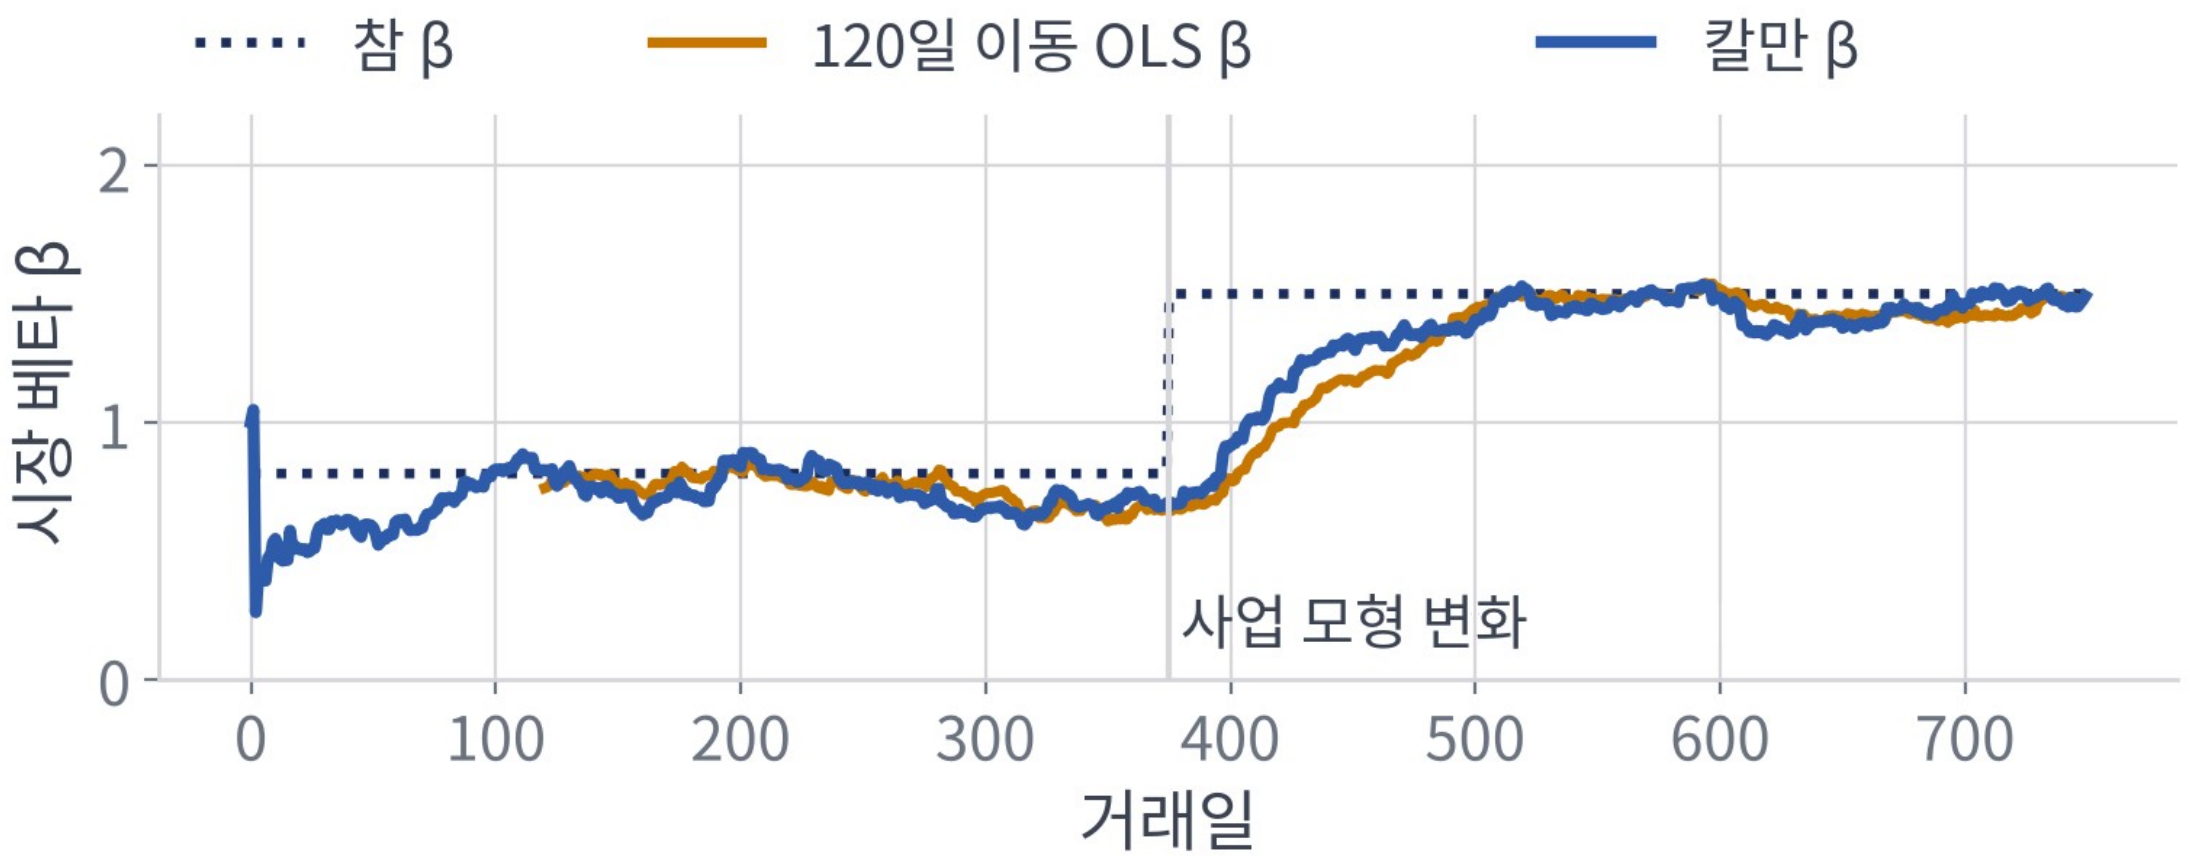
베타는 주식 수익률을 시장 수익률에 회귀한 기울기다

모형을 그림으로: H는 시장 수익률, z는 주식 수익률, β는 기울기다



칼만 베타는 윈도 없이 국면 변화에 적응한다

참 β가 375일째에 0.8에서 1.5로 뛴다 · 일별 수익률 · 모의 자료



나우캐스팅: 성장 갭 G가 상태이고, 각 발표치는 G를 오차와 함께 관측한다

모형 먼저: 갭 G = g − μ를 쓰면 틀 x = A x + w가 적용된다

상태 : $\underbrace{G_k}_{\text{오늘의 갭}} = \underbrace{\phi}_{\text{A}} G_{k-1} + \underbrace{w_{k-1}}_{\text{새 충격}}$

관측 : $z_k = \underbrace{1}_{\text{H}} \cdot G_k + \underbrace{v_k}_{\text{발표 오차}}$

여기서 : $G_k = g_k - \mu$ (참 성장률 – 평균), $z_k =$ 발표 성장률 $- \mu$

자리 채우기

- x = G, 성장 갭
- A = φ = 0.9, H = 1

사용한 설정

- μ = 2%, Q = 0.25, R = 0.36
- v: 발표치의 오차

μ는 성장률이 계속 돌아오는 수준이다

μ = 장기 평균 성장률이고, 상태 G는 g가 μ에서 떨어진 거리다



갭 G는 매달 예측하지만 자료가 발표될 때만 보정한다

두 행 모두 상태 G = g − μ를 가리키고, z는 발표된 성장률에서 μ를 뺀 값이다

	1월	2월	3월	4월	5월	6월	7월	8월	9월
상태 G (성장 갭)	예측	예측	예측	예측	예측	예측	예측	예측	예측
관측값 z (발표치 − μ)	갱신	갱신	z 없음: 건너뜀	갱신	z 없음: 건너뜀	z 없음: 건너뜀	갱신	z 없음: 건너뜀	갱신

두 행 모두 갭 G = g − μ를 가리킨다. G는 매달 예측하고,

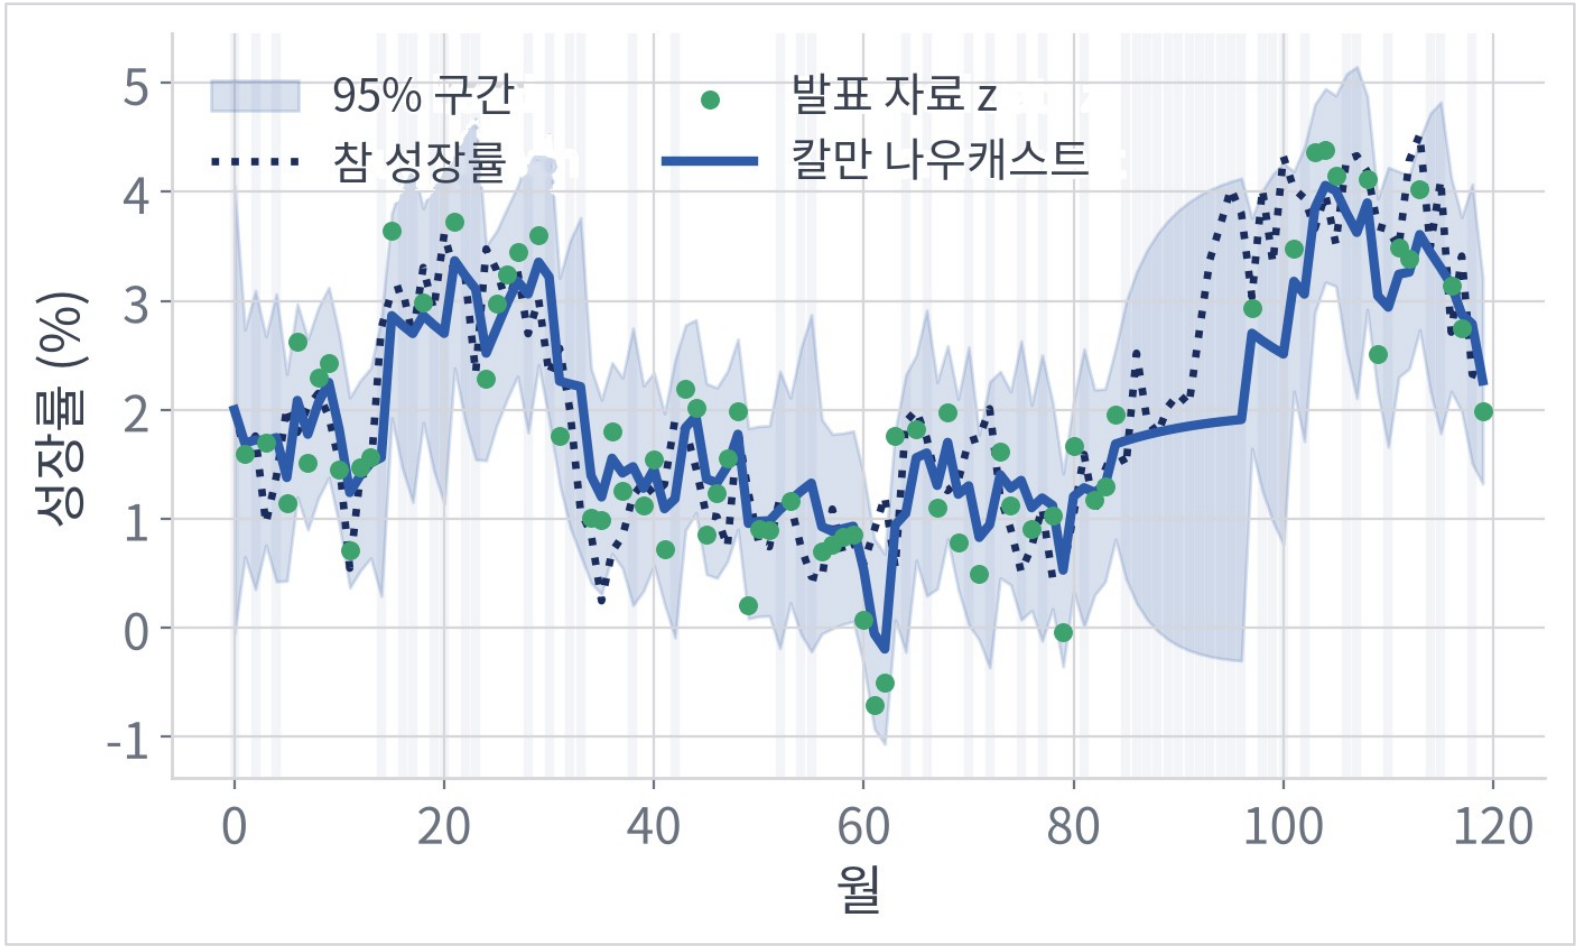
수치 z가 발표된 달에만 보정한다. v는 그 수치의 오차다.

발표가 빠진 달은 갱신을 건너뛰어 처리한다

필터링한 G에 μ를 더해 성장률 g로 그렸다. 공식 자료는 늦고 불규칙하게 나온다

빈 달의 규칙

- 자료 있음: 갱신
- 자료 없음: 예측만
- 빈 구간에서 구간 폭이 넓어진다
- 중앙은행이 쓰는 방식이다



여러 월간 계열과 분기 국내총생산(GDP)이 은닉 성장 갭 하나를 공유한다

혼합주기 동적 요인 나우캐스팅: 적재량은 예시 값이다

상태 : $G_k = \phi G_{k-1} + w_{k-1}$ (G_k : 공통 성장 갭)

관측 :

$$\begin{bmatrix} z^{\text{생산}} \\ z^{\text{소매}} \\ z^{\text{고용}} \\ z^{\text{GDP}} \end{bmatrix}_k = \underbrace{\begin{bmatrix} 1.0 \\ 0.8 \\ 0.6 \\ 0.9 \end{bmatrix}}_{\text{H (적재량)}} G_k + \begin{bmatrix} v^{\text{생산}} \\ v^{\text{소매}} \\ v^{\text{고용}} \\ v^{\text{GDP}} \end{bmatrix}_k$$

자리 채우기

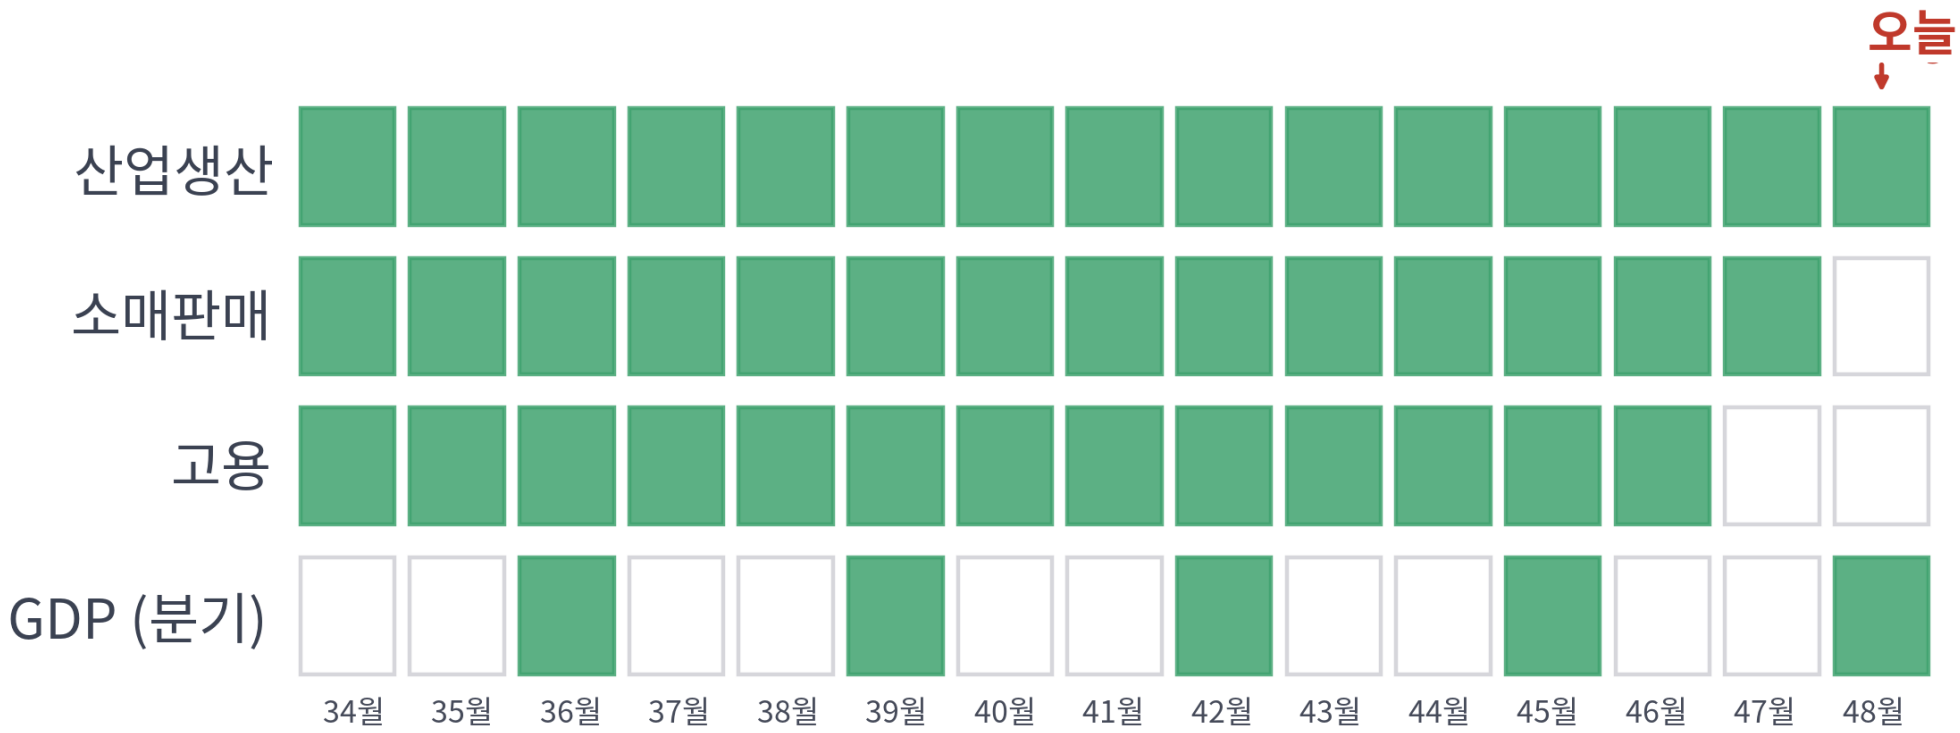
- x = G, 공통 갭 하나
- H: 계열마다 적재량 하나

혼합주기

- 월간 계열: 매달
- GDP: 분기의 셋째 달

필터는 매달 발표된 행만 쓴다

들쭉날쭉한 끝(ragged edge): 최신 달에는 산업생산과 GDP만 있고, 고용과 소매판매는 나중에 나온다

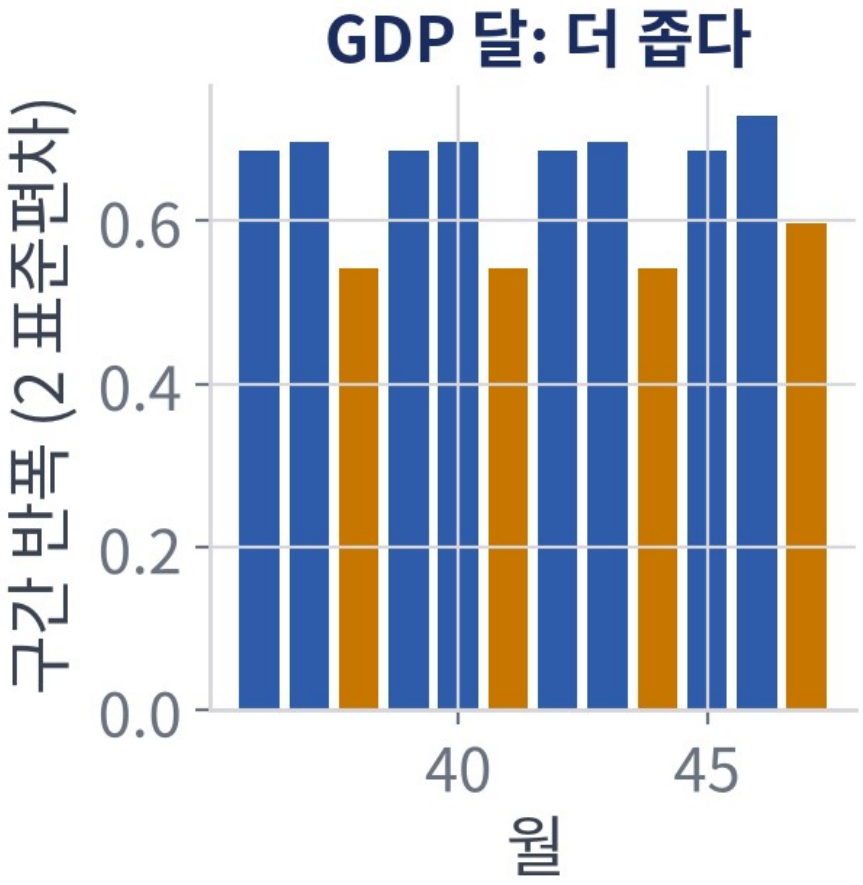


초록색 = 그달에 발표된 수치.
H는 매달 초록색 행만 남긴다.

모든 계열을 결합하면 GDP 발표 사이에도 갭을 추적한다

모의 자료 · GDP는 분기 마지막 달의 G 관측값으로 처리한다(단순화)





수익률 곡선: 세 요인 갭이 상태이고, 그 모양들이 H를 이룬다

모형 먼저: 갭 F = 요인 − μ를 쓰면 틀 x = A x + w가 적용된다

상태 : $F_k = \underbrace{A}_{\text{각 } 0.97} F_{k-1} + w_{k-1}$

관측 : $z_k(\tau) = \underbrace{\begin{bmatrix} 1 & \lambda_S(\tau) & \lambda_C(\tau) \end{bmatrix}}_{\mathrm{H}} F_k + v_k$

여기서 : $F_k = \begin{bmatrix} L_k - \mu_L \\ S_k - \mu_S \\ C_k - \mu_C \end{bmatrix}$ (요인 − 평균), $z_k(\tau) = y_k(\tau) - \bar{y}(\tau)$

자리 채우기

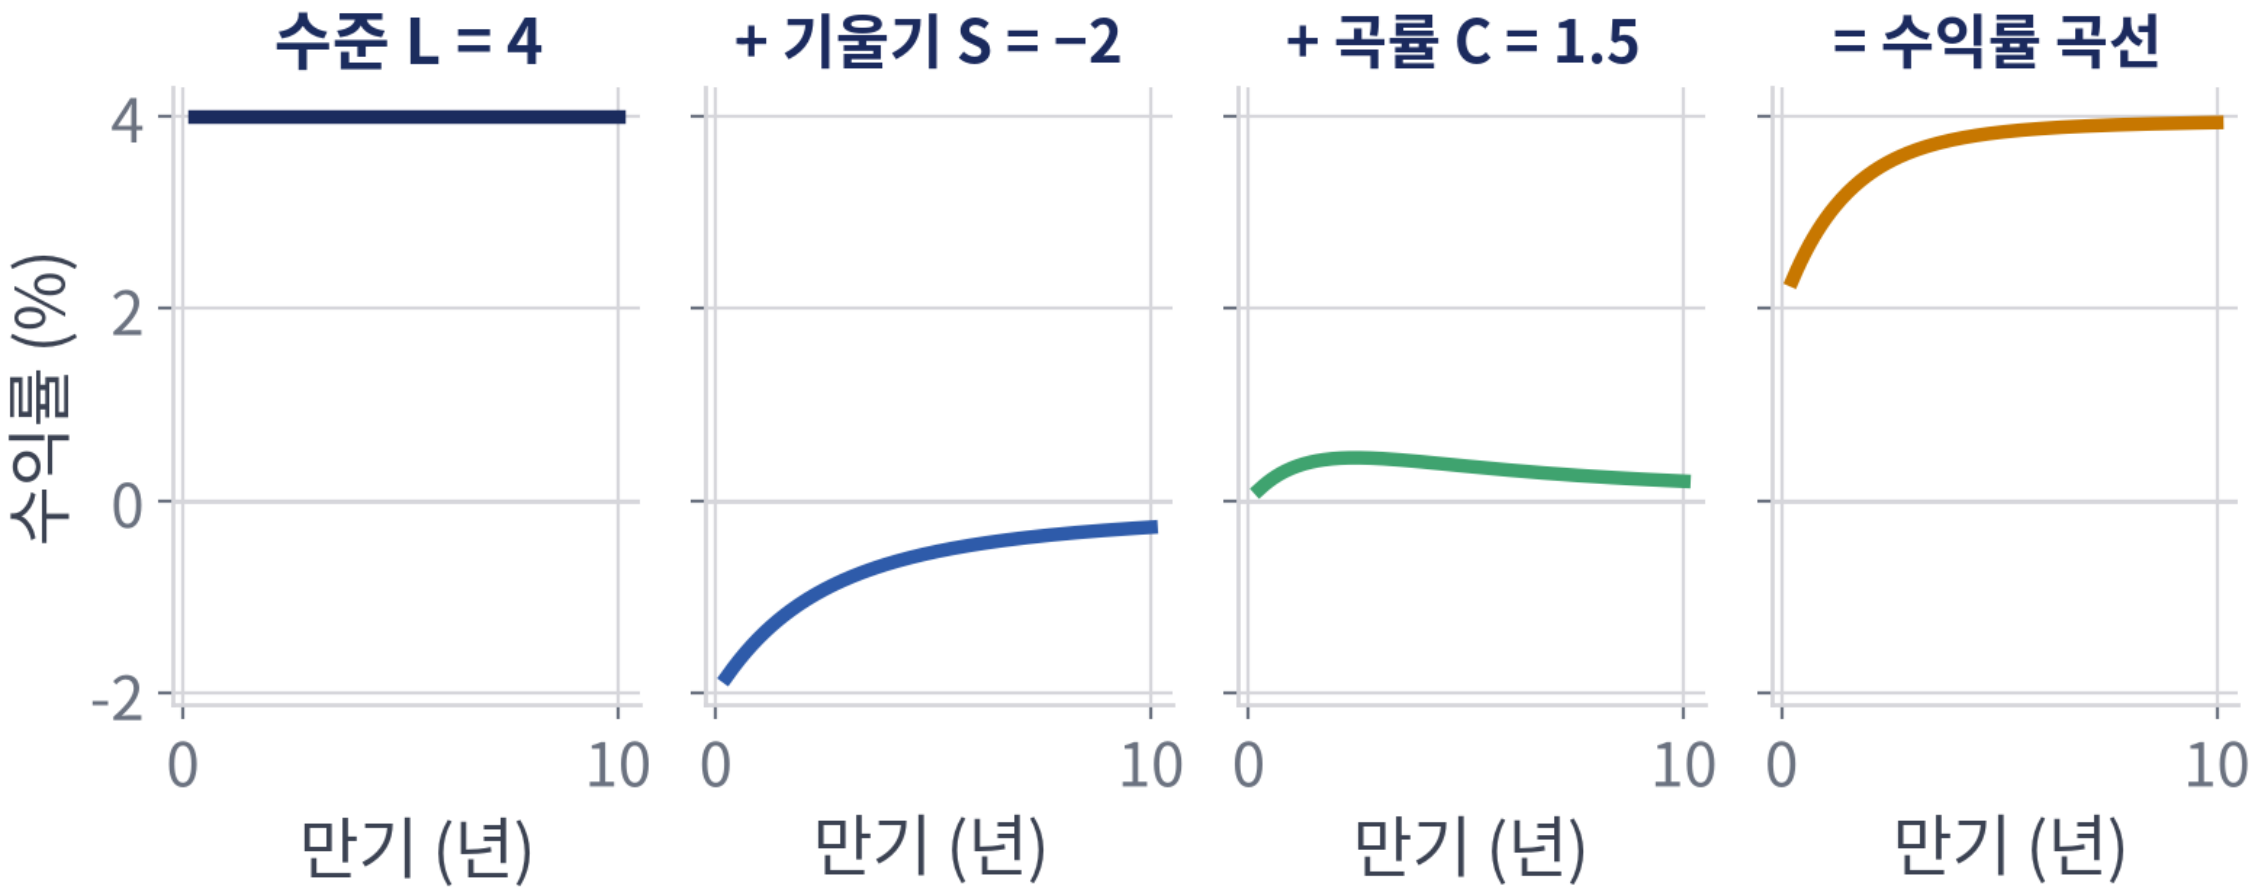
- x = F: 수준·기울기·곡률 갭
- A = 0.97: 각 갭이 줄어든다

사용한 설정

- H: λ(τ), 만기마다 한 행
- v: 수익률별 적합 오차

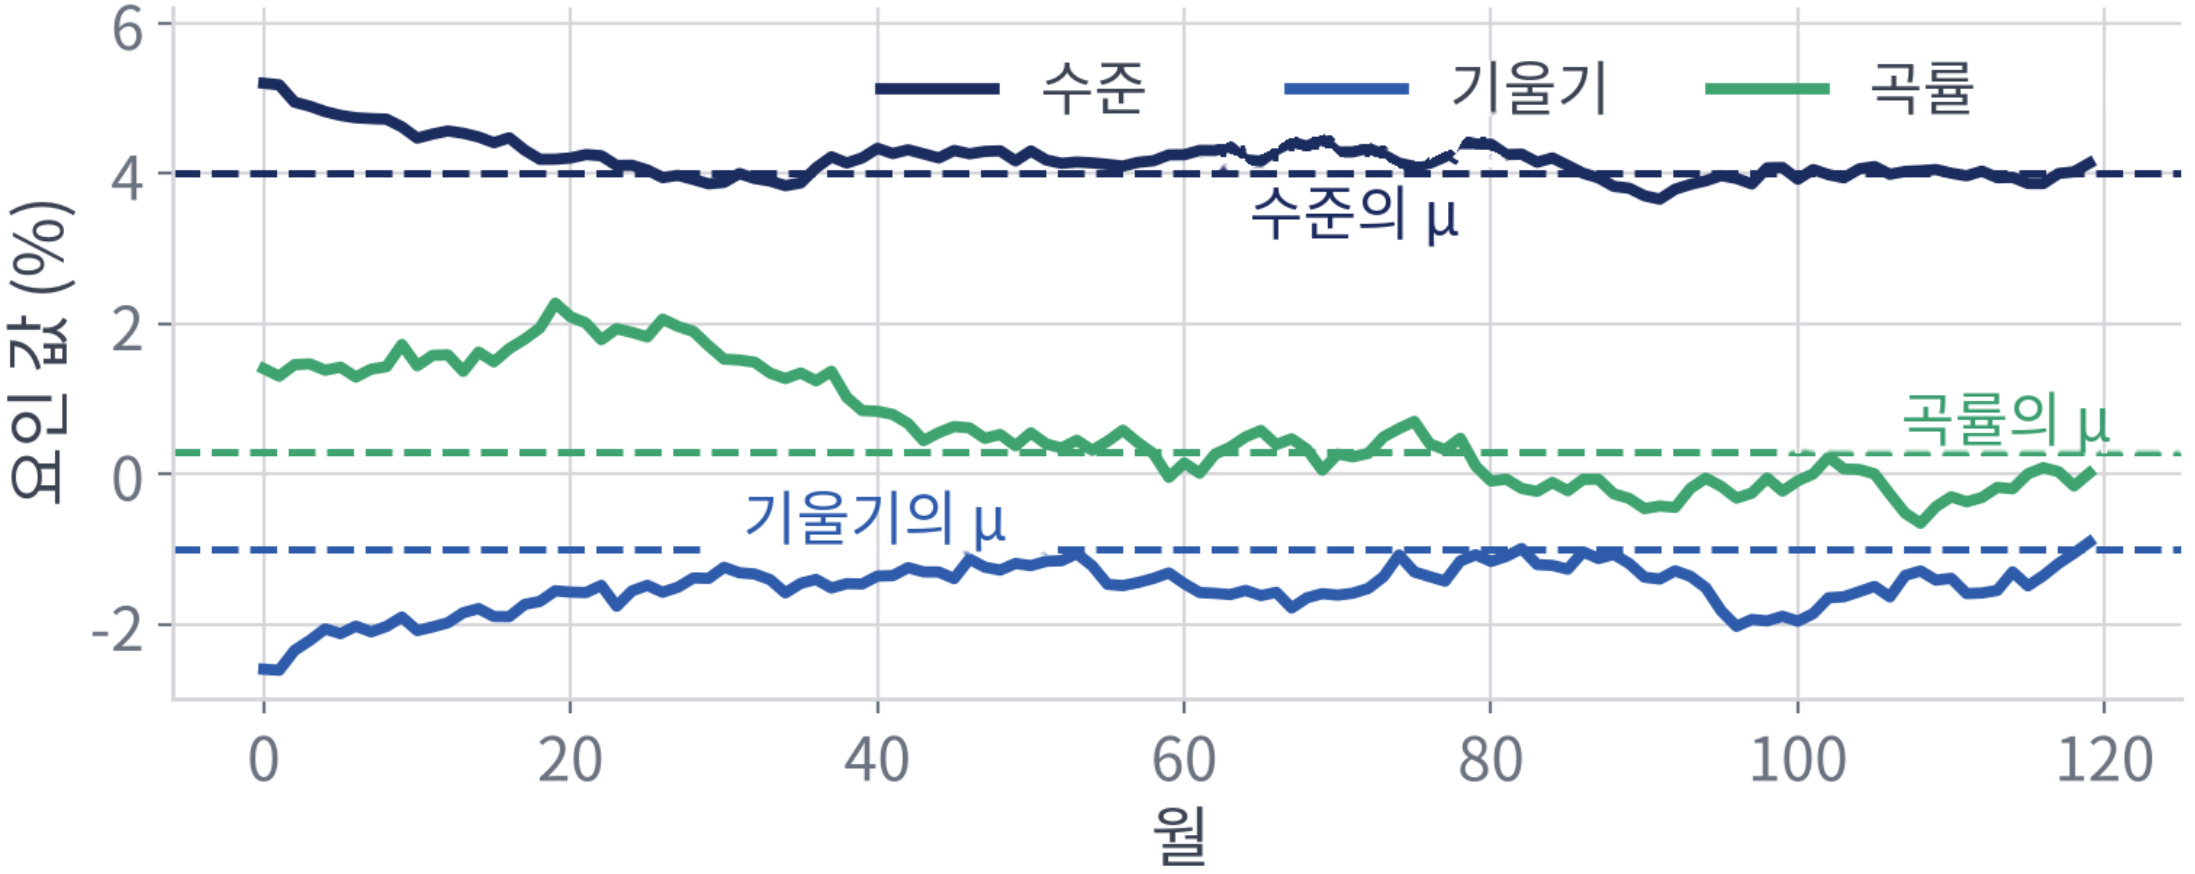
세 요인과 고정된 세 모양을 곱하면 수익률 곡선 전체가 복원된다

관측식을 그림으로: 적재량 λ(τ)가 H의 행이다



각 요인은 자기 μ를 갖고 그쪽으로 돌아간다

상태식을 그림으로: A = 0.97은 μ까지의 갭을 매달 3%씩 줄인다

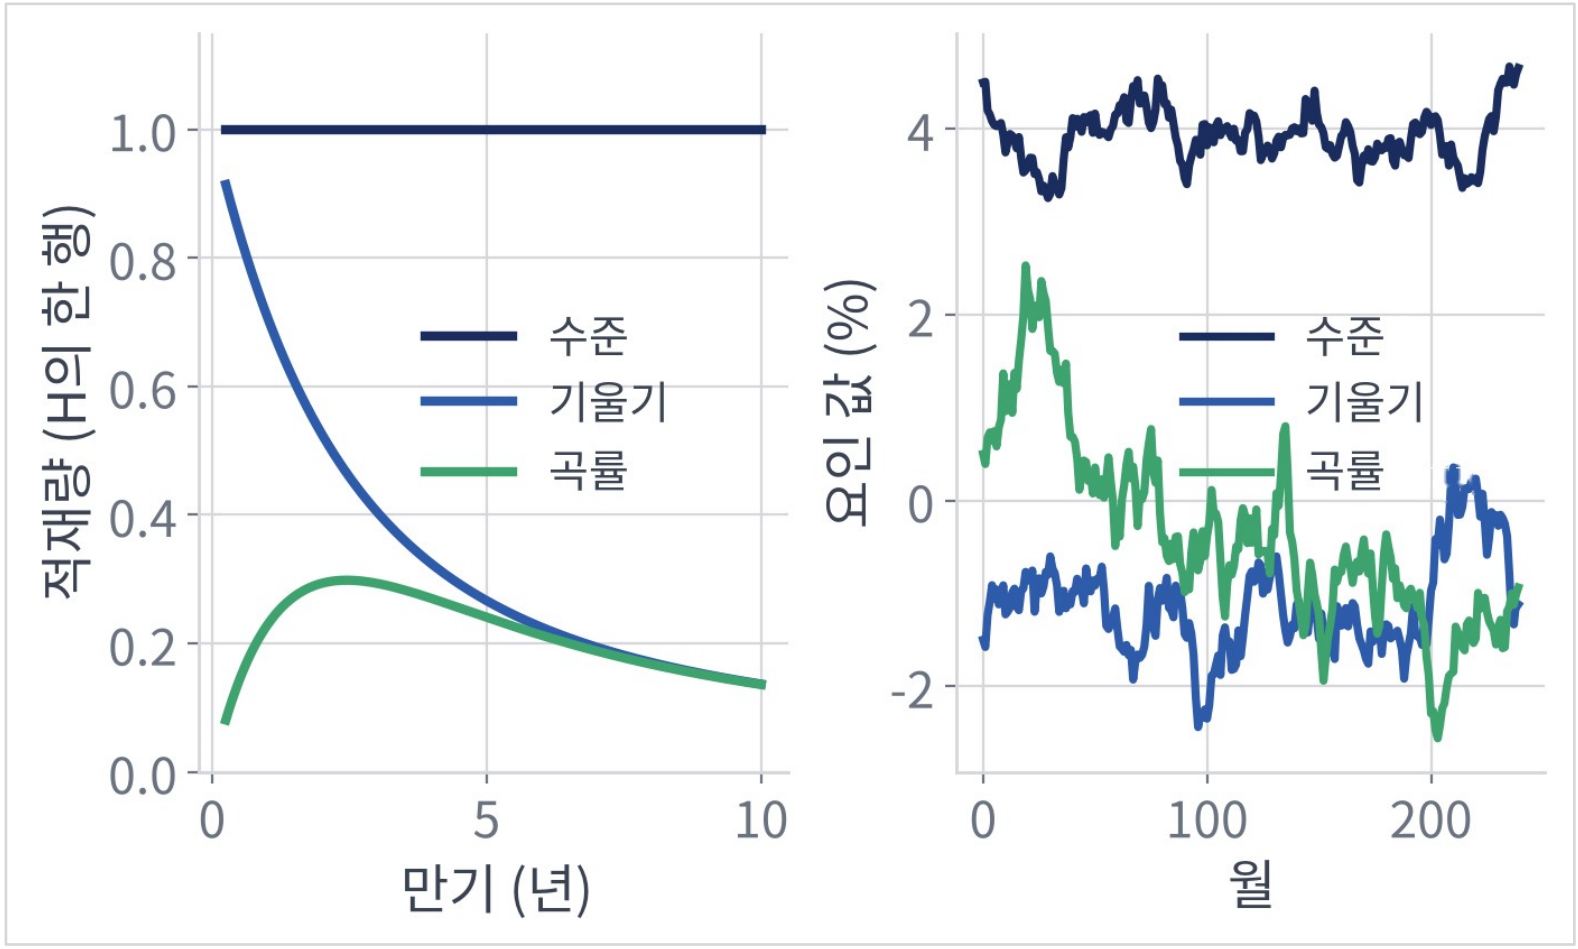


수익률 곡선 전체를 필터링한 세 요인으로 요약한다

동적 Nelson–Siegel 모형: 적재량이 H를, 요인이 상태 x를 이룬다

자리 채우기

- z = 모든 만기의 수익률
- x = 수준, 기울기, 곡률
- H = 적재량(왼쪽 패널)
- A: 요인은 천천히 움직인다



금융 밖에서도 같은 필터가 일상 기기에서 돌아간다

공학과 과학에서 쓰는 틀의 예

분야	은닉상태 x	관측값 z
항공기와 드론	자세, 위치	자이로, GPS
스마트폰	위치, 진행 방향	GPS, 가속도계, 나침반
영상 추적	상자 위치와 속도	프레임별 검출 상자
일기예보	대기 상태	위성, 관측소
웨어러블	심박수	잡음이 섞인 광학 센서

06

기초를 넘어서

그림으로 보는 확장

스무딩, Q와 R 학습, 비선형 모형

스무더는 나중 자료로 과거를 다시 판단하는 다시 보기다

기초 지식: 필터링은 '지금 어디인가?'를, 스무딩은 '그때 어디였나?'를 묻는다

필터 = 생중계 해설자: 각 순간을 벌어지는 대로 판단한다.
스무더 = 다시 보기 분석가: 경기가 끝난 뒤 각 순간을 다시 판단한다.

일상의 예

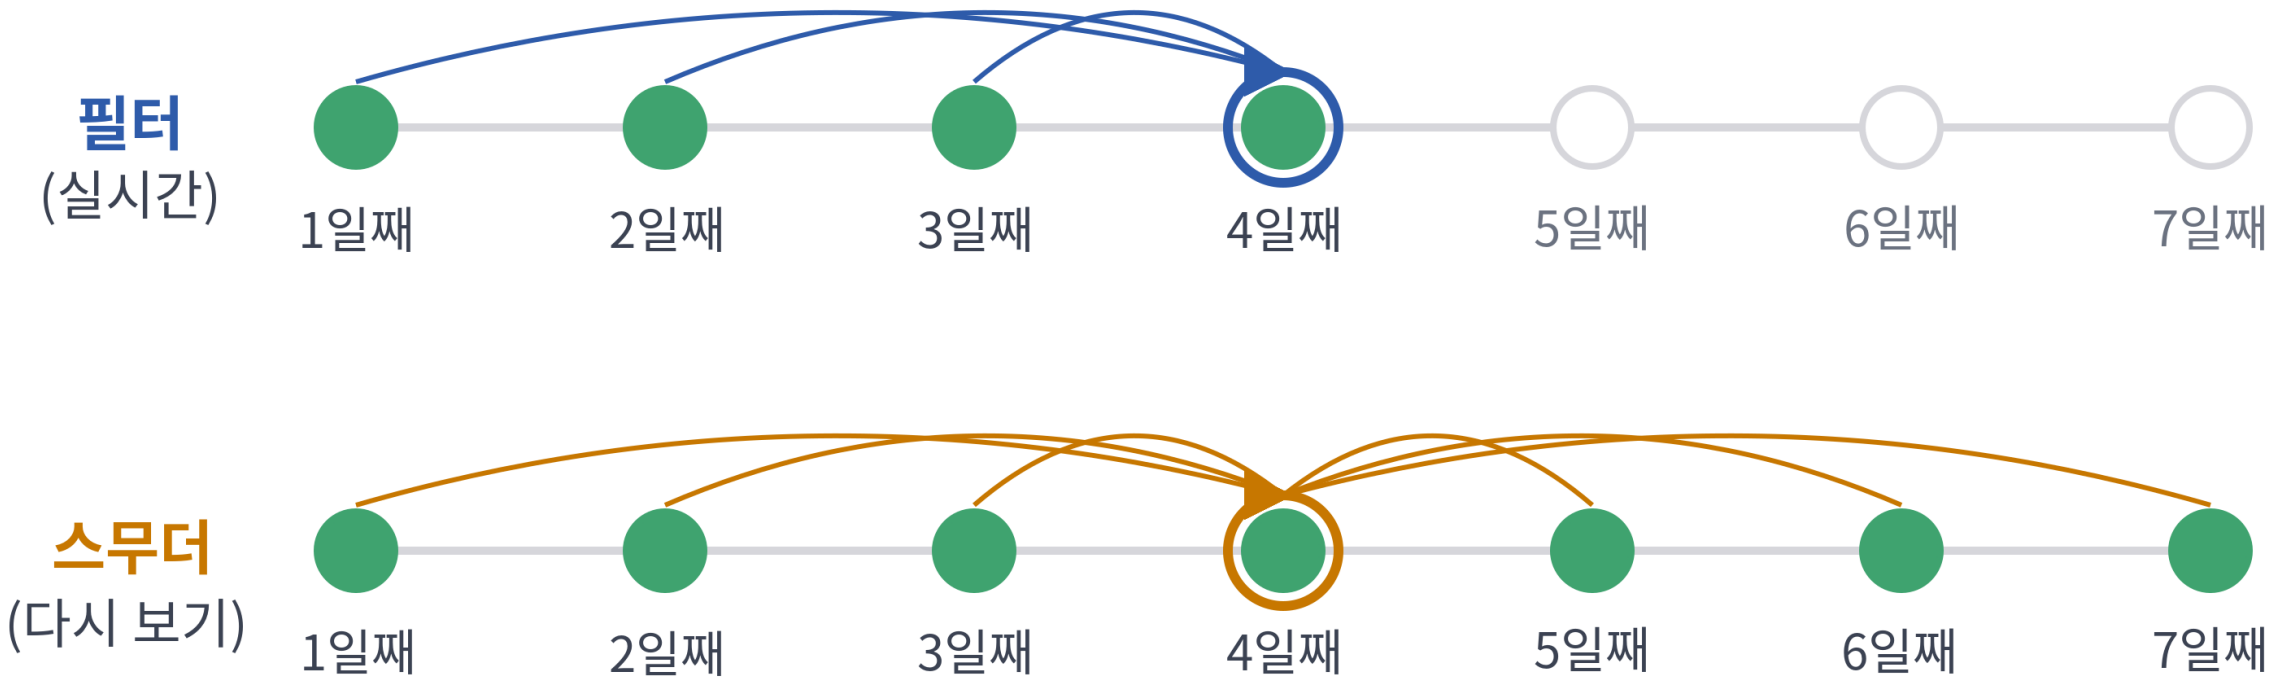
- 터널에서 휴대전화 GPS가 튄다
- 이동이 끝나면 경로를 다시 그린다
- 빠져나온 지점이 경로를 바로잡는다

더 정확한 이유

- 날마다 더 많은 자료를 쓴다
- 양쪽에서 단서가 온다
- 다만 사후에만 가능하다

필터는 뒤만 보고, 스무더는 앞뒤를 모두 본다

4일째를 추정할 때 각 방법이 쓸 수 있는 날



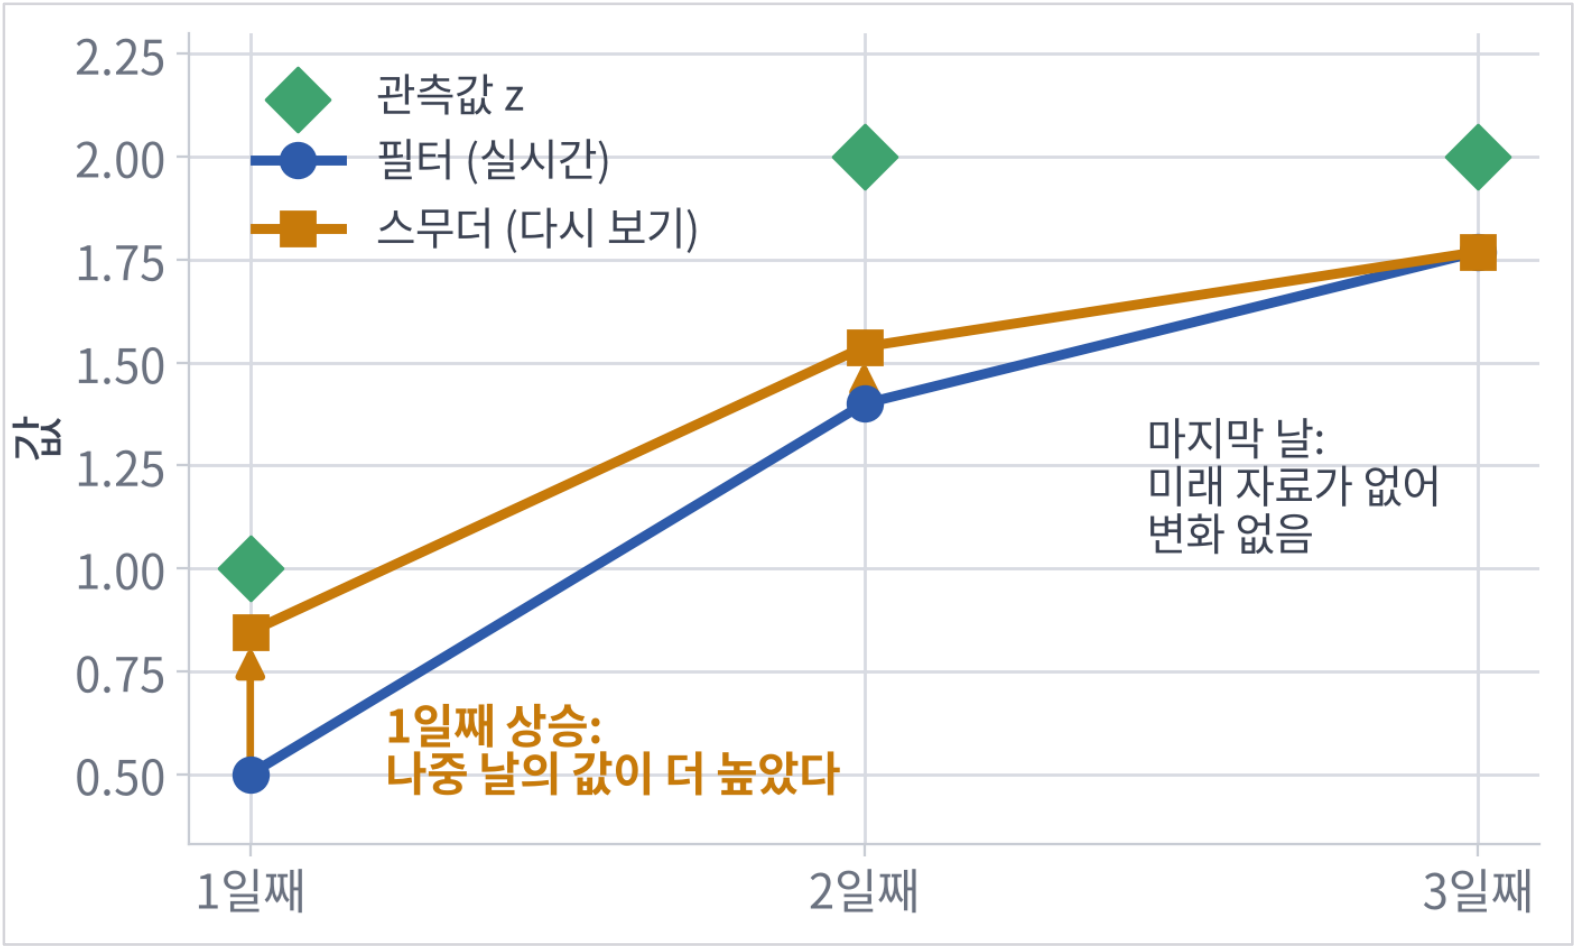
4일째 추정: 필터는 1~4일째를, 스무더는 모든 날을 쓸 수 있다

자료 세 개로도 스무더는 앞쪽 추정값을 나중 자료 쪽으로 끌어당긴다

자료 1, 2, 2와 Q = R = 1: 기댓값 최대화(Expectation–Maximization, EM) 계산 예제와 같은 수치

달라진 점

- 1일째: 0.50 → 0.85
- 2일째: 1.40 → 1.54
- 3일째: 변화 없음
- 나중 자료가 더 높았다



역방향 계산은 다음 날이 수정된 만큼 각 날을 보정한다

필터와 스무더가 일치하는 마지막 날에서 시작해 하루씩 거슬러 간다

$$\hat{x}_{k|T} = \underbrace{\hat{x}_{k|k}}_{\text{오늘의 필터 추정값}} + \underbrace{C_k}_{\text{가중치}} \left(\underbrace{\hat{x}_{k+1|T} - \hat{x}^{-}_{k+1}}_{\text{내일 값이 수정된 크기}} \right)$$

$$C_k = \frac{P_{k|k}\,A}{P^{-}_{k+1}} = \frac{\text{오늘의 불확실성 (필터)}}{\text{내일로 예측한 불확실성}} \times A$$

가중치 C

- 오늘이 불확실했으면 크다
- 오늘이 이미 확실했으면 작다

사용 규칙

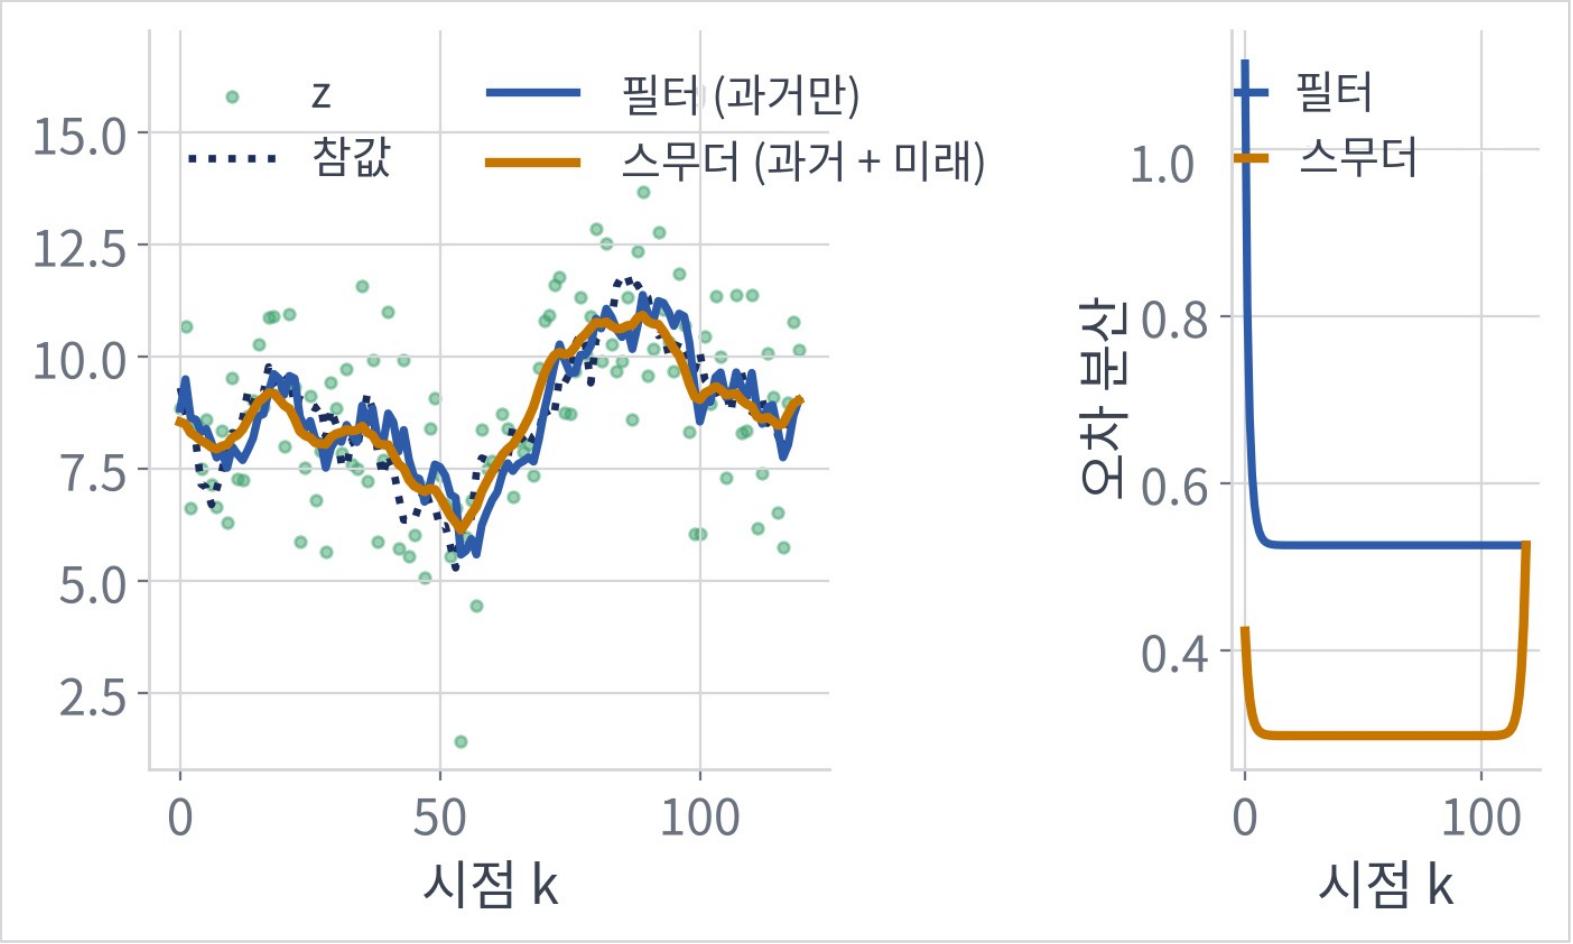
- 분석, 차트, EM에는 써도 된다
- 실시간 거래 신호로는 절대 쓰지 않는다

미래 자료까지 돌아보면 더 매끄러운 경로를 얻는다

칼만 스무더(Rauch–Tung–Striebel, RTS): 필터를 순방향으로 돌린 뒤 역방향으로 한 번 계산한다

주의해서 쓴다

- 필터: 과거 자료만
- 스무더: 과거와 미래
- 오차 분산이 더 낮다
- 백테스트 신호로는 절대 금지

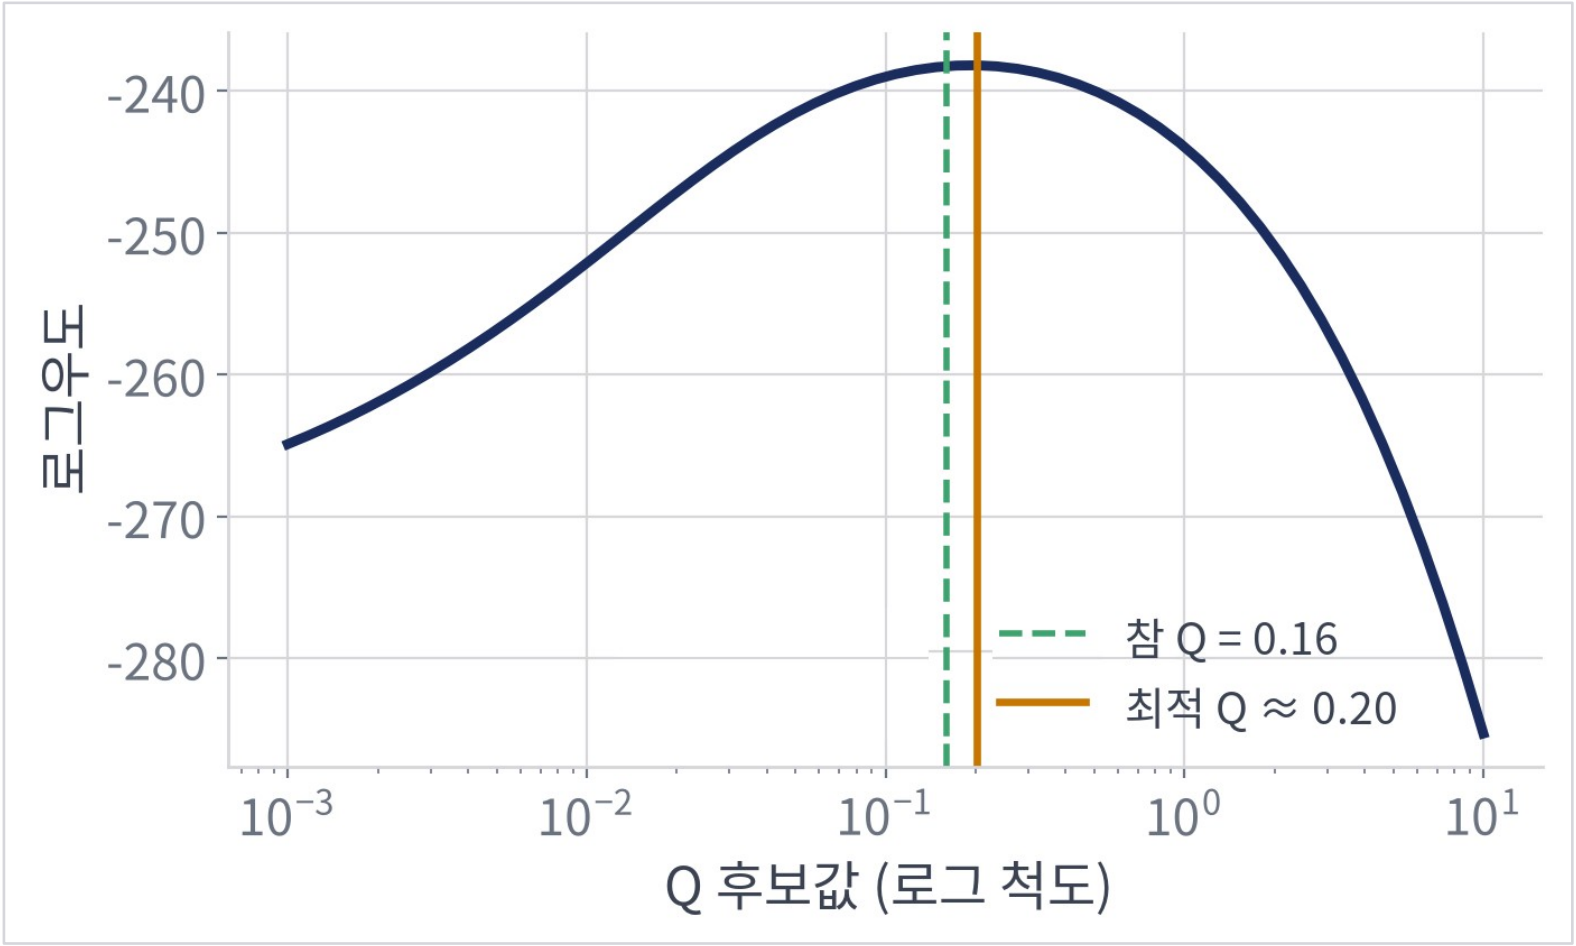


Q와 R은 혁신 자체에서 추정할 수 있다

최대우도: 예측오차가 예측된 크기에 가장 가까워지는 Q를 고른다

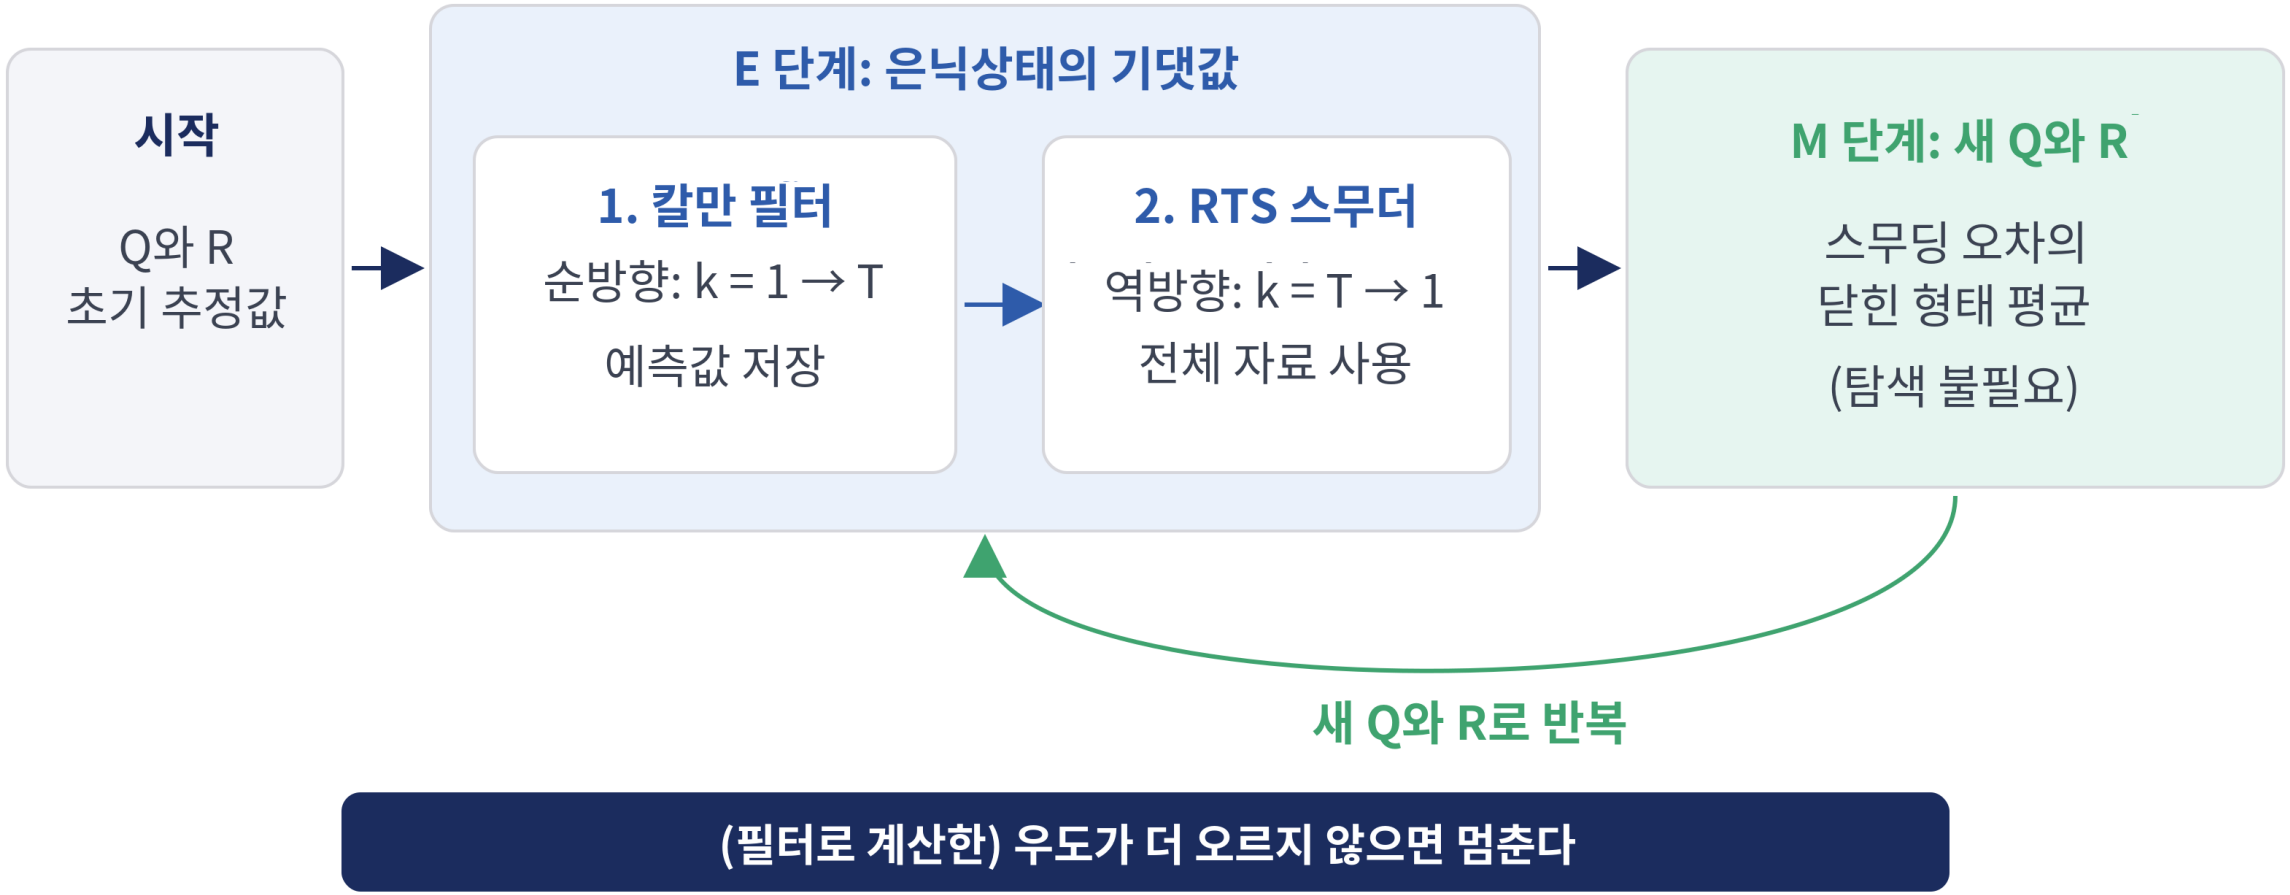
발상

- Q마다 혁신이 나온다
- 적합도를 점수로 매긴다
- 최고 점수를 고른다
- EM이 대안이다



EM의 E 단계는 필터만이 아니라 칼만 스무더다

기댓값 최대화(Shumway–Stoffer, 1982): 필터는 순방향, 스무더는 역방향으로 돈다



M 단계는 스무딩 추정값을 닫힌 형태로 새 Q와 R로 바꾼다

스칼라 국소 수준 모형(A = H = 1). 아래첨자 k|T는 '자료 T개 전체가 주어졌을 때'를 뜻한다

$$\hat{R} = \frac{1}{T}\sum_{k=1}^{T}\left[\underbrace{(z_k - \hat{x}_{k|T})^2}_{\text{적합 오차}} + \underbrace{P_{k|T}}_{\text{남은 상태 불확실성}}\right]$$

$$\hat{Q} = \frac{1}{T-1}\sum_{k=2}^{T}\left[\underbrace{(\hat{x}_{k|T} - \hat{x}_{k-1|T})^2}_{\text{스무딩 변화량}} + P_{k|T} + P_{k-1|T} - 2P_{k,k-1|T}\right]$$

왜 스무더인가

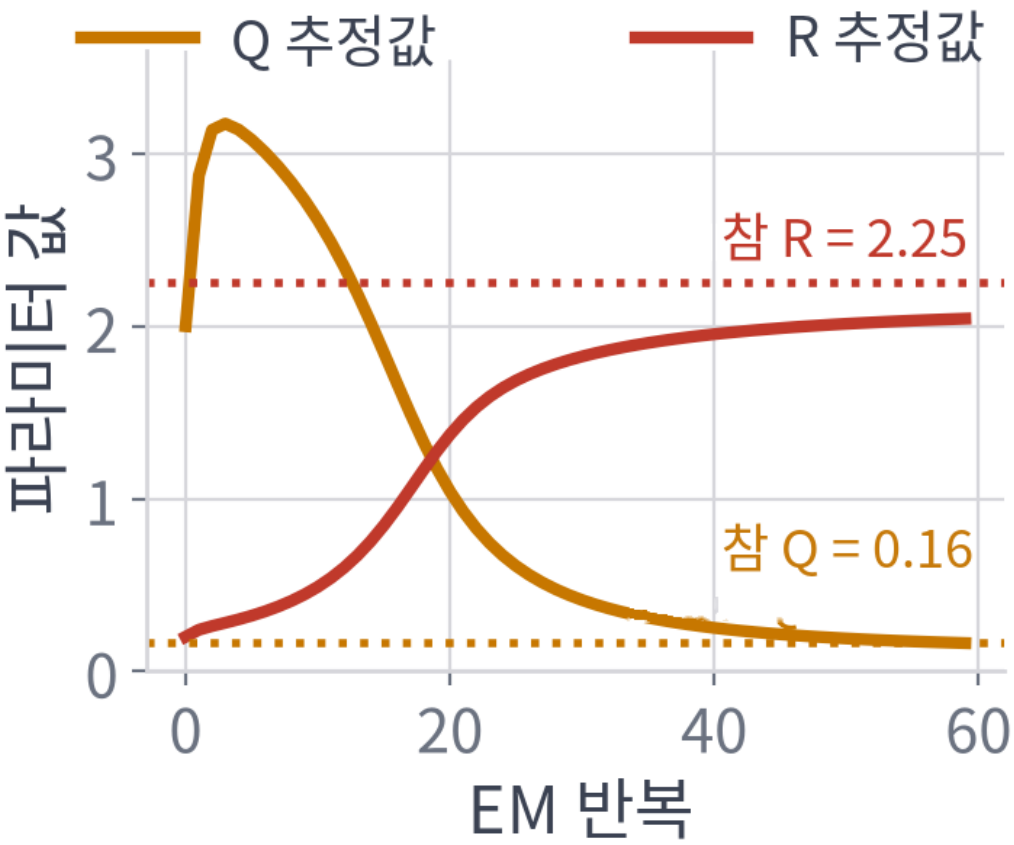
- 전체 자료가 주어진 상태가 필요하다
- 필터는 과거만 본다

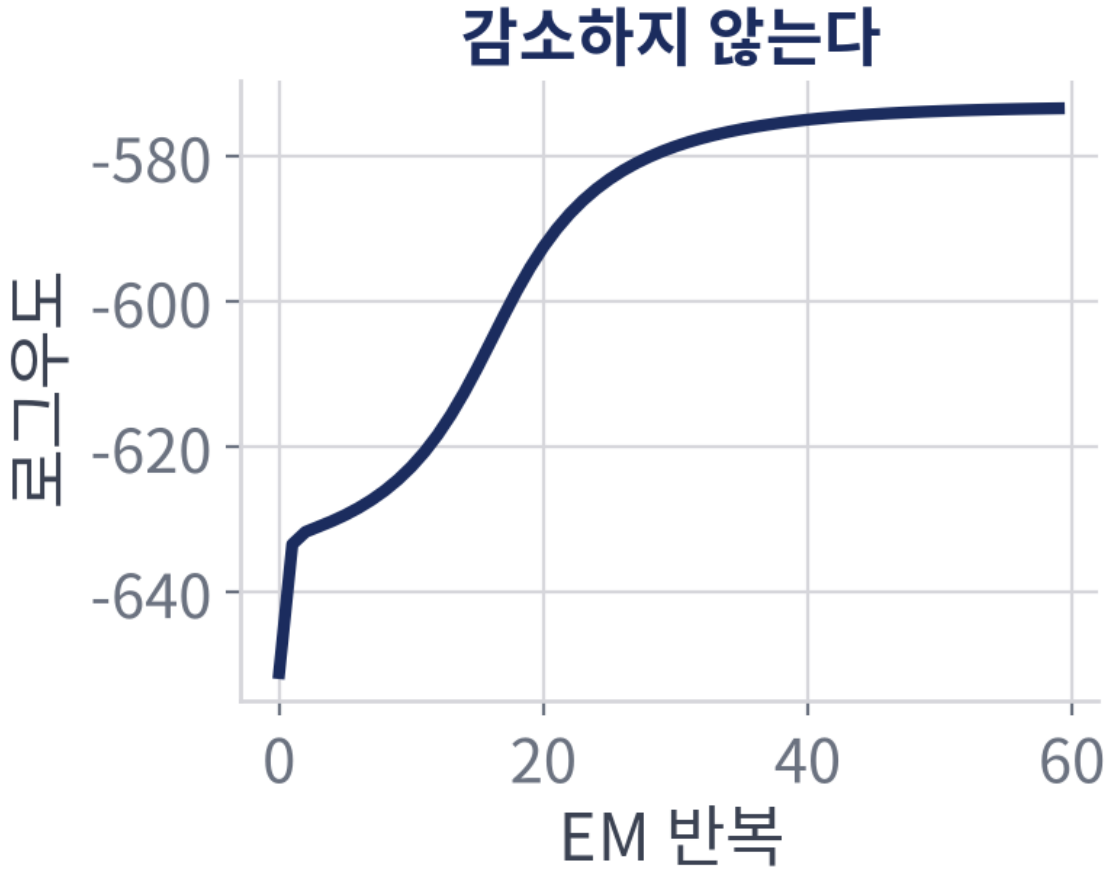
P를 빼지 않는다

- P 항: 상태가 불확실하다는 뜻
- 빠지면 R이 너무 작아진다

EM은 나쁜 초기값에서 출발해 Q와 R을 참값으로 옮겨 간다

모의 자료, 참값 Q = 0.16, R = 2.25, 시작값 Q = 2.0, R = 0.2

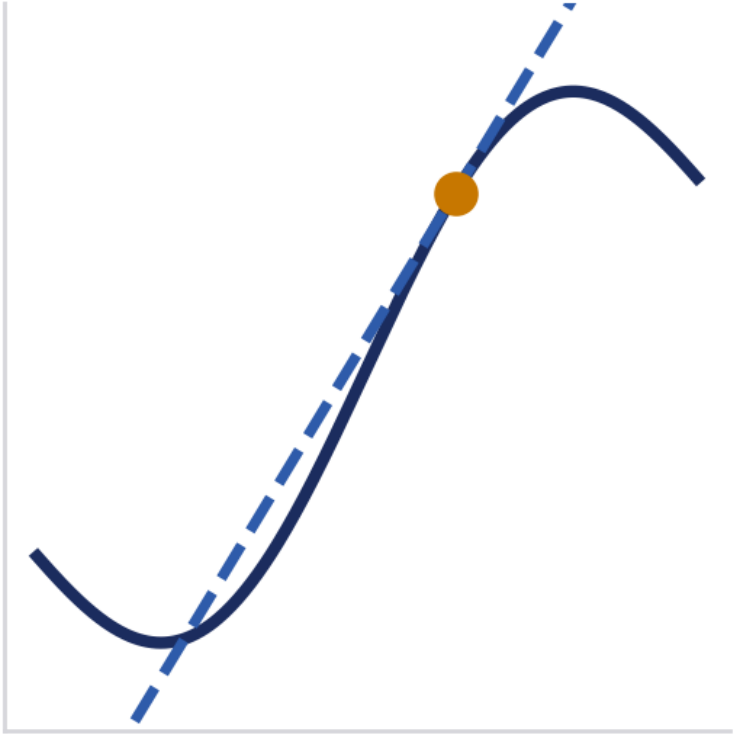




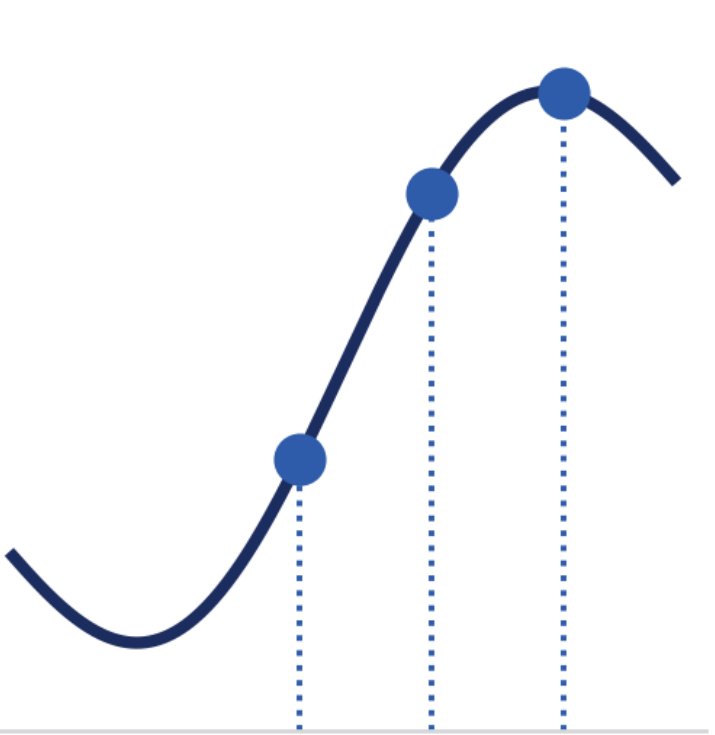
모형이 곡선이면 세 필터가 서로 다르게 근사한다

확장 칼만 필터(Extended KF, EKF), 무향 칼만 필터(Unscented KF, UKF), 입자 필터: 예측·갱신 반복은 같다

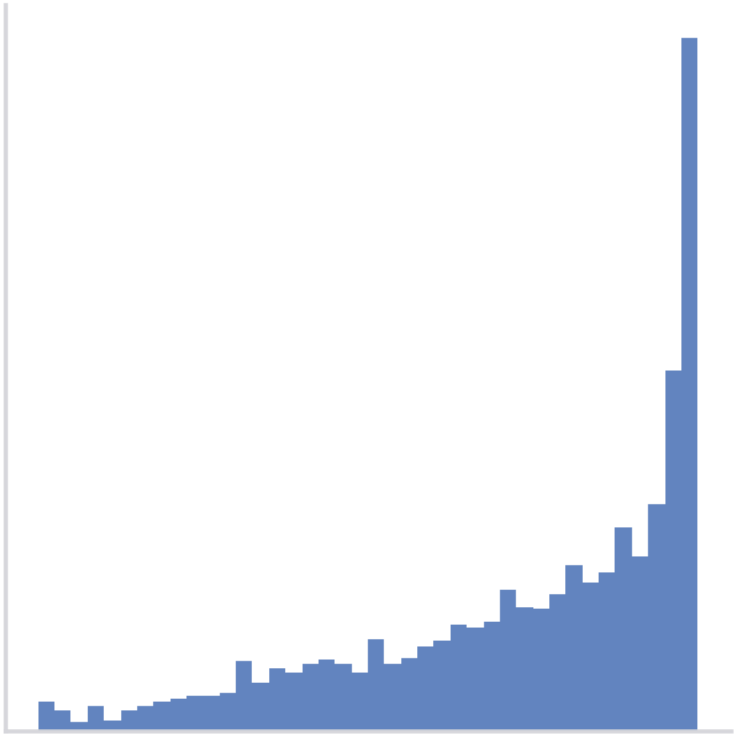
EKF: 곡선을 접선으로 대체한다



UKF: 고른 몇 개의 시그마 포인트를 통과시킨다



입자 필터: 많은 무작위 표본을 통과시킨다



문제의 형태에 따라 쓸 필터가 정해진다

기본 필터에서 시작하고, 뚜렷하게 실패할 때만 표의 아래쪽으로 옮긴다

상황	필터	예
선형 모형, 정규 잡음	칼만 필터	헤지 비율, 추세
약한 곡선 모형	EKF	금리 모형
강한 곡선 모형	UKF	옵션 내재 상태
두꺼운 꼬리나 점프	입자 필터	확률적 변동성
국면 전환	국면 전환 필터	평시 대 위기

함정

여섯 가지 실수가 칼만 결과가 나빠지는 주된 원인이다

결과를 믿기 전에 확인한다

**실패의 원인은 잘못된 모형이나 결과의 잘못된 사용이며,
다섯 식 자체가 원인인 경우는 거의 없다.**

모형 실수

- Q가 너무 작음: 구조 변화에 뒤처진다
- Q가 너무 큼: 잡음을 쫓아간다
- H가 틀림: 추정값이 표류한다

사용 실수

- 백테스트에 스무더 값 사용
- 첫 몇 단계를 신뢰
- 오차 구간 P 무시

요약

칼만 필터는 하나의 틀을 여러 방식으로 채운 것이다

기억할 내용

1

고르지 말고 결합한다

추정값은 예측과 관측값의 가중평균이고, 이득 K가 가중치다.

2

식 두 개, 단계 두 개

상태식과 관측식, 예측과 갱신을 새 자료가 들어올 때마다 반복한다.

3

응용은 자리 채우기다

x, A, z, H, Q, R을 정한다. 추적, 헤지 비율, 베타, 나우캐스팅, 수익률 곡선이 모두 같은 방식이다.

오차 구간 P를 항상 보고한다. 필터는 자기 불확실성을 계산해 준다.

토론 질문

이 덱의 개념으로 답한다. 계산은 필요 없다

Q1	GPS 장치의 잡음이 두 배가 되었다. Q와 R 중 무엇이 바뀌고, 이득은 오르는가 내리는가?	**이득**
Q2	칼만 헤지 비율이 날마다 크게 움직인다. 무엇을 먼저 바꾸고, 그 대가로 무엇을 포기하는가?	**조정**
Q3	스무딩한 β를 쓴 백테스트 결과가 매우 좋다. 왜 믿으면 안 되는가?	**스무딩**
Q4	월간 지표가 석 달 동안 빠졌다. 필터는 무엇을 하고, P는 어떻게 움직이는가?	**결측 자료**

A

부록

손으로 푸는 네 가지 계산

필터 두 단계, 두 센서 갱신, M 단계를 한 줄씩 계산한다

손 계산

1단계는 추정값을 10에서 12.4로 옮긴다

직전 추정값 10, P = 3, A = 1, Q = 1, R = 1, 관측값 z = 13

예측 : $\hat{x}^{-} = 1 \times 10 = 10, \qquad P^{-} = 1 \times 3 \times 1 + 1 = 4$

이득 : $K = \dfrac{4}{4 + 1} = 0.8$

갱신 : $\hat{x} = 10 + 0.8\,(13 - 10) = 12.4, \qquad P = (1 - 0.8) \times 4 = 0.8$

확인

- 종 모양 곡선 장과 일치한다
- P가 4에서 0.8로 줄어든다

의미

- K = 0.8: GPS를 더 신뢰
- 예측오차의 80%를 반영

손 계산

필터가 더 확실해져 2단계의 이득은 더 작다

같은 모형, 다음 관측값 z = 12

$$\text{예측}: \quad \hat{x}^{-} = 12.4, \qquad P^{-} = 0.8 + 1 = 1.8$$

$$\text{이득}: \quad K = \frac{1.8}{1.8 + 1} \approx 0.64$$

$$\text{갱신}: \quad \hat{x} = 12.4 + 0.64\,(12 - 12.4) \approx 12.14, \qquad P \approx 0.64$$

확인

- K가 0.8에서 0.64로 줄어든다
- P가 약 0.64로 줄어든다

규칙성

- K는 단계마다 정상값으로 다가간다
- 파이썬 장의 이득 차트와 같다

손 계산

두 센서 동시 사용: 벡터 이득이 신뢰를 나눈다

센서 융합 예제: 예측 100, P = 4, GPS 관측값 96, 휠 센서 관측값 102

$$\text{설정}: \quad \hat{x}^- = 100,\ P^- = 4,\ R_1 = 9,\ R_2 = 2.25,\ z_1 = 96,\ z_2 = 102$$

$$\text{이득}: \quad D = 4 \times 11.25 + 9 \times 2.25 = 65.25, \qquad K_1 = \frac{4 \times 2.25}{65.25} \approx 0.14, \qquad K_2 = \frac{4 \times 9}{65.25} \approx 0.55$$

$$\text{갱신}: \quad \hat{x} = 100 + 0.14\,(-4) + 0.55\,(+2) \approx 100.55, \qquad P = (1 - 0.69) \times 4 \approx 1.24$$

확인

- 잡음이 큰 GPS: $K_1 \approx 0.14$
- 휠 센서: $K_2 \approx 0.55$

의미

- P가 4에서 1.24로 줄어든다
- 어느 센서 하나만 쓸 때보다 낮다

손 계산

R의 M 단계 한 번은 스무딩 상태와 그 분산을 쓴다

자료 1, 2, 2와 Q = R = 1. E 단계(필터 + 스무더)의 결과가 첫 줄이다

E 단계 : $\hat{x}_{k|T} = (0.846,\ 1.538,\ 1.769), \qquad P_{k|T} = (0.385,\ 0.462,\ 0.615)$

M 단계 : $$\hat{R} = \tfrac{1}{3}\Big[(0.154^2 + 0.385) + (0.462^2 + 0.462) + (0.231^2 + 0.615)\Big]$$
$$= \tfrac{1}{3}\Big[0.409 + 0.675 + 0.668\Big] \approx 0.58$$

확인

- 적합 오차만 쓰면 0.10
- P를 더하면 0.58로 올라간다

다음

- 새 R로 E 단계를 다시 실행
- 우도가 평평해질 때까지 반복