강의 · HMM의 원리

은닉 마르코프 모형(Hidden Markov Model, HMM)

평가·디코딩·학습의 원리

마르코프 모형 → HMM 파라미터 → Forward/Backward 알고리즘 → Viterbi 알고리즘 → Baum-Welch 알고리즘

그림은 원래 강의 슬라이드를 바탕으로 하며, 오타를 바로잡았다.
예제는 하나를 끝까지 쓴다. 정 박사의 일상 활동과 숨겨진 날씨다.

HMM은 보이는 시퀀스로 숨겨진 시퀀스를 읽어낸다

이 강의는 세 가지 개념으로 이어진다

1

은닉상태는 마르코프 체인을 따른다

날씨(비/해)는 상태 전이 확률 행렬(전이행렬) A에 따라 날마다 바뀌며, 직접 관측되지 않는다.

2

은닉상태마다 관측값을 방출한다

정 박사의 활동(산책/쇼핑/연구)은 그날 날씨에 해당하는 방출 확률 행렬 B에서 뽑힌다.

3

세 가지 문제, 세 가지 동적 계획법(dynamic programming)

평가 → Forward/Backward 알고리즘, 디코딩(decoding) → Viterbi 알고리즘, 학습 → Baum-Welch 알고리즘(기댓값 최대화, Expectation-Maximization, EM).

λ = {A, B, π}가 모형을 완전히 규정하며, 나머지는 모두 이 값으로 계산하는 일이다.

순차 데이터는 값의 순서가 의미를 갖는다

배경: 인덱스가 피처 i에서 시간 t로 바뀐다

정의

- 일반 데이터: x1...xd는 피처
- 순차 데이터: 시간으로 인덱스한 x1...xT
- 값의 순서가 곧 정보다

$$\mathbf{X} = (x_1, \ldots x_i, x_{i+1}, \ldots x_d)$$

$$\mathbf{X} = (x_1, \ldots x_t, x_{t+1}, \ldots x_T)$$

→ Sequential Data (순차 데이터)

제조 공정의 설비 경로는 이산 시퀀스를 이룬다

각 행: 공정 1~10에서 쓴 설비와 정상/불량 구분

표 읽는 법

- 행 = 제품
- 열 = 시간순 공정 단계
- 칸 = 설비 ID
- 마지막 열 = 품질 구분

Equipment sequential data in manufacturing processes

Time

	공정1	공정2	공정3	공정4	공정5	공정6	공정7	공정8	공정9	공정10	Class
1	설비1	설비2	설비1	설비1	설비2	설비1	설비4	설비2	설비2	설비1	정상
2	설비2	설비4	설비2	설비2	설비4	설비2	설비4	설비2	설비4	설비2	정상
3	설비1	설비3	설비1	설비1	설비3	설비1	설비3	설비1	설비3	설비1	정상
…	…	…	…	…	…	…	…	…	…	…	…
2998	설비3	설비3	설비3	설비3	설비3	설비3	설비3	설비3	설비3	설비3	불량
2999	설비4	설비1	설비2	설비4	설비6	설비5	설비5	설비1	설비2	설비3	불량
3000	설비5	설비5	설비1	설비3	설비1	설비5	설비1	설비3	설비1	설비1	불량

HMM은 시퀀스를 만들어 내는 확률적 생성 모형이다

은닉(Hidden): 숨겨져 관측되지 않음 + 마르코프 모형(Markov model)

세 단어

- 은닉: 상태가 관측되지 않는다
- 마르코프: 다음 상태가 현재 상태에 의존한다
- 모형: 확률로 시퀀스를 생성한다



01

1부 · 마르코프 모형

마르코프 모형

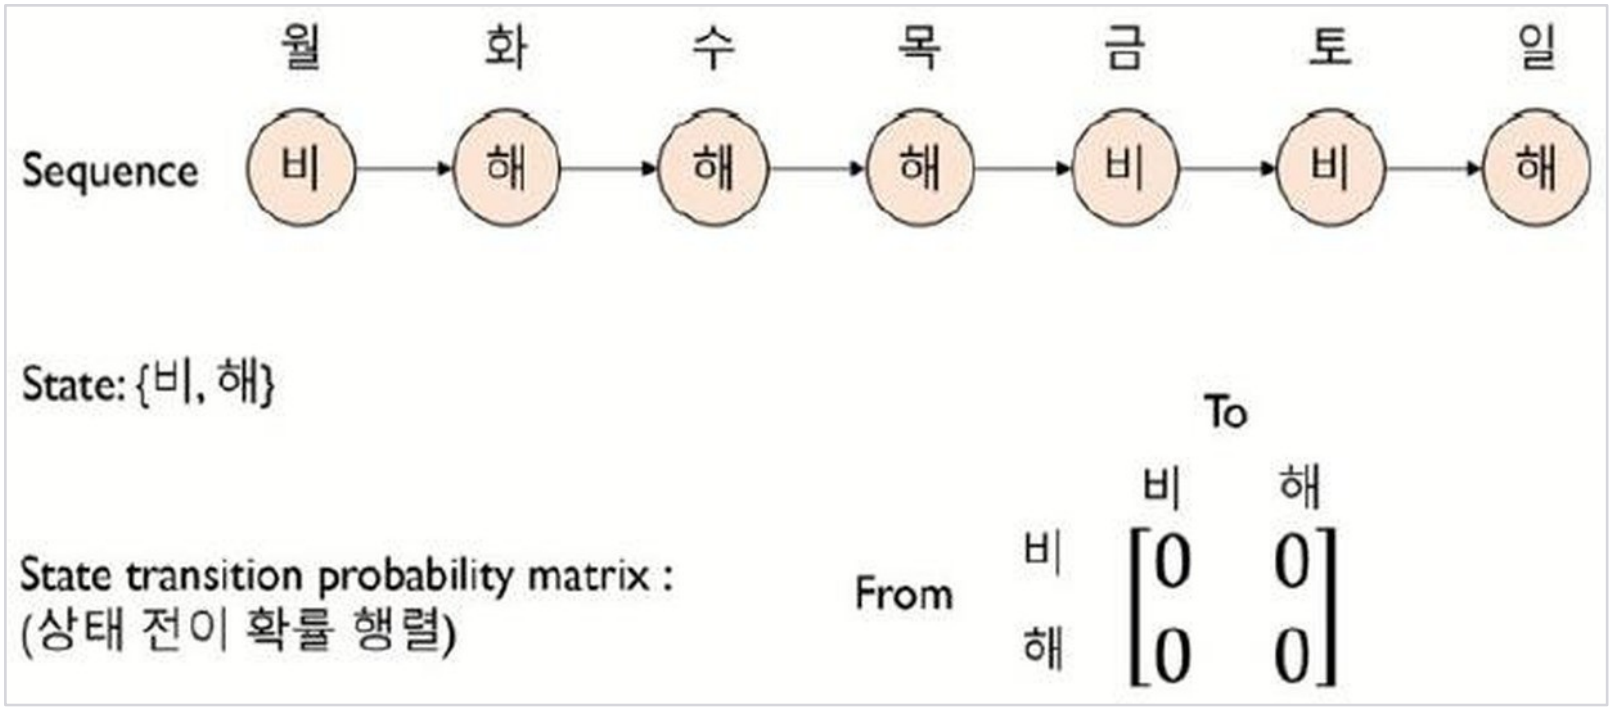
상태, 전이, 마르코프 가정

마르코프 모형은 시퀀스를 전이 확률로 요약한다

예: 한 주의 날씨(비, 해)

설정

- 상태: {비, 해}
- 시퀀스: 월 → 일
- 목표: 2×2 행렬 채우기
- 행 = 출발(From), 열 = 도착(To)

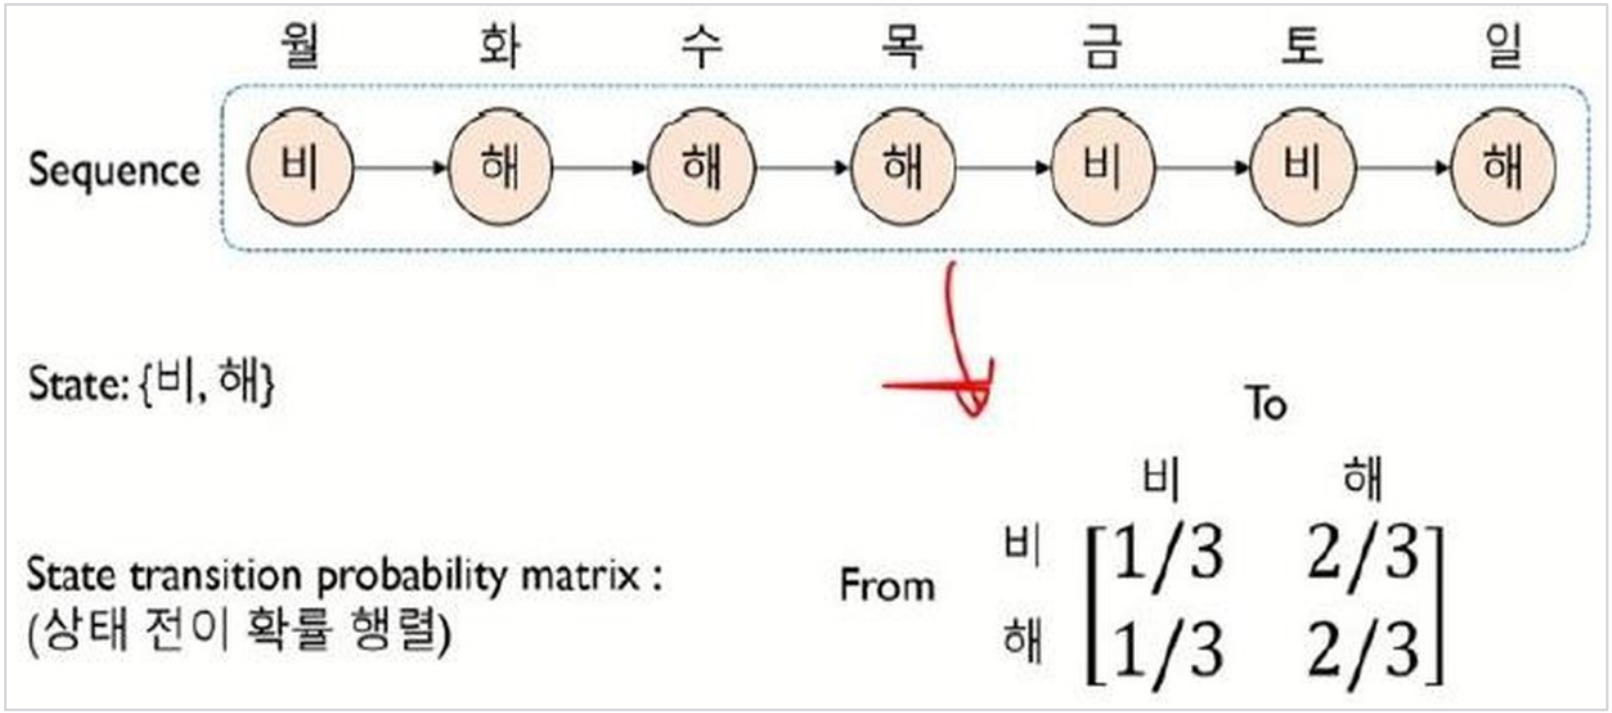


전이 확률은 이동 횟수를 세어 추정한다

비→비는 3회 이동 중 1회, 해→해는 3회 이동 중 2회

세는 법

- 비에서 출발: 3회
- → 비 1회, → 해 2회
- 해에서 출발: 3회
- → 비 1회, → 해 2회
- 각 행의 합은 1이다



마르코프 가정은 긴 과거 이력에 대한 의존을 끊는다

r차 모형: 시점 t의 상태는 직전 r개 상태에만 의존한다

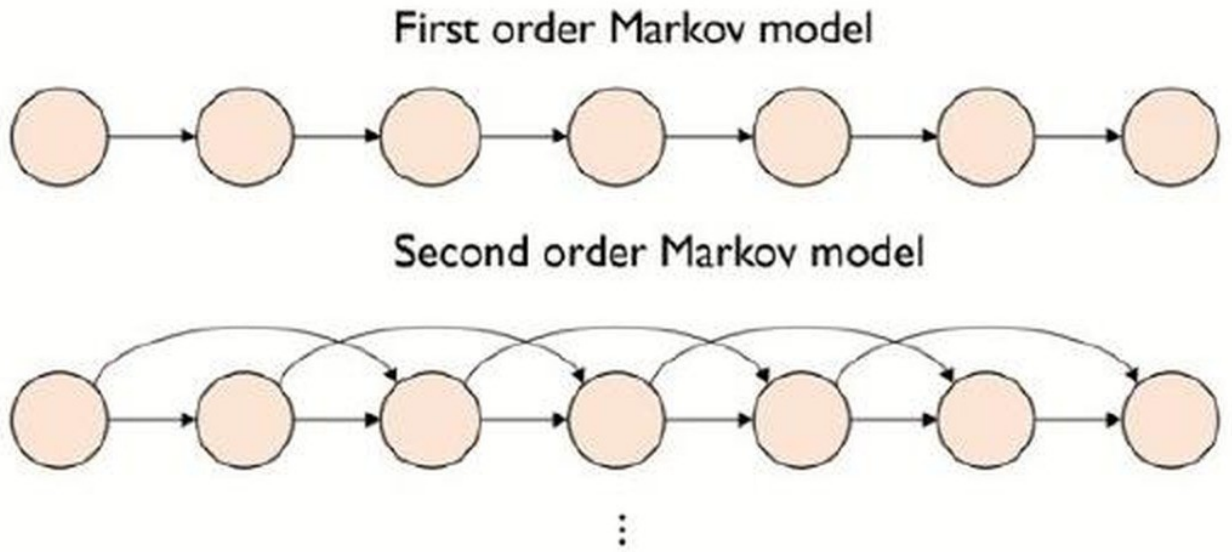
마르코프 가정

- 1차: 직전 상태만
- 2차: 직전 두 상태
- 차수가 높을수록 화살표가 늘어난다

❖ Markov 가정: 시간 t에서 관측은 가장 최근 r 개의 관측에만 의존한다는 가정

❖ 한 상태에서 다른 상태로의 전이는 이전 상태의 긴 이력을 필요치 않다는 가정

- ❖ If r=1, $p(s_t|s_{t-1}s_{t-2}\cdots s_1) = p(s_t|s_{t-1})$
- ❖ If r=2, $p(s_t|s_{t-1}s_{t-2}\cdots s_1) = p(s_t|s_{t-1}, s_{t-2})$
- ❖ …



1차와 2차 마르코프 모형의 차이는 기억 길이뿐이다

원본 슬라이드의 수식

$$p(s_t \mid s_{t-1}s_{t-2}\cdots s_1) = p(s_t \mid s_{t-1}) \quad (r=1)$$

$$p(s_t \mid s_{t-1}s_{t-2}\cdots s_1) = p(s_t \mid s_{t-1}, s_{t-2}) \quad (r=2)$$

왜 중요한가

- 1차 모형에는 n×n 전이행렬 하나만 있으면 된다
- 이 강의를 포함해 대부분의 HMM이 1차 가정을 쓴다

행렬 형식과 그래프 형식은 같은 마르코프 모형을 나타낸다

원소 a_ij = 상태 i에서 상태 j로 이동할 확률

두 가지 표현

- 행렬: 행은 t−1, 열은 t
- 그래프: 화살표 가중치가 a_ij
- 자기 순환(self-loop) = a_ii

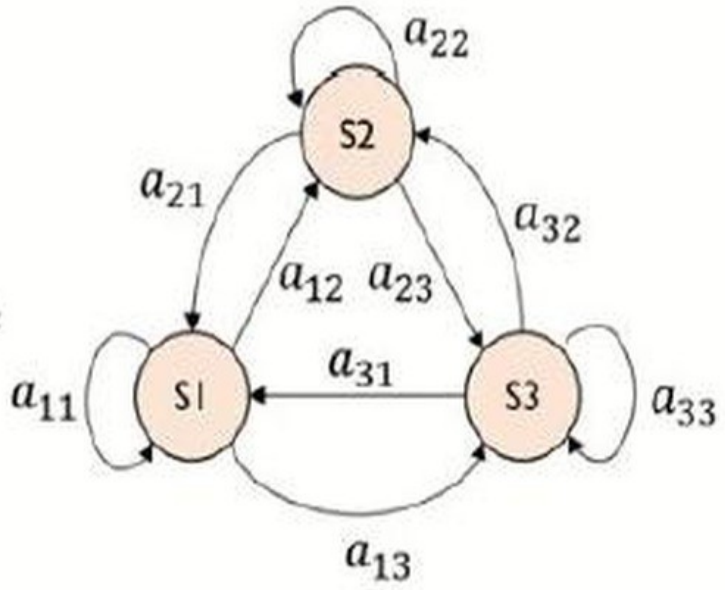
❖ 상태 전이 확률 행렬 $A(a_{ij})$

Matrix Form

$$\begin{array}{c} \\ T-1 \end{array} \begin{array}{c} \begin{array}{ccc} S1 & S2 & S3 \end{array} \\ \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \end{array} \begin{array}{l} T \\ \\ \begin{array}{l} S1 \\ S2 \\ S3 \end{array} \end{array}$$

Graph Form

=



02

2부 · HMM의 개념

은닉 마르코프 모형

시간으로 연결된 두 시퀀스

HMM은 같은 시간에 발생하는 두 시퀀스를 모형화한다

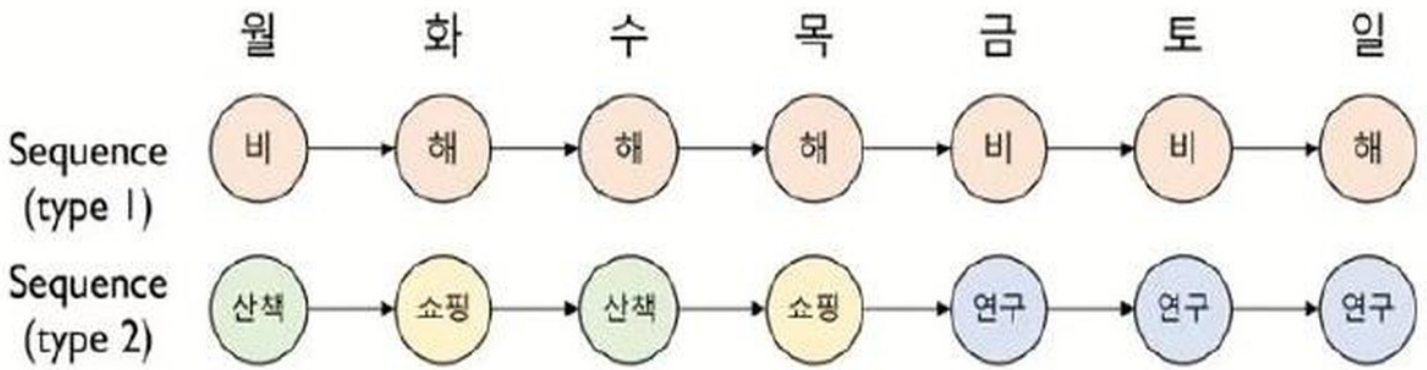
유형 1: 날씨(비/해) · 유형 2: 활동(산책, 쇼핑, 연구)

두 시퀀스

- 유형 1: 상태 s1...sT
- 유형 2: 관측값 o1...oT
- 각각의 특성과 둘의 관계를 모형화

❖ Hidden Markov model 이란?

- Type 1 state sequence: $(s_1, s_2, s_3, \ldots, s_{T-1}, s_T)$
- Type 2 state sequence: $(o_1, o_2, o_3, \ldots, o_{T-1}, o_T)$



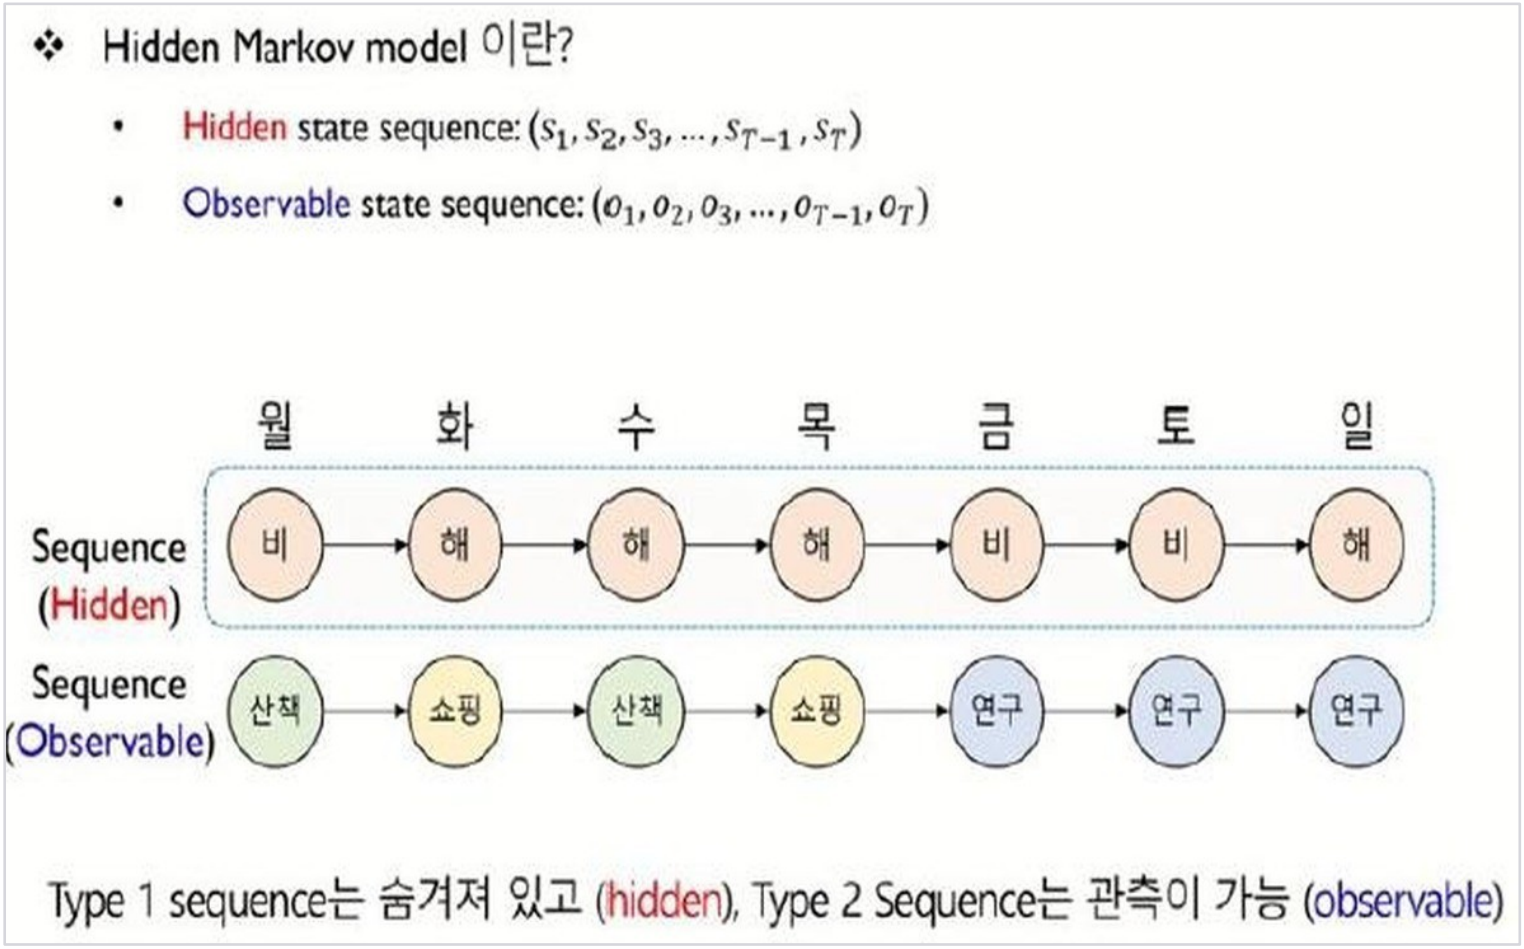
같은 시간에 발생한 두 종류의 state sequence 각각의 특성과 그들의 관계를 이용해 모델링

날씨는 숨겨져 있고 활동은 관측된다

정 박사가 무엇을 했는지는 보이지만 날씨는 보이지 않는다

은닉과 관측

- 은닉: 날씨 시퀀스
- 관측: 활동 시퀀스
- 추론은 아래에서 위로 진행

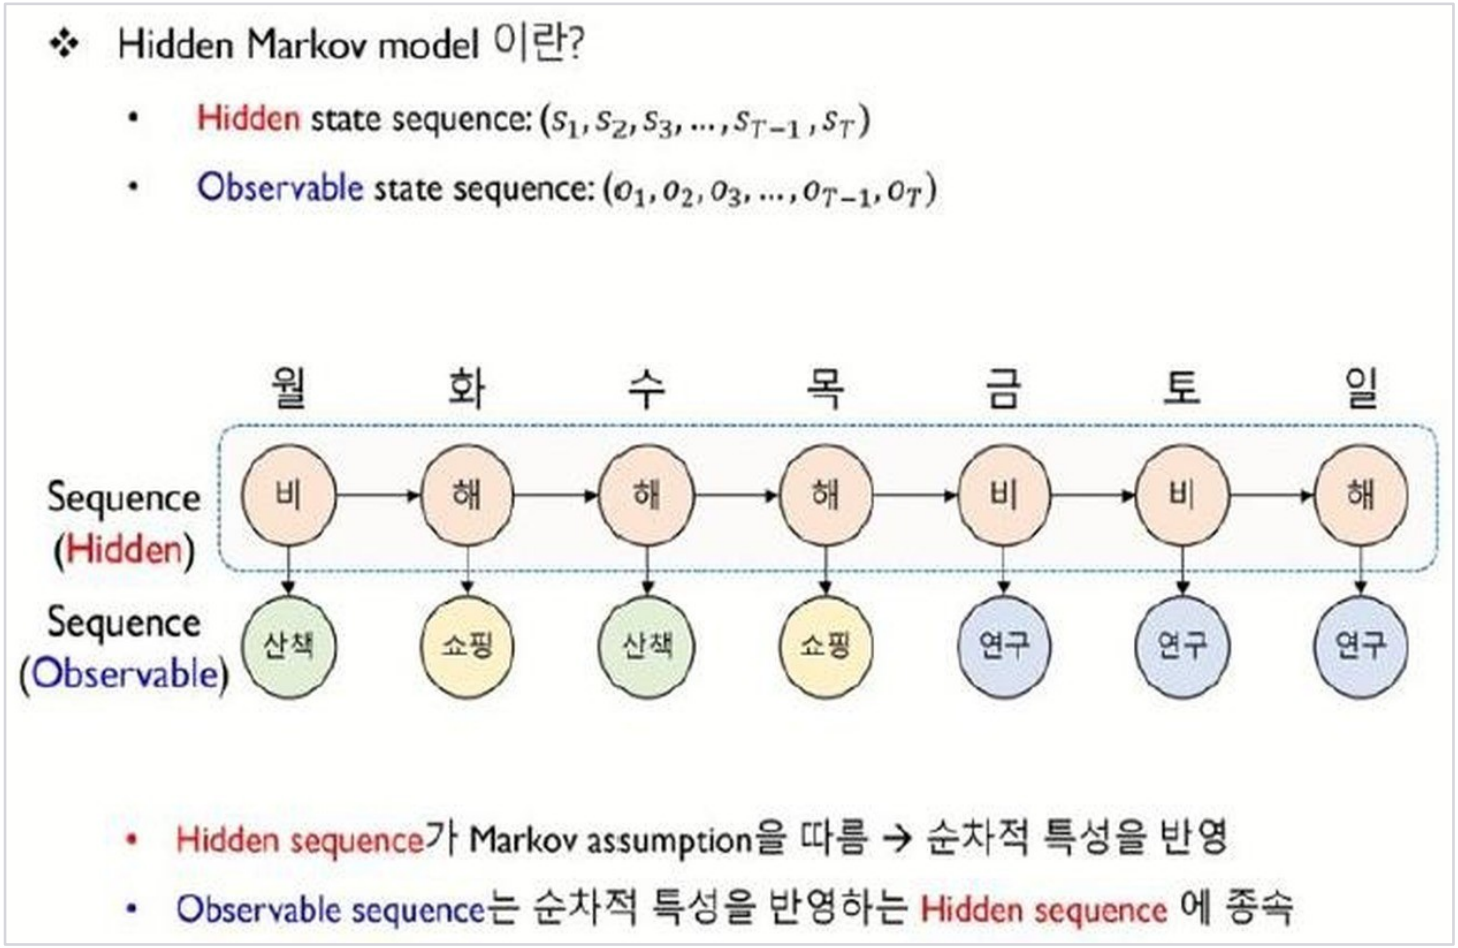


관측값은 같은 날의 은닉상태에 의존한다

은닉 시퀀스는 마르코프 가정을 따르고, 관측값은 은닉 시퀀스에 종속된다

구조

- 은닉 체인이 시간 순서를 담는다
- 날마다 활동 하나를 방출한다
- 활동 사이에는 화살표가 없다

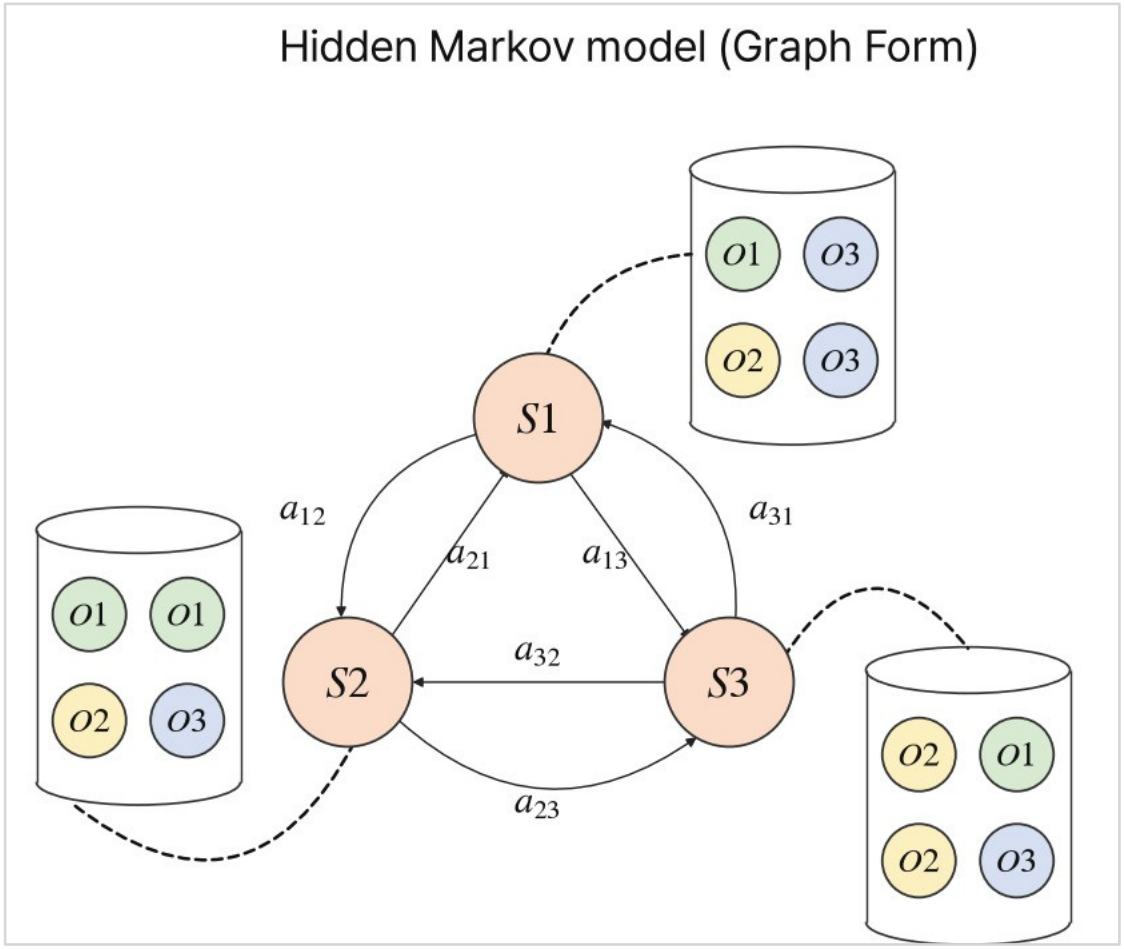


은닉상태마다 관측값을 담은 항아리(urn)가 따로 있다

그래프 형식: 전이 화살표로 이어진 상태 s1–s3와 관측값 항아리 o1–o3

항아리 그림

- 어떤 상태를 방문한다
- 그 상태의 항아리에서 공을 뽑는다
- 항아리의 구성은 상태마다 다르다

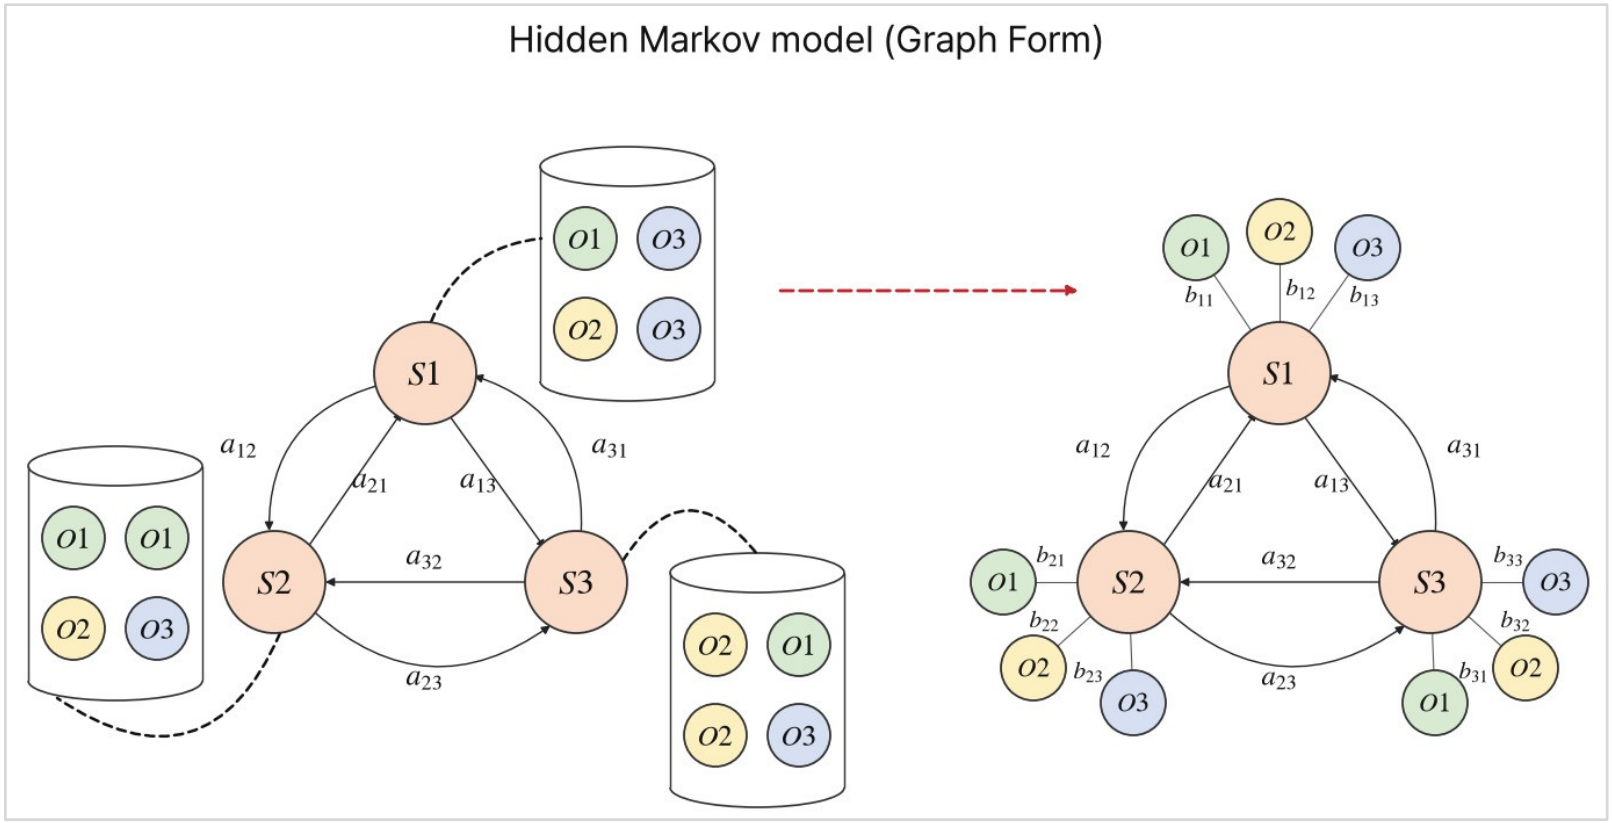


그래프에서 항아리는 방출 확률이 된다

각 항아리의 공 빈도가 가중치 b_jk가 된다

항아리에서 b로

- 왼쪽: 항아리 그림
- 오른쪽: 방출 연결선
- b = 공별 비율



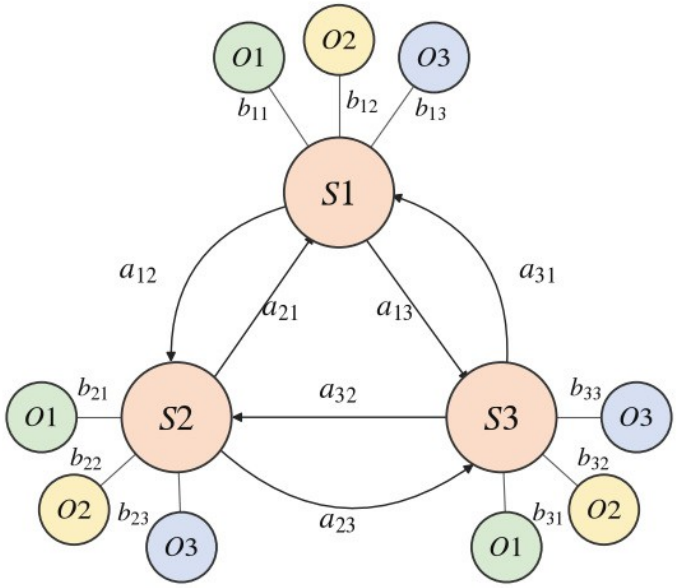
전이행렬 A와 방출 확률 행렬 B가 핵심 파라미터다

A: 상태 → 상태 · B: 상태 → 관측값

두 행렬

- A: n×n 전이
- B: 상태별 방출
- 원본의 a22, a32 오타를 b22, b32로 바로잡음

- $A(a_{ij})$: State transition probability matrix (상태 전이 확률 행렬)
- $B(b_{jk})$: Emission probability matrix (방출 확률 행렬)



$$A = \begin{array}{c} \\ S1 \\ S2 \\ S3 \end{array} \begin{array}{c} \begin{array}{ccc} S1 & S2 & S3 \end{array} \\ \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \end{array}$$

$$B = \begin{array}{c} \\ S1 \\ S2 \\ S3 \end{array} \begin{array}{c} \begin{array}{ccc} O1 & O2 & O3 \end{array} \\ \begin{bmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \\ b_{31} & b_{32} & b_{33} \end{bmatrix} \end{array}$$

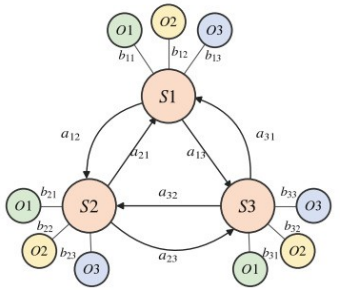
초기 분포 π에 따라 체인의 출발 상태가 달라진다

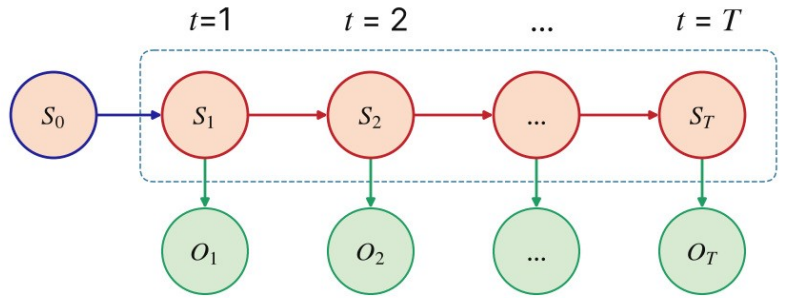
π: t = 1에서 각 상태의 확률(출발 노드 s0에서 시작)

λ = {A, B, π}

- 빨강: 전이 A
- 초록: 방출 B
- 파랑: 시작 π

- Parameters of a hidden Markov model (λ)
  - $A(a_{ij})$: State transition probability matrix
  - $B(b_{jk})$: Emission probability matrix
  - $\pi(\pi_i)$: Initial state probability matrix





$$\pi = \begin{matrix} \\ S1 \\ S2 \\ S3 \end{matrix} \begin{matrix} S_{t=0} \\ \begin{bmatrix} \pi_1 \\ \pi_2 \\ \pi_3 \end{bmatrix} \end{matrix} \qquad A = \begin{matrix} \\ S1 \\ S2 \\ S3 \end{matrix} \begin{matrix} \begin{matrix} S1 & S2 & S3 \end{matrix} \\ \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \end{matrix} \qquad B = \begin{matrix} \\ S1 \\ S2 \\ S3 \end{matrix} \begin{matrix} \begin{matrix} O1 & O2 & O3 \end{matrix} \\ \begin{bmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \\ b_{31} & b_{32} & b_{33} \end{bmatrix} \end{matrix}$$

각 파라미터는 합이 1인 확률분포다

원본 슬라이드의 정의(B의 합 인덱스는 k로 바로잡음)

모형

$$\lambda = \{A,\ B,\ \pi\}$$

A: 다음 상태

$$a_{ij} = p(q_{t+1} = s_j \mid q_t = s_i), \quad \sum_{j=1}^{n} a_{ij} = 1$$

B: 관측되는 값

$$b_j(v_k) = P(o_t = v_k \mid q_t = s_j), \quad \sum_{k=1}^{m} b_j(v_k) = 1$$

π: 출발 상태

$$\pi_i = P(q_1 = s_i), \quad \sum_{i=1}^{n} \pi_i = 1$$

HMM의 모든 과제는 세 문제 중 하나로 귀결된다

평가 · 디코딩 · 학습

세 문제

- 평가: P(O | λ)
- 디코딩: S(최적 은닉 경로)
- 학습: λ*를 데이터에서 찾기

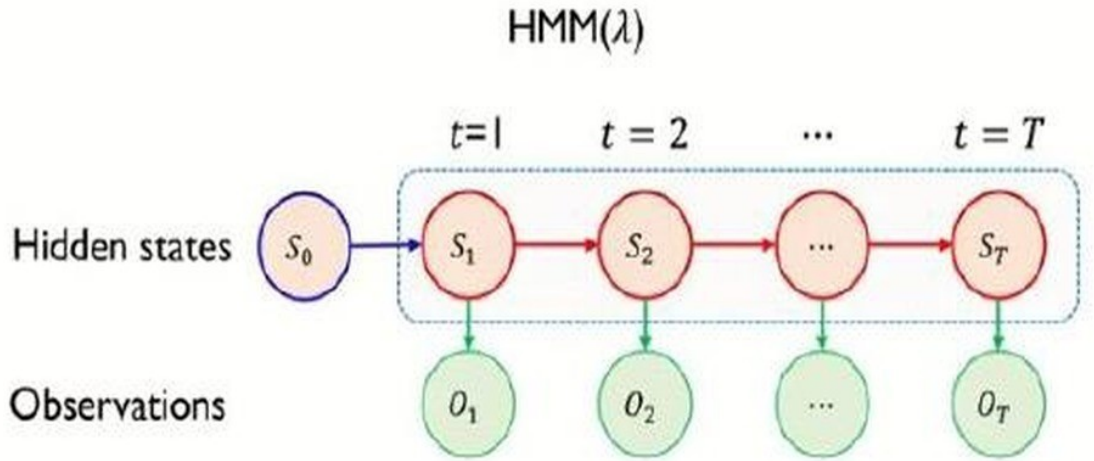
❖ Hidden Markov model $\lambda = (A, B, \pi)$

❖ Three problems of hidden Markov model

① Given HMM (λ^*) and **O**, find the probability of **O** → **Evaluation** problem

② Given HMM (λ^*) and **O**, find the optimal hidden state sequence (**S**) → **Decoding** problem

③ Given $X = \{\mathbf{O_1}, \ldots, \mathbf{O_N}\}$, find the HMM ($\lambda^*$) → **Learning** problem



학습으로 만든 모형을 평가와 디코딩에 쓴다

학습 시퀀스 → λ*, 시험 시퀀스 → 확률 또는 상태 경로

작업 흐름

- O1...ON으로 학습
- 평가: Forward 확률
- 디코딩: 상태 시퀀스

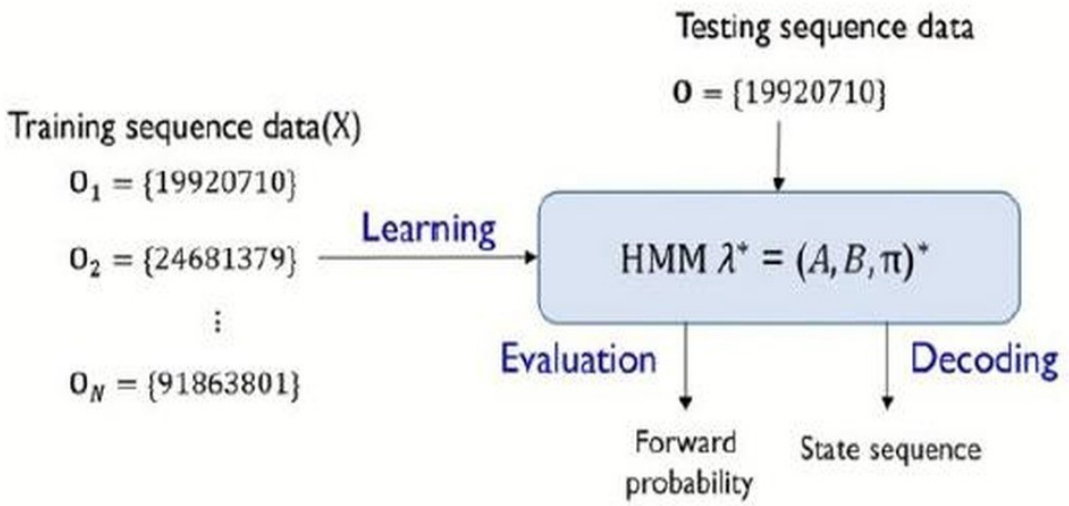
❖ Hidden Markov model $\lambda = (A, B, \pi)$

❖ Three problems of hidden Markov model

① Given HMM (λ^*) and **O**, find the probability of **O** → **Evaluation** problem

② Given HMM (λ^*) and **O**, find the optimal hidden state sequence (**S**) → **Decoding** problem

③ Given X = $\{\mathbf{O_1}, \ldots, \mathbf{O_N}\}$, find the HMM ($\lambda^*$) → **Learning** problem



03

3부 · 평가

평가와 Forward 알고리즘

관측된 시퀀스가 나타날 확률은 얼마인가?

정 박사의 HMM으로 예제의 파라미터를 모두 고정한다

질문: P(산책, 산책, 연구, 쇼핑)은?

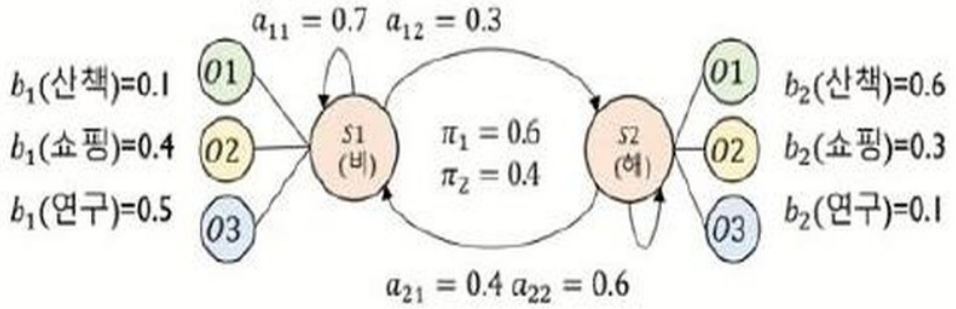
파라미터

- π: 비 0.6, 해 0.4
- A: 비→비 0.7, 해→해 0.6
- B(비): 산책 .1 쇼핑 .4 연구 .5
- B(해): 산책 .6 쇼핑 .3 연구 .1

❖ Evaluation problem

- Problem: Given HMM (λ^*) and **O**, find the probability of O
- Solution: Forward algorithm
- Example: 정 박사가 오늘 산책, 내일 산책, 모레 연구, 글피 쇼핑할 확률은?

정 박사 삶의 HMM



$\mathbf{O} = (o_1 = \text{산책}, o_2 = \text{산책}, o_3 = \text{연구}, o_4 = \text{쇼핑})$

Probability (O) $= (o_1 = \text{산책}, o_2 = \text{산책}, o_3 = \text{연구}, o_4 = \text{쇼핑}) = ?$

전수 열거의 계산량은 N의 T제곱으로 늘어난다

모든 은닉 경로의 확률을 구해 더해야 한다. 원본은 날씨 경로 16개를 열거한다

1	비	비	비	비
2	비	비	비	해
3	비	비	해	비
4	비	해	비	비
5	해	비	비	비
6	해	해	비	비
7	비	해	해	비
8	비	비	해	해
9	해	비	비	해
10	해	비	해	비
11	비	해	비	해
12	해	해	해	비
13	비	해	해	해
14	해	비	해	해
15	해	해	비	해
16	해	해	해	해

총 경우의 수 = 2^4 = 16개

안 되는 이유

- 상태 2개, 4일: 경로 16개
- 상태 3개, 20일: 약 35억 개
- 재귀식이 필요하다

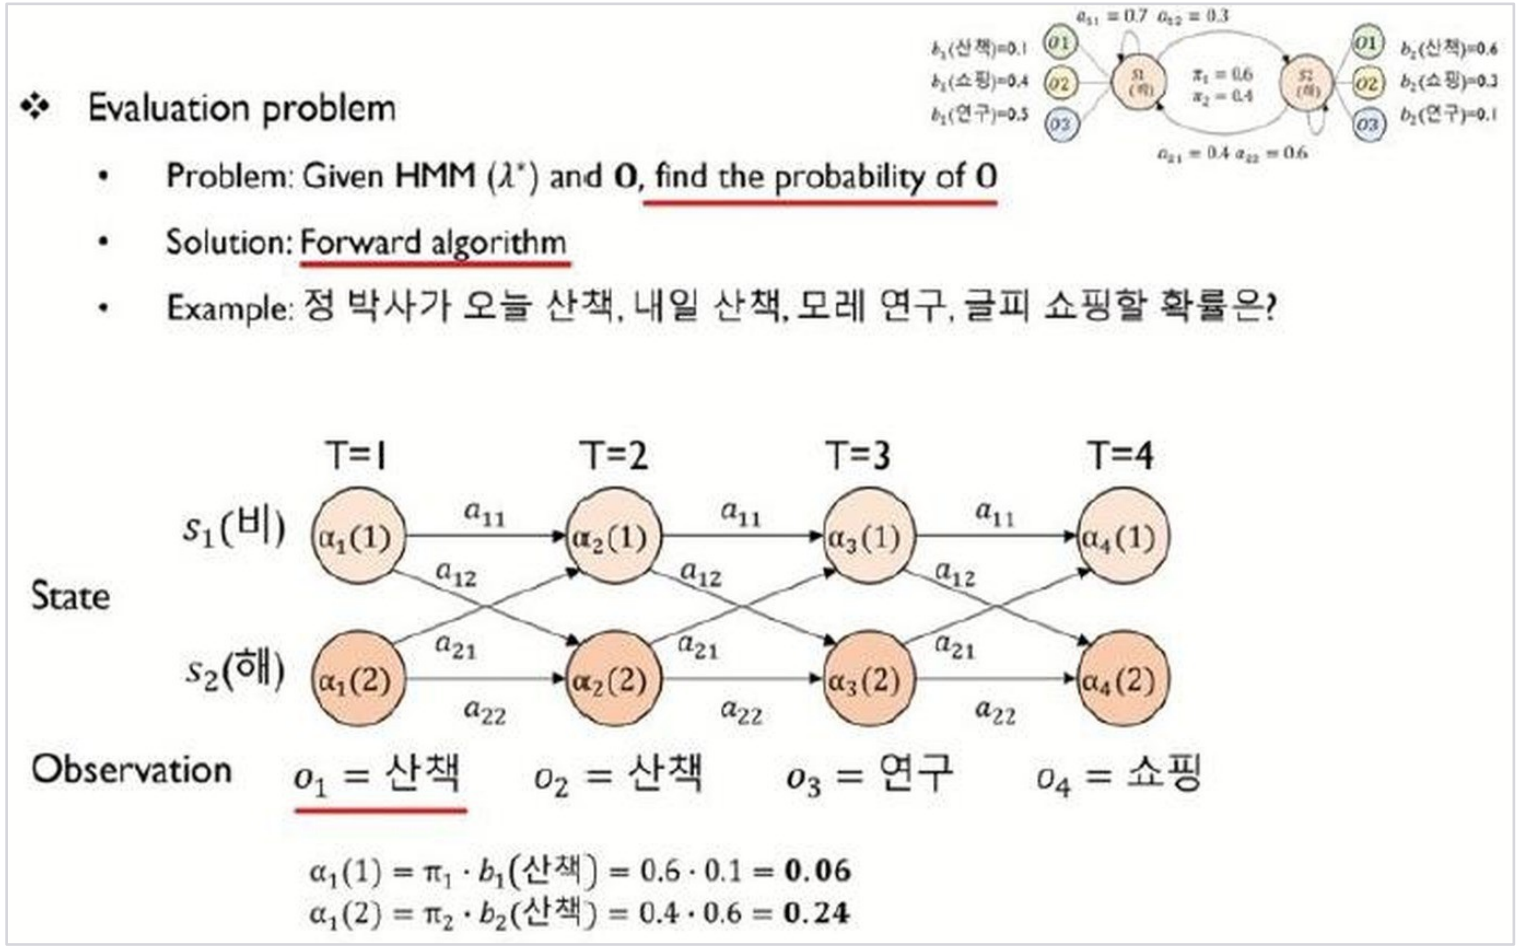
$$\text{은닉 경로의 수} = N^T \qquad 2^4 = 16, \quad 3^{20} = 3{,}486{,}784{,}401$$

Forward 알고리즘은 초기 확률과 첫 방출 확률의 곱에서 시작한다

t = 1, 관측값 산책

1단계

- α1(비) =
  0.6 × 0.1 = 0.06
- α1(해) =
  0.4 × 0.6 = 0.24



Forward 값은 그 상태에 도착하는 모든 경로를 합한 값이다

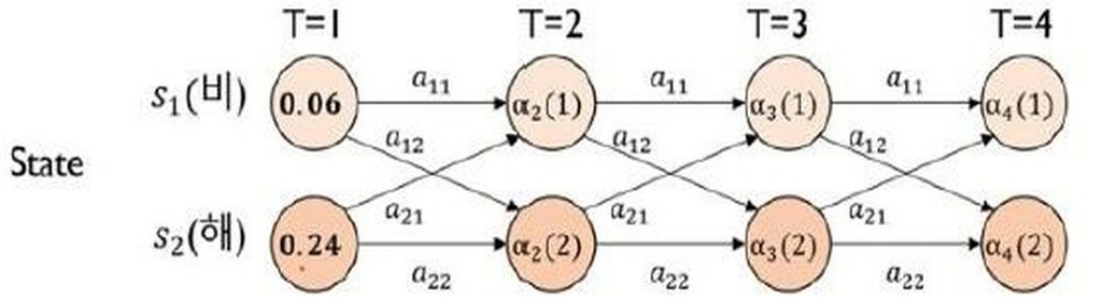
t = 2, 관측값 산책

2단계

- α2(비) = 0.0138
- α2(해) = 0.0972
- 이전 상태를 모두 합한 뒤 b를 곱한다

❖ Evaluation problem

- Problem: Given HMM (λ^*) and **O**, find the probability of **O**
- Solution: Forward algorithm
- Example: 정 박사가 오늘 산책, 내일 산책, 모레 연구, 글피 쇼핑할 확률은?



$$\alpha_2(1) = (\alpha_1(1) \cdot a_{11} + \alpha_1(2) \cdot a_{21}) \cdot b_1(\text{산책}) = (\mathbf{0.06} \cdot 0.7 + \mathbf{0.24} \cdot 0.4) \cdot 0.1 = \mathbf{0.0138}$$

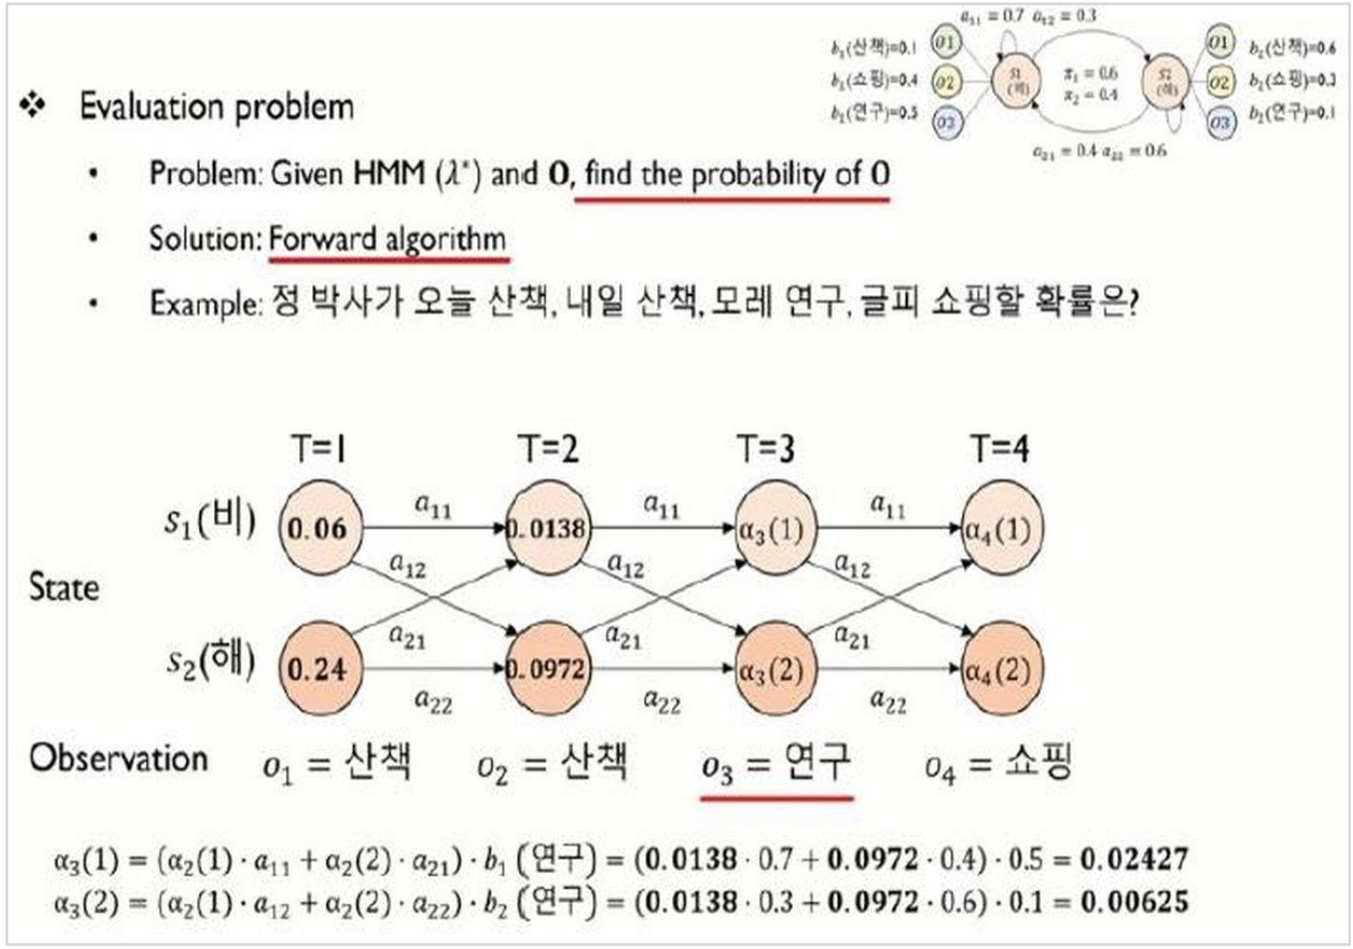
$$\alpha_2(2) = (\alpha_1(1) \cdot a_{12} + \alpha_1(2) \cdot a_{22}) \cdot b_2(\text{산책}) = (\mathbf{0.06} \cdot 0.3 + \mathbf{0.24} \cdot 0.6) \cdot 0.6 = \mathbf{0.0972}$$

재귀식은 전날의 Forward 값을 다시 쓴다

t = 3, 관측값 연구

3단계

- α3(비) = 0.02427
- α3(해) = 0.00625
- 연구는 비일 때 나올 가능성이 크다



마지막 단계에서 최종 상태별 Forward 값이 나온다

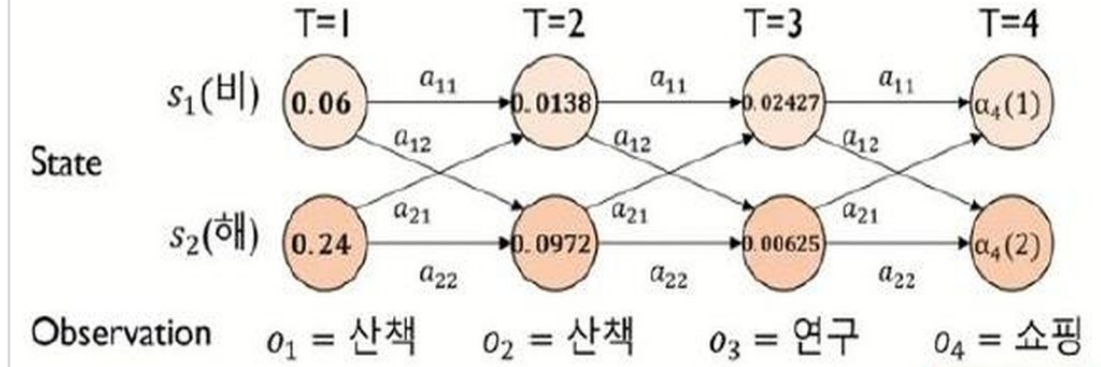
t = 4, 관측값 쇼핑

4단계

- α4(비) = 0.00780
- α4(해) = 0.00331

❖ Evaluation problem

- Problem: Given HMM (λ^*) and **O**, find the probability of **O**
- Solution: Forward algorithm
- Example: 정 박사가 오늘 산책, 내일 산책, 모레 연구, 글피 쇼핑할 확률은?



$$\alpha_4(1) = (\alpha_3(1) \cdot a_{11} + \alpha_3(2) \cdot a_{21}) \cdot b_1(\text{쇼핑}) = (\mathbf{0.02427} \cdot 0.7 + \mathbf{0.00625} \cdot 0.4) \cdot 0.4 = \mathbf{0.00780}$$

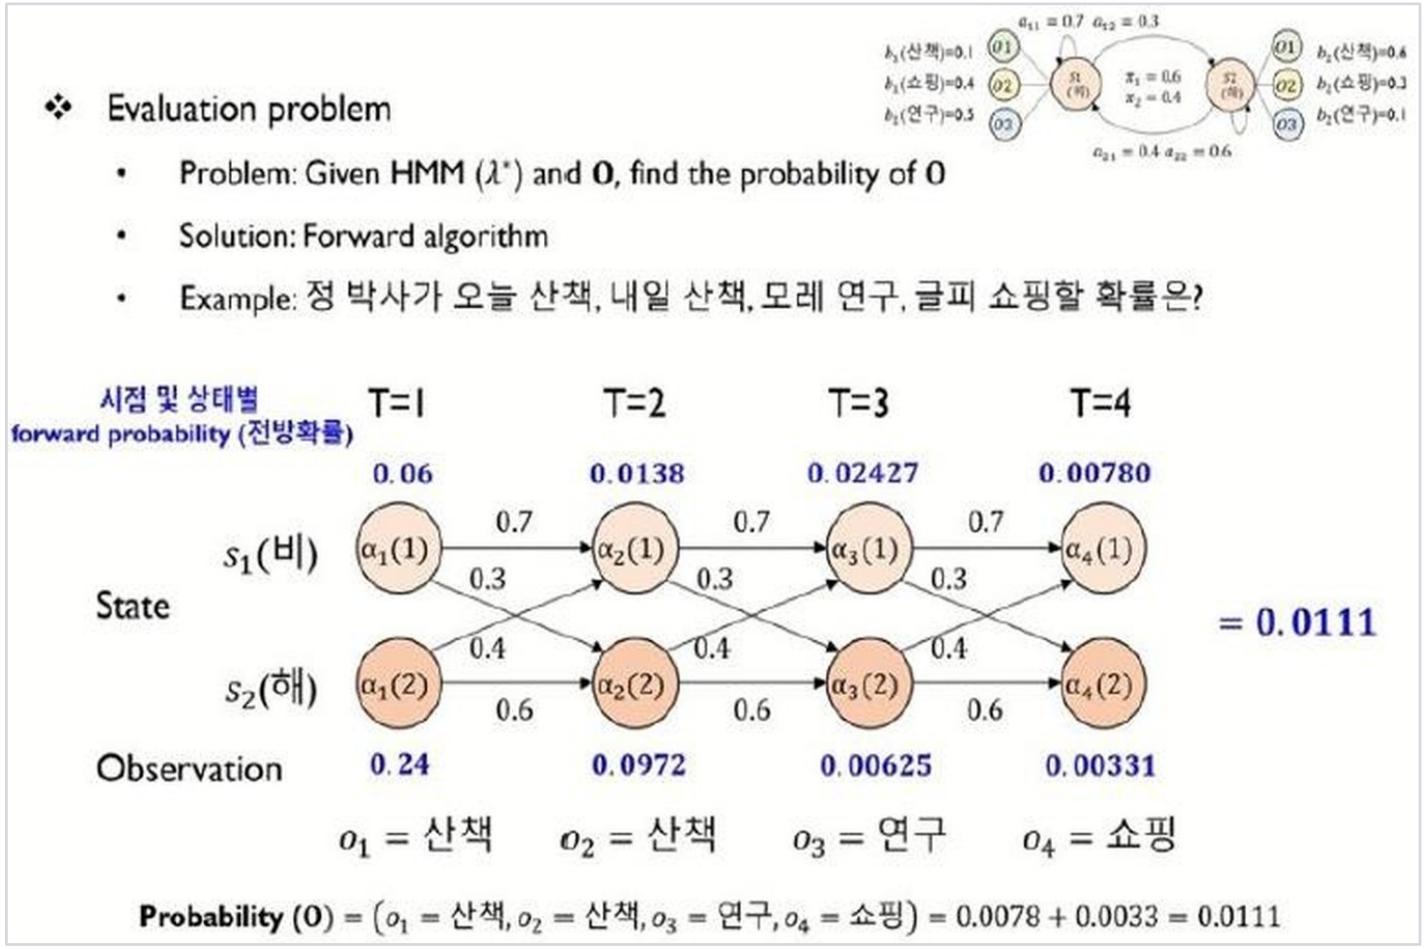
$$\alpha_4(2) = (\alpha_3(1) \cdot a_{12} + \alpha_3(2) \cdot a_{22}) \cdot b_2(\text{쇼핑}) = (\mathbf{0.02427} \cdot 0.3 + \mathbf{0.00625} \cdot 0.6) \cdot 0.3 = \mathbf{0.00331}$$

시퀀스의 확률은 마지막 Forward 값의 합이다

P(O) = 0.0078 + 0.0033 = 0.0111

결과

- 마지막 열을 더한다
- P(O | λ) = 0.0111
- 계산량은 N^T가 아니라 N^2T로 늘어난다



Forward 재귀식은 이전 상태의 합에 방출 확률을 곱한 것이다

Forward 확률 α_t(i): 원본 슬라이드의 수식

$$\alpha_1(i) = \pi_i \, b_i(o_1)$$

$$\alpha_t(i) = \left[\sum_{j=1}^{n} \alpha_{t-1}(j) \, a_{ji} \right] b_i(o_t), \quad 2 \le t \le T$$

$$p(O \mid \lambda) = \sum_{j=1}^{n} \alpha_T(j)$$

활용

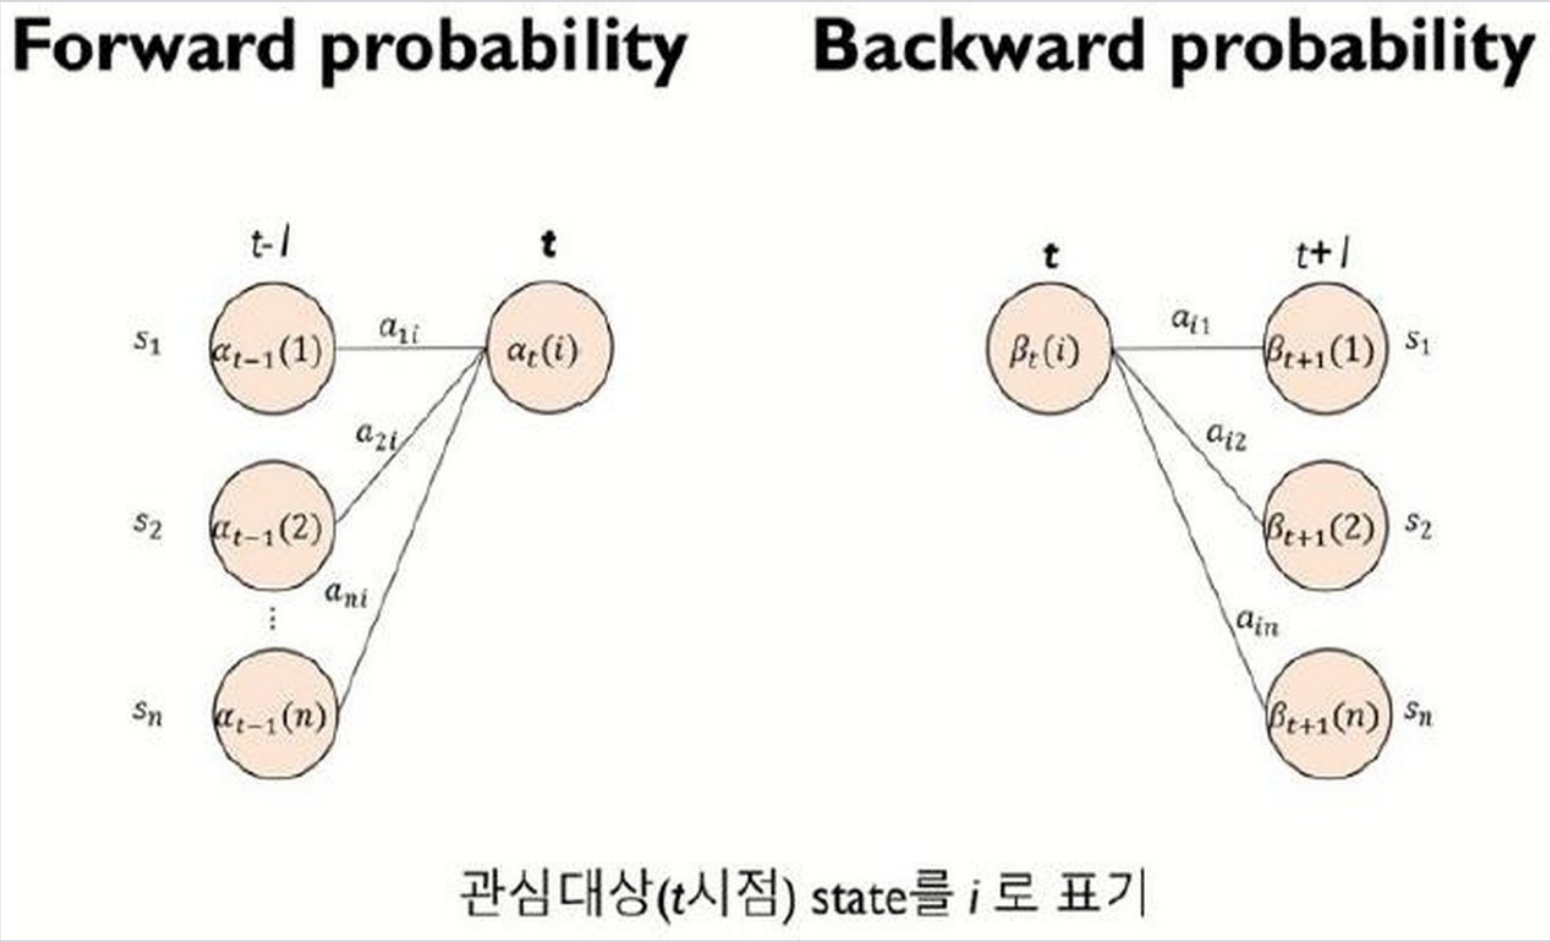
- P(O | λ)로 시퀀스가 어느 모형에서 나왔을 가능성이 가장 큰지 판단한다(정 박사 대 조 박사)
- → 시퀀스 분류

Backward 확률은 같은 아이디어를 시간 역순으로 적용한다

Forward: 과거 → 현재 · Backward: 미래 → 현재

서로 대칭

- α_t(i): t−1에서 i로 들어옴
- β_t(i): i에서 t+1로 나감
- 둘 다 모든 경로를 합산한다



Backward 알고리즘은 마지막 시점의 값 1에서 시작한다

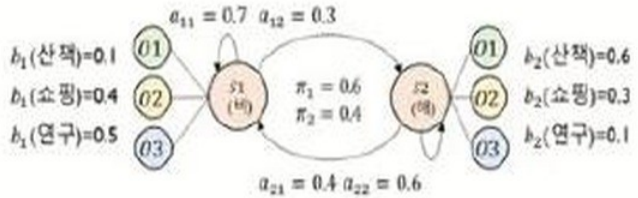
모든 상태에서 β_T(i) = 1

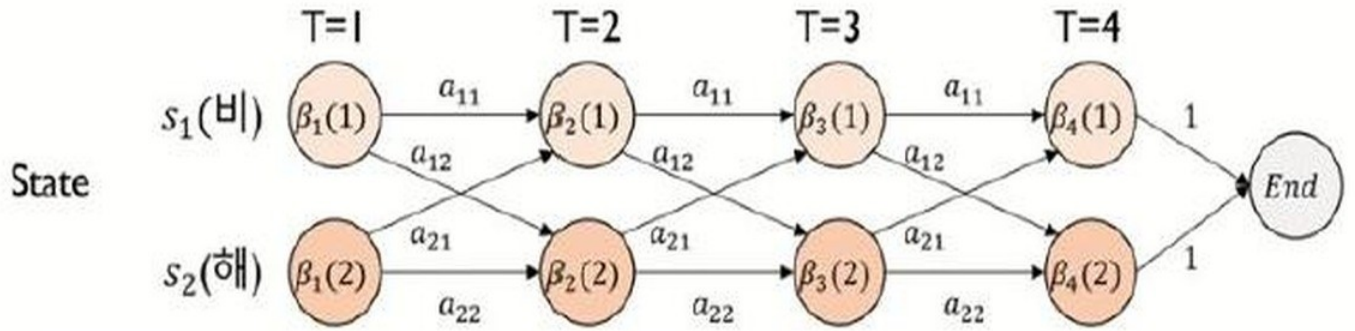
초기화

- 더 설명할 관측값이 없다
- β4(비) = β4(해) = 1

❖ An example of **Backward** algorithm

- Problem: Given HMM (λ^*) and **O**, find the **backward** probability of **O**
- Solution: **Backward** algorithm





Observation o_1 = 산책 o_2 = 산책 o_3 = 연구 o_4 = 쇼핑

$$\beta_{t=T}(i) = 1$$

각 Backward 값에는 다음 날의 방출 확률과 전이 확률이 가중치로 들어간다

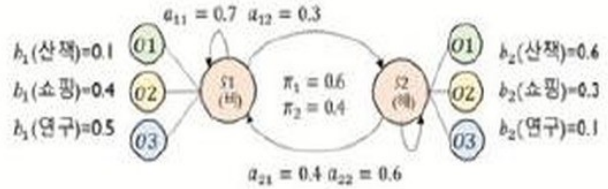
t = 3에서는 o4 = 쇼핑을 쓴다

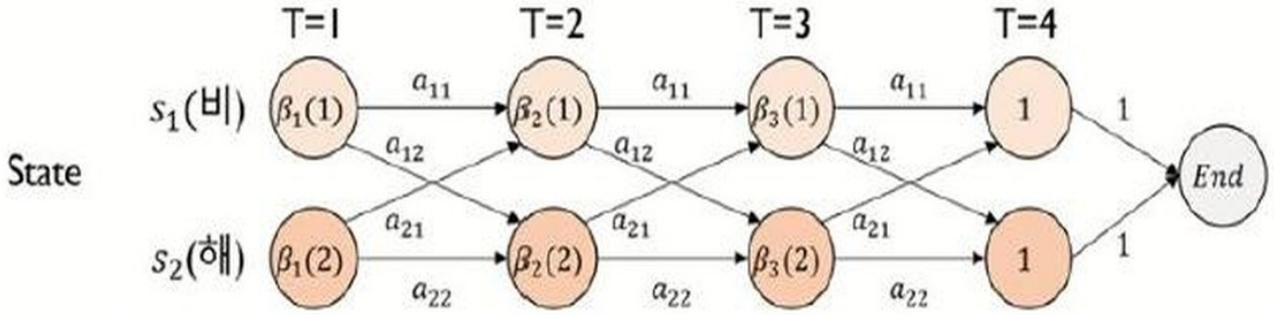
t = 3 단계

- β3(비) = 0.37
- β3(해) = 0.34

❖ An example of **Backward** algorithm

- Problem: Given HMM (λ^*) and **O**, find the **backward** probability of **O**
- Solution: **Backward** algorithm





$$\beta_3(1) = \left(\beta_4(1) \cdot a_{11} \cdot b_1(\text{쇼핑}) + \beta_4(2) \cdot a_{12} \cdot b_2(\text{쇼핑})\right) = (1 \cdot 0.7 \cdot 0.4 + \mathbf{1} \cdot 0.3 \cdot 0.3) = \mathbf{0.37}$$

$$\beta_3(2) = (\beta_4(1) \cdot a_{21} \cdot b_1(\text{쇼핑}) + \beta_4(2) \cdot a_{22} \cdot b_2(\text{쇼핑})) = (\mathbf{1} \cdot 0.4 \cdot 0.4 + 1 \cdot 0.6 \cdot 0.3) = \mathbf{0.34}$$

Backward 계산은 한 시점씩 앞으로 거슬러 간다

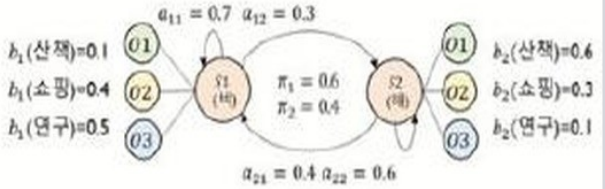
t = 2에서는 o3 = 연구, t = 1에서는 o2 = 산책을 쓴다

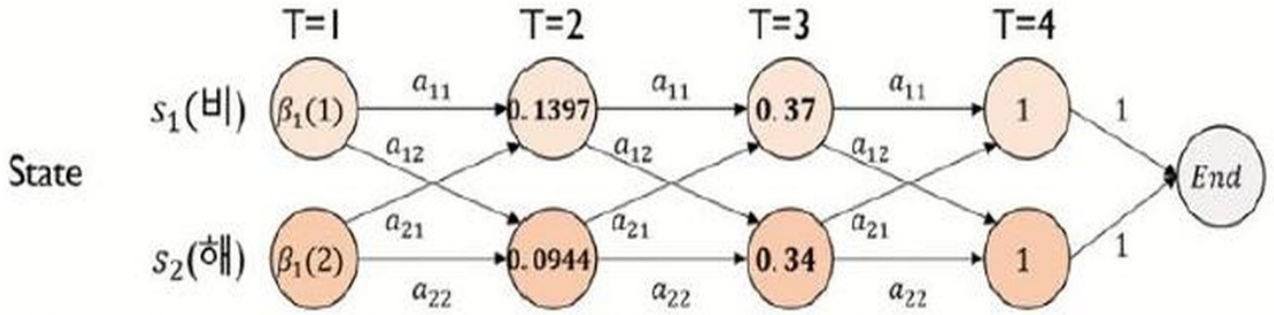
t = 2, 1 단계

- β2: 0.1397, 0.0944
- β1: 0.02677, 0.03957

❖ An example of **Backward** algorithm

- Problem: Given HMM (λ^*) and **O**, find the **backward** probability of **O**
- Solution: **Backward** algorithm





$$\beta_1(1) = \left(\beta_2(1) \cdot a_{11} \cdot b_1(\text{산책}) + \beta_2(2) \cdot a_{12} \cdot b_2(\text{산책})\right) = (0.1397 \cdot 0.7 \cdot 0.1 + 0.0944 \cdot 0.3 \cdot 0.6) = 0.02677$$

$$\beta_1(2) = (\beta_2(1) \cdot a_{21} \cdot b_1(\text{산책}) + \beta_2(2) \cdot a_{22} \cdot b_2(\text{산책})) = (0.1397 \cdot 0.4 \cdot 0.1 + 0.0944 \cdot 0.6 \cdot 0.6) = 0.03957$$

Forward 계산과 Backward 계산의 시퀀스 확률은 같다

원본 37쪽은 π1을 두 번 썼다. 둘째 항은 π2다

$$P(O) = \beta_1(1)\,\pi_1 b_1(o_1) + \beta_1(2)\,\pi_2 b_2(o_1) = 0.02677 \cdot 0.06 + 0.03957 \cdot 0.24 = 0.0111$$

검산

- Forward: 0.0078 + 0.0033 = 0.0111
- Backward: 0.02677·0.06 + 0.03957·0.24 = 0.0111
- Backward 확률은 학습(Baum-Welch 알고리즘)에 다시 쓰인다

Backward 재귀식은 Forward 재귀식을 시간 역순으로 뒤집은 꼴이다

원본 슬라이드의 수식(시간 인덱스는 t로 표기)

$$\beta_T(i) = 1$$

$$\beta_t(i) = \sum_{j=1}^{n} a_{ij}\, b_j(o_{t+1})\, \beta_{t+1}(j), \quad 1 \le t \le T-1$$

$$p(O \mid \lambda) = \sum_{i=1}^{n} \pi_i\, b_i(o_1)\, \beta_1(i)$$

읽는 법

- Forward: 이전 시점 → 다음 시점
- Backward: 다음 시점 → 이전 시점

04

4부 · 디코딩

디코딩과 Viterbi 알고리즘

날마다 날씨는 어땠을까?

디코딩은 가장 그럴듯한 은닉상태 시퀀스를 찾는다

같은 HMM, 같은 관측값: 산책, 산책, 연구, 쇼핑

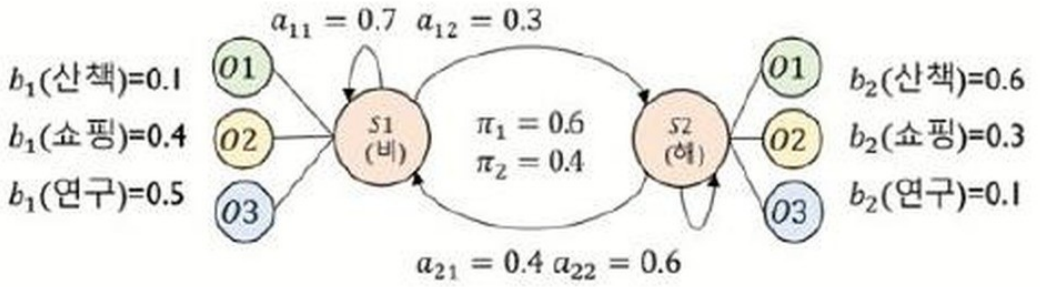
문제

- λ와 O가 주어졌을 때
- 최적의 S를 찾는다
- 풀이: Viterbi 알고리즘

❖ Decoding problem (디코딩) → HMM의 핵심!!

- Problem: Given HMM (λ^*) and **O**, find the optimal **S** (가장 그럴싸한 은닉상태의 시퀀스 결정)
- Solution: Viterbi algorithm
- Example: 정 박사가 오늘 산책, 내일 산책, 모레 연구, 글피 쇼핑 했다면, 각 날들 날씨는?

정 박사 삶의 HMM



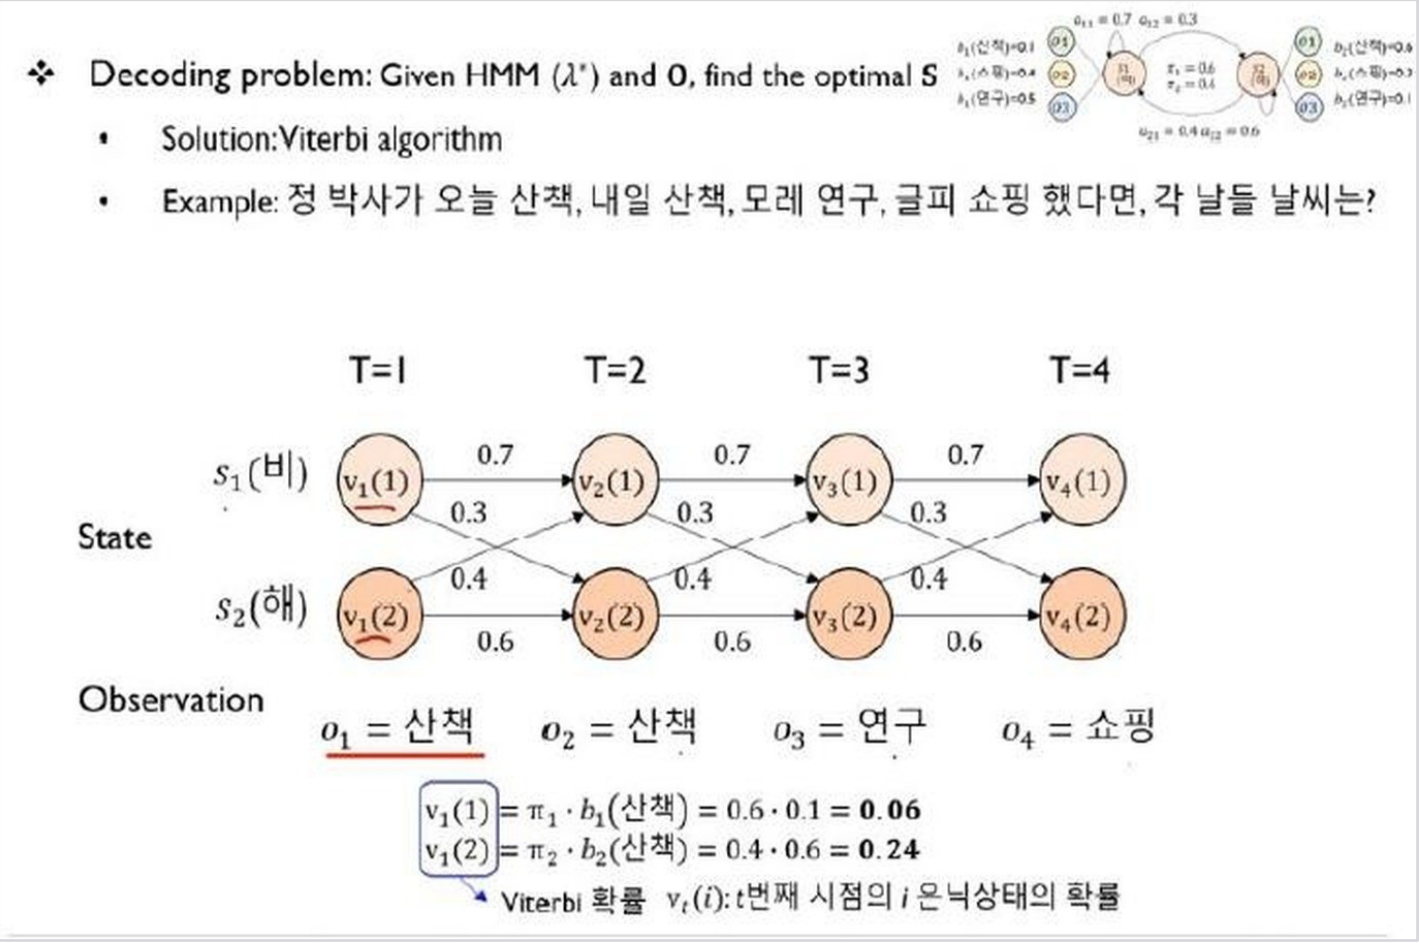
$\mathbf{O} = (o_1 = \text{산책}, o_2 = \text{산책}, o_3 = \text{연구}, o_4 = \text{쇼핑})$

Viterbi 알고리즘의 시작은 Forward 알고리즘과 똑같다

v1(i) = π_i · b_i(o1): 시점 t에서 상태 i의 Viterbi 확률

1단계

- v1(비) = 0.06
- v1(해) = 0.24

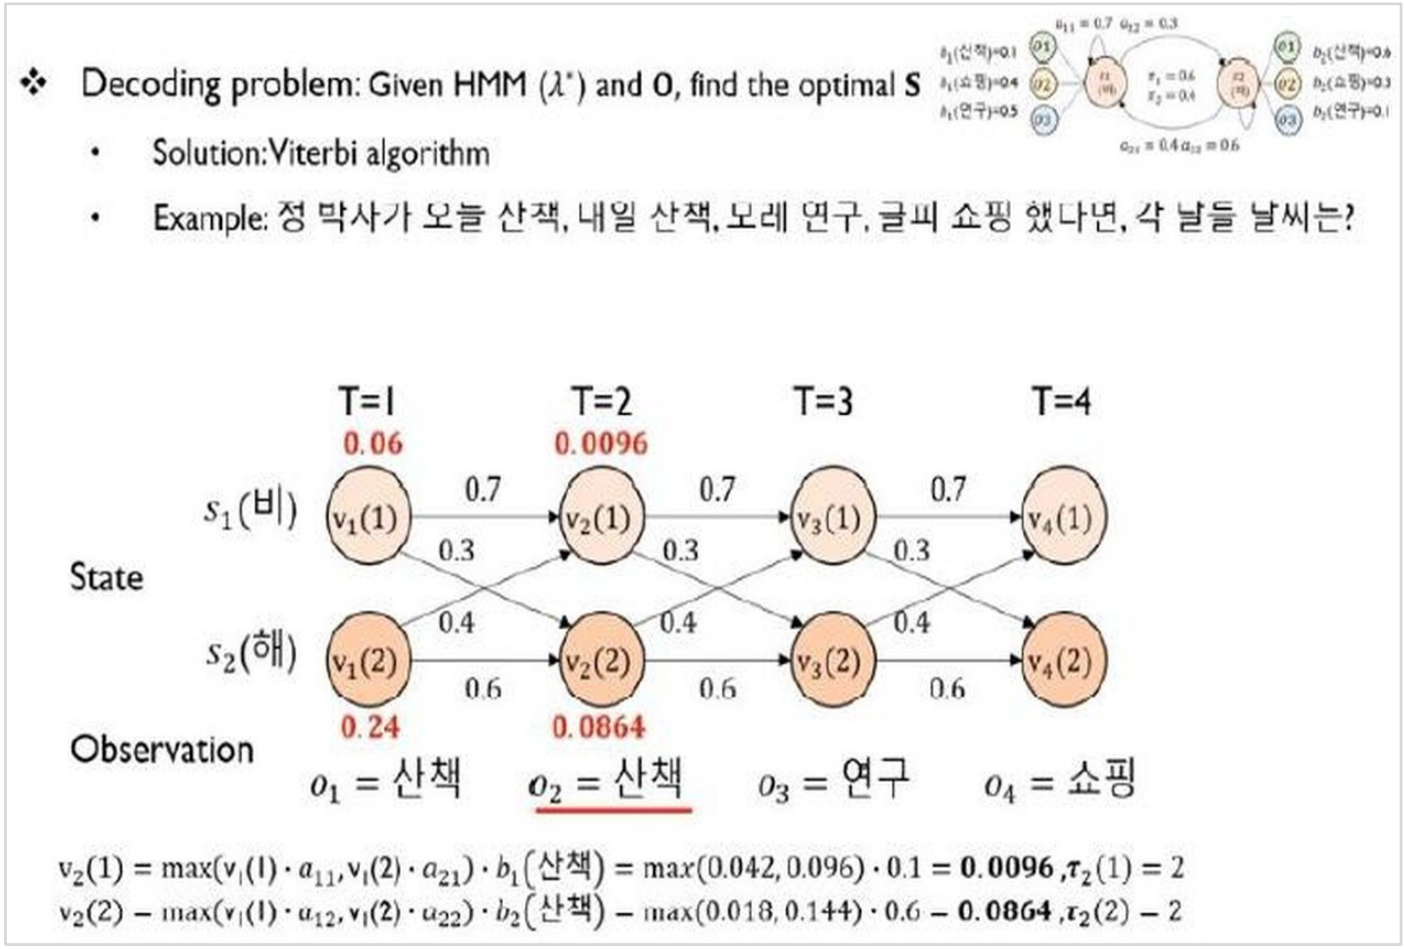


Viterbi 알고리즘은 들어오는 경로 중 최적 경로만 남기고 출처를 기록한다

t = 2: 합 대신 max를 쓰고, τ에 arg max를 저장한다

2단계

- v2(비) = 0.0096,
  τ = 해
- v2(해) = 0.0864,
  τ = 해



3일째 연구 관측으로 최적 상태가 비로 바뀐다

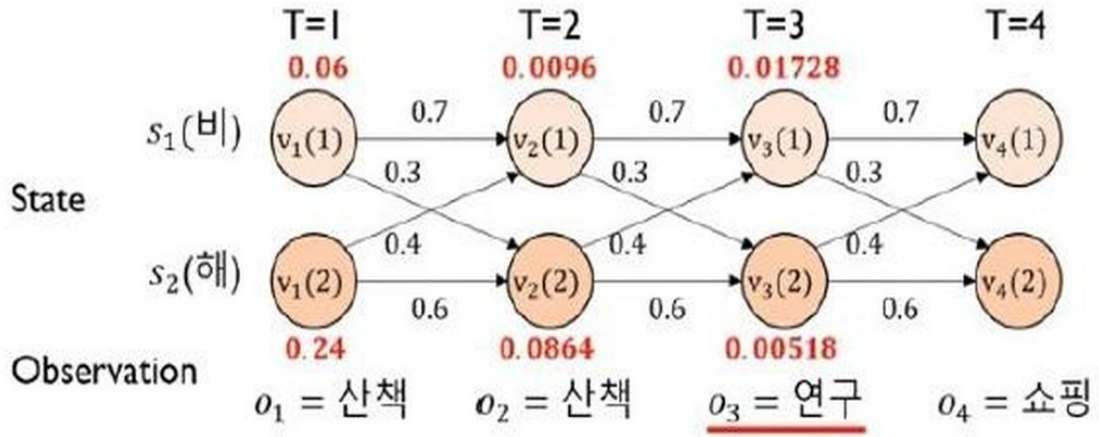
t = 3

3단계

- v3(비) = 0.01728,
  τ = 해
- v3(해) = 0.00518,
  τ = 해

❖ Decoding problem: Given HMM (λ^*) and O, find the optimal S

- Solution:Viterbi algorithm
- Example: 정 박사가 오늘 산책, 내일 산책, 모레 연구, 글피 쇼핑 했다면, 각 날들 날씨는?



$v_3(1) = \max(v_2(1) \cdot a_{11}, v_2(2) \cdot a_{21}) \cdot b_1(\text{연구}) = \max(0.00672, 0.03456) \cdot 0.5 = \mathbf{0.01728}, \tau_3(1) = 2$

$v_3(2) = \max(v_2(1) \cdot a_{12}, v_2(2) \cdot a_{22}) \cdot b_2(\text{연구}) = \max(0.00288, 0.05184) \cdot 0.1 = \mathbf{0.00518}, \tau_3(2) = 2$

마지막 열에는 최종 상태별 최적 경로 점수가 담긴다

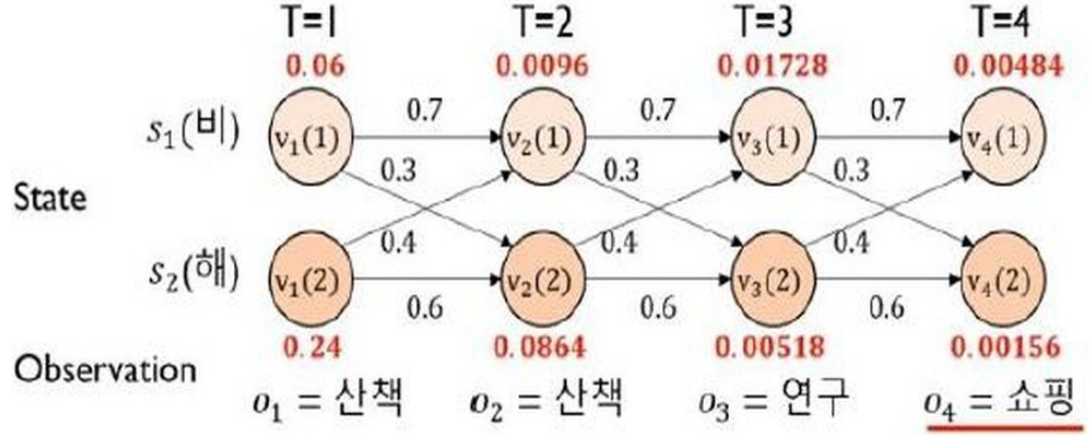
t = 4 (원본의 b(연구)를 b(쇼핑)으로 바로잡음)

4단계

- v4(비) = 0.00484,
  τ = 비
- v4(해) = 0.00156,
  τ = 비

❖ Decoding problem: Given HMM (λ^*) and O, find the optimal S

- Solution:Viterbi algorithm
- Example: 정 박사가 오늘 산책, 내일 산책, 모레 연구, 글피 쇼핑 했다면, 각 날들 날씨는?



$v_4(1) = \max(v_3(1) \cdot a_{11}, v_3(2) \cdot a_{21}) \cdot b_1(\text{쇼핑}) = \max(0.012096, 0.00207) \cdot 0.4 = \mathbf{0.00484}, \tau_4(1) = 1$

$v_4(2) = \max(v_3(1) \cdot a_{12}, v_3(2) \cdot a_{22}) \cdot b_2(\text{쇼핑}) = \max(0.005184, 0.003108) \cdot 0.3 = \mathbf{0.00156}, \tau_4(2) = 1$

역추적 포인터(backpointer)는 노드마다 최적의 이전 상태를 저장한다

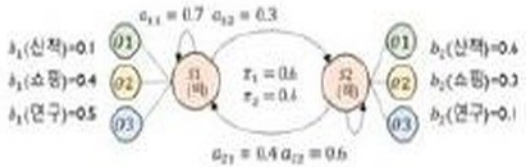
τ_t(i)는 i로 들어오는 최적 경로에서 시점 t−1의 상태다

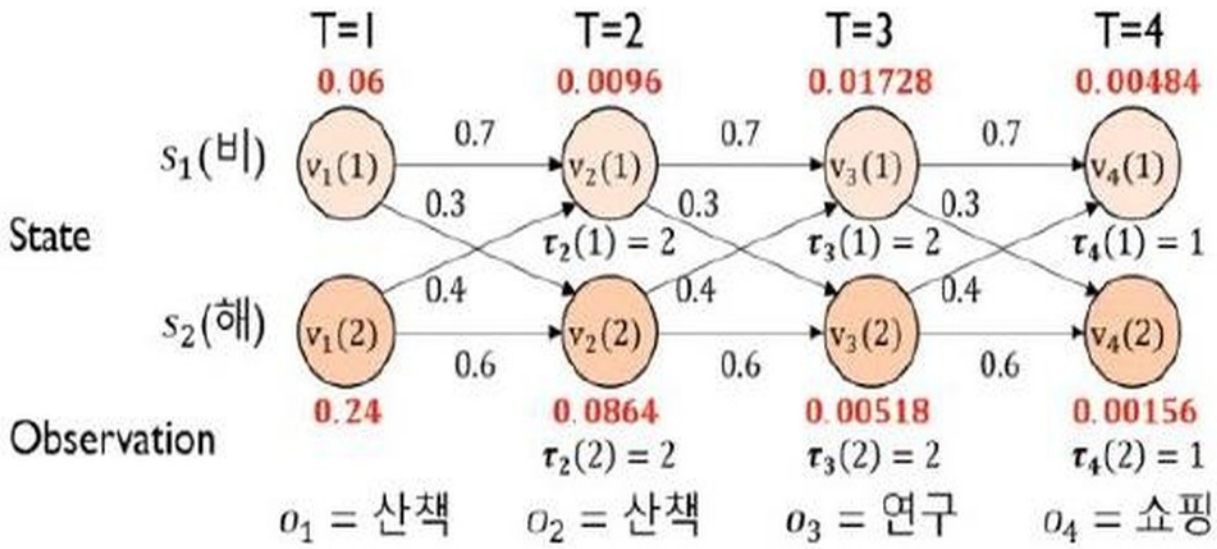
역추적 포인터

- τ2 = (해, 해)
- τ3 = (해, 해)
- τ4 = (비, 비)

❖ Decoding problem: Given HMM (λ^*) and O, find the optimal S

- Solution:Viterbi algorithm
- Example: 정 박사가 오늘 산책, 내일 산책, 모레 연구, 글피 쇼핑 했다면, 각 날들 날씨는?



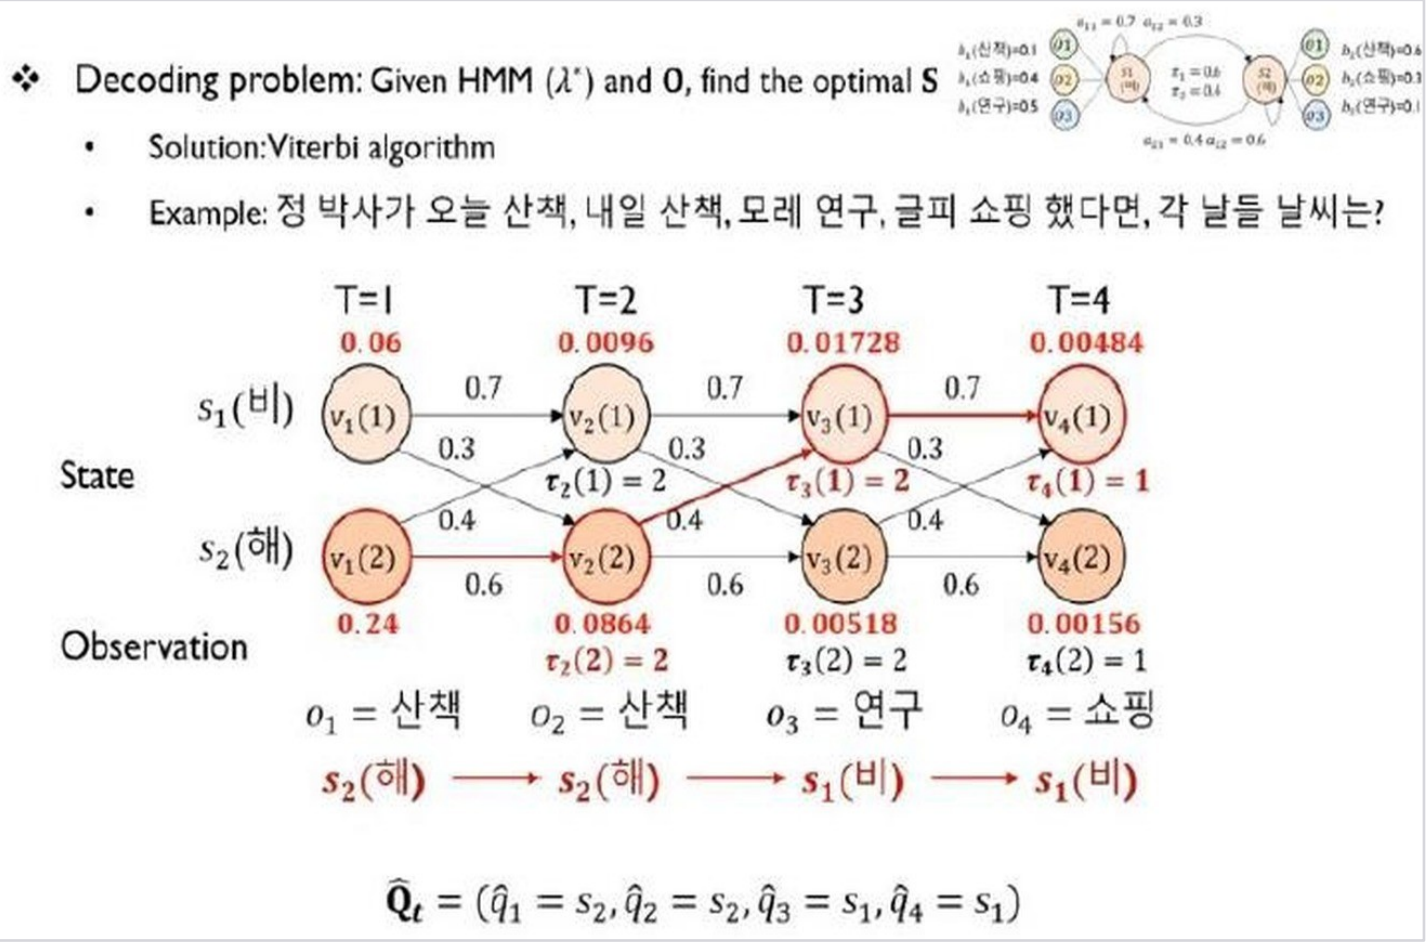


최적 최종 상태에서 역추적하면 전체 경로를 복원할 수 있다

비(0.00484)에서 끝나므로 τ를 거꾸로 따라간다

답

- 해 → 해 → 비 → 비
- $\hat{Q}$ = (s2, s2, s1, s1)



Viterbi 재귀식은 Forward의 합을 최댓값으로 바꾼다

원본 슬라이드의 수식(재귀식의 방출 항은 b_i(o_t))

$$v_1(i) = \pi_i \, b_i(o_1)$$

$$v_t(i) = \left[\max_{1 \le j \le n} v_{t-1}(j) \, a_{ji} \right] b_i(o_t)$$

$$\tau_t(i) = \arg \max_{1 \le j \le n} v_{t-1}(j) \, a_{ji}$$

$$\hat{q}_T = \arg \max_{1 \le j \le n} v_T(j), \qquad \hat{q}_t = \tau_{t+1}(\hat{q}_{t+1})$$

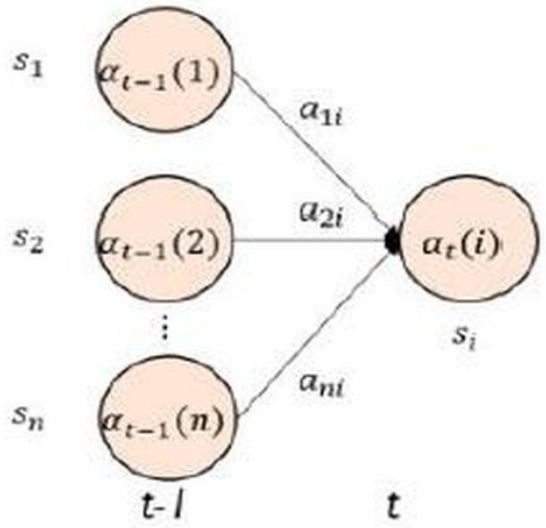
평가는 모든 경로를 합하고, 디코딩은 최댓값을 취한다

같은 격자(trellis), 다른 연산(合 = 합, 最大 = 최대)

격자 하나

- Forward: Σ → O의 확률
- Viterbi: max → 최적 경로
- 원본의 χ를 v로 바로잡음

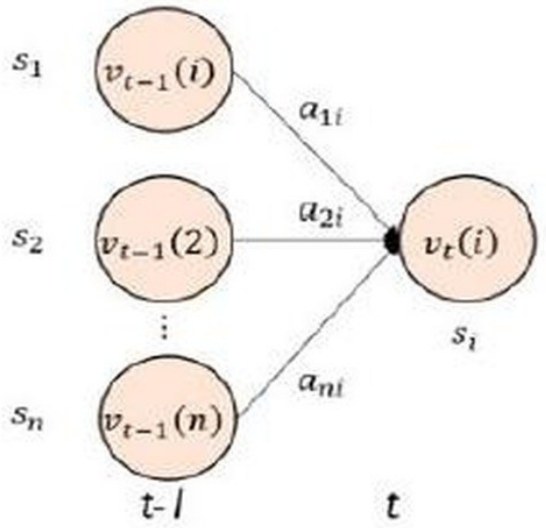
Forward algorithm for evaluation



$$\alpha_t(i) = \left[\sum_{j=1}^{n} \alpha_{t-1}(j)a_{ji}\right] \cdot b_i(o_t),$$

가능한 모든 경우의 확률의 合

Viterbi algorithm for decoding



$$\mathbf{v_t(i)} = \left[\max_{1 \le j \le n} \mathbf{v_{t-1}(j)a_{ji}}\right] \cdot \mathbf{b_i(o_t)}$$

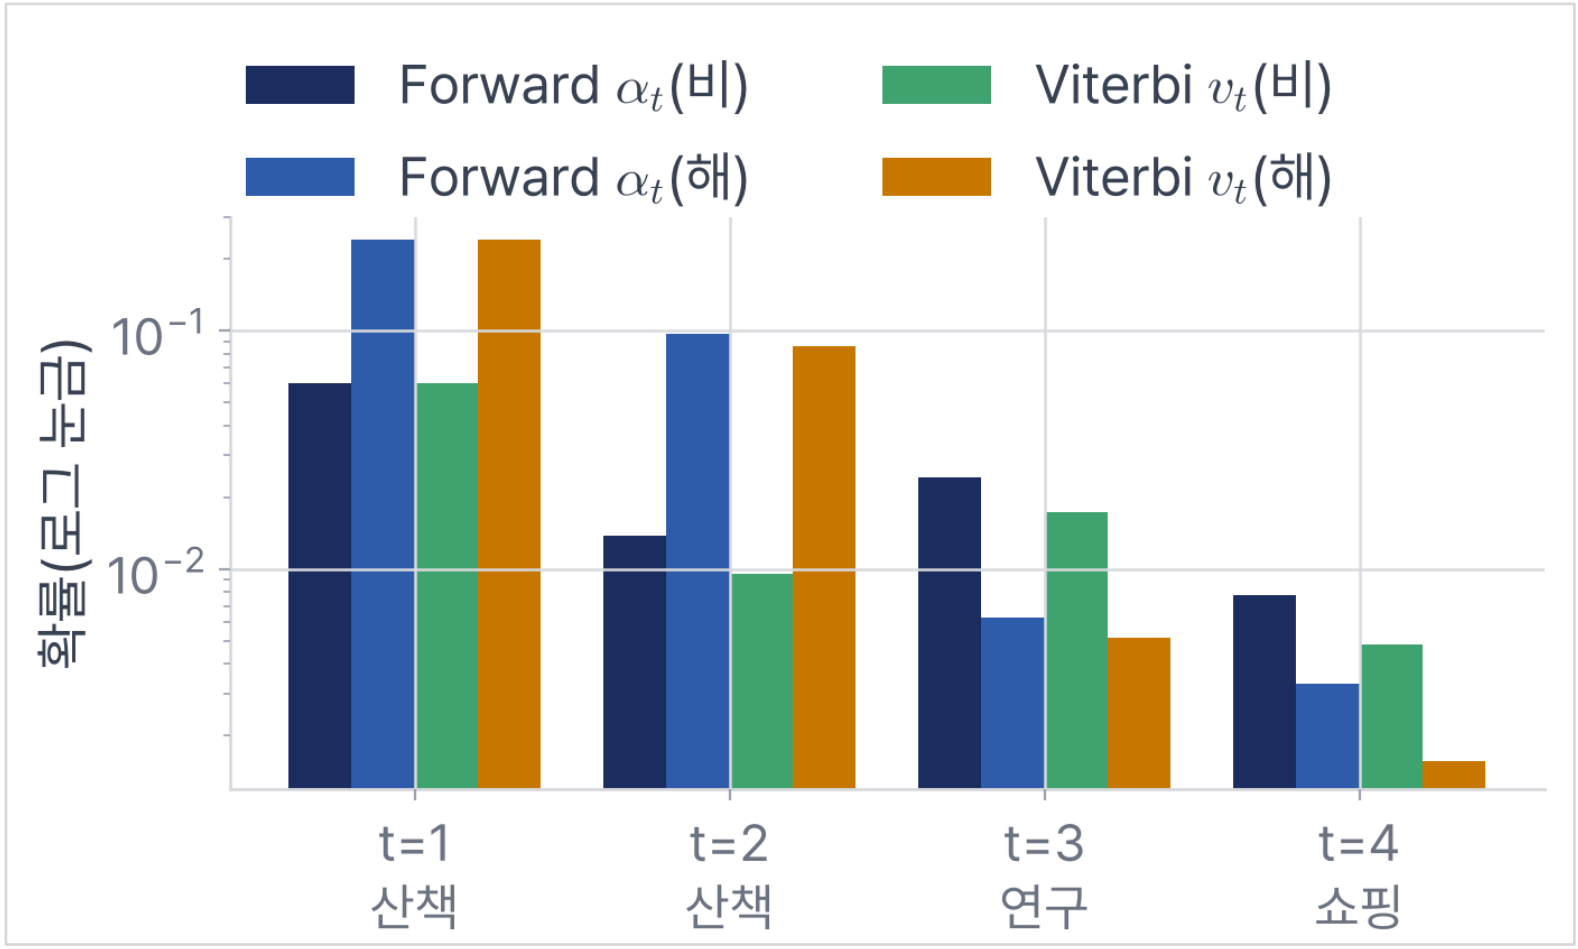
가능한 모든 경우의 확률의 最大

경로 확률은 어느 단계에서도 전체 확률을 넘지 않는다

예제의 값, 로그 눈금

볼 점

- 1일째: 같다
- 이후: max ≤ 합
- 차이 = 나머지 경로



05

5부 · 학습

파라미터 학습과 Baum-Welch 알고리즘

관측 시퀀스에서 λ* 찾기

학습은 데이터가 나타날 가능성을 가장 크게 하는 파라미터를 고른다

최대우도법(maximum likelihood method)

$$\lambda^* = \arg\max_\lambda \; P(O \mid \lambda)$$

아이디어

- 관측 시퀀스가 하나든 여럿이든, P(O | λ)를 최대화하는 HMM을 찾는다
- λ = {A, B, π}: π (n), A (n×n), B (n×m)

학습은 초기 모형을 충분히 좋아질 때까지 개선한다

입력: HMM 구조 · 출력: λ* = {A*, B*, π*}

절차

- 1 HMM 초기화
- 2 P(O|λ)가 더 높은 λ_new 찾기
- 3 멈추거나 2 반복

- Input: HMM(λ) architecture
- Output: HMM(λ^*)=$\{\mathbf{A}^*, \mathbf{B}^*, \boldsymbol{\pi}^*\}$
- Algorithm

$$\pi = \begin{bmatrix} \pi_1 \\ \pi_2 \\ \pi_3 \end{bmatrix}, A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}, B = \begin{bmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \\ b_{31} & b_{32} & b_{33} \end{bmatrix}$$

① HMM 초기화

② 적절한 방법으로 P(O|HMM(λ^{new})) > P(O|HMM(λ))를 찾아라.

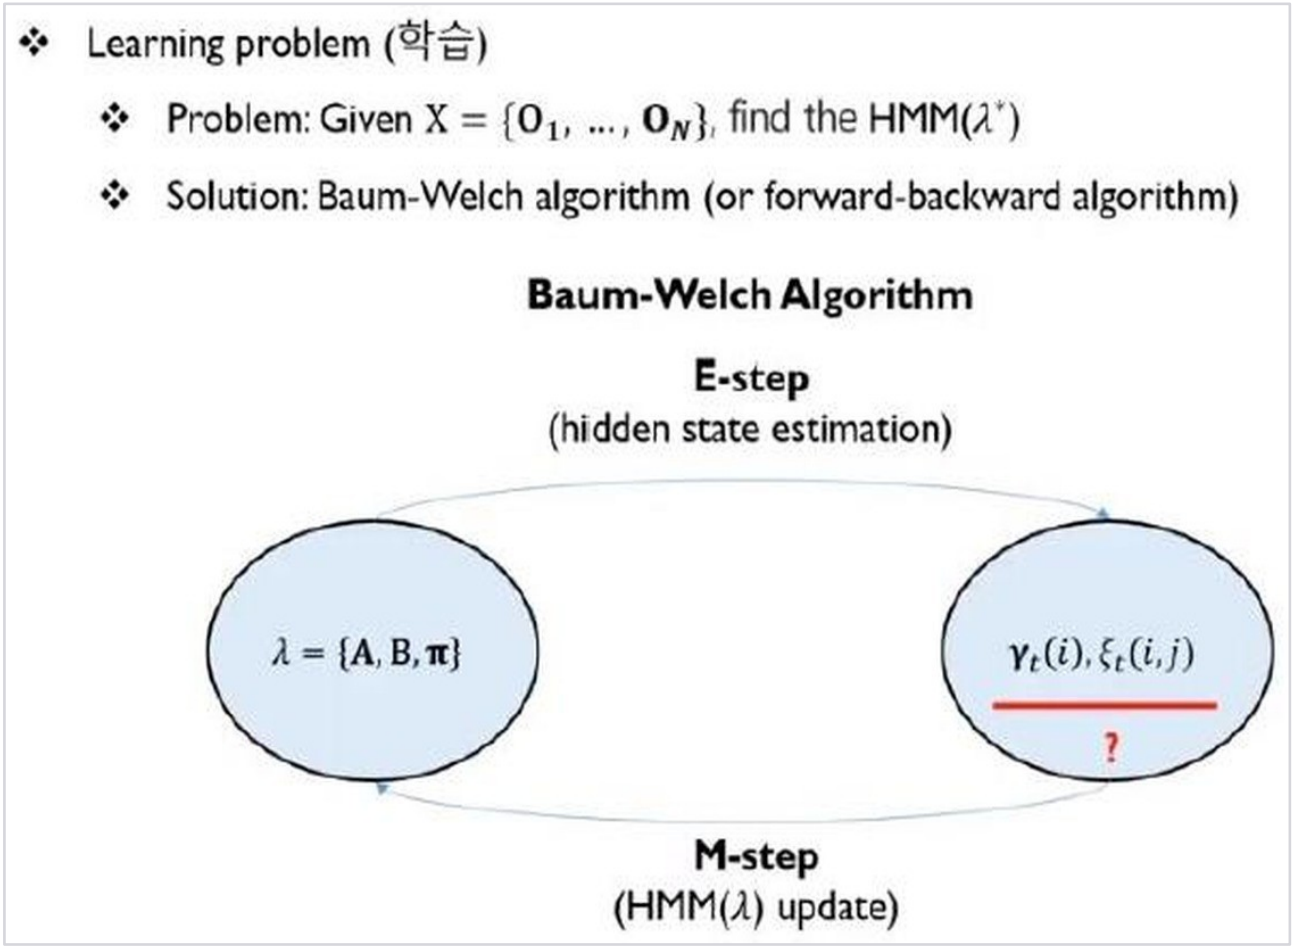
③ 만족스러우면 $\hat{\lambda}$ = HMM(λ^{new})으로 설정하고 멈춤, 혹은 ② 반복

Baum-Welch 알고리즘은 은닉상태 추정과 파라미터 갱신을 번갈아 수행한다

EM 알고리즘의 하나로, Forward-Backward 알고리즘이라고도 한다

두 단계

- E 단계: α, β로 γ, ξ 계산
- M 단계: λ 갱신
- 수렴할 때까지 반복

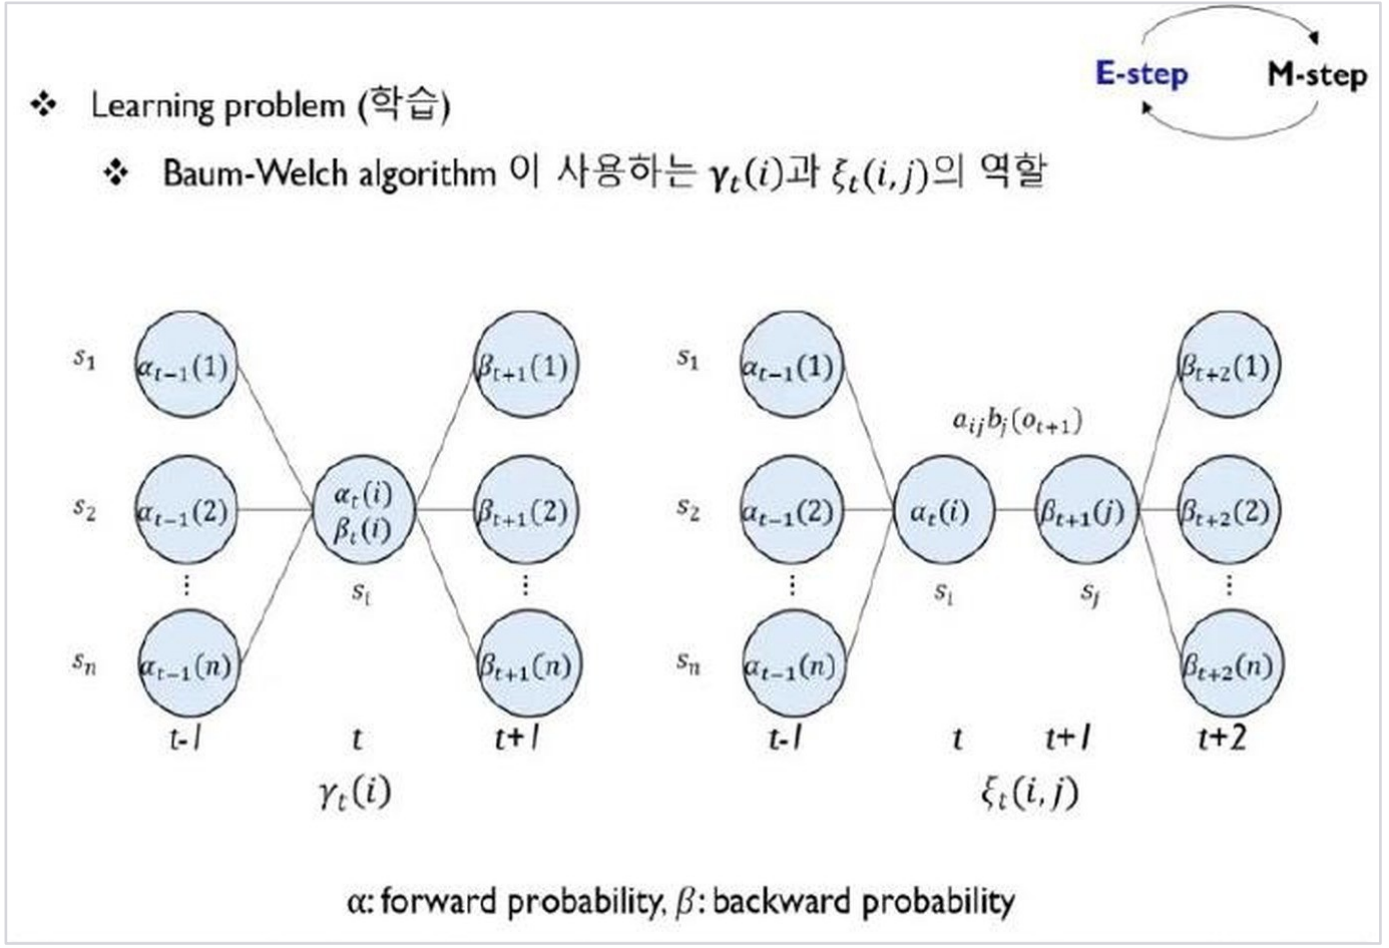


γ와 ξ는 한 시점을 중심으로 Forward 확률과 Backward 확률을 결합한다

γ_t(i): 시점 t의 한 상태 · ξ_t(i,j): t에서 t+1로의 전이

두 가지 값

- γ: t에 상태 i
- ξ: t에 i, t+1에 j
- α = 왼쪽, β = 오른쪽



γ는 상태 i를 지나는 모든 경로의 확률을 정규화한다

α_t(i)β_t(i) = 시점 t에 상태 i를 지나는 모든 경로의 확률

$$\gamma_t(i) = p(q_t = s_i \mid O, \lambda) = \frac{\alpha_t(i)\,\beta_t(i)}{\sum_{j=1}^{n} \alpha_t(j)\,\beta_t(j)}$$

읽는 법

- 분자: t에 s_i를 지나는 경로 · 분모: 같은 값을 모든 상태에 대해 합산

ξ는 a·b로 시점 t의 상태 i와 시점 t+1의 상태 j를 잇는다

가운데 항 a_ij b_j(o_{t+1})가 두 상태를 연결한다

$$\xi_t(i,j) = \frac{\alpha_t(i)\, a_{ij}\, b_j(o_{t+1})\, \beta_{t+1}(j)}{\sum_{i=1}^{n}\sum_{j=1}^{n} \alpha_t(i)\, a_{ij}\, b_j(o_{t+1})\, \beta_{t+1}(j)}$$

읽는 법

- E 단계 = α, β를 구한 뒤 γ_t(i)와 ξ_t(i,j) 계산
- M 단계는 이 값으로 P(O | λ_new) > P(O | λ)인 λ_new를 만든다

새 파라미터는 각각 기대 횟수의 비율이다

기대 전이 횟수 ÷ 기대 방문 횟수, 기대 방출 횟수 ÷ 기대 방문 횟수

$$\pi_i^{new} = \gamma_1(i)$$

$$a_{ij}^{new} = \frac{\sum_{t=1}^{T-1} \xi_t(i,j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$

$$b_i(v_k)^{new} = \frac{\sum_{t=1,\ o_t=v_k}^{T} \gamma_t(i)}{\sum_{t=1}^{T} \gamma_t(i)}$$

말로 풀면

- π: t = 1에 상태 i에 있을 비율
- a_ij: i→j 이동 ÷ i에서 나가는 이동
- b_i(v_k): v_k가 관측된 i 방문 ÷ i 방문

우도 증가분이 임계값 아래로 내려가면 학습을 멈춘다

또는 우도 자체가 목표 수준을 넘으면 멈춘다

중단 규칙

- a. 증가분 < r → 중단
- b. P(O|λ_new) > r → 중단
- 그 외에는 2단계 반복

❖ Procedure of HMM Learning

- ❖ Input: HMM(λ) architecture
- ❖ Output: HMM(λ^*)={$\mathbf{A}^*, \mathbf{B}^*, \boldsymbol{\pi}^*$}
- ❖ Algorithm

① HMM 초기화

② 적절한 방법으로 P(O|HMM(λ^{new})) > P(O|HMM(λ))를 찾자

③ 만족스러우면 $\hat{\lambda}$ = HMM(λ^{new})으로 설정하고 멈춤, 혹은 ② 반복

만족이란?

a. 특정 threshold(r) 값 **이하**인 경우 만족
   - If P(O|HMM(λ^{new})) - P(O|HMM(λ^{old})) is less than r, Stop

b. 특정 threshold(r) 값 **이상**인 경우 만족
   - If P(O|HMM(λ^{new})) is greater than r, Stop

전체 알고리즘은 짧은 의사코드 반복문으로 표현된다

FORWARD-BACKWARD(관측값, 어휘, 은닉상태 집합)

반복문

- A, B 초기화
- E 단계: γ, ξ
- M 단계: â, b̂
- 수렴할 때까지

❖ Pseudocode for Baum-Welch algorithm

function FORWARD-BACKWARD(*observations* of len T, *output vocabulary* V, *hidden state set* Q) **returns** $HMM=(A,B)$

initialize A and B

iterate until convergence

E-step

$$\gamma_t(j) = \frac{\alpha_t(j)\beta_t(j)}{\alpha_T(q_F)} \quad \forall t \text{ and } j$$

$$\xi_t(i,j) = \frac{\alpha_t(i)a_{ij}b_j(o_{t+1})\beta_{t+1}(j)}{\alpha_T(q_F)} \quad \forall t,\ i,\ \text{and } j$$

M-step

$$\hat{a}_{ij} = \frac{\sum_{t=1}^{T-1}\xi_t(i,j)}{\sum_{t=1}^{T-1}\sum_{k=1}^{N}\xi_t(i,k)}$$

$$\hat{b}_j(v_k) = \frac{\sum_{t=1 s.t.\ O_t=v_k}^{T}\gamma_t(j)}{\sum_{t=1}^{T}\gamma_t(j)}$$

return A, B

λ = (A, B, π)와 세 문제로 HMM을 요약한다

평가 → Forward · 디코딩 → Viterbi · 학습 → Baum-Welch

정리

- 평가: P(O|λ)
- 디코딩: 최적 S
- 학습: λ*

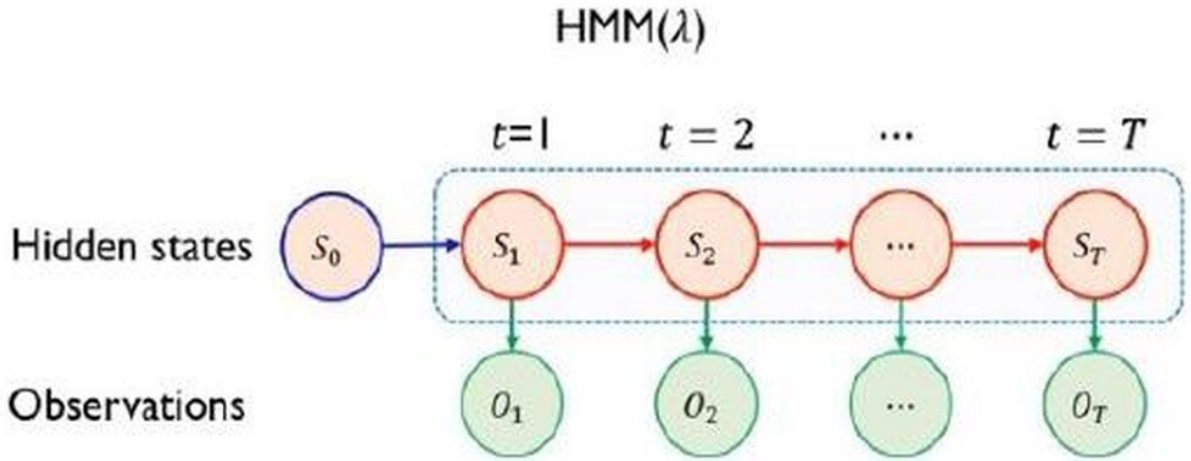
❖ Summary of hidden Markov model $\lambda = (A, B, \pi)$

❖ Three problems of hidden Markov model

① Given HMM (λ^*) and $\mathbf{O}$, find the probability of $\mathbf{O}$ → **Evaluation** problem

② Given HMM (λ^*) and $\mathbf{O}$, find the optimal $\mathbf{S}$ → **Decoding** problem

③ Given $X = \{\mathbf{O_1}, \ldots, \mathbf{O_N}\}$, find the HMM ($\lambda^*$) → **Learning** problem



06

6부 · 응용

응용

실무에서 쓰는 분류와 상태 판독

평가로 새 생산 경로를 정상 또는 불량으로 분류한다

관측값: 설비 ID · 은닉상태: 공정 ID

방법

- HMM(정상), HMM(불량) 학습
- 제품 3001을 각 모형으로 평가
- arg max P(O|HMM) 선택

❖ HMM Evaluation Application

- 관측 시퀀스: 설비 ID 데이터
- 은닉 시퀀스: 공정 ID 데이터

Equipment Sequence Data in Manufacturing Processes

Time

	공정1	공정2	공정3	공정4	공정5	공정6	공정7	공정8	공정9	공정10	품질
1	설비1	설비2	설비1	설비1	설비2	설비1	설비4	설비2	설비2	설비1	정상
2	설비2	설비4	설비2	설비2	설비4	설비2	설비4	설비2	설비4	설비2	정상
…	…	…	…	…	…	…	…	…	…	…	…
2999	설비4	설비1	설비2	설비4	설비6	설비5	설비5	설비1	설비2	설비3	불량
3000	설비5	설비5	설비1	설비3	설비1	설비5	설비1	설비3	설비1	설비1	불량

→HMM(정상)

→HMM(불량)

Argmax $P(O_{3001}|HMM(class)$ … class={정상or불량}
class

3001	설비5	설비5	설비1	설비3	설비4	설비5	설비1	설비3	설비1	설비1	?

디코딩으로 뇌파(EEG)·근전도(EMG) 신호에서 수면 단계를 판별한다

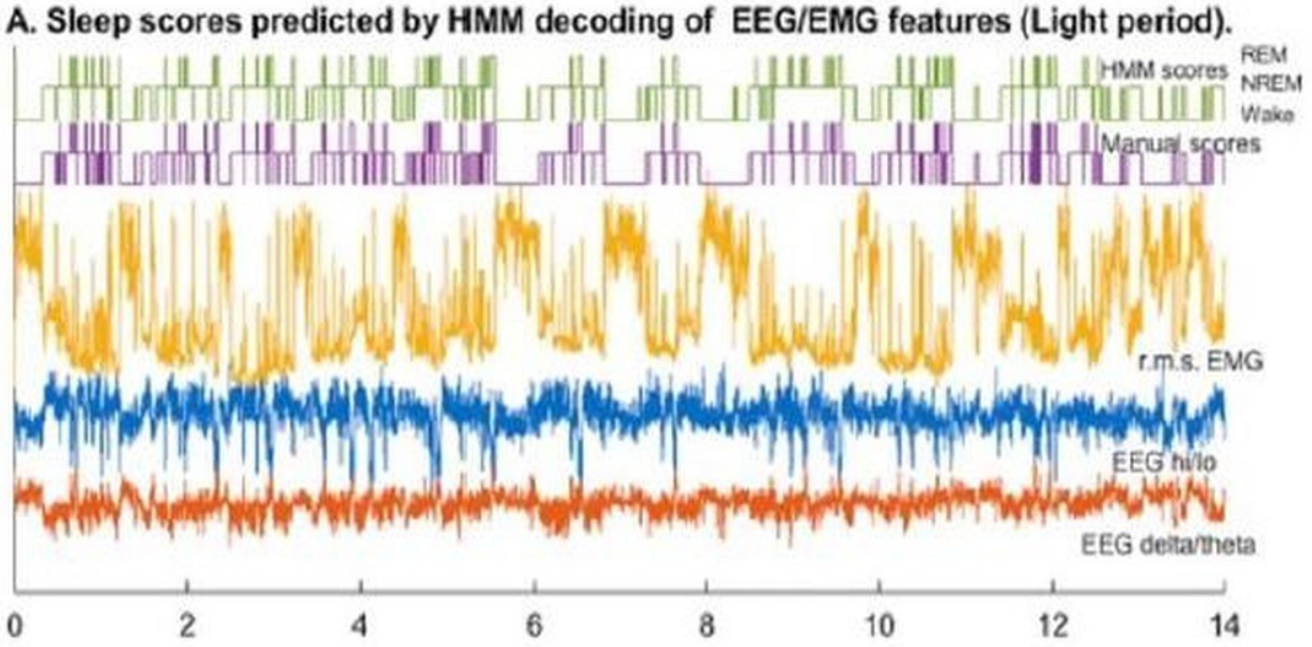
은닉상태: REM, NREM, 각성(Wake). HMM 판정이 수동 판정과 비슷하게 움직인다

방법

- 관측값: EEG/EMG 피처
- Viterbi 알고리즘: 구간(epoch)별 단계
- 수동 판정과 비교

❖ HMM Decoding Application

- ➢ 관측 시퀀스: 수면 EEG 데이터
- ➢ 은닉 시퀀스: REM-수면, NREM-수면, Wake



원본 그림의 오타는 이 덱에서 바로잡았다

수치는 모두 다시 계산했고, 그림에는 바로잡은 값을 넣었다

원본 쪽	원본 표기	고친 표기
14, 16, 56–58쪽	B의 원소 a22, a32	b22, b32
17쪽	b_j(v_k)의 Σ가 j 기준	k 기준의 Σ
27쪽(덱에 없음)	P(O) = 0.00111	0.0111
37쪽	β1(2)·π1·b2(산책)	β1(2)·π2·b2(산책)
47쪽	t = 4의 b(연구)	b(쇼핑)
54–55쪽	b_i(o1), χ_t−1(j)	b_i(o_t), v_t−1(j)
12–14, 16쪽	a_ij 라벨이 a_ij = i→j와 어긋남	라벨을 a_ij = i→j에 맞춤
13, 14, 16쪽	B의 행 = 관측값(b_jk의 k = 상태)	B의 행 = 상태(b_jk = P(o_k | s_j))
14, 16쪽	Emisstion	Emission
22쪽	12행이 7행과 중복	12행 = 해, 해, 해, 비
58쪽	P(HMM(λ_new))	P(O|HMM(λ_new))

네 질문으로 세 문제를 제대로 이해했는지 점검한다

정 박사 예제를 떠올리며 답한다

Q1	Forward 알고리즘의 계산량은 N^2T인데 전수 열거는 왜 N^T인가?	**평가**
Q2	날마다 가장 확률이 높은 날씨가 Viterbi 경로와 다를 수 있는가?	**디코딩**
Q3	사흘 연속 연구가 관측되면 디코딩된 날씨에 가장 크게 작용하는 파라미터는 무엇인가?	**파라미터**
Q4	Baum-Welch 알고리즘은 국소 최적만 보장한다. 초기 λ는 어떻게 고르겠는가?	**학습**

격자 하나로 HMM의 세 질문에 모두 답한다

합산, 최대화, 재추정

1

평가는 합산한다

예제에서 Forward 또는 Backward 재귀식으로 $P(O|\lambda) = 0.0111$을 얻는다.

2

디코딩은 최대화한다

Viterbi 알고리즘과 역추적 포인터로 해 → 해 → 비 → 비를 얻는다.

3

학습은 재추정한다

Baum-Welch 알고리즘은 α, β로 γ, ξ를 구하고 수렴할 때까지 A, B, π를 갱신한다.

다음: 금융 시계열의 국면 탐지에 HMM 적용.