강의 · 금융과 HMM

금융 시장의 은닉 마르코프 모형

개요, 주가 예측, 정보 거래

은닉 마르코프 모형(Hidden Markov Model, HMM) 기초 → 모형 선택 → 수익률 국면 → 금리 캐리 → PIN · VPIN

이 덱의 그림은 모두 원래 강의 슬라이드에서 가져왔다.
AAPL, KOSPI, EUR/USD 선물 데이터로 hmmlearn 실습을 진행했다.

시장은 직접 관측되지 않는 국면 사이를 오간다

이번 강의의 세 가지 핵심

1

가격과 주문 흐름은 은닉상태가 방출한 관측값이다

가우시안 HMM에서는 은닉상태마다 수익률이나 주문 흐름의 분포가 따로 있다.

2

정보기준으로 상태 수를 정한다

AIC(아카이케 정보기준)와 BIC(베이즈 정보기준)는 우도와 파라미터 수 $N^2 + 2N - 1$ 사이의 절충을 평가한다.

3

디코딩한 상태가 매매 신호가 된다

수익률 국면, 캐리 위험 프리미엄, 정보 보유 거래자의 활동을 모두 같은 방법으로 추정한다.

한 모형으로 세 시장을 다룬다: 주식, 금리, 외환 주문 흐름.

01

PART 1 · HMM 개요

은닉 마르코프 모형 개요

마르코프 성질, 방출, 세 가지 문제

마르코프 모형에서 과거는 가장 최근 상태를 통해서만 영향을 준다

기본 정의: 전이확률(transition probability)

$$P\Big(Z(t+1) \mid Z(1), \ldots, Z(t)\Big) = P\Big(Z(t+1) \mid Z(t)\Big)$$

왜 중요한가

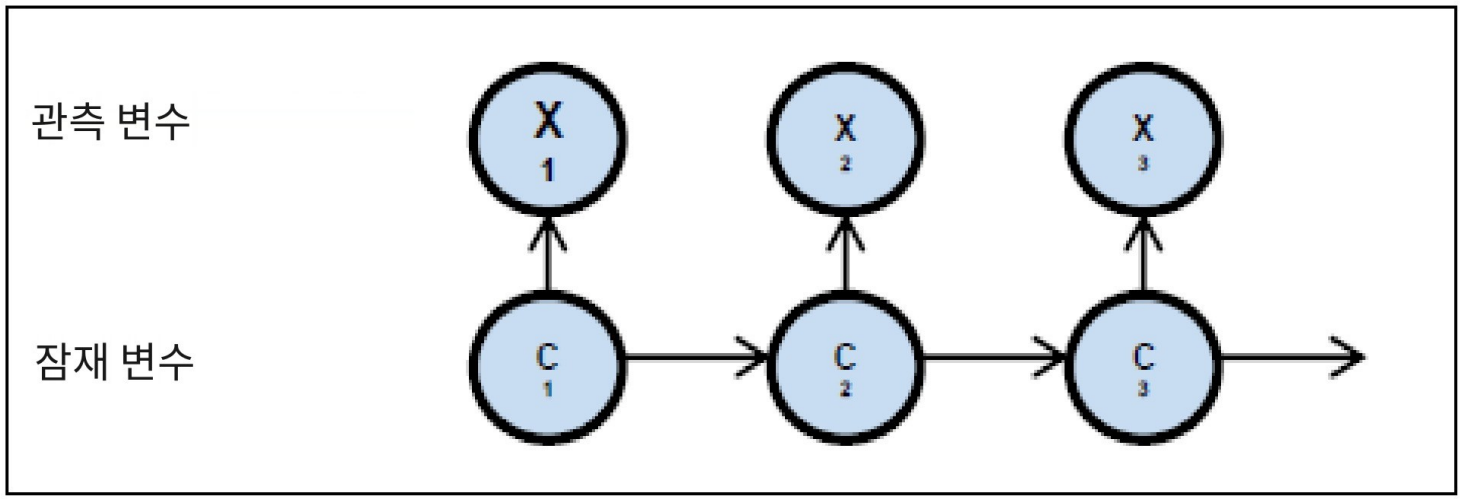
- 전체 이력 Z(1)...Z(t)가 Z(t) 하나로 요약된다
- 모형에는 상태 전이 확률 행렬(전이행렬)만 있으면 된다

HMM은 현재 은닉상태에만 의존하는 관측값을 더한다

잠재변수 C_t는 마르코프 체인을 이루고, 관측값 X_t는 C_t에 의존한다

두 가지 가정

- 은닉상태 체인은 마르코프 성질을 따름
- X(t)는 Z(t)에만 의존
- 오른쪽 그림이 예시



$$P\Big(Z(t) \mid Z(1), \ldots, Z(t-1)\Big) = P\Big(Z(t) \mid Z(t-1)\Big)$$

$$P\Big(X(t) \mid X(1), \ldots, X(t-1), Z(1), \ldots, Z(t)\Big) = P\Big(X(t) \mid Z(t)\Big)$$

HMM의 세 가지 문제에는 각각 알고리즘이 있다

초기 상태 확률, 전이확률, 방출 확률이 모형을 정의한다

평가(Evaluation)

Forward-Backward 알고리즘

초기·전이·방출 확률이 주어졌을 때 관측열 X의 확률을 계산한다.

디코딩(Decoding)

Viterbi 알고리즘

가장 가능성이 높은 은닉상태열 Z를 찾는다.

학습(Learning)

Baum-Welch 알고리즘

X만 주어졌을 때 초기·전이·방출 확률과 상태열 Z를 추정한다.

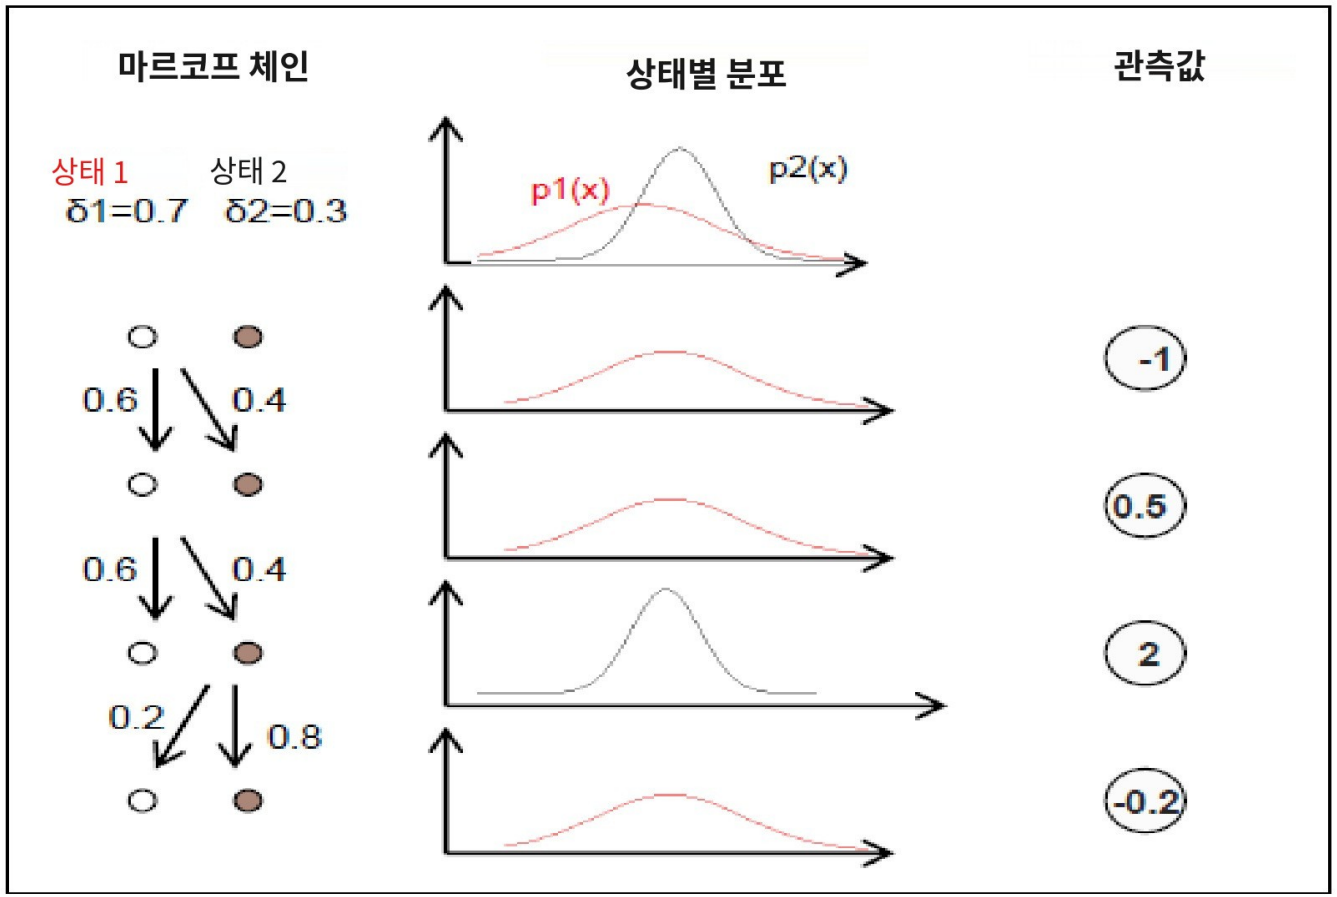
이번 강의에서는 hmmlearn 패키지로 세 문제를 모두 다룬다.

은닉상태마다 고유한 분포에서 관측값이 나온다

두 상태(δ1 = 0.7, δ2 = 0.3)가 −1, 0.5, 2, −0.2 같은 수익률을 방출한다

왼쪽부터 읽기

- 마르코프 체인이 상태를 옮김
- 상태마다 p(x)가 있음
- 시점마다 관측값 추출

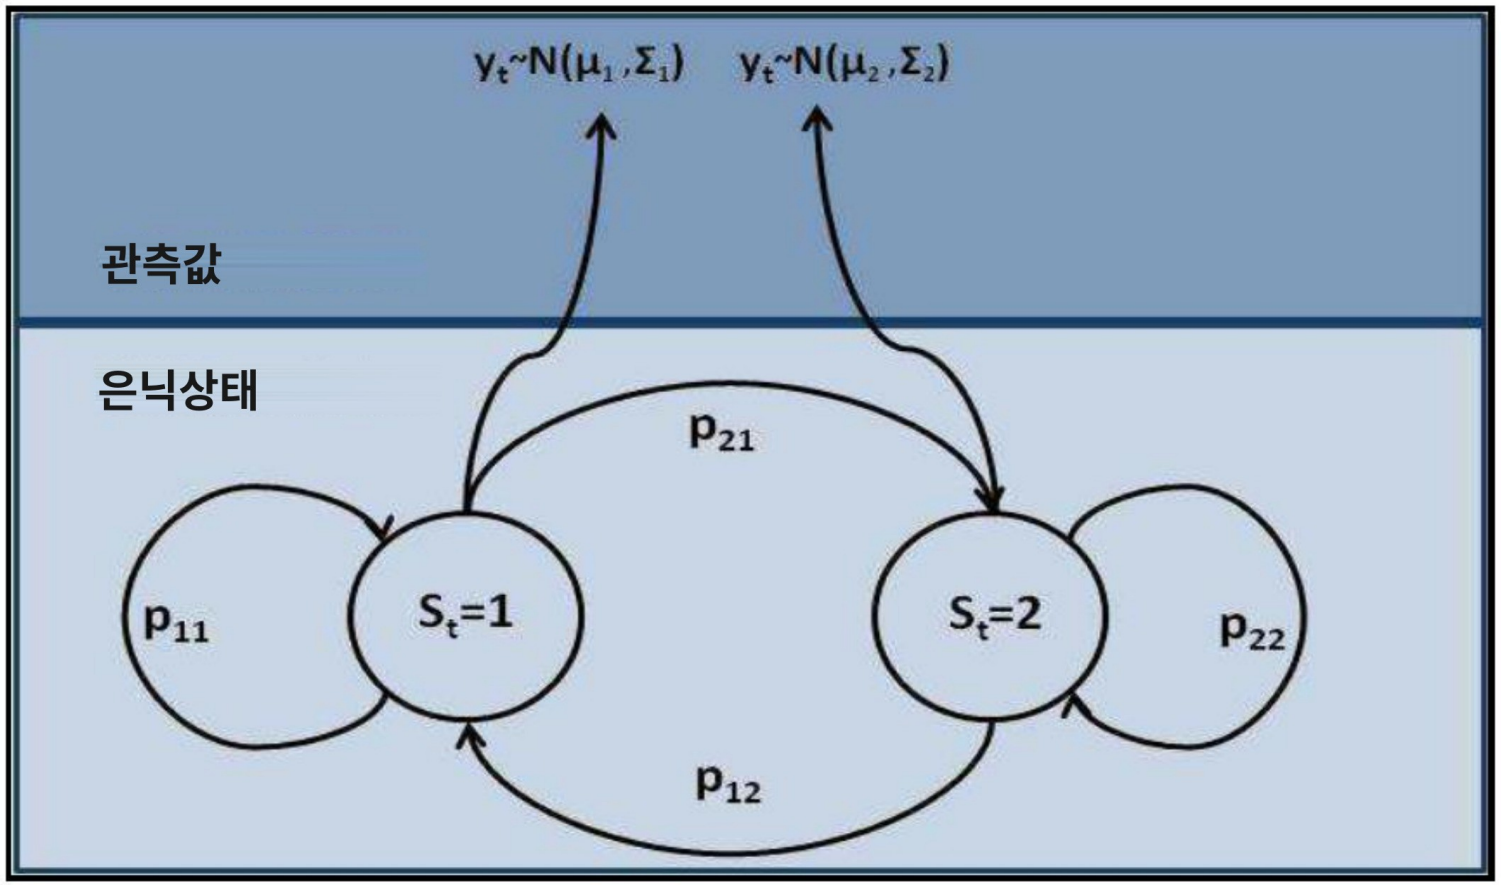


2상태 가우시안 HMM은 수익률 국면 분석의 기본 모형이다

상태 k에서 y_t ~ N(μ_k, Σ_k) · p_ij = 전이확률

모형

- S=1, S=2는 은닉상태
- p11, p22: 지속성
- 방출: 정규분포
- Baum-Welch 알고리즘으로 적합



02

PART 2 · 주가 예측

HMM을 활용한 주가 예측

AAPL과 KOSPI의 모형 선택, 가격 예측, 수익률 국면

정보기준으로 은닉상태 수를 고른다

가우시안 HMM, 상태 N개, 관측값 M개, Baum-Welch 알고리즘으로 파라미터 적합

이 쪽 읽기

- L: 우도
- M: 관측값 수
- k: 파라미터 수
- 논문: 상태 2~4개만

Hidden Markov Model(HMM)에서 은닉상태의 수를 선택하는 것은 중요한 작업이다. 일반적으로 AIC(Akaike Information Criterion)와 BIC(Bayesian Information Criterion)를 사용해 모델의 성능을 평가하며, 이는 Baum-Welch 알고리즘을 통해 최대 우도 추정을 수행할 때 적합하다. 본 연구에서는 상태 수를 2에서 4로 제한해 모델의 단순성과 실용성을 유지한다.

AIC와 BIC는 각각 다음 식으로 계산한다:

$$AIC = -2\ln(L) + 2k$$

$$BIC = -2\ln(L) + k\ln(M)$$

여기서:

- L은 모델의 우도 함수,
- M은 관측 포인트 수,
- k는 추정된 파라미터의 수이다.

각 은닉상태가 정규 분포를 따른다고 가정하며, HMM에서 상태의 수를 N이라 할 때, 파라미터의 수 k는 다음과 같이 정의한다:

$$k = N^2 + 2N - 1$$

시뮬레이션을 100번 수행하며, 각 스텝에서 이전 단계에서 추정된 파라미터를 초기값으로 설정하여 재추정하고, AIC와 BIC를 계산한다. 이를 통해 시뮬레이션 전반에 걸친 BIC 변화를 관찰한다.

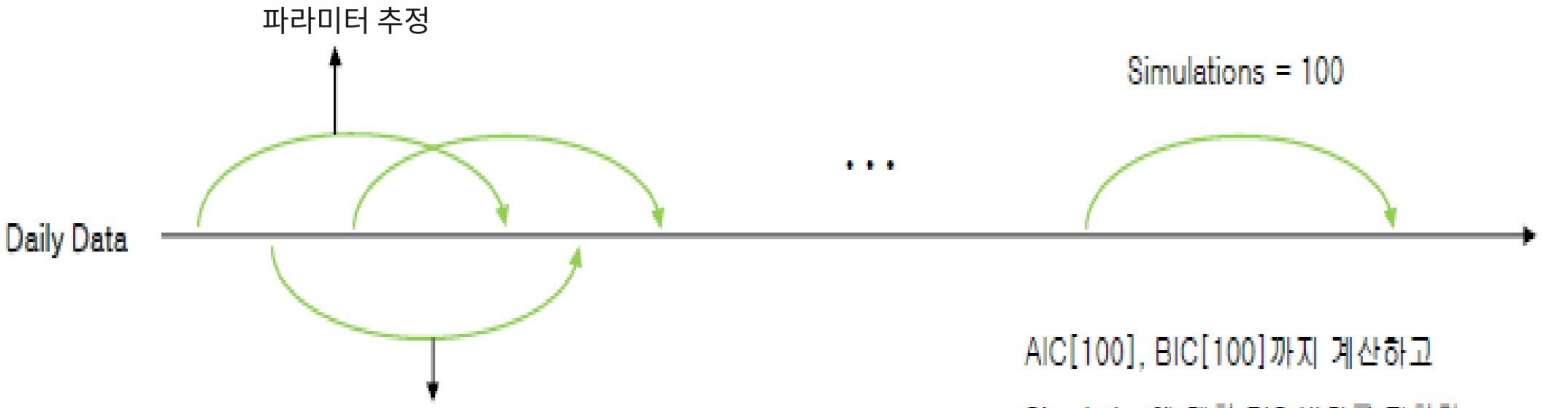
$$AIC = -2\ln(L) + 2k, \qquad BIC = -2\ln(L) + k\ln(M), \qquad k = N^2 + 2N - 1$$

반복 캘리브레이션으로 100회 시뮬레이션의 AIC·BIC를 추적한다

각 단계는 이전 단계의 파라미터 추정값에서 출발한다

캘리브레이션 반복

- 한 스텝 앞으로 이동
- 직전 λ에서 재추정
- AIC[i], BIC[i] 기록
- 100회 반복



이전 스텝에서 추정한 파라미터를 이번 스텝의 초깃값으로 설정한 후

다시 파라미터를 추정하고 AIC[1], BIC[1]을 계산함. → Calibration

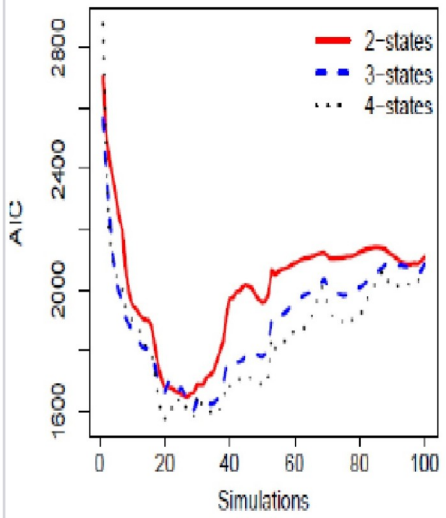
AAPL 논문에서는 상태 4개가 가장 낮고, BIC에서는 그 격차가 유지된다

애플 일별 데이터, 2015.1.6–2015.10.30 · 왼쪽 AIC, 오른쪽 BIC

논문 결과

- AIC: 상태 4개 최저, 격차 축소
- BIC: 상태 4개가 계속 최저
- 논문의 선택: 상태 4개
- 항상 U자형은 아님

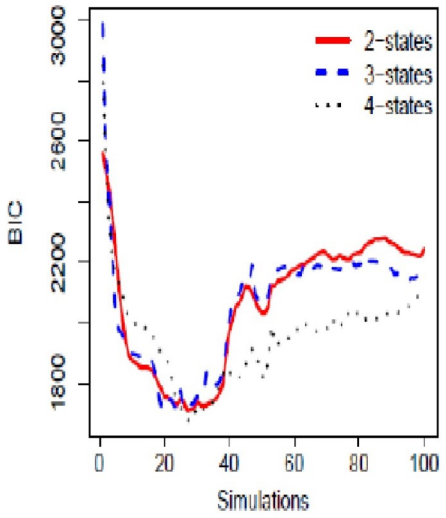
- State를 2,3,4로 변화해 가면서 이전 페이지 절차대로 AIC와 BIC를 측정한다.
- 아래 그림은 논문의 [Figure 1]으로 애플 종목의 상태 개수에 대한 AIC와 BIC의 변화를 보여준다.
- AIC의 경우 상태 개수 = 4일 때의 AIC가 작지만, Simulation이 증가할수록 모든 상태 개수에 대한 AIC가 수렴하고 있어 큰 차이가 없다. 그러나 BIC의 경우는 Simulation이 증가해도 상태 개수 = 4일 때가 작다. 따라서 애플 종목에 대해서는 상태 개수 = 4가 적당하다고 볼 수 있다 (논문의 내용임).
- 단, AIC나 BIC의 변화는 항상 아래와 같이 U-자형 모습을 보이는 건 아니다. 종목과 분석 기간에 따라 모양은 다를 수 있다.



종목 : 애플 (AAPL) Daily data

기간 : 2015.1.6 – 2015.10.30

Figure 1: AIC (left) and BIC (right) for 100 parameter calibrations of HMM using Apple, AAPL, stock daily trading prices



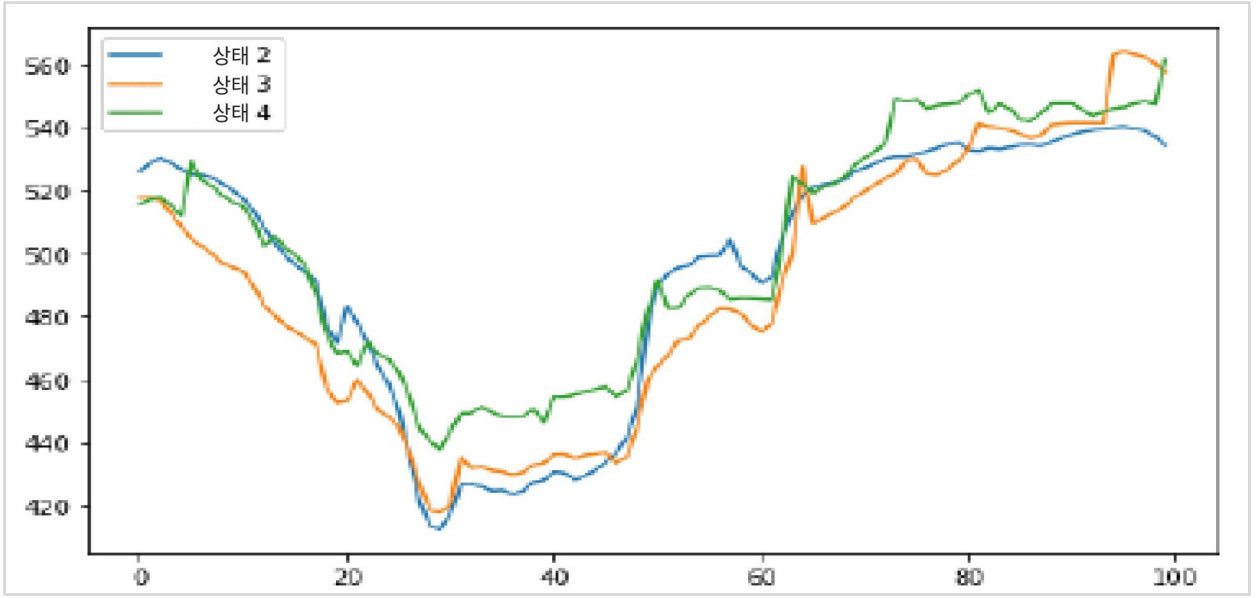
AAPL 종가만으로 BIC 비교를 다시 해 본다

hmmlearn, 논문과 같은 기간, 상태 2~4개

[입력] 프롬프트 · Claude Code (Code 탭)

다음을 하고 차트를 bic_close.png로 저장해 줘.

1. AAPL 일별 종가를 2015-01-06부터 2015-10-30까지 받아 줘. 입력은 종가만 써.
2. hmmlearn으로 가우시안 HMM을 상태 2, 3, 4개로 적합해 줘.
3. 시뮬레이션을 100회 돌려 줘. 한 스텝씩 앞으로 옮기고 직전 스텝의 파라미터에서 재추정해.
4. 스텝마다 BIC = −2 ln(L) + k ln(M), k = N^2 + 2N − 1을 계산해 줘.
5. 시뮬레이션별 BIC를 상태 수마다 곡선 하나로 그려 줘.



[확인] 결과에서 볼 점

· BIC가 낮을수록 좋음
· 어느 상태 수가 계속 가장 낮은가?
· p.12 논문의 BIC와 비교

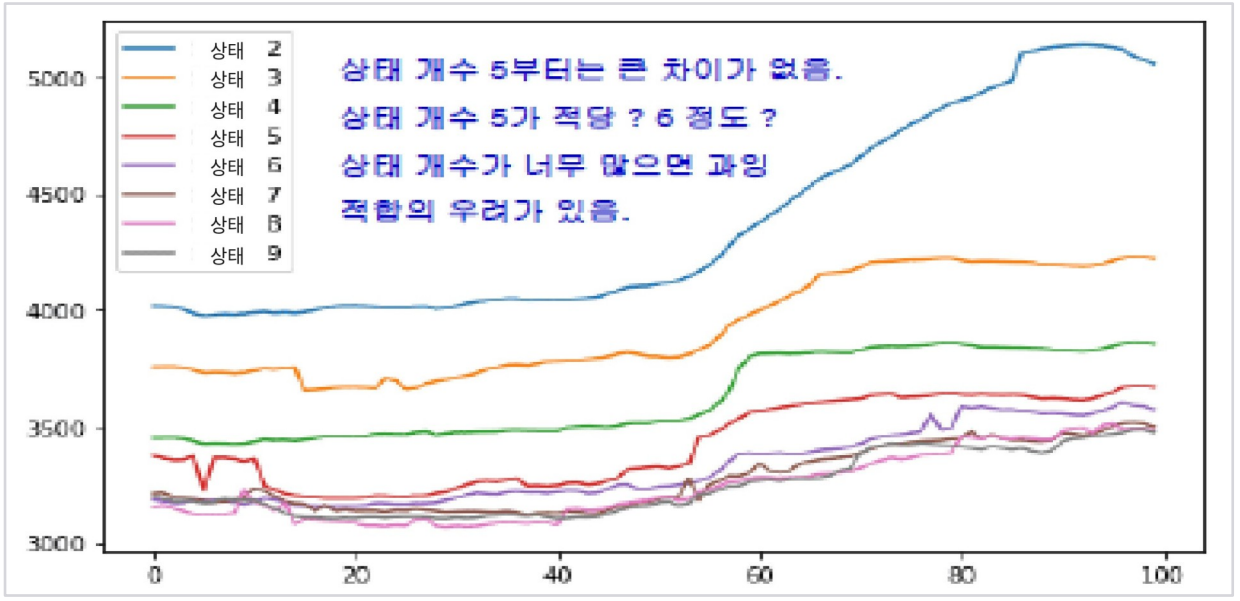
OHLC 입력에서는 상태가 약 5개를 넘으면 BIC 개선이 줄어든다

시가·고가·저가·종가(OHLC) · 상태 2~9개 · 상태가 너무 많으면 과적합 위험

[입력] 프롬프트 · Claude Code (Code 탭)

AAPL 실습을 반복하고 차트를 bic_ohlc.png로 저장해 줘.

1. 같은 기간에 시가, 고가, 저가, 종가를 입력으로 써.
2. 가우시안 HMM을 상태 2~9개로 적합해 줘.
3. 같은 캘리브레이션 반복을 100회 돌리고 스텝마다 BIC를 계산해 줘.
4. 시뮬레이션별 BIC를 상태 수마다 곡선 하나로 그려 줘.



[확인] 결과에서 볼 점

· 5~6개 이후 개선 미미
· N이 크면 과적합

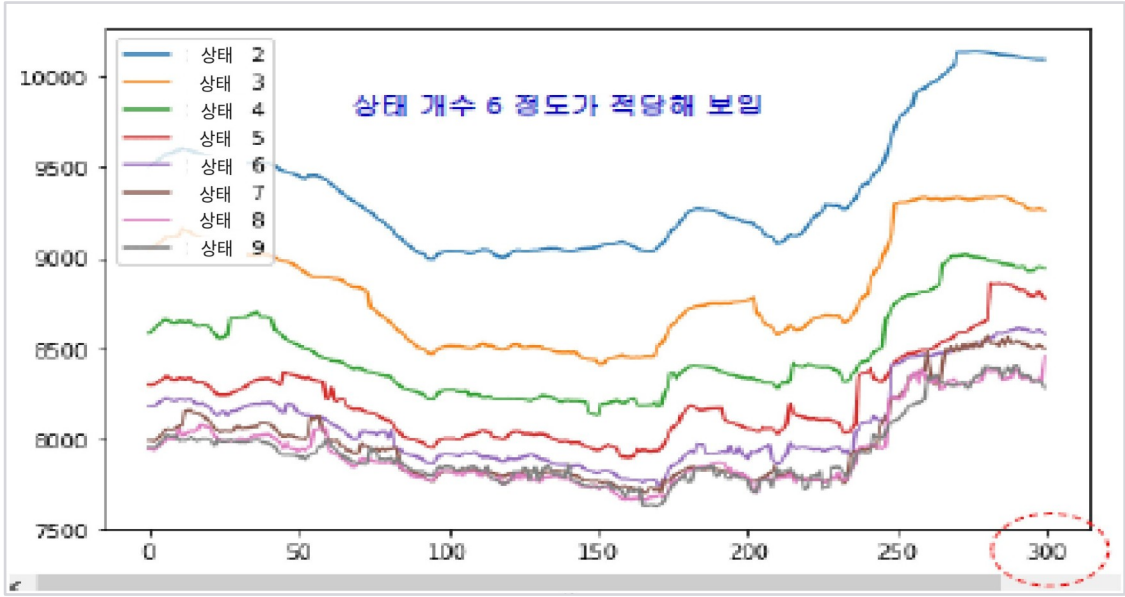
KOSPI 지수 데이터는 은닉상태 6~7개를 시사한다

슬라이드 본문은 7개, 차트 메모는 6개이며, 상태 6~9개의 곡선은 거의 겹친다

[입력] 프롬프트 · Claude Code (Code 탭)

다음을 하고 차트를 bic_kospi.png로 저장해 줘.

1. KOSPI 종합지수 일별 데이터를 받아 줘. 쓴 입력과 기간을 알려 줘.
2. 가우시안 HMM을 상태 2~9개로 적합해 줘.
3. 같은 캘리브레이션 반복으로 시뮬레이션을 300회 돌리고 스텝마다 BIC를 계산해 줘.
4. 시뮬레이션별 BIC를 상태 수마다 곡선 하나로 그려 줘.



[확인] 결과에서 볼 점

· 6~7개에서 곡선 수렴
· 더 작은 N 선택

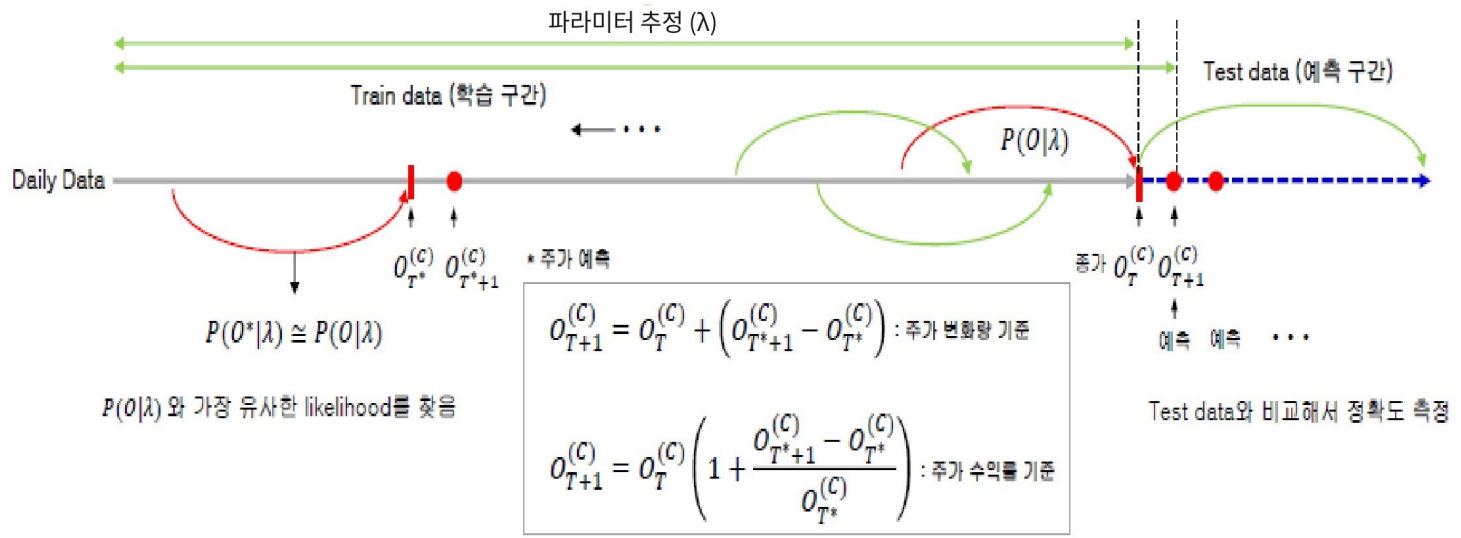
예측은 가장 비슷한 과거 날의 가격 변화를 가져다 쓴다

학습: λ 적합 · 오늘과 우도가 가장 가까운 날 찾기 · 그날의 변화 적용

세 단계

- 1 λ 캘리브레이션, P(O|λ) 계산
- 2 P가 비슷한 과거 날 찾기
- 3 그날의 변화를 오늘에 적용
- 두 방식: 가격 변화량 또는 수익률

▪ We first introduce how to predict stock prices using HMM. The prediction process can be divided by three steps. Step one: calibrate HMM's parameters and calculate likelihood of the model. Step 2: find a day in the past that has a similar likelihood to that of the recent day. Finally, step 3: use the difference of stock prices on the "similar" day in the past to predict future stock prices. This prediction approach is based on the work of Hassan and Nath [2]. ~~However, our procedure is different from their method in that we put the sign of the difference of the likelihood of recent day with likelihood of the "similar" day in the past into the calculation of future stock prices~~. Furthermore, we do not only use HMM with multiple observations (open, low, high, close price), as in [2], but also the HMM with one observation data (close price) to predict future close price. By using both single and multiple observations to predict stocks' close prices, we can examine which method performed better. The HMM with a single observation is a special case of HMM with multiple observations, thus we will explain in detail how to use HMM with multiple observations.

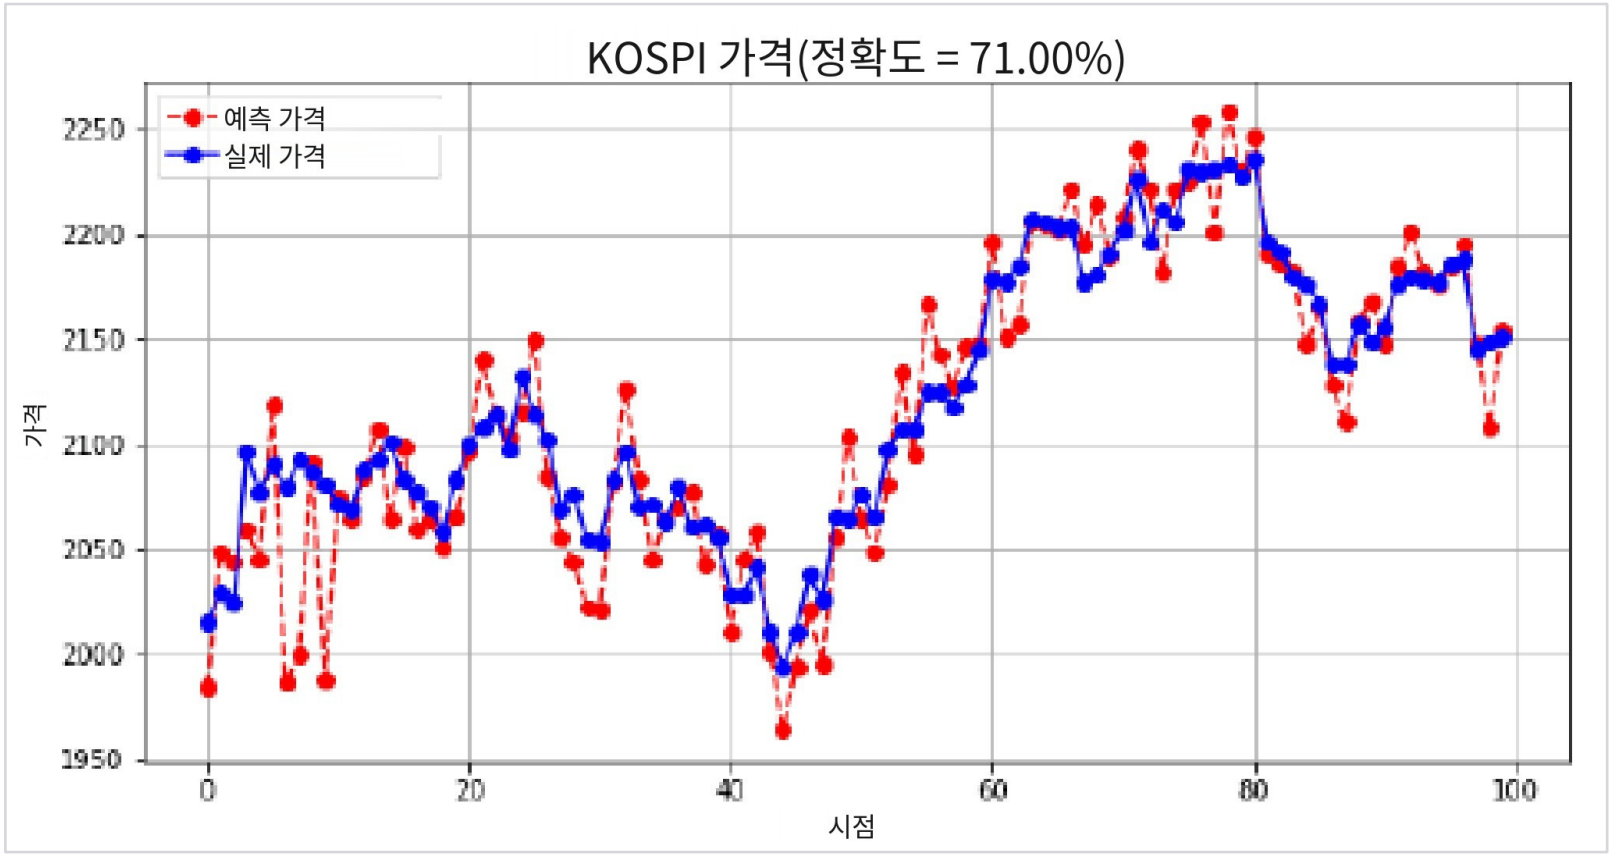


롤링 예측은 최근 100일의 KOSPI를 따라간다

시험 구간에서 보고된 정확도는 71.00%다

결과

- 빨강: 예측 가격
- 파랑: 실제 가격
- 정확도 = 71.00%
- 같은 논리 → 내일 예측



3상태 HMM은 KOSPI 수익률을 서로 다른 국면으로 나눈다

상태별 평균·변동성 추정치와 전이행렬

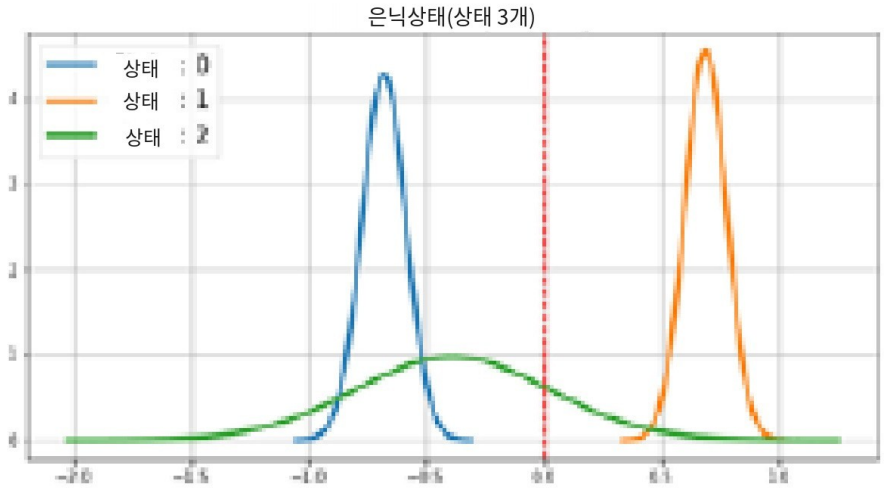
추정치

- μ: −0.681, 0.688, −0.389
- σ: 0.093, 0.088, 0.411
- 대각 원소: 0.855, 0.90, 0.932
- 국면 지속성이 높다

```
mu :
 [[-0.681]
 [ 0.688]
 [-0.389]]

vol :
 [[0.093]
 [0.088]
 [0.411]]
```

3개의 주가 수익률 분포의 평균과 표준편차




```
전이행렬 :
 [[0.855 0.118 0.027]
 [0.099 0.9   0.002]
 [0.017 0.051 0.932]]
```

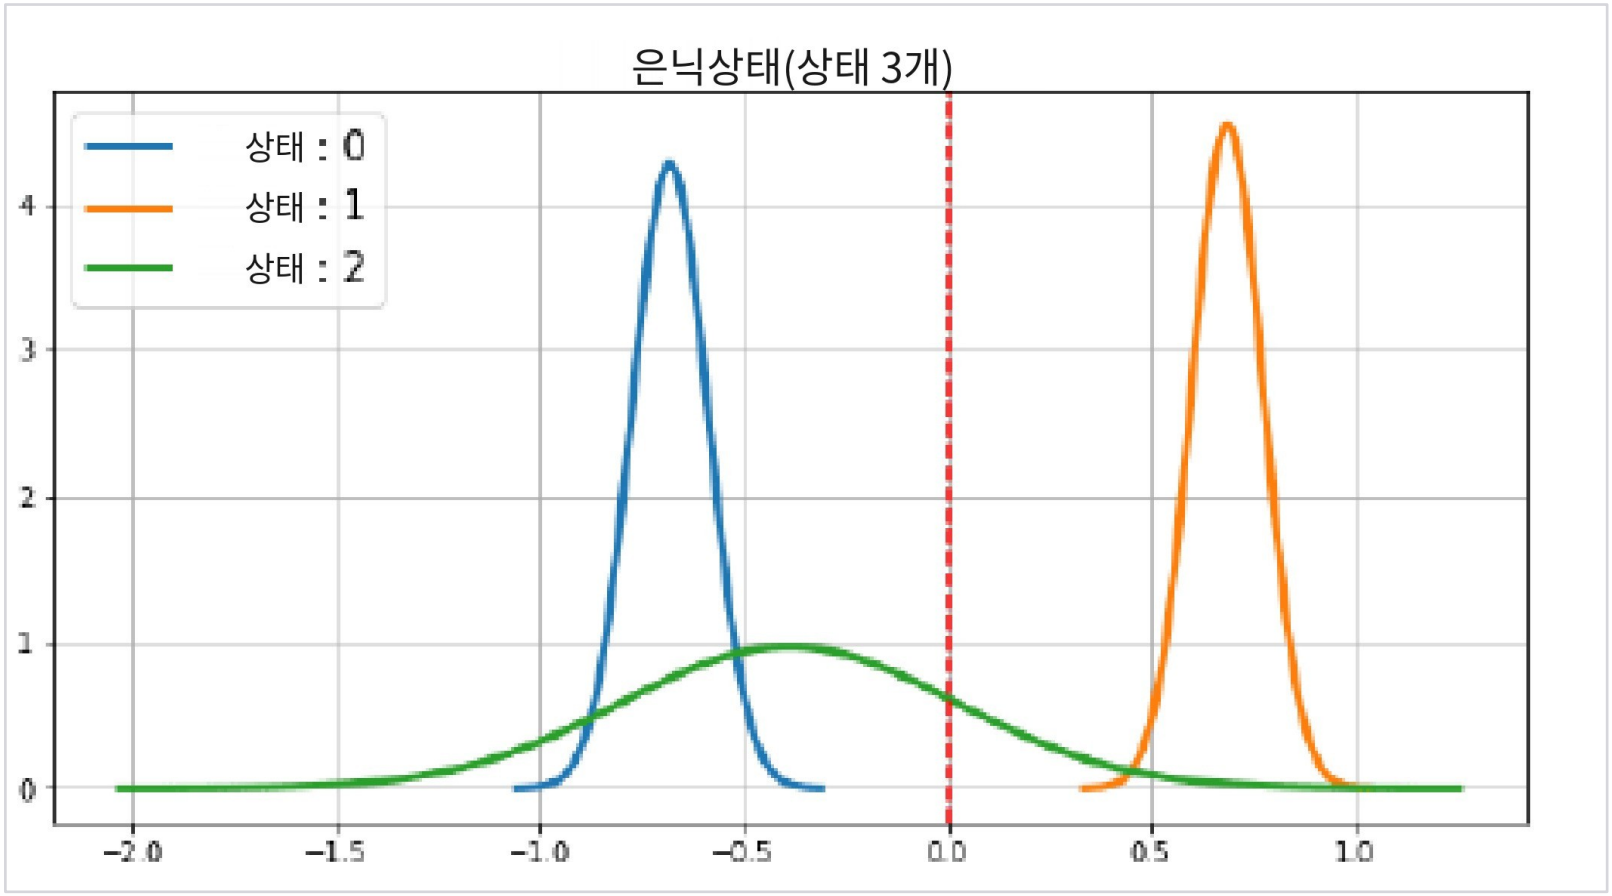
← 3개의 주가 수익률 분포의 전이확률

수익률 분포를 보면 평온한 상태 2개와 변동성 높은 상태 1개로 나뉜다

상태 0: 음의 평균 · 상태 1: 양의 평균 · 상태 2: 넓은 분포

곡선 읽기

- 파랑: 평온한 하락장
- 주황: 평온한 상승장
- 초록: 고변동성
- 빨간 선: 수익률 0



최근 300일 KOSPI 종가가 기준 그림이다

2018-01~2019-03 일별 종가

먼저 볼 것

- 2018년 초 고점
- 2018년 말까지 하락
- 2019년 일부 반등

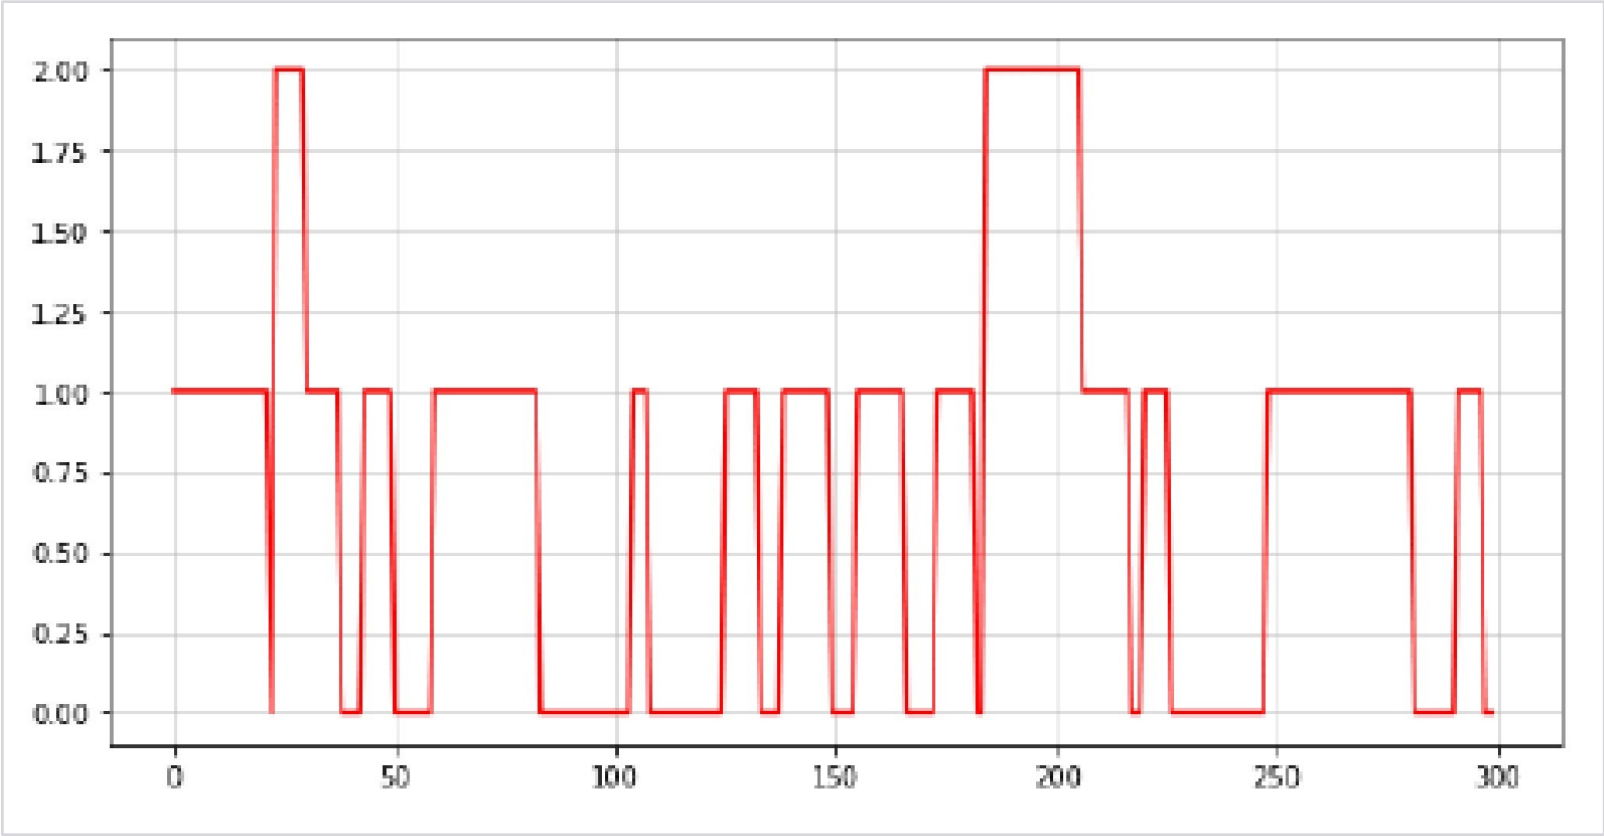


디코딩한 상태 경로에서 시장의 국면 전환 시점을 볼 수 있다

최근 300일 · 현재 상태 0(원본 슬라이드 표기: 평균 −0.681, 표준편차 0.093)

경로 읽기

- y축: 상태 0, 1, 2
- 2로 급등: 시장 스트레스
- 현재: 상태 0



파라미터·분포·상태 경로를 함께 보면 해석이 일관된다

주가 수익률 상태 변화 실습(KOSPI) 요약

종합

- 표: μ, σ, A
- 곡선: 상태별 수익률
- 오른쪽 위: 상태 경로
- 오른쪽 아래: 가격

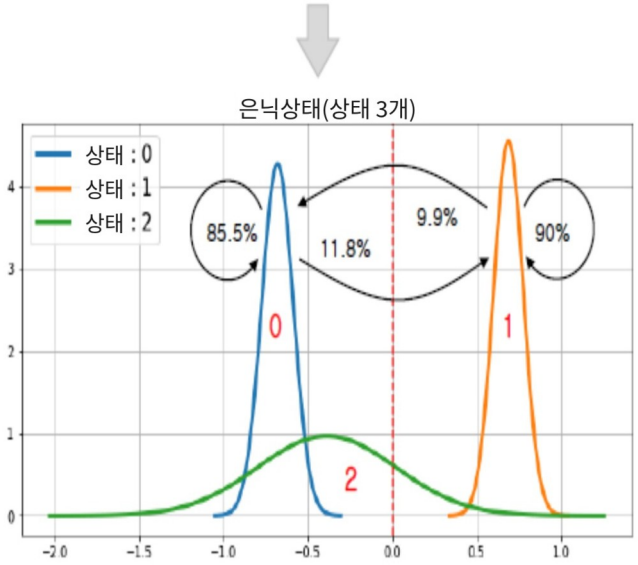
□ 주가 수익률 상태 변화 실습

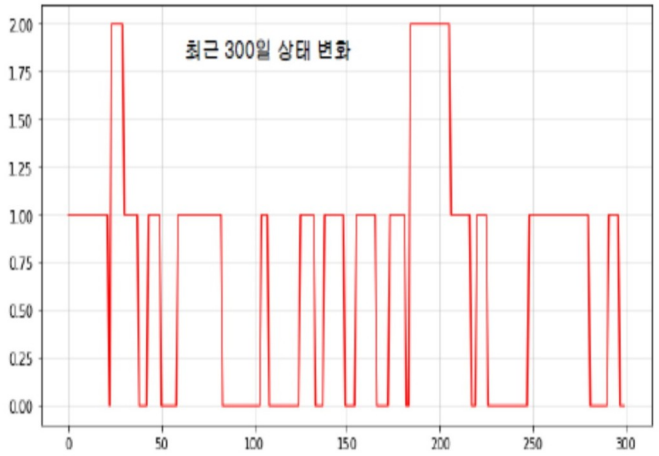
▪ 상태

상태	평균	표준편차
0	-0.681	0.093
1	0.688	0.088
2	-0.389	0.411

▪ 전이확률

상태	0	1	2
0	0.855	0.118	0.027
1	0.099	0.9	0.002
2	0.017	0.051	0.932







03

PART 3 · 금리 캐리

HMM을 활용한 금리 캐리 전략

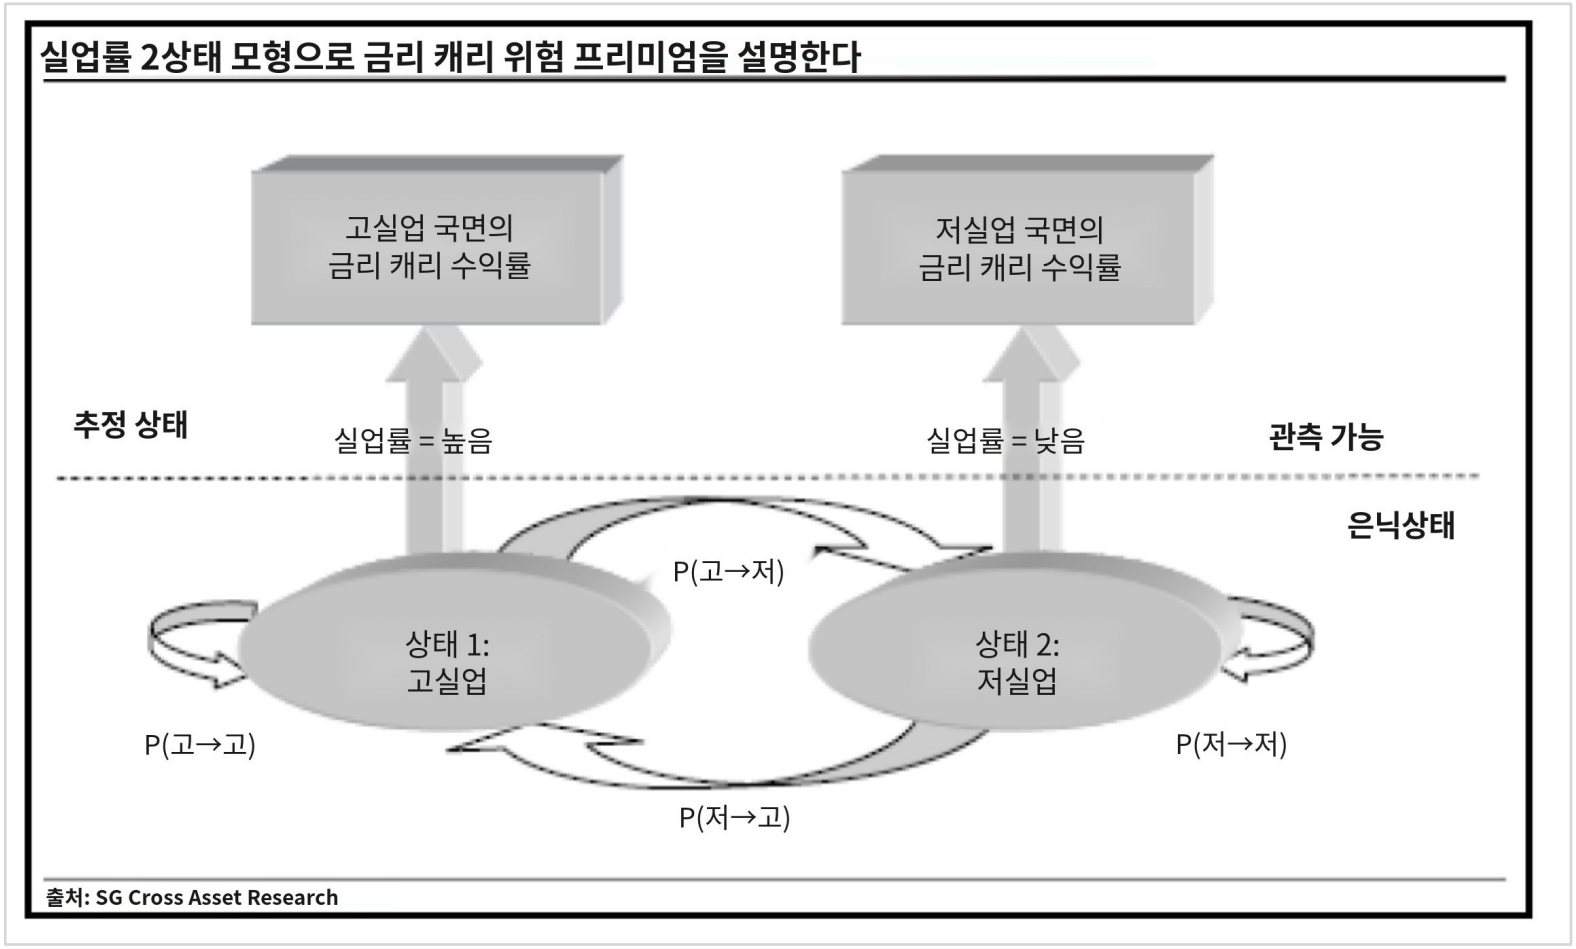
실업률 국면과 캐리 위험 프리미엄

실업률 국면으로 금리 캐리의 수익 시점을 설명한다

2상태 모형: 고실업 대 저실업(SG Cross Asset Research)

아이디어

- 은닉상태: 실업률 국면
- 관측값: 캐리 수익률
- 국면별로 수익률이 다름
- 상태로 캐리 시점 판단



04

PART 4 · 정보 거래

HMM으로 보는 정보 거래

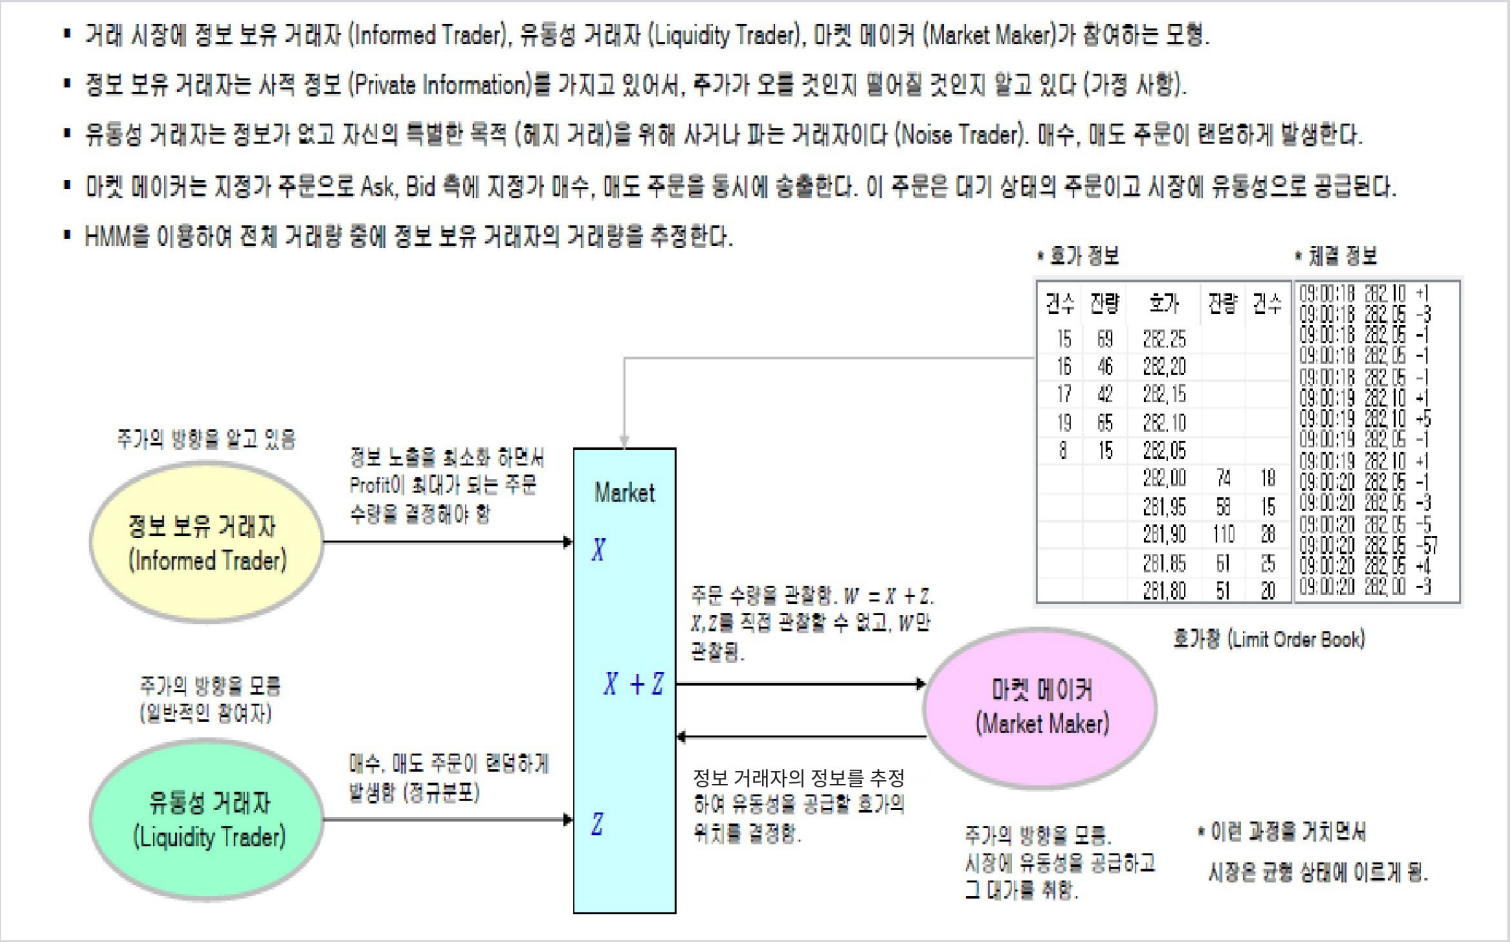
Kyle 모형, 거래량 시간, 정보 거래 확률(Probability of Informed Trading, PIN), VPIN(Volume-Synchronized PIN)

Kyle 모형의 참여자는 정보 보유 거래자, 노이즈 거래자, 마켓메이커 셋이다

정보 보유 거래자(informed trader) · 유동성 거래자(liquidity trader) · 마켓메이커(market maker)

참여자

- 정보 보유 거래자: 사적 정보
- 유동성 거래자: 노이즈 주문
- 마켓메이커: 가격 제시
- HMM: 정보 보유 거래자의 거래량 비중



틱 시간 바는 거래 활동에 맞춰 변하지만 시계 시간 바는 그렇지 못하다

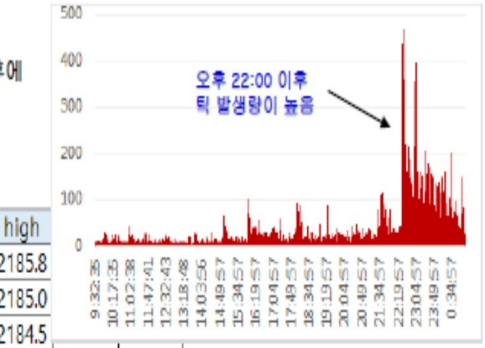
E-mini S&P 500 선물 · 시계 시간 캔들 대 틱 시간 캔들

시계 시간 대 틱 시간

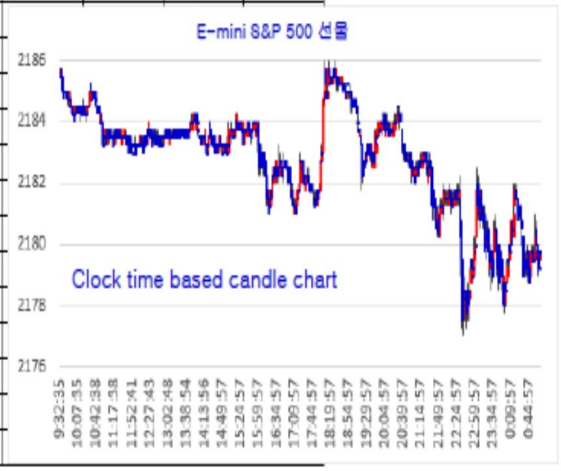
- 시계 시간: 일정 시간
- 틱 시간: 일정 체결 건수
- 22:00 이후 거래 급증
- 틱 바의 정보량이 유지됨

- 일반적인 주가의 캔들 차트는 일정 시간 동안의 주가 (시가, 고가, 저가, 종가)를 관찰한 것이다. → Clock time based candle chart.
- 금융 시장의 정보는 거래량에 반영되어 거래 시장으로 유입됨. 즉, 모든 정보는 주가에 반영된다. → The price is a vehicle of information.
- 그러나 거래량은 시간대에 따라 달라지므로 Clock time으로 구성된 각 캔들은 보유한 정보량이 다르다.

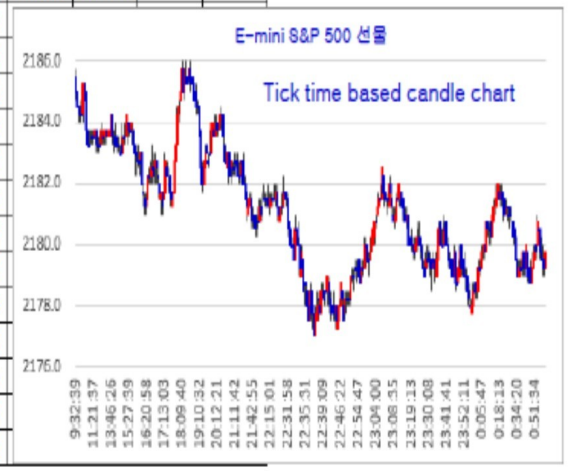
  예를 들어, 장 개장 직후와 폐장 직전에는 거래량이 많고, 점심 시간에는 거래량이 적기 때문에 장 개장 직후에 생성된 캔들과 점심 시간에 생성된 캔들을 동일하게 취급할 수 없다.
- 일정 수량의 체결 틱 데이터가 발생할 때마다 캔들을 구성하면 Tick time based candle chart라 한다.



time	ticks	open	high	low	close
9:32:35	8	2185.5	2185.75	2185.5	2185.5
9:33:35	5	2185.5	2185.75	2185.5	2185.75
9:34:35	6	2185.5	2185.5	2185.5	2185.5
9:35:35	11				
9:36:35	5				
9:37:35	8				
9:38:35	14				
9:39:35	14				
9:40:35	9				
9:41:35	12				
9:42:35	3				
9:43:35	11				
9:44:35	1				
9:45:35	3				
9:46:35	8				
9:47:35	6				



time	ticks	open	high
9:32:39	100	2185.5	2185.8
9:43:50	100	2185.0	2185.0
9:55:48	100	2184.5	2184.5
10:01:41	100		
10:14:49	100		
10:23:12	100		
10:31:39	100		
10:42:02	100		
10:54:45	100		
10:57:41	100		
11:03:49	100		
11:12:24	100		
11:21:37	100		
11:32:22	100		
11:41:19	100		
11:50:13	100		



거래량 시간 바는 일정 거래량이 체결되면 닫힌다

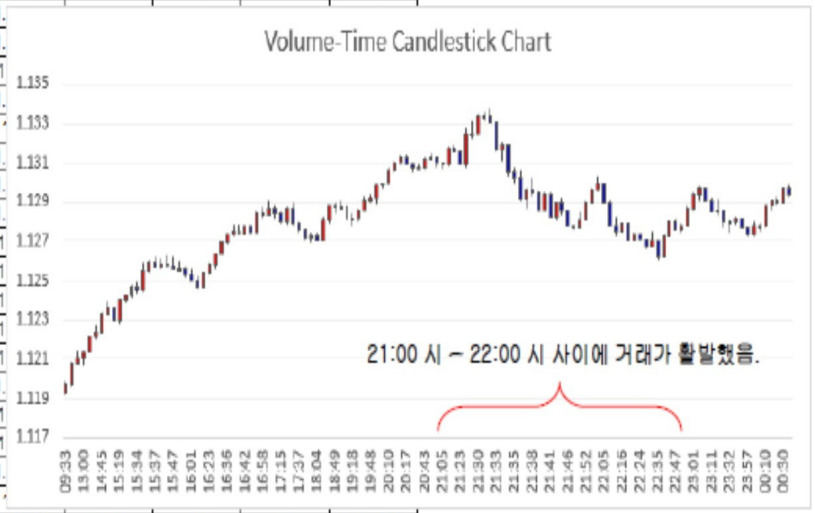
EUR/USD 선물, 2016-08-16 · 바당 1,500계약 · 바별 매수/매도 비율

거래량 시간

- 바 = 일정 거래량
- 매수·매도 수량 기록
- 바별 B/S 비율
- HMM 입력값

▪ 일정 거래량이 발생할 때마다 캔들을 구성하면 Volume time based candle chart라 한다.

	A	B	C	D	E	F	G	H	I	J	K
1	Euro Currency Futures EUR/USD (2016.8.16 09:32:39 ~ 익일 01:08:00)										
2	date	time	ticks	open	high	low	close	volume	buy	sell	buy/sell
3	2016-08-16	09:33	475	1.11925	1.1199	1.1192	1.1197	1500	795	705	1.1276596
4	2016-08-16	11:38	376	1.1197	1.12085	1.1196	1.1208	1500	962	538	1.7881041
5	2016-08-16	12:20	332	1.1208	1.12145	1.12075	1.121	1500	837	663	1.2624434
6	2016-08-16	13:00	280	1.121	1.1214	1.1207	1.12135	1500	956	544	1.7573529
7	2016-08-16	13:58	290	1.12135	1.1222	1.12135	1.				
8	2016-08-16	14:17	396	1.12215	1.12275	1.122	1.				
9	2016-08-16	14:45	388	1.12235	1.12335	1.1223	1				
10	2016-08-16	15:05	238	1.1233	1.12395	1.1233	1.				
11	2016-08-16	15:07	295	1.12365	1.12365	1.123					
12	2016-08-16	15:19	246	1.123	1.12405	1.12285	1.				
13	2016-08-16	15:31	164	1.12405	1.1243	1.1239	1.				
14	2016-08-16	15:33	186	1.12425	1.1248	1.1241	1.				
15	2016-08-16	15:34	219	1.12465	1.1249	1.12435	1				
16	2016-08-16	15:36	159	1.1245	1.1259	1.12445	1				
17	2016-08-16	15:36	280	1.1255	1.12605	1.1254	1				
18	2016-08-16	15:37	290	1.1259	1.12625	1.12565	1				
19	2016-08-16	15:39	327	1.1257	1.12615	1.1256	1				
20	2016-08-16	15:42	288	1.1258	1.12635	1.12565	1.				
21	2016-08-16	15:47	259	1.12575	1.12625	1.1256	1				
22	2016-08-16	15:53	258	1.1256	1.126	1.1255	1				
23	2016-08-16	15:58	231	1.1256	1.1257	1.12515	1.				
24	2016-08-16	16:01	318	1.12535	1.1256	1.125					
25	2016-08-16	16:07	305	1.125	1.12525	1.1246	1.12465	1500	600	900	0.6666667
26	2016-08-16	16:14	344	1.12465	1.1254	1.12465	1.1254	1500	891	609	1.4630542
27	2016-08-16	16:23	215	1.1254	1.1259	1.1253	1.12585	1500	1075	425	2.5294118
28	2016-08-16	16:28	348	1.12585	1.1264	1.1256	1.1264	1500	955	545	1.7522936



HMM은 매수·매도 흐름에서 정보 거래 비중을 추론한다

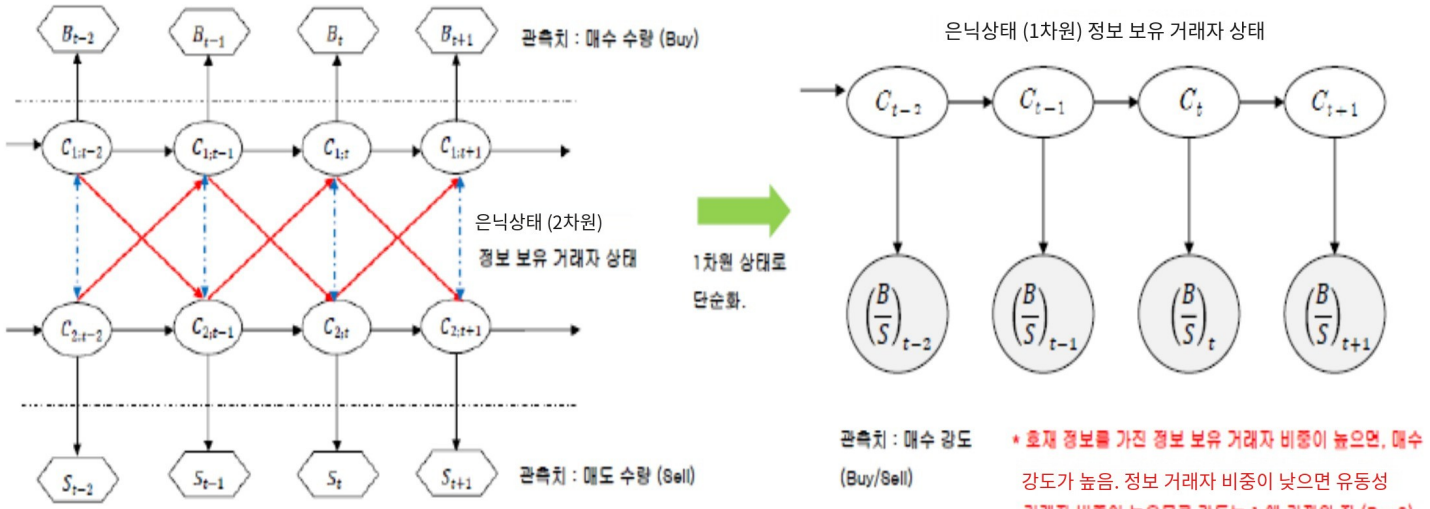
Yin & Zhao (2012), A Hidden Markov Process Approach to Information-Based Trading

모형

- 은닉상태: 정보 거래 비중
- 관측값: 매수, 매도
- 2차원 → 1차원 상태
- 관측값: B/S

HMM에 의한 정보 거래자의 은닉상태(비중) 추론

- 시장에 유입되는 매수 (Buy), 매도 (Sell) 주문 수량, 혹은 매수 주문 강도 (Buy / Sell)를 관찰하여 정보 거래자의 비중을 추정한다.
- 정보 보유 거래자의 참여 비중은 주문 수량의 은닉상태로 볼 수 있다. 정보 보유 거래자가 호재성 정보를 가지고 있다면 매수 주문이 매도 주문에 비해 많을 것이고, 악재성 정보를 가지고 있다면 매도 주문이 많을 것이다. 정보 거래자가 없다면 (시장에 유입되는 정보가 없다면), 시장에는 Noise Trader만 있으므로 매수, 매도 주문이 랜덤하게 발생할 것이다.
- Market microstructure 분야에서 정보 보유 거래자의 참여 비중을 추정하는 모형으로 PIN (Probability of Informed Trading), VPIN (Volume Synchronized PIN) 모형이 있으며, HMM 으로도 PIN을 추정해 볼 수 있다.



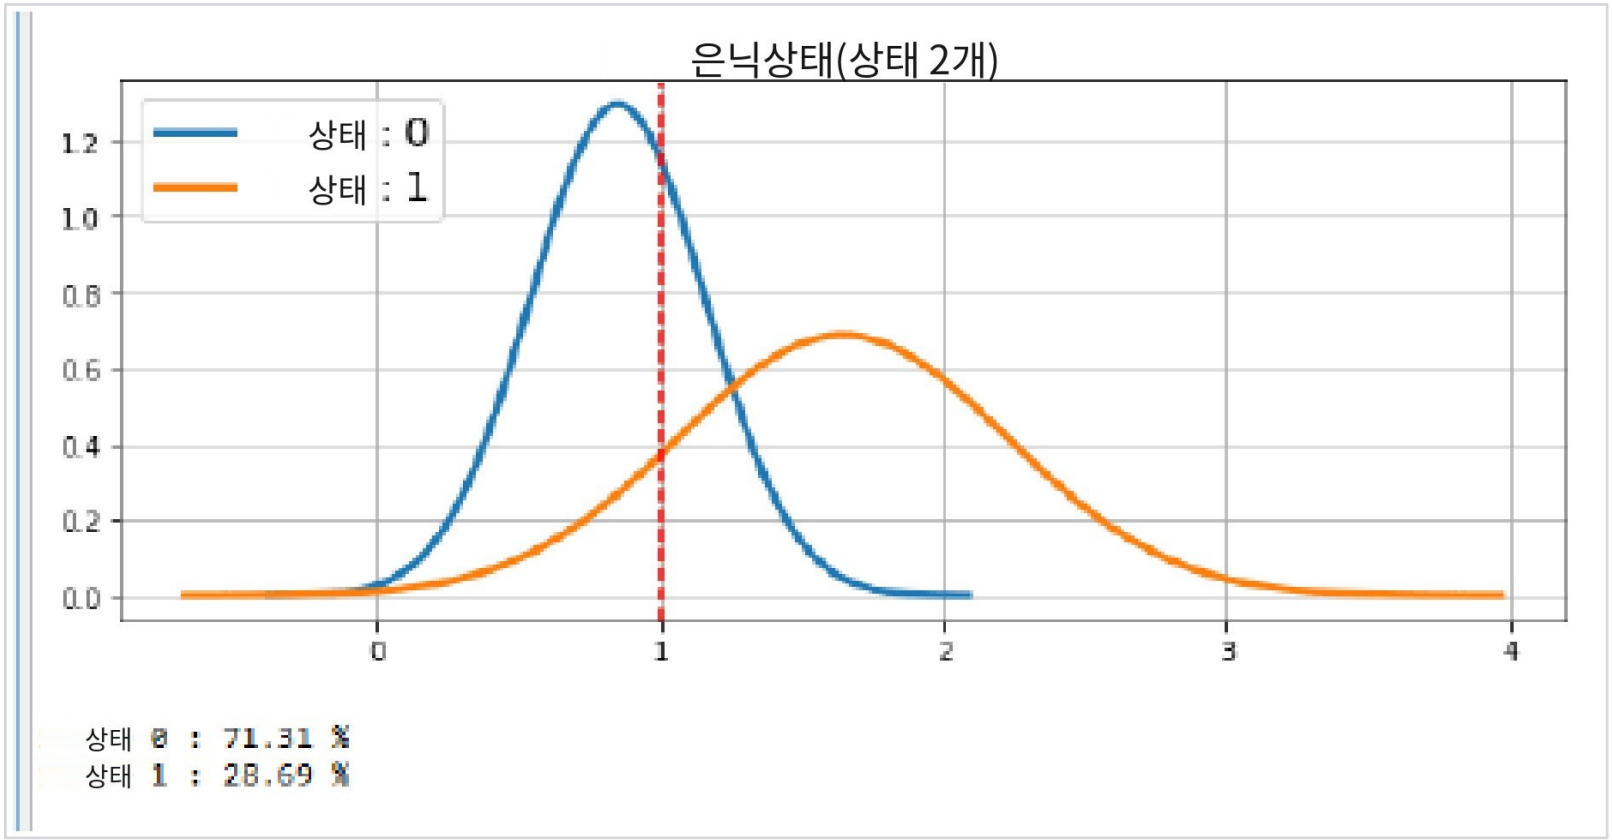
* 그림 출처 : Xiangkang Yin, Jing Zhao, 2012, A Hidden Markov Process Approach to Information-Based Trading. (Figure 2)

두 상태로 일반 주문 흐름과 매수 우위 흐름을 구분한다

B/S에 가우시안 HMM 적합 · 상태 1(평균 B/S > 1)이 전체 바의 28.69%

두 상태

- 상태 0: 71.31%
- 상태 1: 28.69%
- 빨간 선: B/S = 1
- 상태 1 = 정보 거래 매수

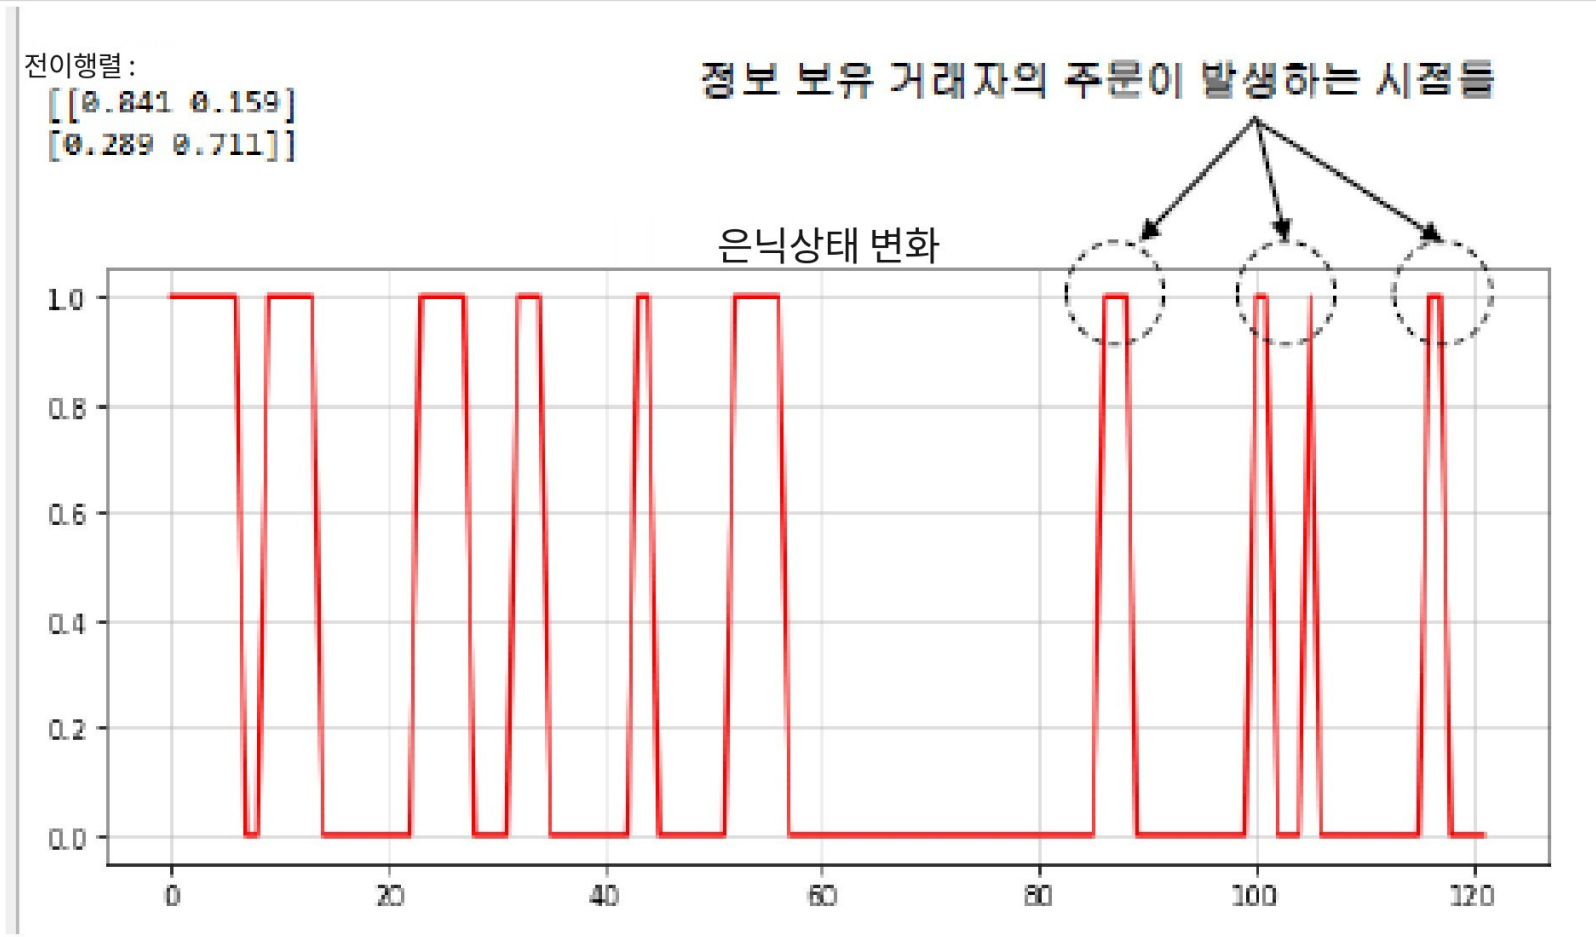


정보 보유 거래자의 주문은 상태 경로에 짧은 군집으로 나타난다

전이: 유지 0.841 · 정보 거래 상태로 전환 0.159(슬라이드 본문: 0.84 / 15.9%)

경로 읽기

- 현재: 상태 0
- 유지 확률 0.841
- 전환 확률 0.159
- 원: 정보 거래 군집

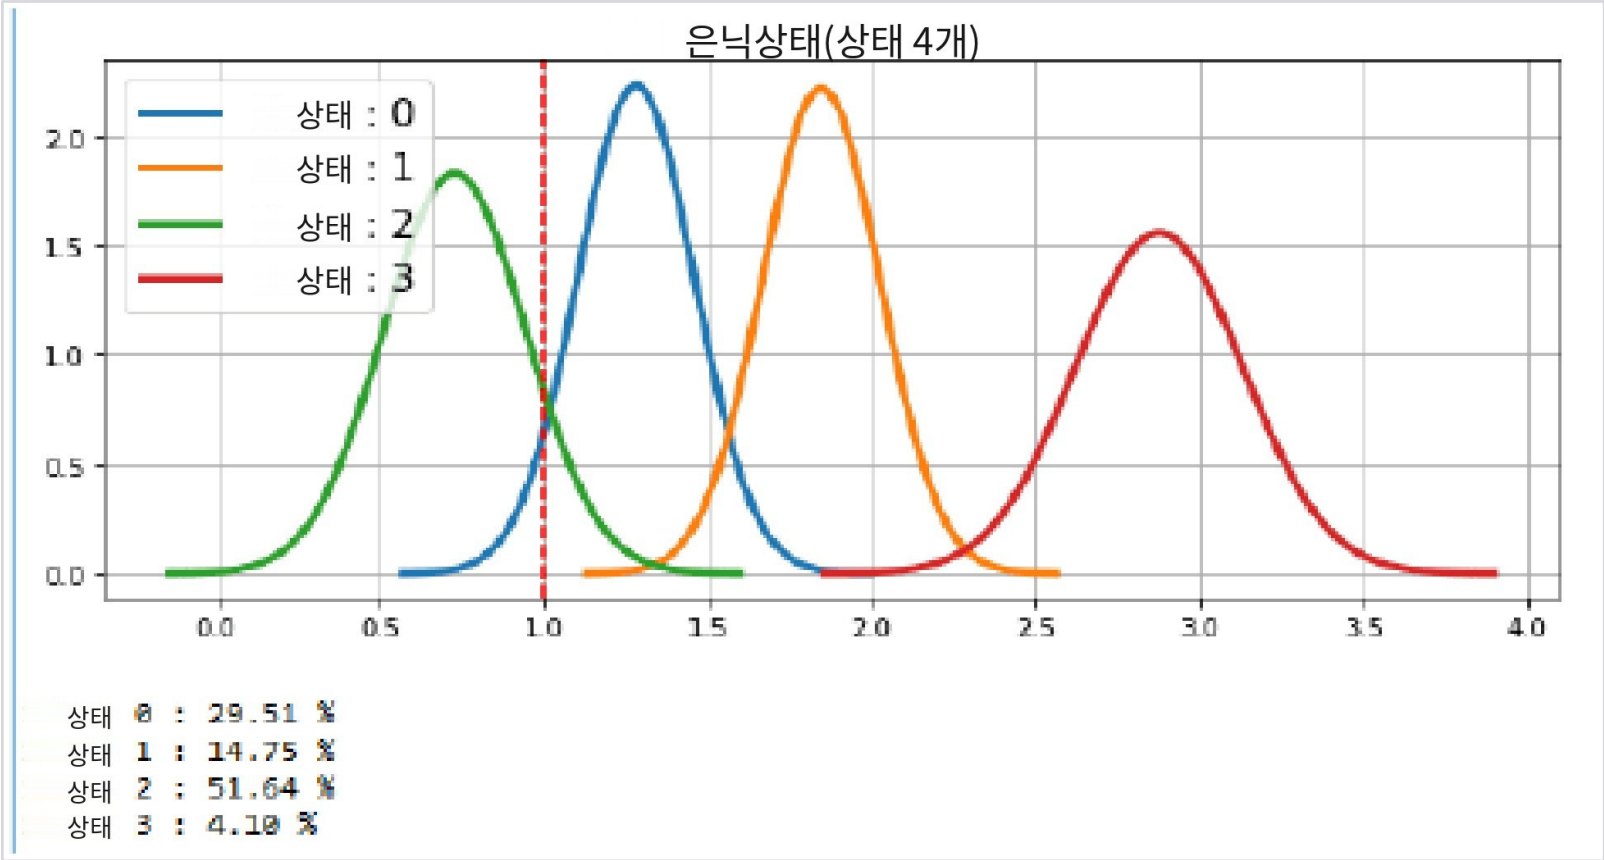


네 상태로 구조 모형 없이 주문 흐름을 설명한다

HMM에는 Kyle 모형이나 PIN의 가정이 필요 없다

네 상태

- 상태 0: 29.51%
- 상태 1: 14.75%
- 상태 2: 51.64%
- 상태 3: 4.10%

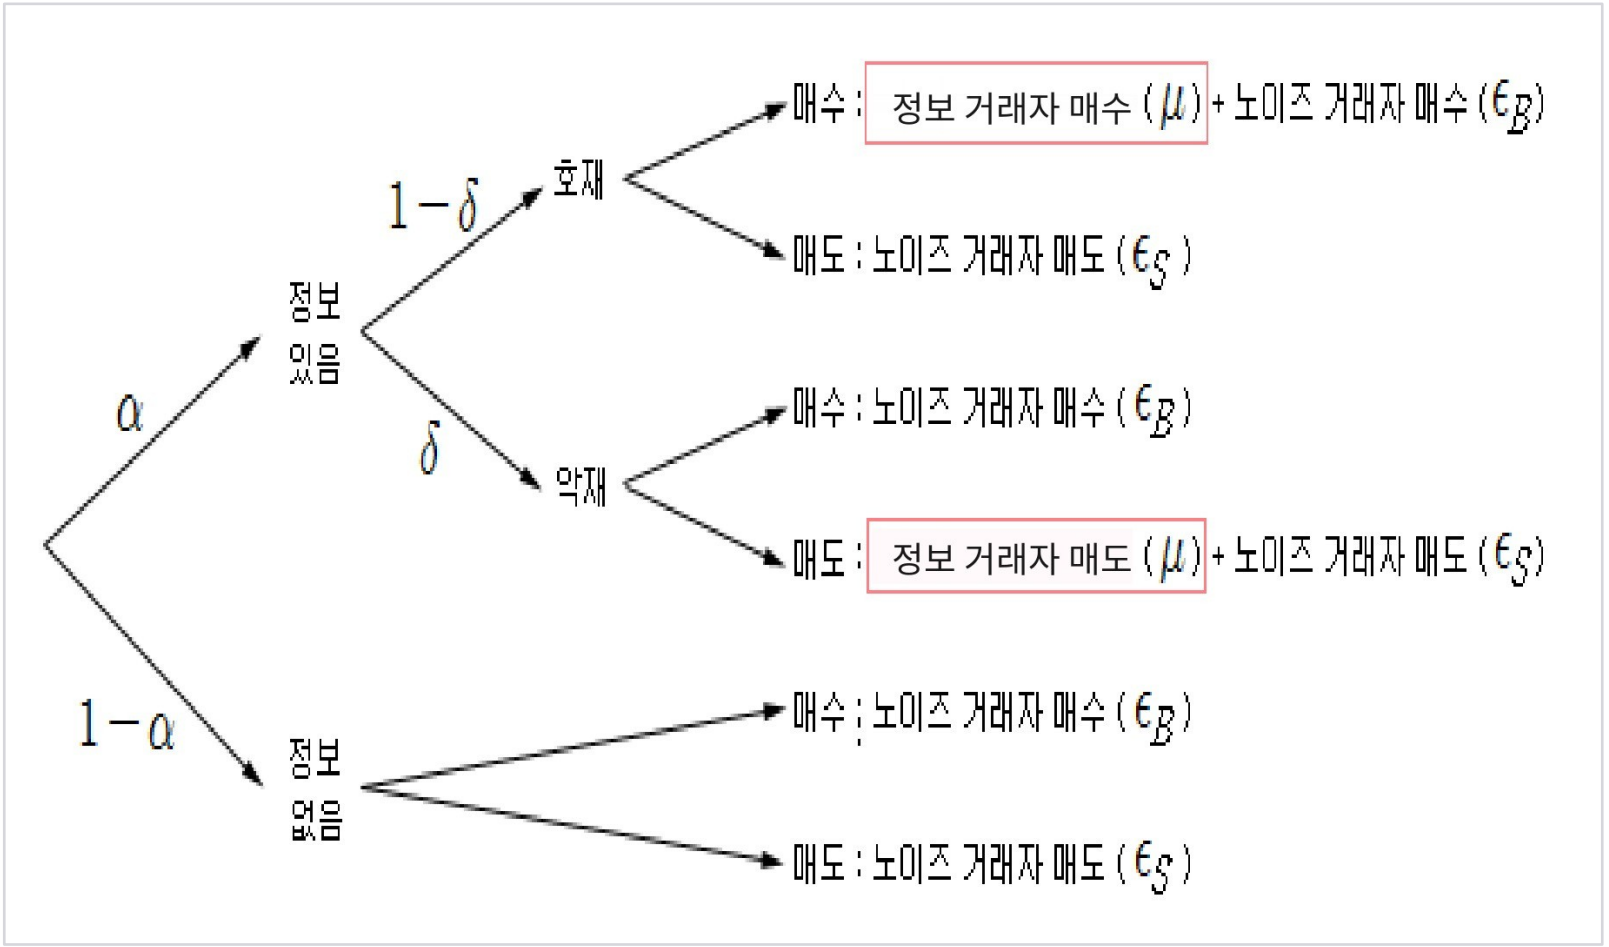


PIN은 거래 도착을 정보 이벤트 나무로 모형화한다

Easley et al. (1996) · 정보 있음(information event) · 호재(good news) · 악재(bad news)

이벤트 나무

- α: 정보 이벤트 발생
- δ: 정보가 악재
- μ: 정보 거래 도착
- ε_B, ε_S: 노이즈 매수, 매도



PIN은 총 거래 강도 중 정보 거래의 비중이다

원본 슬라이드의 유도: 매수·매도·총 거래 강도

단계

- 매수: α(1−δ)μ + ε_B
- 매도: αδμ + ε_S
- 합계: αμ + ε_B + ε_S
- PIN = αμ / 합계

1) 매수 강도 $= \alpha(1-\delta)(\mu+\epsilon_B) + \alpha\delta\epsilon_B + (1-\alpha)\epsilon_B$

$= \alpha(1-\delta)\mu + \epsilon_B$ ← 시장에서 관측되는 총 매수 강도

2) 매도 강도 $= \alpha(1-\delta)\epsilon_S + \alpha\delta(\mu+\epsilon_S) + (1-\alpha)\epsilon_S$

$= \alpha\delta\mu + \epsilon_S$ ← 시장에서 관측되는 총 매도 강도

3) 총 거래 강도 $= \alpha(1-\delta)\mu + \epsilon_B + \alpha\delta\mu + \epsilon_S$

$= \alpha\mu + \epsilon_B + \epsilon_S$ ← 총 매수 강도 + 총 매도 강도

4) 정보 거래자의 총 거래 강도 $= \alpha\mu$ ← 정보 거래자는 정보가 있는 경우만 거래함

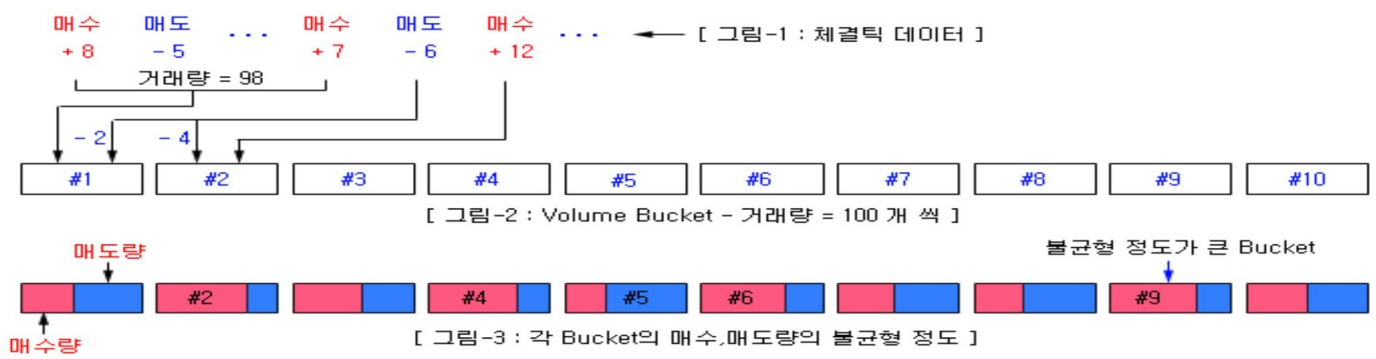
5) $PIN = \dfrac{\text{정보 거래자의 총 거래 강도}}{\text{총 거래 강도}} = \dfrac{\alpha\mu}{\alpha\mu + \epsilon_B + \epsilon_S}$

VPIN은 거래량 버킷의 매수·매도 불균형으로 PIN을 추정한다

버킷마다 거래량 V가 같고, 불균형 |S − B|가 αμ의 대리변수다

단계

- 거래를 버킷으로 묶기
- |S_i − B_i| 측정
- 평균을 구해 V로 나누기
- VPIN ≈ PIN



1) $PIN = \frac{\alpha\mu}{\alpha\mu + 2\epsilon}$

2) $\alpha\mu \approx E[|S-B|] = \frac{1}{n}\sum_{i=1}^{n}|S_i - B_i|$ ← n = Volume Bucket의 총 개수, S_i = i 번째 Volume Bucket의 매도 (Sell) 수량, B_i = i 번째 Volume Bucket의 매수 (Buy) 수량

3) $\alpha\mu + 2\epsilon = E[S+B] = V$ ← 각 Bucket의 거래량 (V)을 일정하게 만들었으므로 Constant 임

4) $PIN = \frac{\alpha\mu}{\alpha\mu + 2\epsilon} \approx \frac{1}{nV}\sum_{i=1}^{n}|S_i - B_i| = VPIN$

5) $VPIN = \frac{1}{nV}\sum_{i=1}^{n}|S_i - B_i|$

PIN과 VPIN은 전체 주문 흐름 대비 정보 거래 비율로 정리된다

원본 슬라이드의 수식

$$PIN = \frac{\alpha\mu}{\alpha\mu+\epsilon_B+\epsilon_S}$$

$$VPIN = \frac{1}{nV}\sum_{i=1}^{n}|S_i - B_i|$$

PIN

- α, δ, μ, ε를 최대우도추정(Maximum Likelihood Estimation, MLE)으로 구함
- 일별 매수·매도 건수

VPIN

- 거래량 버킷 사용, MLE 불필요
- 고빈도에서도 적용 가능

주문 흐름 불균형(OFI)은 최우선 호가의 매수·매도 변화를 집계한다

Cont et al. (2010) · Order-Flow Imbalance · 이벤트 단위 e_n을 구간 k로 합산

OFI

- 매수 호가 이벤트: + q_B
- 매도 호가 이벤트: – q_A
- 구간별 e_n 합산
- 또 다른 HMM 입력값

Cont et al. (2010)에 따른 이벤트 기반(Level-1) 대안 OFI는
호가창 이벤트로 계산한다:

$$e_n = I_{\{P_n^B \geq P_{n-1}^B\}} q_n^B - I_{\{P_n^B \leq P_{n-1}^B\}} q_{n-1}^B - I_{\{P_n^A \leq P_{n-1}^A\}} q_n^A + I_{\{P_n^A \geq P_{n-1}^A\}} q_{n-1}^A$$

구간 k에 대해 합산한다:

$$\mathrm{OFI}_k = \sum_{n=N(t_{k-1})+1}^{N(t_k)} e_n$$

원본 슬라이드의 일부 서술은 주의해서 읽어야 한다

그림은 원본 슬라이드를 따르며, 읽을 때 아래 설명을 참고한다

쪽	원본 표기	비고
p.15	본문: 상태 약 7개	차트 메모는 6개이며, 둘 다 타당하다
p.21	연평균 −0.681, 표준편차 0.093	p.18 상태 0의 μ, σ와 같은 수치이며 단위는 표기되지 않았다
p.28	표 날짜 2016-08-01	표 제목과 같은 2016-08-16으로 고침
p.31	0.84와 15.9%	행렬에는 0.841과 0.159로 나온다

네 가지 질문으로 HMM 결과를 투자 의사결정에 연결한다

KOSPI와 EUR/USD 사례를 활용한다

Q1	AIC는 BIC보다 상태를 더 많이 고른다. 실거래 모형에는 어느 쪽을 쓰겠는가? 이유는 무엇인가?	**모형 선택**
Q2	예측 정확도는 100일 기준 71%다. 실제 거래에 쓰기 전에 무엇을 더 확인하겠는가?	**예측**
Q3	KOSPI의 상태 2는 σ = 0.411이다. 모형이 이 상태에 들어가면 익스포저를 어떻게 바꾸겠는가?	**국면**
Q4	B/S에 적합한 HMM은 왜 PIN 나무의 가정 없이 정보 거래를 찾아낼 수 있는가?	**시장 미시구조**

요약

은닉상태는 시장 데이터를 국면 신호로 바꾼다

N을 정하고, 경로를 디코딩하고, 상태에 따라 판단한다

1

AIC와 BIC로 상태 수를 정한다

AAPL OHLC와 KOSPI에서는 상태가 약 5~7개를 넘으면 개선이 줄어들고, 상태가 더 많으면 과적합된다.

2

디코딩한 경로에서 국면을 읽는다

KOSPI는 평온한 하락, 평온한 상승, 고변동성 상태로 나뉘며, 전이는 지속성이 높다.

3

매수·매도 불균형에서 정보 거래 흐름을 찾아낸다

B/S에 적합한 2상태 HMM은 거래량 바의 28.69%를 매수 우위로 분류하고, PIN과 VPIN은 구조적 시각을 제공한다.

다음: HMM 알고리즘을 단계별로 응용과 함께 다룬다(HMM Applications 덱).