강의 · HMM 응용

은닉 마르코프 모형(HMM)의 응용

K-Means 군집화에서 시장 국면과 정보 거래까지

K-Means → 마르코프 체인 → Forward·Viterbi·Baum-Welch → 주가 예측 → PIN / VPIN

이 덱의 그림은 원본 강의 슬라이드를 바탕으로 한다.
풀이 예제: 날씨와 일상 활동, KOSPI 수익률, EUR/USD 선물 주문 흐름.

군집화·시퀀스·국면은 EM 아이디어 하나로 이어진다

이번 강의의 세 가지 핵심

1

K-Means는 시간 순서 없이 점을 묶는다

캔들을 모양으로 군집화하며, 발생 순서는 고려하지 않는다.

2

HMM은 마르코프 체인으로 시간을 더한다

은닉상태는 전이확률에 따라 움직이며 우리가 보는 관측값을 방출한다.

3

같은 알고리즘을 시장 데이터에 적용한다

Forward·Viterbi·Baum-Welch 알고리즘으로 KOSPI 수익률과 주문 흐름을 국면 신호로 바꾼다.

K-Means와 Baum-Welch는 모두 EM(기댓값-최대화)의 E단계와 M단계를 번갈아 수행한다.

01

PART 1 · 군집화

K-Means 군집화

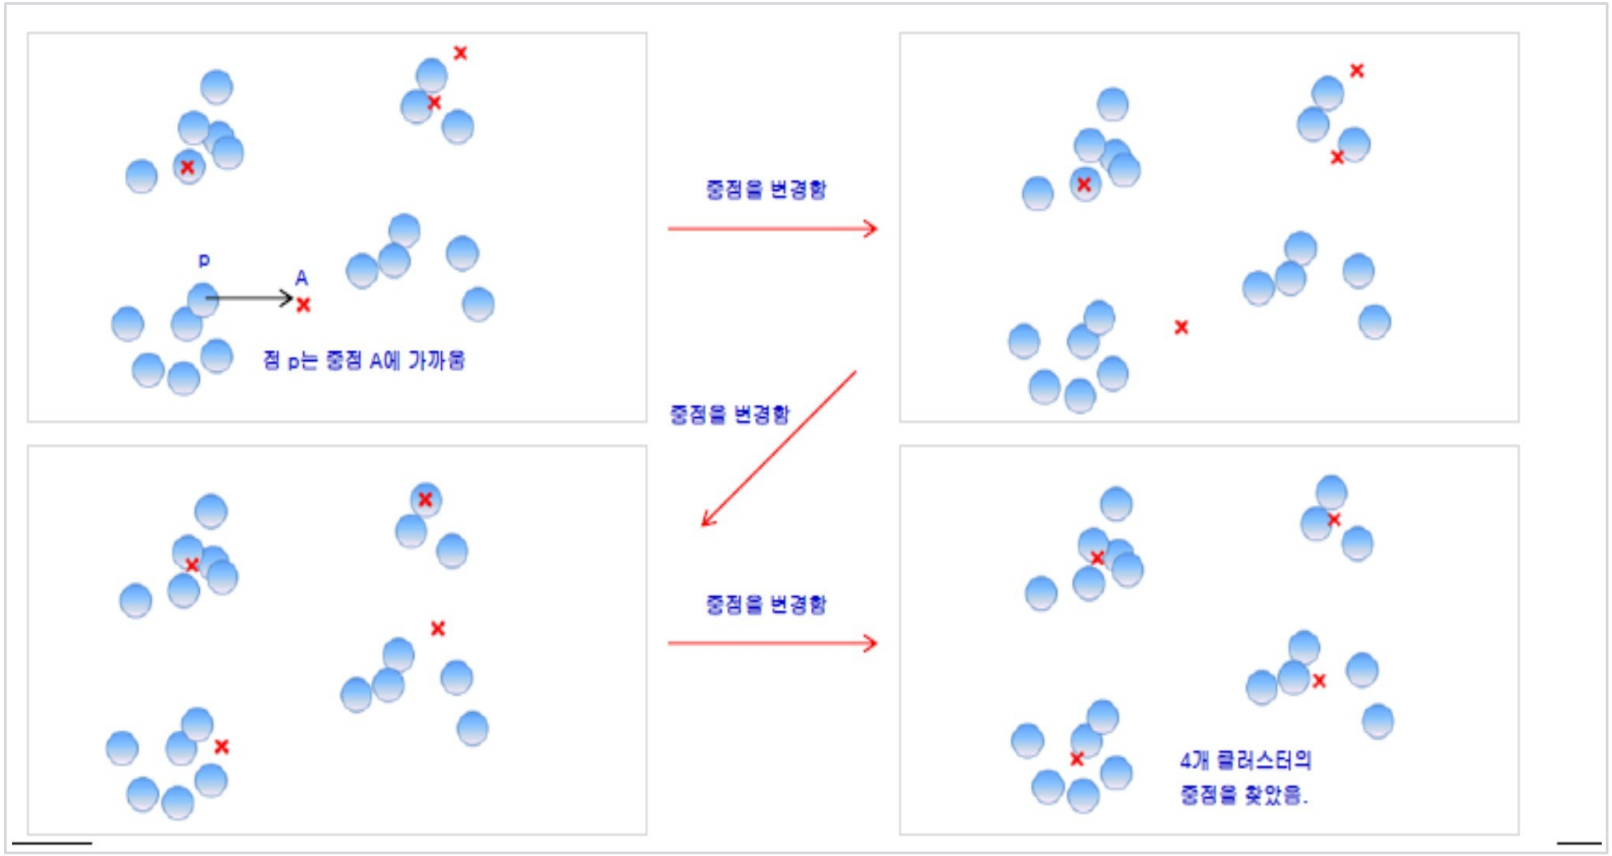
은닉상태로 넘어가기 전의 비지도 학습 예제

K-Means는 점 배정과 중심 이동을 번갈아 반복한다

비지도 학습 · EM 유형의 반복 계산 · 중심점(centre)과 군집(cluster)

반복 절차

- 중심 K개(×) 선택
- 각 점을 가장 가까운 중심에 배정
- 중심을 군집 평균으로 이동
- 안정될 때까지 반복

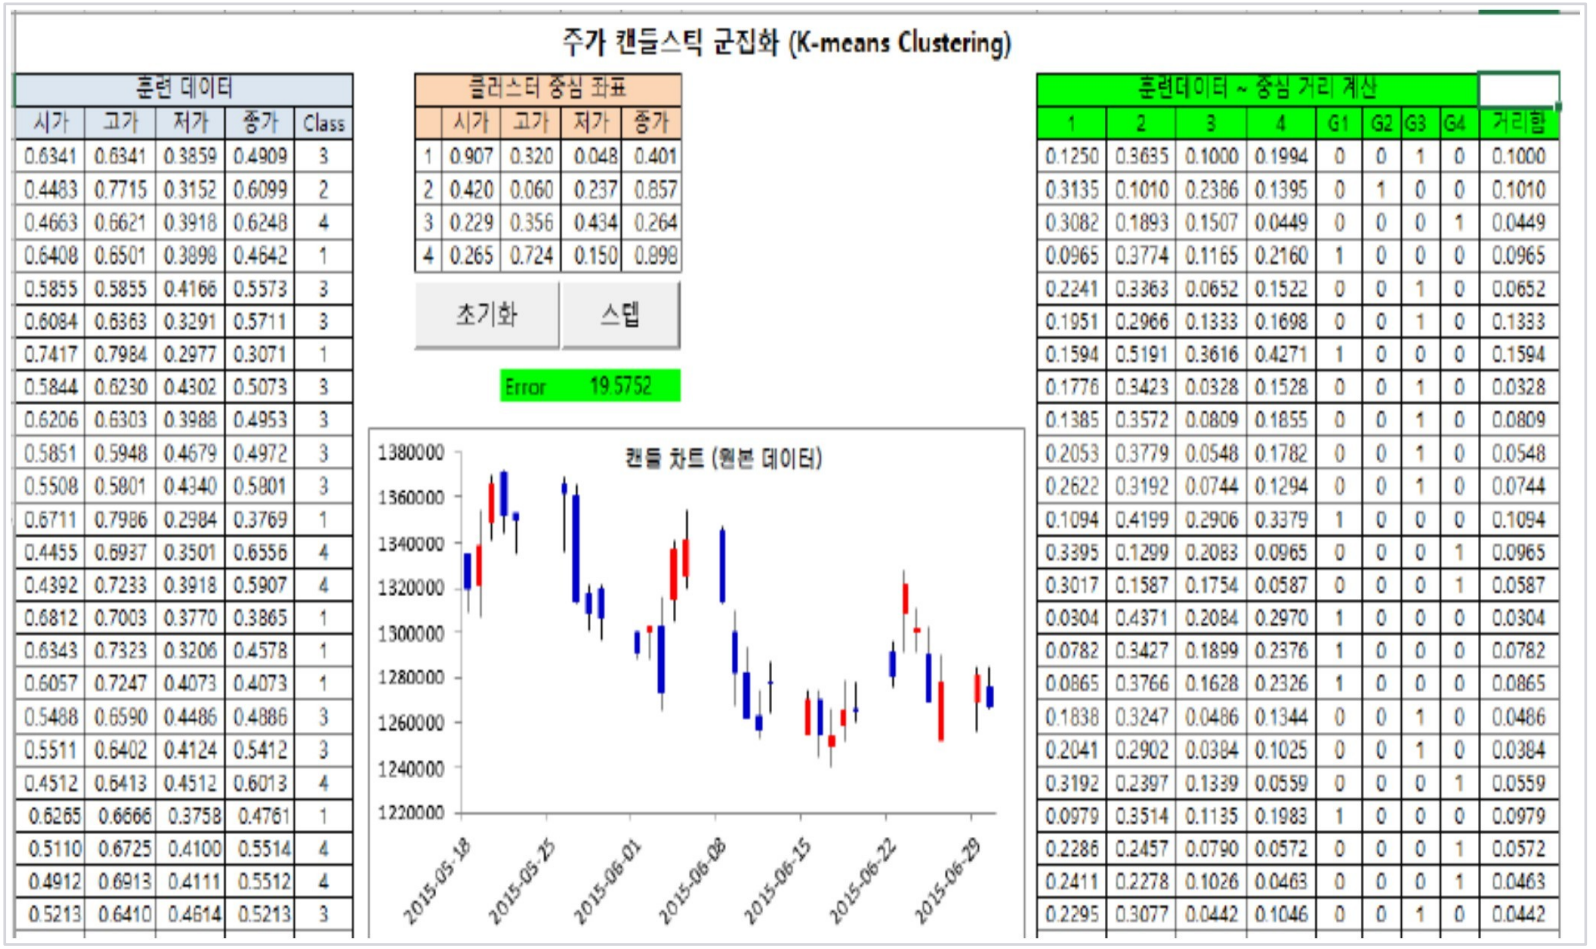


일별 캔들은 시가·고가·저가·종가의 모양으로 군집화할 수 있다

스프레드시트로 구현한 주가 캔들스틱 군집화(K-Means clustering)

설정

- 행: 일별 시가·고가·저가·종가(OHLC)
- 캔들별 정규화
- 4개 군집에 배정
- 중심 재계산

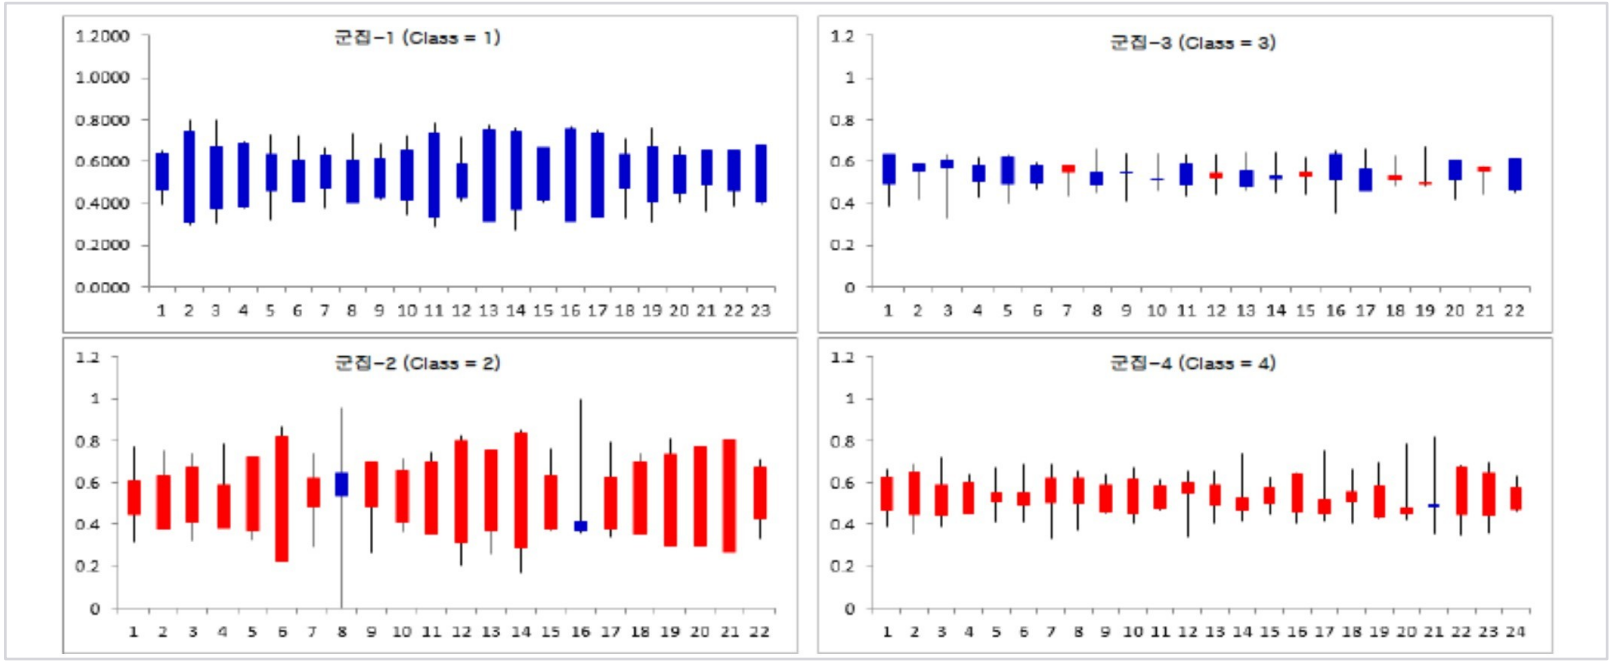


네 군집에 모양이 비슷한 캔들이 모인다

패널마다 한 군집(class)의 캔들을 보여 준다

결과

- Class 1: 큰 하락 캔들
- Class 2: 큰 상승 캔들
- Class 3, 4: 몸통이 작음

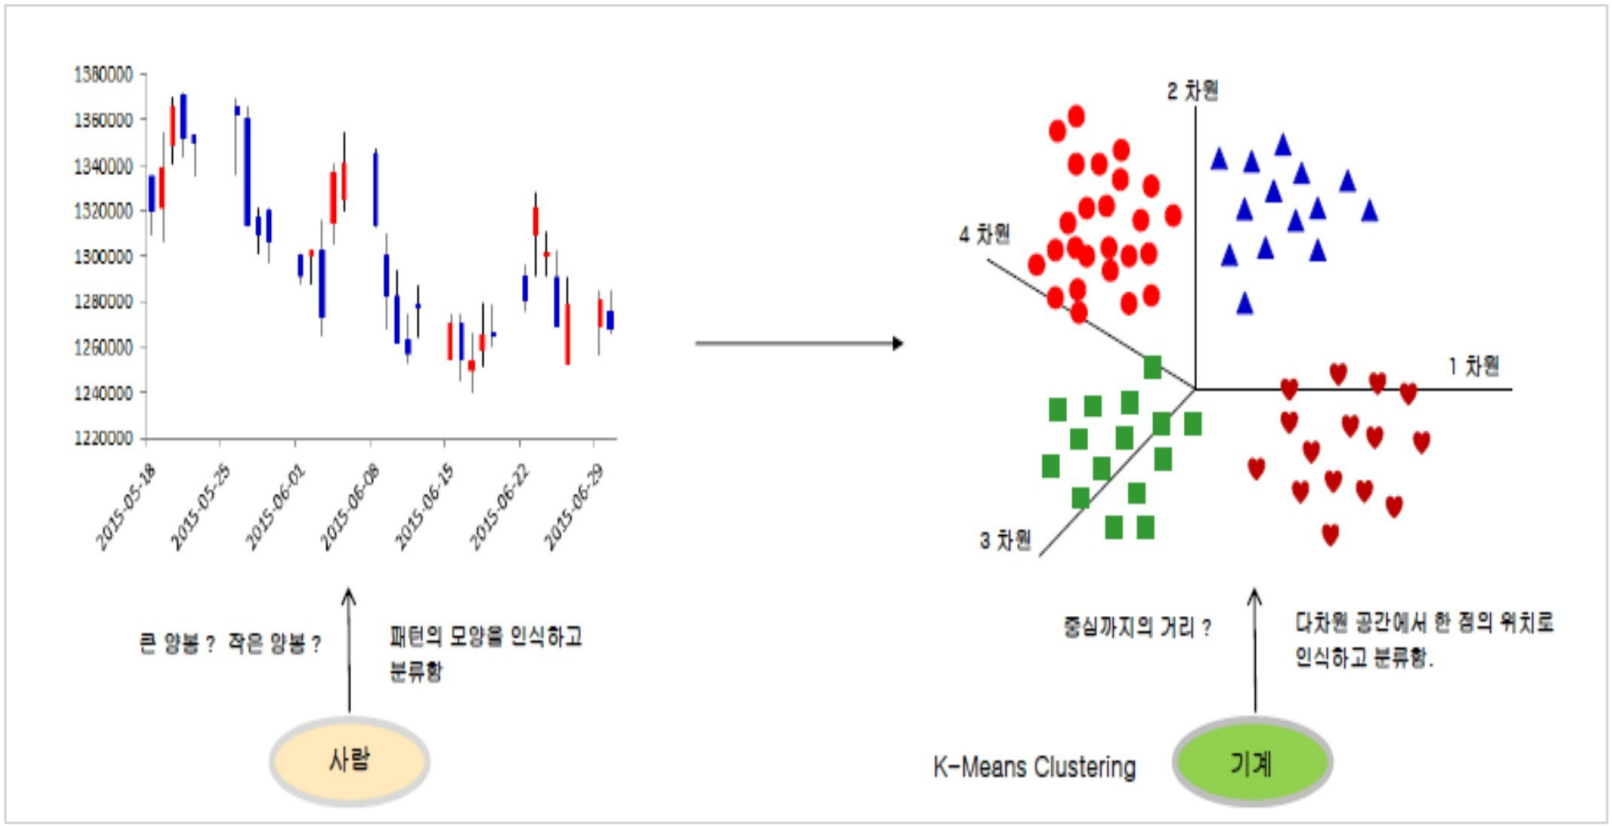


사람은 캔들 모양을 눈으로 읽고, K-Means는 거리로 판별한다

사람과 기계의 비교 · 2~4차원 특성 공간

사람과 기계

- 사람: 상승인가 하락인가?
- 기계: 공간상의 거리
- 같은 생각을 자동화
- 아직 시간 순서는 없음



02

PART 2 · 마르코프 체인

마르코프 체인과 은닉 마르코프 모형

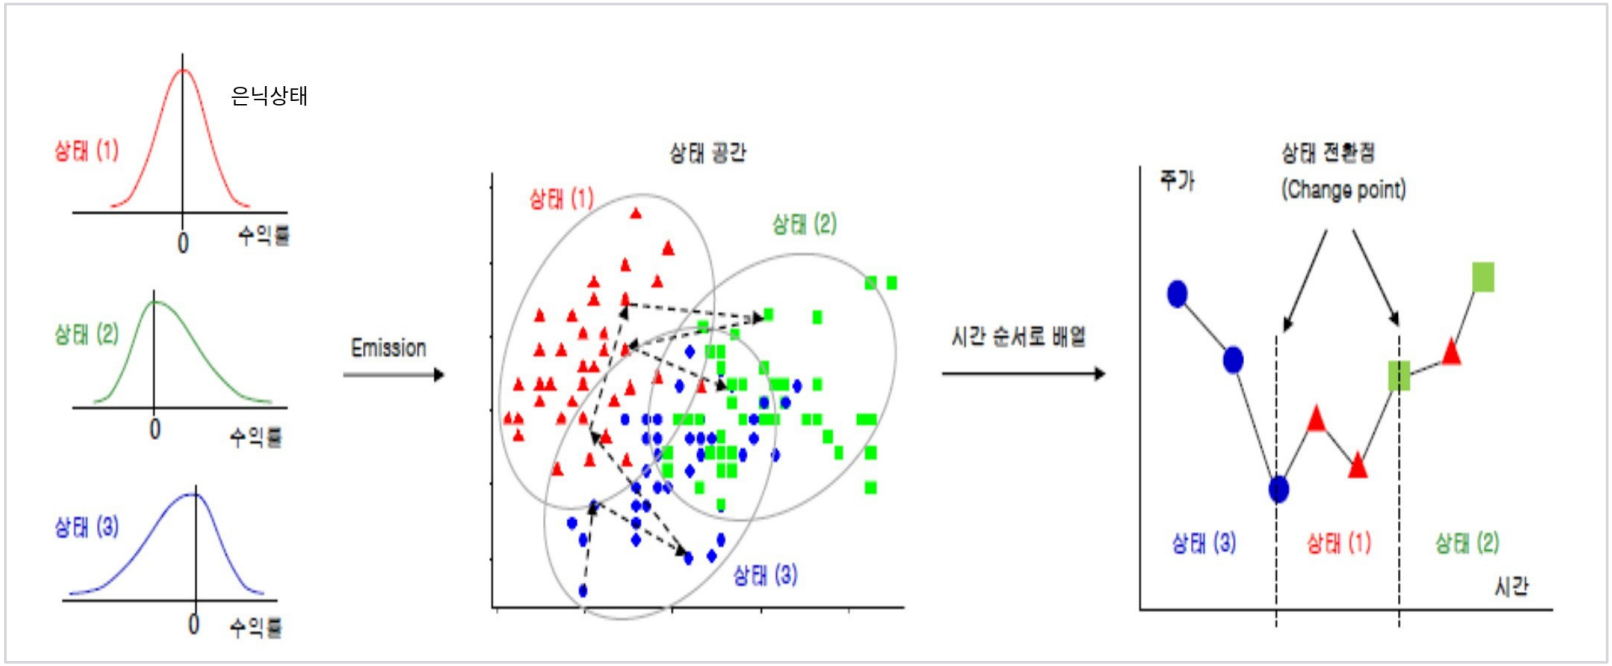
전이, 방출, 세 가지 과제

은닉상태가 바뀌면 그 상태에서 방출되는 수익률도 달라진다

상태(state) · 방출(emission) → 상태 공간 → 시간에 따른 상태 전환점

그림 읽기

- 상태마다 수익률 분포가 있음
- 수익률 공간에서는 점이 뒤섞임
- 시간순으로 놓으면 전환점이 드러남



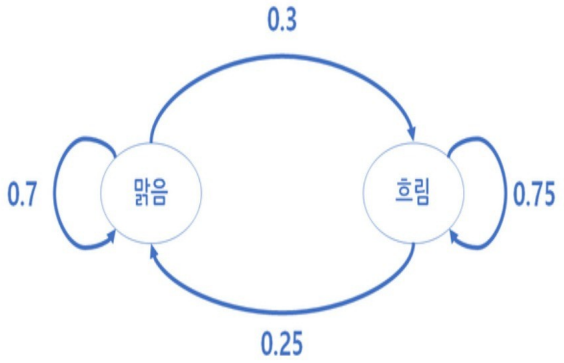
상태 전이 확률 행렬(전이행렬)로 이틀 뒤 날씨를 전망한다

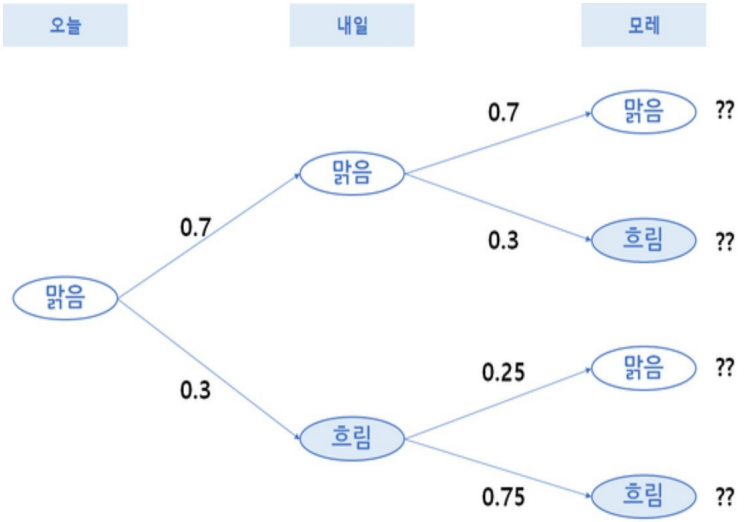
맑음(sunny)과 흐림(cloudy) · $P^2 = P \cdot P$로 2단계 전이확률을 구한다

2단계 전이

- P = [[0.7, 0.3], [0.25, 0.75]]
- P^2 1행: 0.565, 0.435
- P^2 2행: 0.3625, 0.6375
- 나무 그림도 같은 합을 보여 줌

오늘/내일	맑음	흐림
맑음	0.7	0.3
흐림	0.25	0.75





$$P = \begin{bmatrix} 0.7 & 0.3 \\ 0.25 & 0.75 \end{bmatrix}$$

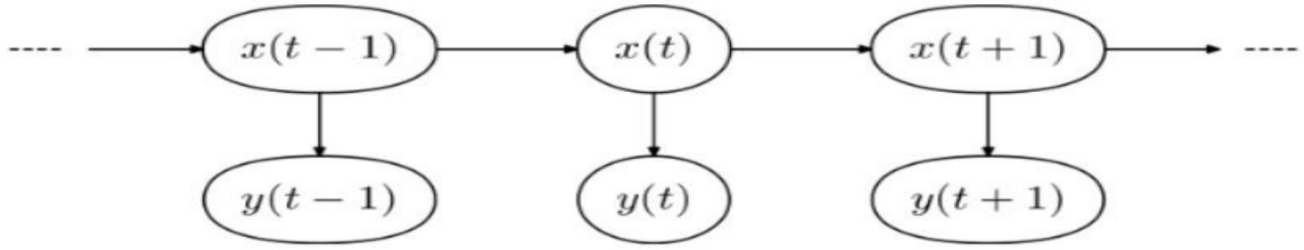
$$P2 = \begin{bmatrix} 0.7 & 0.3 \\ 0.25 & 0.75 \end{bmatrix} \cdot \begin{bmatrix} 0.7 & 0.3 \\ 0.25 & 0.75 \end{bmatrix} = \begin{bmatrix} 0.565 & 0.435 \\ 0.3625 & 0.6375 \end{bmatrix}$$

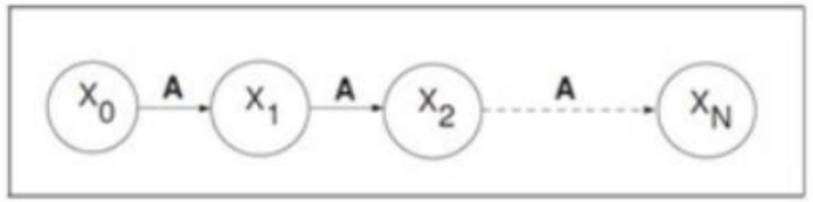
HMM은 마르코프 체인의 각 상태에 관측값을 붙인다

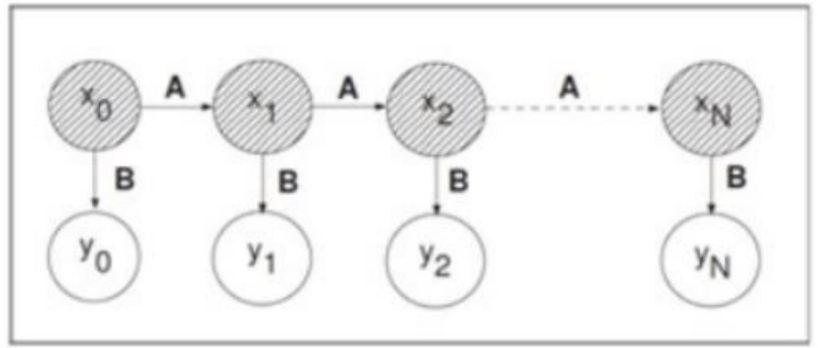
마르코프 모형: x(t)만 있음 · HMM: x(t)는 은닉상태, y(t)를 관측

비교

- 마르코프: A만 있음
- HMM: A와 B
- y는 같은 시점의 x에 의존





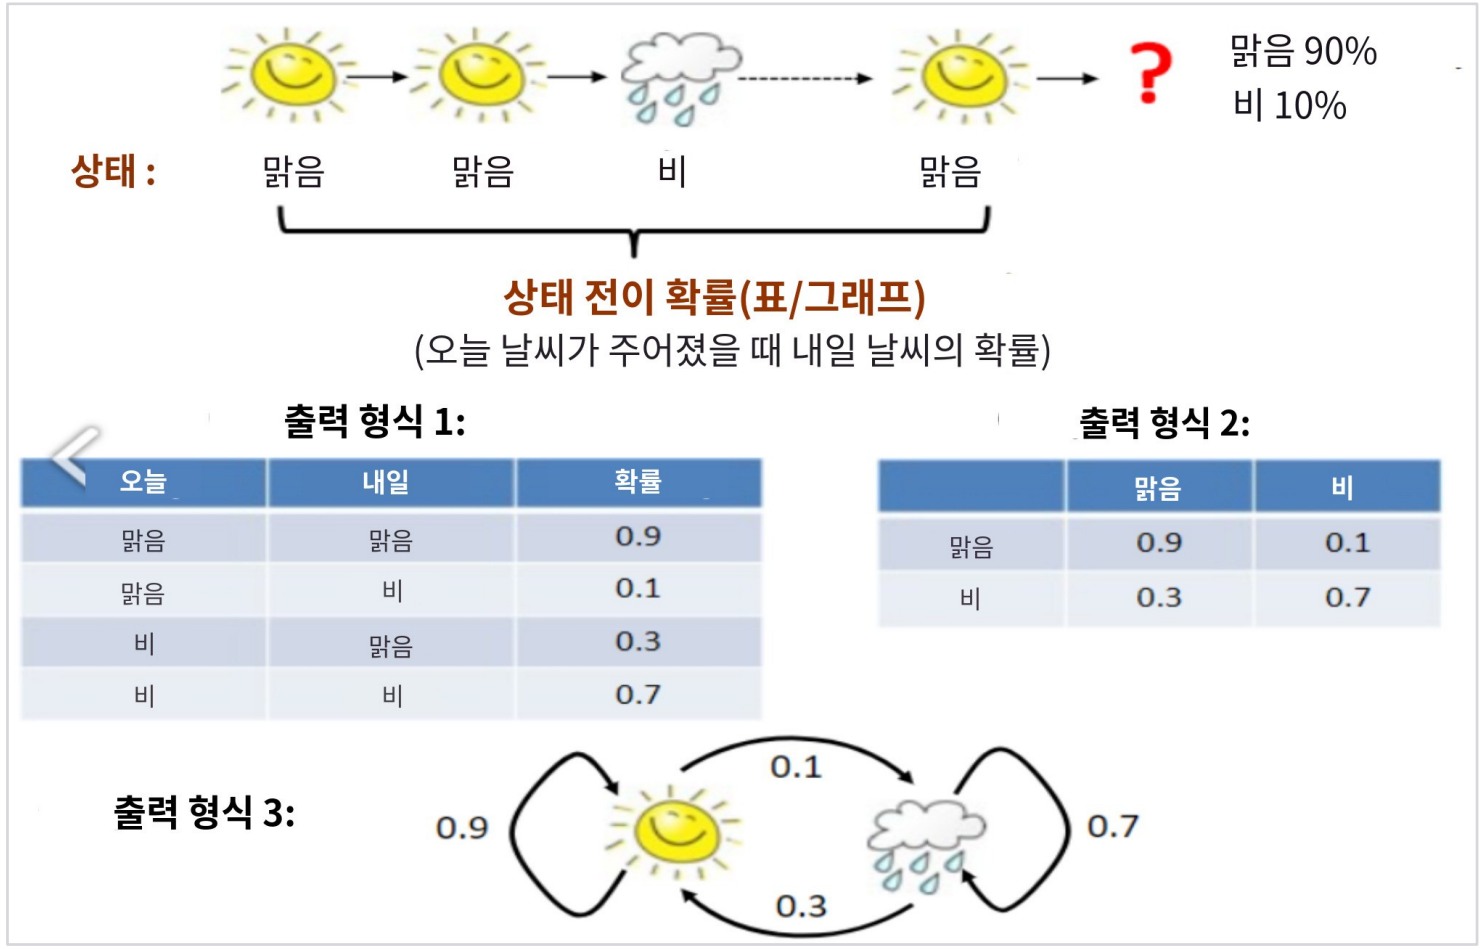


날씨 상태가 2개이면 전이행렬은 2×2다

오늘 날씨가 주어졌을 때 내일 날씨의 확률

세 가지 형식

- 표: 오늘 → 내일
- 행렬: 행의 합은 1
- 그래프: 화살표와 고리



오늘	내일	확률
맑음	맑음	0.9
맑음	비	0.1
비	맑음	0.3
비	비	0.7

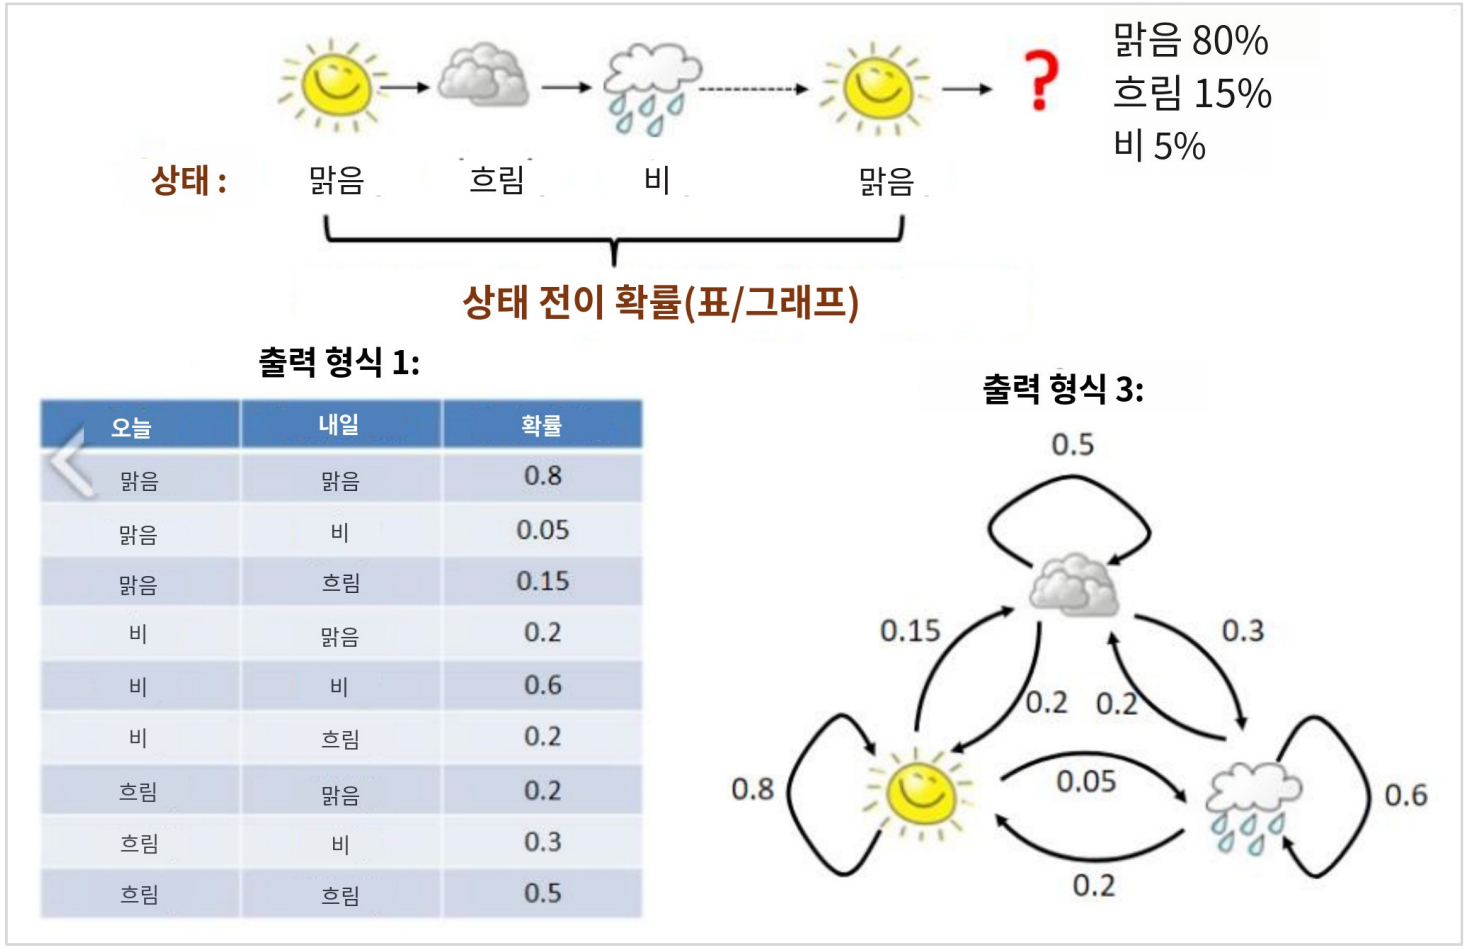
	맑음	비
맑음	0.9	0.1
비	0.3	0.7

날씨 상태가 3개이면 전이행렬은 3×3이다

맑음, 흐림, 비 · 출력 형식 1과 3

읽는 법

- 맑음→맑음 0.8
- 비→비 0.6
- 흐림→비 0.3



출력 형식 1:

오늘	내일	확률
맑음	맑음	0.8
맑음	비	0.05
맑음	흐림	0.15
비	맑음	0.2
비	비	0.6
비	흐림	0.2
흐림	맑음	0.2
흐림	비	0.3
흐림	흐림	0.5

출력 형식 3:

방출 확률은 은닉상태인 날씨와 관측되는 옷차림을 잇는다

은닉상태: 날씨 · 관측값: 선글라스, 티셔츠, 우산, 재킷

두 개의 표

- 전이: 상태 → 상태
- 방출: 상태 → 관측 품목
- 각 행의 합은 1



HMM의 과제마다 쓰는 알고리즘이 다르다

초기 확률, 전이확률, 방출 확률이 모형을 정의한다

평가(Evaluation)

Forward-Backward 알고리즘

초기 확률, 전이확률, 방출 확률이 주어졌을 때 관측값이 나올 확률을 계산한다.

디코딩(Decoding)

Viterbi 알고리즘

모형과 산책(Walk) → 청소(Clean) → 쇼핑(Shop) → 쇼핑 → 청소 같은 관측값이 주어졌을 때 가장 가능성이 높은 은닉상태 시퀀스(예: 맑음 → 비 → 맑음 → 비 → 비)를 찾는다.

학습(Learning)

Baum-Welch 알고리즘

관측값만 주어졌을 때 초기 확률, 전이확률, 방출 확률과 은닉상태 시퀀스를 추정한다.

03

PART 3 · 알고리즘

Forward·Viterbi·Baum-Welch 알고리즘

재귀식과 풀이 예제

Forward 알고리즘은 결합확률을 재귀식으로 바꾼다

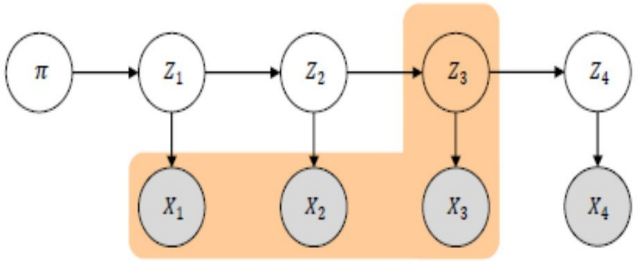
이전 상태에 대해 합하고 전이확률과 방출 확률을 곱한다

유도

- z(k-1)로 경우를 나눔
- 세 항으로 분해
- 재귀식 → 동적 계획법
- Backward 알고리즘은 이후의 x를 추가

- Forward Algorithm

$$P(z_k, x_{1:k}) = \begin{cases} z_{k-1} = Rainy \rightarrow P(z_k, z_{k-1} = Rainy, x_{1:k}) \\ z_{k-1} = Sunny \rightarrow P(z_k, z_{k-1} = Sunny, x_{1:k}) \end{cases} (+)$$



Forward 알고리즘은 z_3이 x_1, x_2, x_3에 영향을 받는 모형이다. 그러나 z_3은 x_4와 그 이후의 관측값에도 영향을 받을 수 있다. x_4 이후의 관측값까지 고려한 알고리즘은 Backward 알고리즘이다.

$$P(z_k, x_{1:k}) = \sum_{z_{k-1}} P(z_k, z_{k-1}, x_{1:k-1}, x_k)$$

$$P(z_k, x_{1:k}) = \sum_{z_{k-1}} P(x_k|z_k, z_{k-1}, x_{1:k-1})\, P(z_k|z_{k-1}, x_{1:k-1}) P(z_{k-1}|x_{1:k-1}) P(x_{1:k-1})$$

$$P(z_k, x_{1:k}) = \sum_{z_{k-1}} P(x_k|z_k)\, P(z_k|z_{k-1}) P(z_{k-1}, x_{1:k-1}) \rightarrow \alpha_k(z_k) = \sum_{z_{k-1}} P(x_k|z_k)\, P(z_k|z_{k-1}) \alpha_{k-1}(z_{k-1})$$

재귀적 관계식 (Recursion) : Dynamic Programming으로 풀 수 있는 형태

$$\alpha_1(z_1) = P(z_1, x_1) = P(x_1|z_1) P(z_1)$$

이 HMM에서 Walk, Clean, Shop이 관측될 확률은 3.10%다

π = [0.6, 0.4] · Forward 알고리즘을 세 단계로 계산한다

결과

- k=1: 0.06, 0.24
- k=2: 0.069, 0.0162
- k=3: 0.0219, 0.0091
- 합 = 0.031038

Forward 알고리즘 연습

- 오른쪽 HMM에서 아래의 시퀀스가 관찰될 확률은 얼마인가?
- 가능한 모든 Z-시퀀스 조합에 대한 확률을 계산한 후 모두 더하면 되지만, Forward 알고리즘을 사용하여 재귀적으로 계산한다.

$X = Walk \rightarrow Clean \rightarrow Shop$

초기 확률 $(\pi) = [0.6,\ 0.4]$

전이 확률 (a)

	Rainy	Sunny
Rainy	0.7	0.3
Sunny	0.4	0.6

방출 확률 (b)

	Walk	Shop	Clean
Rainy	0.1	0.4	0.5
Sunny	0.6	0.3	0.1

$$\alpha_k(z_k) = \sum_{z_{k-1}} P(x_k|z_k)\,P(z_k|z_{k-1})\alpha_{k-1}(z_{k-1})$$

$$\alpha_1(z_1) = P(z_1, x_1) = P(x_1|z_1)P(z_1)$$

$k = 1$:

$$\alpha_1(z_1 = R) = P(z_1 = R, x_1 = W) = P(x_1 = W|z_1 = R)P(z_1 = R) = 0.1 * 0.6 = 0.06$$

$$\alpha_1(z_1 = S) = P(z_1 = S, x_1 = W) = P(x_1 = W|z_1 = S)P(z_1 = S) = 0.6 * 0.4 = 0.24$$

$k = 2$:

$$\alpha_2(z_2 = R) = P(z_2 = R, x_1 = W, x_2 = C) = \begin{cases} z_1 = R:\ 0.5 * 0.7 * 0.06 = 0.021 \\ z_1 = S:\ 0.5 * 0.4 * 0.24 = 0.048 \end{cases} \rightarrow \Sigma = 0.069$$

$$\alpha_2(z_2 = S) = P(z_2 = S, x_1 = W, x_2 = C) = \begin{cases} z_1 = R:\ 0.1 * 0.3 * 0.06 = 0.0018 \\ z_1 = S:\ 0.1 * 0.6 * 0.24 = 0.0144 \end{cases} \rightarrow \Sigma = 0.0162$$

$k = 3$:

$$\alpha_3(z_3 = R) = P(z_3 = R, x_1 = W, x_2 = C, x_3 = S) = \begin{cases} z_2 = R: 0.4 * 0.7 * 0.069 = 0.01932 \\ z_2 = S: 0.4 * 0.4 * 0.0162 = 0.002592 \end{cases} \rightarrow \Sigma = 0.021912$$

$$\alpha_3(z_3 = S) = P(z_3 = S, x_1 = W, x_2 = C, x_3 = S) = \begin{cases} z_2 = R: 0.3 * 0.3 * 0.069 = 0.00621 \\ z_2 = S: 0.3 * 0.6 * 0.0162 = 0.002916 \end{cases} \rightarrow \Sigma = 0.009126$$

$$\rightarrow \Sigma = 0.031038 \approx 3.1038\%$$

Viterbi 알고리즘은 Forward의 합을 최댓값으로 바꾼다

원본 슬라이드의 재귀식

$$\alpha_k(z_k) = \sum_{z_{k-1}} P(x_k \mid z_k)\, P(z_k \mid z_{k-1})\, \alpha_{k-1}(z_{k-1}), \qquad \alpha_1(z_1) = P(x_1 \mid z_1) P(z_1)$$

$$\mu_k(z_k) = \max_{z_{k-1}} P(x_k \mid z_k)\, P(z_k \mid z_{k-1})\, \mu_{k-1}(z_{k-1}), \qquad \mu_1(z_1) = P(x_1 \mid z_1) P(z_1)$$

비교

- Forward: z(k−1)에 대한 Σ → 관측값의 확률
- Viterbi: z(k−1)에 대한 max → 가장 가능성이 높은 은닉상태 시퀀스

Viterbi 알고리즘은 각 상태로 들어오는 최선의 경로를 남긴다

유도에는 f ≥ 0일 때 성립하는 max(f·g) = f·max g를 쓴다

유도

- 같은 방식으로 분해
- Σ가 max로 바뀜
- arg max를 저장
- 마지막에 역추적

- π, a, b,가 주어진 상태에서 관측값 X 가 발생할 수 있는 가장 가능성 있는 Z 의 시퀀스 (Z^*) 를 추정한다.
- Forward 알고리즘처럼 재귀적 표현으로 알고리즘을 만든다.

$$Z = \{z_1, z_2, z_3, \cdots\}, \quad X = \{x_1, x_2, x_3, \cdots\}$$

목표 : $Z^* = \underset{Z}{\operatorname{argmax}} P(Z|X) = \underset{Z}{\operatorname{argmax}} P(Z, X)$

정의 : $\mu_k(z_k) = \max_{z_{1:k-1}} P(z_{1:k}, x_{1:k})$

$$\mu_k(z_k) = \max_{z_{1:k-1}} P(x_k|z_k)\, P(z_k|z_{k-1}) P(z_{1:k-1}, x_{1:k-1})$$

$$\mu_k(z_k) = \max_{z_{k-1}} \left[P(x_k|z_k) P(z_k|z_{k-1}) \max_{z_{1:k-2}} P(z_{1:k-1}, x_{1:k-1}) \right]$$

$$\mu_k(z_k) = \max_{z_{k-1}} P(x_k|z_k) P(z_k|z_{k-1}) \mu_{k-1}(z_{k-1})$$

재귀적 관계식 (Recursion) : Dynamic Programming으로 풀 수 있는 형태

정리 (1)

$$If\ f(a) \geq 0, g(a,b) \geq 0, then$$

$$\max_{a,b} f(a)g(a,b) = \max_{a} \left[f(a) \max_{b} g(a,b) \right]$$

Viterbi 알고리즘

$$\mu_k(z_k) = \max_{z_{k-1}} P(x_k|z_k) P(z_k|z_{k-1}) \mu_{k-1}(z_{k-1})$$

$$\mu_1(z_1) = P(z_1, x_1) = P(x_1|z_1) P(z_1)$$

Walk, Clean, Shop, Walk를 가장 잘 설명하는 상태는 맑음, 비, 비, 맑음이다

가장 가능성이 높은 은닉상태 시퀀스의 확률은 0.2419%다

결과

- k=4: R 0.000941, S 0.002419
- 맑음(S)에서 끝남
- 빨간 화살표로 역추적
- Z = S → R → R → S

Viterbi 알고리즘 연습

- 아래의 시퀀스가 관찰됐을 때 가장 가능한 Z-시퀀스는 무엇인가?
- 가능한 모든 Z-시퀀스 조합에 대한 확률을 계산한 후 가장 큰 값을 찾으면 되지만, Viterbi 알고리즘을 사용하여 재귀적으로 계산한다.

$X = Walk \rightarrow Clean \rightarrow Shop \rightarrow Walk$

$$\mu_k(z_k) = \max_{z_{k-1}} P(x_k|z_k)P(z_k|z_{k-1})\mu_{k-1}(z_{k-1})$$

$$\mu_1(z_1) = P(z_1, x_1) = P(x_1|z_1)P(z_1)$$

$k = 1: x_1 = Walk$

$\mu_1(z_1 = R) = P(x_1 = W|z_1 = R)P(z_1 = R) = 0.1 * 0.6 = 0.06$

$\mu_1(z_1 = S) = P(x_1 = W|z_1 = S)P(z_1 = S) = 0.6 * 0.4 = 0.24$

$k = 2: x_2 = Clean$

$\mu_2(z_2 = R) = max \begin{cases} z_1 = R: 0.5 * 0.7 * 0.06 = 0.021 \\ z_1 = S: 0.5 * 0.4 * 0.24 = 0.048 \end{cases}$

$\mu_2(z_2 = S) = max \begin{cases} z_1 = R: 0.1 * 0.3 * 0.06 = 0.0018 \\ z_1 = S: 0.1 * 0.6 * 0.24 = 0.0144 \end{cases}$

$k = 3: x_3 = Shop$

$\mu_3(z_3 = R) = max \begin{cases} z_2 = R: 0.4 * 0.7 * 0.048 = 0.01344 \\ z_2 = S: 0.4 * 0.4 * 0.0144 = 0.002304 \end{cases}$

$\mu_3(z_3 = S) = max \begin{cases} z_2 = R: 0.3 * 0.3 * 0.048 = 0.00432 \\ z_2 = S: 0.3 * 0.6 * 0.0144 = 0.002592 \end{cases}$

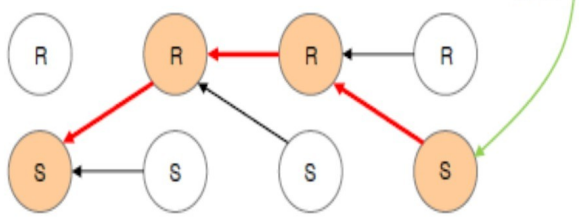
$k = 4: x_4 = Walk$

$\mu_4(z_4 = R) = max \begin{cases} z_3 = R: 0.1 * 0.7 * 0.01344 = 0.000941 \\ z_3 = S: 0.1 * 0.4 * 0.00432 = 0.000173 \end{cases}$

$\mu_4(z_4 = S) = max \begin{cases} z_3 = R: 0.6 * 0.3 * 0.01344 = 0.002419 \\ z_3 = S: 0.6 * 0.6 * 0.00432 = 0.001555 \end{cases}$

Trace back

큰 값



$Z = Sunny \rightarrow Rainy \rightarrow Rainy \rightarrow Sunny$

z^*가 이 시퀀스일 때의 확률이 0.2419%로 가장 높다.

Baum-Welch 알고리즘은 EM 알고리즘으로 π, a, b를 갱신한다

E단계: Q(θ, θ_t) · M단계: 합이 1이라는 제약 아래 θ_(t+1) = arg max Q

절차

- 추정한 θ에서 출발
- E: 로그우도의 기댓값
- M: 라그랑주 승수로 최대화
- 안정될 때까지 반복

▪ 관측값인 X 만 가지고 가장 가능성이 높은 π, a, b, Z를 추정한다.

▪ $\theta = \{\pi, a, b\}$의 초깃값을 임의로 설정한 후 관측값인 X를 이용하여 E-M 알고리즘 (Expectation and Maximization)을 반복하여 θ를 업데이트한다.

* E-단계 (Expectation) : $Q(\theta, \theta_t) = \sum_Z P(Z|X, \theta_t) log P(X, Z|\theta)$

$\theta = \{\pi, a, b\}, Z = \{z_1, z_2, z_3, \cdots\}, X = \{x_1, x_2, x_3, \cdots\}$

* M-단계 (Maximization) : $\theta_{t+1} = \underset{\theta}{\operatorname{argmax}}\, Q(\theta, \theta_t)$

▪ 파라메터 업데이트

$$\pi_{t+1} = \frac{P(z_1 = j|X, \theta_t)}{\sum_{j=1}^{k} P(z_1 = j|X, \theta_t)}$$

$$a_{t+1}(i,j) = \frac{\sum_{t=2}^{T} P(z_{t-1} = i, z_t = j|X, \theta_t)}{\sum_{t=2}^{T} P(z_{t-1} = i|X, \theta_t)}$$

$$b_{t+1}(i,j) = \frac{\sum_{t=1}^{T} P(z_t = i|X, \theta_t) I(x_t = j)}{\sum_{t=1}^{T} P(z_t = i|X, \theta_t)}$$

▪ 파라메터 업데이트 식 산출 원리

1. 아래 식을 이용하여 $Q(\theta, \theta_t)$ 정의한다 (Factorization).

$$P(X, Z|\theta) = \pi \prod_{t=2}^{T} a(z_{t-1}, z_t) \prod_{t=1}^{T} b(x_t, z_t)$$

$$log P(X, Z|\theta) = \log(\pi) + \sum_{t=2}^{T} \log\big(a(z_{t-1}, z_t)\big) + \sum_{t=1}^{T} \log(b(x_t, z_t))$$

2. 제한조건 ($\sum \pi = 1, \sum a = 1, \sum b = 1$)을 이용하여 $Q(\theta, \theta_t)$를 라그랑지 함수로 표현.

$$L(\theta, \theta_t) = Q(\theta, \theta_t) - \lambda_\pi \left(\sum_{i=1}^{k} \pi_i - 1 \right) - \lambda_a (a - \text{조건}) - \lambda_b (b - \text{조건})$$

3. 라그랑지 함수를 최대화하는 파라메터를 찾는다.

$$\frac{\partial L}{\partial \pi_i} = 0 \quad \frac{\partial L}{\partial a_i} = 0 \quad \frac{\partial L}{\partial b_i} = 0 \quad \frac{\partial L}{\partial \lambda_\pi} = 0 \quad \frac{\partial L}{\partial \lambda_a} = 0 \quad \frac{\partial L}{\partial \lambda_b} = 0$$

04

PART 4 · 주가 예측

HMM을 이용한 주가 예측

애플(AAPL)과 KOSPI로 보는 모형 선택, 주가 예측, 수익률 국면

정보기준으로 은닉상태의 수를 고른다

가우시안 HMM, 상태 N개, 관측값 M개, Baum-Welch 알고리즘으로 파라미터 추정

읽는 법

- L: 우도
- M: 관측값 개수
- k: 파라미터 개수
- 논문: 상태 2~4개만 비교

Hidden Markov Model(HMM)에서 은닉상태의 수를 선택하는 것은 중요한 작업이다. 일반적으로 AIC(Akaike Information Criterion)와 BIC(Bayesian Information Criterion)를 사용해 모델의 성능을 평가하며, 이는 Baum-Welch 알고리즘을 통해 최대 우도 추정을 수행할 때 적합하다. 본 연구에서는 상태 수를 2에서 4로 제한해 모델의 단순성과 실용성을 유지한다.

AIC와 BIC는 각각 다음 식으로 계산한다:

$$AIC = -2\ln(L) + 2k$$

$$BIC = -2\ln(L) + k\ln(M)$$

여기서:

- L은 모델의 우도 함수,
- M은 관측 포인트 수,
- k는 추정된 파라미터의 수이다.

각 은닉상태가 정규 분포를 따른다고 가정하며, HMM에서 상태의 수를 N이라 할 때, 파라미터의 수 k는 다음과 같이 정의한다:

$$k = N^2 + 2N - 1$$

시뮬레이션을 100번 수행하며, 각 스텝에서 이전 단계에서 추정된 파라미터를 초기값으로 설정하여 재추정하고, AIC와 BIC를 계산한다. 이를 통해 시뮬레이션 전반에 걸친 BIC 변화를 관찰한다.

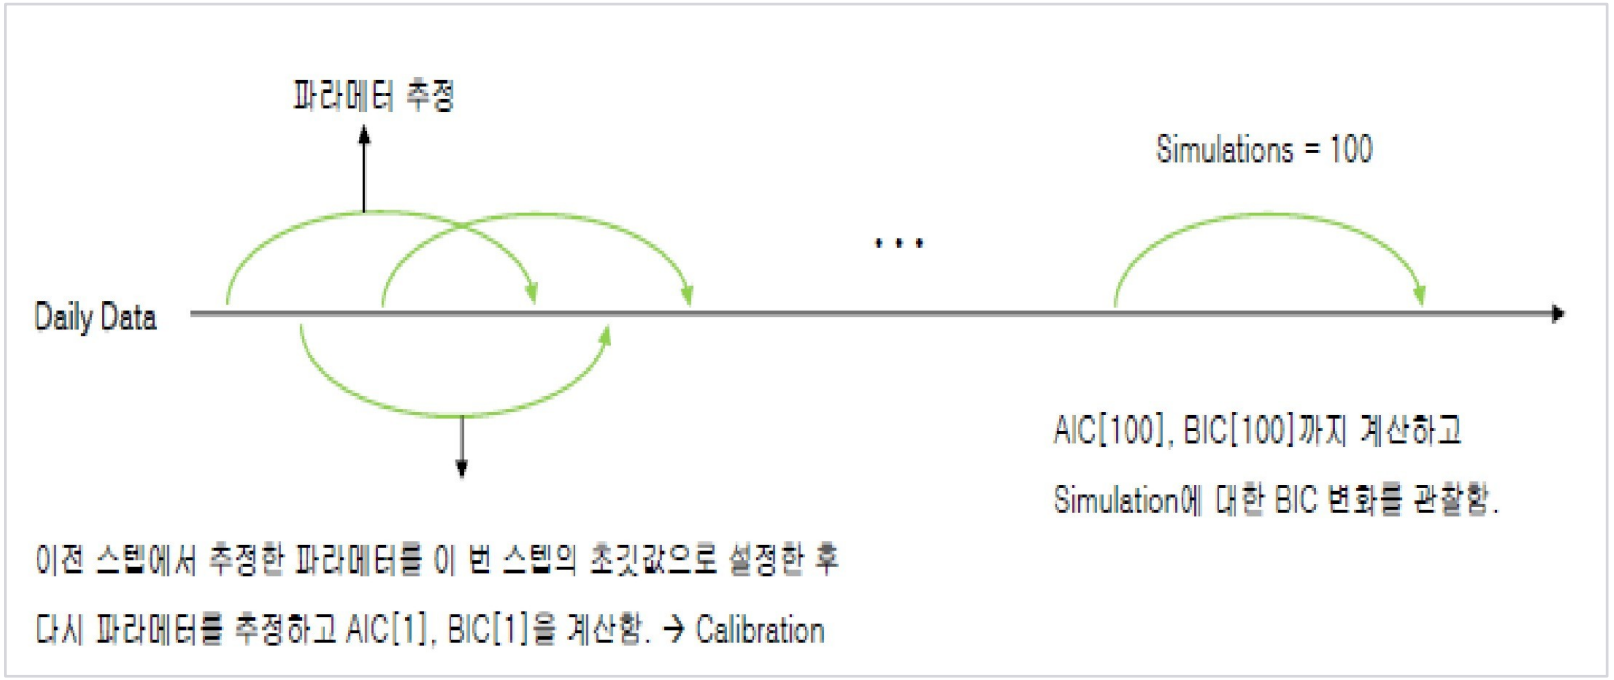
$$AIC = -2\ln(L) + 2k, \qquad BIC = -2\ln(L) + k\ln(M), \qquad k = N^2 + 2N - 1$$

반복 보정으로 시뮬레이션 100회의 AIC·BIC 변화를 추적한다

매 스텝은 이전 스텝에서 추정한 파라미터에서 출발한다

보정 반복

- 한 스텝 앞으로 이동
- 직전 λ에서 재추정
- AIC[i], BIC[i] 기록
- 100회 반복



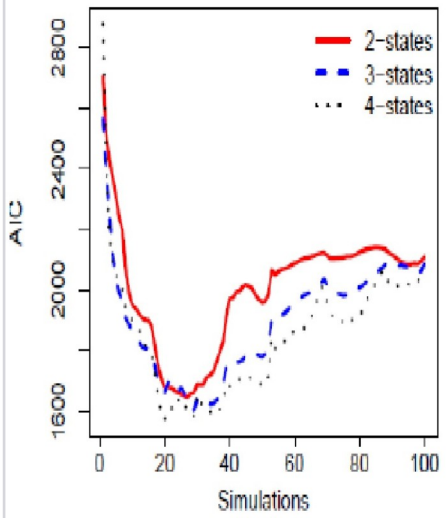
AAPL 논문에서는 상태 4개가 가장 낮고, BIC에서는 그 격차가 유지된다

애플 일별 데이터, 2015.1.6~2015.10.30 · 왼쪽 AIC, 오른쪽 BIC

논문 결과

- AIC: 상태 4개 최저, 격차 축소
- BIC: 상태 4개가 계속 최저
- 논문의 선택: 상태 4개
- 항상 U자형은 아님

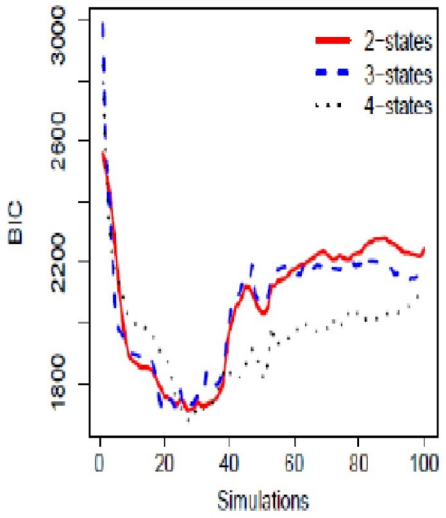
- State를 2,3,4로 변화해 가면서 이전 페이지 절차대로 AIC와 BIC를 측정한다.
- 아래 그림은 논문의 [Figure 1]으로 애플 종목의 상태 개수에 대한 AIC와 BIC의 변화를 보여준다.
- AIC의 경우 상태 개수 = 4일 때의 AIC가 작지만, Simulation이 증가할수록 모든 상태 개수에 대한 AIC가 수렴하고 있어 큰 차이가 없다. 그러나 BIC의 경우는 Simulation이 증가해도 상태 개수 = 4일 때가 작다. 따라서 애플 종목에 대해서는 상태 개수 = 4가 적당하다고 볼 수 있다 (논문의 내용임).
- 단, AIC나 BIC의 변화는 항상 아래와 같이 U-자형 모습을 보이는 건 아니다. 종목과 분석 기간에 따라 모양은 다를 수 있다.



종목 : 애플 (AAPL) Daily data

기간 : 2015.1.6 – 2015.10.30

Figure 1: AIC (left) and BIC (right) for 100 parameter calibrations of HMM using Apple, AAPL, stock daily trading prices

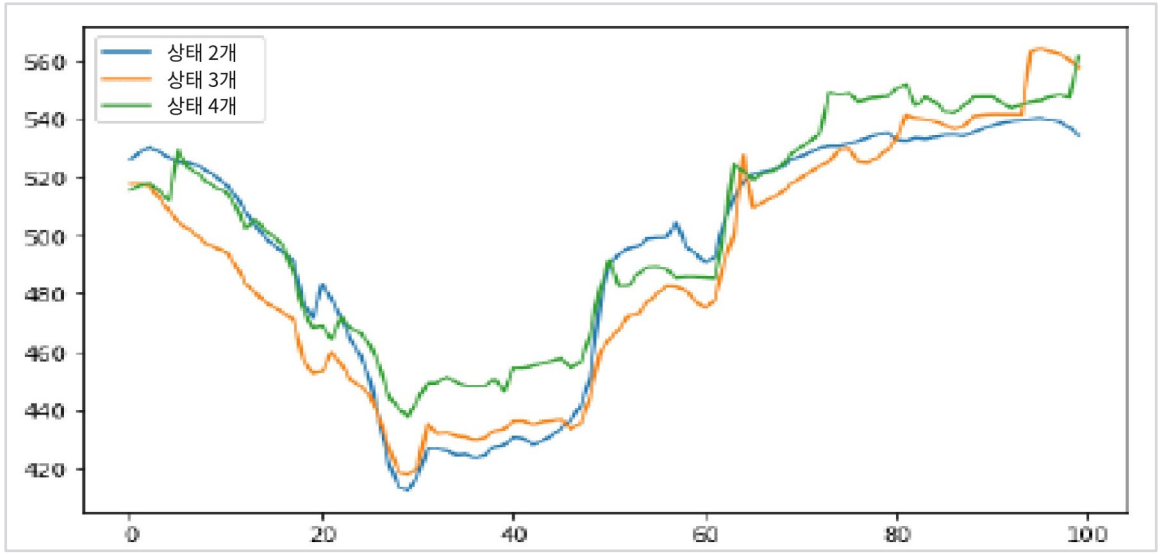


AAPL 종가만으로 BIC 비교를 다시 해 본다

hmmlearn, 논문과 같은 기간, 상태 2~4개

[입력] 프롬프트 · Claude Code

```
hmm-bic 폴더에서 다음을 해 줘.
1. AAPL 일별 종가를 받아 줘.
   기간: 2015.1.6~2015.10.30
2. hmmlearn 가우시안 HMM을 상태 2, 3, 4개로
   각각 적합해 줘.
3. 시뮬레이션 100회: 한 스텝씩 앞으로 옮기고
   직전 스텝의 파라미터에서 재추정해.
   창 길이는 먼저 제안해 줘.
4. 매회 BIC = −2 ln(L) + k ln(M)을 기록해.
   k = N² + 2N − 1
5. 상태 수별 BIC 곡선은 bic_close.png로,
   값은 bic_close.csv로 저장해.
```



[확인] 사람이 볼 점

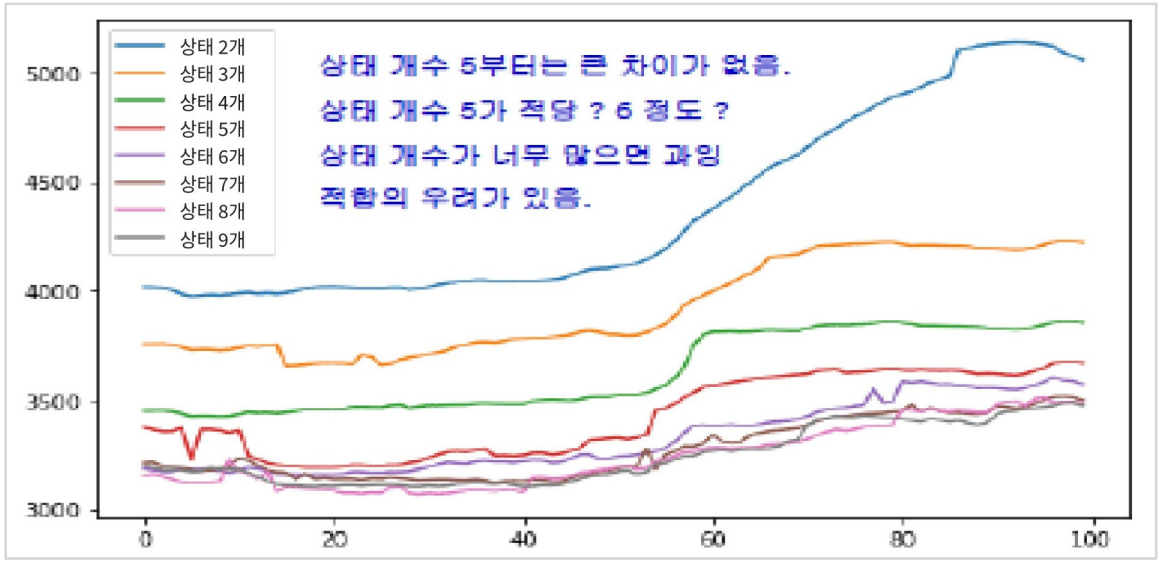
- k가 $N^2 + 2N - 1$인가
- 스텝마다 직전 파라미터에서 출발했는가
- BIC가 낮을수록 좋다: 어느 상태 수가 낮은가

OHLC를 입력하면 상태 5개 무렵부터 BIC 개선이 줄어든다

시가, 고가, 저가, 종가 · 상태 2~9개 · 상태가 너무 많으면 과적합 위험이 있다

[입력] 프롬프트 · Claude Code

```
hmm-bic 폴더에서 이어서 해 줘.
1. 입력을 시가, 고가, 저가, 종가 4개로 바꿔 줘.
   종목과 기간은 앞 장과 같아.
2. 상태를 2~9개로 늘려 줘.
3. 시뮬레이션 100회와 BIC 절차는 앞 장과 같게
   하고, k는 입력 차원에 맞게 다시 세어 줘.
4. 상태 수별 BIC 곡선은 bic_ohlc.png로,
   값은 bic_ohlc.csv로 저장해.
```



[확인] 사람이 볼 점

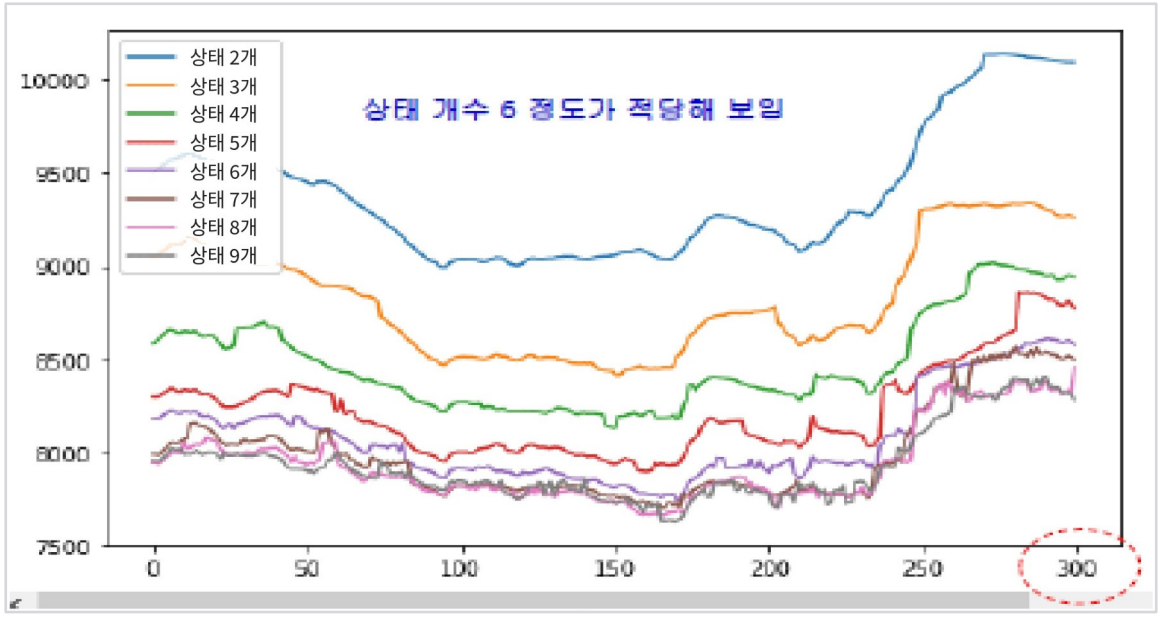
- k를 입력 차원에 맞게 세었는가
- 상태 5~6개 이후 개선이 작은가
- N이 크면 과적합: 고른 N이 너무 크지 않은가

KOSPI 지수 데이터는 은닉상태 6~7개를 가리킨다

슬라이드 본문은 7개, 차트 메모는 6개다. 상태 6~9개의 곡선은 거의 겹친다

[입력] 프롬프트 · Claude Code

```
hmm-bic 폴더에서 이어서 해 줘.
1. 데이터를 KOSPI 종합지수 일별 자료로 바꾸고
   사용한 기간을 적어 줘.
2. 상태는 2~9개로 둬.
3. 시뮬레이션을 300회 돌려 줘.
   절차는 앞 장과 같아.
4. 상태 수별 BIC 곡선은 bic_kospi.png로,
   값은 bic_kospi.csv로 저장해.
```



[확인] 사람이 볼 점

- 사용한 기간이 적혀 있는가
- 곡선이 상태 6~7개에서 수렴하는가
- 곡선이 겹치면 더 작은 N을 골랐는가

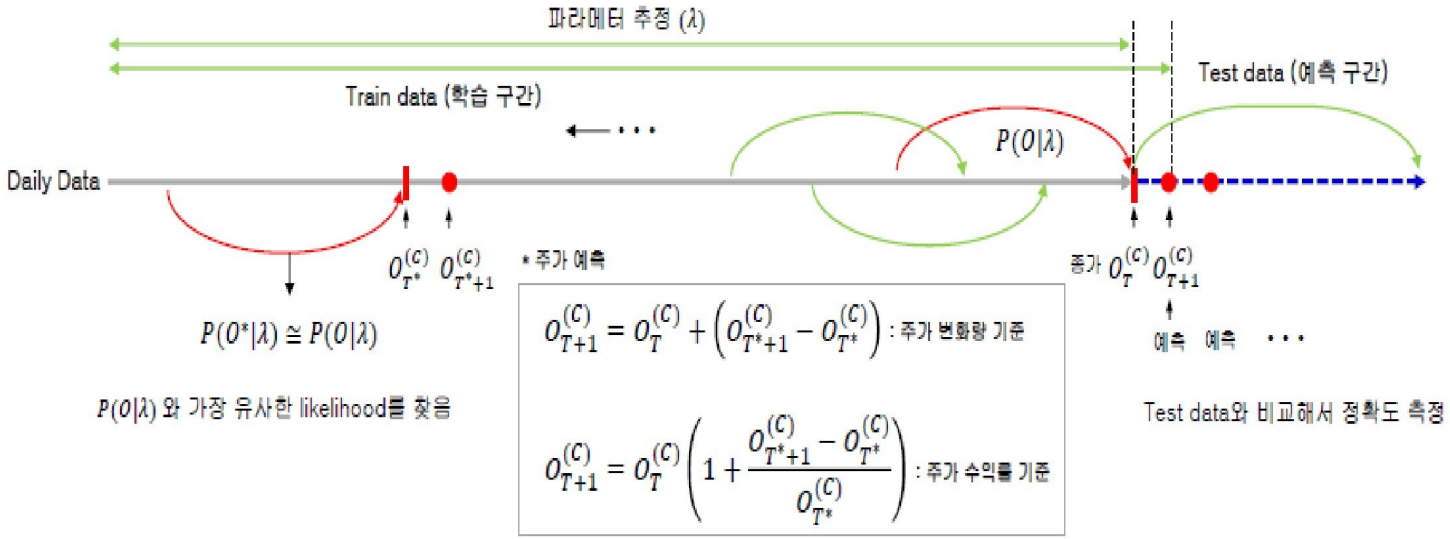
가장 비슷한 과거 날의 가격 변화를 빌려 예측한다

학습: λ 적합 · 오늘과 우도가 가장 가까운 날 찾기 · 그날의 변화 적용

세 단계

- 1 λ 보정, P(O|λ) 계산
- 2 P가 비슷한 과거 날 찾기
- 3 그날의 변화를 오늘에 적용
- 두 변형: 가격 변화 또는 수익률

▪ We first introduce how to predict stock prices using HMM. The prediction process can be divided by three steps. Step one: calibrate HMM's parameters and calculate likelihood of the model. Step 2: find a day in the past that has a similar likelihood to that of the recent day. Finally, step 3: use the difference of stock prices on the "similar" day in the past to predict future stock prices. This prediction approach is based on the work of Hassan and Nath [2]. ~~However, our procedure is different from their method in that we put the sign of the difference of the likelihood of recent day with likelihood of the "similar" day in the past into the calculation of future stock prices~~. Furthermore, we do not only use HMM with multiple observations (open, low, high, close price), as in [2], but also the HMM with one observation data (close price) to predict future close price. By using both single and multiple observations to predict stocks' close prices, we can examine which method performed better. The HMM with a single observation is a special case of HMM with multiple observations, thus we will explain in detail how to use HMM with multiple observations.

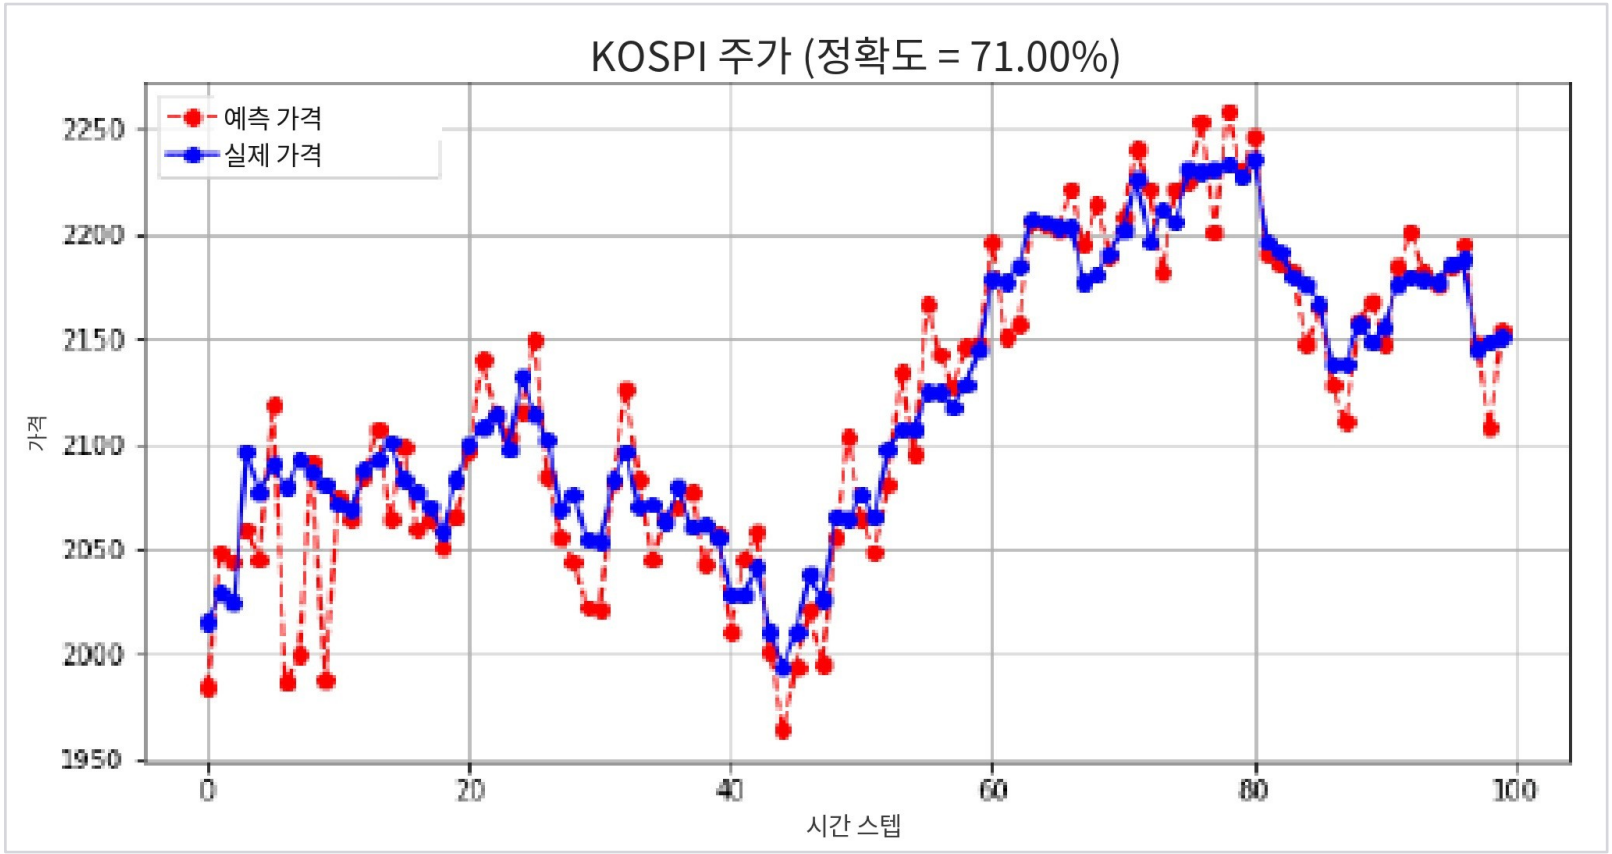


롤링 예측이 최근 100일의 KOSPI를 따라간다

테스트 구간에서 보고된 정확도는 71.00%다

결과

- 빨강: 예측 가격
- 파랑: 실제 가격
- 정확도 = 71.00%
- 같은 논리 → 내일 예측



3상태 HMM은 KOSPI 수익률을 뚜렷한 국면으로 나눈다

상태별 평균·변동성 추정치와 전이행렬

추정치

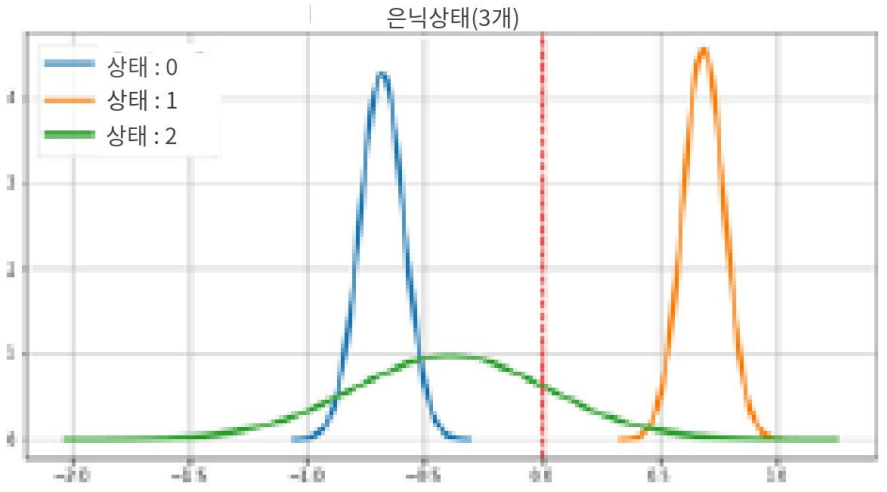
- μ: −0.681, 0.688, −0.389
- σ: 0.093, 0.088, 0.411
- 대각 성분: 0.855, 0.90, 0.932
- 국면은 지속성이 높음

```
mu :
 [[-0.681]
 [ 0.688]
 [-0.389]]

vol :
 [[0.093]
 [0.088]
 [0.411]]

Transition :
 [[0.855 0.118 0.027]
 [0.099 0.9   0.002]
 [0.017 0.051 0.932]]
```

3개의 주가 수익률 분포의 평균과 표준편차



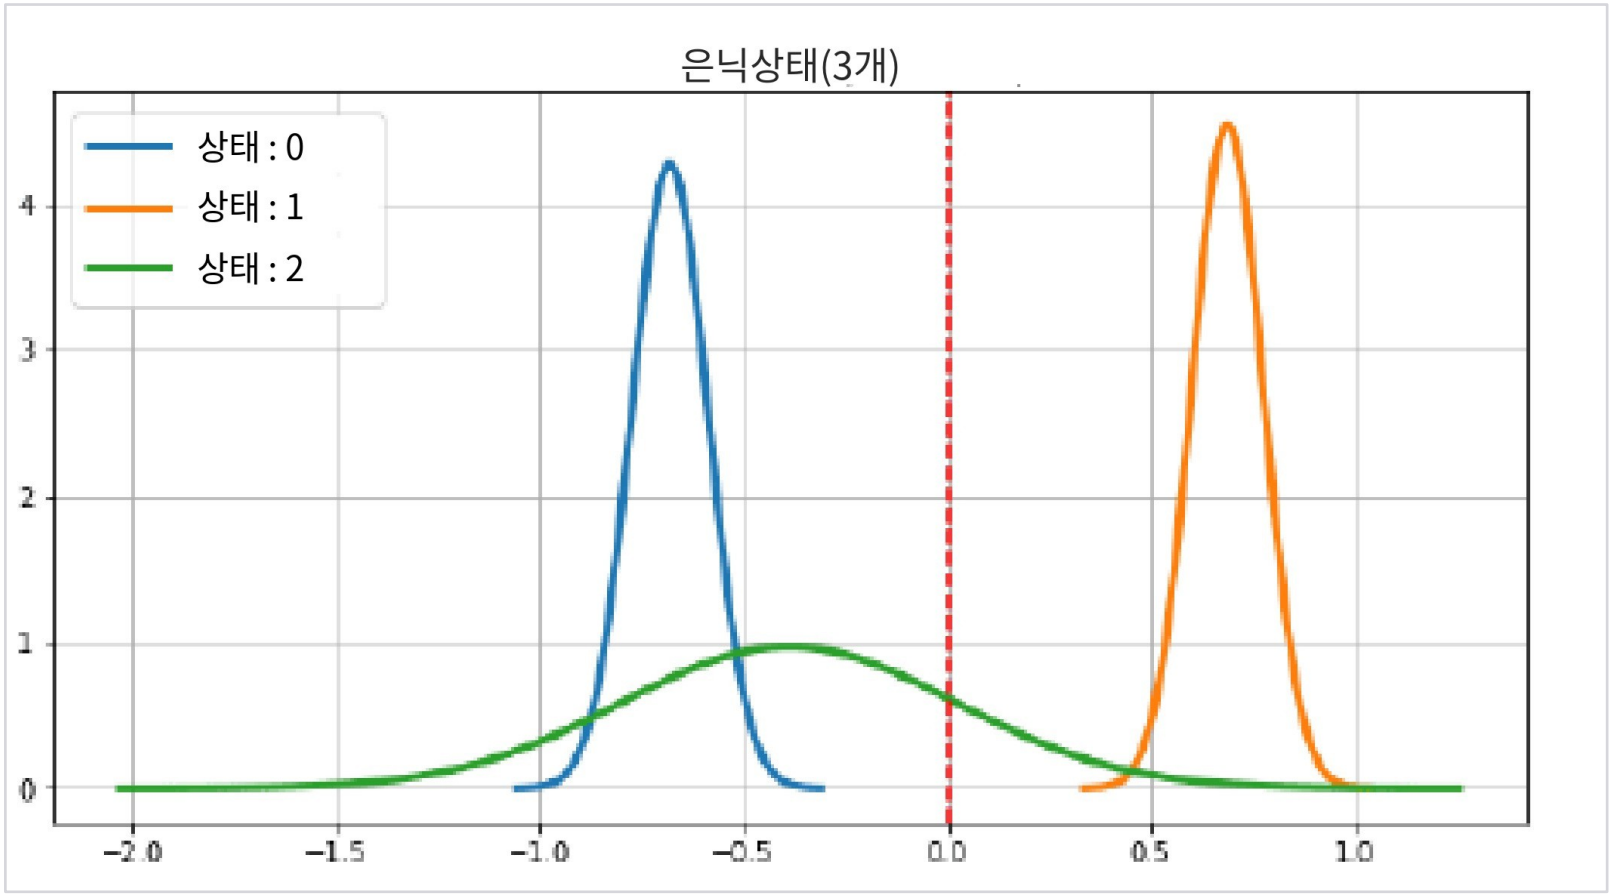
3개의 주가 수익률 분포의 전이 확률

수익률 분포를 보면 평온한 상태 2개와 변동성이 큰 상태 1개가 있다

상태 0: 평균이 음수 · 상태 1: 평균이 양수 · 상태 2: 분포가 넓음

곡선 읽기

- 파랑: 평온한 하락장
- 주황: 평온한 상승장
- 초록: 고변동성
- 빨간 선: 수익률 0



최근 300일 KOSPI 종가를 기준 그림으로 삼는다

2018-01~2019-03 일별 종가

먼저 볼 점

- 2018년 초 고점
- 2018년 말까지 하락
- 2019년 일부 반등

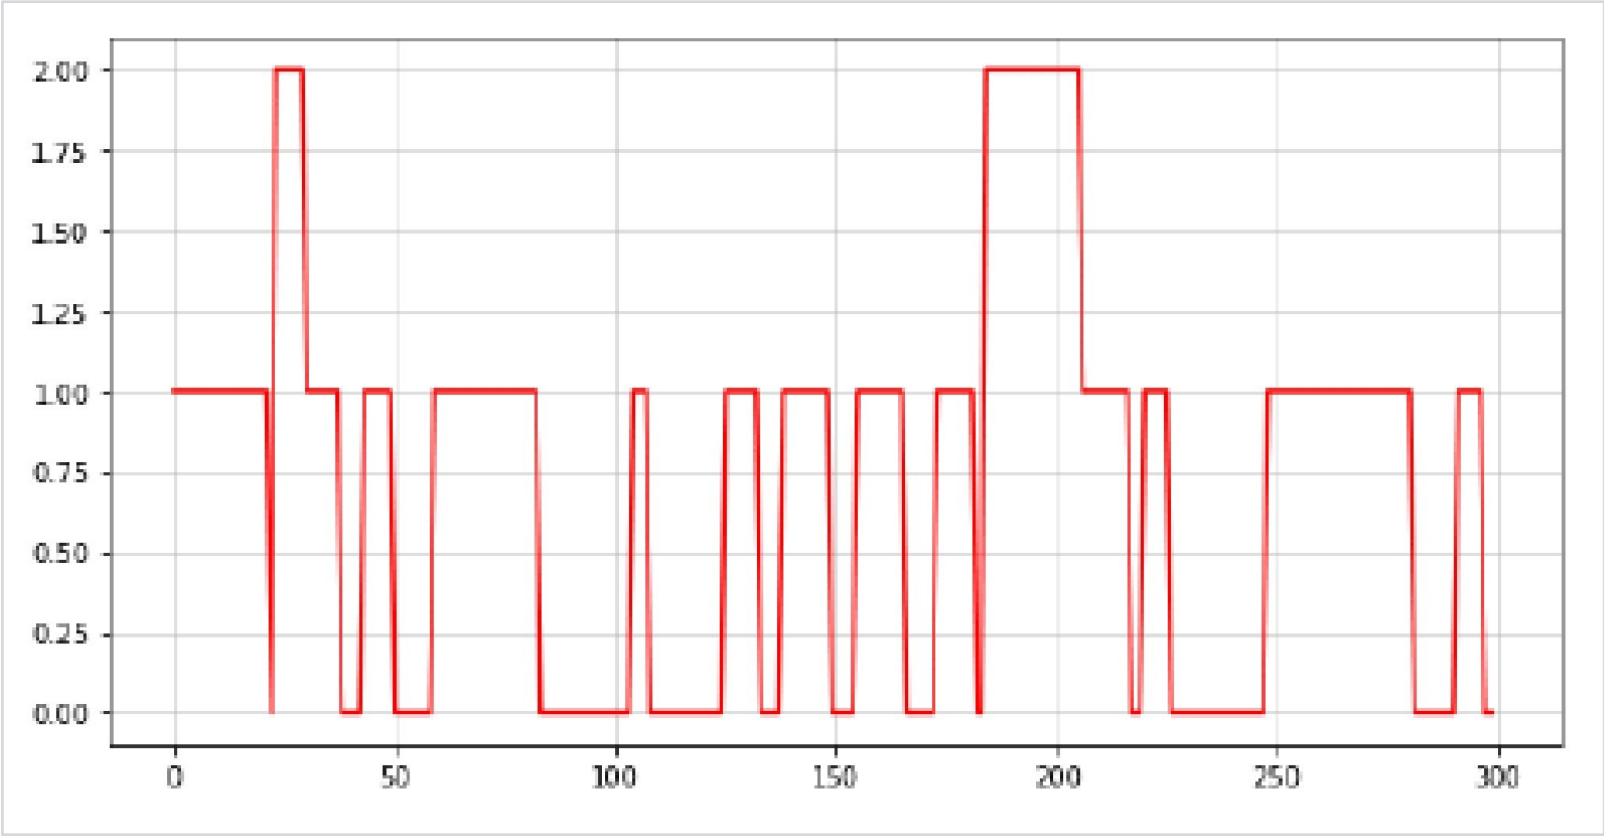


디코딩한 상태 경로에 시장 국면의 전환 시점이 나타난다

최근 300일 · 현재 상태 0 (슬라이드 표기로 평균 −0.681, 표준편차 0.093)

경로 읽기

- y축: 상태 0, 1, 2
- 2로 급등: 스트레스 구간
- 현재: 상태 0



파라미터, 분포, 상태 경로가 같은 내용을 가리킨다

KOSPI 주가 수익률 상태 변화 실습 요약

종합

- 표: μ, σ, A
- 곡선: 상태별 수익률
- 오른쪽 위: 상태 경로
- 오른쪽 아래: 주가

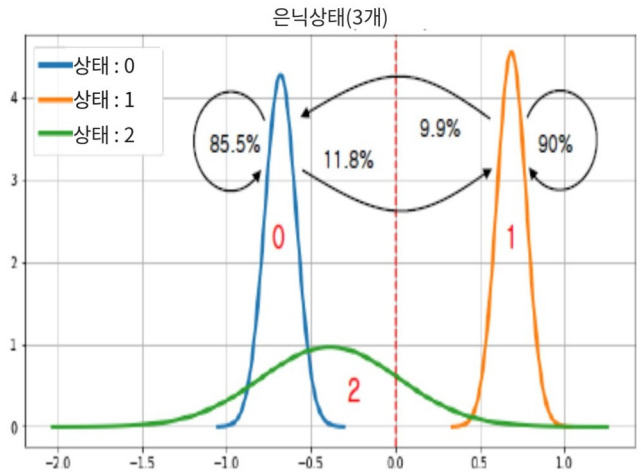
□ 주가 수익률 상태 변화 실습

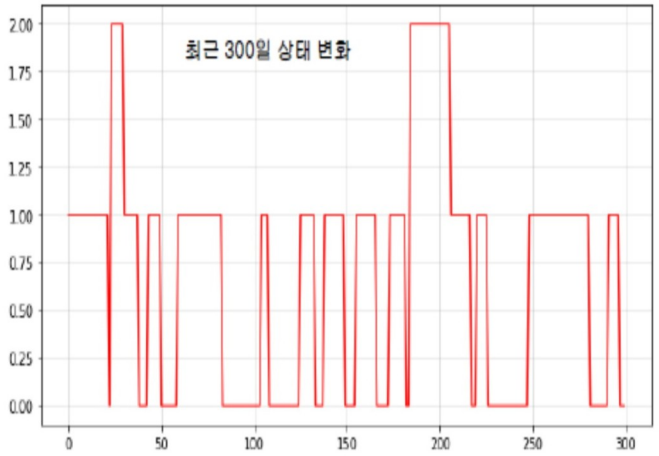
▪상태

상태	평균	표준편차
0	-0.681	0.093
1	0.688	0.088
2	-0.389	0.411

▪전이확률

상태	0	1	2
0	0.855	0.118	0.027
1	0.099	0.9	0.002
2	0.017	0.051	0.932







05

PART 5 · 정보 거래

정보 기반 거래에 대한 HMM 접근

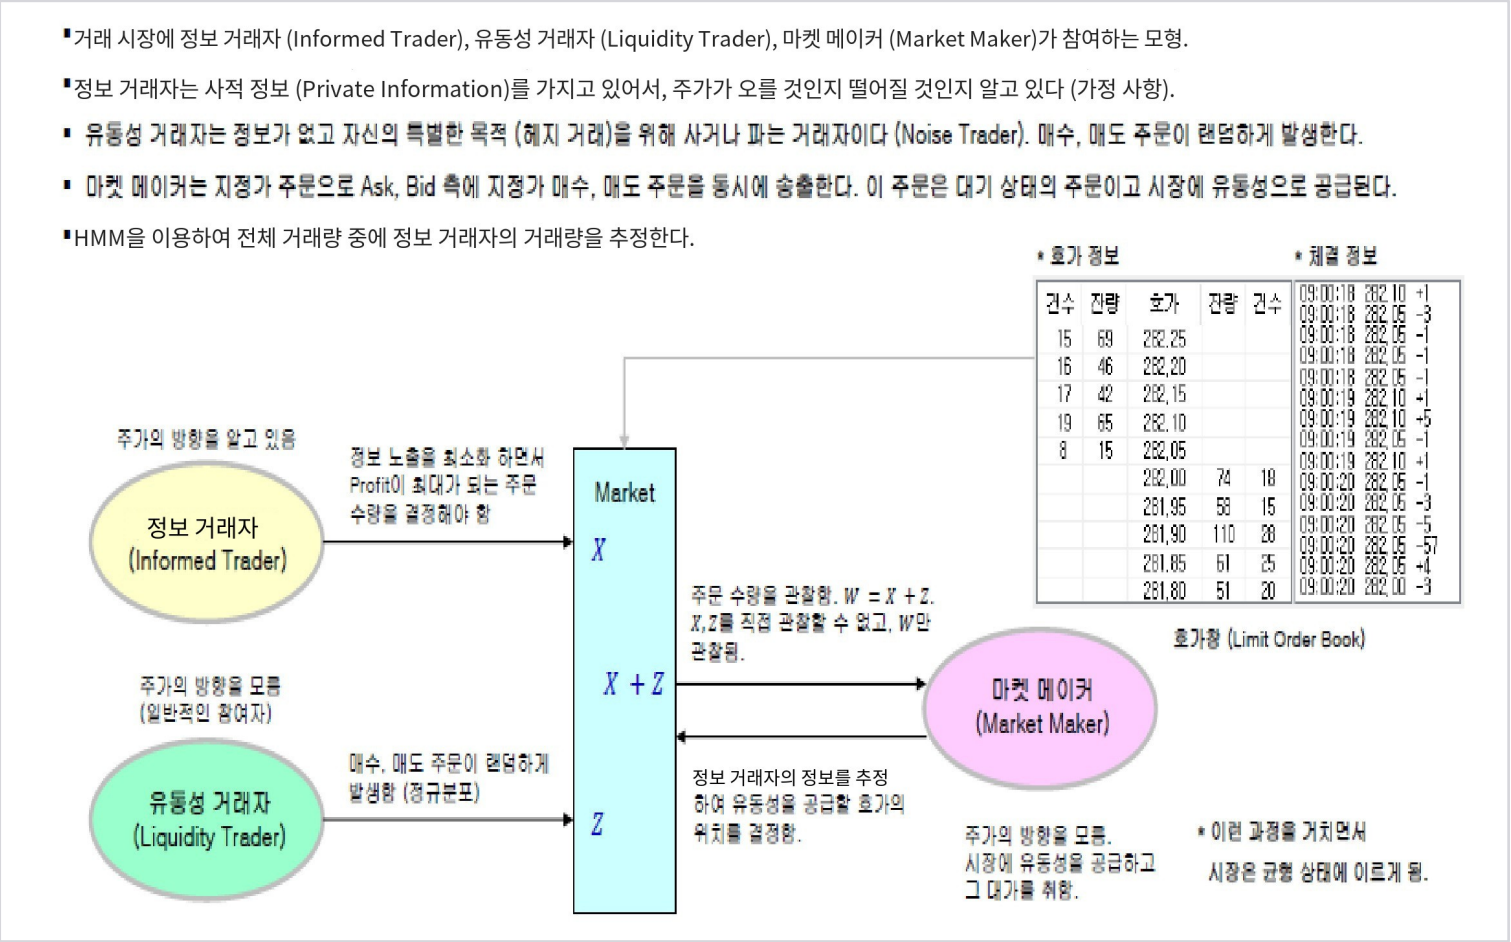
Kyle 모형, 거래량 시간, PIN과 VPIN

Kyle 모형의 참여자는 정보 거래자, 노이즈 거래자, 마켓메이커 셋이다

정보 거래자(informed trader) · 유동성 거래자(liquidity trader) · 마켓메이커(market maker)

참여자

- 정보 거래자: 사적 정보
- 유동성 거래자: 노이즈 주문
- 마켓메이커: 가격 설정
- HMM: 정보 거래량 비중



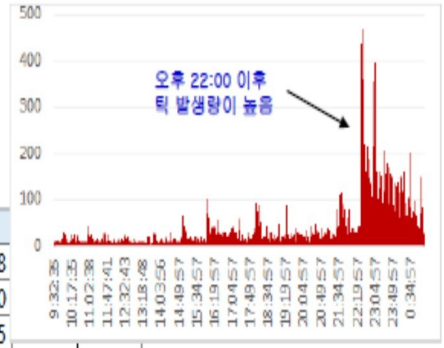
틱 시간 바는 시계 시간 바와 달리 거래 활동에 맞춰 조정된다

E-mini S&P 500 선물 · 시계 시간 캔들과 틱 시간 캔들

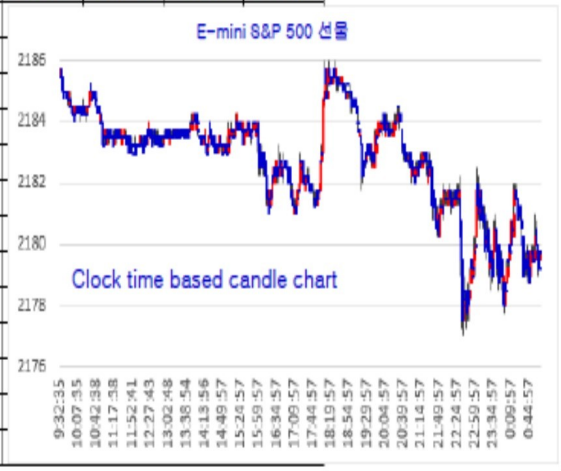
시계와 틱

- 시계: 시간 고정
- 틱: 체결 건수 고정
- 22:00 이후 거래 급증
- 틱 바는 정보량을 유지

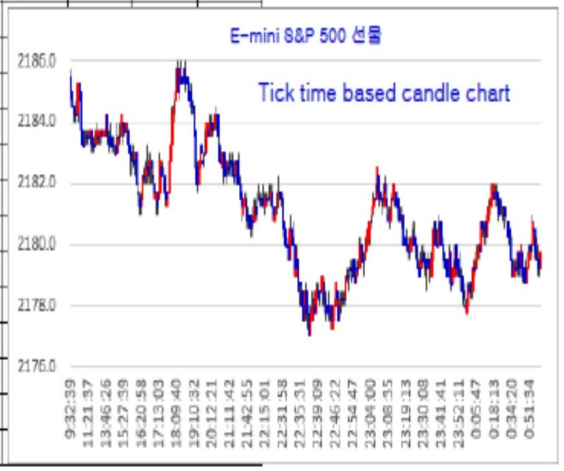
- 일반적인 주가의 캔들 차트는 일정 시간 동안의 주가 (시가, 고가, 저가, 종가)를 관찰한 것이다. → Clock time based candle chart.
- 금융 시장의 정보는 거래량에 반영되어 거래 시장으로 유입됨. 즉, 모든 정보는 주가에 반영된다. → The price is a vehicle of information.
- 그러나 거래량은 시간대에 따라 달라지므로 Clock time으로 구성된 각 캔들은 보유한 정보량이 다르다.
  예를 들어, 장 개장 직후와 폐장 직전에는 거래량이 많고, 점심 시간에는 거래량이 적기 때문에 장 개장 직후에 생성된 캔들과 점심 시간에 생성된 캔들을 동일하게 취급할 수 없다.
- 일정 수량의 체결 틱 데이터가 발생할 때마다 캔들을 구성하면 Tick time based candle chart라 한다.



time	ticks	open	high	low	close
9:32:35	8	2185.5	2185.75	2185.5	2185.5
9:33:35	5	2185.5	2185.75	2185.5	2185.75
9:34:35	6	2185.5	2185.5	2185.5	2185.5
9:35:35	11				
9:36:35	5				
9:37:35	8				
9:38:35	14				
9:39:35	14				
9:40:35	9				
9:41:35	12				
9:42:35	3				
9:43:35	11				
9:44:35	1				
9:45:35	3				
9:46:35	8				
9:47:35	6				



time	ticks	open	high
9:32:39	100	2185.5	2185.8
9:43:50	100	2185.0	2185.0
9:55:48	100	2184.5	2184.5
10:01:41	100		
10:14:49	100		
10:23:12	100		
10:31:39	100		
10:42:02	100		
10:54:45	100		
10:57:41	100		
11:03:49	100		
11:12:24	100		
11:21:37	100		
11:32:22	100		
11:41:19	100		
11:50:13	100		



거래량 시간 바는 일정 거래량이 체결되면 닫힌다

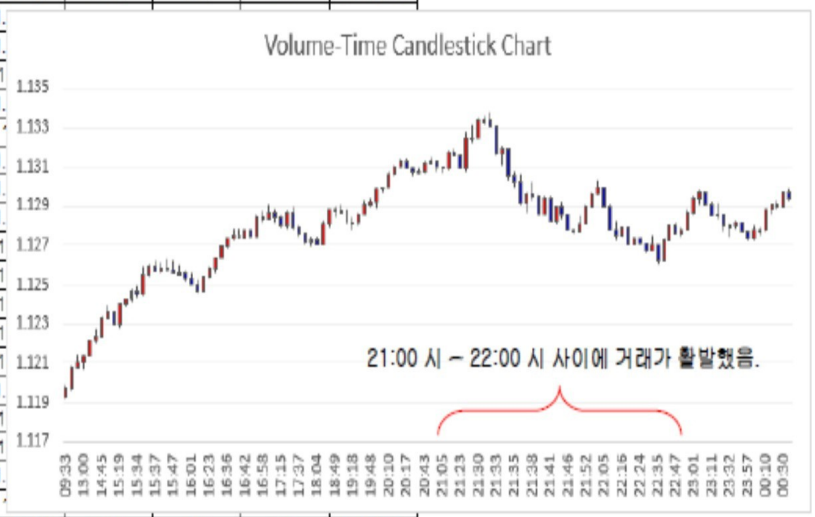
EUR/USD 선물, 2016-08-16 · 바당 1,500계약 · 바별 매수/매도 비율

거래량 시간

- 바 = 일정 거래량
- 매수·매도 기록
- 바별 비율 B/S
- HMM의 입력값

▪ 일정 거래량이 발생할 때마다 캔들을 구성하면 Volume time based candle chart라 한다.

	A	B	C	D	E	F	G	H	I	J	K
1	Euro Currency Futures EUR/USD (2016.8.16 09:32:39 ~ 익일 01:08:00)										
2	date	time	ticks	open	high	low	close	volume	buy	sell	buy/sell
3	2016-08-16	09:33	475	1.11925	1.1199	1.1192	1.1197	1500	795	705	1.1276596
4	2016-08-16	11:38	376	1.1197	1.12085	1.1196	1.1208	1500	962	538	1.7881041
5	2016-08-16	12:20	332	1.1208	1.12145	1.12075	1.121	1500	837	663	1.2624434
6	2016-08-16	13:00	280	1.121	1.1214	1.1207	1.12135	1500	956	544	1.7573529
7	2016-08-16	13:58	290	1.12135	1.1222	1.12135	1.				
8	2016-08-16	14:17	396	1.12215	1.12275	1.122	1.				
9	2016-08-16	14:45	388	1.12235	1.12335	1.1223	1				
10	2016-08-16	15:05	238	1.1233	1.12395	1.1233	1.				
11	2016-08-16	15:07	295	1.12365	1.12365	1.123					
12	2016-08-16	15:19	246	1.123	1.12405	1.12285	1.				
13	2016-08-16	15:31	164	1.12405	1.1243	1.1239	1.				
14	2016-08-16	15:33	186	1.12425	1.1248	1.1241	1.				
15	2016-08-16	15:34	219	1.12465	1.1249	1.12435	1				
16	2016-08-16	15:36	159	1.1245	1.1259	1.12445	1				
17	2016-08-16	15:36	280	1.1255	1.12605	1.1254	1				
18	2016-08-16	15:37	290	1.1259	1.12625	1.12565	1				
19	2016-08-16	15:39	327	1.1257	1.12615	1.1256	1				
20	2016-08-16	15:42	288	1.1258	1.12635	1.12565	1.				
21	2016-08-16	15:47	259	1.12575	1.12625	1.1256	1				
22	2016-08-16	15:53	258	1.1256	1.126	1.1255	1				
23	2016-08-16	15:58	231	1.1256	1.1257	1.12515	1.				
24	2016-08-16	16:01	318	1.12535	1.1256	1.125					
25	2016-08-16	16:07	305	1.125	1.12525	1.1246	1.12465	1500	600	900	0.6666667
26	2016-08-16	16:14	344	1.12465	1.1254	1.12465	1.1254	1500	891	609	1.4630542
27	2016-08-16	16:23	215	1.1254	1.1259	1.1253	1.12585	1500	1075	425	2.5294118
28	2016-08-16	16:28	348	1.12585	1.1264	1.1256	1.1264	1500	955	545	1.7522936



HMM은 매수·매도 흐름에서 정보 거래 비중을 추론한다

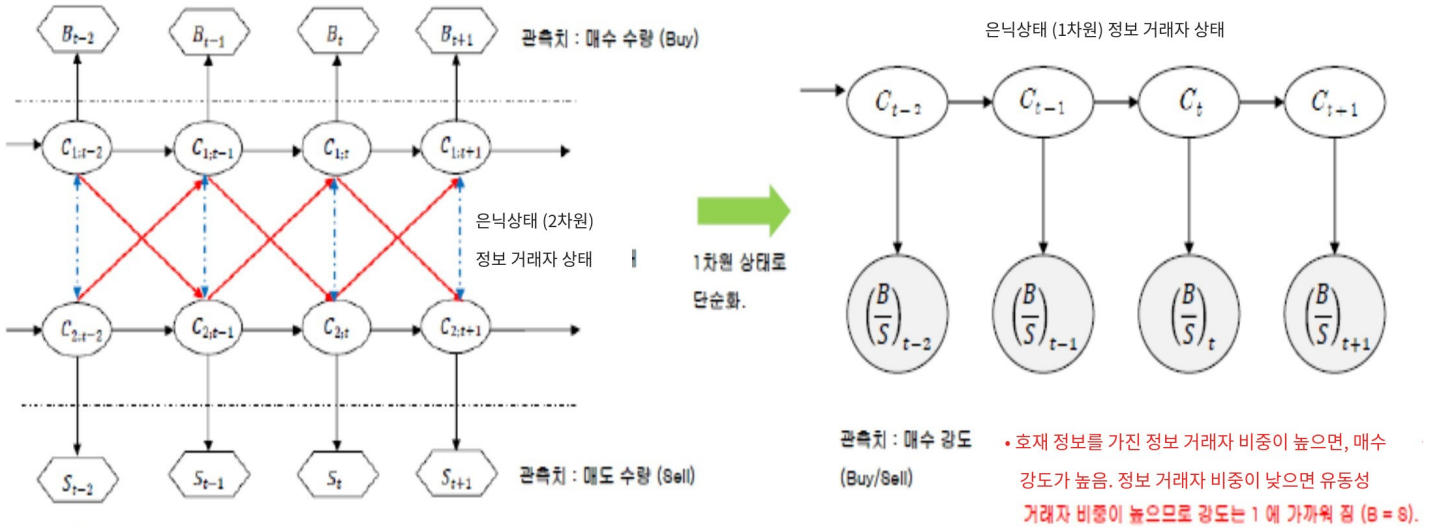
Yin & Zhao (2012), A Hidden Markov Process Approach to Information-Based Trading

모형

- 은닉상태: 정보 거래 비중
- 관측값: 매수, 매도
- 2차원 → 1차원
- 관측값: B/S

HMM에 의한 정보 거래자의 은닉상태 (비중) 추론

- 시장에 유입되는 매수 (Buy), 매도 (Sell) 주문 수량, 혹은 매수 주문 강도 (Buy / Sell)을 관찰하여 정보 거래자의 비중을 추정한다.
- 정보 거래자의 참여 비중은 주문 수량의 은닉상태로 볼 수 있다. 정보 거래자가 호재성 정보를 가지고 있다면 매수 주문이 매도 주문에 비해 많을 것이고, 악재성 정보를 가지고 있다면 매도 주문이 많을 것이다. 정보 거래자가 없다면 (시장에 유입되는 정보가 없다면), 시장에는 Noise Trader만 있으므로 매수, 매도 주문이 랜덤하게 발생할 것이다.
- Market microstructure 분야에서 정보 거래자의 참여 비중을 추정하는 모형으로 PIN (Probability of Informed Trading), VPIN (Volume Synchronized PIN) 모형이 있으며, HMM 으로도 PIN을 추정해 볼 수 있다.



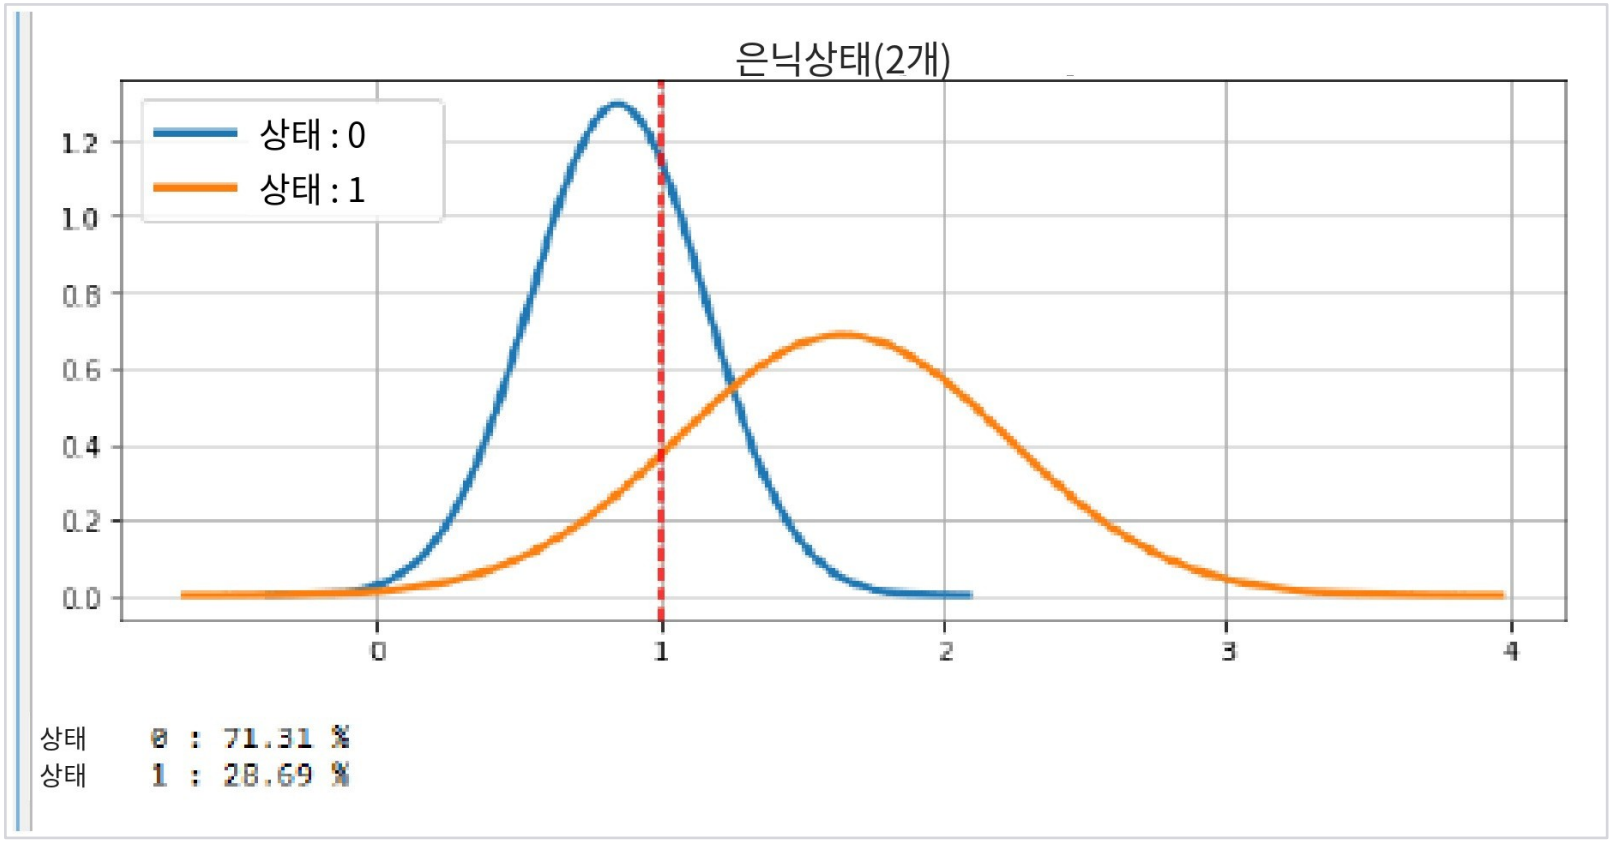
• 그림 출처 : Xiangkang Yin, Jing Zhao, 2012, A Hidden Markov Process Approach to Information-Based Trading. (Figure 2)

두 상태는 평상시 흐름과 매수 우위 흐름을 가른다

B/S에 적합한 가우시안 HMM · 상태 1(평균 B/S > 1)이 전체 바의 28.69%

두 상태

- 상태 0: 71.31%
- 상태 1: 28.69%
- 빨간 선: B/S = 1
- 상태 1 = 정보 거래자의 매수

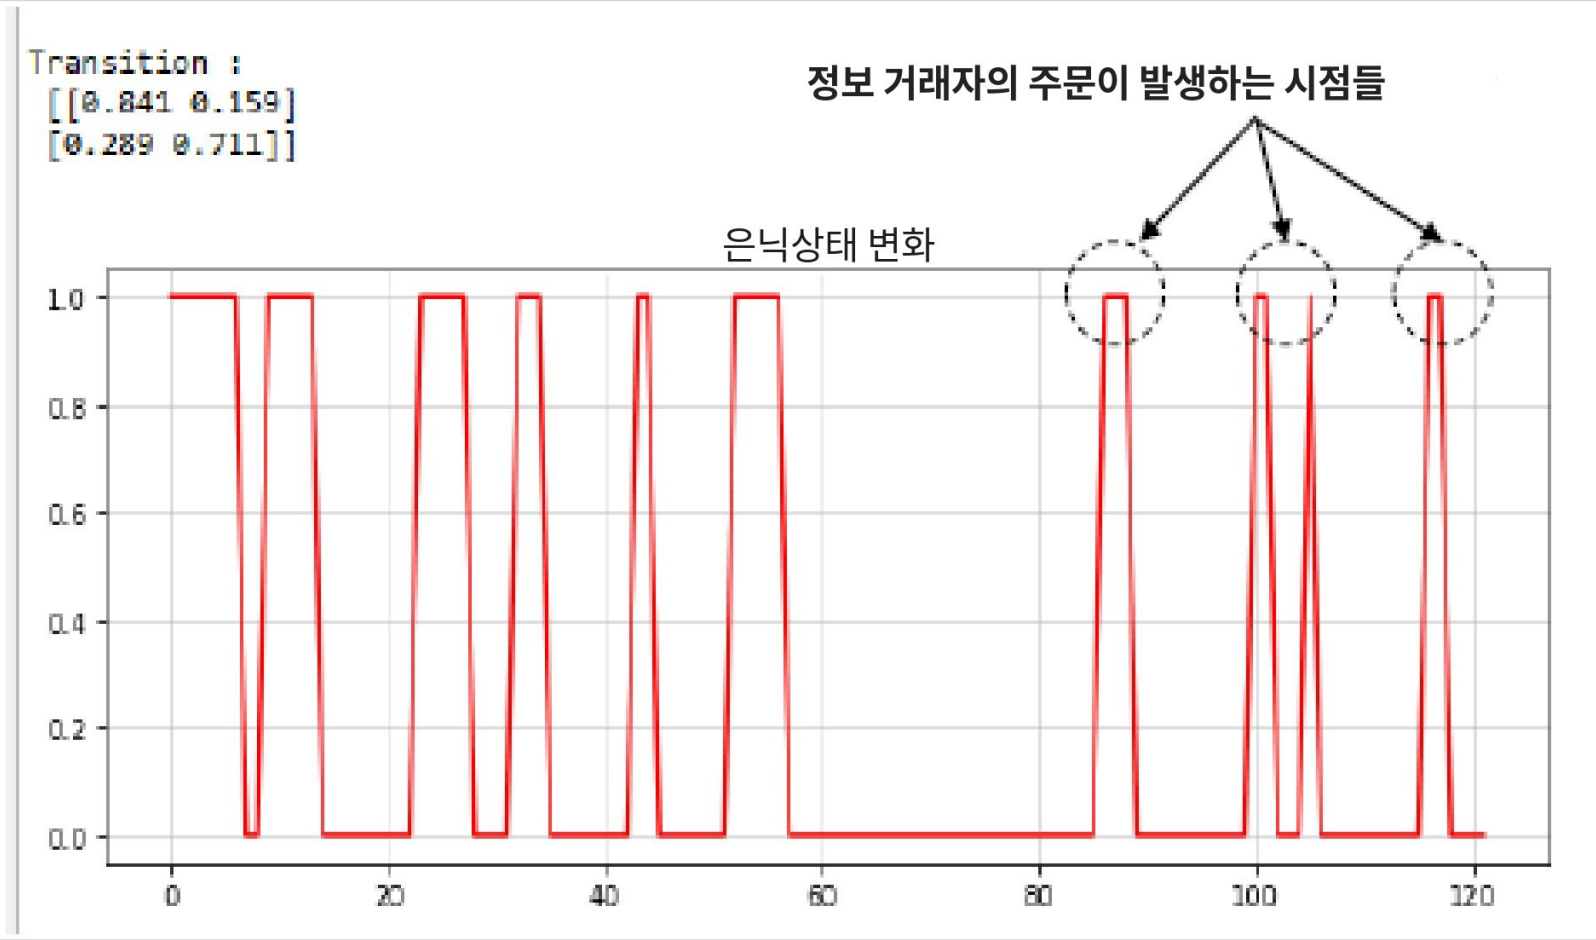


상태 경로에서 정보 거래 주문은 짧은 급증으로 나타난다

전이: 유지 0.841 · 정보 거래로 전환 0.159 (슬라이드 본문: 0.84 / 15.9%)

경로 읽기

- 현재: 상태 0
- 유지 확률 0.841
- 전환 확률 0.159
- 원: 정보 거래 급증

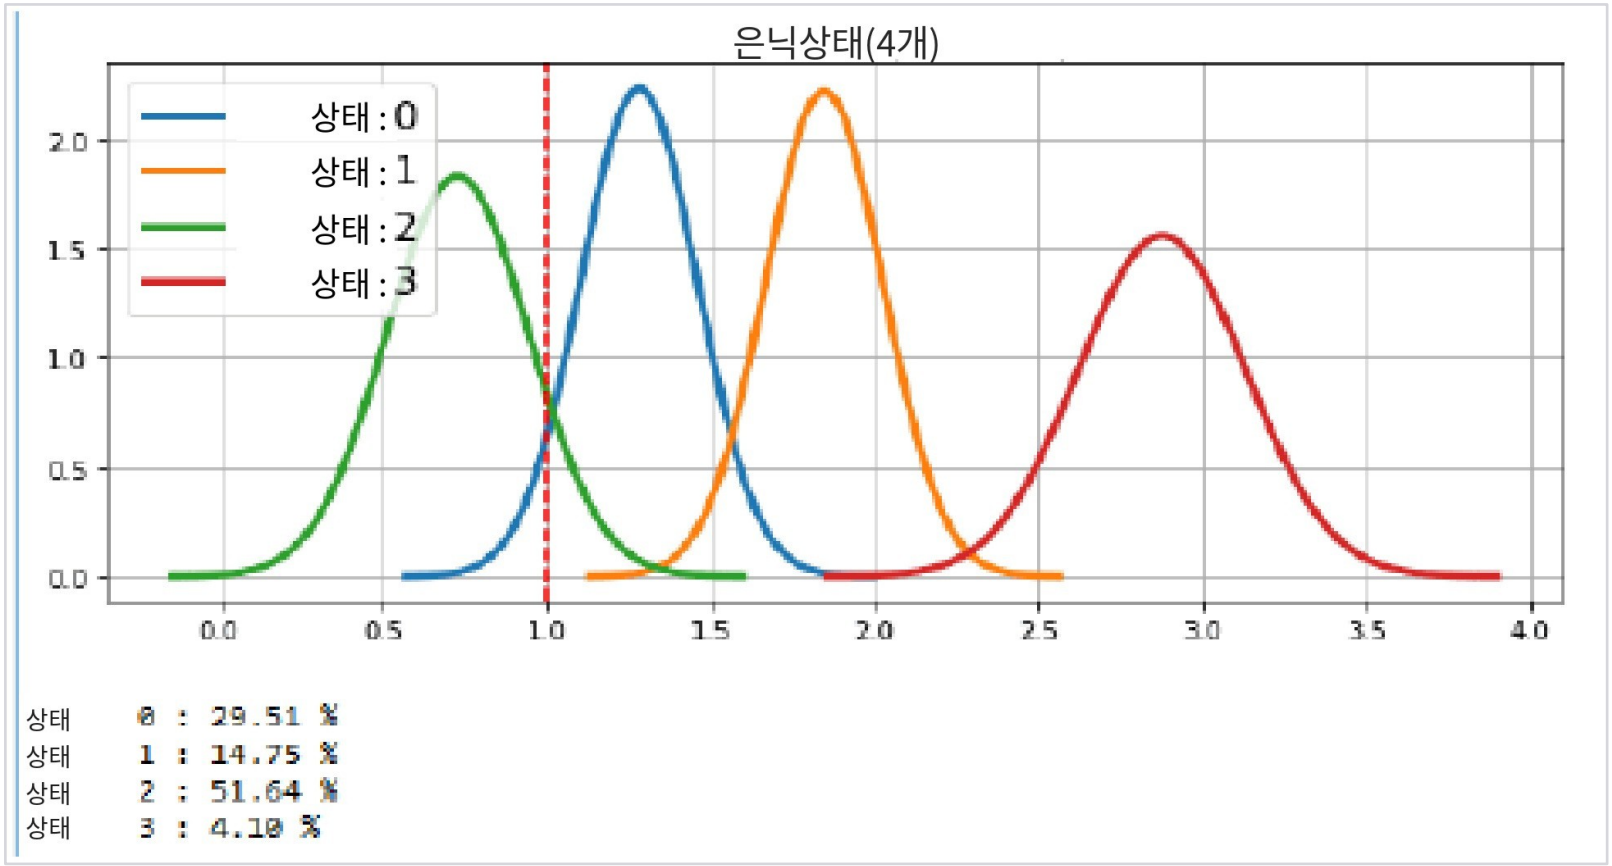


상태 4개로 구조 모형 없이 주문 흐름을 기술한다

HMM에는 Kyle 모형이나 PIN의 가정이 필요 없다

네 상태

- 상태 0: 29.51%
- 상태 1: 14.75%
- 상태 2: 51.64%
- 상태 3: 4.10%

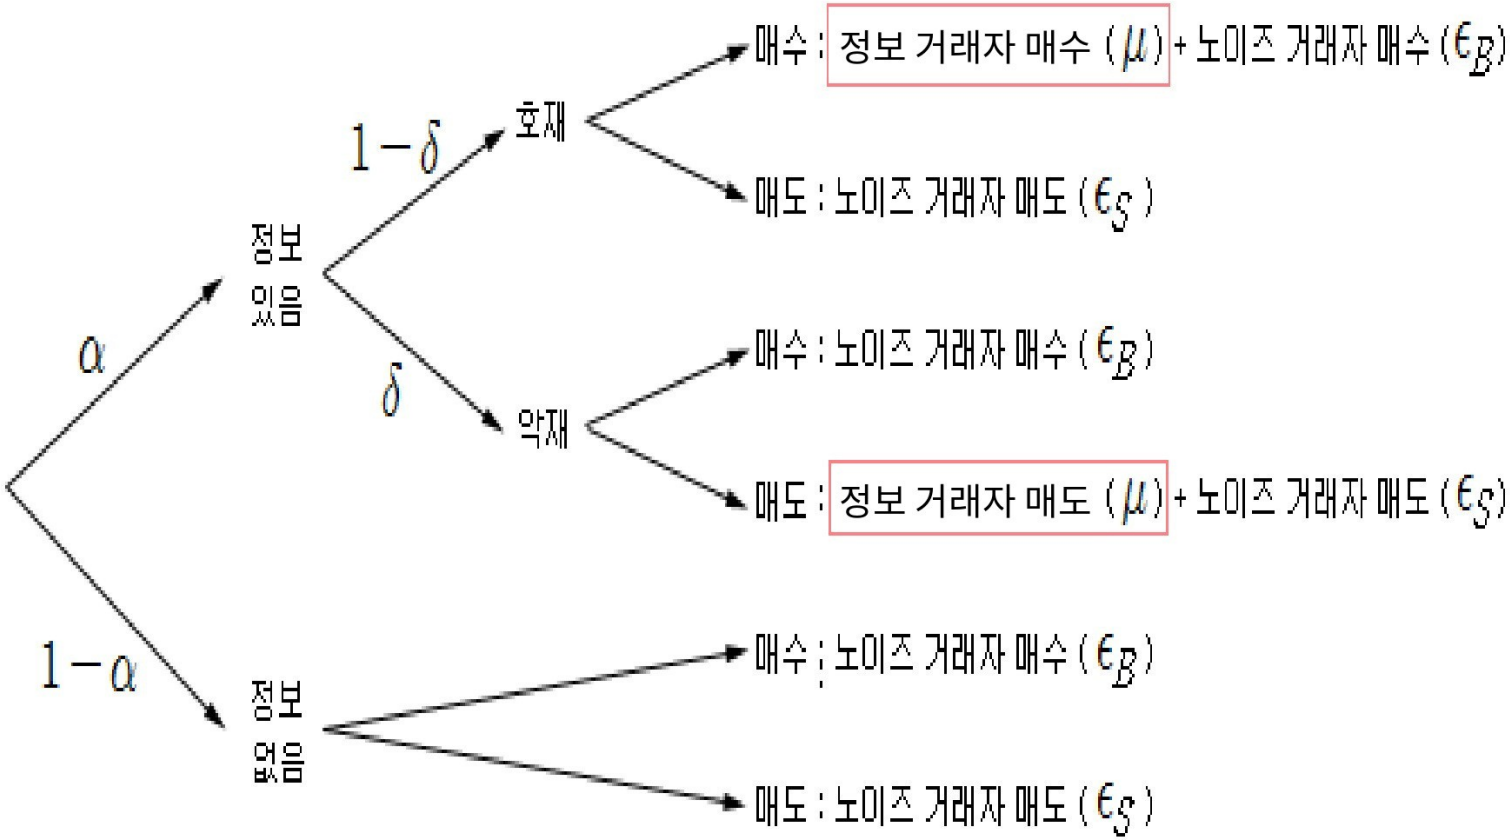


PIN은 거래 도착을 정보 사건의 나무로 모형화한다

정보 거래 확률(Probability of Informed Trading, PIN) · Easley et al. (1996) · 정보 있음, 호재, 악재

사건 나무

- α: 정보 사건 발생
- δ: 악재일 확률
- μ: 정보 거래 도착률
- ε_B, ε_S: 노이즈 매수, 매도



PIN은 전체 거래 강도에서 정보 거래가 차지하는 비중이다

원본 슬라이드의 유도: 매수, 매도, 총 거래 강도

절차

- 매수: α(1−δ)μ + ε_B
- 매도: αδμ + ε_S
- 합계: αμ + ε_B + ε_S
- PIN = αμ / 합계

1) 매수 강도 $= \alpha(1-\delta)(\mu+\epsilon_B) + \alpha\delta\epsilon_B + (1-\alpha)\epsilon_B$

$= \alpha(1-\delta)\mu + \epsilon_B$ ← 시장에서 관측되는 총 매수 강도

2) 매도 강도 $= \alpha(1-\delta)\epsilon_S + \alpha\delta(\mu+\epsilon_S) + (1-\alpha)\epsilon_S$

$= \alpha\delta\mu + \epsilon_S$ ← 시장에서 관측되는 총 매도 강도

3) 총 거래 강도 $= \alpha(1-\delta)\mu + \epsilon_B + \alpha\delta\mu + \epsilon_S$

$= \alpha\mu + \epsilon_B + \epsilon_S$ ← 총 매수 강도 + 총 매도 강도

4) 정보 거래자의 총 거래 강도 $= \alpha\mu$ ← 정보 거래자는 정보가 있는 경우만 거래함

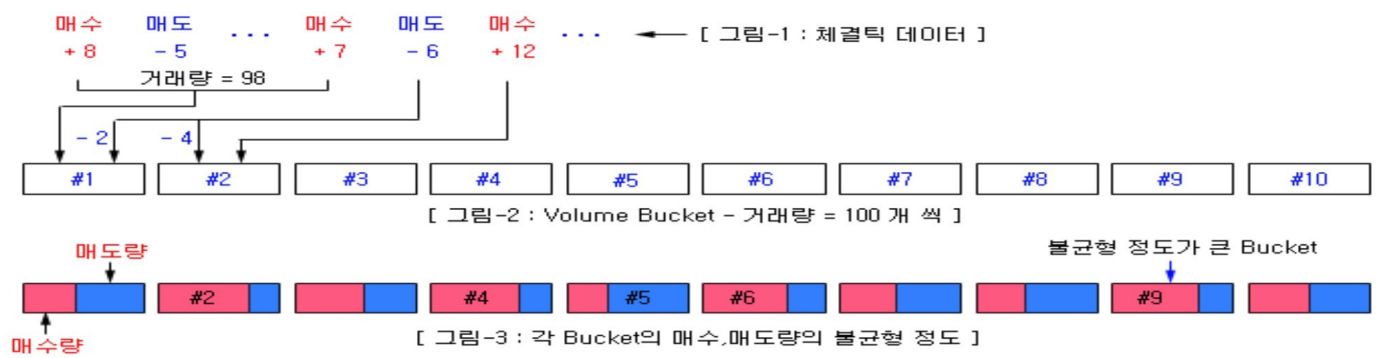
5) $PIN = \dfrac{\text{정보 거래자의 총 거래 강도}}{\text{총 거래 강도}} = \dfrac{\alpha\mu}{\alpha\mu + \epsilon_B + \epsilon_S}$

VPIN은 거래량 버킷의 매수·매도 불균형으로 PIN을 추정한다

거래량 동기화 PIN(Volume-Synchronized PIN, VPIN) · 버킷마다 거래량 V가 같고, 불균형 |S − B|가 αμ의 대리변수다

절차

- 거래를 버킷으로 묶음
- |S_i − B_i| 측정
- 평균을 내고 V로 나눔
- VPIN ≈ PIN



1) $PIN = \frac{\alpha\mu}{\alpha\mu + 2\epsilon}$

2) $\alpha\mu \approx E[|S - B|] = \frac{1}{n}\sum_{i=1}^{n}|S_i - B_i|$ ← n = Volume Bucket의 총 개수, S_i = i 번째 Volume Bucket의 매도 (Sell) 수량, B_i = i 번째 Volume Bucket의 매수 (Buy) 수량

3) $\alpha\mu + 2\epsilon = E[S + B] = V$ ← 각 Bucket의 거래량 (V)을 일정하게 만들었으므로 Constant 임

4) $PIN = \frac{\alpha\mu}{\alpha\mu + 2\epsilon} \approx \frac{1}{nV}\sum_{i=1}^{n}|S_i - B_i| = VPIN$

5) $VPIN = \frac{1}{nV}\sum_{i=1}^{n}|S_i - B_i|$

PIN과 VPIN은 전체 흐름 대비 정보 거래의 비율로 귀결된다

원본 슬라이드의 수식

$$PIN = \frac{\alpha\mu}{\alpha\mu+\epsilon_B+\epsilon_S}$$

$$VPIN = \frac{1}{nV}\sum_{i=1}^{n}|S_i - B_i|$$

PIN

- 최대우도추정(MLE)으로 α, δ, μ, ε 추정 필요
- 일별 매수·매도 건수

VPIN

- 거래량 버킷 사용, MLE 불필요
- 고빈도에서 사용 가능

주문 흐름 불균형(OFI)은 최우선 호가의 매수·매도 변화를 집계한다

주문 흐름 불균형(Order-Flow Imbalance) · Cont et al. (2010) · 이벤트 단위 e_n을 구간 k에 걸쳐 합산

OFI

- 매수호가 이벤트: + q_B
- 매도호가 이벤트: − q_A
- 구간별로 e_n 합산
- HMM의 또 다른 입력값

대안으로, 이벤트 기반(Level-1) OFI는 (Cont et al., 2010)에 따라 호가창 이벤트에 기반한다:

$$e_n = I_{\{P_n^B \geq P_{n-1}^B\}} q_n^B - I_{\{P_n^B \leq P_{n-1}^B\}} q_{n-1}^B - I_{\{P_n^A \leq P_{n-1}^A\}} q_n^A + I_{\{P_n^A \geq P_{n-1}^A\}} q_{n-1}^A$$

구간 k에 걸쳐 합산한다:

$$\mathrm{OFI}_k = \sum_{n=N(t_{k-1})+1}^{N(t_k)} e_n$$

원본 슬라이드의 몇몇 서술은 주의해서 읽어야 한다

쪽 번호는 원본 강의 슬라이드 기준이며, 아래 사항을 참고해 그림을 읽는다

원본 쪽	원문 표기	참고
p.2	E단계에서 중심을 찾고 M단계에서 거리를 최소화	일반적인 순서: 점 배정(E) 뒤 중심 이동(M)
p.24	본문: 상태 약 7개	차트 메모는 6개, 둘 다 타당
p.30	연간 평균 −0.681, 표준편차 0.093	p.27의 상태 0 μ, σ와 같은 수치, 단위 표기 없음
p.38	0.84와 15.9%	행렬에는 0.841과 0.159

네 가지 질문으로 알고리즘과 시장 활용을 잇는다

날씨 예제와 KOSPI 실습을 활용한다

Q1	K-Means와 HMM 모두 수익률을 집단으로 나눌 수 있다. HMM은 무엇을 더하는가?	**군집화**
Q2	날마다 가장 가능성이 높은 단일 상태가 Viterbi 경로와 다를 수 있는 이유는 무엇인가?	**디코딩(Decoding)**
Q3	Baum-Welch 알고리즘은 국소 최적해를 찾는다. KOSPI에서 시작 θ를 어떻게 고르겠는가?	**학습(Learning)**
Q4	B/S의 상태 1이 전체 바의 28.69%를 차지한다. 그것만으로 매매 신호가 되는가?	**주문 흐름**

요약

EM 아이디어 하나가 군집화에서 시장 국면까지 이어진다

묶고, 시간을 더하고, 시장에 적용한다

1

K-Means는 순서 없이 군집화한다

배정과 갱신 단계가 이미 EM의 형태를 따른다.

2

HMM 알고리즘은 시간 차원을 더한다

Forward는 경로를 합하고(3.10%), Viterbi는 최선의 경로를 남긴다(S → R → R → S, 0.2419%).

3

시장 데이터가 국면과 신호가 된다

KOSPI 수익률 상태, BIC 기반 모형 선택, 그리고 B/S·PIN·VPIN에서 얻는 정보 거래 흐름 상태.

학습 데이터로 적합하고 테스트 데이터로 디코딩하며, 행동하기 전에 상태를 확인한다.