강의

상태공간모형과 칼만 필터

은닉상태에서 확장 칼만 필터(EKF)·무향 칼만 필터(UKF)·입자 필터까지

구조 · 칼만 필터 · ARMA의 상태공간 표현 · 최대우도(ML) 추정 · 재귀 최소제곱(RLS) · 비선형 필터 · 금융

잡음이 섞이고 불완전한 관측에서 은닉상태를 어떻게 추정하는가,
현실이 비선형·비가우시안이면 필터를 어떻게 일반화하는가.

01

제1부

상태공간모형

잠재 동학, 측정, ARIMA(자기회귀누적이동평균 모형)와의 연결

상태공간모형은 값만이 아니라 은닉상태를 추정한다

동기: 전통적 시계열 모형과 상태공간모형(State Space Model, SSM) 비교

전통적 시계열 모형	상태공간모형
과거 관측으로 미래를 예측한다	은닉상태를 추정하면서 예측한다
ARIMA 구조가 고정되어 있다	시스템 모형과 관측 모형을 분리한다
측정값이 전부다	잡음과 측정오차를 모형에 넣는다
결측값에 취약하다	결측값에 강건하다(칼만 필터가 갱신을 건너뛴다)
파라미터가 고정된다	시변(적응형) 파라미터를 지원한다

상태공간모형은 상태식과 관측식을 짝으로 쓴다

상태공간모형의 구조: 은닉상태가 측정값을 만들어 낸다

상태식과 관측식

시스템(잠재 동학)

$$X_t = AX_{t-1} + Bu_{t-1} + e_{1,t}$$

관측(측정)

$$Y_t = CX_t + e_{2,t}$$

특징

X_t : 은닉상태 (m차원)

Y_t : 관측 벡터

$e_1,\ e_2$: 시스템 / 측정 잡음

잡음은 서로 독립인 백색잡음으로 가정한다

예시 ①

낙하 물체는 상태가 둘인 고전적 예시다

대표 예시 ①: 낙하 물체(Falling Body), 위치만 관측할 수 있다

상태 정의

$x_1(t) = z(t)$ (높이), $x_2(t) = z'(t)$ (속도)

위치만 관측할 수 있다

$$Y_t = x_1(t) + e_{2,t}$$

이산화

$$X_t = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} X_{t-1} + \begin{pmatrix} -1/2 \\ -1 \end{pmatrix} g + e_{1,t}$$

$$Y_t = (1\ 0) X_t + e_{2,t}$$

모형 읽기

- 상태: 높이와 속도
- 속도는 측정되지 않는다
- 중력 g는 알려진 입력이다
- 필터는 위치에서 속도를 추론한다

잡음 섞인 랜덤워크는 가장 단순한 상태공간모형이다

단순한 상태공간모형을 분석해 시계열의 구조와 ARIMA와의 연결을 살핀다

모형 정의	수식	설명
상태식(랜덤워크)	$X_t = X_{t-1} + \eta_t$	시스템잡음(백색잡음)
관측식	$Y_t = X_t + \varepsilon_t$	관측잡음(백색잡음)

시스템잡음은 상태를 움직이고, 관측잡음은 보이는 값을 흐린다.

잡음 섞인 랜덤워크는 ARIMA(0,1,1) 과정이다

관측 과정의 1차 차분으로 ARIMA 구조를 식별한다

1. 차분 연산자 적용

$$\nabla Y_t = Y_t - Y_{t-1}$$

$$\nabla Y_t = (X_t + \varepsilon_t) - (X_{t-1} + \varepsilon_{t-1})$$

2. 랜덤워크 대입

$$\nabla Y_t = \eta_t + \varepsilon_t - \varepsilon_{t-1}$$

3-4. 자기상관함수(ACF)와 결론

- 차분 계열은 시차 1에서만 유의한 자기상관을 보인다
- 이는 이동평균 MA(1)의 전형적 특징이다
- 한 번 차분하면 MA(1)을 따르므로 관측 과정은 ARIMA(0,1,1)이다

02

제2부

칼만 필터

예측과 갱신, ARMA의 상태공간 표현, 우도, 적응 추정

칼만 필터는 먼저 예측하고 관측으로 수정한다

칼만 필터(Kalman Filter, KF): 핵심 개념

단계	설명
예측	현재 상태에서 미래 상태를 예측한다
갱신 / 재구성	관측으로 상태를 갱신해 오차를 줄인다
칼만 이득	관측과 모형 중 어느 쪽을 얼마나 믿을지 정하는 가중치

예측 → 관측 → 수정 → 반복을 한 시점씩 진행한다

다섯 식이 칼만 필터를 정의한다

칼만 필터: 갱신 식

예측

$$\hat{X}_{t|t-1} = A\hat{X}_{t-1|t-1} + Bu_{t-1}$$

$$P_{t|t-1} = AP_{t-1|t-1}A^T + \Sigma_1$$

갱신

$$K_t = P_{t|t-1}C^T(CP_{t|t-1}C^T + \Sigma_2)^{-1}$$

$$\hat{X}_{t|t} = \hat{X}_{t|t-1} + K_t(Y_t - C\hat{X}_{t|t-1})$$

$$P_{t|t} = (I - K_tC)P_{t|t-1}$$

칼만 이득은 새 관측을 예측에 얼마나 반영할지를 정한다.

모든 ARMA(p, q) 모형은 상태공간 형태로 쓸 수 있다

자기회귀이동평균(ARMA)에서 상태공간모형으로: ARMA(p, q) 모형, 상태 벡터, 관측식

$$Y_t - \varphi_1 Y_{t-1} - \ldots - \varphi_p Y_{t-p} = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \ldots + \theta_q \varepsilon_{t-q}$$

1. 상태 벡터(차원 p + q)

$$X_t = \begin{bmatrix} Y_t \\ Y_{t-1} \\ \vdots \\ Y_{t-p+1} \\ \varepsilon_t \\ \varepsilon_{t-1} \\ \vdots \\ \varepsilon_{t-q+1} \end{bmatrix}$$

관측식

$$Y_t = HX_t, \qquad H = \begin{bmatrix} 1 & 0 & \cdots & 0 \end{bmatrix}$$

상태공간 형태

$$\begin{aligned} X_t &= GX_{t-1} + Rv_t, \quad v_t \sim N(0, \sigma^2) \\ Y_t &= HX_t, \quad H = (1, 0, \ldots, 0) \end{aligned}$$

전이행렬에 ARMA 계수가 담긴다

2. 상태 전이식: 새 잡음을 정의하면 상태식이 따라 나온다

새 잡음

$$v_t = \varepsilon_t, \qquad v_t \sim N(0, \sigma^2)$$

상태식

$$X_t = GX_{t-1} + Rv_t$$

여기서

$$G = \begin{bmatrix} \varphi_1 & \varphi_2 & \cdots & \varphi_{p-1} & \varphi_p & \theta_1 & \theta_2 & \cdots & \theta_q \\ 1 & 0 & \cdots & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 & 0 & 0 & 0 & \cdots & 0 \\ \vdots & & \ddots & & \vdots & \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & 1 & 0 & 0 & 0 & \cdots & 0 \\ \hline 0 & 0 & \cdots & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 & 0 & 1 & 0 & \cdots & 0 \\ \vdots & & & & \vdots & \vdots & \ddots & & \vdots \\ 0 & 0 & \cdots & 0 & 0 & 0 & \cdots & 1 & 0 \end{bmatrix}$$

$$R = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

결측 자료가 있어도 필터는 계속 작동한다

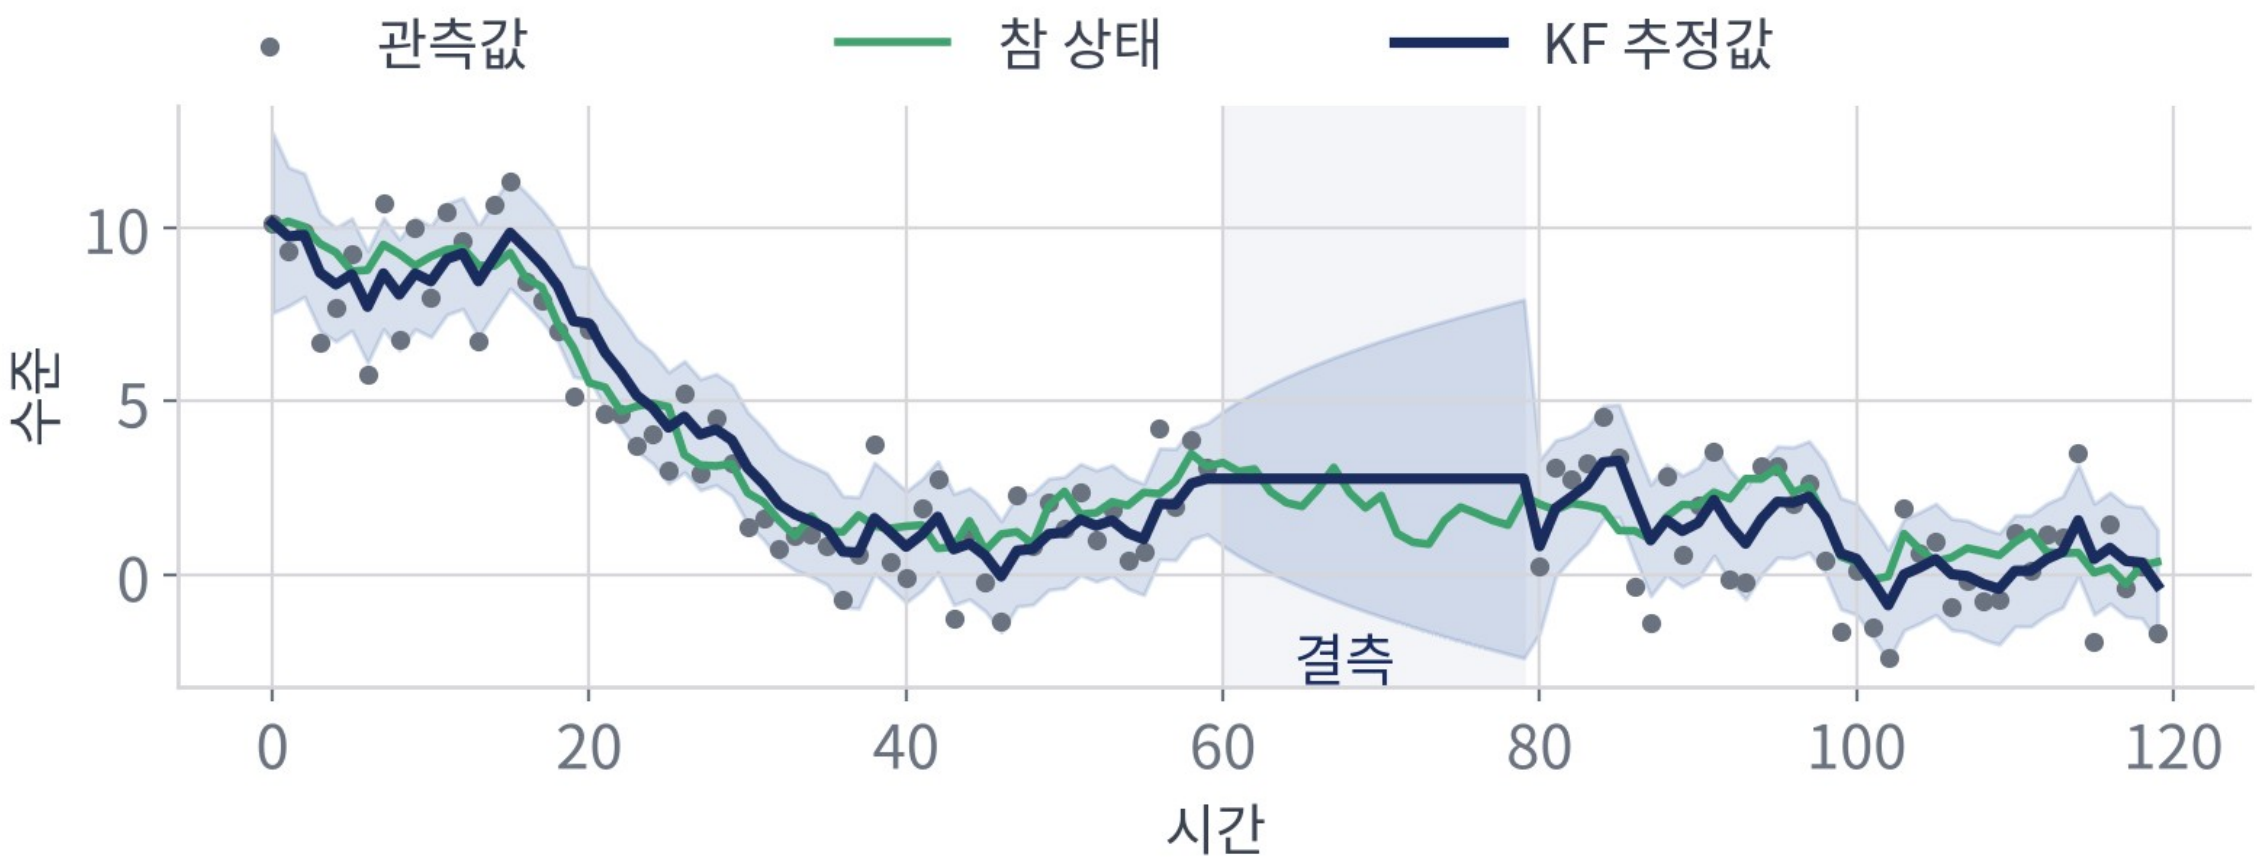
결측값 처리: 일부 시점이 비어 있어도 칼만 필터는 작동한다

관측 있음	관측 없음(결측)
예측 + 갱신	예측만
불확실성 감소	불확실성 증가

관측 없음 → 갱신할 정보 없음 → 예측을 그대로 이어 간다

불확실성은 결측 구간에서 넓어지고 그 뒤 급감한다

로컬 레벨 모형(랜덤워크 + 잡음) · 음영 구간 = ±2 표준편차 · ※ 합성 자료



필터의 예측오차로 우도를 구한다

최대우도(Maximum Likelihood, ML) 추정(칼만 필터로 구하는 우도): KF 예측오차 활용

$$\tilde{Y}_t = Y_t - \hat{Y}_{t|t-1}$$

$$\log L = -\frac{1}{2}\sum_{t=1}^{N}(\log\det\Sigma_{yy,t|t-1} + \tilde{Y}_t^T\Sigma_{yy,t|t-1}^{-1}\tilde{Y}_t)$$

ARMA를 상태공간으로 쓰고 칼만 필터를 적용한다

- 예측오차(혁신, innovation)로 가우시안 로그우도를 구성한다
- 이를 최대화해 AR·MA 계수와 잡음 분산을 추정한다
- 관측이 결측이어도 이 방법을 쓸 수 있다

RLS는 회귀계수를 온라인으로 갱신한다

재귀·적응 추정(칼만 + RLS): 재귀 최소제곱(Recursive Least Squares, RLS)의 핵심 아이디어

핵심 아이디어

- 새 자료가 들어오는 즉시 β를 갱신한다. 과거 자료 전체를 다시 계산하지 않는 온라인 추정이다
- 이전 β 추정값과 현재 자료의 정보를 결합한다
- 역상관행렬로 상관을 줄인다 → 수렴이 빨라진다. 최소평균제곱(LMS)보다 빠르고 안정적이다

핵심 식

$$\beta_t = \beta_{t-1} + K_t(y_t - x_t^T \beta_{t-1})$$

$$K_t = \frac{P_{t-1}x_t}{\lambda + x_t^T P_{t-1} x_t}$$

$$P_t = \frac{1}{\lambda}\left(P_{t-1} - K_t x_t^T P_{t-1}\right)$$

망각 인자 λ에 따라 RLS의 적응 속도가 달라진다

망각 인자(forgetting factor) λ는 빠르게 변하는 환경에 맞춰 적응력을 조절하는 파라미터다

λ 값	의미	결과
1에 가까움	과거 자료를 새 자료만큼 신뢰	β가 거의 고정(변화가 작음)
1보다 작음	최근 자료에 더 큰 가중치	β가 빠르게 변함(시장 변화에 민감)

고정 λ

- 점진적 망각

가변 λ

- 환경이 급변하면 빠르게 적응한다

기본 칼만 필터는 느린 변화를 가정한다

안정적 시스템 → KF 대 빠르게 변하는 시스템 → λ가 1보다 작은 적응형 RLS

$$\beta_t = \beta_{t-1} + w_t, \qquad w_t \sim N(0, Q)$$

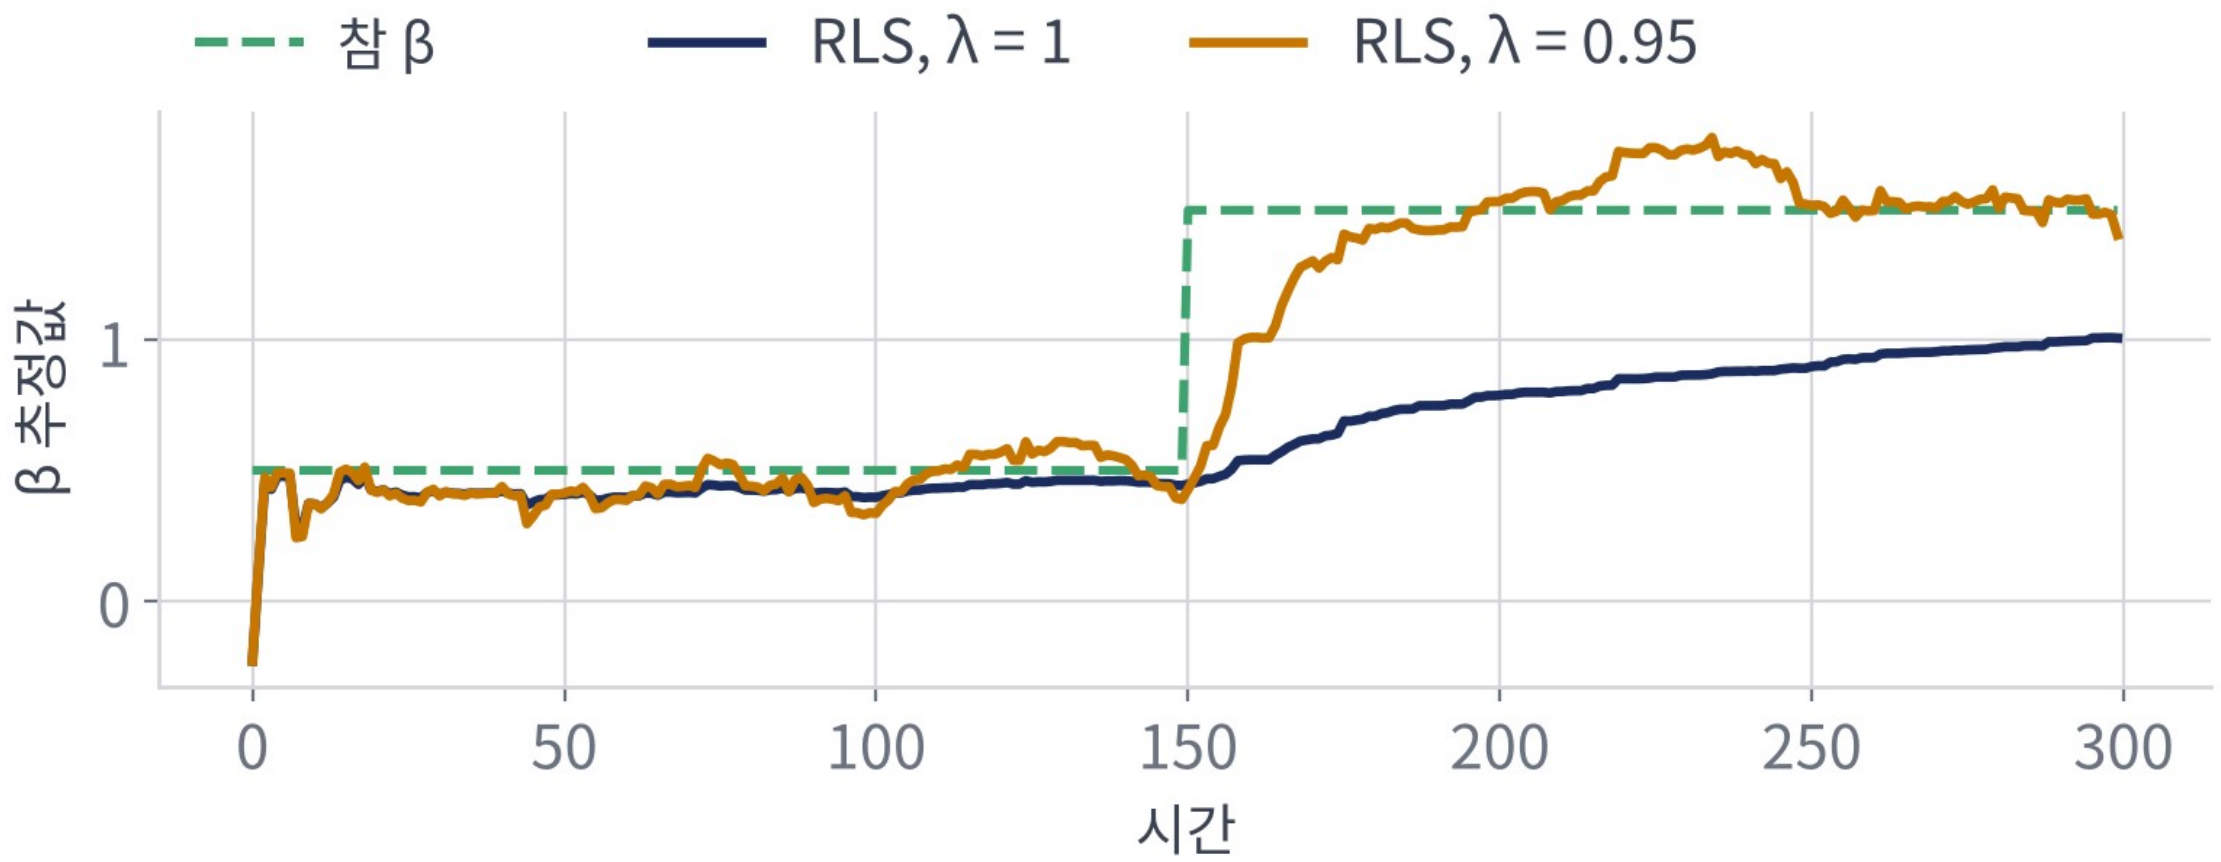
KF 상태식: Q는 상태의 잡음(변화 크기)이다

Q	시스템 거동
0	상태가 거의 변하지 않음(거의 고정)
작음	천천히 변하는 시스템(완만한 동학)
큼	베타가 크게 변동(시변성이 강함)

기본 KF는 점진적 변화에 최적이다 → 급변에는 느리게 반응한다(작은 이득)

망각 인자가 1보다 작으면 베타의 급변을 따라잡는다

β가 t = 150에서 0.5에서 1.5로 뛰는 회귀에 RLS 적용 · ※ 합성 자료



자료의 문제에 따라 쓸 모형이 달라진다

실무 연결: 언제 어떤 모형을 쓰는가

상황	적합한 모형
물리 시스템 / 동역학	상태공간 + KF
ARIMA 구조 추정	ARMA → SS + KF-ML
잡음 섞인 센서 자료	SS + KF
결측 관측	SS + KF
시변 파라미터	적응형 KF / 적응형 RLS
비선형 시스템	EKF / UKF / 입자 필터

관측이 결측이면 이득은 0이 된다

실무 칼만 필터의 초기화와 결측 자료: 결측값 처리 원리

칼만 이득

관측이 없으면 관측 분산을 무한대로 보므로 칼만 이득이 0이 된다.

상태 추정값

이득이 0이면 재구성 추정값은 직전 예측과 같다. 새 정보가 없다.

재구성값 = 이전 추정값

분산

새 정보가 없으면 상태 추정값의 분산이 줄지 않는다(불확실성 유지).

관측 결측 → 예측만 수행하고 갱신 단계는 건너뛴다

초기값보다 초기 불확실성이 더 중요하다

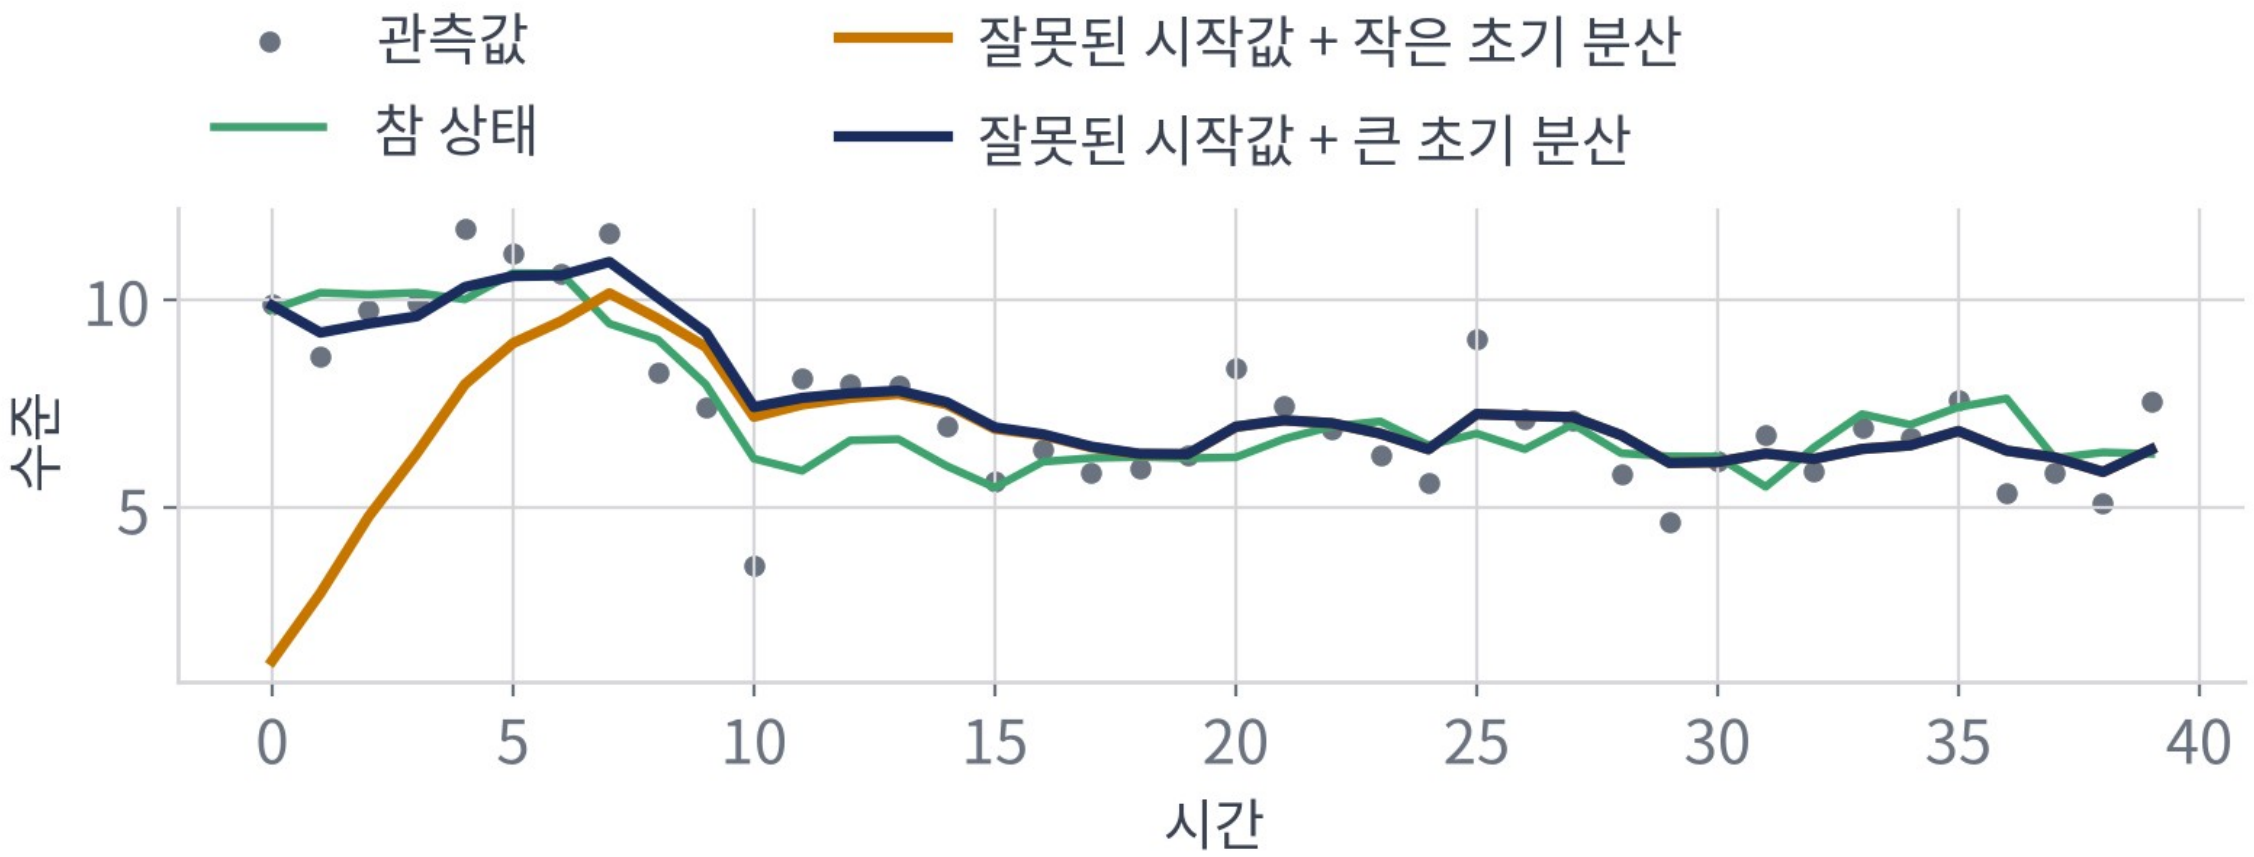
초기 불확실성을 얼마나 적절히 두느냐에 따라 수렴 속도와 성능이 달라진다

시나리오	초기 상태와 분산	핵심 결과
잘못된 시작 + 과신	부정확한 값 + 낮은 초기 분산	느린 수렴과 오버슈팅
잘못된 시작 + 적절한 불확실성	부정확한 값 + 큰 초기 분산	불확실성을 인식해 첫 관측에서 매우 빠르게 수렴

잘못 출발해도 큰 문제는 아니다. 다만 그 추정값의 불확실성은 적절해야 한다.

초기 분산이 크면 잘못된 시작값의 영향이 사라진다

같은 잘못된 시작값(0), 서로 다른 두 초기 분산 · ※ 합성 자료



결측 자료

불확실성은 자료가 없으면 커지고 자료가 있으면 줄어든다

자료가 결측일 때의 필터 성능

관측 없음

시스템잡음 때문에 예측구간의 불확실성이 단계마다 커진다.

새 관측

불확실성이 빠르게 줄고 상태 추정값이 수정된다.

주의

시스템잡음을 과대추정하면 관측이 없는 동안 불확실성이 급격히 커질 수 있다.

자료가 결측인 동안 불확실성이 커지는 속도는 시스템잡음에 따라 달라진다

03

제3부

고급 필터: EKF, UKF, 입자 필터

칼만 필터링을 비선형 시스템과 분포 전체의 추적으로 확장한다

현실의 시스템은 칼만 필터의 선형·가우시안 가정을 벗어난다

칼만 필터의 요건은 (1) 선형 모형 (2) 가우시안 잡음 (3) 선형·고정 변환 A와 C이지만 현실은...

예시	특성
로봇 / 드론 / 동시적 위치추정·지도작성 (SLAM)	회전·좌표 변환 → 비선형
실시간 매매 전략	시장 점프, 비정규 변동성 구조
레이더 / 센싱	비선형 센서 모형
신경·생체 자료	비가우시안 잡음

선형 + 가우시안 KF의 한계 → EKF → UKF → 입자 필터

EKF는 선형화한 뒤 칼만 필터를 적용한다

1. 확장 칼만 필터(Extended Kalman Filter, EKF): 선형화로 KF를 확장한다. f와 h는 비선형이다

모형

$$X_t = f(X_{t-1}) + e_{1,t}$$

$$Y_t = h(X_t) + e_{2,t}$$

핵심 아이디어: 야코비안이 A와 C를 대신한다

$$A_t = \frac{\partial f}{\partial X}|_{X=\hat{X}_{t-1|t-1}}, \quad C_t = \frac{\partial h}{\partial X}|_{X=\hat{X}_{t|t-1}}$$

1차 테일러 전개. 나머지 식은 모두 KF와 같다

EKF는 빠르지만 비선형성이 강하면 약하다

1. 확장 칼만 필터(EKF): 장점과 단점

장점	단점
계산이 빠르다	비선형성이 강하면 근사가 나쁘다
제어·SLAM에서 효율적이다	야코비안을 계산해야 한다
산업계에서 널리 쓰인다	분포를 왜곡할 수 있다

언제 적합한가?

- 비선형이지만 급변하지 않는 경우: 로봇, 항공우주, SLAM, 센서 융합

UKF는 분포 자체를 전파한다

2. 무향 칼만 필터(UKF): EKF의 선형화 오차를 고치려고 등장했다. 선형화 없이 시그마 포인트(sigma point)만 쓴다

핵심 아이디어

- 상태 분포를 결정론적으로 고른 소수의 점으로 나타낸다
- 분포의 평균과 공분산을 유지한다
- 다변량 가우시안의 대표 점 2n + 1개를 배치한다

알고리즘 흐름

1. 시그마 포인트를 생성한다
2. 각 점을 f와 h에 통과시킨다
3. 결과 점의 평균·공분산을 합쳐 새 분포를 만든다

UKF는 EKF보다 정확하지만 비용이 더 크다

2. 무향 칼만 필터(UKF): 장점과 단점

장점	단점
EKF보다 훨씬 정확하다	계산량이 더 많다
야코비안이 필요 없다	극단적 비정규성에서는 여전히 한계가 있다
비선형성이 강해도 안정적이다	고차원에서는 시그마 포인트 수가 늘어난다

적합한 경우

- 비선형성이 강한 센서, 레이더, 안전 제어, 다중 센서 융합, 관성 항법

EKF와 UKF를 한 줄로

- EKF = 비선형 함수의 선형 근사
- UKF = 분포를 직접 통과시킨다

입자 필터는 분포 모양을 가정하지 않는다

3. 입자 필터(Particle Filter, PF) = 순차 몬테카를로(Sequential Monte Carlo, SMC): 가장 일반적이고 강력한 베이즈 필터

핵심 개념

- 상태 분포를 입자(표본) 집합으로 나타낸다
- 입자 하나 = 가능한 상태 하나
- 관측이 들어오면 입자 가중치를 갱신한다
- 확률이 높은 입자는 남기고 낮은 입자는 버린다 (재표본추출, resampling)

알고리즘

1. 초기 분포에서 입자를 많이 추출한다
2. 모형에 따라 각 입자를 이동한다(예측)
3. 관측과 비교해 가중치를 갱신한다
4. 재표본추출로 입자 퇴화를 억제한다
5. 반복한다

입자 필터는 어떤 분포에도 맞지만 비용이 따른다

3. 입자 필터(순차 몬테카를로): 장점과 단점

장점	단점
어떤 비선형·비정규 시스템에도 쓸 수 있다	계산량이 많다
다봉 분포를 나타낼 수 있다	고차원에서 차원의 저주가 나타난다
점프와 국면 전환에 강건하다	입자가 너무 적으면 추정 성능이 크게 떨어진다

적합한 경우

- 금융: 국면 전환, 점프 모형, 변동성 모형 · 레이더 / SLAM / 추적 · 비가우시안 동학

네 필터는 일반성과 계산량을 절충한다

방법별 핵심 비교

모형	분포	비선형 처리	복잡도	활용 분야
KF	가우시안	없음	낮음	센서, 시계열
EKF	가우시안	선형화	중간	로봇, 항공우주
UKF	가우시안	시그마 포인트	중간~높음	자율주행, 센서 융합
입자 필터	제한 없음	표본 기반	높음	금융, 장비, 국면 변화

단순하게 시작하고, 자료가 요구할 때만 복잡한 필터로 옮긴다

실무에서 어떤 필터를 쓸까: 상황별 권장

상황	권장 필터
선형 시스템 + 가우시안	KF
약한 비선형성 + 계산 자원 제약	EKF
강한 비선형성 + 야코비안 계산이 어려움	UKF
점프, 국면, 비정규성, 다봉	입자 필터
“무엇이 최선인지 모르겠다”	UKF → 성능이 부족하면 PF

필터마다 분포를 다루는 방식이 다르다

결론: 한 문장 요약

이름	핵심
EKF	“비선형을 먼저 선형화한 뒤 KF를 적용한다”
UKF	“평균과 공분산을 유지하면서 분포를 함수에 통과시킨다”
PF	“상태 분포 전체를 입자로 나타내고 갱신한다”

A1

부록 1

EKF, UKF, PF 수식 요약

세 필터의 수식 중심 핵심 정리

EKF는 매 단계 다시 선형화한다

1. 확장 칼만 필터(EKF): 모형, 선형화, 예측, 갱신

모형

$$X_t = f(X_{t-1}) + e_{1,t}, \qquad e_{1,t} \sim \mathcal{N}(0, \Sigma_1)$$

$$Y_t = h(X_t) + e_{2,t}, \qquad e_{2,t} \sim \mathcal{N}(0, \Sigma_2)$$

(1) 선형화(야코비안)

$$A_t = \left.\frac{\partial f}{\partial X}\right|_{X=\hat{X}_{t-1|t-1}}, \qquad C_t = \left.\frac{\partial h}{\partial X}\right|_{X=\hat{X}_{t|t-1}}$$

(2) 예측

$$\hat{X}_{t|t-1} = f(\hat{X}_{t-1|t-1})$$

$$P_{t|t-1} = A_t P_{t-1|t-1} A_t^T + \Sigma_1$$

(3) 갱신

$$K_t = P_{t|t-1} C_t^T \left(C_t P_{t|t-1} C_t^T + \Sigma_2\right)^{-1}$$

$$\hat{X}_{t|t} = \hat{X}_{t|t-1} + K_t \left(Y_t - h(\hat{X}_{t|t-1})\right)$$

$$P_{t|t} = (I - K_t C_t) P_{t|t-1}$$

UKF는 시그마 포인트 2n + 1개를 배치한다

2. 무향 칼만 필터(UKF): 모형(동일)과 상태 차원 n의 시그마 포인트 생성

$$X_t = f(X_{t-1}) + e_{1,t}, \qquad Y_t = h(X_t) + e_{2,t}$$

핵심: 시그마 포인트 생성

$$\chi_{t-1}^{(0)} = \hat{X}_{t-1|t-1}$$

$$\chi_{t-1}^{(i)} = \hat{X}_{t-1|t-1} + \left(\sqrt{(n+\xi)P_{t-1|t-1}}\right)_i, \quad i = 1, \ldots, n$$

$$\chi_{t-1}^{(i+n)} = \hat{X}_{t-1|t-1} - \left(\sqrt{(n+\xi)P_{t-1|t-1}}\right)_i, \quad i = 1, \ldots, n$$

예측은 전파된 시그마 포인트를 평균한다

2. 무향 칼만 필터(UKF): (1) 예측

각 시그마 포인트를 함수에 통과시킨다

$$\chi_{t|t-1}^{(i)} = f(\chi_{t-1}^{(i)})$$

가중평균으로 상태 예측

$$\hat{X}_{t|t-1} = \sum_i w_m^{(i)} \chi_{t|t-1}^{(i)}$$

공분산

$$P_{t|t-1} = \sum_i w_c^{(i)} (\chi_{t|t-1}^{(i)} - \hat{X}_{t|t-1})(\chi_{t|t-1}^{(i)} - \hat{X}_{t|t-1})^T + \Sigma_1$$

갱신은 시그마 포인트로 공분산을 구성한다

2. 무향 칼만 필터(UKF): (2) 갱신

관측 시그마 포인트

$$\gamma^{(i)} = h(\chi^{(i)}_{t|t-1})$$

관측 평균

$$\hat{Y}_{t|t-1} = \sum_i w_m^{(i)} \gamma^{(i)}$$

관측 공분산과 교차공분산

$$S = \sum_i w_c^{(i)} (\gamma^{(i)} - \hat{Y}_{t|t-1})(\gamma^{(i)} - \hat{Y}_{t|t-1})^T + \Sigma_2$$

$$P_{xy} = \sum_i w_c^{(i)} (\chi^{(i)}_{t|t-1} - \hat{X}_{t|t-1})(\gamma^{(i)} - \hat{Y}_{t|t-1})^T$$

UKF 이득은 두 공분산에서 나온다

2. 무향 칼만 필터(UKF): (2) 갱신(계속)

칼만 이득

$$K_t = P_{xy} S^{-1}$$

상태 갱신

$$\hat{X}_{t|t} = \hat{X}_{t|t-1} + K_t(Y_t - \hat{Y}_{t|t-1})$$

공분산

$$P_{t|t} = P_{t|t-1} - K_t S K_t^T$$

신경망을 f와 h로 쓸 수 있다

2. 무향 칼만 필터(UKF): [참고] 딥러닝 분야의 f와 h 예시

분야	f	h
금융 시계열	LSTM	MLP
고빈도 시장 미시구조	Transformer	CNN
옵션 가격 역산	Neural ODE	Black–Scholes
변동성 추적	GRU	MLP
국면 전환 탐지	RNN	소프트맥스 분류기
자율주행	LSTM	CNN(카메라)
뇌 신호	RNN	뇌파(EEG) CNN

중요도 샘플링으로 가중 입자를 얻는다

3. 입자 필터(SMC): 목표는 사후분포를 임의 형태의 분포로 추정하는 것이다

목표

$$p(X_t|Y_{1:t})$$

(1) 중요도 샘플링

$$X_t^{(i)} \sim q(X_t|X_{t-1}^{(i)}, Y_t)$$

(2) 가중치 갱신

$$w_t^{(i)} \propto w_{t-1}^{(i)} \cdot \frac{p(Y_t|X_t^{(i)})\, p(X_t^{(i)}|X_{t-1}^{(i)})}{q(X_t^{(i)}|X_{t-1}^{(i)}, Y_t)}$$

정규화

$$\tilde{w}_t^{(i)} = \frac{w_t^{(i)}}{\sum_j w_t^{(j)}}$$

유효 표본 수가 너무 낮아지면 재표본추출한다

3. 입자 필터(SMC): (3) 재표본추출(필수 단계)과 (4) 상태 추정

(3) 재표본추출

유효 표본 수

$$N_{\text{eff}} = \frac{1}{\sum_i (\tilde{w}_t^{(i)})^2}$$

$N_{\text{eff}} <$ 임계값 $\Rightarrow$ 재표본추출 수행

(4) 상태 추정

$$\hat{X}_{t|t} = \sum_i \tilde{w}_t^{(i)} X_t^{(i)}$$

입자 구름 하나로 필터링·예측·스무딩을 모두 한다

3. 입자 필터(SMC): (5) PF의 용도

(a) 온라인 필터링

- 새 관측이 들어올 때마다 실시간으로 추정한다

(b) 예측

$$p(X_{t+k}|Y_{1:t}) \approx \{X_{t+k}^{(i)}\}_i$$

(c) 스무딩

$$p(X_t|Y_{1:T})$$

대표 용도

- 금융, 레이더, 자율주행, 로봇

미래

- 입자를 여러 단계 전파한다 → 미래 분포를 예측한다

과거

- 역방향 스무딩: PF판 RTS(Rauch–Tung–Striebel) 스무딩

A2

부록 2

금융 시계열을 위한 입자 필터

상태 설계, 모형 예시, 알고리즘, 산출물

금융 자료의 특성은 입자 필터의 강점과 맞는다

금융 자료의 다음 특성 때문에 PF가 가장 강력한 선택이 된다

금융의 현실	KF 계열의 약점	PF의 강점
국면 전환	선형·정규 가정이 깨진다	국면을 입자로 나타낼 수 있다
두꺼운 꼬리 / 점프	가우시안 가정이 맞지 않는다	어떤 분포든 가능하다
변동성 군집	분산이 시간에 따라 변한다	입자에 자동으로 반영된다
비정상 시계열	ARIMA로는 부족하다	상태 과정을 직접 모형화한다

수익률은 관측되지만 시장 상태는 숨어 있다

1. 금융 입자 필터의 전형적 상태변수 설계: 대표 구성 요소

상태(시점 t)	의미
μ	기대수익률
σ	변동성
s	국면(상승 / 하락 / 위기)
κ	점프 강도
v	확산 요인(예: 일반화 자기회귀 조건부 이분산, GARCH)
ρ	상관 전이

관측 = 가격 / 수익률, 상태 = 시장의 숨은 구조

점프가 있는 국면 전환 GARCH에는 PF가 적합하다

2. 상태공간 예시(PF 적용): 국면 전환 + GARCH형 변동성 + 점프

상태

$$X_t = \begin{pmatrix} \mu_t \\ \sigma_t^2 \\ s_t \end{pmatrix}$$

동학

$$\mu_t = \mu_{t-1} + \eta_{\mu,t}$$

$$\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2 + \eta_{\sigma,t}$$

$$P(s_t = j \mid s_{t-1} = i) = \Pi_{ij}$$

관측

$$r_t = \mu_t + \sigma_t \epsilon_t + J_t q_t$$

점프 발생

$$J_t \sim \text{Bernoulli}(p_t)$$

혼합분포·국면·점프는 EKF와 UKF로 다루기 어렵다

2. 상태공간 예시(PF 적용): 점프 성분이 있는 관측식

관측식

$$r_t = \mu_t + \sigma_t \epsilon_t + J_t q_t$$

점프 발생

$$J_t \sim \text{Bernoulli}(p_t)$$

→ EKF / UKF로는 다루기 어렵다

- 비정규
- 혼합분포
- 이산 국면
- 조건부 분산
- 점프
- → PF는 이를 직접 다룰 수 있다

금융 PF의 순환은 포지션 크기 조정으로 끝난다

3. 금융 PF 알고리즘 흐름: 입자 N개 초기화 후 예측, 가중치 계산, 재표본추출, 실행

입자 N개 초기화

$$\{X_0^{(i)},\ w_0^{(i)} = 1/N\}, \quad i = 1..N$$

상태 예측

$$X_t^{(i)} \sim p(X_t | X_{t-1}^{(i)})$$

관측 기반 가중치

$$w_t^{(i)} \propto w_{t-1}^{(i)}\, p(r_t | X_t^{(i)})$$

필요할 때 재표본추출

$$\mathrm{ESS} < c \Rightarrow \text{재표본추출}$$

수익률 예측 / 위험가치(VaR) / 리밸런싱에 활용

$$\hat{\mu}_t,\ \hat{\sigma}_t \quad \Rightarrow \quad \text{포지션 크기 조정}$$

PF는 수익률보다 리스크 탐지에 강하다

4. 실무상 장점: PF가 제공하는 것

응용	PF가 제공하는 것
시장 예측	국면확률, 변동성 예측
리스크	시나리오 기반 분포 예측
포트폴리오	μ / σ 사후분포에 기반한 동적 비중
옵션 헤지	비정규 꼬리를 반영한다
이벤트 대응	점프 위험의 실시간 추정

꼬리 · 국면 · 변동성: 모두 사후분포에 기반한다

실무에서는 PF 산출물 세 가지를 가장 많이 쓴다

5. 금융 PF 산출물의 가장 유용한 형태

(1) 국면확률

$$P(s_t = \text{위험회피} \mid Y_{1:t})$$

활용

- 변동성 지수(VIX), 금리 충격, 옵션 델타 헤지 시점

(2) 예측 변동성

$$P(\sigma_{t+k} \mid Y_{1:t})$$

활용

- 분산 목표화 / 포지션 크기 조정

(3) 시나리오 기반 기대손실(ES)

$$ES_\alpha = E[-r_t \mid r_t < -\mathrm{VaR}_\alpha]$$

활용

- 조건부 위험가치(CVaR) 기반 포트폴리오 최적화