나우캐스팅 · 강의

실시간 경제 나우캐스팅

상태공간모형, 혼합주기 자료, 칼만 필터, 기댓값 최대화(EM) 알고리즘

개념 · 상태공간 형식 · 칼만 필터 · 손 계산 예제 · EM 알고리즘 · 실시간 절차

원논문: 이현창·최동규·김용건(2022). 동적 요인 모형과 딥러닝 알고리즘을 결합한 당분기 경제전망(GDP 나우캐스팅) 시스템 개발.

01

1부

개념과 모형

나우캐스팅이 필요한 이유, 상태공간 형식, 혼합주기 자료, 칼만 필터

나우캐스팅은 미래가 아니라 현재를 추정한다

1. 나우캐스팅(nowcasting)의 개념: “Now(현재)” + “Forecasting(예측)”, 오늘의 경제 상태를 실시간으로 추정

1.1 필요한 이유

- 국내총생산(GDP) 같은 핵심 지표에는 발표시차가 있다
- 분기 GDP는 분기가 끝나고 약 1~2개월 뒤에 발표된다
- 정책과 투자 판단에는 현재의 경제 상태가 필요하다
- 월별·주별·일별 고빈도 자료로 분기별 저빈도 지표를 추정한다

1.2 핵심 아이디어

- 당분기 GDP 성장률은 분기 마지막 달에 관측된다
- 앞선 달의 값은 필터링(filtering)·스무딩(smoothing)으로 채운다
- 이렇게 해서 당분기 나우캐스트를 얻는다

두 식이 관측값과 추론할 상태를 잇는다

2.1 기본 구조: 상태공간모형은 두 식으로 이루어진다

관측식

$$y_t = Z_t \alpha_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, H_t)$$

상태식

$$\alpha_{t+1} = T_t \alpha_t + R_t \eta_t, \quad \eta_t \sim N(0, Q_t)$$

기호 설명

y_t:	관측 가능한 변수(예: 월별 지표)
α_t:	은닉상태(예: 분기 GDP 성장률)
Z_t, T_t, R_t:	시스템 행렬
ε_t, η_t:	관측 오차, 상태 오차

분기 GDP는 월별 값의 가중합이다

3. 혼합주기 자료: 3.1 분기–월 변환 · 3.2 상태공간 형식

분기 GDP와 월별 지표

$$y_t^* = \omega_1 x_{t,1} + \omega_2 x_{t,2} + \omega_3 x_{t,3}$$

선형결합 가중치

$$\omega_1 + \omega_2 + \omega_3 = 1$$

분기 말

$$(m = 3): y_t = [1 \quad 0 \quad 0 \quad 0]\alpha_t + \varepsilon_t$$

분기 중: 월별 자료만 있음

$$(m = 1, 2): \ y_t = \text{결측}$$

3.2 상태벡터

$$\alpha_t = \begin{bmatrix} y_t^* \\ x_{t,1} \\ x_{t,2} \\ x_{t,3} \end{bmatrix}$$

필터는 매달 예측한 뒤 갱신한다

4. 칼만 필터로 실시간 추정: 4.1 알고리즘

예측 단계

$$\alpha_{t|t-1} = T_t \alpha_{t-1|t-1}$$

$$P_{t|t-1} = T_t P_{t-1|t-1} T_t' + R_t Q_t R_t'$$

- v_t: 예측오차(혁신, innovation)
- F_t: 예측오차 분산
- K_t: 칼만 이득

갱신 단계

$$v_t = y_t - Z_t \alpha_{t|t-1}$$

$$F_t = Z_t P_{t|t-1} Z_t' + H_t$$

$$K_t = P_{t|t-1} Z_t' F_t^{-1}$$

$$\alpha_{t|t} = \alpha_{t|t-1} + K_t v_t$$

$$P_{t|t} = P_{t|t-1} - K_t F_t K_t'$$

02

2부

칼만 필터 손 계산

예제 1 1차 자기회귀(AR(1)) · 예제 2 분기–월 혼합주기 · 예제 3 다변량 시스템

예제 1은 GDP 성장률을 잡음이 섞인 AR(1)로 본다

5. 손 계산 예제 1: 단순 AR(1) 모형, 5.1 모형 설정

GDP 성장률이 AR(1) 과정을 따른다고 가정한다

$$y_t = \phi y_{t-1} + \eta_t, \quad \eta_t \sim N(0, \sigma_\eta^2)$$

이 값은 잡음이 섞여 관측된다

$$z_t = y_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

상태공간 형식

상태식

$$y_t = \phi y_{t-1} + \eta_t$$

관측식

$$z_t = y_t + \varepsilon_t$$

파라미터 값

$$\phi = 0.8, \sigma_\eta^2 = 1, \sigma_\varepsilon^2 = 0.5$$

한 번의 갱신으로 관측값 1.5가 1.230이 된다

5.2 초기 조건(t = 0)과 5.3 t = 1 나우캐스트: 예측, 관측, 갱신

5.2 초기 조건

$$y_{0|0} = 0, \quad P_{0|0} = 2$$

예측 단계

$$y_{1|0} = \phi y_{0|0} = 0.8 \times 0 = 0$$

$$P_{1|0} = \phi^2 P_{0|0} + \sigma_\eta^2 = 0.64 \times 2 + 1 = 2.28$$

관측

$$z_1 = 1.5$$

갱신 단계

$$v_1 = z_1 - y_{1|0} = 1.5 - 0 = 1.5$$

$$F_1 = P_{1|0} + \sigma_\varepsilon^2 = 2.28 + 0.5 = 2.78$$

$$K_1 = \frac{P_{1|0}}{F_1} = \frac{2.28}{2.78} = 0.820$$

$$y_{1|1} = y_{1|0} + K_1 v_1 = 0 + 0.820 \times 1.5 = 1.230$$

$$P_{1|1} = P_{1|0} - K_1 F_1 K_1 = 2.28 - 0.820 \times 2.78 \times 0.820 = 0.410$$

결과: t = 1의 GDP 성장률 나우캐스트는 1.230이다

예제 2는 월별 AR(1) 값 세 개를 평균한다

6. 손 계산 예제 2: 분기–월 혼합주기, 6.1 모형 설정

분기 GDP는 3개월 평균이다

$$y_t^* = \frac{1}{3}(x_{t,1} + x_{t,2} + x_{t,3})$$

월별 지표는 AR(1)을 따른다

$$x_{t,m} = 0.7x_{t,m-1} + \eta_{t,m}, \quad \eta_{t,m} \sim N(0, 0.8)$$

관측 오차

$$\sigma_\varepsilon^2 = 0.3$$

1월 지표로 추정값이 2.049로 올라간다

6.2 1분기 1월(t = 1, m = 1): 초기 조건, 예측, 관측, 갱신

초기 조건

$$x_{0,3|0,3} = 2.0, \quad P_{0,3|0,3} = 1.0$$

예측(t = 1, m = 1)

$$x_{1,1|0,3} = 0.7 \times 2.0 = 1.4$$

$$P_{1,1|0,3} = 0.7^2 \times 1.0 + 0.8 = 0.49 + 0.8 = 1.29$$

관측

$$z_{1,1} = 2.2$$

갱신

$$v_{1,1} = 2.2 - 1.4 = 0.8$$

$$F_{1,1} = 1.29 + 0.3 = 1.59$$

$$K_{1,1} = \frac{1.29}{1.59} = 0.811$$

$$x_{1,1|1,1} = 1.4 + 0.811 \times 0.8 = 2.049$$

$$P_{1,1|1,1} = 1.29 - 0.811 \times 1.59 \times 0.811 = 0.243$$

1월 자료만 있을 때 GDP 나우캐스트는 1.496이다

6.3 1월 말 GDP 나우캐스트(중간 추정): 1월 지표만 관측된 상태

방법 1: 단순 예측값을 쓴다

$$x_{1,1|1,1} = 2.049 \ (\text{관측})$$

$$x_{1,2|1,1} = 0.7 \times 2.049 = 1.434 \ (\text{예측})$$

$$x_{1,3|1,1} = 0.7 \times 1.434 = 1.004 \ (\text{예측})$$

$$y^*_{1|\text{1월}} = \frac{1}{3}(2.049 + 1.434 + 1.004) = \frac{4.487}{3} = 1.496$$

1월 말 GDP 나우캐스트: 1.496(불확실성 높음)

2월 지표로 추정값이 1.710으로 내려온다

6.4 1분기 2월(t = 1, m = 2): 예측, 관측, 갱신

예측

$$x_{1,2|1,1} = 0.7 \times 2.049 = 1.434$$

$$P_{1,2|1,1} = 0.7^2 \times 0.243 + 0.8 = 0.919$$

관측

$$z_{1,2} = 1.8$$

갱신

$$v_{1,2} = 1.8 - 1.434 = 0.366$$

$$F_{1,2} = 0.919 + 0.3 = 1.219$$

$$K_{1,2} = \frac{0.919}{1.219} = 0.754$$

$$x_{1,2|1,2} = 1.434 + 0.754 \times 0.366 = 1.710$$

$$P_{1,2|1,2} = 0.919 - 0.754^2 \times 1.219 = 0.226$$

2월 말

두 달이 관측되자 나우캐스트가 1.669로 올라간다

6.5 2월 말 GDP 나우캐스트(개선된 추정): 1~2월 관측 후 재추정

1. 1월 스무딩
2월 정보가 1월로 거슬러 반영된다

$$x_{1,1|1,2} = 2.100 \ (\text{스무딩})$$

2. GDP 계산

$$x_{1,1|1,2} = 2.100 \ (\text{1월, 스무딩})$$

$$x_{1,2|1,2} = 1.710 \ (\text{2월, 관측})$$

$$x_{1,3|1,2} = 0.7 \times 1.710 = 1.197 \ (\text{3월 예측})$$

$$y^{*}_{1|\text{2월}} = \tfrac{1}{3}(2.100 + 1.710 + 1.197) = \tfrac{5.007}{3} = 1.669$$

2월 말 GDP 나우캐스트: 1.669(불확실성 감소)

3월의 예상 밖 지표로 추정값이 2.177로 움직인다

6.6 1분기 3월(t = 1, m = 3): 예측, 관측, 갱신

예측

$$x_{1,3|1,2} = 0.7 \times 1.710 = 1.197$$

$$P_{1,3|1,2} = 0.7^2 \times 0.226 + 0.8 = 0.911$$

관측

$$z_{1,3} = 2.5$$

갱신

$$v_{1,3} = 2.5 - 1.197 = 1.303$$

$$F_{1,3} = 0.911 + 0.3 = 1.211$$

$$K_{1,3} = \frac{0.911}{1.211} = 0.752$$

$$x_{1,3|1,3} = 1.197 + 0.752 \times 1.303 = 2.177$$

$$P_{1,3|1,3} = 0.911 - 0.752^2 \times 1.211 = 0.226$$

분기 전체가 관측되면 최종 나우캐스트는 2.063이다

6.7 3월 말 GDP 나우캐스트(최종 추정): 분기 내 모든 정보를 관측한 뒤

앞의 두 달은 칼만 스무더(Kalman smoother)로 재추정한다

$$y_1^* = \frac{1}{3}(x_{1,1|1,3} + x_{1,2|1,3} + x_{1,3|1,3})$$

분기 전체 스무딩: 3월 정보가 1~2월로 거슬러 전파된다

$$x_{1,1|1,3} \approx 2.132, \quad x_{1,2|1,3} \approx 1.880, \quad x_{1,3|1,3} = 2.177$$

$$y^*_{1|\text{3월}} = \tfrac{1}{3}(2.132 + 1.880 + 2.177) = \tfrac{6.189}{3} = 2.063$$

3월 말(최종) GDP 나우캐스트: 2.063(불확실성 최저)

정보가 늘면 추정값이 움직이고 불확실성은 줄어든다

6.8 실시간 갱신 요약

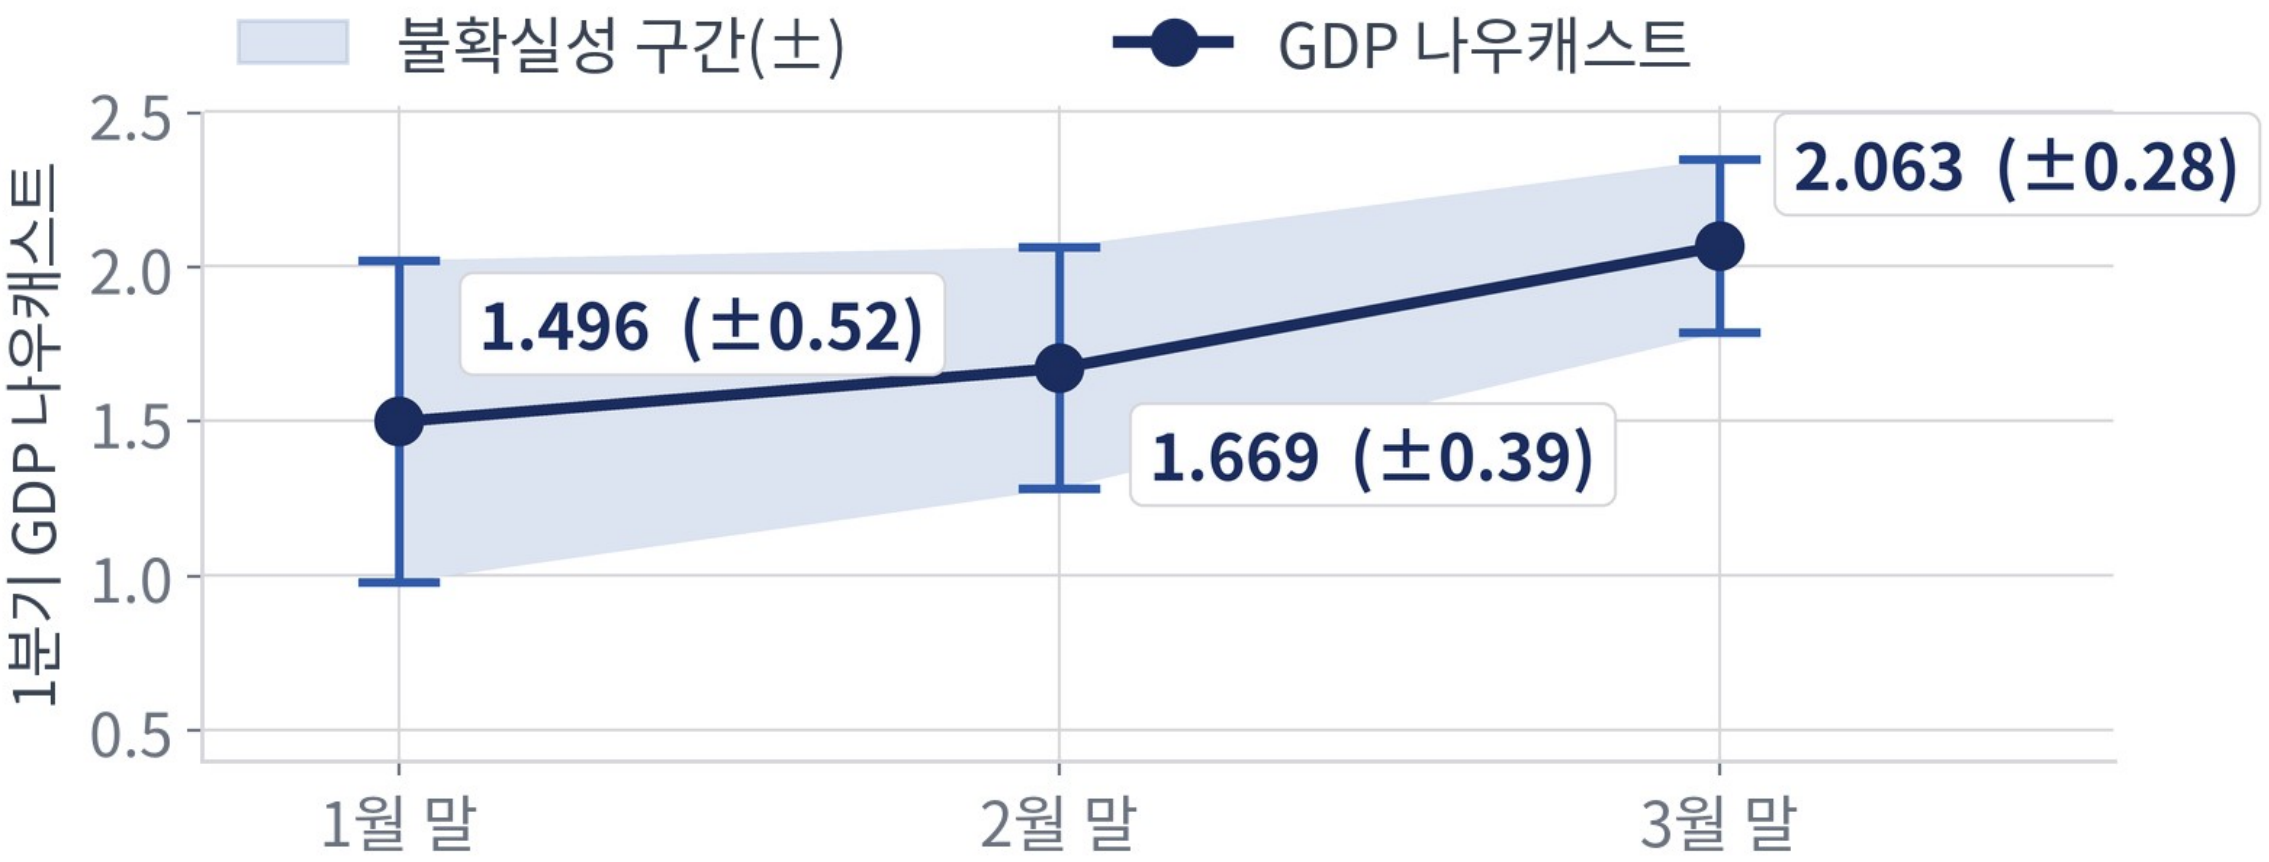
시점	관측된 정보	GDP 나우캐스트	불확실성
1월 말	$\overline{x_{1,1}}$ 만	1.496	높음(±0.52)
2월 말	$\overline{x_{1,1}, x_{1,2}}$	1.669	중간(±0.39)
3월 말	$\overline{x_{1,1}, x_{1,2}, x_{1,3}}$	2.063	낮음(±0.28)

해석

- 정보가 쌓이면 GDP 추정값이 바뀌고 불확실성은 동시에 줄어든다. 이것이 실시간 나우캐스팅의 핵심이다.

불확실성이 좁아지면서 나우캐스트는 올라간다

월말별 1분기 GDP 나우캐스트와 불확실성(±) · 수치는 앞의 풀이 예제 값



예제 3은 월별 지표 두 개로 GDP를 구성한다

7. 손 계산 예제 3: 다변량 시스템, 7.1 모형 설정

지표 두 개로 만드는 분기 GDP

$$y_t^* = 0.6x_t^{(1)} + 0.4x_t^{(2)}$$

상태벡터

$$\alpha_t = \begin{bmatrix} y_t^* \\ x_t^{(1)} \\ x_t^{(2)} \end{bmatrix}$$

상태식

$$\begin{bmatrix} y_{t+1}^* \\ x_{t+1}^{(1)} \\ x_{t+1}^{(2)} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0.8 & 0 \\ 0 & 0 & 0.6 \end{bmatrix} \begin{bmatrix} y_t^* \\ x_t^{(1)} \\ x_t^{(2)} \end{bmatrix} + \begin{bmatrix} \eta_t^y \\ \eta_t^{(1)} \\ \eta_t^{(2)} \end{bmatrix}$$

공분산

$$Q = \mathrm{diag}(0, 0.5, 0.4)$$

관측: 지표 1만

$$z_t = [0 \quad 1 \quad 0]\alpha_t + \varepsilon_t, \quad \sigma_\varepsilon^2 = 0.2$$

예측 단계에서 사전 공분산이 커진다

7.2 초기 조건(t = 0)과 7.3 t = 1 예측

7.2 초기 조건

$$\alpha_{0|0} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \quad P_{0|0} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

7.3 t = 1 예측

$$\alpha_{1|0} = T\alpha_{0|0} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

사전 공분산

$$P_{1|0} = TP_{0|0}T' + Q = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 0.64 + 0.5 & 0 \\ 0 & 0 & 0.36 + 0.4 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1.14 & 0 \\ 0 & 0 & 0.76 \end{bmatrix}$$

예제 3

지표 1만 관측해도 나우캐스트 1.532를 얻는다

7.4 t = 1 관측과 갱신: 지표 1만 관측

$z_1 = 3.0$ (지표 1만)

$$Z = [0 \quad 1 \quad 0]$$

$$v_1 = z_1 - Z\alpha_{1|0} = 3.0 - 0 = 3.0$$

$$F_1 = ZP_{1|0}Z' + \sigma_\varepsilon^2 = 1.14 + 0.2 = 1.34$$

칼만 이득과 상태 갱신

$$K_1 = P_{1|0}Z'F_1^{-1} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1.14 & 0 \\ 0 & 0 & 0.76 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \frac{1}{1.34} = \begin{bmatrix} 0 \\ 0.851 \\ 0 \end{bmatrix}$$

$$\alpha_{1|1} = \alpha_{1|0} + K_1 v_1 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0.851 \\ 0 \end{bmatrix} \times 3.0 = \begin{bmatrix} 0 \\ 2.553 \\ 0 \end{bmatrix}$$

GDP 나우캐스트

$$y_1^* = 0.6 \times 2.553 + 0.4 \times 0 = 1.532$$

결과: 1.532

03

3부

EM(Expectation-Maximization, 기댓값 최대화) 알고리즘

파라미터 추정과 결측 자료 처리: 이론, Shumway–Stoffer, 수치 예제

문제 제기

나우캐스팅에서는 파라미터도 추정해야 한다

8.1 문제 설정과 동기: 칼만 필터의 전제

필터는 θ를 안다고 가정한다

$$\theta = (\phi, \sigma_\eta^2, \sigma_\varepsilon^2, \ldots)$$

실제로는 파라미터를 자료에서 추정해야 한다

EM은 결측값과 파라미터를 동시에 푼다

나우캐스팅의 이중 문제

1. 결측값: 지표마다 발표 시점이 다르다 (Ragged edge)
2. 미지의 파라미터: 상태공간모형의 파라미터를 모른다
3. EM은 칼만 스무더와 자연스럽게 결합된다

EM은 번갈아 풀어서 닭과 달걀의 순환을 끊는다

8.2.1 '닭이 먼저냐, 달걀이 먼저냐'의 딜레마: EM의 해법은 두 단계를 번갈아 반복하는 것이다

딜레마

- 파라미터를 알면 → 결측값을 추정할 수 있다(칼만 필터)
- 결측값을 알면 → 파라미터를 추정할 수 있다(최대우도추정, MLE)

EM 반복 절차

1. 초깃값 $\theta^{(0)}$(예: $\varphi = 0.5$)
2. E-step: θ를 고정하고 칼만 스무더로 결측값의 기댓값을 계산
3. M-step: 채운 자료로 θ를 MLE 추정
4. 수렴 점검: YES → 중단 / NO → E-step 반복

수렴 점검 $|\theta^{(k+1)} - \theta^{(k)}| < \epsilon$?

정의

EM은 관측 자료의 우도를 최대화한다

8.2.2 수학적 정의: 목표와 EM 알고리즘의 아이디어

목표: 관측 자료만으로 로그우도를 최대화하는 θ를 찾는다

$$\max_{\theta} \log p(Y_{\text{obs}}|\theta)$$

그러나 자료의 일부가 숨어 있다

- 잠재변수·결측값, 이를 α라 한다

EM의 아이디어

- 현재 θ로 숨은 α를 예측하고(E-step), 그 예측으로 θ를 갱신한다(M-step)

E-step은 α를 추정하고 θ는 M-step에서만 움직인다

8.2.2 수학적 정의: E-step(기댓값)과 M-step(최대화)

E-step(기댓값 단계)

완전 자료 로그우도의 기댓값

$$Q(\theta \mid \theta^{(k)}) = E\left[\log p(Y_{\text{obs}}, \alpha \mid \theta) \mid Y_{\text{obs}}, \theta^{(k)}\right]$$

이 단계는 α를 추정하며 θ를 갱신하지 않는다

M-step(최대화 단계)

Q를 최대화하는 θ를 고른다

$$\theta^{(k+1)} = \arg\max_{\theta} Q(\theta \mid \theta^{(k)})$$

θ는 여기서만 갱신된다

반복할 때마다 우도는 낮아지지 않는다

8.2.2 수학적 정의: 반복, 수렴 보장, 기억할 점

반복

$$\theta^{(k)} \rightarrow \text{E-step} \rightarrow \text{M-step} \rightarrow \theta^{(k+1)} \rightarrow \cdots$$

수렴 보장

- 로그우도는 반복마다 증가한다

핵심 정리

단계	추정 대상	입력	출력
E-step	숨은 자료 α	$\theta^{(k)}$	$Q(\theta \mid \theta^{(k)})$
M-step	파라미터 θ	Q	$\theta^{(k+1)}$

상태공간모형의 EM은 칼만 필터 위에서 돌아간다

8.3 칼만 필터와의 연결, Shumway–Stoffer 알고리즘: 8.3.1 상태공간모형 다시 보기

관측식

$$y_t = Z_t\alpha_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, H_t)$$

상태식

$$\alpha_{t+1} = T_t\alpha_t + \eta_t, \quad \eta_t \sim N(0, Q_t)$$

추정할 파라미터(또는 그 원소)

$$\theta = (T, Q, Z, H)$$

E-step: 순방향 필터를 돌린 뒤 역방향 스무더를 돌린다

8.3.2 E-step = 칼만 스무더: E-step에는 충분통계량의 기댓값이 필요하다

순방향: 칼만 필터

$$\alpha_{t|t}, \quad P_{t|t} \quad (t = 1, \ldots, T)$$

순방향 계산

- 4절과 똑같다
- 결측값은 자동 처리된다(그 관측을 건너뛴다)

역방향: 칼만 스무더

$$\alpha_{t|T} = \alpha_{t|t} + J_t(\alpha_{t+1|T} - \alpha_{t+1|t})$$

$$P_{t|T} = P_{t|t} + J_t(P_{t+1|T} - P_{t+1|t})J_t'$$

여기서

$$J_t = P_{t|t}T'P_{t+1|t}^{-1}$$

스무딩한 합 세 개가 M-step의 입력이 된다

8.3.2 E-step: 시차 1 공분산 스무더(시점 간 공분산)와 충분통계량

시차 1 공분산 스무더

$$P_{t,t-1|T} = P_{t|t}J'_{t-1} + J_t(P_{t+1,t|T} - TP_{t|t})J'_{t-1}$$

충분통계량

$$S_1 = \sum_{t=1}^{T}(\alpha_{t|T}\alpha'_{t|T} + P_{t|T})$$

$$S_2 = \sum_{t=1}^{T-1}(\alpha_{t+1|T}\alpha'_{t|T} + P_{t+1,t|T})$$

$$S_3 = \sum_{t=1}^{T-1}(\alpha_{t|T}\alpha'_{t|T} + P_{t|T})$$

M-step은 T, Q, Z, H를 닫힌 형태로 갱신한다

8.3.3 M-step = 파라미터 갱신

전이행렬 T

$$T^{(k+1)} = S_2(S_3)^{-1}$$

관측식 파라미터도 같은 방식

$$Z^{(k+1)}, \quad H^{(k+1)}$$

상태 공분산 Q

$$Q^{(k+1)} = \frac{1}{T-1}\sum_{t=1}^{T-1}[(\alpha_{t+1|T} - T^{(k+1)}\alpha_{t|T})(\alpha_{t+1|T} - T^{(k+1)}\alpha_{t|T})' + P_{t+1|T} + T^{(k+1)}P_{t|T}(T^{(k+1)})' - T^{(k+1)}P_{t,t+1|T} - P_{t+1,t|T}(T^{(k+1)})']$$

요약하면

$$Q^{(k+1)} = \frac{1}{T-1}[S_1^{(2)} - T^{(k+1)}S_2' - S_2(T^{(k+1)})' + T^{(k+1)}S_3(T^{(k+1)})']$$

결측이 하나인 3시점 AR(1)로 EM을 손으로 계산해 본다

8.4 손 계산 예제: AR(1) + 결측값 + 파라미터 추정, 8.4.1 모형 설정

모형

$$y_t = \phi y_{t-1} + \eta_t, \quad \eta_t \sim N(0, \sigma_\eta^2)$$

$$z_t = y_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

추정할 파라미터

$$\theta = (\phi, \sigma_\eta^2, \sigma_\varepsilon^2)$$

초깃값

$$\phi^{(0)} = 0.5,\ \sigma_\eta^{(0)2} = 1.0,\ \sigma_\varepsilon^{(0)2} = 0.5$$

자료

$$z_1 = 1.0 \ (\text{관측})$$

$$z_2 = \text{결측}$$

$$z_3 = 2.0 \ (\text{관측})$$

t = 1에서 필터는 관측값 1.0으로 갱신한다

8.4.2 반복 1회차 E-step(칼만 필터): 초기 조건과 t = 1(관측)

초기 조건

$$y_{0|0} = 0, \quad P_{0|0} = 2.0$$

t = 1(관측): 예측

$$y_{1|0} = 0.5 \times 0 = 0$$

$$P_{1|0} = 0.5^2 \times 2.0 + 1.0 = 1.5$$

갱신

$$v_1 = 1.0 - 0 = 1.0$$

$$F_1 = 1.5 + 0.5 = 2.0$$

$$K_1 = 1.5/2.0 = 0.75$$

$$y_{1|1} = 0 + 0.75 \times 1.0 = 0.75$$

$$P_{1|1} = 1.5 - 0.75 \times 2.0 \times 0.75 = 0.375$$

t = 2는 결측이어서 예측값을 그대로 쓴다

8.4.2 반복 1회차 E-step(칼만 필터): t = 2(결측)

예측

$$y_{2|1} = 0.5 \times 0.75 = 0.375$$

$$P_{2|1} = 0.5^2 \times 0.375 + 1.0 = 1.094$$

갱신: 결측이므로 예측값 유지

$$y_{2|2} = y_{2|1} = 0.375$$

$$P_{2|2} = P_{2|1} = 1.094$$

t = 3의 관측값 2.0이 상태를 1.489로 끌어올린다

8.4.2 반복 1회차 E-step(칼만 필터): t = 3(관측)

예측

$$y_{3|2} = 0.5 \times 0.375 = 0.188$$

$$P_{3|2} = 0.5^2 \times 1.094 + 1.0 = 1.273$$

갱신

$$v_3 = 2.0 - 0.188 = 1.812$$

$$F_3 = 1.273 + 0.5 = 1.773$$

$$K_3 = 1.273/1.773 = 0.718$$

$$y_{3|3} = 0.188 + 0.718 \times 1.812 = 1.489$$

$$P_{3|3} = 1.273 - 0.718 \times 1.773 \times 0.718 = 0.358$$

스무딩으로 t = 2의 빈자리를 0.933으로 채운다

8.4.3 반복 1회차 E-step(칼만 스무더): t = 2 스무딩(3 → 2 역방향)

t = 2 스무딩(3 → 2 역방향)

$$J_2 = P_{2|2}\phi(P_{3|2})^{-1} = 1.094 \times 0.5/1.273 = 0.429$$

$$y_{2|3} = y_{2|2} + J_2(y_{3|3} - y_{3|2})$$

$$y_{2|3} = 0.375 + 0.429 \times (1.489 - 0.188) = 0.933$$

$$P_{2|3} = P_{2|2} + J_2(P_{3|3} - P_{3|2})J_2'$$

$$P_{2|3} = 1.094 + 0.429 \times (0.358 - 1.273) \times 0.429 = 0.925$$

t = 1까지 스무딩하면 값이 0.845로 수정된다

8.4.3 반복 1회차 E-step(칼만 스무더): t = 1 스무딩(2 → 1 역방향)

t = 1 스무딩(2 → 1 역방향)

$$J_1 = P_{1|1}\phi(P_{2|1})^{-1} = 0.375 \times 0.5/1.094 = 0.171$$

$$y_{1|3} = y_{1|1} + J_1(y_{2|3} - y_{2|1})$$

$$y_{1|3} = 0.75 + 0.171 \times (0.933 - 0.375) = 0.845$$

$$P_{1|3} = 0.375 + 0.171 \times (0.925 - 1.094) \times 0.171 = 0.370$$

스무딩한 계열은 세 시점의 정보를 모두 쓴다

8.4.3 반복 1회차 E-step(칼만 스무더): 스무딩 결과(전체 계열)

스무딩 결과(전체 계열)

$$y_{1|3} = 0.845 \ (\text{1월})$$

$$y_{2|3} = 0.933 \ (\text{2월, 결측값 추정치})$$

$$y_{3|3} = 1.489 \ (\text{3월})$$

결과 읽기

- 비어 있던 2월 값이 이제 추정값으로 채워졌다
- 모든 시점이 과거와 미래의 관측을 함께 쓴다

M-step에서 φ가 0.5에서 0.865로 올라간다

8.4.4 반복 1회차 M-step(파라미터 갱신): 충분통계량과 φ 갱신

충분통계량

$$S_1 = y_{1|3}^2 + y_{2|3}^2 + y_{3|3}^2 + P_{1|3} + P_{2|3} + P_{3|3}$$

$$S_1 = 0.845^2 + 0.933^2 + 1.489^2 + 0.370 + 0.925 + 0.358 = 5.455$$

$$S_2 = y_{2|3}y_{1|3} + y_{3|3}y_{2|3} + P_{2,1|3} + P_{3,2|3}$$

$$S_2 = 0.933 \times 0.845 + 1.489 \times 0.933 + 0.159 + 0.154 = 2.491$$

$$S_3 = y_{1|3}^2 + y_{2|3}^2 + P_{1|3} + P_{2|3}$$

$$S_3 = 0.845^2 + 0.933^2 + 0.370 + 0.925 = 2.880$$

φ 갱신

$$\phi^{(1)} = \frac{S_2}{S_3} = \frac{2.491}{2.880} = 0.865$$

0.5에서 0.865로 상승: 자료는 더 높은 자기상관을 시사한다

M-step에서 상태 잡음이 1.0에서 1.108로 올라간다

8.4.4 반복 1회차 M-step: 상태 잡음 분산 갱신

상태 잡음 분산 갱신

$$\sigma_\eta^{(1)2} = \frac{1}{2}\sum_{t=1}^{2}\left[\left(y_{t+1|3} - \phi^{(1)} y_{t|3}\right)^2 + P_{t+1|3} + \left(\phi^{(1)}\right)^2 P_{t|3} - 2\phi^{(1)}\, P_{t+1,t|3}\right]$$

계산

$$= \tfrac{1}{2}[(0.933 - 0.865 \times 0.845)^2 + 0.925 + 0.865^2 \times 0.370 - 2 \times 0.865 \times 0.159 + (1.489 - 0.865 \times 0.933)^2 + 0.358 + 0.865^2 \times 0.925 - 2 \times 0.865 \times 0.154]$$

$$\approx 1.108$$

관측 잡음은 관측된 시점만 쓴다: 0.507

8.4.4 반복 1회차 M-step: 관측 잡음 분산 갱신

관측 잡음 분산(관측된 시점만)

$$\sigma_\varepsilon^{(1)2} = \frac{1}{2}\left[(z_1 - y_{1|3})^2 + (z_3 - y_{3|3})^2 + P_{1|3} + P_{3|3}\right]$$

$$= \frac{1}{2}\left[(1.0 - 0.845)^2 + (2.0 - 1.489)^2 + 0.370 + 0.358\right]$$

$$= \frac{1}{2}\left[0.024 + 0.261 + 0.728\right] = 0.507$$

EM 한 번으로 세 파라미터가 모두 움직인다

8.4.4 반복 1회차: 갱신 요약

파라미터	초깃값	1회차 후	변화
φ	0.500	0.865	↑ +0.365
σ^2_η	1.000	1.108	↑ +0.108
σ^2_ε	0.500	0.507	≈ +0.007

가장 크게 움직인 값은 φ이다. 채운 자료에서 드러난 자기상관이다

E와 M을 반복하면 φ는 1을 넘어 1.414 쪽으로 간다

8.4.5 반복 2, 3, …회차

새 파라미터로 E-step 재실행

$\phi^{(1)} = 0.865$ 로 칼만 필터·스무더 재실행

결측값 추정치가 바뀐다:

$y_{2|3} = 0.933 \rightarrow y'_{2|3} \approx 1.356$

M-step 재실행

갱신된 충분통계량으로 파라미터 재추정

$\phi^{(2)} \approx 1.021$

10회 반복 후(아직 수렴 전)

$$\phi^{(10)} = 1.328, \quad \sigma_\eta^{(10)2} = 0.117, \quad \sigma_\varepsilon^{(10)2} = 0.072$$

$$y_2^{(10)} = 1.448 \quad (\text{결측값 추정치})$$

필터는 실시간으로 돌고, EM은 파라미터를 학습한다

8.5.1 비교표: 칼만 필터와 EM 알고리즘

항목	칼만 필터	EM 알고리즘
목적	상태 추정	파라미터 + 상태 추정
가정	파라미터를 앎	파라미터를 모름
입력	θ(고정)	자료만
출력	$\alpha_{t\|T}$	θ^*, $\alpha_{t\|T}^*$
결측값	자동 처리	처리 + 파라미터 개선
계산	1회 계산(순방향 + 역방향)	반복(수렴할 때까지)
실시간	가능(필터만)	불가능(전체 자료 필요)

오프라인에서 EM으로 학습하고, 온라인에서 필터로 운영한다

8.5.2 실무 작업 흐름: 세 단계

1단계: 학습(과거 자료)

과거 자료(결측 포함) → EM 실행(10~100회 반복) → 추정치 θ* 획득

2단계: 운영(실시간 나우캐스팅)

고정된 θ* 사용 → 새 자료가 실시간 유입 → 칼만 필터만 실행 (빠른 1회 계산) → GDP 나우캐스트 출력

3단계: 주기적 갱신(예: 매년)

새로 쌓인 자료로 EM 재실행 → θ* 갱신 → 2단계로 복귀

EM은 오프라인 학습용(느림), 칼만 필터는 온라인 운영용(실시간)이다

EM은 결측을 처리하고 이론적 보장을 갖춘다

8.6 EM의 장단점과 실무 고려사항: 8.6.1 장점

1. 결측 자료 자동 처리

- 값을 명시적으로 채우지 않고 기댓값으로 대체한다
- Ragged edge 문제를 자연스럽게 처리한다

2. 이론적 보장

- 로그우도의 단조 증가
- 국소 최적해로 수렴

3. 칼만 스무더와 자연스러운 결합

- E-step = 칼만 스무더(이미 아는 알고리즘)
- 추가 개발이 최소한으로 든다

4. 불확실성 전파

- 결측값의 불확실성(스무딩 분산)이 파라미터 추정에 반영된다

단점

EM은 느릴 수 있고 점추정치만 준다

8.6 EM의 장단점과 실무 고려사항: 8.6.2 단점

1. 국소 최적해

- 초깃값에 따라 다른 해로 수렴할 수 있다
- 여러 초깃값에서 실행한다

2. 계산 비용

- 반복마다 칼만 스무더(전체 표본)를 돌린다
- 대규모 시스템에서는 느리다

3. 표준오차 계산의 어려움

- EM은 점추정치만 준다
- 헤시안(Hessian)이나 부트스트랩이 필요하다

4. 수렴 속도

- 때로 매우 느리다(100회 이상 반복)
- 결측이 많을수록 느려진다

좋은 초깃값은 단순한 모형에서 얻는다

8.6 EM의 장단점과 실무 고려사항: 8.6.3 초깃값 전략

1. 일부 자료에 보통최소제곱(OLS) 적용

- 결측이 없는 구간으로 회귀한다

2. 단순한 모형 가정

- 예: 임의보행($\varphi = 1$)
- 잡음 분산의 초깃값은 표본분산으로 잡는다

3. 문헌의 전형적인 값

- 유사 모형의 추정치

4. 격자 탐색

- 여러 초깃값을 시험해 가장 좋은 값을 고른다

파라미터나 우도의 변화가 멈추면 중단한다

8.6 EM의 장단점과 실무 고려사항: 8.6.4 수렴 기준

기준 1: 파라미터 변화

$$\max_i \left|\theta_i^{(k+1)} - \theta_i^{(k)}\right| < \epsilon$$

기준 2: 로그우도 변화

$$\left|L(\theta^{(k+1)}) - L(\theta^{(k)})\right| < \epsilon \cdot \left|L(\theta^{(k)})\right|$$

실무 기준

$$\epsilon = 10^{-4} \sim 10^{-6}$$

연습문제 세 개로 EM 풀이 예제를 확장한다

8.7 연습문제

문제 1: 예제 8.4의 반복 2회차를 완성하라.

힌트: 다음 값으로 칼만 필터·스무더를 다시 돌린다.

$$\phi^{(1)} = 0.865$$

문제 2: 다음 자료에 EM을 실행하라.

자료:

$$z_1 = 2.0,\ z_2 = \text{결측},\ z_3 = \text{결측},\ z_4 = 3.5$$

모형: AR(1) · 초깃값:

$$\phi^{(0)} = 0.6$$

문제 3

- EM에서 로그우도가 항상 증가하는 이유는 무엇인가? 증명의 개요를 쓰라.
- 힌트: 젠센 부등식(Jensen's inequality)

04

4부

실시간 나우캐스팅 절차

정보 흐름, 상태벡터, 불확실성, 정보 가치, 실무, 요약

매달 지표가 발표될 때마다 나우캐스트를 한 번 갱신한다

9.1 정보 흐름: 15일 발표, 월말 나우캐스트

1월

1월 1일 → 1월 15일(발표) → 1월 31일

사전 추정(과거 정보) → x_1 관측·갱신, x_2·x_3 예측

1월 말 GDP 나우캐스트: 1.496

2월

2월 1일 → 2월 15일(발표) → 2월 28일

1월 정보 유지 → x_2 관측·갱신, x_3 예측, x_1 스무딩(역방향)

2월 말 GDP 나우캐스트: 1.669

3월

3월 1일 → 3월 15일(발표) → 3월 31일

1~2월 정보 유지 → x_3 관측·갱신, 전체 스무딩

3월 말 GDP 나우캐스트: 2.063

매달 원소 하나가 예측값에서 관측 자료로 바뀐다

9.2 시점별 상태벡터

1월 말

$$\alpha_{1,1} = \begin{bmatrix} y_1^* \\ x_{1,1|1,1} \\ x_{1,2|1,1} \\ x_{1,3|1,1} \end{bmatrix} = \begin{bmatrix} 1.496 \\ 2.049\ (\text{관측}) \\ 1.434\ (\text{예측}) \\ 1.004\ (\text{예측}) \end{bmatrix}$$

2월 말

$$\alpha_{1,2} = \begin{bmatrix} 1.669 \\ 2.100\ (\text{스무딩}) \\ 1.710\ (\text{관측}) \\ 1.197\ (\text{예측}) \end{bmatrix}$$

3월 말

$$\alpha_{1,3} = \begin{bmatrix} 2.063 \\ 2.132\ (\text{스무딩}) \\ 1.880\ (\text{스무딩}) \\ 2.177\ (\text{관측}) \end{bmatrix}$$

95% 구간이 ±1.02에서 ±0.55로 좁아진다

9.3 불확실성의 변화: GDP 추정치의 표준편차

1월 말

$$\sigma_{GDP|\text{1월}} = \sqrt{\frac{1}{9}(P_{1,1|1,1} + P_{1,2|1,1} + P_{1,3|1,1})}$$

$$\approx \sqrt{\tfrac{1}{9}(0.243 + 0.919 + 1.250)} \approx 0.52$$

2월 말

$$\sigma_{GDP|\text{2월}} \approx \sqrt{\tfrac{1}{9}(0.243 + 0.226 + 0.911)} \approx 0.39$$

3월 말

$$\sigma_{GDP|\text{3월}} \approx \sqrt{\tfrac{1}{9}(0.243 + 0.226 + 0.226)} \approx 0.28$$

95% 신뢰구간

1월 말(매우 넓음)

$$1.496 \pm 1.02 \rightarrow [0.48, 2.52]$$

2월 말(중간)

$$1.669 \pm 0.76 \rightarrow [0.91, 2.43]$$

3월 말(더 좁음)

$$2.063 \pm 0.55 \rightarrow [1.51, 2.61]$$

3월의 예상 밖 지표는 2월보다 가치가 컸다

9.4 정보 가치 분석: 관측별 기여

관측	GDP 변화	불확실성 감소	정보 가치
1월 → 2월	+0.173	−0.13	중간
2월 → 3월	+0.394	−0.11	높음

해석

- 3월 관측으로 GDP가 크게 상향 수정됐다(2.5는 예측값 1.197을 크게 웃돈다)
- 정보가 쌓일수록 추정 정확도가 높아진다

Ragged edge, 모형 선택, 평가가 중요하다

10. 실무 고려사항: 10.1 자료 불균형 · 10.2 모형 선택 · 10.3 평가

자료 불균형

- Ragged edge 문제: 지표마다 발표 시점이 다르다
- 일부 지표는 관측되고 나머지는 결측이다
- 칼만 필터는 결측 자료를 자연스럽게 처리한다

모형 선택

- 요인 모형: 많은 지표를 소수의 공통 요인으로 요약
- 동적 요인 모형: 시계열 동학을 추가
- MIDAS(Mixed Data Sampling, 혼합주기 표본추출): 회귀 기반 접근

평가

- 실시간 성능: 과거 자료로 백테스트
- 예측오차: 평균제곱근오차 (RMSE), 평균절대오차 (MAE) 등
- 갱신 효과: 새 정보 추가 시 개선 폭

나우캐스팅 문헌의 기준이 되는 논문 세 편

11. 주요 참고문헌

주요 참고문헌

- Banbura, M., et al. (2013). “Now-casting and the real-time data flow.” ECB Working Paper.
- Giannone, D., et al. (2008). “Nowcasting: The real-time informational content of macroeconomic data.” Journal of Monetary Economics.
- Mariano, R. S., & Murasawa, Y. (2003). “A new coincident index of business cycles based on monthly and quarterly series.” Journal of Applied Econometrics.

요약

나우캐스팅 = 상태공간모형 + 칼만 필터

12. 요약

나우캐스팅의 요점

1. 목표: 현재의 경제 상태를 실시간으로 추정
2. 방법: 고빈도 지표로 저빈도 지표를 예측(혼합주기)
3. 도구: 상태공간모형 + 칼만 필터
4. 강점: 결측 자료를 처리하고 정보를 단계적으로 갱신
5. 활용: 중앙은행 정책, 투자 판단, 경기 모니터링

칼만 필터의 역할

- 새 정보가 들어올 때마다 추정값을 실시간으로 갱신한다
- 추정의 불확실성(분산)도 함께 제공한다
- 과거 자료를 스무딩해 전체 계열을 재추정한다

A

부록

손 계산 점검표

칼만 필터 단계 점검 · 실시간 갱신 작업 흐름 · 예제 3 따라가기

칼만 필터의 각 단계를 순서대로 점검한다

부록: 손 계산 점검표, 칼만 필터 단계별 점검

예측 단계(1~2행) · 갱신 단계(3~7행)

- [ ] $\alpha_{t|t-1} = T_t \alpha_{t-1|t-1}$ 계산
- [ ] $P_{t|t-1} = T_t P_{t-1|t-1} T_t' + R_t Q_t R_t'$ 계산
- [ ] $v_t = y_t - Z_t \alpha_{t|t-1}$ (예측오차)
- [ ] $F_t = Z_t P_{t|t-1} Z_t' + H_t$ (예측오차 분산)
- [ ] $K_t = P_{t|t-1} Z_t' F_t^{-1}$ (칼만 이득)
- [ ] $\alpha_{t|t} = \alpha_{t|t-1} + K_t v_t$ (상태 갱신)
- [ ] $P_{t|t} = P_{t|t-1} - K_t F_t K_t'$ (분산 갱신)

주의 사항

- 행렬 차원이 맞는가
- 분산은 항상 양수인가
- 칼만 이득이 0과 1 사이인가(단변량의 경우)
- 예측오차의 평균이 0인가

관측, 갱신, 나우캐스트 후 다음 분기로 넘어간다

부록: 실시간 갱신 작업 흐름

[t=1, m=1]

1월 지표 관측

칼만 필터 갱신 → GDP_1 계산

1월 말 나우캐스트

[t=1, m=2]

2월 지표 관측

칼만 필터 갱신 → GDP_2 계산

2월 말 나우캐스트

[t=1, m=3]

3월 지표 관측

칼만 필터 갱신 + 스무더 → GDP_3 계산

3월 말 최종 나우캐스트

시작 → 월별 갱신 3회 → 다음 분기로

지표 1만 보일 때 GDP를 어떻게 추정할까?

부록: 손 계산 점검표(예제 3), 설정

분기 GDP는 지표 두 개의 가중합이고, 지표 1만 관측된다

$$\text{GDP} = 0.6 \times \text{지표}1 + 0.4 \times \text{지표}2$$

1단계: 초기 상태(모두 불확실)	값	분산
GDP	?	2
지표 1	?	1
지표 2	?	1

예상 밖 3.0의 85%를 믿으면 GDP는 1.532가 된다

부록: 손 계산 점검표(예제 3), 2·3단계

2단계: 지표 1 = 3.0 관측

- 예상: 지표 1 = 0(사전 평균)
- 관측: 지표 1 = 3.0
- 오차: 3.0(크게 빗나감!)

칼만 이득 = 0.851: “오차의 85%를 반영”

$$\text{지표}1\ \text{갱신}: 0 + 0.851 \times 3.0 = 2.553$$

3단계: GDP 추정

```
GDP = 0.6 × 2.553 + 0.4 × 0 = 1.532
```

지표 2는 왜 0인가?

- 지표 2는 관측되지 않았다
- 지표 1과 2는 독립이다(공분산 = 0)
- 그래서 지표 1의 정보가 지표 2로 넘어가지 않는다

사전 분산에 비해 잡음이 작으면 신뢰도가 높다

부록: 손 계산 점검표(예제 3), 실무적 의미와 이득의 직관

시나리오

- 지표 1 = 산업생산지수(일찍 발표)
- 지표 2 = 소비지출(늦게 발표), GDP는 두 지표를 결합

해석

- 생산이 예상보다 3.0 높게 나왔다
- “그럼 GDP도 높은가?” 소비는 아직 모르므로 0으로 둔다

K = 0.851의 의미

$$\text{GDP} = 0.6 \times (\text{산업생산 높음}) + 0.4 \times 0 = \text{부분 상승}$$

$$\text{신뢰도} = \text{사전 분산} \,/\, (\text{사전 분산} + \text{관측 잡음})$$

$$= 1.14 \,/\, (1.14 + 0.2) = 0.85$$

아는 것은 적고 측정은 정확해서 이득이 높다

부록: 손 계산 점검표(예제 3), 칼만 이득의 직관(계속)

사전 분산 1.14는 크다

"아는 것이 많지 않다"

관측 잡음 0.2는 작다

"측정이 정확하다"

따라서

관측값을 85% 신뢰한다

$$\text{신뢰도} = \text{사전 분산} \,/\, (\text{사전 분산} + \text{관측 잡음})$$

$$= 1.14 \,/\, (1.14 + 0.2) = 0.85$$

이득이 0이면 그 상태로 정보가 흐르지 않는다

부록: 손 계산 점검표(예제 3), 지표 2는 왜 갱신되지 않는가?

칼만 이득 벡터

$$K = [0,\ 0.851,\ 0]'$$

첫째 0: GDP는 직접 관측되지 않는다

둘째 0.851: 지표 1이 관측된다

셋째 0: 지표 2는 관측되지 않고 지표 1과 무관하다

지표 1과 2가 상관돼 있다면

- "산업생산이 늘면 소비도 늘 것이다"(양의 상관)
- 그러면 지표 2도 조금 갱신된다
- 그러나 이 예제는 독립을 가정한다 → 전파 없음

요약

$$\text{GDP} = 0.6 \times 2.553 = 1.532 \quad (\text{지표 2는 0에 머문다: 정보 없음})$$

필터는 분산으로 신뢰도를 정하고 새 정보에 가중치를 준다

부록: 손 계산 점검표(예제 3), 세 줄 요약과 핵심 메시지

세 줄 요약

1. 지표 1이 3.0으로 관측 → 예상(0)보다 3.0 높음
2. 오차의 85%를 신뢰 → 지표 1을 2.553으로 갱신
3. GDP 나우캐스트 1.532: 지표 2는 정보가 없어 0에 머문다

핵심 메시지: 신뢰도는 분산으로 계산하고, 새 정보는 최적 비율로 반영한다