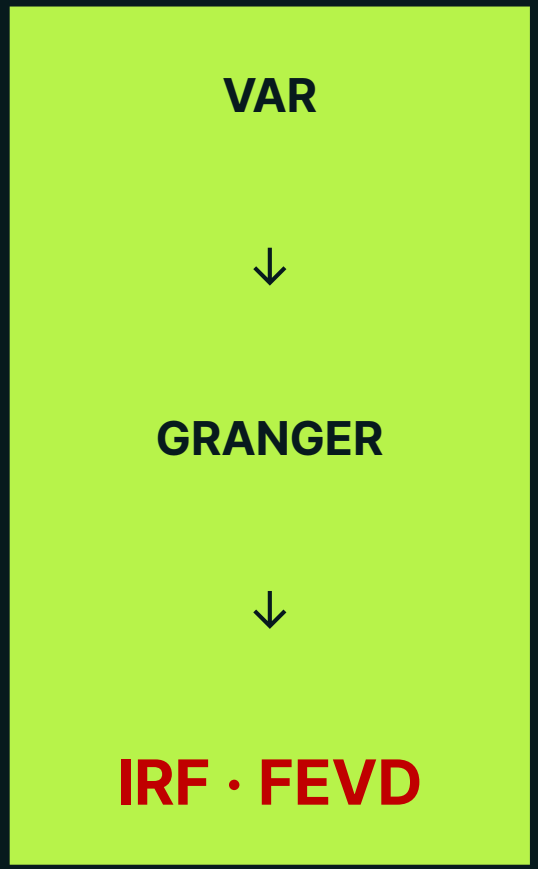
VAR 모형 핵심 수식 치트 시트

한 장에 수식 하나 — VAR · 그레인저 인과 · IRF와 FEVD



Advanced Financial Time Series · Week 6

세 부를 수식 중심으로 한 시간에 정리합니다

부마다 모형 → 검정·조건 → 그림 순서로, 한 장에 수식 하나씩 본다

01	VAR 모형	**여러 시계열을 하나의 시스템으로** 정의 · 계수 행렬 · 추정 · 안정성 · 시차 · 예측
02	그레인저 인과	**예측 검정이지 인과 증명이 아니다** 정의 · F-검정 · 네 가지 결과 · 교란변수 · 확장
03	IRF와 FEVD	**얽힌 충격을 풀고 추적한다** 직교화 · 촐레스키 · 충격반응 · 분산분해
04	종합	**하나의 VAR, 세 개의 렌즈** 도구 비교 · 7주차 공적분으로의 연결

모형을 세우고 → 예측 관계를 검정하고 → 충격의 경로와 비중을 읽는다

01

VAR 모형

각 시계열이 모든 시계열의 과거에 반응하는 하나의 시스템

VAR는 모든 변수를 모든 변수의 과거로 설명합니다

k개 시계열을 세로로 쌓은 벡터 Y에 대한 p차 자기회귀

VAR(p)

$$\mathbf{Y}_t = \mathbf{c} + A_1\mathbf{Y}_{t-1} + A_2\mathbf{Y}_{t-2} + \cdots + A_p\mathbf{Y}_{t-p} + \boldsymbol{\varepsilon}_t$$

변수가 하나(k=1)면 AR(p)로 돌아간다

$$k = 1: \quad y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

읽는 법

- Y: k개 시계열을 쌓은 벡터, ε: 충격 벡터 (공분산 Σ)
- A: 시차마다 하나씩 붙는 k행 k열 계수 행렬
- 모든 방정식이 모든 변수의 과거를 설명변수로 쓴다
- Sims(1980): 이론 제약 없이 데이터가 말하게 한다

VAR는 벡터를 위한 AR이다 — 자기 과거와 남의 과거를 함께 본다

교차항 a12와 a21이 VAR를 쓰는 이유입니다

2변수·시차 1개로 풀어 쓴 VAR(1)과 그 계수 행렬

2변수 VAR(1)

$$y_{1,t} = c_1 + a_{11}\, y_{1,t-1} + a_{12}\, y_{2,t-1} + \varepsilon_{1,t}$$
$$y_{2,t} = c_2 + a_{21}\, y_{1,t-1} + a_{22}\, y_{2,t-1} + \varepsilon_{2,t}$$

행렬로 묶으면: 비대각 a12, a21이 상호작용

$$\begin{pmatrix} y_{1,t} \\ y_{2,t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{pmatrix}$$

읽는 법

- 대각 a11, a22: 자기 시차 효과(AR 계수)
- a12: Y2의 과거가 Y1을 움직이는 정도
- a21: Y1의 과거가 Y2를 움직이는 정도
- 비대각이 크면 선행-후행, 부호는 방향

교차항이 모두 0이면 서로 무관한 AR 두 개와 같다

VAR는 방정식마다 OLS로 추정하면 충분합니다

모든 방정식의 설명변수가 같아 방정식별 OLS가 효율적이다 (SUR 결과)

모든 방정식의 공통 설명변수

$$\mathbf{x}_t = \left(1,\ y_{1,t-1},\ y_{2,t-1}\right)^\top$$

잔차 공분산 행렬

$$\hat{\Sigma} = \frac{1}{T}\sum_{t=1}^{T} \hat{\boldsymbol{\varepsilon}}_t \hat{\boldsymbol{\varepsilon}}_t^\top = \begin{pmatrix} \hat{\sigma}_1^2 & \hat{\sigma}_{12} \\ \hat{\sigma}_{12} & \hat{\sigma}_2^2 \end{pmatrix}$$

읽는 법

- 추정 결과: 계수 행렬 A와 잔차 공분산 Σ
- σ12 ≠ 0: 두 충격이 같은 시점에 함께 온다
- 축약형: 어떤 변수도 원인으로 지정하지 않는다
- 대가: 인과적 충격은 바로 읽을 수 없다

추정은 쉽고, 해석의 어려움은 Σ에 숨어 있다

고유값이 모두 단위원 안에 있어야 VAR가 안정적입니다

충격은 매기 A를 곱하며 전달된다 — 단변량 단위근 조건의 다변량 버전

안정성 조건

$$\frac{\partial \mathbf{Y}_{t+h}}{\partial \boldsymbol{\varepsilon}_t^\top} = A^h \;\to\; 0 \quad\Longleftrightarrow\quad |\lambda_i| < 1 \;\; \forall i$$

시차가 여럿이면 동반 행렬 F로 쌓는다

$$\begin{pmatrix} \mathbf{Y}_t \\ \mathbf{Y}_{t-1} \end{pmatrix} = \underbrace{\begin{pmatrix} A_1 & A_2 \\ I & 0 \end{pmatrix}}_{F\ (\text{companion})} \begin{pmatrix} \mathbf{Y}_{t-1} \\ \mathbf{Y}_{t-2} \end{pmatrix} + \begin{pmatrix} \mathbf{c} + \boldsymbol{\varepsilon}_t \\ \mathbf{0} \end{pmatrix}$$

읽는 법

- λ: 계수 행렬(또는 F)의 고유값
- 안정: 충격이 사라지고 평균 주위에서 등락
- 불안정: 충격이 증폭되어 시스템이 폭발
- F의 아래 블록 [I 0]은 값을 한 칸 미는 항등식

안정성 확인이 모든 VAR 분석의 첫 관문이다

고유값이 단위원 밖으로 나가면 충격이 증폭됩니다

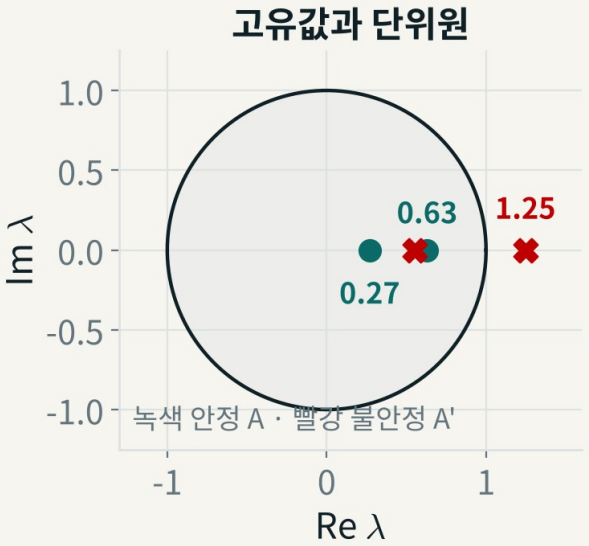
A = [[0.5, 0.3], [0.1, 0.4]] 와 A' = [[0.9, 0.4], [0.3, 0.9]] 비교

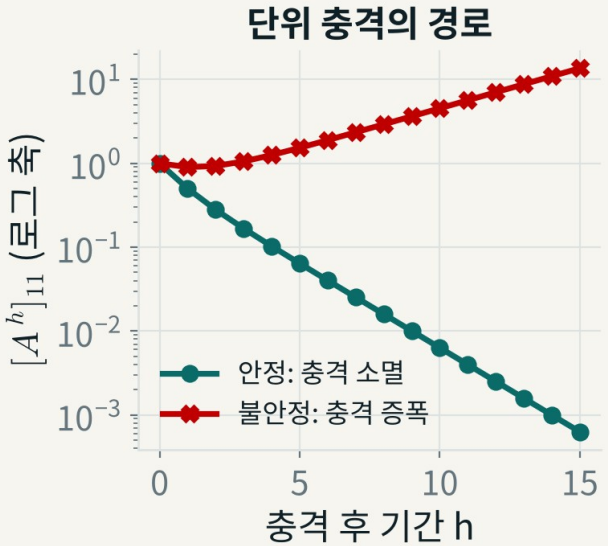
2×2 행렬의 고유값

$$\lambda = \frac{\operatorname{tr} A \pm \sqrt{(\operatorname{tr} A)^2 - 4 \det A}}{2}$$

STABLE vs EXPLOSIVE

- A: 고유값 0.63, 0.27 → 안정
- A': 최대 고유값 1.25 → 폭발





고유값의 크기가 충격이 사라지는 속도를 정한다

정보기준이 가장 작은 시차 p를 고릅니다

잔차의 크기(적합도)와 파라미터 수(벌점)를 한 숫자로 저울질한다

AIC · BIC · HQ

$$\mathrm{AIC}(p) = \ln|\hat{\Sigma}_p| + \frac{2}{T}pk^2$$

$$\mathrm{BIC}(p) = \ln|\hat{\Sigma}_p| + \frac{\ln T}{T}pk^2$$

$$\mathrm{HQ}(p) = \ln|\hat{\Sigma}_p| + \frac{2\ln\ln T}{T}pk^2$$

읽는 법

- 첫 항: 잔차 공분산 행렬식의 로그 — 적합도
- 둘째 항: 벌점 — 시차 하나에 계수가 k의 제곱 개
- 값이 작을수록 좋다. BIC는 벌점이 커서 짧은 시차를 고른다
- 선택 후 잔차에 자기상관이 남았는지 확인한다

둘이 다르면 BIC의 단순한 모형이 표본 밖에서 더 안정적인 경우가 많다

변수가 두 배가 되면 추정할 계수는 약 네 배가 됩니다

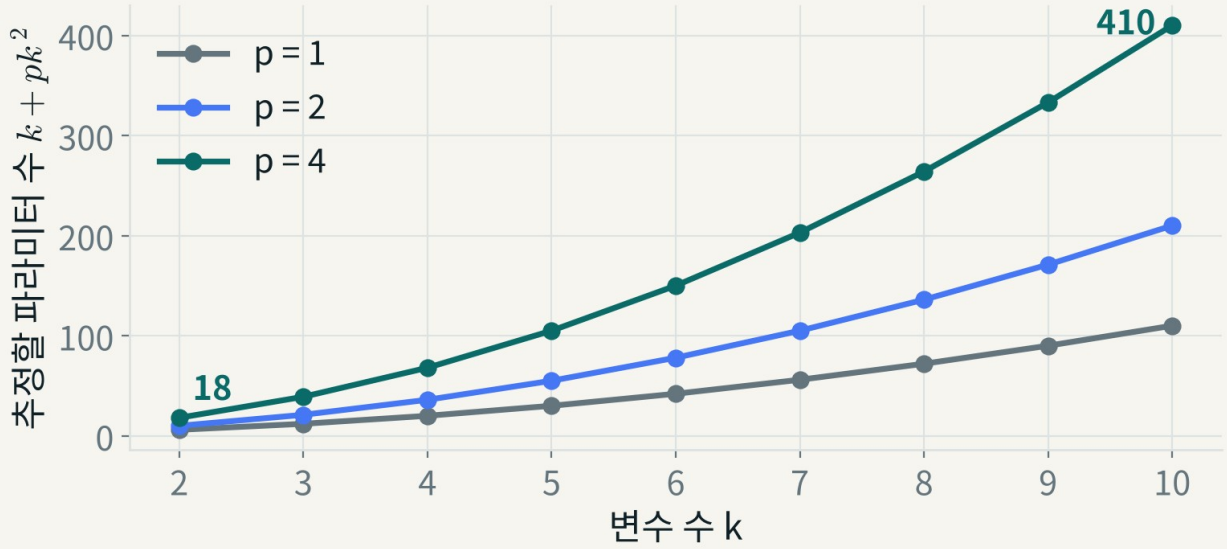
상수 k개에 시차마다 k행 k열 계수 행렬이 하나씩 붙는다

추정할 파라미터 수

$$\#\text{params} = \underbrace{k}_{\text{constants}} + \underbrace{p\,k^2}_{\text{coefficients}}$$

CURSE OF DIMENSIONALITY

- k=10, p=4 → 410개
- 월간 10년: 식당 41개



VAR는 작고 낮은 차수로 유지한다

VAR 예측은 행렬 곱셈을 반복하는 것입니다

한 기 앞 예측값을 다시 입력으로 넣어 여러 기 앞을 만든다

한 기 앞 예측: 마지막 관측값을 모두 넣는다

$$\hat{\mathbf{Y}}_{t+1|t} = \mathbf{c} + A_1\mathbf{Y}_t + A_2\mathbf{Y}_{t-1} + \cdots + A_p\mathbf{Y}_{t-p+1}$$

반복 예측과 장기 평균 μ

$$\hat{\mathbf{Y}}_{t+h|t} = \mathbf{c} + A\,\hat{\mathbf{Y}}_{t+h-1|t} \xrightarrow{h\to\infty} \boldsymbol{\mu} = (I - A)^{-1}\mathbf{c}$$

읽는 법

- 오차의 기댓값은 0이므로 예측식에서 빠진다
- 각 변수의 예측이 다른 변수의 최근 움직임을 쓴다
- 안정적이면 예측은 μ로 수렴한다
- 모든 변수를 한 번에, 서로 일관되게 예측한다

예측은 추정한 교차 동학을 그대로 따른다

예측 구간은 넓어지다가 일정 폭에서 멈춥니다

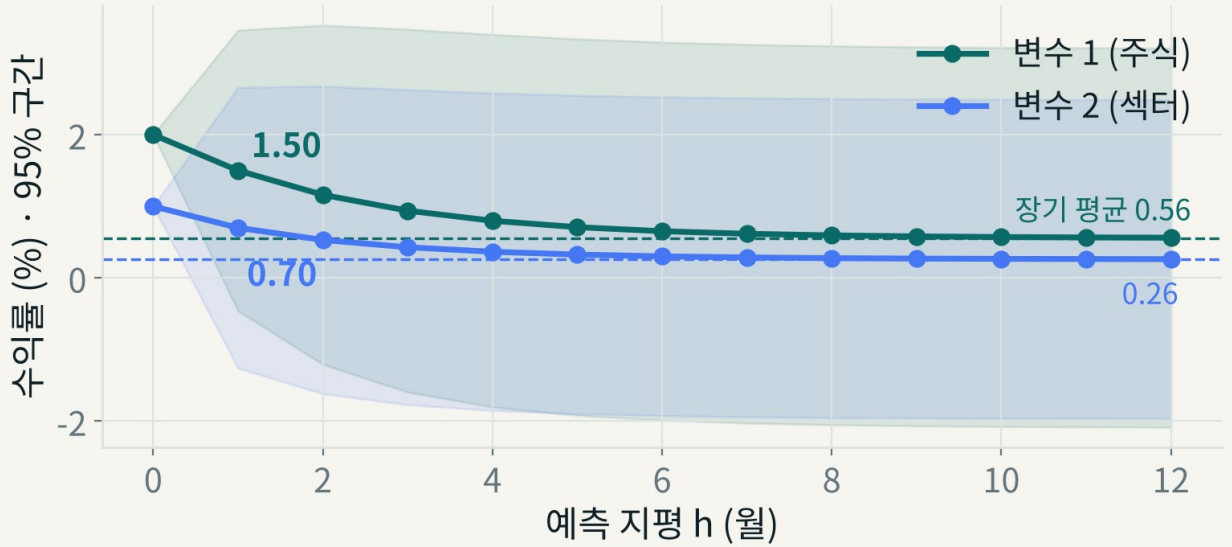
예시: c = [0.2, 0.1], 출발값 [2.0, 1.0], 충격 분산 1·상관 0.4

h기 앞 예측오차 공분산

$$\mathrm{Cov}\left(\mathbf{Y}_{t+h} - \hat{\mathbf{Y}}_{t+h|t}\right) = \sum_{i=0}^{h-1} A^i \, \Sigma \, (A^i)^\top$$

JOINT FORECAST

- 한 기 앞 1.50, 0.70
- 장기 평균 0.56, 0.26으로 수렴



안정성이 예측의 수렴과 구간의 상한을 함께 보장한다

02

그레인저 인과

X의 과거가 Y의 예측을 개선하는가 — 예측 검정이지 인과 증명이 아니다

X의 과거가 Y의 예측오차를 줄이면 X가 Y를 그레인저 인과합니다

Granger(1969) — '인과'는 '예측에 도움이 된다'는 뜻일 뿐이다

정의: 예측오차로 쓴 문장

$$X \text{ Granger-causes } Y$$
$$\iff \quad \mathrm{MSE}(Y_t \mid Y_{<t}, X_{<t}) < \mathrm{MSE}(Y_t \mid Y_{<t})$$

VAR 안에서는 교차 계수의 결합 제약

$$Y_2 \not\Rightarrow Y_1 \quad \iff \quad a_{12}^{(1)} = a_{12}^{(2)} = \cdots = a_{12}^{(p)} = 0$$

읽는 법

- MSE: 평균제곱 예측오차, Y<t: t 이전의 Y 전체
- X를 더해 오차가 엄격히 줄어야 한다
- Part 1의 교차항 a12가 모두 0인지 묻는 검정이다
- 이름과 달리 원인-결과를 뜻하지 않는다

그레인저 인과는 '예측 정보가 있다'는 뜻까지만이다

검정은 제약 모형과 비제약 모형의 비교입니다

Y를 자기 과거로만 예측한 뒤, X의 과거를 더해 다시 예측한다

제약 모형 (R): Y의 과거만

$$Y_t = c + \sum_{i=1}^{p} a_i \, Y_{t-i} + u_t$$

비제약 모형 (U): X의 과거 추가

$$Y_t = c + \sum_{i=1}^{p} a_i \, Y_{t-i} + \sum_{i=1}^{p} b_i \, X_{t-i} + \varepsilon_t$$

읽는 법

- a: Y 자신의 시차 계수, b: X의 시차 계수
- 제약 모형 = 비제약 모형에 b = 0을 건 것
- 두 변수에 같은 시차 p를 둔다(VAR의 p)
- 입력은 차분한 정상 시계열이어야 한다

X→Y와 Y→X는 별개의 질문이다 — 반드시 두 번 검정한다

F-통계량은 줄어든 잔차가 우연 이상인지 묻습니다

변수를 더하면 RSS는 항상 줄어든다 — 줄어든 양을 남은 잡음과 비교한다

귀무가설: X의 시차 계수가 모두 0

$$H_0 : \ b_1 = b_2 = \cdots = b_p = 0$$

F-통계량

$$F = \frac{(\mathrm{RSS}_R - \mathrm{RSS}_U)/q}{\mathrm{RSS}_U/(T-k)} \ \sim \ F(q, T-k)$$

읽는 법

- RSS: 잔차제곱합, q: 제약 수(X의 시차 수)
- k: 비제약 모형의 계수 수, T: 관측치 수
- 분자는 시차 하나가 줄인 오차, 분모는 남은 잡음
- b를 하나씩 보지 않고 한꺼번에 검정한다

임계값을 넘으면 귀무가설을 기각한다 — X가 Y를 그레인저 인과

섹터는 주식을 예측하지만 주식은 섹터를 예측하지 못합니다

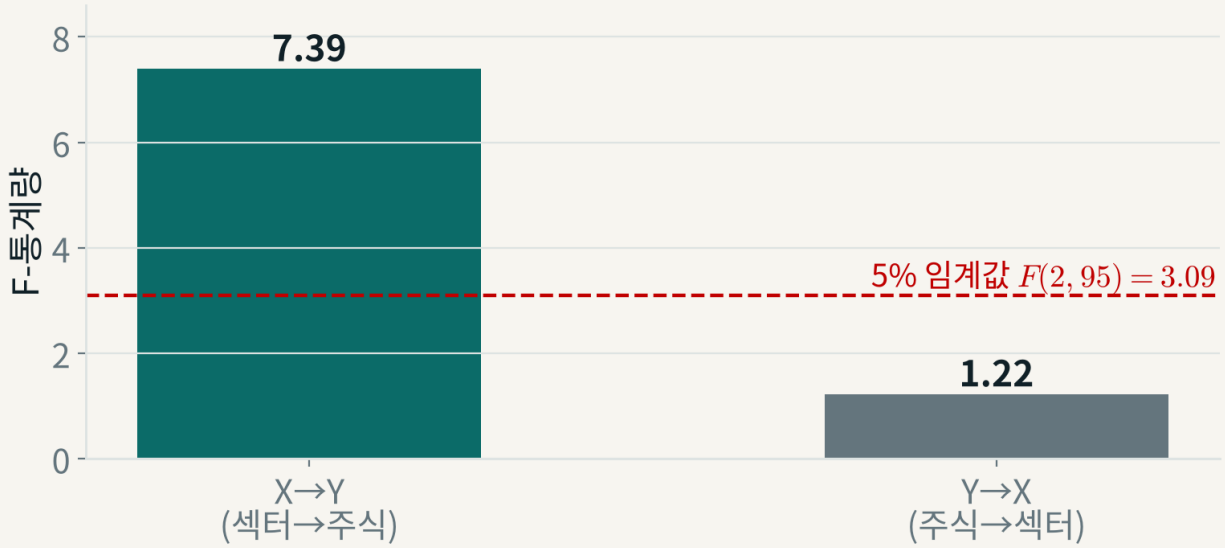
섹터 지수(X)와 개별 주식(Y), 시차 2·관측치 100으로 두 방향을 검정한 결과

X → Y 방향의 F

$$F = \frac{(52-45)/2}{45/95} = 7.39 > F_{0.05}(2,95) = 3.09$$

BOTH DIRECTIONS

- 역방향 RSS 60 → 58.5, F 1.22
- 결과: X → Y 단방향



한 방향만 보면 피드백과 단방향을 구분할 수 없다

두 방향 검정으로 모든 쌍은 네 칸 중 하나에 들어갑니다

각 방향이 유의한지·아닌지의 조합

FOUR OUTCOMES

- 단방향: 예측의 선행 순서가 있다
- 피드백: 서로를 예측한다
- 독립: 시차 예측 연결이 없다
- 독립이어도 같은 시점 상관은 남을 수 있다

X → Y 단방향
X→Y 유의 · Y→X 아님



Y → X 단방향
Y→X 유의 · X→Y 아님



양방향 피드백
두 방향 모두 유의



독립
두 방향 모두 유의하지 않음



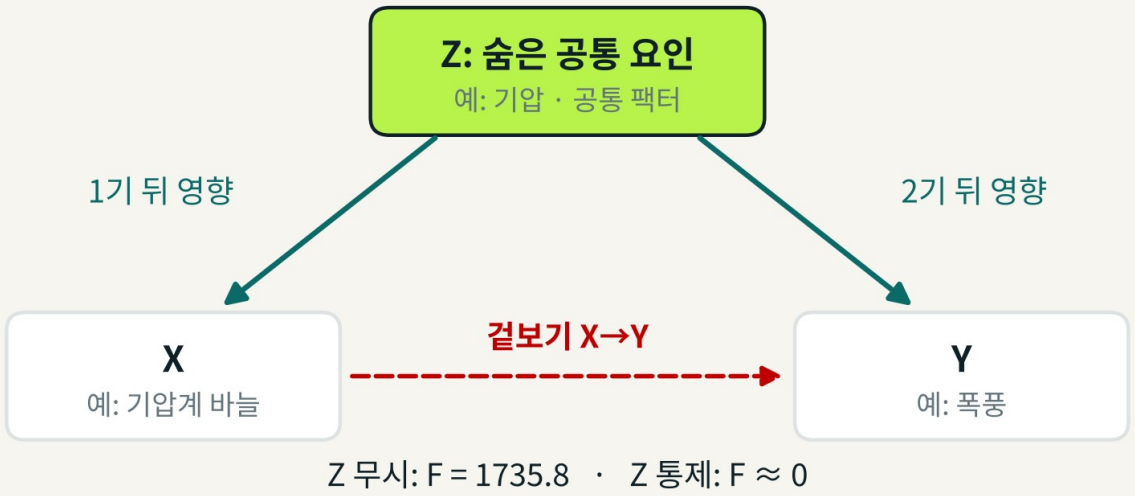
앞의 섹터-주식 쌍은 X → Y 단방향 칸에 들어간다

숨은 공통 요인은 가짜 그레인저 인과를 만듭니다

Z가 X에는 1기 뒤, Y에는 2기 뒤에 영향을 주는 경우 (강의 시뮬레이션)

교란변수 구조

$$X_t = Z_{t-1} + u_t, \quad Y_t = Z_{t-2} + v_t$$
$$\Longrightarrow \ \mathrm{Corr}(X_{t-1},\, Y_t) \neq 0$$



SPURIOUS CAUSALITY

- X와 Y 사이 연결은 없다
- 기대·발표 시차도 착시

예측 관계는 인과의 증거가 아니다 — Z를 통제하면 사라진다

같은 시점의 연결과 변수 묶음의 연결은 따로 다룹니다

동시적 인과(instantaneous causality)와 블록 외생성(block exogeneity)

동시적 인과: 같은 기간의 오차 상관

$$\mathrm{Cov}\left(\varepsilon_{1,t},\ \varepsilon_{2,t}\right) = \sigma_{12} \neq 0$$

블록 외생성: Y2 블록이 Y1 블록을 예측하는가

$$\mathbf{Y}_t = \begin{pmatrix} \mathbf{Y}_{1,t} \\ \mathbf{Y}_{2,t} \end{pmatrix} : \quad H_0 : \ A_{12}^{(1)} = \cdots = A_{12}^{(p)} = \mathbf{0}$$

읽는 법

- 동시적 인과에는 방향이 없다 — Σ의 비대각
- 블록 검정은 왈드·LR 검정(카이제곱 분포)으로 판정
- 제3의 변수를 넣으면 가짜 연결이 사라질 수 있다
- 교차상관이 X의 과거 쪽에서 정점이면 X가 선행

방향 없는 동시 상관이 Part 3의 직교화를 부른다

03

충격반응함수와 분산분해

얽힌 충격을 독립 충격으로 풀고, 그 경로(IRF)와 비중(FEVD)을 읽는다

충격이 얽혀 있으면 직교화로 독립 충격을 만듭니다

잔차 공분산이 대각이 아니면 '변수 1에만 충격'을 정의할 수 없다

문제: 같은 시점 충격의 상관

$$\Sigma = \mathrm{Cov}(\boldsymbol{\varepsilon}_t) = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix}, \qquad \sigma_{12} \neq 0$$

해법: 구조적 충격 u로 다시 쓰기

$$\boldsymbol{\varepsilon}_t = P\,\mathbf{u}_t, \qquad \mathrm{Cov}(\mathbf{u}_t) = I \quad \Longrightarrow \quad \Sigma = PP^\top$$

읽는 법

- u: 서로 독립이고 분산이 1인 구조적 충격
- P: 독립 충격이 섞여 관측 잔차가 되는 방식
- 조건을 만족하는 P는 무수히 많다
- 표준 선택은 아래 삼각 P — 촐레스키 분해

직교화 없이는 충격 하나의 효과를 말할 수 없다

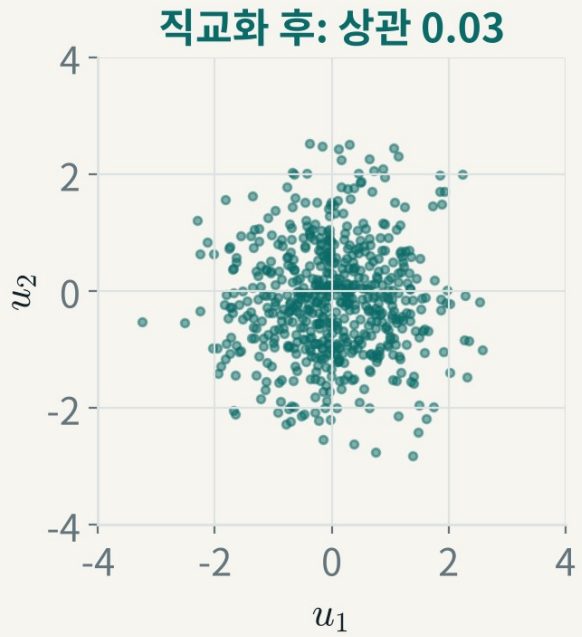
직교화는 기울어진 잔차 구름을 둥근 구름으로 바꿉니다

상관 0.7로 만든 잔차 600개를 촐레스키로 변환한 결과 (예시 데이터)

ORTHOGONALIZATION

- 왼쪽: ε1이 오르면 ε2도 오른다
- 오른쪽: u1과 u2는 서로 무관하다
- 같은 정보를 겹치지 않는 축으로 다시 썼다





이제 충격을 하나씩 따로 움직일 수 있다

촐레스키 분해는 변수 순서라는 가정을 함께 들여옵니다

아래 삼각 P: 먼저 놓인 변수가 같은 시점의 공유 움직임을 모두 가져간다

2변수 촐레스키

$$P = \begin{pmatrix} p_{11} & 0 \\ p_{21} & p_{22} \end{pmatrix} : \quad \begin{aligned} \varepsilon_{1,t} &= p_{11}\, u_{1,t} \\ \varepsilon_{2,t} &= p_{21}\, u_{1,t} + p_{22}\, u_{2,t} \end{aligned}$$

원소는 Σ에서 바로 계산된다

$$p_{11} = \sigma_1, \qquad p_{21} = \frac{\sigma_{12}}{\sigma_1}, \qquad p_{22} = \sqrt{\sigma_2^2 - \frac{\sigma_{12}^2}{\sigma_1^2}}$$

읽는 법

- p21: 두 충격이 공유하는 부분 → 변수 1이 가져간다
- 뒤 변수의 충격은 같은 기간 앞 변수에 못 간다
- 가장 외생적인 변수를 먼저 둔다
- 순서를 바꿔 민감도를 함께 보고한다

순서는 데이터가 아니라 분석자가 고르는 가정이다

충격반응함수는 독립 충격의 가중치 Θ입니다

안정적 VAR(1)을 과거 충격의 합(이동평균 표현)으로 풀어 쓴 결과

이동평균 표현 MA(∞)

$$\mathbf{Y}_t = \boldsymbol{\mu} + \sum_{h=0}^{\infty} A^h \boldsymbol{\varepsilon}_{t-h} = \boldsymbol{\mu} + \sum_{h=0}^{\infty} \underbrace{A^h P}_{\Theta_h} \mathbf{u}_{t-h}$$

IRF: 충격 j에 대한 변수 i의 h기 뒤 반응

$$\mathrm{IRF}_{ij}(h) = \frac{\partial\, y_{i,t+h}}{\partial\, u_{j,t}} = \left[A^h P\right]_{ij} = [\Theta_h]_{ij}$$

읽는 법

- h = 0이면 Θ = P: 충격 직후의 반응
- h가 늘면 A를 한 번씩 더 곱한다
- 읽을 것: 부호, 크기와 정점, 지속성
- 신뢰대가 0을 포함하지 않을 때만 의미 있다

IRF는 계수 행렬을 '충격 이야기'로 번역한다

충격은 두 변수로 번진 뒤 6개월 무렵 거의 사라집니다

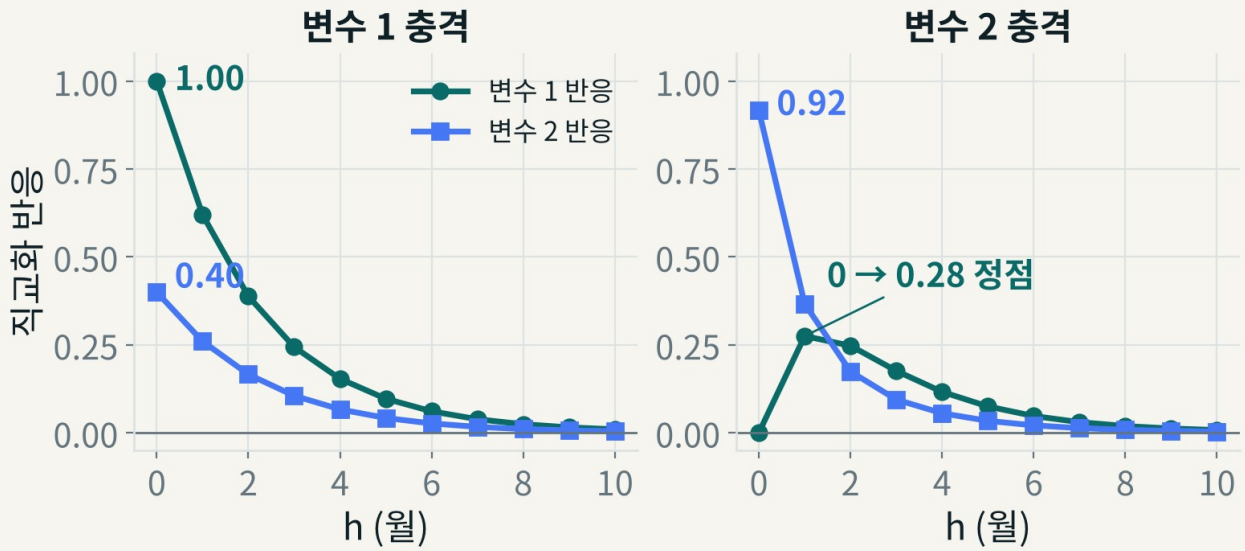
A = [[0.5, 0.3], [0.1, 0.4]], 충격 분산 1·상관 0.4, 순서 [1, 2]

충격 직후 반응 = P의 열

$$\Sigma = \begin{pmatrix} 1 & 0.4 \\ 0.4 & 1 \end{pmatrix} \Rightarrow P = \begin{pmatrix} 1 & 0 \\ 0.4 & 0.917 \end{pmatrix}$$

IMPULSE RESPONSES

- 변수 1 충격: 1.00, 0.40
- 변수 2 충격: 0, 0.92



교차 반응이 한 기 늦게 나타나는 것은 순서 가정 때문이다

FEVD는 예측오차 분산을 충격별 비중으로 나눕니다

독립 충격이므로 예측오차 분산이 충격별 기여의 단순합으로 나뉜다

h기 앞 예측오차 = 앞으로 올 충격의 합

$$\mathbf{Y}_{t+h} - \hat{\mathbf{Y}}_{t+h|t} = \sum_{s=0}^{h-1} \Theta_s \, \mathbf{u}_{t+h-s}$$

FEVD 정의

$$\mathrm{FEVD}_{ij}(h) = \frac{\sum_{s=0}^{h-1} [\Theta_s]_{ij}^2}{\sum_{s=0}^{h-1} \sum_{m=1}^{k} [\Theta_s]_{im}^2}, \qquad \sum_{j=1}^{k} \mathrm{FEVD}_{ij}(h) = 1$$

읽는 법

- 분자: 충격 j가 만든 분산, 분모: 전체 예측분산
- IRF가 모양이면 FEVD는 비중이다
- 짧은 지평은 보통 자기 충격이 지배한다
- 지평이 길면 다른 변수 충격의 몫이 커진다

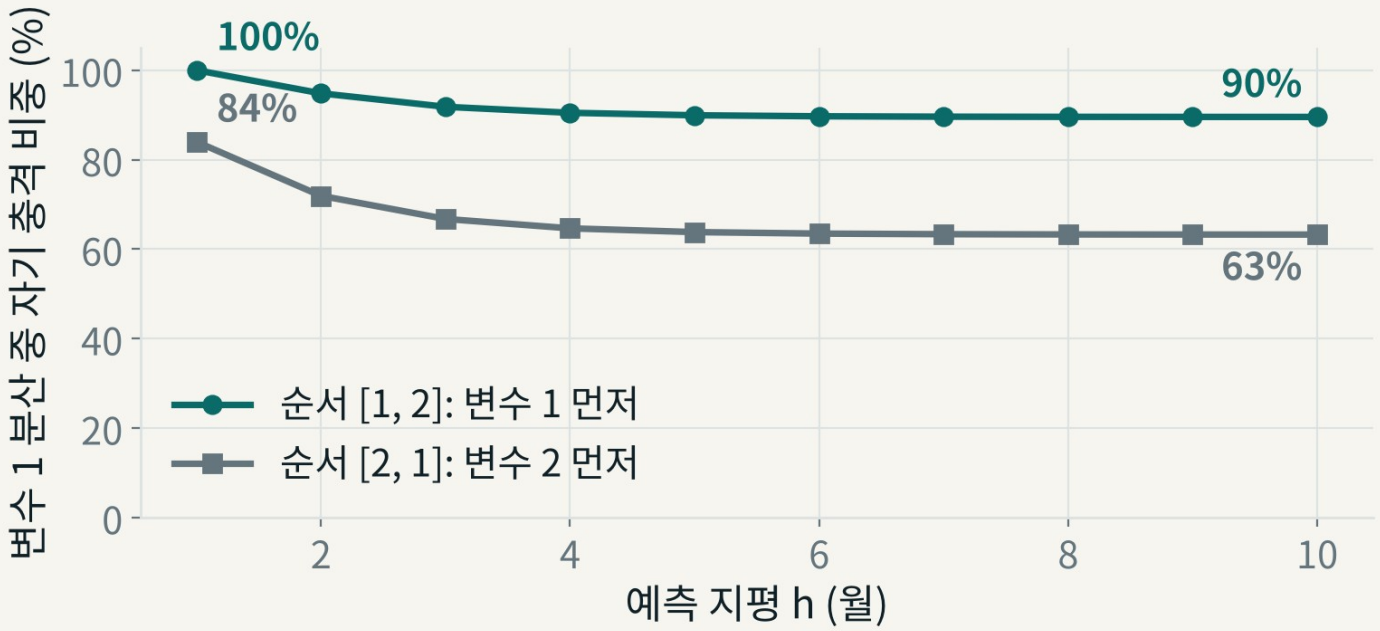
비중은 예측분산의 배분이지 인과적 기여도가 아니다

순서만 바꿔도 자기 충격 비중이 90%에서 63%로 바뀝니다

같은 VAR, 같은 데이터 — 촐레스키 순서만 [1, 2]와 [2, 1]로 바꾼 결과

ORDERING SENSITIVITY

- 순서 [1, 2]: 100% → 90%
- 순서 [2, 1]: 84% → 63%
- 공유 움직임이 앞 변수의 충격으로 넘어간다
- IRF·FEVD는 순서와 함께 보고한다



데이터는 그대로다 — 바뀐 것은 순서 가정뿐이다

04

종합

하나의 VAR가 세 개의 질문에 답한다

하나의 VAR가 세 가지 질문에 답합니다

그레인저는 예측, IRF는 경로, FEVD는 비중 — 뒤의 둘은 직교화가 필요하다

도구	답하는 질문	결과물	순서 가정
그레인저 인과	**X의 과거가 Y 예측을 돕는가**	**예·아니오와 방향**	**불필요**
충격반응함수	**X 충격이 Y를 어떻게 움직이나**	**시간에 따른 반응 경로**	**필요**
분산분해	**Y 불확실성의 몇 %가 X 충격인가**	**지평별 비중(%)**	**필요**

※ 축약형 VAR는 기술이지 인과 증명이 아니다 — 시스템은 작고, 정상이며, 진단을 거친 상태로 유지한다

다음 7주차: 공적분과 오차수정모형 — 수준(level)의 장기 균형으로

모형을 세운다 — VAR

예측 관계를 검정한다 — 그레인저

충격의 경로와 비중을 읽는다 — IRF · FEVD

다음 주
공적분과 오차수정모형